



华南理工大学
South China University of Technology

《人工智能理论及应用》

基于数据的机器学习

授课老师：青春美

联系邮箱：qchm@scut.edu.cn

2026年4月

目 录



01 基于数据的机器学习

02 强化学习

03 常见深度学习算法

04 模型驱动与数据驱动的融合

01

基于数据的机器学习





人工智能、机器学习和深度学习三者的联系和区别



人工智能是使计算机具有像人类一样智能的愿望，实现人工智能的方法和路径有很多，例如专家系统、规则系统等，其中机器学习是当前取得进展最大和发展最快的分支；机器学习包含了决策树、支持向量机、随机森林等很多学习方法，而深度学习只是机器学习领域的一种方法之一，它以深度神经网络的应用为主要特征。

人工智能

人工智能是计算机具有像人类一样智能的愿望，实现该愿望的路径有多种，机器学习是其中一种。

机器学习

机器学习是实现人工智能的一条技术路线，也是取得进展最大的路线

- 专家系统
- 规则系统
-

- 决策树
- 逻辑回归
- 支持向量机
- 集成学习
- 聚类
-

深度学习

深度学习是机器学习的一种方法

- 神经网络
- 卷积神经网络
- 循环神经网络
- ...

三个概念的联系和区别

人工智能

人工智能是一种使计算机具有像人类智能一样的能力和特征的技术和领域。

机器学习

机器学习是一种让计算机从数据中自动学习模式、规律和趋势，从而做出预测和决策的方法和技术。

深度学习

深度学习是机器学习的一种方法，它使用深度神经网络来学习和表示复杂的数据模式，当前深度学习几乎等同于神经网络。



人工智能的研究方法



01

基于知识的方法

- 专家系统：基于规则、“知识+推理”
- 知识图谱：结构化的知识表示、存储

02

基于学习的方法


基于数据的方法

- 机器学习：通过数据进行训练，建立自动学习模型
- 深度学习：基于神经网络，构建自动学习方法

03

基于仿生的方法

- 行为主义：模拟生物行为，进行学习
- 进化计算：模拟生物的进化过程，进行优化





数据驱动方法



近年来，机器学习与深度

投票 最多可选1项



基于数据的学习方法与基于知识的学习方法，你更倾向于使用哪种（ ）

- ☐ A 基于数据的学习方法
- ☐ B 基于知识的学习方法
- ☐ C 具体情况具体分析
- ☐ D 不了解，感觉差不多



机器学习概念的由来



机器学习 (Machine Learning) 这一概念最早由阿瑟·萨缪尔 (Arthur Samuel, 美国) 创造和提出, 阿瑟·萨缪尔也被称为“机器学习之父”。1952年萨缪尔在 IBM 701 计算机上开发出了自主学习型的跳棋程序, 在1956年2月24日, 萨缪尔的下棋程序和人类的西洋跳棋冠军进行公开对抗, 比赛通过电视实况转播, 人类棋手最终输给了电脑。自此“机器学习”这一概念得到了初步的确立与普及。



阿瑟·萨缪尔 Arthur Samuel

阿瑟·萨缪尔对机器学习的定义

Machine Learning is field of study that gives computers the ability to learn without being explicitly programmed.

机器学习：计算机在没有明确编程的情况下具有学习能力的研究领域。



机器学习的应用场景十分广泛



机器学习技术广泛地应用于个性化推荐、计算机视觉、自然语言处理、信用评估和风控等应用场景，并已经全面地渗透到我们生活、工作的方方面面。

机器学习技术已经渗透到我们生活、工作的方方面面

7:00 头条个性化推荐



8:00 自动驾驶去上班



9:00 人脸识别进入公司



11:00 微信语音转文字，与同事沟通



15:00 接到银行电话，信用额度增加



21:00 利用ChatGPT查找资料





机器学习的发展历史





机器学习的类别



机器学习是一类从数据中自动分析获得规律，并利用规律对未知数据进行预测的方法，可以分为监督学习、无监督学习和强化学习三种类型。



监督学习

在训练时，对数据进行了标记，相当于有一个“监督者”或者“老师”将答案告诉给机器，比如正确的分类（针对分类问题），帮助机器更好地学习。

决策树

逻辑回归

支持向量机

朴素贝叶斯

随机森林

...



无监督学习

在训练时，没有对数据进行标记（没有“老师”），由机器自己去观察不同数据的特征，从而发现规律的一种学习方式。

聚类

主成分分析

关联规则

自编码器

...



强化学习

主要研究作为主体的智能体与作为客体的环境交互的序列决策过程，以及“主体”在环境中逐渐学习到能产生最大的利益的习惯性行为的过程。

Q-Learning

sarsa

deep q network

policy gradients

...



机器学习的本质



机器学习的本质是通过对历史数据的学习，自动识别和发现数据中的规律和知识，并利用学习得到的规律和知识对未知数据进行预测的一个过程。简而言之，机器学习让计算机能从数据中“训练”，并预测未知的一种方法。





直观地理解机器学习



如同人类认识事物的过程一样，人通过观察不同的事物的关键特征和差异点，学习得到区分事物的知识，并将知识应用到日常生活中。机器学习是通过喂给计算机大量的历史数据，让计算机自动从数据中去学习，并利用学习得到的知识进行预测。

例：人类学习的过程—学习如何区分翘嘴、红尾和青梢三种鱼

机器学习

观察事物



找关键特征



学习得到知识



应用知识



头部形状、眼睛大小、尾巴颜色、鱼鳍颜色、鱼背形状

正确识别三种鱼的知识

• 鱼嘴上翘、眼大、背部平坦



翘嘴

• 头部稍尖、尾巴红色



红尾

• 口上位、高肩驼背、尾巴青黑色



青梢



钓到一条鱼，这是什么鱼？

这是一条 红尾

从历史数据学习




自动学习得到规律和知识



预测




机器学习的基本过程





机器学习思维导图





数据准备：数据质量是机器学习建模的前提



1. 定性数据

(1) 无序数据

- 如：性别可以分为：男，女，未知三类；学生的成绩可以分为：及格，不及格等。

(2) 顺序数据

- 如：如空气污染可分为：优、良、轻度污染、中度污染、重度污染，其中后面一级都比前面一级的程度更严重。
- 学生的成绩可分为：优秀，良好，及格，不及格，后面一级的数据也都比前面的更差，虽然是表示类别，但可以用数据的大小来反映类别之间的关系。




良好	普通	對敏感族群 不健康	對所有族群 不健康	非常 不健康	危害
0~50	51~100	101~150	151~200	201~300	301~500



2. 定量数据


(1) 离散型数据

● 不连续数据，这类数据在任何两个数据点之间的个数是有限的。例如：某年级有10个班，这里班级的数目就是离散数据。



(2) 连续型数据

● 任意两个数据点之间可以细分出无限多个数值。例如智商数。





数据处理的常见方式



CDA大数据 bilibili





数据处理常见方法



删除无关数据、重复数据；平滑噪声数据；筛选无关数据；处理缺失值、异常值

数据清洗

缺失值处理

删除记录

不做处理

数据插补

均值、众数、中位数插补

使用固定值

回归方法

插值法

牛顿插值法

拉格朗日插值法

最近临插补

异常值处理

删除含有异常值的记录


平均值修正

不做处理

视为缺失值



数据处理常见方法





数据处理常见方法





主要预处理函数

interpolate Scipy; 插值函数

unique Numpy; 去除数据重复值

isnull/notnull pandas; 判断是否空值/非空值

random Numpy; 随机矩阵

PCA scikit-learn; 主成分分析


CSDN @cx330上的猫



特征工程：起到特征提取和数据转换两大作用



特征工程是机器学习过程中很重要的一个环节，原始数据不能直接输入到机器学习模型中，需要经过特征工程这个处理过程，它从原始数据中提取能够更好地表示业务问题的特征，并将数据转换为机器学习模型能够处理的形式，特征工程主要有转换和提取两大作用。



将原始数据转换为特征数据，再输入到机器学习模型

特征工程是指从原始数据中**提取能够更好地表示业务问题的特征**，并将数据**转换为机器学习模型能够处理的形式**的一个过程。

特征工程的主要作用

一、转换：转换为机器学习模型能够处理的格式

- 不同的机器学习模型对于输入的数据是有不同的要求的，例如决策树模型可以处理非数值型变量，而神经网络模型则必须要求是数值型的变量数据，因此需要对原始数据进行转换处理。
- 不同的数据表达形式，例如变量间量纲是否相等等，对于建模效果和性能有着很大的影响，也需要对原始数据进行相应的转换处理。

二、提取：提取能够更好地表示业务问题的数据

- 不是所有的原始数据都可以看做特征，区分它们的关键在于看这个变量对解决这个业务问题有没有影响，因此需要通过特征提取来筛选出对于建模任务有用的变量。



特征工程定义



- 如果我们对特征工程(feature engineering)做一个定义, 那它指的是: 利用领域知识和现有数据, 创造出新的特征, 用于机器学习算法; 可以手动(manual)或自动(automated)。
- **特征**: 数据中抽取出来的对结果预测有用的信息。
- **特征工程**: 使用专业背景知识和技巧处理数据, 使得特征能在机器学习算法上发挥更好的作用的过程。





特征工程意义



- 在业界有一个很流行的说法：**数据与特征工程**决定了模型的**上限**，改进算法只不过是逼近这个上限而已。这是因为，在数据建模上，「理想状态」和「真实场景」是有差别的，很多时候原始数据并不是规矩干净含义明确充分的形态。而特征工程处理，相当于对数据做一个梳理，结合业务提取有意义的信息，以干净整齐地形态进行组织



原始数据送入模型

可直接建模



数据需要经过**特征工程处理**

再进入模型建模



特征工程意义



- 特征工程有着非常重要的意义：
 - **特征越好，灵活性越强。**只要特征选得好，即使是一般的模型（或算法）也能获得很好的性能，好特征的灵活性在于它允许你选择不复杂的模型，同时运行速度也更快，也更容易理解和维护。
 - **特征越好，构建的模型越简单。**有了好的特征，即便你的参数不是最优的，你的模型性能也能仍然会表现的很好，所以你就不要花太多的时间去寻找最优参数，这大大的降低了模型的复杂度，使模型趋于简单。
 - **特征越好，模型的性能越出色。**显然，这一点是毫无争议的，我们进行特征工程的最终目的就是提升模型的性能。






模型训练：样本数据分割



在模型训练时，通常情况下将数据集分为训练集、验证集和测试集三部分，训练集数据用于模型的训练，验证集数据用于模型选择、超参数选择时的比较验证，测试集数据用于评估模型的最终表现。



为什么需要验证数据？

1. 超参数选择

在一些机器学习模型中，需要设置超参数，例如模型的学习速率等，通过比较不同的超参数设置在验证数据集上的性能表现，帮助选择出最佳的超参数。

2. 模型选择

在机器学习过程中，有时需要比较不同的模型，通过比较不同模型在验证数据集上的表现来选择最佳的模型。



模型训练：常见的机器学习模型



在开始模型训练之前，需要选择合适的模型。按照监督学习和无监督学习两个大类，下图提供了最为常见的机器学习模型，在监督学习中，很多模型即可用来解决分类问题，也可以用来解决回归问题。







常见的机器学习模型




• 机器学习常用方法




决策树




逻辑回归（分类）




神经网络



支持向量机





贝叶斯分类器



基于数据的机器学习是通过输入训练数据对模型进行训练，使模型掌握数据所蕴含的潜在规律，进而对所输入的数据进行准确的分类或预测。





线性回归



- 在统计学和机器学习领域，线性回归可能是最广为人知也最易理解的算法之一。线性回归模型被表示为一个**方程式**，它为输入变量找到特定的权重（即系数 B ），进而描述一条最佳拟合了输入变量（ x ）和输出变量（ y ）之间关系的**直线**。例如： $y = B_0 + B_1 * x$
- 我们将在给定输入值 x 的条件下预测 y ，线性回归学习算法的**目的是找到系数 B_0 和 B_1 的值**。





决策树



- 决策树可以被表示为一棵**二叉树**。每个节点都代表一个输入变量（x）和一个基于该变量的分叉点（假设该变量是数值型的）。
- 决策树的**叶子结点**包含一个用于做出**预测的输出变量**（y）。预测结果是通过在树的各个分叉路径上游走，直到到达一个叶子结点并输出该叶子结点的类别值而得出。
- 简单决策树**算法案例**，确定人群中谁喜欢使用信用卡。考虑人群的年龄和婚姻状况，如果年龄在30岁或是已婚，人们更倾向于选择信用卡，反之则更少。通过确定合适的属性来定义更多的类别，可以进一步扩展此决策树。在左边例子中，如果一个人结婚了，他超过30岁，他们更有可能拥有信用卡。





支持向量机



- 支持向量机（SVM）可能是目前最流行、被讨论地最多的机器学习算法之一。
- 支持向量机/网络算法(SVM)属于**分类型算法**。SVM模型将实例表示为空间中的点，将使用一条直线分隔数据点。需要注意的是，支持向量机需要对输入数据进行完全标记，仅直接适用于两类任务，应用**将多类任务需要减少到几个二元问题**





随机森林



- 随机森林算法（Random Forest）的名称由 1995 年由贝尔实验室提出的random decision forests 而来，正如它的名字所说的那样，随机森林可以看作一个**决策树的集合**。
- 随机森林中每棵决策树估计一个分类，这个过程称为“**投票 (vote)**”。理想情况下，我们根据每棵决策树的每个投票，选择最多投票的分类



聚类



- 聚类任务是一种“**无监督学习**”，训练样本的标记信息是未知的，目标通过无标记训练样本的学习来**揭示数据的内在性质及规律**。
- 聚类的任务是将数据集中的样本划分为若干个不相交的子集，每个子集称为一个簇
- 聚类分为原型聚类，密度聚类，层次聚类，其中应用较广的是**原型聚类**。



模型评估：分类模型中的评估指标



在二分类问题中，经常用查准率（精确率）和查全率（召回率）两个指标来评估机器学习模型的好坏，查准率和查全率两个指标越高越好，但是在实际情况中，这两个指标往往是相互矛盾的，查准率越高可能意味着查全率越低，反之亦然。

混淆矩阵

真实结果	预测结果	
	正例	负例
正例	TP	FN
负例	FP	TN

在二分类预测中，根据模型预测结果、真实结果两个维度，可以将预测结果分为以下四种情况：

- TP (True Positive)：表示真实结果为正例，预测结果也为正例；
- FP (False Positive)：表示真实结果为负例，预测结果却是正例；
- TN (True Negative)：表示真实结果为负例，预测结果是负例；
- FN (False Negative)：表示真实结果为正例，预测结果是负例；

查准率

- 查准率也叫精确率，指的是模型预测的正例中，其中真实情况也为正例的比例，是衡量预测准确性的重要指标。

$$\text{查准率/精确率 (precision)} = \frac{TP}{TP + FP}$$

我们希望查准率越高越好，例如在预测某个商品的潜在用户中，查准率越高，那么在营销时成功率就越高，模型带来的业务效果就越好。

查全率


- 查全率也叫召回率，指的是模型预测的正例，占真实情况中所有正例的比例。

$$\text{查全率/召回率 (recall)} = \frac{TP}{TP + FN}$$

我们同时也希望查全率越高越好，预测商品潜在用户的场景中，如果能够把



机器学习的应用





机器学习的应用



- 机器学习促进人工智能飞速发展，使人工智能已经渗透进人类社会的不同行业和生活环节。



应急管理



精准农业



智能制造



智能交通



智慧医疗



智能反恐



物流仓储



电力巡检

02

强化学习





强化学习简史



是花子呀_ bilibili





强化学习是什么



2016

Alpha Go 战李世石


Alpha Go 挑战世界冠军韩国职业棋手李世石，以4:1的结果取胜



2019

Alpha Star 登上Nature

已经达到星际争霸2人类对战天梯的顶级水平





强化学习是什么



• 虚拟教师

- 不会指导要去做什么
- 只会对行为打分



• 对比监督学习

- 强化学习一开始并没有数据和标签
- 在不断尝试中学习到哪些数据能得高分






强化学习是什么



强化学习 (reinforcement learning, RL) 讨论的问题是智能体 (agent) 怎么在复杂、不确定的环境 (environment) 中最大化它能获得的奖励。

在强化学习过程中, 智能体与环境一直在交互。智能体在环境中获取某个状态后, 它会利用该状态输出一个动作 (action), 这个动作也称为决策 (decision)。然后这个动作会在环境中被执行, 环境会根据智能体采取的动作, 输出下一个状态以及当前这个动作带来的奖励。智能体的目的就是尽可能多地从环境中获取奖励。






强化学习与监督学习



监督学习 (supervised learning) 假设我们有大量被标注的数据，这些图片都要满足独立同分布，即它们之间是没有关联关系的。假设我们训练一个分类器，比如神经网络。为了分辨输入的图片中是汽车还是飞机，在训练过程中，需要把正确的标签信息传递给神经网络。当神经网络做出错误的预测时，比如输入汽车的图片，它预测出来是飞机，我们会直接告诉它，该预测是错误的，正确的标签应该是汽车。最后我们根据类似错误写出一个损失函数 (loss function)，通过反向传播 (back propagation) 来训练神经网络。

训练有标签的数据



预测值：
飞机

预测错误
真实标签：汽车

反向传播




强化学习与监督学习




强化学习的训练数据就是一个玩游戏的过程。我们没有标签来说明现在这个动作是正确还是错误的，必须等到游戏结束才可能知道。这里我们就面临**延迟奖励 (delayed reward)** 的问题，延迟奖励使得训练网络非常困难。

训练数据



人类在玩?



正确还是错误?
我们不会知道, 直到游戏结束
奖励延迟



反向传播?



强化学习与监督学习



- (1) 强化学习输入的样本是**序列数据 (sequential data)**。在机器学习中，如果观测数据有非常强的关联，会使得训练非常不稳定。
- (2) 学习器并没有告诉我们每一步正确的动作应该是什么，学习器需要自己去发现哪些动作可以带来最多的奖励，只能通过不停地尝试来发现最有利的动作。在强化学习里面一个非常重要的问题就是，**怎么让智能体的动作一直稳定地提升**。
- (3) 智能体获得自己能力的过程，其实是不断地**试错探索 (trial-and-error exploration)**的过程。探索 (exploration) 和利用 (exploitation) 是强化学习里面非常核心的问题。我们需要在探索和利用之间进行权衡。
- (4) 在强化学习过程中，没有非常强的监督者 (supervisor)，只有**奖励信号 (reward signal)**，并且奖励信号是延迟的，即环境会在很久以后告诉我们之前我们采取的动作到底是不是有效的。因为我们没有得到即时反馈，所以智能体使用强化学习来学习就非常困难。



强化学习发展历史



早期基础 (20世纪50-60年代)

- **行为主义和试探学习理论**: 强化学习的早期理论基础来自于心理学中的行为主义, 特别是B.F.斯金纳 (B.F. Skinner) 的操作性条件反射理论和Edward Thorndike的试错学习理论。
- **控制论**: 控制论家Norbert Wiener在1948年提出的《控制论》一书中, 描述了通过反馈控制系统来优化行为的概念, 这为后来的强化学习奠定了基础。
- **Bellman方程**: Richard Bellman在1957年提出的动态规划和Bellman方程, 为后来的强化学习算法提供了理论支持。

初步发展 (20世纪70-80年代)

- **马尔可夫决策过程 (MDP)**: 在20世纪60年代, Ronald A. Howard提出了马尔可夫决策过程 (MDP), 为强化学习提供了一个数学框架。
- **TD算法**: 在1980年, Arthur Samuel开发了自学习的跳棋程序, 展示了TD (Temporal Difference, 时序差分) 学习的应用。
- **Watkins的Q-learning**: 在1989年, Christopher Watkins提出了Q-learning算法, 这是一种基于值函数的无模型强化学习方法, 成为了强化学习研究的一个重要里程碑。



强化学习发展历史



强化学习的兴起 (20世纪90年代)

- **《Reinforcement Learning: An Introduction》**：Richard S. Sutton和Andrew G. Barto在1998年出版了《强化学习：一个介绍》，系统化地介绍了强化学习的基本原理和方法，成为该领域的经典教材。
- **应用于游戏和控制**：在1992年，Gerald Tesauro开发了TD-Gammon，一个用于学习和玩双陆棋的强化学习程序，取得了显著成功，展示了强化学习在复杂任务中的潜力。

深度学习与强化学习的结合 (21世纪初至今)

- **深度Q网络 (DQN)**：2013年，DeepMind的研究团队将深度学习和强化学习结合，提出了深度Q网络 (DQN) 算法，成功在多个雅达利游戏上超越人类表现。这标志着**深度强化学习 (Deep Reinforcement Learning)** 的兴起。
- **AlphaGo**：2016年，DeepMind开发的AlphaGo程序使用深度强化学习和蒙特卡罗树搜索 (MCTS) 击败了围棋世界冠军李世石，展示了强化学习在复杂战略游戏中的潜力。
- **策略梯度方法**：Policy Gradient Methods，包括REINFORCE，Proximal Policy Optimization (PPO) 和 Trust Region Policy Optimization (TRPO)：用于提高强化学习算法的稳定性和效率。
- **AlphaZero**：在2017年，DeepMind进一步开发了AlphaZero，通过自我对弈的方式学习，成功掌握了围棋、国际象棋和将棋等多个游戏，展示了通用强化学习算法的强大能力。



强化学习发展历史



近年来的进展

- **多智能体强化学习**：随着研究的深入，多智能体强化学习（Multi-Agent Reinforcement Learning, MARL）成为一个重要的研究方向，探索多个智能体在共享环境中的协作和竞争。
- **元强化学习**：研究者们开始探索元强化学习（Meta-Reinforcement Learning），旨在开发能够快速适应新任务的通用智能体。
- **应用领域拓展**：包括机器人控制、自动驾驶、金融交易、智能制造和医疗健康等。

当前研究热点

- **高效探索和利用**：如何在未知环境中高效探索并利用已有知识仍是强化学习的核心问题。如探究算法（Exploration Algorithms）。
- **长期依赖和信用分配**：研究如何处理长期依赖问题和有效分配奖励以改进学习策略。如分层强化学习（Hierarchical Reinforcement Learning）。
- **安全性和鲁棒性**：确保强化学习算法在实际应用中能够安全、可靠地运行。安全强化学习（Safe Reinforcement Learning）。
- **可解释性和透明性**：提高强化学习模型的可解释性，使其决策过程更加透明。可解释强化学习（Interpretable Reinforcement Learning）。



强化学习分类





- 按照环境是否已知划分

- 免模型学习 (Model-Free) : Q-learning
- 有模型学习 (Model-Based)

- 按照学习方式划分

- 在线策略 (On-Policy) : Sarsa
- 离线策略 (Off-Policy) : Q-learning, Deep-Q-Network





强化学习分类



	有模型 (model-based)	免模型 (model-free)
代表算法	Dyna算法, 马尔可夫决策过程 (MDP)	policy optimization, Q-learning
	通过学习状态的转移来采取动作	通过学习价值函数和策略函数进行决策。没有去直接估计状态的转移。
	需要对环境进行建模, 同时在真实环境与虚拟环境中进行学习。	不需要对环境进行建模, 直接与真实环境进行交互即可。
	如果建模的环境与真实环境的差异较大, 那么会限制其泛化性能。	通常需要较多的数据或者采样工作来优化策略, 这也使其对于真实环境具有更好的泛化性能。






强化学习分类



- 按照学习目标划分

- 基于策略 (Policy-Based) : Policy gradients, Actor-Critic
- 基于价值 (Value-Based) : Q-learning、Deep Q Network, Sarsa, Actor-Critic



知乎 @张浩



强化学习分类



	基于价值的智能体	基于策略的智能体
代表算法	Q学习 (Q-learning)、Sarsa、演员-评论员算法	策略梯度 (Policy Gradient, PG)、演员-评论员算法
	智能体不需要制定显式的策略，它维护一个价值表格或价值函数，并通过这个价值表格或价值函数来选取价值最大的动作。	智能体会制定一套动作策略（确定在给定状态下需要采取何种动作），并根据这个策略进行操作。
		强化学习算法直接对策略进行优化，使制定的策略能够获得最大的奖励。
范围	不连续的、离散的环境下（如围棋或某些游戏领域）	动作集合规模庞大、动作连续的场景（如机器人控制领域）



Q-learning



- Q-learning是一个决策过程
- 使用Q值表(Q-Table)计算每个状态的最大预期未来奖励



Initialize $Q(s, a)$ arbitrarily
Repeat (for each episode):
 Initialize s
 Repeat (for each step of episode):
 Choose a from s using policy derived from Q (e.g., ϵ -greedy)
 Take action a , observe r, s'
 $Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$
 $s \leftarrow s'$
 until s is terminal

Annotations in the diagram:

- $Q(s_2)$ 最大估计 (Maximum estimate of $Q(s_2)$)
- $Q(s_1, a_2)$ 现实 (Actual $Q(s_1, a_2)$)
- $Q(s_1, a_2)$ 估计 (Estimated $Q(s_1, a_2)$)



Deep Q Network




- 经验回放

DQN利用Qlearning特点，目标策略与动作策略分离，学习时利用经验池储存的经验取batch更新Q。同时提高了样本的利用率，也打乱了样本状态相关性使其符合神经网络的使用特点。

- 固定Q目标

神经网络一般学习的是固定的目标，而Qlearning中Q同样为学习的变化量，变动太大不利于学习。所以DQN使Q在一段时间内保持不变，使神经网络更易于学习。





Policy Gradient 策略梯度




• 优点

- 连续的动作空间（或者高维空间）中更加高效；
- 可以实现随机化的策略；
- 某种情况下，价值函数可能比较难以计算，而策略函数较容易。

• 缺点

- 通常收敛到局部最优而非全局最优
- 评估一个策略通常低效（这个过程可能慢，但是具有更高的可变性，其中也会出现很多并不有效的尝试，而且方差高）



输入当前的状态，输出action的概率分布，选择概率最大的一个action作为要执行的操作。



Actor-Critic 演员-评论家算法



- 演员-评论家算法(Actor-Critic)是基于策略(Policy Based)和基于价值(Value Based)相结合的方法
- 演员(Actor)是指策略函数 $\pi_{\theta}(a|s)$, 即学习一个策略来得到尽量高的回报。
- 评论家(Critic)是指值函数 $V^{\pi}(s)$, 对当前策略的值函数进行估计, 即评估演员的好坏。

Move
down



Actor



Bad
action



Critic





AlphaGo 为什么厉害



- 蒙特卡洛树搜索

它能使用这种树形结构来尝试非常多的策略，每一个树的分支就是一种可能的发展趋势。这种形式正是在国际象棋AI上所采取的方式，当时IBM开发的国际象棋人工智能 Deep Blue，通过这种树形搜索在1997年战胜人类的。但是在围棋中，同样的套路并不适用，所以 DeepMind 团队放弃广泛的搜索，取而代之的是深度搜索，这种搜索更节省计算资源，对有限的情况，分析更加准确。不过单单有这种树形搜索是远远不够的。






AlphaGo 为什么厉害




• 神经网络

一个简单的神经网络包括了三个方面，**接受外界的信息**，比如说一张棋谱，然后通过神经网络内部的千万个神经节点，**将接收到的信息进行加工处理**，换做我们人类，这个过程就叫做“理解”。最后**将理解的东西输出**，它可以是下一个要采取的动作，或者是对当前下棋状态的评估。AlphaGo 中就使用了两套神经网络系统 一个神经网络基于当前的状态给出下一步的动作，一个神经网络用来评估当前状态是否对我方有利。使用神经网络配合搜索树来提供好的下棋行为，将这些好行为作为训练数据反过来训练神经网络，这样一来一回，使用**强化学习**的方法不断训练，我们的神经网络就能不断的提升自己下棋的能力。



深度强化学习 (Deep Reinforcement Learning, DRL)



感知 (深度学习) + 决策 (强化学习) = 深度强化学习

核心思想

深度强化学习 = 深度学习的感知能力 + 强化学习的决策能力。利用深度神经网络的强大表示能力，解决传统强化学习在高维连续状态/动作空间中表现有限的问题——使智能体能够直接从原始图像、传感器等复杂输入中学习最优策略。

代表算法

DQN: Q-learning + 卷积神经网络，处理复杂视觉输入

DDPG: 深度确定性策略梯度，连续动作控制

PPO: 近端策略优化，ChatGPT/RLHF 核心算法

GRPO: PPO 变体，DeepSeek-R1 使用

典型应用

机器人控制、自动驾驶、大语言模型等

深度强化学习 (Deep Reinforcement Learning, DRL)

梗直哥、bilibili

RLHF：把人类好恶变成奖励信号

前面所提到的 PPO 等策略梯度算法，奖励来自游戏得分这类明确信号。但训练一个会聊天的 AI，谁来打分？给出了答案

①

第一步：预训练语言模型 (Pre-training)

在海量文本上训练模型预测下一个词，让模型学会语言规律。

②

第二步：人类示范微调 (SFT)

让标注员写出高质量问答示例，模型照着学，让模型知道什么叫好的回答。

③

第三步：RLHF —— 用人类偏好作为奖励

训练奖励模型学会判断哪个回答更好（人类对多个候选排序），再用 PPO 等策略梯度算法以此为信号持续优化——这正是 ChatGPT 的关键技术。

RLHF 将强化学习的奖励最大化思想迁移到语言模型：用人类判断代替环境给分，让模型学会说人话，而不只是预测下一个词。

► 推荐视频：ChatGPT 是怎么包装强化学习的？



ChatGPT狂飙：强化学习 RLHF 与 PPO!

ZOMI酱

<https://www.bilibili.com/video/BV1eT411S7Yx/>

DeepSeek-R1：用纯强化学习激发推理能力（2025.1）

2025 年 1 月，DeepSeek 发布 R1，将强化学习推向新高度——不需要人类标注推理步骤，通过自动验证最终答案来提供奖励信号，让模型在可验证的任务（数学、编程等）上自主发展推理能力。

① 从 RLHF 到 RLVR（可验证奖励强化学习）

RLHF 中人类给语言回答打分；RLVR 针对数学、代码——答案对错可自动验证，奖励信号更纯粹，无需人工介入。

② GRPO：更轻量的策略优化算法

相比 PPO 需要额外价值网络，GRPO 通过同一问题多次采样取均值来估计优势，大幅节省计算资源。

③ 推理能力的自发涌现

训练中模型自发学会自我验证、回溯重想等行为——与 AlphaGo 通过自弈提升棋力的思路如出一辙。

代表成果：在 AIME 2024（美国数学邀请赛）上，从初始 15.6% 提升至 77.9%（自洽解码 86.7%），逼近 OpenAI o1 水平；RL 训练成本仅约 30 万美元，完全开源。

► 推荐视频：DeepSeek-R1 的强化学习是怎么工作的？



DeepSeek-R1深度解读，大模型+强化学习重挫英伟达股价

ZOMI酱

<https://www.bilibili.com/video/BV1dHw4e8E3e/>




一个故事秒懂强化学习与 GRPO！

懂点AI事儿

<https://www.bilibili.com/video/BV1Tg94Y8Eq/>



强化学习应用





强化学习应用：机械臂翻魔方



OpenAI 在 2018 年的时候设计了一款带有“手指”的机械臂，它可以通过翻动手指使得手中的木块达到预期的设定。

OpenAI 先在一个虚拟环境里面使用强化学习对智能体进行训练，再把它应用到真实的机械臂上。

学习走路



学习抓取



学习操作



学习穿衣






现在是强化学习开启商用的时机吗？




强化学习可以处理复杂、随机、长期动态变化的场景问题，商业价值极大，但难度与风险也高居首位。



Phil Winder • Reinforcement Learning



什么条件下适合使用强化学习落地?






目前的强化学习应用与落地



• 智能决策平台赋能产业化项目

决策平台 能源——强化学习调度解决方案






目前的强化学习应用与落地



能源——电网智能控制

- 在新能源为主的电网系统中，突发极端天气和重大事件等随机因素会对供给侧和负荷侧稳定性造成重大影响；
- 系统将提供基于强化学习的电网运行故障辅助处置模型，提供更低风险的处置支撑。



在包含新能源与储能元素的电网系统环境中，引入随机攻击（如电网中的多根线路会随机跳闸），输出的每一时刻电网状态观测值（Observation），来决定执行不同的操作动作值（Action），探索电网潮流收敛、母线过载符合规定的状态下，**更可靠、更经济、负荷损失更小**的电网运行故障辅助处置方案。

仿真器



有专家系统
有标准的解决方案
(潮流计算)



有具体指标
可评估结果优劣
(电网正常运行，能耗低)



需要达到全局
(长期)最优
(序列决策问题)







目前的强化学习应用与落地



交通——交通灯控制

- Deep DL 在智能交通系统中的一个主要应用领域之一为交叉口信号控制。算法利用检测到的实时交通数据计算出合适的交通灯配时方案，最终应用到交通灯上，通常可以表现出比规则模型更好的性能（全局/长期 最优）



最直接的reward应该是车辆通过交叉口的总行驶时间，但是这时间在每个时间步内无法直接计算，所以一般将reward设置为交叉路口的队列长度、车辆的等待时间、交叉口的吞吐量等。

仿真器

有专家系统
(规则)

有具体
评估指标
(车辆等待时间)

需达到全局
(长期) 最优
(序列决策问题)



强化学习资料



强化学习入门教程

【OpenAI出品的强化学习 (RL) 入门教程】

<https://spinningup.openai.com/en/latest/index.html>

【开源平台Hugging Face上的深度强化学习课程】

<https://hugging-face.cn/learn/deep-rl-course/unit0/introduction>

强化学习开源项目

【乒乓球游戏+策略梯度算法】

<https://karpathy.github.io/2016/05/31/rl/>

【小鸟FlappyBird游戏+DQN算法】

<https://www.jianshu.com/p/3ba69493f020>

【Torcs自动驾驶+DDPG算法】

<https://yanpanlau.github.io/2016/10/11/Torcs-Keras.html>



一个视频回顾深度学习、强化学习、深度强化学习的区别与联系




Deep Learning



Reinforcement Learning



Deep Reinforcement Learning



视频来源：[【科普向】深度学习、强化学习、深度强化学习傻傻分不清？概念及名词解释_哔哩哔哩_bilibili](#)

03

常见深度学习算法





深度学习简介





□ 深度学习的框架

框 架	机 构	支持语言
TensorFlow	Google	Python/C++/Go/..
Caffe	BVLC	C++/Python
Keras	fchollet	Python
CNTK	Microsoft	C++
MXNet	DMLC	Python/C++/R/..
Torch7	Facebook	Lua
Theano	U.Montreal	Python
Deeplearning4J	DeepLeaming4J	Java/Scala
Leaf	AutumnAI	Rust
Lasagne	Lasagne	Python
Neon	NervanaSystems	Python
PaddlePaddle	百度	Python/C++/Java
MindSpore	华为	Python/C++/Java

 TensorFlow

 PyTorch

 Keras


theano



深度学习模型



深度学习框架





深度学习：基本概念与术语



□ 深度学习

- 深度学习，具体来说，是深度神经网络学习。
- 深度学习是机器学习的一个重要分支。机器学习底下有一条“神经网络”路线，而深度学习，是加强版的“神经网络”学习。





深度学习：基本概念与术语



深度学习 $\approx$ 神经网络

深度学习 $\neq$ 神经网络

深度学习是传统神经网络的升级版本

部分深度学习算法中会出现“神经网络”4个字

假设深度学习要处理的信息是“水流”，而处理数据的深度学习网络是一个由管道和阀门组成的巨大水管网络。

深度学习类似一个水流系统





深度学习：基本概念与术语



将图片数字化



当计算机看到一张写有“田”字的图片，就简单将组成这张图片的所有数字（在计算机里，图片的每个颜色点都是用“0”和“1”组成的数字来表示的）全都变成信息的水流，从入口灌进水管网络

深度学习 – 识别“田”字






深度学习：基本概念与术语



传统机器学习和深度学习的「相似点」



深度学习的优点和缺点

优点

1. 学习能力强
2. 覆盖范围广、适应性好
3. 数据驱动、上限高
4. 可移植性好



缺点

1. 计算量大、便携性差
2. 硬件需求高
3. 模型设计复杂
4. 没有“人性”、容易产生偏见



□ 神经网络

- 神经网络是联结主义的代表。
- 神经网络是模仿人脑的工作原理，建立神经元之间的联结模型，以此实现人工神经运算。






深度学习：基本概念与术语



深度学习

深度学习所谓的“深度”，是指神经网络中“隐藏层”的层级更“深”：

- 经典机器学习算法使用的神经网络，具有输入层、一个或两个“隐藏层”和一个输出层。
- 深度学习算法使用了更多的“隐藏层”（数百个）。它的能力更加强大，让神经网络能够完成更困难的工作。





□ 神经网络的几大经典模型

- 卷积神经网络 (Convolutional Neural Network, CNN)
- 循环神经网络 (Recurrent Neural Network, RNN)
- 生成对抗网络 (Generative Adversarial Network, GAN)
- 长短期记忆网络 (Long Short-Term Memory, LSTM)
- Transformer (转换器)
- 扩散模型 (Diffusion Model)




卷积神经网络



□ 卷积神经网络 (CNN)

- 是一种专门设计用于处理具有网格结构的数据（如图像和视频）的深度学习模型。
- 在计算机视觉领域取得了显著的成功，尤其是在图像分类、物体检测、语义分割等任务中表现突出。
- 基本组成部分：卷积层、激活函数、池化层、全连接层。





卷积神经网络




AI学习探索者 bilibili

今天我们分享的主题是



卷积神经网络







循环神经网络(RNN)



- 一种特殊的神经网络架构，专门设计用于处理序列数据，例如时间序列数据、文本序列、语音信号等。
- 与传统的前馈神经网络不同，RNN 可以处理可变长度的输入序列，并且能够记住先前的输入以影响后续的输出。
- 核心思想是在网络中引入循环连接，允许信息在不同的时间步之间流动。这样，每个时间步的输出不仅可以作为下一个时间步的输入，还可以影响当前时间步的输出。这种设计使得 RNN 能够捕捉序列数据中的长期依赖关系。






• RNN变体——长短期记忆网络LSTM

- 在传统RNN中，短期记忆比长期记忆的影响更大

- 长短期记忆网络 (Long Short Term Memory Network, LSTM), 是一类特殊的循环神经网络它主要能解决传统RNN面临的长期依赖问题






Transformer



Transformer (转换器)

- 一种基于自注意力机制的深度学习模型，最初由Google研究人员在2017年提出，用于处理序列数据。
- 通过自注意力机制，允许模型在处理序列的任何元素时，同时考虑序列中的所有其他元素并给出不同元素的重要程度，从而极大地提高了模型在语言理解、情感分析、语音识别等复杂任务中的表现。
- Transformer模型因其高效和强大的性能，已经成为自然语言处理领域的标准架构之一。





Transformer





Transformer 结构



Transformer 结构是由谷歌在2017 年提出并首先应用于机器翻译
Transformer结构完全通过注意力机制完成对源语言序列和目标语言序列全局依赖的建模。如今，几乎全部大语言模型都是基于Transformer 结构的。
本节以应用于机器翻译的基于Transformer 的编码器和解码器为例介绍该模型。

Attention Is All You Need

Ashish Vaswani*
Google Brain
avaswani@google.com

Noam Shazeer*
Google Brain
noam@google.com

Niki Parmar*
Google Research
nikip@google.com

Jakob Uszkoreit*
Google Research
usz@google.com

Llion Jones*
Google Research
llion@google.com

Aidan N. Gomez* †
University of Toronto
aidan@cs.toronto.edu

Lukasz Kaiser*
Google Brain
lukaszkaizer@google.com

Illia Polosukhin* ‡
illia.polosukhin@gmail.com



Transformer 结构



自注意力 (Self-Attention) 操作是基于 Transformer 的语言模型的基本操作，在源语言的编码和目标语言的生成中频繁地被使用以建模源语言、目标语言任意两个单词之间的依赖关系。

$$Z = \text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V$$





图 2.2 自注意力机制中的查询、键、值向量



深度学习的一大应用：生成模型



看起来逼真但现实中不存在的人脸

前述的分类、检测、分割模型都是对给定的样本进行判定的模型。随着深度学习的发展，另一类模型，即“**生成模型**”，也引起了人们的广泛关注。通过**生成模型**，我们可以“**从无到有**”地生成一些**现实世界中不存在然而逼真的样本**。同时，生成模型也在虚拟现实、数字人、三维场景重建等领域中发挥了重要的作用。

生成模型的典型代表：

1. 变分自编码器 (Diederik P. Kingma, 2014)
2. 生成对抗网络 (Ian Goodfellow, 2014)
3. 扩散模型 (Jascha Sohl-Dickstein, 2015)



生成模型对比




特征	扩散模型(DM)	GAN	VAE
训练稳定性	高，相对无模式崩溃	低，易不稳定，模式崩溃	中等，基于变分推断
生成质量	高，细节丰富	高，但易出现模式缺失或崩溃	一般较清晰度略逊
显式概率解释	有，基于似然、KL散度	无显式似然	有(ELBO)
推断速度	慢，多步迭代	快，单次前向传递	快，同上
多样性	避免模式崩溃，样本多样	可能模式崩溃	尚可



生成对抗网络简介 (GAN)



- 采用了一种对抗式的训练方法，其中两个神经网络相互竞争：一个称为生成器 (Generator)，另一个称为判别器 (Discriminator)。这两个网络的目标是相反的，但最终它们共同协作以生成高质量的数据样本。
- 非常适用于图片生成、图像分割、视频预测、风格迁移等。






变分自编码器(VAE)简介



- GAN的想法是，训练一个神经网络，用于辨别某图片是不是和训练集里的图片长得一样。生成图像的神经网络叫做**生成器**，鉴定图像的神经网络叫做**判别器**。两个网络**互相对抗**，共同进步。
- VAE则使用了**逆向思维**：用向量生成图像很困难，那就同时学习怎么用图像生成向量。这样，把某图像变成向量，再用该向量生成图像，就应该得到一幅和原图像一模一样的图像。VAE中，把图像变成向量的网络叫做**编码器**，把向量转换回图像的网络叫做**解码器**。其中，解码器就是负责生成图像的模型。







变分自编码器(VAE)简介



• 举例说明VAE





扩散模型简介





扩散模型简介



问题


- 如何对训练数据建模?
- 如何采样?

思路

- 从一个简单分布采样是容易的
- 从简单分布到观测数据分布是可以拟合的

生成模型的解题思路

- 将观测数据分布映射到简单分布 【Encoder】
- 从简单分布中映射到观测数据分布 【Decoder】






扩散模型简介




具体来说，扩散模型由正向过程和反向过程这两部分组成，对应VAE中的编码和解码。在正向过程中，输入 x_0 会不断混入高斯噪声。经过 T 次加噪声操作后，图像 x_T 会变成一幅符合标准正态分布的纯噪声图像。而在反向过程中，我们希望训练出一个神经网络，该网络能够学会 T 个去噪声操作，把 x_T 还原回 x_0 。网络的学习目标是让 T 个去噪声操作正好能抵消掉对应的加噪声操作。训练完毕后，只需要从标准正态分布里随机采样出一个噪声，再利用反向过程里的神经网络把该噪声恢复成一幅图像，就能够生成一幅图片了。






基于扩散的新型多模态生成模型



语义交叉注意力



物理世界模拟



组合概念学习



Stable Diffusion XL

Get involved with the fastest growing open software project. Download and join other developers in creating incredible applications with Stable Diffusion XL as a foundation model.

2023.7



Stable Diffusion 3 Large

The largest base model in the SD3 series delivers outstanding quality, with a balanced trade-off between output speed and image excellence. Ideal for content creation in media, entertainment, and retail industries.

2024.7



Stable Diffusion 3.5 Large

At 8 billion parameters, with superior quality and prompt adherence, this base model is the most powerful in the Stable Diffusion family. This model is ideal for professional use cases at 1 megapixel resolution.

2024.10



扩散生成模型学习资料



扩散模型基础原理讲解

【【较真系列】讲人话-Diffusion Model全解(原理+代码+公式)】

https://www.bilibili.com/video/BV19H4y1G73r?vd_source=e3c1c841af4f412fd055e3f14fcbda43

【【AI博士】由浅入深了解扩散模型Diffusion Model】

https://www.bilibili.com/video/BV1tY4y1N7jg?vd_source=e3c1c841af4f412fd055e3f14fcbda43

Stable Diffusion全解 & 三维表征NeRF 3DGS讲解

【【串讲系列】讲人话-Stable Diffusion全解（原理+代码+公式）之SD1.5】

https://www.bilibili.com/video/BV1KStDeSENA?vd_source=e3c1c841af4f412fd055e3f14fcbda43

【【较真系列】讲人话-NeRF全解（原理+代码+公式）】

https://www.bilibili.com/video/BV1CC411V7oq?vd_source=e3c1c841af4f412fd055e3f14fcbda43

【【较真系列】讲人话-3d gaussian splatting全解(原理+代码+公式)【1】捏雪球】

https://www.bilibili.com/video/BV1zi421v7Dr?vd_source=e3c1c841af4f412fd055e3f14fcbda43



基于自回归模型的图像生成模型



自回归模型将图像生成视为序列预测问题，主要分为三类：

1. **像素级预测**：如PixelRNN，逐像素生成图像，但计算成本高。

2. **分词级预测**：如VQ-VAE，将图像压缩为离散token，再用Transformer建模。

3. **多token预测**：如VAR（视觉自回归模型），通过分层预测提升效率。

尽管扩散模型目前在图像质量上占优，但自回归模型因其与LLM的结构一致性，更受统一框架的青睐。




Fig. 4. Illustration of core components in autoregressive models, including the autoregression sequence modeling and discrete vector quantization. Existing autoregressive models can be roughly divided into three types: Next-Pixel Prediction flattens the image into a pixel sequence, Next-Token Prediction converts the image into a token sequence via a visual tokenizer, and Next-Multiple-Tokens Prediction outputs multiple tokens in an autoregressive step.

知乎 @北方的那



千问-Qwen-Image



Figure 2: Showcase of Qwen-Image in complex text rendering, including multi-line layouts, paragraph-level semantics, and fine-grained details. Qwen-Image supports both alphabetic languages (e.g., English) and logographic languages (e.g., Chinese) with high fidelity.

Qwen-image 发布时间2025.8

Enhanced Human Realism

Qwen-Image



Qwen-Image-2512



Qwen-image-2512 发布时间 2025.12



Figure 1: Multi-ratio text-to-image samples from HunyuanImage 3.0, demonstrating its powerful prompts-following, reasoning, concept generalization and text-rendering capabilities.

HunyuanImage-3.0 2025.9



HunyuanImage-3.0-Instruct 2026.1



AI时代的图像生成- nanobanana



Nano Banana Pro 2025.11



Nano Banana2 2026.2

04

模型驱动与数据驱动的融合





模型驱动方法

- 问题的本质：给定输入，通过施加一定条件（或算法），得到最终的输出。这些算法可以是确定性的，也可以是随机的。



关键：

- 如何获得模型（方程或公式），即输入和输出之间的映射关系或者模式
- 构造求解方程的复杂算法
- 模型参数：观测值、反问题建模、数据同化等。



数据驱动方法




数据驱动方法

- 问题的本质：我们找不到对应的模式，我们不知道如何把输入映射为输出。

案例: MNIST 数字识别。由于手写字体因人而异，我们不知道如何将输入转化为输出。

- 虽然我们不知道如何映射，但是我们有数据，可以把这个映射学习出来。



From the MNIST Database of Hand-written Digits






数据驱动方法



- 01 常用机器学习模型：人工神经网络（ANN），支持向量机（SVM），卷积神经网络（CNN），循环神经网络（RNN）等
- 02 机器学习模型预测原理：利用大量历史数据，寻找并确定输入多元变量与目标变量的复杂映射关系，构造模型并基于该模型对未来的目标变量进行预测
- 03 以人工神经网络为例：





数据驱动（连接主义AI）局限性



知识

数据

1. 现实场景数据极度稀缺

深度学习网络，待训练参数量往往上万甚至上百万。

- GPT-3: 96层，12,288隐层维度，1750亿参数。
- 大数据、大模型、大算力

采集成本高昂：

- 测井曲线（一口井5000万RMB）
- 吸附解析实验（一组一周）

难以观测未来：

- 地下渗流场分析与预测
- 水驱油问题



数据驱动（连接主义AI）局限性



知识

数据

2. MSE等指标的局限性

● Prediction 1

● Observation

?

=

● Observation

● Prediction 2



数据驱动（连接主义AI）局限性



知识

数据

3. 易被攻击与误导（没有常识，缺少知识）





Fig. 2: Set of legitimate and adversarial samples for two datasets: For each dataset, a set of legitimate samples, which are correctly classified by DNNs, can be found on the top row while a corresponding set of adversarial samples (crafted using [7]), misclassified by DNNs, are on the bottom row.





数据驱动（连接主义AI）局限性



知识

数据

4. 知识工程难以处理复杂现实问题

早期机器学习系统：

- DENDRAL（1980）有机化学结构分析
- MYCIN（1984）血液传染病诊断
- Deep Blue（1997）国际象棋



蛋白质结构？

X光片分析？

围棋？






数据驱动的不足与解决方案



数据驱动方法的不足与解决方案



行业挑战（以能源为例）：


- 能源行业对模型的鲁棒性与解释性要求高
- 能源数据的采集费时且成本高昂
- 能源系统极其复杂，存在大量高维非线性映射关系

解决方案：

- 活化利用能源行业内多年积累的知识，构建知识与数据双驱动模型，提升模型精度和鲁棒性，降低数据需求



科学机器学习中的知识嵌入与知识发现



Chen & Zhang, *arXiv:2202.10337*, 2022

知识嵌入：构建具有物理常识的AI模型

- 借助机器学习的强拟合能力，描述变量间高维复杂映射关系（准确性）
- 利用能源领域内的先验知识，保证预测结果符合物理机理（可靠性）

知识发现：从观测数据中提炼物理知识


- 借助人工智能自动探索物理原理，推进人类认知前沿
- 迭代利用发现的知识，和知识嵌入结合，形成知识和数据的闭环系统




知识嵌入



知识嵌入是将领域知识整合到数据驱动模型中的过程，目的是创建具有物理常识的模型



构建物理上合理、数学上准确、计算上稳定高效的智慧能源模型。



机器学习建模全流程的知识嵌入方法示意图


核心问题:

- 复杂形式控制方程的嵌入方法
- 控制方程以外的通用知识的嵌入方法
- 不规则物理场的知识嵌入方法
- 损失函数中正则项权重的自动调整策略

Wang, N., Zhang, D., Chang, H., & Li, H. (2020). Journal of Hydrology, 584, 124700.
Wang, N., Chang, H., & Zhang, D. (2021). Computer Methods in Applied Mechanics and Engineering, 373, 113492.
Chen, Y., & Zhang, D. (2021). Advances in Applied Energy, 1, 100004.
Xu, R., Zhang, D., Rong, M., & Wang, N. (2021). Journal of Computational Physics, 436, 110318.
Wang, N., Chang, H., & Zhang, D. (2021). Computer Methods in Applied Mechanics and Engineering, 385, 114037.
Chen, Y., Huang, D., Zhang, D., Zeng, J., Wang, N., Zhang, H., & Yan, J. (2021). Journal of Computational Physics, 445, 110624.



知识嵌入



Chen & Zhang, *arXiv:2202.10337*, 2022



知识嵌入



研究1：电力系统中结合EnLSTM预测电网负荷

核心问题： 如何在**反馈更新阶段**嵌入知识？
如何将空间序列模型**拓展到时间序列模型**？

引入领域算法改进反向传播优化过程

代表模型：ENN、EnLSTM

数据预处理环节嵌入领域知识：

e. g. 电力负荷比值分解

代表模型：TgDLF






知识嵌入



研究1：电力系统中结合EnLSTM预测电网负荷



Chen, Y., & Zhang, D.* (2021). Theory guided deep-learning for load forecasting (TgDLF) via ensemble long short-term memory, *Advances in Applied Energy*, 1, 1-15.




知识嵌入



研究2：融合概率分布信息的风力发电预测

核心问题：

如何在效果评估阶段嵌入知识？
如何将概率分布信息作为约束嵌入到AI模型中？






知识嵌入



研究3：理论指导的机器学习

核心问题：

如何在效果评估阶段嵌入知识？
如何将控制方程作为约束嵌入到AI模型中？






知识嵌入



理论指导神经网络(Theory-guided Neural Network, TgNN) 物理信息神经网络(Physics-informed Neural Network, PINN)






知识嵌入



理论指导神经网络(Theory-guided Neural Network, TgNN) 物理信息神经网络(Physics-informed Neural Network, PINN)

TgNN模型总的目标函数:

$$L(\theta) = \lambda_{data} MSE_{data} + \lambda_{PDE} MSE_{PDE} + \lambda_{BC} MSE_{BC} \\ + \lambda_{IC} MSE_{IC} + \lambda_{EC} MSE_{EC} + \lambda_{EK} MSE_{EK}$$



同时考虑:

- 观测数据 – 训练数据
- 物理准则 – 控制方程 (PDE)
- 边界条件 – BC
- 初始条件 – IC
- 工程控制 – EC
- 专家经验 – EK

特点:

- **准确的预测能力:** 复杂的映射关系; 同时遵循物理准则、工程实践与专家知识
- **强泛化能力:** 更容易地推广到训练数据所涵盖的范围之外; 适用于训练数据稀疏的情况
- **迁移学习的能力:** 当问题条件发生改变时, 可通过迁移学习的思路对网络进行微调




知识嵌入



研究4：利用硬约束嵌入控制方程求解地下渗流场

核心问题：

如何在模型结构设计和效果评估阶段嵌入知识？
如何将控制方程作为硬约束嵌入到AI模型中？





知识嵌入



软约束 → 硬约束（硬约束映射，HCP）


软约束 (TgNN/PINN):

- 优: 易于实现
- 劣: 只能产生平均意义上符合物理约束的预测结果。

硬约束 (HCP):

- 优: 通过映射的方式, 保证局部严格满足物理约束。不需要全局求解。
- 劣: 操作比软约束复杂。

Chen, Huang, Zhang et al., *Journal of Computational Physics*, 2021





知识发现



知识发现的目标是从数据中提取未发现的知识，并推进人类认知的边界




发挥机器学习算法描述高维非线性映射的优势，从实验数据中（下图左侧）**直接挖掘新的知识**（下图右侧），加深对物理本质的理解

核心问题：

- 控制方程的灵活表示方法以及优化算法
- 复杂结构控制方程的挖掘方法
- 复杂系数控制方程的挖掘方法
- 针对**稀缺且嘈杂**的数据的挖掘方法
- 从实验数据中挖掘**全新**的控制方程

Xu, H., Chang, H., & Zhang, D. (2020). Journal of Computational Physics, 418, 109584.
Xu, H., Zhang, D., & Wang, N. (2021). Journal of Computational Physics, 445, 110592.
Xu, H., & Zhang, D. (2021). Physical Review Research, 3(3), 033270.
Chen, Y., Luo, Y., Liu, Q., Xu, H., & Zhang, D. (2022). Physical Review Research, 4(2), 023174



从细观模拟数据中挖掘粘性重力流的宏观控制方程



知识发现




从行星运动三定律的提出看控制方程的挖掘





基于观测数据挖掘控制方程




$$\frac{\partial u}{\partial t} = u \frac{\partial u}{\partial x} - 0.0025 \frac{\partial^3 u}{\partial x^3}$$



知识发现




从人工智能的发展看控制方程的挖掘



- 神经网络是一个黑盒模型，可解释性差（知其然不知其所以然）



- 显式表达出神经网络的内部逻辑（控制方程），提高可解释性（知其然也知其所以然）





数据驱动的偏微分方程挖掘

利用机器学习方法从数据中**直接发现**潜在的物理过程及其控制方程

封闭候选集方法：**稀疏回归**

偏微分方程的形式可以表示为：

$$u_T = \Phi(u) \cdot \zeta$$

u_T : u 关于时间的各阶导数.

$\Phi(u)$: 偏微分方程中可能存在的项 (**候选集**), 共**17**项.

$$\Phi = [1 \quad u \quad u^2 \quad u^3 \quad u_x \quad uu_x \quad u^2u_x \quad u^3u_x \quad \dots \quad u^2u_{xx} \quad u^3u_{xx}]$$

ζ : 稀疏的系数向量.

观测数据

离散化

$$\begin{bmatrix} u_T(x_1, t_1) \\ u_T(x_1, t_1) \\ \vdots \\ u_T(x_N, t_N) \end{bmatrix} = \begin{bmatrix} u(x_1, t_1) & \dots & uu_x(x_1, t_1) & \dots \\ u(x_2, t_2) & \dots & uu_x(x_2, t_2) & \dots \\ \vdots & \ddots & \vdots & \ddots \\ u(x_N, t_N) & \dots & uu_x(x_N, t_N) & \dots \end{bmatrix} \cdot \zeta$$

简化

$$U_T = \Theta(u) \cdot \zeta$$


目的: 从数据中识别出**时间导数** (例如, 左端项是 u_t 还是 u_{tt}), **潜在偏微分方程**的项及稀疏的系数向量 ζ 。



知识发现



候选集复杂度
及
方程项表示方法





知识发现



➤ 研究5：基于知识发现和符号数学实现控制方程自挖掘（生产知识）

- 找到最适合数据的 PDE 的关键在于解决两个问题：

表示：如何通过**符号数学表示**任何给定的复杂开放式偏微分方程；



优化：如何使用机器学习算法从 PDE 的无限可行域中**挖掘**正确的方程。

- 引入符号回归中树结构的概念，在开放空间中挖掘方程形式

- 父节点为运算符（包括偏微分算符）
- 子节点为系数、变量或函数
- 对树结构的深度和广度约束：稀疏性

- 任何方程都是一片森林 (Any equation is a forest).

- 能够挖掘**自由形式的方程**：可解释性强



树结构

$$\{\partial [+ (\partial u x) (\times u u)] x\}$$



$$\frac{\partial \left(\frac{\partial u}{\partial x} + u * u \right)}{\partial x}$$

方程形式

Chen, Y., Luo, Y., Liu, Q., Xu, H., & Zhang, D.* (2022). Symbolic genetic algorithm for discovering open-form partial differential equations (SGA-PDE), Physical Review Research 4, 023174

55




模型驱动与数据驱动的融合



模型驱动与数据驱动的融合

Chen & Zhang, *arXiv*:2202.10337, 2022





模型驱动与数据驱动的融合



1. 机器学习算法可以有效解决具有复杂非线性映射关系的问题

- 数据是基础：信息化、物联网
- 从数据大到大数据

2. 通过引入行业知识，可以有效提升机器学习模型的效果

- 可以在数据预处理、机器学习模型结构以及模型效果评估环节嵌入领域知识
- 提升精度和鲁棒性
- 在一定程度上降低数据需求

3. AI+行业，还是，行业+AI?

- 数据驱动（机器学习）与模型驱动（传统模型）的有机结合

理论指导的核心：知识嵌入

挖掘控制方程的本质：知识发现





谢谢!

THANK YOU FOR WATCHING!

