



华南理工大学
South China University of Technology

《人工智能理论及应用》

算力---人工智能芯片

授课老师：青春美

联系邮箱：qchm@scut.edu.cn

2026年4月

投票 最多可选1项

以下哪项是AI芯片的主要应用场景（ ）

- ☐ A 文本编辑
- ☐ B 图像识别
- ☐ C 打印文档
- ☐ D 文件压缩

目 录



01 算力——人工智能的基石

02 主流算力芯片

03 国产算力AI芯片的发展

04 AI算力应用



华南理工大学
South China University of Technology

01

算力——人工智能的基石





AI芯片的重要性






算力是AI的发展根基



- ✓ 算力、算法和数据是人工智能产业发展的三个核心要素，在三大要素中，**算力才是最核心的要素**
- ✓ **数据的生产不再是问题，如何处理、分析和使用数据才是问题。**算法经历了数十年的发展，在深度学习和加速计算出现之后，得到了迅速的发展和优化
- ✓ **算力是承载和推动人工智能走向实际应用的决定性力量**
- ✓ 算法模型的复杂化和巨量化需要更强算力的支撑。近些年，算法模型的参数量和复杂程度都在呈现指数级增长态势，尤其是自然语言处理等新兴认知智能领域对算力的要求远超图像识别和语音识别等传统AI领域



人工智能的三驾马车

- ✓ **数据的快速增长对算力发展提出更高要求。**随着信息化、数字化的持续推进，全球新产生的数据量正在快速增长，根据IDC数据显示，预计到2026年全球新增数据总量将达到**221.22B**，2021年至2026年间的年复合增速达到21.22%
- ✓ **新应用场景的出现对数据实时性要求更高，**从而使得边缘计算能力变得愈发重要，人工智能应用也越来越依赖边缘算力支撑。



算力的基本单位



在计算机领域，常用算力的衡量指标包括**FLOPS**（每秒浮点运算次数）、**OPS**（每秒运算次数）。FLOPS特别适用于评估超级计算机、高性能计算服务器和GPU等设备的计算性能。

在计算性能的度量中，常见单位包括**Kilo/Mega/Giga/Tera/Peta/Exa**，算力通常以PetaFIOPS（每秒千万亿次浮点运算）单位来衡量。

AI算力常见单位分为**TOPS**和**TFLOPS**。**推理算力**，即通常用设备处理实时任务的能力，通常以**TOPS**（每秒万亿次操作）为单位来衡量。而**训练算力**，即设备的学习能力和数据处理能力，常用**TFLOPS**（每秒万亿次浮点操作）来衡量。TFLOPS数值越高，反映了模型在训练时的**效率越高**。





不同场景对应算力精度表示不同



算力精度作为可以衡量算力水平的一种方式，可分为浮点计算和整型计算。其中浮点计算可细分为半精度（2Bytes，FP16）、单精度（4Bytes，FP32）和双精度（8Bytes，FP64）浮点计算，加上整型精度（1Byte，INT8）。

不同场景对应算力精度表示不同。FP64主要用于对精度要求很高的科学计算，如制造产品设计、机械模拟和Ansys应用中的流体动力学，AI训练场景下支持FP32和FP16，模型推理阶段支持FP16和INT8。

表：常见浮点整型规格及定义

常见浮点/整型规格	定义
FP64	被称为双精度，它是使用64位(8 Bytes)来表示一个浮点数，精度较高，常用于科学计算和对精度要求较高的场景。
FP32	被称为单精度，使用32位(4 Bytes)来表示一个浮点数，精度略逊于FP64，仍然足够用于大多数AI训练任务。
FP16	被称为半精度，它的精度极低，但占用存储空间和计算资源较少，对精度要求低，通常运用在节能场景下。
INT8	是一种低精度、高效率的数值表示方式。在推理阶段(即模型训练完成用于实际应用的阶端),使用它可以显著提高运算速度，降低能耗。

图：不同精度可执行任务对比





稀疏算力与稠密算力



稀疏算力和稠密算力用于描述计算资源的利用程度。在实际场景中，稀疏算力和稠密算力存在互补关系与转换关系。

- **稠密算力**：指的是在计算过程中，数据点之间的关联度都较高，需要处理大量连续的数据。通常用于需要密集型计算的任务，如图像处理、视频编码、大规模数值模拟等
- **稀疏算力**：指在计算过程中，数据点之间的关联度较低，数据分布稀疏。这种算力常用于处理稀疏矩阵或者稀疏数据集，如社交网络分析、推荐系统、基因序列分析等。

表：稠密算力与稀疏算力特性对比

特性	稠密算力	稀疏算力
数据关联度	高	低
数据存储	连续存储	稀疏存储、使用特殊数据结构
计算模式	并行计算	稀疏优化算法，可能包含并行计算
应用场景	图像处理、科学计算	社交网络分析、推荐系统
能耗	相对较高	相对较低
算法优化	针对大规模数据处理优化	针对稀疏数据处理优化
硬件需求	高性能CPU/GPU、大容量内存	优化的存储解决方案、可能需要特定硬件支持

图：稠密算力与稀疏算力结构对比






训练算力与推理算力



训练算力：指在训练机器学习模型时所需的计算资源。训练过程涉及将模型与训练数据进行多次迭代，调整模型参数以最小化损失函数（损失函数是衡量模型预测值与实际值之间差异的函数，反映模型性能）。所需训练算力的大小与模型复杂度、数据集大小和迭代次数有关。

推理算力：指执行已经训练好的模型进行预测或推理时所需的计算资源。在推理阶段，模型不再更新参数，而是用来对新数据进行预测。这时，算力的需求与模型大小、批处理大小（Batch Size，是指在深度学习中每次输入的数据集大小）、硬件配置有密切联系。

图：AI训练与AI推理对比





训练芯片与推理芯片



- **训练芯片**：用于构建神经网络模型，需要高算力和一定的通用性。
- **推理芯片**：利用神经网络模型进行推理预测，注重综合指标，单位能耗算力、时延、成本等。

图：训练芯片与推理芯片对比

场景	算力需求	精度要求	主要产品	应用场景
训练	高，每个Token的训练成本通常约为 $6N$ (N 是 LLM 的参数数量)	高，一般使用 16 位、32 位浮点甚至 64 位双精度数据	英伟达 V100、A100、H100；AMD MI200；华为昇腾 910；寒武纪思元 290；壁仞 BR100 等	对特定的预研模型、神经网络的大量参数进行运算训练，使模型能够完成各种任务
推理	较低，每个Token的推理成本通常约为 $2N$	较低，一般使用 8 位或 16 位整型数据	英伟达 L40、T4、A10、A30；AMD Alveo V70；寒武纪思元 100、思元 370；燧原邃思 1.0；阿里平头哥含光 800 等	在已经完成训练的模型基础上，利用输入数据获得所需要输出的结果



算法的技术突破拉动了算力的需求



- 2015-2016 年左右开启了大模型时代，整体的训练计算量较之前的时期大2到3个数量级。从2022年底，随着ChatGPT成功带来大规模参数通用大模型相继发布。这些大模型的训练需要千亿、甚至万亿级参数，以及上千GB的高质量数据，大模型的训练迭代将极大地拉动了智能算力的需求。
- 2012-2024年算力需求翻了数十万倍，AI算力需求远超摩尔定律，大模型对算力的需求每年持续增长，未来10年AI算力需求将再增长500倍。


2010前

深度学习时期之前，训练计算算力需求缓慢增长，
算力翻倍需要21.3个月


2010-2024

深度学习不断取得进展，算力翻倍仅需要5.7个月，
所需算力量级由 TFLOPs增至EFLOPs

训练算力 (FLOPS) 需求与人工智能发展关系图



模型规模指数级增长推动算力需求爆发






大模型时代全球算力需求呈指数级增长




- 技术层面上，基础模型通过迁移学习（Transfer Learning）和规模（scale）得以实现；Transformer的应用标志着基础模型时代的开始（基础模型的庞大规模和应用范围突飞猛进），模型参数量指数级增长，带动算力超过摩尔定律。
- Sora等视频生成类模型相较于大语言模型消耗的算力提升20倍。随着海量数据的积累，大模型需要处理的数据量也在不断增长，进一步加剧了对算力的需求。

Transformer结构对于基础模型训练算力需求的推动作用



推理消耗算力对比（单位：FLOPS）






生成式AI的发展依赖算力的提升



- AI技术在实际应用中包括两个环节：训练（Training）和推理（Inference），AIGC的算力需要考虑训练及推理两个方面。
- 训练是指通过数据开发出AI模型，使其能够满足相应需求，一般为AI技术的研发。因此参数量的升级对算力的需求影响大。
- 推理是指利用训练好的模型进行计算，利用输入的数据获得正确结论的过程，一般为AI技术的应用。推理部署的算力主要在于每个应用场景日数据的吞吐量。





AI生态加速收敛



- 大模型技术逐步收敛，生态走向聚合，模型更收敛、框架更归一。
- 为了开发更高性能的 AI 大模型需要更强的算力平台，算力底座技术门槛将提高，未来训练核心拼**集群系统能力**。

图：AI技术逐步收敛，生态走向聚合

	模型更收敛	框架更归一
大模型	基础大模型10~20个	Pytorch框架占95%+
小模型	数万小模型 字节有上万个自研模型	PyTorch、TensorFlow, Caffe, 飞桨等

图：算力底座技术门槛提高

	万级参数时代		亿级参数时代		万亿参数时代
计算需求	百TF级平台 1张GPU卡	X10倍	PF级平台 单服务器, 8卡	X1000倍	EF级平台 AI集群, ~万卡
网络需求	无互联	N/A	节点内卡间互联	X100倍	超节点+网络互联
存储需求	GB级存取 -服务器硬盘	X100倍	TB级存取 -服务器硬盘	X1000倍	PB级存取 -高并发多级存储




提升算力内存带宽，HBM供不应求



- 以ChatGPT为代表的生成类模型需要在海量数据中训练，对存储容量和带宽提出新要求，**HBM (High Bandwidth Memory, 高带宽存储器)**成为减小内存墙的优选项。HBM将多个DDR芯片堆叠并与GPU封装在一起，是一种基于3D堆叠工艺的高附加值DRAM产品。通过增加带宽，扩展内存容量，让更大模型、更多参数留在离计算核心区更近的地方，从而减少内存和存储解决方案带来的延迟。据Omdia，到2025年，HBM市场的总收入达到25亿美元。
- 由于ChatGPT的爆火，GPU需求明显，英伟达也加大对三星和SK海力士HBM3的订单。2023年10月，SK海力士表示，已经在2023年出售了2024年HBM3和HBM3E的所有产量。

图：HBM3产品结构



图：英伟达使用的HBM带宽不断升级 (TB/s)





提升算力内存带宽，HBM供不应求



当我们站在数字化时代的浪潮之巅时




复杂工程的落地需要实现目标与成本的平衡



- 应用落地的算力选择，更应该强调最优解，而非最大解。在实现AIGC的技术落地过程中，模型的参数量及涌现结果固然重要，但模型在运行过程中所需的算力成本、能耗成本、运营成本等是否能匹配AIGC技术提供的效果及价值突破更为重要。

以终为始，贴合行业需求，实现目标与资源平衡，是AI新世代下的算力选择依据






随着推理成本的降低，推理端算力需求将持续增加



□ AIGC模型在处理输入和输出时，其计算资源消耗与输入输出的数据量成正比，费用计算基于输入输出的Token数量。

□ 以OpenAI为例，在过去两年里，它将API访问成本降低了99%。具体来看，GPT-3的API推理成本从2021年的每千Token 0.06美元降至2022年的0.02美元，降幅达66%。到2023年，GPT-3.5 Turbo的API推理成本与2021年相比下降了86%。

GPT-4 的价格变化



根据英伟达财报，其数据中心的推理占比已经达到40%

英伟达FY2024数据中心推理与训练占比



未来，AI服务器的工作负载可能以推理为主

2022-2027年中国AI服务器工作负载及预测





随着推理成本的降低，推理端算力需求将持续增加




- 未来AI应用推理的成本可能会远超训练。大模型训练是阶段性的需求，训练数据通常是固定的，比如几万亿、几十万亿token的量级，且客户集中度高。但做推理，可能每天都是几万亿到10万亿Token，一周就超过了训练的计算量。
- 模型推理成本下降是超级应用爆发的前提条件之一。



- 当前AI应用需求正在发生变迁，大模型正从ToVC泡沫炒作阶段走向ToB落地阶段，未来可能走向ToC阶段，当前制约在于AI推理成本，成本降低后将迎来应用爆发。
- 企业可以进行推理成本优化，包括硬件降本（如硬件梯次利用）、算力调度（按需求波峰波谷配置资源）和推理加速。

推理算力未来可能爆发的示意图






算力与数据成为AI的重要基石



- 在现代人工智能领域，算力扮演着推动创新、实现突破的核心驱动力。算力、算法、数据和系统架构等多个方面的综合优化对于大规模模型训练的成功至关重要。从技术层面看，在大模型的研发过程中，预训练、微调和模型推理等环节是核心关键因素和主要计算特征。





AI赋能各行各业，算力成为智能化升级的核心支撑




- AI快速发展正在推动各行业的数智化转型，大模型为千行百业提供了创新解决方案。通用大模型侧重发展通识能力，行业/场景大模型侧重发展专业能力，模型赋能行业有效的提升了效率、降低成本及优化决策过程。
- 算力支撑成为了AI产业发展的关键，也是实现AI技术在各行业广泛应用的基础。目前大模型在广告、传媒、教育、金融等领域快速落地应用，AI算力与各行业深度融合，将加速产业升级和数字化转型进程。

图1：大模型赋能各行各业



图2：主要行业大模型应用阶段示意图





AI芯片作为算力的基石，发展前景巨大



- ❑ 芯片作为算力产业的基石，为智能算法和应用提供了不可或缺的计算能力。在服务器成本中，核心芯片如GPU占据了超过80%的比重。掌握自主可控的AI芯片技术，对于智算产业的持续发展至关重要。
- ❑ 随着人工智能应用场景的不断拓展，市场对高性能AI芯片的需求日益增长。同时，存算一体、光通信等前沿技术的突破，为AI芯片产业注入了强劲的增长动力。数据显示，2023年中国AI芯片市场规模已达到约652亿人民币。预计到2026年，市场规模将显著增长至1611亿人民币，AI芯片市场正迎来快速发展的黄金时期。

图1：服务器主要成本构成





图2：2020-2026年中国AI芯片市场规模（单位：亿人民币）





AI芯片成为中美科技博弈焦点



□ 在中美科技博弈的背景下，AI芯片的国产化既是技术发展的需求，也是国家战略的一部分，对于提升国家的科技实力和产业竞争力具有重要作用。

图1：近年美国对华半导体制措施

2023.10	美国商务部将壁仞科技、摩尔线程等公司列入实体名单。
2023.03	美国商务部将浪潮集团、龙芯中科等公司列入实体名单。
2022.10	BIS对中国实体超级计算机芯片和包含此类芯片的计算机商品的禁令，对收到许可证要求限制的外国生产项目的范围扩大到实体名单上中国境内的28家现有实体；针对 $\leq 18\text{nm}$ 的DRAM ≥ 128 层的NAND存储芯片增加了新的许可证要求；限制美国人员在没有许可证的情况下支持中国某些半导体制造设施的研发和集成电路的制造；将包括长江存储、中国科学院大学等科研院校在内的31家实体列入未经核实名单（UVL）。
2022.08	美国通知英伟达向中国和俄罗斯出口A100和H100芯片需新的许可证要求。
2022.08	BIS公告美国准备对EDA等四项技术实行出口管制。
2022.07	美国半导体厂商收到美国商务部规定，要求不得向中国供应用于制造 $\leq 14\text{nm}$ 芯片的设备。
2022.07	美国众议院通过《芯片与科学法案》，主要包括：分5年提供527亿美元用于半导体制造激励计划、研发投入、税收减免，其中美国芯片基金共500亿美元，390亿美元用于鼓励半导体制造企业，110亿美元补贴芯片研发；法案要求获得补贴的半导体企业未来10年内不得在中国大陆新建或扩建先进制程的半导体工厂。
2020.12	中芯国际被纳入实体名单，对用于 $\leq 10\text{nm}$ 技术节点的产品或技术，美国商务部采取“推定拒绝”的审批政策进行审核。
2019-2020	2019年5月，华为及69家附属关联公司被美国列入“实体名单”，2020年5月，BIS限制华为购买使用美国技术、软件设计制造的半导体；2020年8月，BIS在实体清单中新增38家华为附属公司，并修订外国制造直接产品规则，进一步限制华为使用基于美国软件/技术生产的半导体。
2018.04	美国商务部发布公告，在未来7年内禁止中兴通讯向美国企业购买敏感产品。

图2：被美国列入“实体清单”的中国半导体企业

2023.10.17	壁仞科技及其附属关联公司
	摩尔线程及其附属关联公司
2023.03.02	龙芯中科技术股份有限公司
	浪潮集团
2022.12.15	长江存储科技有限责任公司
	寒武纪及其附属关联公司
	合肥兆芯电子有限公司
2021.12.17	长沙景嘉微电子股份有限公司
2021.11.26	新华三半导体技术有限公司
2021.07.09	杭州华澜微电子股份有限公司
2021.03.08	国家超级计算深圳中心
2020.12.18	中芯国际及其附属关联公司
	深圳云天励飞技术有限公司
2019.06.24	曙光信息产业股份有限公司
2019.05.16	华为及其附属关联公司



美国限制措施加速国产化替代过程




- 在AI技术快速发展的背景下，AI芯片已成为美国政府卡中国脖子的新武器。自2018年以来，被美国列入“实体清单”的中国AI芯片企业持续增加。同时，美国聚焦于高算力芯片，限制英伟达、AMD等企业的GPU出口，试图全面遏制我国AI产业发展。
- 美国的限制措施激发了中国AI芯片产业的自主创新和研发，加速了国产替代的进程。中国企业面对外部压力，加大研发投入，努力构建自主可控的产业链。

被列入“实体清单”的AI芯片企业数量



美国商务部工业和安全局对华高算力芯片出口限制





全球数字基础算力设施建设加快



- 数字经济成为全球经济增长的活力所在。2022年，全球51个主要经济体数字经济同比名义增长7.4%，高于同期GDP名义增速3.2%，持续为全球经济平稳回升注入动力。数字经济快速发展推动数字基础设施建设步伐加快。算力作为重要的数字基础设施，算力结构不断调整。
- 全球算力主要由通用算力、智能算力和超算算力组成。通用算力作为基础，满足广泛的日常计算需求；智能算力则在新兴技术领域发挥关键作用；超算算力针对特定高端需求提供强大计算能力。数据显示，2023年底全球算力总规模约910EFLOPS，其中，智能算力从2021年的113EFLOPS增长至2023年的335EFLOPS，增速远超其他。

图1：2021-2023年全球算力规模（单位：EFLOPS）



图2：不同算力的重点应用领域

	通用算力	智能算力	超算算力
技术特点	一般主要由CPU芯片提供计算能力，适合计算复杂度适中的云计算、边缘计算类场景。	一般由GPU为代表、FPGA、ASIC等AI芯片的加速计算平台提供的算力，侧重于处理和分析大量数据，执行复杂计算任务。	由超级计算机等高性能计算集群所提供的算力，注重双精度通用计算能力，追求精确的数值计算。
应用场景	应用范围广泛，如科学研究、工程设计、商业分析、医学诊断等。	主要用于人工智能的训练和推理计算，如语音、图像和视频的处理等。	主要用于尖端科学领域的计算，如行星模拟、药物分子设计、基因分析等。



国家层面出台多项政策大力支持算力发展



时间	发文部门	文件名称	主要内容
2024.10	国家发展改革委员会	《国家数据标准体系建设指南》	要强化基础设施互联互通、算力保障和流通利用标准建设，为数据资源、数据技术、数据流通、融合应用提供支撑。
2024.12	国家发展改革委员会	《关于深入实施“东数西算”工程加快构建全国一体化算力网的实施意见(发改数据〔2023〕1779号)》	到2025年底，普惠易用、绿色安全的综合算力基础设施体系初步成型，东西部算力协同调度机制逐步完善，通用算力、智能算力、超级算力等多元算力加速集聚，国家枢纽节点地区各类新增算力占全国新增算力的60%以上，国家枢纽节点算力资源使用率显著超过全国平均水平。1ms时延城市算力网、5ms时延区域算力网、20ms时延跨国家枢纽节点算力网在示范区域内初步实现。算力电力双向协同机制初步形成，国家枢纽节点新建数据中心绿电占比超过80%。用户使用各类算力的易用性明显提高、成本明显降低，国家枢纽节点间网络传输费用大幅降低。算力网关键核心技术基本实现安全可靠，以网络化、普惠化、绿色化为特征的算力网高质量发展格局逐步形成。
2024.9	国务院办公厅	《国务院办公厅关于加快公共数据资源开发利用的意见》	繁荣数据产业发展生态。将数据产业作为鼓励发展类纳入产业结构调整指导目录，支持数据采集标注、分析挖掘、流通使用、数据安全等技术创新应用，鼓励开发数据模型、数据核验、评价指数等多形式数据产品。围绕数据采存算管用，培育高水平数据要素型企业。聚焦算力网络和可信流通，支持数据基础设施企业发展。落实研发费用加计扣除、高新技术企业税收优惠等政策。支持数据行业协会、学会等社会团体和产业联盟发展，凝聚行业共识，加强行业自律，推动行业发展。
2024.3	中央人民政府	《政府工作报告》	适度超前建设数字基础设施，加快形成全国一体化算力体系，培育算力产业生态。
2023.10	工业和信息化部	《算力基础设施高质量发展行动计划》	推动算力结构多元配置。结合人工智能产业发展和业务需求，重点在西部算力枢纽及人工智能发展基础较好地区集约化开展智算中心建设，逐步合理提升智能算力占比。推动不同计算架构的智能算力与通用算力协同发展，满足均衡型、计算和存储密集型等各类业务算力需求。
2023.3	科技部	《关于开展国家新一代人工智能公共算力开放创新平台申报工作的通知》	为贯彻落实《国家新一代人工智能发展规划》(国发〔2017〕35号),做好“国家新一代人工智能公共算力开放创新平台”(简称“公共算力平台”)启动建设工作,根据《国家新一代人工智能公共算力开放创新平台建设指引(试行)》(国科办高〔2022〕89号,简称《建设指引》),结合我国人工智能技术发展和算力基础设施建设的需求,现启动“公共算力平台”建设申报工作。
2022.8	科技部财政部	《企业技术创新能力提升行动方案(2022-2023年)》	推动国家超算中心、智能计算中心等面向企业提供低成本算力服务。支持建设一批重大示范应用场景,鼓励创新型城市、国家自创区、国家高新区、国家农高区、国家新一代人工智能创新发展试验区等发布一批应用场景清单,向企业释放更多场景合作机会。



各省市积极响应，大力推动地方算力发展



- 各省市通过政策引导和支持，推动地方算力资源的开放共享、数据中心的集约化发展、算力网络的一体化建设，以及算力与实体经济的深度融合，从而加速AI应用的落地和数字经济的发展。

省市	时间	文件名称	主要内容
山东	2024.6	山东省算力基础设施高质量发展行动方案	强化多元算力协同部署。引导通用算力、智能算力、高性能算力中心等合理梯次布局，支持重点企业建设智算中心，适度超前提高智能算力占比。推进通用算力中心规范有序、规模集约发展。重点在人工智能发展基础较好、产业需求旺盛的地区集约化开展智算中心建设，支持济南、青岛等市用好人工智能创新应用先导区、创新发展试验区，构建多元异构的千卡级别、万卡级别智能算力集群。引导济南、青岛国家级超算中心深度融入国家分布式超算互联网系统，争取建设中国算力网山东节点，打造国际一流的超算中心。
河北	2024.5	关于进一步优化算力布局推动人工智能产业创新发展的意见	到2025年，全省算力规模达到350亿次/秒(EFLOPS)以上，智能算力占比达到35%左右，新增算力基础设施投资自主可控比例60%以上。在智能制造、医疗等领域推动人工智能产业创新发展等优势领域孵化一批行业应用大模型，培育典型应用场景30个。智能产业合作进一步深化，在环京区域打造人工智能产业集聚区，推动一批人工智能合作项目落地实施。
北京	2024.4	北京市算力基础设施建设实施方案（2024-2027）	到2025年，基本建成智算资源供给规模化、有算设施建设自主化、有算能力赋能精准化、有算中心运营绿色化、有算生态发展体系化的格局。到2027年，优化京津冀算力供给质量和规模，力争自主可控算力满足大模型训练需求，算力能效标准达到国内领先水平。
江苏	2024.4	江苏省算力基础设施发展专项规划	全市“613”产业体系重点企业和在苏从事人工智能研发应用的科研院所，在运河城市算力平台积累非关联方的智能算力资源，凭已签订的算力服务合同获取算力券。算力需求方通过平台购买使用智能算力资源服务的，按照实际支付智能算力费用30%给予支持，给予同一主体每年最高200万元补贴，算力券有效期为12个月。
黑龙江	2024.3	黑龙江省支持智算中心和超算中心建设奖励政策实施细则	省工信厅负责对照绩效目标做好事后绩效评价工作，聚焦注重投入产出效益，对政策实施效果和资金使用情况开展“双评价”，提升绩效评价质量和实效。健全评价指标体系，将包括但不限于新增智算、超算规模，新增算力服务营收等个性化指标作为产出效益评价重点。加强绩效评价结果应用，将评价结果作为政策调整、预算安排和资金分配的重要依据，对于产出效益未达预期的，对政策延续实施的必要性开展评估，根据评估结果提出应用措施。
上海	2024.3	上海市智能算力基础设施高质量发展“算力浦江”智算行动实施方案（2024-2025年）	力争到2024年，信息通信行业基本形成布局合理、算网协同、软硬协同、低破高效、数字化特型带动能力突出、产业链更加完备的新型数据中心发展体系，初步建成全国一体化算力网络上海枢纽节点，形成与本市数字经济发展方向相适应、长三角地区协同发展的算力服务发展格局，建成具有跟头乃至全球影响力的高能级算力枢纽中心。
广东	2024.3	广东省算力基础设施高质量发展行动暨“粤算”行动计划	2025年，在计算方面，算力规模达到38EFLOPS，智能算力占比达到50%，建成智能计算中心10个。
浙江	2024.3	关于发展计算产业 打造算力强区的若干政策（征求意见稿）	力争到2025年，全区集成电路产业规模达400亿元，网络通信产业规模达850亿元。招引杭州人工智能计算中心建设扩容，基于全核自主技术路线的公共算力规模达到500P，培育等化5个具有行业影响力的专用模型，人工智能赋能标杆企业8家、典型应用场景10个。
南京	2024.3	南京市推进算力产业发展行动方案	2025年，全市数据中心总规模达到25万标准机架，总算力超8.5EFLOPS(FP32)，可统筹智能算力超6000PFLOPS(FP16)。
贵州	2024.2	贵州省算力基础设施高质量发展行动计划（2024-2025）	推动算力结构多元配置。结合人工智能产业发展和业务需求，重点在西部算力枢纽及人工智能发展基础较好地区集约化开展智算中心建设，逐步合理提升智能算力占比。推动不同计算架构的智能算力与通用算力协同发展，满足均衡型、计算和存储密集型等各类业务算力需求。



AI发展推动数据中心走向智算中心




- ❑ AI快速发展推动智能时代的到来，对算力的需求爆发式增长。传统数据中心以CPU为核心，主要负责数据处理及应用承载，已无法满足当前大规模并行计算的需求。因此，智算中心应运而生，专注于提供AI模型训练和推理所需的高性能计算能力。
- ❑ 智算中心以xPU为核心，单机柜功率密度达到20~100kW，耗电量大，在建设规划时需重点考量地理位置、能源条件、算力规模、网络能力、能耗问题等关键因素。

图1：传统数据中心VS智算中心

传统数据中心	智算中心
➢ 得益于个人数字化的高速发展，互联网行业的公有云及应用需求是拉动IDC业务快速增长的核心驱动力。 ➢ 以CPU为中心，适用于一般性的计算需求。 ➢ 采用冯·诺依曼的主从架构，面对大量并行任务时存在“计算墙”、“内存墙”等问题。 ➢ 单机柜的功率密度通常在3~8千瓦之间，可装载的服务器设备数量有限，算力密度相对较低，一般次啊用传统的风冷散热。 ➢ 主要承载企业级应用和数据存储，如Web服务、数据库管理和文件存储等常规信息处理任务。	✓ AI降低编程门槛，迭代速度快，让懂业务与懂编程的融合，开发出更好的应用，推动企业数字化。 ✓ 以xPU为中心，提供并行计算，处理AI模型训练所需的大量矩阵运算。 ✓ 采用多元算力融合架构，利用异构计算与分布式系统，提供弹性、可伸缩扩展的算力聚合能力。 ✓ 单机柜功率密度通常在20~100千瓦之间，主要采用液冷或风液混合的散热技术。 ✓ 主要承载AI模型的训练与推理，高效提供算力资源，并支持大数据的处理。

图2：不同时期数据中心机柜的典型功率（单位：kW每机柜）





智算中心建设规模稳步增长



- 我国大力推动智算中心建设，截至2024年6月，我国数据中心超过830万标准机架，算力规模达246EFLOPS（FP32），智算同比增速超过65%。
- 2022年，我国数据中心平均上架率为58%，华东、华北、华南地区上架率超过65%，西北、西南地区分别约为30%和40%。“东数西算”工程实施以来，算力集群的整体上架率快速提升，西部地区的算力规模增长显著。在用算力中心平均PUE为1.48，与2022年的1.52相比有所改善。

图1：2023年中国数据中心机架规模（单位：万个）




图2：中国在用算力中心PUE值





图3：2023年末国家重点数据中心集群上架率





全国加快智算中心建设



- 2022年中国智能算力规模为259.9EFLOPS（基于FP16计算），预计2027年达到1117.4EFLOPS，五年复合增长率达33.9%。
- 智算中心建设提速，数据显示，2024年上半年，全国已经建设和正在建设的智算中心超过250个，招标投标事件791起，已有超20个城市建设了智算中心。

图1：2022-2027年中国智能算力规模及预测
(基于FP16计算, 单位: EFLOPS)




图2：中国智算中心项目建设现状

	项目数量占比	项目投资规模	项目地区分布	主要应用领域
>1000P 大型智算中心	20%	百亿元以上	京津冀、长三角、珠三角	AI大模型、自动驾驶、空间地理等人工智能技术领域
300~1000P 中型智算中心	70%	10亿元以上	一线、新一线及二线城市	人工智能产业链或细分行业智能化集群
<100P 小型智算中心	10%	10亿元以下	二线及以下城市	企业智能化建设或小型人工智能产业集群



多种智算中心建设及运营模型并行




从目前建设情况看，根据算力规模，智算中心可划分为三大类：


- ❑ 超级智算中心：1000P以上的多为公共用途，承担枢纽节点角色。
- ❑ 中型智算中心：100P到1000P多服务于产业集群类需求，当前落地项目数量更多。
- ❑ 小型智算中心：100P以下更多以企业级零散需求为主。

目前建设运营模式主要有政府投资建设、企业建设运营、政府购买服务、政府和社会资本合作等模式，主要产业合作方如下：


- ✓ **云厂商及AI科技企业**
具备智算中心操作系统和AI算法的开发部署能力。
- ✓ **三大通信运营商**
拥有全国布局的网络基础资源、数据中心资源和云资源池。
- ✓ **第三方数据中心厂商**
具备高标准等级的算力硬件和运维能力，为高性能算力和节能方案提供支撑。



- ❑ 政府或通过平台公司投资建设智算中心。
- ❑ 运营上由平台公司运营，或引入第三方企业参与运营。该模式多适用于发达地区，本地有强算力需求。



- ❑ 引入运营商或第三方企业投资运营。
- ❑ 政府提供电力、土地等优惠政策，如每年购买不少于2000万算力补贴，连续购买5年。



- ❑ 平台公司投资建设智算中心。
- ❑ 企业与平台公司或地方性国资企业成立合资公司，负责公司人、财、物管理，其他部门可采用外包等方式。



人工智能芯片简介





华南理工大学
South China University of Technology

02

主流算力芯片





芯片的工作原理





AI芯片的分类



目前通用的CPU、GPU、FPGA等都能执行AI算法，只是执行效率差异较大。但狭义上讲一般将AI芯片定义为“**专门针对AI算法做了特殊加速设计的芯片**”。AI芯片可以分为GPU、FPGA和ASIC架构，根据场景可以分为云端和端侧。和其他芯片相比，AI芯片重点增强了运行AI算法的能力。






AI芯片的分类



目前主流AI芯片为GPU和ASIC。国际上，Nvidia的GB200 GPU以其卓越的计算性能和能效比领先市场，而Google的第六代 TPU Trillium ASIC芯片则以其专为机器学习优化的设计提供高速数据处理。在国内，寒武纪的思元370芯片(ASIC)凭借其先进的计算处理能力在智能计算领域占据重要地位，已与主流互联网厂商开展深入适配；海光信息的DCU系列基于GPU架构，以其类“CUDA”通用并行计算架构较好地适配、适应国际主流商业计算软件和AI软件。

图：AI芯片在模拟场景和模型运行中具有显著的计算优势
(对比英伟达GPU和AMD x86 CPU)





GPU是较为成熟的通用型人工智能芯片



- 从技术架构来看，AI芯片主要分为图形处理器（GPU）、现场可编程门阵列（FPGA）、专用集成电路（ASIC）、类脑芯片四大类。
 - GPU是较为成熟的通用型人工智能芯片
 - FPGA和ASIC则是针对人工智能需求特征的半定制和全定制芯片
 - 类脑芯片颠覆传统冯诺依曼架构，是一种模拟人脑神经元结构的芯片，类脑芯片的发展尚处于起步阶段。



GPU是较为成熟的通用型人工智能芯片



三种技术架构AI芯片类型比较

	GPU	FPGA (半定制化)	ASIC (全定制化)
定制化程度	通用性	半定制化	定制化
灵活度	好	好	不好
成本	高	较高	低
编程语言/架构	CUDA、OpenCL等	Verilog/NHDL等硬件描述语言, OpenCL、HLS	/
功耗	大	较大	小
主要优点	峰值计算能力强、产品成熟	平均性能较高、功耗较低、灵活性强	平均性能很强、功耗很低、体积小
主要缺点	效率不高、不可编辑、功耗高	量产单价高、峰值计算能力较低、编程语言难度大	前期投入成本高、不可编辑、研发成本长、技术风险大
主要应用场景	云端训练、云端推断	云端推断、终端推断	云端训练、云端推断、终端推断
代表企业芯片	英伟达Tesla、高通Adreno等	赛灵思Versal、英特尔Arria、百度XPU等	谷歌TPU、寒武纪Cambricon



国内外AI芯片产业



- 全球范围内主要布局人工智能芯片的厂商有Intel、NVIDIA、Qualcomm、Google等。美国的巨头企业，凭借着多年在芯片领域的领先地位，迅速切入AI领域并积极布局，目前已经成为该产业的引领者。
- 我国AI芯片产业起步较晚，技术上与世界先进水平也还存在着较大的差距。国内AI芯片市场也较为分散，集中度低。随着数字经济的兴起，人工智能已经深入渗透到各个行业，特别是在互联网等科技公司中更为普及。这些公司对于计算机软件技术和存储设备的要求极高，因此对于底层技术的布局和提升更为重视，尤其是在人工智能芯片领域。





AI芯片的硬件重点性能指标



AI芯片指标	定义
计算能力	GPU执行浮点运算的能力，通常以TFLOPs(每秒万亿次浮点操作次数)为单位衡量。高计算能力对科学计算、模拟和深度学习等计算密集型任务至关重要。它能加速模型训练、数据分析以及复杂模拟的处理速度。
显存	是GPU用于存储数据和纹理的专用内存，与系统内存(RAM)不同，显存具有更高的带宽和更快的访问速度。显存的大小和性能直接影响GPU处理大规模数据的能力。
功耗	即功率损耗，指单位时间内的能量消耗，反应消耗能量的速率，单位是瓦特(W)。
卡间互联	NVIDIA® NVLink™ 是世界首项高速 GPU 互连技术，与传统的 PCIe 系统解决方案相比，能为多 GPU 系统提供更快速的替代方案。NVLink 技术通过连接两块 NVIDIA® 显卡能够实现显存和性能扩展，从而满足最大视觉计算工作负载的需求。
显存带宽	作为GPU与显存之间数据传输的桥梁；显存带宽=显存位宽x显存频率

图：Nvidia H200 Tensor Core GPU规格

Technical Specifications		
	H200 SXM ¹	H200 NVL ¹
FP64	34 TFLOPS	34 TFLOPS
FP64 Tensor Core	67 TFLOPS	67 TFLOPS
FP32	67 TFLOPS	67 TFLOPS
TF32 Tensor Core ²	989 TFLOPS	989 TFLOPS
BFLOAT16 Tensor Core ²	1,979 TFLOPS	1,979 TFLOPS
FP16 Tensor Core ²	1,979 TFLOPS	1,979 TFLOPS
FP8 Tensor Core ²	3,958 TFLOPS	3,958 TFLOPS
INT8 Tensor Core ²	3,958 TFLOPS	3,958 TFLOPS
GPU Memory	141GB	141GB
GPU Memory Bandwidth	4.8TB/s	4.8TB/s
Decoders	7 NVDEC 7 JPEG	7 NVDEC 7 JPEG
Confidential Computing	Supported	Supported
Max Thermal Design Power (TDP)	Up to 700W (configurable)	Up to 600W (configurable)
Multi-Instance GPUs	Up to 7 MIGs @16.5GB each	Up to 7 MIGs @16.5GB each
Form Factor	SXM	PCIe
Interconnect	NVIDIA NVLink™: 900GB/s PCIe Gen5: 128GB/s	2- or 4-way NVIDIA NVLink bridge: 900GB/s PCIe Gen5: 128GB/s
Server Options	NVIDIA HGX™ H200 partner and NVIDIA-Certified Systems™ with 4 or 8 GPUs	NVIDIA MGX™ H200 NVL partner and NVIDIA-Certified Systems with up to 8 GPUs
NVIDIA AI Enterprise	Add-on	Included

1. Preliminary specifications. May be subject to change.
2. With sparsity.




CPU：中央处理器



CPU 是**中央处理器**（Central Processing Unit）的简称，采用**超大规模的集成电路**组成制造，是计算机的运算核心和控制核心。CPU 包括运算器（算术逻辑单元、累加寄存器、数据缓冲寄存器、状态条件寄存器）、控制器（指令寄存器、程序计数器、地址寄存器、指令译码器、时序，总线，中断逻辑控制）、高速缓冲存储器、内部数据总线、控制总线及状态总线输入/输出接口等模块。

CPU基本架构图





CPU的分类



指令集是 CPU 所执行指令的二进制编码方法，是软件和硬件的接口规范。CPU 按照指令集可分为 CISC（Complex Instruction Set Computer，复杂指令集）和 RISC（Reduced Instruction Set Computer，精简指令集）两大类，CISC 型 CPU 目前主要是 X86 架构，RISC 型 CPU 主要包括 ARM、RISC-V、MIPS、POWER 架构等：

CPU主流架构对比

指令集架构	X86	ARM	RISC-V	MIPS	POWER
指令集	CISC	RISC	RISC	RISC	RISC
发布时间	1978 年	1985 年	2010 年	1981 年	1990 年
设计方	英特尔	ARM 计算机公司	加州大学伯克利分校	美普思科技	IBM
核心应用领域	主要应用于 Intel、AMD 等 PC 机，X86 服务器中	主要应用于移动终端之中，类如手机，平板等	主要应用于物联网领域，可扩展至高性能计算领域	主要应用于数字消费、宽带、无线、网络和便携式媒体领域	大型机领域
市占率	在 PC 市场独霸多年	在移动领域占主流	起步相对较晚，但发展很快，在智能穿戴产品上应用广泛	MIPS 两度易主后，新公司已转向 RISC-V，MIPS 基本退出国际主流应用	/
开/闭源	闭源	闭源	开源	闭源	闭源
显著特征	面向家用，商用领域，性能和兼容性上做得更好	面向移动，低功耗领域，体积小、功耗低、低成本、高性能	低功耗、低成本、灵活可扩展、安全可靠	追求高性能	追求最高性能




GPU: AI 算力的核心




- 图形处理器（graphics processing unit，缩写：GPU），又称显示核心、视觉处理器、显示芯片，是一种专门在个人电脑、工作站、游戏机和一些移动设备（如平板电脑、智能手机等）上做图像和图形相关运算工作的微处理器。
- NVIDIA公司在1999年发布GeForce 256图形处理芯片时首先提出GPU的概念。从此NVIDIA显卡的芯片就用这个新名字GPU来称呼。GPU使显卡削减了对CPU的依赖，并执行部分原本CPU的工作，尤其是在3D图形处理时。

GPU与显卡



SOC中的GPU模块






GPU是较为成熟的通用型人工智能芯片



科普创世纪 bilibili



显卡的GPU是如何用于AI训练的

科普创世纪



GPU在运算及并行任务处理能力上具有显著优势




- 图片处理器GPU又称**显示核心、视觉处理器、显示芯片**，是一种专门在个人电脑、工作站、游戏机和一些移动设备（如平板电脑、智能手机等）上**做图像运算工作的微处理器**，是显卡或GPU卡的“心脏”。
- CPU和GPU在架构组成上都包括3个部分：**运算单元（ALU）、控制单元（Control）、缓存单元（Cache）**。从结构上看，在CPU中，缓存单元占50%，控制单元占25%，运算单元占25%；然而在GPU中，**运算单元占90%比重**，缓存、控制各占5%；由此可见，**CPU运算能力更加均衡，GPU更适合做大量运算。**
- GPU通过将复杂的数学任务拆解成简单的小任务，并利用其**多流处理器来并行处理**，从而高效地执行图形渲染、数值分析和AI推理。




GPU在运算及并行任务处理能力上具有显著优势



图：CPU与GPU基本组成单元对比



图：GPU将极为复杂的任务进行拆解并行处理






GPU始于图形处理设备



- 最早计算机是黑白显示的时代，机器对于显示的要求极低，随着计算机的普及和软件的多样化，使用者对于显示的要求越来越高。VGA (Video Graphics Array, 视频图形阵列) 是一种标准的显示接口，是IBM于1987年提出的一个使用模拟信号的电脑显示标准。VGA标准由于可以呈现的彩色显示能力大大加强，因此迅速成为了显示设备的标准，也推动了VGA Card也即是显卡的诞生。早期的VGA Card的唯一功能是输出图像，图形运算全部依赖CPU，当微软Windows操作系统出现后，大量的图形运算占据了CPU的大量资源，如果没有专门的芯片来处理图形运算，Windows界面运作会大受影响而变得卡顿，因此出现专门处理图形运算的芯片成为必然趋势。
- 1993年1月，英伟达创立，1999年，英伟达发布了划时代的产品GeForce 256，首次推出了所谓图形处理器（GPU，Graphic Processing Unit）的概念，它带来了3D图形性能的一次革命。

图：显卡发展历程








浮点计算能力与可编程结合



- GeForce 256 是一款用于实时图形处理的专用处理器，GeForce图形处理器的发布，实现了顶点的矩阵变换和光照计算，图形实时处理应用需要高内存带宽和大量的浮点计算能力。2001年英伟达发布了第三代显示核心GeForce3，GeForce3不仅集成了来自之前GeForce 256和GeForce2芯片的“静态”座标转换和照明引擎，更增加了称为“顶点着色单元”的可编程顶点处理器功能。游戏开发者可借由加上顶点程序，让游戏产生令人惊艳的全新效果。
- 可编程性与浮点计算能力相结合，基于GPU的通用计算也开始出现，GPU朝着通用计算的方向持续演进。2006年，英伟达 CUDA (Compute Unified Device Architecture, 统一计算设备架构)，及对应工业标准的OpenCL的出现，让GPU实现更广泛的通用计算功能，GPGPU的概念落地。



图：Nvidia Tesla 架构






CUDA: NVIDIA的坚固护城河



- **CUDA**是英伟达2006年推出的一种并行计算平台和应用程序编程接口(API)，允许软件使用某些类型的GPU进行通用计算机处理。CUDA与NVIDIA GPU 无缝协作，加速跨多个领域的应用程序开发和部署。
- 目前，超过一百万的开发人员正在使用 **CUDA-X**，它提供了提高生产力的能力，同时受益于持续的应用程序性能。






GPU核心分类



通常GPU核心可分为三种：CUDA Core、Tensor Core、RT Core。

每个CUDA核心含有一个ALU(整数单元)和一个浮点单元，并且提供了对于单精度和双精度浮点数的FMA指令。

图：Cuda核心结构



GPU 核心类型	定义
CUDA Core	核心用于通用并行计算任务，可以执行FP32和FP64运算，以及整数运算，在处理广泛并行计算任务方面非常高效。
Tensor Core	针对深度学习和AI工作负载而设计的专用核心，擅长处理FP16和FP32的矩阵乘法和累加，在加速深度学习训练和推理中发挥重要作用。
RT Core	专门用于光线追踪处理的核心，能够高效进行光线和声音的渲染，对图形渲染和光线追踪等任务具有重要意义。

如果将GPU处理器比作玩具工厂，CUDA核心就是其中的流水线。流水线越多，生产的玩具就越多，虽然“玩具工厂”的性能可能会越好，但也受限于每个流水线的生产效率、生产设备的架构、生产存储资源能力等。反应在GPU上，还需考虑显卡架构、时钟速度、内存带宽、内存速度、VRAM等因素。

图：CUDA的核心数量并不能直接反映不同代GPU性能的好坏

	Nvidia Geforce GTX 980 Ti	GTX GeForce GTX 1080
晶体管数量	8,100,000,000	7,200,000,000
CUDA 核心数量	2816	2560
晶体管数量/核心	2,876,420	2,812,500
时钟速度	1500兆赫	2000兆赫



Tensor Core是增强AI计算的核心



图：Nvidia 初代Tensor Core的Volta GV100 SM架构



Tensor Core是用于加速深度学习计算的关键技术，其主要功能是执行深度神经网络中的矩阵乘法和卷积计算。

与传统CUDA Core相比，Tensor Core在每个时钟周期能执行多达 $4 \times 4 \times 4$ 的GEMM运算，相当于同时进行64个浮点乘法累加（FMA）运算。

其计算原理是采用半精度（FP16）作为输入和输出（矩阵A×矩阵B），并利用全精度（矩阵C）进行存储中间结果计算，以确保计算精度的同时最大限度地提高计算效率。


图：Tensor Core计算原理

$$D = \begin{pmatrix} A_{0,0} & A_{0,1} & A_{0,2} & A_{0,3} \\ A_{1,0} & A_{1,1} & A_{1,2} & A_{1,3} \\ A_{2,0} & A_{2,1} & A_{2,2} & A_{2,3} \\ A_{3,0} & A_{3,1} & A_{3,2} & A_{3,3} \end{pmatrix} \begin{pmatrix} B_{0,0} & B_{0,1} & B_{0,2} & B_{0,3} \\ B_{1,0} & B_{1,1} & B_{1,2} & B_{1,3} \\ B_{2,0} & B_{2,1} & B_{2,2} & B_{2,3} \\ B_{3,0} & B_{3,1} & B_{3,2} & B_{3,3} \end{pmatrix} + \begin{pmatrix} C_{0,0} & C_{0,1} & C_{0,2} & C_{0,3} \\ C_{1,0} & C_{1,1} & C_{1,2} & C_{1,3} \\ C_{2,0} & C_{2,1} & C_{2,2} & C_{2,3} \\ C_{3,0} & C_{3,1} & C_{3,2} & C_{3,3} \end{pmatrix}$$


FP16 or FP32 FP16 FP16 FP16 or FP32

图：Volta Tensor Core较Pascal架构的AI吞吐量增加了12倍

Pascal



Volta Tensor Core






GPU的三大发展方向



- GPU最初用在PC和移动端上运行绘图运算工作的微处理器，与CPU集成以集成显卡（核显）的形态发挥功能。NVIDIA于2007年率先推出独立GPU（独显），使其作为“协处理器”在PC和服务器端负责加速计算，承接CPU计算密集部分的工作负载，同时由CPU继续运行其余程序代码。
- 2019年NVIDIA的中国GTC大会设置了两大主题：AI和图形。从大会的关注重点可以看出，GPU未来趋势主要是3个：大规模扩展计算能力的高性能计算（GPGPU）、人工智能计算（AIGPU）、更加逼真的图形展现（光线追踪Ray Tracing GPU）。

四核心Intel处理器的die shot框图（带有Gen9核显）



英伟达三大产品系列



TESLA



QUADRO



GEFORCE




图形流水线是GPU工作的通用模型



- 图形流水线（graphics pipeline），也叫图形管线，指的是一连串的图形处理任务，这一系列的工作先后有序、不可颠倒，因此得以有这个形象的称呼。图形流水线是GPU工作的通用模型，它以某种形式表示的三维场景为输入，输出二维的光栅图形到显示器。

图：图形流水线






统一渲染架构的推出开启了通用计算大时代





- GPU的硬件结构从固定功能流水线架构发展为大规模并行的统一染色器架构。所谓统一渲染，即GPU中不再有单独的顶端渲染单元和像素渲染单元，而是由一个通用的渲染单元同时完成顶点和像素渲染任务。为了实现这一点，图形指令必须先经过一个通用的解码器、将顶点和像素指令翻译成统一渲染单元可直接执行的渲染微指令，而统一渲染单元其实就是一个高性能的浮点和矢量计算逻辑，它具有通用和可编程属性。在统一渲染架构的GPU中，Vertex Shader和Pixel Shader概念都将废除同时代之以ALU。ALU是个完整的图形处理体系，它既能够执行对顶点操作的指令（代替VS），又能够执行对象素操作的指令（代替PS）。基于统一渲染架构，Shader Core被挖掘出了更多的使用方法，比如通用计算。

早期的GPU只支持固定管线



统一渲染架构





program: mad mul txx cmp emt

shader processors

time

warps

stall & swap

stall & swap

stall & swap

finish & swap

finish & swap

fragment/thread




光线追踪时代开启



- 光线跟踪是一种真实地显示物体的方法，该方法由Appel在1968年提出。光线跟踪方法沿着到达视点的光线的反方向跟踪，经过屏幕上每一个像素，找出与视线相交的物体表面点P0，并继续跟踪，找出影响P0点光强的所有光源，从而算出P0点上精确的光线强度，在材质编辑中经常用来表现镜面效果。光线跟踪或称光迹追踪是计算机图形学的核心算法之一。在算法中，光线从光源被抛射出来，当他们经过物体表面的时候，对他们应用种种符合物理光学定律的变换。最终，光线进入虚拟的摄像机底片中，图片被生成出来。

光线追踪原理图



光线追踪效果对比图






走向新场景的GPGPU



- 对GPU通用计算进行深入研究从2003年开始，并提出了GPGPU概念，前一个GP则表示通用目的（General Purpose），所以GPGPU一般也被称为通用图形处理器或通用GPU。伴随着GPU Shader单元计算能力的不断增长，GPU也在向通用计算开始扩张边界。GPU从由若干专用的固定功能单元（Fixed Function Unit）组成的专用并行处理器，进化为了以通用计算资源为主，固定功能单元为辅的架构，这一架构的出现奠定了GPGPU的发展基础。
- GPGPU由于其高并发性、高吞吐量以及不断提升的可编程能力，目前的应用已经扩展到科学计算、区块链、大数据处理、工程计算、金融、基因等方面。

计算是未来科学和工程突破的关键



一些典型科学与工程计算应用的计算需求估计

二维非混流计算:	10^{16} 次/秒:
二维分子动力学计算:	10^{14} 次/秒:
三维多介质(氢)计算:	10^{15} 次/秒:
输运计算:	10^{15} 次/秒:
全球海洋计算:	10^{15} 次/秒:
三维重结构计算:	10^{15} 次/秒:
QCD, 聚冷格子计算:	10^{16} 次/秒:
三维计算:	10^{18} 次/秒:
计算流体力学:	10^{18} 次/秒:
原子内电子能级计算:	10^{17} 次/秒:



GPGPU与GPU的对比




- GPU的核心价值体现在图形图像渲染，GPGPU的重点在于算力，虽然都是由GPU的架构演进而来，但所关注的重点有明显区别。GPGPU架构设计时，**去掉了**GPU为了图形处理而设计的**加速硬件单元**，**保留了**GPU的**SIMT架构**和**通用计算单元**，使之更适合高性能并行计算，并能使用更高级别的编程语言，在性能、易用性和通用性上更加强大。

GPGPU与GPU对比

技术门槛：GPU的软硬件系统设计复杂度超越AI芯片100倍以上

	GPU	GPGPU&AI
指令集	千条量级	百条以内
算力利用率	基于硬件层的任务管理和智能调度能力要求高 让芯片从硬件层即提高算力的利用率	多依赖于软件层的调度实现，但： - 增加了软件开发的复杂度 - 降低了硬件算力的利用率 - 减缓了软件栈迭代更新的速度
开发生态	- 生态系统复杂 - 涉及行业应用广泛 - 行业标准成熟(OpenCL, OpenGL, Vulkan, DirectX)	- 新生态面临客户冗长的适配期和巨大的软件投入 - 产品“快”，应用“慢”

GPGPU架构图






SIMT, 主流GPU的系统架构核心




- 现代的GPU架构中，每个GPU会包含很多的core，英伟达称之为流多处理器(streaming multiprocessors, SM)。每个核都在执行单指令多线程的程序(single-instruction multiple-thread, SIMT)。在单个核上执行的线程可以通过暂存内存(有点像阻塞操作, 保存现场)进行通信, 并使用快速barrier操作进行同步。
- SIMT与SIMD(同一条指令多个数据)的共同点是同一条指令。SIMT是SIMD的线程等价物, 不同之处在于, SIMD使用执行单元或矢量单元, 而SIMT将其扩展为利用线程。SIMT的好处是无需开发者费力把数据凑成合适的矢量长度, 并且SIMT允许每个线程有不同的分支。SIMT的主要优点是它减少了指令预取带来的等待时间。

现代GPU简单架构示意图



SIMD与SIMT对比





GPGPU架构，以A100为例



- A100是NVIDIA2020年5月14日发布的采用新一代Ampere架构的计算卡，使用了GA100核心。Ampere架构仍然沿用了成熟的GPC-TPC-SM多级架构，GA100内部包含8组图形处理集群（Graphics Processing Cluster，GPC），每组GPC包含8组纹理处理集群（Texture Processing Cluster，TPC），每组TPC又包含8组流式多处理器（Streaming Multiprocessor，SM），另外还有内存控制器组成。





网络：算力的瓶颈之一



在人工智能（AI）模型的训练过程中，特别是涉及大型模型的多GPU（多卡）训练时，网络通信的效率对整体性能起着关键作用。多GPU协同训练需要频繁交换数据，如梯度和模型参数，这使得**通信速度**成为影响训练效率的瓶颈之一。以NVIDIA的A100和RTX 4090两款GPU为例，它们在计算能力上可能相近，但他们的售价几乎相差**10倍**，主要原因在于他们在通信能力和内存配置上存在显著差异。A100配备了80GB的高带宽内存（HBM2），内存带宽达到2TB/s，并支持高达900GB/s的NVLink通信带宽，通信延迟约为1微秒。这些特性使A100在多GPU训练中能够高效地处理大规模数据交换，从而提高训练速度和效率。

	H100	A100	4090
Tensor FP16 算力	989 Tflops	312 Tflops	330 Tflops
Tensor FP32 算力	495 Tflops	156 Tflops	83 Tflops
内存容量	80 GB	80 GB	24 GB
内存带宽	3.35 TB/s	2 TB/s	1 TB/s
通信带宽	900 GB/s	900 GB/s	64 GB/s
通信时延	~1 us	~1 us	~10 us
售价	\$30000~\$40000	\$15000	\$1600



PCIe和NVLINK




目前的**GPU**互联方式主要有两种，一种是**PCIe**，另一种是**NVlink**。

- PCIe (Peripheral Component Interconnect Express)：它是一种**计算机总线标准**，用于在计算机内部连接各种设备和组件（例如显卡、存储设备、扩展卡等）。PCIe接口以串行方式传输数据，具有较高的通信带宽，适用于连接各种设备。然而，由于其基于总线结构，同时连接多个设备时可能会受到带宽的限制。
- NVLink (Nvidia Link)：它是由NVIDIA开发的一种**高速、低延迟的专有连接技术**，主要用于连接NVIDIA图形处理器（GPU）。NVLink提供了具有很高带宽和低延迟的直接GPU间通信能力，多个GPU通过英伟达SXM封装技术封装在一起，使得多个GPU可以在更紧密和高效的方式下协同工作。相比于PCIe，NVLink在支持GPU之间的数据传输和协作方面提供了更好的性能和效率。SXM为NVLink的接口。





PCIe和NVLINK



- 以英伟达的DGX服务器为例。它通过4个NVLinkSW芯片将8个GPU互连起来，实现了GPU之间的高带宽互联，最新一代的DGXH100GPU之间带宽高达900GB/s。
- 英伟达的八张SXM接口的GPU形成一个模组HGX（市面上的服务器厂商都需要基于HGX模组推出服务器），且8张卡是一起的，无法拆分
- Nvlink解决的是GPU之间的高速互联，GPU与CPU之间的还需要标准的PCIE链路链接。
- 主流的大模型依赖于多卡协同，非常吃GPU之间的带宽，因此Nvlink全互联的GPU非常抢手




NVLINK




- 英伟达NVLink。NVLink是 NVIDIA 的高带宽、高效能、低延迟、无损的 GPU 到 GPU 互连技术，其中包含诸如链路级错误检测和数据包回放机制等弹性特性，可保证数据的成功传输。
- 对比上一代，第四代NVLink可将全局归约操作的带宽提升 3 倍，通用带宽提升 50%，单个NVIDIA H100 Tensor Core GPU最多支持18个NVLink连接，多 GPU IO 的总带宽为 900GB/s，是 PCIe 5.0 的 7 倍。

NVLink 链接图




具有 NVLink GPU 到 GPU 连接的 NVIDIA H100 PCIe



具有 NVLink GPU 到 GPU 连接的 NVIDIA H100

NVLink 性能表现




NVLink 规格

	第二代	第三代	第四代
每个 GPU 的 NVLink 带宽	300GB/秒	600GB/秒	900GB/秒
每个 GPU 的最大链接数	6个	12	18
支持的 NVIDIA 架构	NVIDIA Volta™ 架构	NVIDIA 安培架构	NVIDIA Hopper™ 架构



PCIe和NVLINK





通用算力提升是英伟达GPU架构演进的重点之一



- 2016年3月英伟达推出Pascal架构, 采用16nm和14nm的工艺。该架构建立在五大技术突破之上, 启用了全新的计算平台, 打破了从书桌端到数据中心的传统思维。Pascal彻底采用全新设计, 为深度学习和其他计算工作负载提供更好的性能。该架构利用全新的混合精度指令, 可为深度学习提供每秒超过20万亿次浮点运算的性能峰值。

英伟达架构两年升级一次






Nvidia AI芯片的技术演进



Nvidia的AI芯片在过去八年中实现了显著的技术进步。从“Pascal”P100 GPU到“Blackwell” B100 GPU，性能提升了1053倍。通过降低浮点精度（从FP16到FP4），实现了更高效的计算，同时每单位能耗显著下降，从P100的17000焦耳/token降低到B100的0.4焦耳/token。尽管GPU价格上涨了约7.5倍，但性能的大幅提升使得其在十天内训练1.8万亿参数的大模型成为可能。

图：B100 GPU较P100处理Token的能耗减少了45000倍



图：P100到B100各项指标参数(以GPT-4 1.8T MOE 10天基准测试为参考)

年份	2016	2018	2020	2022	2024
GPU	"Pascal" P100	"Volta" V100	"Ampere" A100	"Hopper" H100	"Blackwell" B100
峰值(TFLOPS)	19	130	620	4000	20000
训练和推理精度	FP16	FP16	FP16	FP8	FP4
推理每token焦耳数	17000	1200	150	10	0.4
训练所需电力(GW/小时)	1000	140	40	13	3
GPU 架构图					




AI ASIC: 算力芯片的下一章



ASIC 作为**专用芯片**，可以针对特定的 AI 算法和应用场景进行优化，提供最高的性能和能效。许多科技巨头都在开发自己的 AI 专用 ASIC，如**谷歌的 TPU**、华为的昇腾 Ascend **NPU** 系列等。与 GPU 和 FPGA 相比，ASIC 可以在**计算速度、功耗、成本**等方面做到更加极致的优化。

但是，ASIC 的**设计周期较长**，**前期投入大**，**灵活性也较差**。此外，ASIC 芯片通常需要配合专门的软件栈和开发工具，生态系统的建设也是一大挑战。

下图为 ASIC 架构概略图，我们可以看到其包括接口模块，存储器接口，统一缓冲区，计算单元，数据处理单元，控制单元等等，旨在提供高效的计算和数据处理能力。





训练和推理集群对加速计算芯片的需求




□ 目前在训练阶段，**训练集群**对加速计算芯片的需求已提升到**万卡**级别。随着AI模型对训练需求的提升，未来10万卡级别指日可待。

□ 而在推理阶段，由于计算量与业务和应用密切相关，单个推理集群对加速计算芯片的需求低于训练集群，但推理集群的部署数量要远多于训练集群，推理集群的数量预计将达到**百万级别**。

□ AI算力集群特别是推理集群对加速计算芯片的庞大需求，是ASIC快速成长的核心驱动力。

训练和推理对AI算力集群的需求差异





训练和推理集群对加速计算芯片的需求



- **ASIC针对特定算法和应用进行优化设计，在特定任务上的计算能力强大**，例如在某些AI深度学习算法中实现高效的矩阵运算和数据处理。GPU具有强大的并行计算能力，拥有众多计算核心，可同时处理多个任务，在通用计算和图形处理方面表现出色，适用于大规模的数据并行计算，如科学计算、图形渲染、视频处理等；但GPU在特定任务上的计算效率可能不如ASIC。
- **ASIC通常具有较高的能效比，因其硬件结构是为特定任务定制的，能最大限度减少不必要的功耗。** GPU由于其通用的设计架构，在执行特定任务时可能存在一些功耗浪费；但随着技术的进步，新一代GPU也在不断提高能效比。
- **ASIC在处理特定任务时，能实现高吞吐量，数据处理速度快**，可快速完成大量的数据处理工作。GPU具有较高的带宽和并行处理能力，在图形处理和通用计算中能够实现较高吞吐量，但在处理一些复杂、非图形相关的特定任务时，其吞吐量可能会受到一定限制。
- **ASIC在绝对算力和片间互联方面普遍低于GPU，但ASIC的服务器间互联由于采用以太网为主，具有通用性强、生态开放、低成本等优势。**



训练和推理集群对加速计算芯片的需求



市面主流GPU与ASIC规格对比

公司		英伟达		AMD		Google		亚马逊		微软	Meta
型号		H100	B100	MI300X	MI325X	TPU v5p	TPU v6 Trillium	Trainium 2	Inferentia 2	Maia 100	MTIA 2
算力 (TFLOPS)	FP16/BF16	990	1750	1307	1307	459	926	430	190	800	354
	FP8/INT8	1979	3500	2615	2615	918	1852	860	380	1600	708
内存	类型	HBM3	HBM3e	HBM3	HBM3e	HBM2e	HBM3	HBM3	HBM2e	HBM2e	LPDDR5
	容量 (GB)	96	200	192	256	96	96	96	48	64	128
	带宽 (TB/s)	3.35	8	5.3	6	2.765	1.6	4	-	1.8	0.2
网络性能 (GB/s)		900	1800	896	896	600	800	-	100	600	32
最大TDP (W)		700	700	750	1000	-	-	-	-	700	90
工艺制程 (nm)		4	4	5	4	5	4	4	7	5	5



ASIC的竞争格局



ASIC 不同于 CPU、GPU、FPGA，目前全球 ASIC 市场**并未形成明显的头部厂商**。由于 ASIC 开发周期长，仅有大厂有资金与实力进行研发。同时，ASIC 是全定制芯片，在某些特定场景下运行效率最高，故某些场景下游市场空间足够大时，量产 ASIC 芯片可以实现丰厚的利润。目前市场上主流 ASIC 有 TPU 芯片、NPU 芯片、VPU 芯片以及 BPU 芯片，它们分别是由 **Google、寒武纪、Intel 以及地平线公司** 设计生产。在**海外，谷歌 TPU 是主导者**，国内初创芯片企业（如寒武纪、比特大陆和地平线），互联网巨头（如百度、华为海思和阿里）在细分领域也有所建树，目前已经取得了一定的成果。

名称		提供商	简介
ASIC	TPU	Google	TPU 是谷歌针对自身应用专门优化的人工智能芯片，该芯片已经在 AlphaGo 中应用，并支持 TensorFlow 机器学习框架。
	NPU	寒武纪	NPU 是中科院计算所团队研发，采用“数据驱动并行计算”的架构，可应用于手机、安防、可穿戴设备等终端芯片中。
	VPU	Intel	Intel 收购的 Movidius 开发的 Myriad 系列 VPU 专门为计算机视觉进行优化，可以用于 3D 扫描建模、室内导航、360 度全景视频等计算机视觉用途。
	BPU	地平线	BPU 芯片是地平线机器人研发，该芯片未来会直接应用于自身的主要产品中，包括智能驾驶、智能生活和智能城市。
	BM1680	比特大陆	2017 年其最新发布的 BM1680 专用芯片适用于 CNN/RNN 等深度学习网络模型的预测和训练计算加速。




TPU



TPU (Tensor Processing Unit, 张量处理器), 是一种**专为处理张量运算**而设计的**ASIC芯片**, 由谷歌自研在2016年推出首款产品。在深度学习的世界里, 张量(多维数组)是无处不在的。TPU就是为了高效处理这些张量运算而诞生的。TPU内置大量**矩阵运算单元**, 使得其能够**并行处理**大量的矩阵运算, 大大提高计算效率。

核心特性:

- **脉动阵列 (Systolic Array)**: 通过数据流驱动架构, 实现矩阵乘法的高效流水线计算, 减少内存访问延迟。
- **混合精度支持**: 支持BF16、FP16、INT8等低精度计算, 适配不同模型需求。
- **大规模可扩展性**: 通过光互连 (Optical Interconnect) 技术, 单集群 (TPU Pod) 可集成数万颗芯片。






TPU的主要架构



下图为TPU V1的芯片架构设计原理图。主要的计算部件是右上角的矩阵乘单元Matrix Multiply Unit。其输入是蓝色的权重数据队列FIFO和蓝色的统一缓冲（UB:Unified Buffer），而其输出是蓝色的累加器(Acc: Accumulators)。Google选择**复杂指令集(CISC)**作为TPU指令集的基础，为了控制MUX、UB和AU进行计算，Google定义了十几个专门为神经网络计算而设计的高级指令。同时TPU又遵循极简设计方案，专门为深度学习运算加速服务，是一个**单线程芯片**，不需要考虑缓存、分支预测、多道处理等问题。

TPU主要包括以下计算资源：

- **矩阵乘法单元(MUX)**：65,536个8位乘法和加法单元，运行矩阵计算
- **统一缓冲(UB)**：作为寄存器工作的24MB容量SRAM
- **激活单元(AU)**：硬件连接的激活函数






TPU的核心：脉动阵列



TPU采用了与传统CPU和GPU截然不同的脉动阵列（**systolic array**）结构来加速AI运算，脉动阵列能够在时钟周期内处理数十万次矩阵运算，在每次运算过程中，TPU能够将多个运算逻辑单元（ALU）串联在一起，并复用从一个寄存器中取得的结果。这种设计，不仅能够将数据复用实现最大化，减少芯片在运算过程中的内存访问次数，提高AI计算效率，同时也降低了内存带宽压力，进而降低内存访问的能耗。






谷歌TPU算力集群能力




- TPU v4和TPU v5p算力集群采用3D torus(3D环面)架构和OCS, 提供高速的网络连接, 增强拓展性与互联效率。在TPUv4的架构中, 每64颗TPU v4芯片组成4x4x4的立方体, 每个CPU配备4颗TPU v4, 64颗TPU v4和16颗CPU放入一个机架, 形成一个模块。
- 一个模块有6个面的光路链接, 每个面有16个链接, 单模块共有96个光路连接到OCS。为了提供3D环面的环绕链接, 对面的链接必须连接到同一个OCS。每个模块连接48个OCS ($6 \times 16 \div 2$), 最终实现所需的4096个TPU v4芯片互联。
- TPU v4算力集群的物理架构: 一个PCB包含4个TPU v4, 通过ICI链路连接到其他托盘 (tray), 16个托盘共同放入一个机架, 形成4x4x4的3D模块结构。64个机柜共同组成4096颗芯片规模的算力集群。

TPU立方体与3个OCS的连接



TPU v4封装和算力集群





TPU的发展过程



自2016年推出首款张量处理单元（TPU）以来，谷歌在人工智能专用芯片领域持续创新，不断提升性能和能效。最新发布的TPUv6e（2024年）在前代产品的基础上，进一步优化了训练和推理能力，为中大型模型提供了更高效的支持。

参数/TPU 版本	TPUv1	TPUv2	TPUv3	TPUv4	TPUv5e	TPUv5p	TPUv6e (Trillium)
推出年份	2015年	2017年	2018年	2021年	2023年	2023年	2024年
制程工艺	28nm	16nm	16nm	7nm	5nm	5nm	5nm
裸片尺寸 (mm²)	331	625	700	<400	300-350	未公布	未公布
片上内存 (MiB)	28	32	37	170	48	112	未公布
时钟速度 (MHz)	700	700	940	1050	未公布	1750	未公布
内存类型	DDR3	HBM	HBM	HBM	HBM	HBM	HBM
内存容量	8 GB	16 GB	32 GB	32 GB	16 GB	96 GB	96 GB
内存带宽 (GB/s)	34	600	900	1200	819	2765	1640
热设计功耗 (W)	75	280	220	170	未公布	未公布	未公布
峰值性能 (BF16)	23 TFLOPS	45 TFLOPS	123 TFLOPS	275 TFLOPS	197 TFLOPS	459 TFLOPS	918 TFLOPS
峰值性能 (INT8)	92 TOPS	92 TOPS	246 TOPS	未公布	393 TOPS	918 TOPS	1836 TOPS




谷歌TPU基准测试性能对比



□ TPUv4与英伟达A100在MLPerf基准测试中的性能对比：TPU v4在BERT上比A100快1.15倍，比IPU快约4.3倍；在ResNet上，TPUv4分别比A100和IPU快1.67倍和约4.5倍；运行MLPerf基准测试时，A100的平均功耗比TPUv4高1.3~1.9倍。虽然TPUv4单芯片算力A100的88%，但在性能和功耗表现上要优于A100。

TPU与A100在MLPerf训练中的性能对比



TPU与A100在MLPerf训练中的功耗对比

MLPerf Benchmark	英伟达A100	谷歌TPU v4	比率
BERT	380 W	197 W	1.93
ResNet	273 W	206 W	1.13




谷歌TPU迭代推动大模型训练效率显著提升



□ TPU的算力成本随着产品更新迭代也在持续优化。TPUv5e的相对性价比 (TFLOPs/\$) 是TPUv4的2.3倍，参考谷歌披露的TPUv4公开标价3.22美元/芯片/小时，TPUv5e的标价为1.2美元/芯片/小时，TPUv5e以更低的成本实现了更高的算力。TPUv5p训练 LLM的速度比TPUv4快2.8倍，利用第二代SparseCores，TPUv5p训练嵌入密集模型的速度比TPUv4快1.9倍。

谷歌TPU迭代推动大模型训练效率的显著提升






NPU



NPU (**Neural Processing Unit, 神经网络处理器**) 是一种专为神经网络计算设计的专用硬件加速器, 其核心目标是高效执行深度学习模型的推理 (Inference) 和训练 (Training) 任务。与CPU和GPU不同, NPU通过定制化架构**优化矩阵乘加运算 (MAC)**、**激活函数和量化计算**, 显著提升能效比 (TOPS/W) 和计算密度 (TOPS/mm²)。





NPU



工科男孙老师 bilibili

CPU GPU NPU


问题 | GPU的长处 | CPU的长处 | CPU GPU区别 | 从GPU到GPGPU | NPU | 总结



NPU的兴起——DianNao




2014年中科院的**陈天石科研团队**发表了**DianNao**系列论文，随即席卷了体系结构界，开启了专用人工智能芯片设计的先河。后来中科院旗下的**寒武纪科技**推出了其第一代**NPU寒武纪1A**，并用在了华为麒麟970芯片中。随后**谷歌**推出了**TPU架构**，**华为**推出了自研的基于**达芬奇架构的NPU**，**阿里**推出了“**含光**”架构的NPU。后续的NPU架构与DianNao架构都有一定联系。



神经网络模式图，基于神经网络的人工智能算法，成功模拟了人类大脑内部神经元的结构。图中的neuron代表的就是单个神经元，synapse代表神经元的突触，hidden layer是神经网络中的隐含层，output layer是输出层，input是神经网络输入。



DianNao的结构



蓝色区域是硬件逻辑模拟的神经网络结构，称为NFU(Neural Functional Units)。从左到右分为三个部分，NFU-1、NFU-2、NFU-3。

NFU-1是乘法单元，共有256(16×16)个乘法器。

NFU-2是加法树，共有16个加法树，每个加法树由15个加法器组成，排列依次为8-4-2-1。

NFU-3是激活单元，共有16个激活单元。

NFU将资源分为了16份，每一份包括NFU-1的16个乘法器，NFU-2的1个加法树(15个加法器)和NFU-3的一个激活函数运算器

运算时一份资源中乘法器同时运行共输出16个结果，送加法树，加法树运算后得出一个结果送激活函数，激活函数运算判断是否激活。


三个缓冲区，一个存储输入的数据(NBin)，一个存储运算的权值(SB)，一个存储结果(NBout)。



PuDianNao的结构



PuDianNao是寒武纪为了加速机器学习中除了深度学习之外的其他重要算法而推出的一款嵌入式处理器方案。PuDianNao，内部实现了7种常用的机器学习算法：k-means, k-nearest neighbors, naive bayes, support vector machine, linear regression, and DNN。






昇腾系列NPU



为了满足当今飞速发展的深度神经网络对芯片算力的需求, 华为公司于 2018 年推出了**昇腾系列 AI 处理器** (NPU, Neural-Network Processing Units), 可以对**整型数 (INT8、INT4) 或浮点数 (FP16)** 提供强大高效的乘加计算力

昇腾 AI 处理器本质上是一个**片上系统**, 主要可以应用在与图像、视频、语音、文字处理相关的场景。其主要的架构组成部件包括特制的计算单元、大容量的存储单元和相应的控制单元



昇腾 AI 处理器逻辑图




达芬奇架构



达芬奇架构 (DaVinci Architecture) 基于 ARM 架构, 是华为自研的面向 AI 计算特征的全新计算架构, 不同于传统的支持通用计算的 CPU 和 GPU, 也不同于专用于某种特定算法的专用芯片 ASIC, 达芬奇架构本质上是为了适应某个特定领域中的常见应用和算法。

计算部件: 矩阵计算单元 (Cube Unit)、向量计算单元 (Vector Unit) 和标量计算单元 (Scalar Unit) 这三种计算单元分别对应了张量、向量和标量三种常见的计算模式, 形成了三条独立的执行流水线, 在系统软件的统一调度下互相配合达到优化的计算效率。

DaVinci Core



- **Cube**: 4096(16^3) FP16 MACs + 8192 INT8 MACs
- **Vector**: 2048bit INT8/FP16/FP32 vector with special functions (activation functions, NMS- Non Minimum Suppression, ROI, SORT)
- Explicit memory hierarchy design, managed by MTE




FPGA



FPGA (Field - Programmable Gate Array) , 即**现场可编程门阵列**, 它是在 PAL、GAL、CPLD 等可编程器件的基础上进一步发展的产物。它是作为专用集成电路 (ASIC) 领域中的一种半定制电路而出现的, 既解决了定制电路的不足, 又克服了原有可编程器件门电路数有限的缺点。

FPGA 通常由可编程的逻辑单元 (Logic Cell, LC)、输入输出单元 (Input Output Block, IO) 和开关连线阵列 (Switch Box, SB) 三种功能单元构成。

FPGA 常年来被用作专用芯片 (ASIC) 的**小批量替代品**, 然而近年来在微软、百度等公司的数据中心大规模部署, 以同时提供强大的计算能力和足够的灵活性。





FPGA简介





FPGA编程





FPGA和ASIC对比



- FPGA全称是FieldProgrammableGateArray: 可编程逻辑门阵列, 是一种“**可重构**”芯片, 具有模块化和规则化的架构, 主要包含可编程逻辑模块、片上存储器及用于连接逻辑模块的克重购互连层次结构。在较低的功耗下达到GFLOPS数量级的算力使之成为并行实现人工神经网络的**替代方案**。
- ASIC (Application-SpecificIntegrated Circuit) 是指应特定用户要求和特定电子系统的需要而设计、制造的集成电路。ASIC从性能、能效、成本均极大的超越了标准芯片, 非常适合AI计算场景, 是当前大部分AI初创公司开发的目标产品。

- **可加速上市进程:** 开发时间较短, 且无需布局、掩膜等制造步骤。
- **非提前支付的一次性开支:** 这些均是ASIC设计中需要的开支。
- **更简化的设计周期:** 可通过设计软件处理布线、布局及时序等问题。
- **更具预测性的项目周期:** 消除了潜在的重新设计和晶圆容量等。
- **现场可重编功能:** 可以远程上传的新比特流, 通过软件实现自定义硬件功能。



- **完整的定制功能与更小的尺寸:** 由于器件是根据设计的规格进行生产的 (注: ASIC芯片也分为全定制和半定制)。
- **更低的器件成本:** 实现大批量设计与生产, 批量越大, 成本越低。
- **高性能、低功耗:** ASIC芯片相当于将AI算法“硬件化”, 特定算法下能效更高。
- **可形成IP核复用:** 模块化的设计方法, 可根据设计需要进行IP选取。



FPGA的特性



FPGA 和 CPU、GPU、ASIC 的核心区别：

- 其底层逻辑运算单元的连线及逻辑布局未固化，适用于底层算法需要持续更迭的运算领域，例如人工智能算法优化。而其他类别逻辑芯片，像 ASIC、CPU 和 GPU 等，物理底层逻辑单元的运算关系均已固定且不可变。
- 并且 FPGA 不需要像 CPU 和 GPU 在软件应用层面的指令系统编译，对 FPGA 进行编程是使用硬件描述语言（如verilog），并直接编译烧录为晶体管电路的组合，即直接用晶体管电路实现用户的算法。

名称	CPU	GPU	ASIC	FPGA
设计灵活性	设计灵活性较低，主要通过软件编程实现功能。	设计相对固定。	设计完全定制，灵活性最低。	设计高度灵活，可根据需求进行编程和重配置。
性能与效率	适用于通用计算任务，性能均衡。	在并行计算方面表现出色，计算效率高。	性能最优，专为特定应用设计，能效高。	性能介于CPU和ASIC之间，可根据应用需求调整。
开发难度与成本	开发难度相对较低，通用性强，成本适中。	开发难度适中，需要一定的并行编程知识，成本较高。	开发难度最大，设计周期长，成本高昂但长期回报丰厚。	开发难度较大，需要深厚的硬件设计知识，但可通过重用减少成本。

芯片类型	英文全称	核心定位	关键优势
CPU（中央处理器）	Central Processing Unit	通用计算核心	处理复杂逻辑
GPU（图形处理器）	Graphics Processing Unit	并行计算核心	海量简单任务并行计算
ASIC（专用集成电路，包含 TPU、NPU、VPU、BPU 等）	Application-Specific Integrated Circuits	定制计算	较高的能效比，针对特定用户要求和场景应用而设计，在特定任务上的计算能力强大
FPGA（现场可编程门阵列）	Field Programmable Gate Array	可编程、半定制计算	可反复编程，快速迭代



FPGA四大巨头企业对比



	赛灵思	英特尔	Lattice	Microchip
公司产品	广泛的高级集成电路，软件设计工具，以及作为预定义系统级功能的IP核等	可编程逻辑器件，带有软件工具的可编程逻辑技术、知识产权(IP)和技术服务等	现场可编程系统芯片，复杂的可编程逻辑器件，可编程混合信号产品，可编程数字互连器件等	高性能高可靠性模拟不射频器件，混合信号不射频集成电路，Soc解决方案等
产品工艺	7nm/16nm/20nm/28nm/45nm	10nm/14nm/20nm/28nm/40nm/65nm/90nm/130nm	28nm/40nm	28nm
应用领域	5G无线，数据中心，汽车，无线通信，AI智能，工业，消费电子，医疗不科学等	数据中心，5G，物联网，汽车，消费电子，军事航空，医疗，无线通信等	消费品市场，通讯、计算机、工业、汽车、医药、军事等	军用/航，医疗，移动通信、计算机及周边设备、汽车、卫星、通讯等
客户	全世界有 60000多家客户包括Alcatel, Cisco Systems, EMC, Ericsson, Fujitsu, Hewlett-Packard, IBM, Lucent Technologies, Motorola, NEC, Nokia, Nortel, Samsung, Siemens, Sony, Oracle以及Toshiba.	在世界范围内为 14000多个客户提供高质量的可编程解决方案。包括百度，艾睿，骁龙，贸泽，罗彻斯特，得捷等。	苹果和HTC等	文晔科技等




基于不同计算范式的AI芯片：类脑芯片



- CPU/GPU/GFPGA/ASIC及SoC是目前用的较多的AI芯片，此类AI芯片大多是基于深度学习，也就是**深度神经网络（DNN）**，以并行方式进行计算的芯片，此类AI芯片又被称为**深度学习加速器**。
- 如今，模仿大脑结构的芯片具有更高的效率和更低的功耗，这类基于神经形态计算，也就是**脉冲神经网络（SNN）**的芯片为**类脑芯片**。
- 目前，部分企业产品已进入小批量试用阶段，类脑芯片最快将于**2023年**成熟，能效比有望较当前芯片提高2-3个数量级。

中国类脑芯片发文数量
(2014-2022.01)



DNN与SNN对比

	DNN	SNN
训练方式	需大量数据	单个数据样本
学习方式	监督学习	无监督学习
输入类型	图像帧或数据阵列	脉冲
时延	高	极低（接近实时）
神经元模型复杂程度	低	高
功耗	由处理器与存储器存取决定	由每个事件功耗决定
分类精度	较高	较低
分类速度	低	高较
研究阶段	较成熟	探索及部分小规模试用阶段

类脑芯片的硬件实现方式

- **忆阻器**：在紧凑性、可靠性、耐用性、存储器保留期限、可编程状态和能效等方面的特性，有利用成为电子突触器件。
- **自旋电子器件**：其不易失性、可塑性及振荡和随机行为，允许创建模仿生物突触和神经元关键特征的组件。
- **光子器件**：利用半导体放大器中使用的非线性光学增益介质，实现神经形态计算所需的功能。
- **电化学器件**：具有高精度、现行和对称的电导效应，低开关能量和高扩展性，使用于SNN的内置定时机制。
- **二维材料**：包括过渡金属二硫族化合物、石墨烯等，可开发成为人工突触。
-




AI芯片发展：向着更低功耗、更接近人脑的方向



- 现在用于深度学习的AI芯片（包括CPU、GPU、FPGA、ASIC）为了实现深度学习的庞大乘积累加运算和并行计算的高性能，芯片面积越做越大，带来了成本和散热等问题。AI芯片软件编程的成熟度、芯片的安全，神经网络的稳定性等问题也未能得到很好的解决，因此在现有基础上进行改进和完善此类AI芯片仍是当前主要的研究方向。
- 最终，AI芯片将近一步提高智能，向着更接近人脑的高度智能方向不断发展，并向着边缘逐步移动以获得更低的能耗。

功耗 (W)

AI芯片消耗



AI芯片与类脑智能

AI芯片	可实现的功能	人类特征
传感器AI芯片	感知：视觉、听觉、触觉等	人体
类脑芯片及深度学习芯片	识别、分类、决策、预测、分析、推理	人脑
未来带意识、带自主性的芯片	情感、想象力、创造力等	人性



AI芯片发展：AI设计AI芯片



小木陪你看科技

AI设计AI芯片

谷歌AlphaChip
芯片新革命



华南理工大学
South China University of Technology

03

国产算力AI芯片的发展





新一代人工智能拉开新一轮科技竞赛




中美人工智能产业发展情况对比

衡量指标	美国	中国
累计企业数量	4100+	1200+
累计融资规模	1600+亿	470+亿
算力指数	77	70
AI顶尖人才 (AI 2000榜单学者数量)	1146人次	232人次
AI顶尖机构 (AI 2000榜单全球前20强)	15家	2家
AI人才规模	16万+	18万+
AI专利数量 (近10年累计)	116万+	191万+
数据量规模 (2025年预计)	30.6ZB	48.6ZB

人工智能全球市场规模及预测

(单位：亿元人民币)



2020-2028年中国人工智能产业规模

(单位：亿元人民币)



数据来源：Precedence Research、艾瑞咨询



GPU行业需跨越CUDA横亘



- **英伟达CUDA已经实现了与算法工程师、芯片客户的强绑定**，众多算法工程师已经习惯了一套工具库、一套编程语言，向外迁移存在不习惯等问题。所以很多算力芯片硬件厂商选择了兼容CUDA的路线——使硬件能够直接用CUDA调动起来，以降低用户的硬件迁移痛点。
- **兼容CUDA需要巨大时间和成本投入**。例如，兼容CUDA涉及50个驱动、50个编译器、50个数学库、300个应用层工程师，3-5年的时间。功能的验证，用户的培养需要额外3-5年，每年还要至少开支1000万-3000万元资助外部开发者。
- **从头部AI厂商布局来看，英伟达竞争者AMD选择兼容CUDA+自研原生“两条腿”并行**，英伟达客户谷歌、Meta、亚马逊等均已推出自己的AI芯片。国产GPU在起步阶段兼容CUDA生态更容易发展，易于生存。在美国技术封锁的大背景之下，“AI信创”为国产算力芯片提供了市场窗口，远期国产GPU还是需要发展原生生态。

	公司	芯片名	发布时间	代数	制程 (nm)
对标英伟达GPU	亚马逊	Trainium	2022	1	5
	亚马逊	Inferentia	2019	2	5
	Google	Tensor (TPU)	2015	4	7
	微软	Athena	2024	1	5
对标英特尔CPU	亚马逊	Graviton	2018	3	5
	Google	Maple	2025	1	5
	Google	Cypress	2025	1	5
	微软	Cascade	2024	1	5



国产算力有待提升



- 本土人工智能芯片仍需在发展、继承和竞争中成长。在中美脱钩的时代背景下，国产算力芯片正经历“可用”到“好用”的阶段，国产算力芯片整体实力有待提升。
- **从生态成熟度来看，华为海思有望率先替代英伟达算力芯片。** 受益于华为ICT行业的领先地位，昇腾系列将获得从芯片设计、芯片制造、算力部署、应用生态的全方位支持，有更大概率成为主流国产算力芯片。
- 目前英伟达最新的 GPU 产品为GB200。该芯片由两个 Blackwell 架构的 B200 GPU 和一个 Grace CPU 组成，国内AI芯片与之相比还存在一定差距。不过据报道，华为最新的AI处理器昇腾910C的良率已经在过去一年内实现了翻倍，910C芯片对标Nvidia H100 AI GPU，计划在2025年实现量产。

	英伟达	英伟达	英伟达	英伟达	华为海思	海光信息	寒武纪	摩尔线程
代表产品	A100	H100	B200	GB200	昇腾910B	深算二号	MLU290-M5	MTT S3000
FP32算力 (TFLOPS)	19.5	60	80	180	-	-	-	15.2
FP16算力 (TFLOPS)	624	2000	4500	10000	320	-	-	-
显存大小(GB)	80	80	192	384	64	-	32	32
显存带宽(TB/S)	2	3	8	16	-	-	1	0.4
互联带宽 (GB/S)	600	900	1800	1800	392	-	600	-
功耗 (W)	400	700	1000	2700	400	-	350	250
生态	CUDA	CUDA	CUDA	CUDA	昇思Mindspore	ROCm, 兼容 CUDA	-	-




华为：Mindspore开发生态崛起




- 人工智能框架TensorFlow和PyTorch仍然占据领导地位；昇思MindSpore原生支持预训练大模型开发,已在中国市场上占据优势地位,并已经孵化出了一系列创新大模型。
- “造假”等AI伦理道德问题,人工智能开发者和机构越来越关注“负责任的人工智能”。在所有主流人工智能框架中,TensorFlow与MindSpore对“负责任的人工智能”提供的支持能力最好,分别位居第一与第二名。

图：TensorFlow, PyTorch, MindSpore和PaddlePaddle在支持超大规模模型训练方面处于领先



图：TensorFlow和MindSpore对“负责任的人工智能”提供的支持能力最好





华为：打造全栈 AI 软硬件平台，构筑国产智能基石




- 华为通过芯片、异构计算架构、AI框架、AI开发平台等根技术的持续创新突破，打造自主的计算生态。硬件方面，昇腾GPU对标英伟达GPU，软件方面；软件方面，CANN计算架构对标英伟达CUDA架构；昇思计算框架对标TensorFlow、Pytorch计算框架，并且PyTorch已同步支持昇腾NPU；应用方面，华为昇腾已经支持了业界50多个大模型，使能各行各业的智能化升级。





华为：打造全栈 AI 软硬件平台，构筑国产智能基石



朋友们，你们有没有想过




华为：引领国内AI芯片发展



■ 2023年1月，国家工业信息安全发展研究中心提出，我国智能算力中心建设已进入2.0阶段，在智能算力中心的建设过程中，投-建-运往往由不同的单位负责，导致资源浪费，体验不佳。所以2.0阶段，算力中心的建设、运营、应用应该联动，满足一体化服务需求。

■ 华为AI芯片在国内优势显著，因为华为在ICT领域具备从建设到运营的全环节壁垒。至顶智库统计，截至2023年2月，我国目前已投入运营和在建的人工智能算力中心达23个，有16家人工智能算力中心由华为参与建设，使用华为昇腾人工智能计算系统作为底层技术支持。国内约70%算力中心由华为参与，叠加国产AI芯片自主化的需求，所以华

图：中国人工智能算力中心分布





海光信息：CPU+GPU布局完整，产品迭代顺利



- 海光DCU属于GPGPU的一种，全面兼容ROCm GPU计算生态。ROCm是AMD的软件平台，用来加速GPU计算，对标英伟达的CUDA平台。AMD的GPU上编程模型使用的是HIP或者OpenCL，运行环境是ROCm。英伟达显卡上，编程模型是CUDA，运行环境也是CUDA。
- 由于ROCm和CUDA在生态、编程环境等方面具有高度的相似性，CUDA用户可以以较低代价快速迁移至ROCm平台，ROCm也被称为“类CUDA”。因此，海光DCU协处理器能够较好地适配、适应国际主流商业计算软件和人工智能软件。在互联网领域，公司的DCU产品已得到百度、阿里等互联网企业的认证，并推出联合方案，打造全国产软硬件一体全栈AI基础设施。

图：公司OEM客户



图：海光提供完善的AI软件栈支持





海光信息：兼容“类CUDA”生态，打造全栈AI基础设施



- 海光信息的产品包括海光通用处理器（CPU）和海光协处理器（DCU）。
- **强大研发实力推动公司产品持续迭代。**海光CPU系列产品海光三号为主力销售产品，海光四号、海光五号处于研发阶段；海光DCU系列产品深算一号为公司GPGPU主要在售产品，深算二号于2023Q3发布，深算三号研发进展顺利。

图：海光信息主要产品

产品类型	处理器种类	指令集	主要产品	产品特征	典型应用场景
海光CPU	通用处理器	兼容x86指令集	海光3000系列	内置多个处理器核心，集成通用的高性能外设接口，拥有完善的软硬件生态环境和完备的系统安全机制，适用于数据计算和事务处理等通用型应用	云计算、物联网、信息服务等
			海光5000系列		
			海光7000系列		
海光DCU	协处理器	兼容“类CUDA”环境	海光8000系列	内置大量运算核心，具有较强的并行计算能力和较高的能效大数比，适用于向量计算和矩阵计算等计算密集型应用	数据处理、人工智能、商业计算等




寒武纪：云边端AI硬件协同发展



- 寒武纪成立于2016年，专注于人工智能芯片产品的研发与技术创新，是目前国际上少数全面掌握通用型智能芯片及其基础系统软件研发和产品化核心技术的企业之一，可提供智能芯片产品及平台化基础系统软件产品。
- 目前，寒武纪产品已广泛用于服务器厂商和产业公司，涵盖互联网、金融、交通、能源、电力和制造等多个领域，为复杂AI应用场景提供充足算力，推动人工智能赋能的产业升级。

端云一体AI解决方案





寒武纪：云边端AI硬件协同发展



- 寒武纪提供云边端一体、软硬件协同、训练推理融合、具备统一生态的系列化智能芯片产品和平台化基础系统软件。
- 公司云端产品线前五大客户，包括中科可控、浪潮信息等服务器厂商及阿里、百度等互联网公司，目前公司已完成了服务器厂商的产品适配并与主要服务器厂商建立了长期深入的合作关系。


产品线	产品类型	寒武纪主要产品	推出时间
云端产品线	云端智能芯片及加速卡	思元100 (MLU100) 芯片及云端智能加速卡	2018年
		思元270 (MLU270) 芯片及云端智能加速卡	2019年
		思元290 (MLU290) 芯片及云端智能加速卡	2020年
		思元370 (MLU370) 芯片及云端智能加速卡	2021年、2022年
	训练整机	玄思1000智能加速器	2020年
		玄思1001智能加速器	2022年
边缘产品线	边缘智能芯片及加速卡	思元220 (MLU220) 芯片及边缘智能加速卡	2019年
IP授权及软件	终端智能处理器IP	寒武纪1A处理器	2016年
		寒武纪1H处理器	2017年
		寒武纪1M处理器	2018年
	基础系统软件平台	寒武纪基础软件开发平台 (适用于公司所有芯片与处理器产品)	持续研发和升级，以适配新的芯片



推理加速引擎 MagicMind



- MagicMind 是寒武纪全新打造的推理加速引擎，其定位对标的是英伟达 CUDA 之上的 TensorRT，但是架构和功能上相对于 TensorRT 更为先进和强大。在寒武纪的整体软件栈架构中，MagicMind 之下是高效软件栈工具和高性能库，并且还提供了 Bang 语言支撑定制化开发功能。
- MagicMind 支持跨框架的模型解析、自动后端代码生成及优化，在 MLU、GPU、CPU 训练好的算法模型上，借助 MagicMind，用户仅需投入极少的开发成本，即可将推理业务部署到寒武纪全系列产品上，并获得优化后具有竞争力的性能。





昆仑芯科技：专注通用人工智能芯片



- 昆仑芯科技的前身是百度智能芯片及架构部，2021年完成独立融资。公司专注于打造拥有强大通用型、易用性和高性能的通用人工智能芯片，是国内为数不多可支撑互联网大规模核心算法的AI芯片。
- 目前，昆仑芯拥有100%自研核心架构及7nm制程量产经验，产品已在近百家客户部署实践。配合百度飞桨平台，获得更友好开发环境。

昆仑芯主要产品

K系列



昆仑芯1代芯片

产品特点：

自研XPU-K架构
256 TOPS @ INT8,
512GB/s内存带宽，
高性能功耗比，
AI算法全场景覆盖

工艺：14nm，2.5D封装

系列产品：

昆仑芯 AI加速卡 K200
昆仑芯 AI加速卡 K100

R系列



昆仑芯2代芯片

产品特点：

自研XPU-R架构
256 TOPS @ INT8, 128 TOPS @
XFP16
GDDR6高性能显存
高度集成ARM CPU

工艺：7nm

系列产品：

昆仑芯 AI加速卡 R200
昆仑芯 通用基板 R480

昆仑芯产品优势

经过实践验证

在百度内部各业务
已部署超2万片
在百度外，有工业
质检、智慧城市、
智慧金融等多场景
落地案例

领先的性能

比市场同类主流
产品、各种算法
和各业务场景中
均有1.5-2倍的性
能提升

开发环境友好

昆仑芯SDK可实现
模型迁移
支持百度飞桨、
PyTorch和
TensorFlow等主流
深度学习框架

百度飞桨核心框架及其领先技术

开发		训练		部署	
动态图	静态图	大规模分 布式训练	工业级数 据处理	PaddleServing	PaddleLite
				PaddleSlim	安全与加密

- 产业及深度框架
- 超大规模深度学习训练模型
- 覆盖多领域工业级模型库
- 多端多平台部署
- 高性能推理引擎



地平线：“芯片+算法+工具链”完整智能驾驶生态



- 地平线成立于2015年6月，致力于开发边缘人工智能芯片及相关解决方案，产品可面向智能驾驶以及更广泛的智能物联网领域，提供包括效能边缘AI芯片，丰富算法IP、开放工具链等在内的全面赋能服务。
- 基于其创新的人工智能专用计算架构BPU(Brain processing Unit),地平线为AI芯片规划了完备的研发路线图。
- 目前，地平线是业界唯一能够提供覆盖从L2到L4全场景整车智能芯片方案的人工智能平台型企业，与奥迪、比亚迪、长安汽车等企业达成了深度合作，构建合作供应的智能汽车芯生态，加速智能驾驶创新产品成熟落地。

BPU处理器及解决方案研发线路图



地平线主要产品

应用场景	产品线	产品种类	产品特点
智能驾驶	车规级芯片: 征程	征程2 征程3 征程5	即时图像处理、支持高清视频输入、BPU/DSP/CPU异构计算、面向自动驾驶的I/O接口
	汽车中央AI计算平台 Matrix	Matrix2 Matrix5	4颗征程SoC保障算力 多路摄像头、以太网、雷达接口 车云协同
智能物联网	针对AIoT的AI处理器 旭日	旭日2 旭日3	BPU架构AI引擎，提供5TOPS等效算力 同等性能下实现低功耗 开放工具链加速AI落地
AI开发平台	天工开物	天工开物AI全生命周期开发平台	AI算法仓库、AI芯片工具和AI应用开发中间件三大功能模块。



SynSense时识科技:类脑智能先行者



- SynSense时识科技于2017年2月在瑞士苏黎世成立（原名aiCTX），并于2020年4月将全球运营总部迁至中国。公司是全球领先的类脑智能与应用解决方案提供商，横跨计算与感知技术领域，拥有苏黎世大学和苏黎世联邦理工学院20多年数模混合神经形态处理器与神经形态算法自主研发成果。
- 目前，类脑芯片产品已流片成功，进入小规模试用环节，即将进入量产。未来，产品将广泛适用于IoT实时信号处理及AI边缘运算。

时识科技主要产品

动态视觉处理		自然信号处理	开发套件
			
“感算一体”动态视觉智能SoC-Speck		低纬度类脑处理器XYLO	开发套件
无隐私：基于点阵数据的视觉处理 实时性：5-10ms端到端延时 小于1mW超低功耗，真正always-on 预计2022年Q3试量产		丰富的可扩展性，可直连事件相机 ms级延时，<1mW超低功耗 实时数据运算，无需缓存 预计2022年初量产	基于SRNN算法和动态稀疏数据 低成本：全新芯片架构，全并行运算 信号转化实时处理，无缓存 预计2022年Q3试量产
			DYNAP-SE开发套件 DYNAP-CNN开发套件 XYLO开发套件 DVS开发套件 Speck开发套件

时识科技核心创始团队

- **Dr. 乔宁 创始人兼CEO**
本科毕业于西安交通大学，博士毕业于中科院半导体所
苏黎世大学博士后，苏黎世大学高级研究员
主导10+项欧盟类脑研发项目，10+颗类脑芯片研发
主导设计了全球首款动态视觉专用处理器
- **Prof. Dr. Giacomo Indiveri 联合创始人 首席科学家**
苏黎世联邦理工学院、苏黎世大学终身教授
INI苏黎世神经信息研究所所长
主导20+项欧洲重大类脑项目，类脑计算领域权威人物

时识科技时识科技类脑芯片优势及技术布局

- **超低功耗**
- **超低延时**
- **端侧智能**
- **隐私安全**
- **动态视觉处理**
动态视觉智能感知交互，运动轨迹、定位及路径规划
- **自然信号处理**
实时传感信息处理
- **机器人感知决策及可植入式处理器**
多模态融合运算，感知及决策；人机交互，人体增强



总结：国产算力持续增长



在智能产业飞速发展大背景下，各个省市大力建设智算、超算中心，但利用率普遍偏低





华南理工大学
South China University of Technology

04

AI算力应用





GPU算力的典型业务场景



大型模型训练



OpenAI从英伟达采购了三万多张顶级人工智能芯片，每枚价值近十万元，光是这批芯片，就价值三十亿人民币。

高性能计算



CPU+GPU是HPC发展重要基石，CPU擅长逻辑控制，串行的运算和通用类型数据运算，GPU擅长大规模并发计算。

AI推理



AI推理的场景非常广泛，比如：安防监控、自动驾驶、各类边缘计算场景等。对GPU卡的要求是性价比高、功耗低。

图形渲染



以广电媒资、游戏开发、工程3D建模，AR、VR等，主要对GPU的视频处理、图形渲染要求高，同时还需要支持视频接口输出等。

云游戏



大型3D游戏对显卡性能要求极高。对应英伟达GeForce消费类卡，但是由于卡的高性价比也经常被用于企业级应用中。




ChatGPT的破局



- 聊天生成型预训练变换模型（Chat Generative Pre-trained Transformer）简称ChatGPT，是OpenAI开发的人工智能聊天机器人程序，于2022年11月推出，上线两个月后已有上亿用户。
- ChatGPT目前仍以文字方式互动，而除了可以用人类自然对话方式来互动，还可以用于甚为复杂的语言工作，包括自动生成文本、自动问答、自动摘要等多种任务。

ChatGPT突破1亿用户数所需时间对比



ChatGPT介绍

ChatGPT		
Examples	Capabilities	Limitations
"Explain quantum computing in simple terms"	Remembers what user said earlier in the conversation	May occasionally generate incorrect information
"Got any creative ideas for a 10 year old's birthday?"	Allows user to provide follow-up corrections	May occasionally produce harmful instructions or biased content
"How do I make an HTTP request in Javascript?"	Trained to decline inappropriate requests	Limited knowledge of world and events after 2021




ChatGPT的成功离不开预训练大模型




- 人工智能需要用大量的数据对其进行训练，理论上讲，投喂数据越多、数据质量越高，模型效果就会越好。而预训练 (Pre-trained Models, PTMs)，就是预先训练好的模型，可以帮助人们降低模型创建和训练的成本。预训练大模型需要深度学习的算法，也需要大的数据、大的算力，做自监督学习（模型直接从无标签数据中自行学习，无需标注数据），再面向不同的任务、在不同的应用场景里做少量任务数据进行迁移学习，进而应用于很多场景。
- ChatGPT能够实现当前的交互，离不开OpenAI在AI预训练大模型领域的积累。

NLP模型开发领域的标准范式 “pretrain+finetune”



预训练的起源与发展






预训练模型的发展历程



- 预训练的研究最早起源于迁移学习。迁移学习的核心思想，即运用已有的知识来学习新的知识，通俗来说就是将一个预训练的模型被重新用在另一个任务中。早期的预训练模型主要基于有标签数据。而在NLP领域，由于下游任务的多样性以及数据标注的复杂性，导致无法获得一个像ImageNet这样大规模的有标签数据，所以NLP领域尝试使用自监督学习的方法来获取预训练模型，自监督学习的主要思想就是利用文本间的内在联系为监督信号。
- 2017年出现的Transformer结构，给NLP领域预训练模型的发展带来了绝大的突破。Transformer的成功，也诱使CV领域加入了自监督预训练模型的赛道。如今，自监督预训练已经成为当前人工智能研究的重点，几乎所有的最新的PTM都是采用类Transformer结构与自监督学习的方法。





预训练模型的发展历程




- 2017年，谷歌团队首先提出Transformer模型。该团队将Transformer概括为一句话：“Attention is All You Need.” 目前Transformer已经成为自然语言处理领域的主流模型，基于Transformer的预训练语言模型更是成为主流。除了NLP 之外，Transformer 也逐渐成为很多基于序列的语音应用的主流AI模型，在很多场景中已取代RNN/LSTM，比如自动语音识别、语音合成等等
- Transformer受欢迎的主要原因是其架构引入了并行化，它利用了强大的TPU和并行训练，从而减少了训练时间。

基于Transformer架构的NLP模型规模



基于Transformer架构的应用






大模型的突现能力




- 当扩展大型语言模型时，偶尔会出现一些较小模型没有的新能力，这种类似于「创造力」的属性被称作「突现」能力。GPT-3的论文表明，语言模型执行多位数加法的能力对于从100M到13B参数的模型具有平坦的缩放曲线，近似随机，但会在一个节点造成性能的飞升。
- 初代GPT-3展示了三个重要能力：语言生成、上下文学习、世界知识。基本上三种能力都来自于大规模预训练：在有3000亿单词的语料上预训练拥有1750亿参数的模型。

大模型的「突现」能力



GPT-3.5的进化树





参数量爆发式增长的ChatGPT



自2018年以来，OpenAI的GPT系列模型在参数规模和预训练数据量方面经历了显著增长。最初的GPT-1模型拥有1.17亿参数，预训练数据量约为5GB。随后，2019年发布的GPT-2模型参数量提升至15亿，预训练数据量约为40GB。2020年，GPT-3模型的参数量进一步跃升至1750亿，预训练数据量约为570GB。2022年推出的GPT-3.5模型，参数量未公开，但推测在200亿至1750亿之间，预训练数据量未明确披露。最新的GPT-4模型于2023年发布，采用混合专家（MoE）架构，总参数量达到1.8万亿，每次推理激活约2800亿参数，预训练数据集包含约20万亿个token。

	GPT-1	BERT(开源)	GPT-2 (开源)	GPT-3	ChatGPT/GPT-3.5	GPT4 (多模态)
发布时间	2018	2018	2019	2020	2022年11月30日	2023年3月14日
模型技术结构特点与安全性措施	- 基于Transformer架构 - 12层，768维词嵌入向量 - 无监督预训练和有监督微调	- 基于Transformer架构，12层 - 双向编码器(全文本) - 词嵌入向量维度为 768或1024使用掩码语言模型 (MLM)进行预训练 - 下游任务微调	- 从GPT-1基础上增加到48层，使用1600维向量进行词嵌入 - 修改初始化的残差层权重，缩放为原来的 1/N (N为残差层的数量) - 交替密度和局部带状稀疏注意模式	- 96层，参数量增加到约1750亿 (175B) - 上下文窗口宽度增加到2048个tokens - 训练数据更大 - 采用交替密度和局部带状稀疏注意模式	- 基于GPT-3的架构，进行了针对性的优化和调整 - 参数量、层数和词表与GPT-3相近，但具体参数可能有所不同 - RLHF训练	- 预期参数量远大于1750亿 - 视觉语言模型组件 (VLM) - 对抗性测试和红队测试 - RLHF训练 - 基于规则的奖励模型(RBRM)
模型参数	117M	340M	1.5B	175B	大概2B-175B	1800B
上下文窗口	512 token	512 token	1024 token	2048 token	4096 token	32,000 token
训练方法	无监督预训练和有监督微调	掩码语言模型预训练	无监督预训练	无监督预训练	1) 有监督微调 2) RLHF训练奖励模型 3) PPO强化学习	1) 有监督微调 2) RLHF训练奖励模型 3) 构造基于规则的奖励模型(RBRM) 4) PPO强化学习
数据集	BooksCorpus	BooksCorpus 与 English Wikipedia	WebText	Common Crawl, WebText2, Books1, Books2和 Wikipedia	类似GPT-3,但可能有更新	更大规模和多样化
数据量规模	5G		40GB	570GB		20万亿Tokens



大模型对算力产生爆发式需求



算力存在于大模型生命周期的每一环





市场上可见的大模型日益丰富



- 自ChatGPT发布以来，其在全球范围内引发了人工智能领域的广泛关注，推动了各大科技公司加速布局大模型技术，形成了“百模大战”的局面。

厂商	大模型	厂商	大模型	厂商	大模型
Meta	LlaMA	字节跳动	—	微软、微软亚洲研究院	Megatron Turing (&英伟达)、NUWA(&北大)
google	PaLM	OpenGVLab (商汤平台)	基于书生的超高效预训练模型	北京智源人工智能研究院	悟道2.0
商汤科技 (&上交等)	书生 (INTERN)	清华大学	GLM-1308、CokeBert (&腾讯)	京东	—
北京大学	鹏程·盘古α (&鹏程&华为) (资料少，不确定含北大)、NUWA (微软亚洲)	DeepMind	Gopher	OPPO	OBERT
NVIDIA 英伟达	NeMo LLM	粤港澳大湾区数字经济研究院 (IDEA研究院)	二郎神	中国科学院	紫东太初
浪潮	源1.0智能大模型	美团	—	华为云	鹏程·盘古α (&鹏程&华为)
奇点智源	SkyCode多语言开源编程大模型	澜舟科技	孟子	腾讯	混元AI大模型
追一科技	RoFormerV2	快手	—	百度	文心一言
鹏程实验室	鹏程·盘古α (&北大&华为)	OpenAI	GPT-4	云从科技	SemBERT (&上海交通大学)
阿里巴巴达摩院智能计算实验室	M6、“通义”大模型	联汇科技	OmModel	幻方量化	DeepSeek




汽车智能化推动算力升级加速




- 自动驾驶的完整流程包括感知、决策、控制，自动驾驶域算法一般也被划分感知算法、融合算法和执行算法三种。随着车辆自动驾驶等级的提升，对于车辆的主动性要求也大幅度提升，自动驾驶算法的难度就在于在所面对场景的多样性和复杂性。
- 由于不依赖人工智能算法实现基于机器的环境感知和规划决策，L1-L2级传统汽车不需要太大的车载算力，因此多采用小算力、微控制器的解决方案。从L2级开始，尤其是**L3级以上的自动驾驶汽车需要装备大算力芯片支撑感知、决策算法的高效运行**。自动驾驶每提高一级，算力就增加一个数量级。L2级别大概需要2个TOPS的算力，L3需要24个TOPS，L4为320TOPS，L5为2000+TOPS。

自动驾驶核心技术



不同等级的自动驾驶






智能驾驶芯片需求快速增长，大模型催化AI功能部署



- 随着智能驾驶水平的提高，对算力的要求不断增长；如L5级别的自动驾驶最低算力要求为2000TOPS。
- 芯片厂商生产高算力车规芯片，可用于自动驾驶与AI应用，车企推出装配高算力芯片的智能汽车。



自动驾驶等级	L2	L3	L4	L5
算力需求 (TOPS)	2-2.5	20-30	200-500	2000以上

技术路线	厂家	芯片	架构	算力(TOPS)	每瓦功耗(W)	制程(nm)	SOP时间
提供整套解决方案	Mobileye(英特尔)	EyeQ3	CPU+ASIC	0.256	10	40	2014
		EyeQ4		2.5	1.2	28	2018
		EyeQ5		24	0.416	7	2021E
平台化硬件	英伟达	Xavier	CPU+GPU+ASIC	30	1	12	2020
		Orin		200	0.225	7	2022E
		Atlas		1000	/	5	2025E
	地平线	征程2	CPU+ASIC	4	0.125	28	2019
		征程3		5	0.5	16	2020
		征程5		128	0.195	7	2022E
全部自研	华为	昇腾310	CPU+ASIC	16	0.5	12	2018
		昇腾910		640	0.48	/	2022E
		FSD	CPU+GPU+ASIC	72	1	14	2019
		升级版FSD		210	/	5/7	2021E



汽车电动化、智能化发展推动算力布局



- ❑车厂与科技公司发力车端AI大模型，随着新能源汽车对智能化的要求不断提高，将AI大模型接入整车已经成为行业趋势；车厂与科技公司均发力自研AI大模型，以期提高智能化水平。

部分厂商车端大模型布局

蔚来	NomiGPT：端云融合架构，多模态感知，支持第三方API调用，搭载情感引擎和长期记忆能力
小鹏	AI天玑大模型：集成感知大模型、规控大模型、生活助理、出行助理
理想	Mind GPT：训练数据总量超过3万亿tokens，多模态认知模型，采用taskformer架构
广汽	广汽AI大模型平台：AI大模型平台成为全场景应用的入口，重塑智能汽车场景交互范式
华为	千悟引擎大模型：以华为盘古大模型、MindSpore昇思计算框架和昇腾AI基础硬件平台等技术为基础底座
百度	智舱大模型 2.0：采用全新MoE架构，可支持本地化部署！支持车企高效定制品牌特色
商汤	日日新SenseNova50：基于超过10TBtokens训练、覆盖数千亿量级的逻辑型合成思维链数据
科大讯飞	星火大模型：基于“讯飞星火+汽车”模式，创造性地将大模型与汽车产业深度融合

各车企、智驾供应商智算中心算力布局情况

企业类型	企业名称	算力布局
车企	特斯拉	100EFLOPS(2024年10月)
	理想	4.5EFLOPS
	小鹏	2.5EFLOPS
	长城	1.64EFLOPS
	长安	1.42EFLOPS
	蔚来	1.4EFLOPS
	吉利	0.81EFLOPS



算力的获取平台 谷歌Colab



Colaboratory(简称Colab),即合作实验室,是谷歌提供的一个在线工作平台,用户可以直接通过浏览器执行python代码并与他人分享合作。Colab的主要功能当然不止于此,它还为我们提供免费的GPU。

Colab 之所以能够免费提供资源,部分原因在于它的使用量限额是时有变化的动态限额,并且它不会保证资源供应或无限供应资源(单次最长12小时,自动断开连接)。为了保证计算资源的自动分配,Colab 中的可用 GPU 类型是动态变化的,通常包括 Nvidia K80、T4、P4 和 P100。若免费资源无法满足需求,Colab还支持订阅服务:

Pay As You Go	Colab Pro	Colab Pro+	Colab Enterprise
\$9.99/100 个计算单元 \$49.99/500 个计算单元 您目前有 0 个计算单元。 计算单元将在 90 天后过期。请根据需求购买更多计算单元。 ✓ 无需订阅。 只需为实际用量付费。 ✓ 更快的 GPU 升级到更强大的 GPU。	推荐 Colab Pro \$9.99/月 ✓ 每月 100 个计算单元 计算单元将在 90 天后过期。请根据需求购买更多计算单元。 ✓ 更快的 GPU 升级到更强大的 GPU。 ✓ 更多内存 使用我们内存更高的机器。 ✓ 持续 能够使用已连接虚拟机的持续。	Colab Pro+ \$49.99/月 获得 Pro 的所有福利, 外加: ✓ 每月可额外使用 400 个计算单元, 总计 500 个。 计算单元将在 90 天后过期。请根据需求购买更多计算单元。 ✓ 更快的 GPU 可以优先升级到更强大的付费 GPU。 ✓ 后台执行 借助计算单元, 即使您关闭浏览器, 正在运行的笔记本也能继续运行长达 24 小时。	Colab Enterprise 用多少, 付多少 ✓ 集成 与 BigQuery 和 Vertex AI 等 Google Cloud 服务紧密集成。 ✓ 企业级笔记本存储空间 从使用 Google Drive 笔记本改为使用您的 Cloud 控制台存储和共享的 GCP 笔记本。 ✓ 高效 生成式 AI 辅助的代码补全和生成。

平台链接: <https://colab.research.google.com/>



算力的获取平台



AutoDL

AutoDL是一个提供GPU租用服务的平台，主要面向深度学习和人工智能领域的研究者和开发者。用户可以在AutoDL上租用GPU服务器，进行深度学习模型的训练和实验。平台提供了多种GPU资源，用户可以根据自己的需求和预算选择合适的GPU型号和配置。

平台链接：<https://www.autodl.com/>

AutoDL可提供的算力





算力的获取平台



Featurize

与AutoDL类似，Featurize也是一个提供GPU租用服务的平台，主要面向深度学习和人工智能领域的研究者和开发者。用户可以在Featurize上租用GPU服务器，选择合适的开发环境进行深度学习模型的训练和实验。

► Featurize 蒜粒方块，加速您的科技创新

高性能 GPU 资源

提供最新的NVIDIA GPU,满足各类计算需求。



集成开发环境

预装主流机器学习框架，开箱即用。提升开发效率。



灵活的计费模式

支持按需计费和包月服务，用户可以根据实际需求灵活选择。



海量数据集

提供常用数据集的快速访问,简化数据处理流程。



平台链接: <https://featurize.cn/>



谢谢!

THANK YOU FOR WATCHING!

