



华南理工大学
South China University of Technology

《人工智能理论及应用》

数据挖掘

授课老师：青春美
联系邮箱：qchm@scut.edu.cn

2026年4月

投票 最多可选1项



数据挖掘相关知识基础情况 ()

- ☐ A 基本空白
- ☐ B 掌握基本概念
- ☐ C 较熟悉
- ☐ D 熟悉, 已经开展相关研究

目 录



01 大数据时代

02 数据挖掘的由来

03 数据挖掘的内容

04 相关技术和应用

05 数据挖掘相关问题

01

大数据时代






大数据时代



数据到信息的进化





“十四五”大数据产业发展规划

当前，数据已成为重要的生产要素，大数据产业作为以**数据生成、采集、存储、加工、分析、服务**为主的战略性新兴产业，是激活数据要素潜能的关键支撑，是加快经济社会发展质量变革、效率变革、动力变革的重要引擎。面对世界百年未有之大变局和新一轮科技革命和产业变革深入发展的机遇期，世界各国纷纷出台大数据战略，开启大数据产业创新发展新赛道，聚力数据要素多重价值挖掘，抢占大数据产业发展制高点。

发展目标



产业保持高速增长



价值体系初步形成



产业基础持续夯实



产业链稳定高效



产业生态良性发展

- 到2025年，大数据产业测算规模突破**3万亿元**，年均复合增长率保持在**25%左右**
- 创新力强、附加值高、自主可控的**现代化大数据产业体系**基本形成

- 数据要素价值评估体系**初步建立
- 培育一批较成熟的**交易平台**

- 关键核心技术**取得突破
- 标准引领**作用显著增强
- 形成一批**优质大数据开源项目**
- 存储、计算、传输等基础设施**达到国际先进水平**

- 数据全生命周期产业系统**统筹发展，与**创新链、价值链**深度融合
- 形成一批**技术领先、应用广泛的大数据产品和服务**

- 社会对大数据认知水平**不断提升，**企业数据管理能力**显著增强
- 形成具有国际影响力的**数字产业集群**
- 国际交流合作**全面深化

专栏3 工业大数据价值提升行动

1. 原材料行业大数据



- 支持**原材料企业**综合运用数据，提升全流程**智能化、精准化**水平。

2. 装备制造行业大数据



- 支持**装备制造企业**打通全价值链数据流，发展数据驱动的**新模式新业态**。

3. 消费品行业大数据



- 支持**消费品企业**打通线上线下全域数据，**促进供需精准对接**。
- 支持企业建立**质量追溯数据库**，实现产品质量可追溯可管理。

4. 电子信息行业大数据



- 支持**电子信息制造企业**加快大数据在**全流程**场景中的应用，保证产业链供应链的**稳定性**



大数据时代



“发挥大数据特性优势”

《规划》提出“发挥大数据特性优势”，坚持大数据“5V”特性与产业高质量发展相统一，通过“**技术应用+制度完善**”双向引导，重点推进“大体量”汇聚、“多样性”处理、“时效性”流动、“高质量”治理、“高价值”转化等各环节协同发展，鼓励企业探索应用模式，推广行业通用发展路径，建立健全符合规律、激发创新、保障底线的制度体系，实现**大数据产业**发展和**数据要素价值**释放互促共进。

筑牢数据安全保障防线



完善数据安全保障体系

- 强化**大数据安全**顶层设计，落实法律法规和政策标准
- 鼓励推进**数据安全**管理，开展**数据安全能力成熟度**评估
- 加强数据安全保障能力建设，引导建设**数据安全态势感知平台**



推动数据安全产业发展

- 提升重点行业**数据安全**防护水平和应急处置能力
- 推动大数据技术在**数字基础设施**安全防护中的应用
- 提升**数据安全产品**供给能力

打造繁荣有序产业生态

培育壮大企业主体



- 提升龙头企业**自主创新**、**产品竞争**和**知识产权布局**能力
- 鼓励中小企业“**专精特新**”发展
- 推动大中小企业**融通发展**和产业链上下游**协同创新**
- 支持有条件的垂直行业企业开展**大数据业务剥离重组**

优化大数据公共服务



- 建设**大数据协同研发平台**
- 建设**大数据应用创新推广中心**等载体
- 加强**公共数据训练集**建设
- 构建**大数据产业运行监测体系**

推动产业集群化发展



- 推动大数据领域**国家新型工业化产业示范基地**高水平建设
- 鼓励有条件的地方围绕**数据要素市场机制**、**国际交流合作**等开展先行先试
- 支持协会联盟举办**产业论坛**、**行业大赛**等活动

发展现状与核心挑战

十四五期末成效 · 三大核心挑战 · 三大战略机遇

十四五期末成效

产业规模
3.2万亿元

数据交易额
800亿元

枢纽节点算力占比
55%

数据库国产化率
65%

DCMM贯标率
45%

三大核心挑战

01 要素流通受阻
72% 企业反映数据权属不清晰制约交易

02 技术代差压力
AI大模型训练算力密度仅为国际领先水平的 1/5

03 安全治理缺口
2024年数据泄露事件同比上升 37%

三大战略机遇

政策红利释放
数据资产入表催生万亿级市场

技术拐点突破
量子计算“九章三号”255光子操纵

国际规则参与
中国正式加入DEPA谈判

"十五五"核心目标与重点任务

总体要求：激活数据要素 × 发展新质生产力

2030年核心目标

产业规模

2025基准

3.2万亿

2030目标
→ 10万亿

年均复合增长率25%

数据要素对GDP贡献率

2025基准

9%

2030目标
→ 15%

大模型训练算力成本

2025基准

2.8万元

2030目标
→ 0.9万元

(PP1天)

绿色算力使用率

35% → 65%

核心系统自主可控率

50% → 85%

四大重点任务

01 数据要素市场化攻坚行动

- 制定《数据产权登记管理条例》（2026年立法）
- 组建国家级数据资产交易所（北京+海南双总部）
- 推行公共数据授权运营“负面清单”

02 技术自强“筑基工程”

- 智能计算：千亿参数大模型训练能力优化
- 量子计算：建成3个E级超算量子协同中心
- 隐私计算：全同态加密性能突破100Kops/sec

03 “数据要素×”场景赋能计划

制造业
工业数据空间

农业
耕地数据图谱

医疗
健康数据中心

04 数据安全“长城体系”

- 开发数据流通区块链审计平台（100%覆盖跨境数据）
- 建立数据安全保险基金（财政部注资200亿元）
- 发布《国家核心数据目录》（涉密数据禁止出境）

重大载体建设工程

总投资3620亿元 · 三大战略工程 · 构建数据要素市场基础设施



投资规模

3000亿元

核心内容


新增西藏、内蒙古枢纽节点，构建全国算力网络

产出效益

降低单位算力成本 40%

绿色目标

国家枢纽节点绿电使用率提升至65%



投资规模

120亿元

核心内容

建设10所大数据现代产业学院

产出效益

年培养 50万 DCMM工程师

认证体系

建立国家级数据人才认证标准



投资规模

500亿元

核心内容

在东盟、中东布局5个海外数据枢纽

产出效益

带动国产技术出口额超 2000亿元

国际合作

对接DEPA数字经济伙伴关系协定

15+



大数据时代



02

数据挖掘的由来





背景





为什么要数据挖掘



- 数据爆炸但知识贫乏

人们积累的数据越来越多。但是，目前这些数据还仅仅应用在数据的录入、查询、统计等功能，**无法发现数据中存在的关系和规则**，无法根据现有的数据预测未来的发展趋势，导致了“数据爆炸但知识贫乏”的现象。



数据爆炸式增长（每分钟.....）

13000+个 iPhone 应用下载	Skype上 37万+分钟的 语音通话	Twitter上发 布98000+新 微博
上传6600张 新照片到 flickr	发出1.68亿+ 条Email	Facebook上 更新69.5万+ 条新状态
YouTube上 上传600+新 视频	淘宝光棍节 10680+个新 订单	12306出票 1840+张





为什么要数据挖掘



大量信息带来方便的同时也带来了一大堆问题：

- 信息过量，难以消化
- 信息真假难以辨识
- 信息安全难以保证
- 信息形式不一致，难以统一处理

数据本质是生产资料和资产





为什么要数据挖掘



- 科学发展范式





为什么要数据挖掘



- 已获得的大量数据往往是**数据丰富但信息贫乏**的
- **计算设备**变得廉价且功能强大
- 没有强大的工具的话，数据量已经超过人类的理解能力
- 数据收集存储的速度越来越快
- **传统技术已经不适用于**原始数据
- 数据挖掘有助于科学研究

数据挖掘技术：Motivation

问题：淹没在数据中；不能制定合适的决策！



数据挖掘是应实际需求而出现的**技术**



为什么要数据挖掘：从商业数据到商业信息的进化



进化阶段	商业问题	支持技术	产品厂家	产品特点
数据搜集 (60年代)	“过去五年中我的总收入是多少？”	计算机、磁带和磁盘	IBM CDC	提供历史性的、 静态的数据 信息
数据访问 (80年代)	“在新英格兰的分部去年三月的销售额是多少？”	关系数据库(RDBMS) 结构化查询语言(SQL) ODBC	Oracle Sybase Informix IBM Microsoft	在记录级提供历史性的、 动态数据 信息
数据仓库 决策支持 (90年代)	“在新英格兰的分部去年三月的销售额是多少？波士顿据此可得出什么结论？”	联机分析处理(OLAP) 多维数据库 数据仓库	Pilot Comshare Arbor Cognos Microstrategy	在 各种层次上提供回溯的、动态的 数据信息
数据挖掘 (正在流行)	“下个月波士顿的销售会怎么样？为什么？”	高级算法 多处理器计算机 海量数据库	Pilot Lockheed IBM SGI 其他初创公司	提供 预测性 的信息



数据挖掘的经典故事和案例：一个网络流传的笑话



- 客服：“东东披萨店您好!请问有什么需要我为您服务?”
- 顾客：“你好，我想要……”
- 客服：“先生，请把您的AIC会员卡号码告诉我。”
- 顾客：“喔!请等等，12345678。”
- 客服：“陈先生您好，您是住在泉州街一号二楼,您家的电话是23939889，您的公司电话是23113731,您的移动电话是939956956。请问您现在是用哪一个电话呢?”

(1.客户数据库)

- 顾客：“我家，为什么你知道我所有的电话号码?”
- 客服：“陈先生，因为我们有连线“AIC CRM 系统”。”

Add-in-Cards
亲密合作伙伴

Customer Relationship
Management
客户关系管理





数据挖掘的经典故事和案例：一个网络流传的笑话



- 顾客：“我想要一个海鲜披萨……”
- 客服：“陈先生，海鲜披萨不适合您。”
- 顾客：“为什么？”
- 客服：“根据您的医疗纪录，您有高血压和胆固醇偏高。”

Why?

(2. 医疗数据库)

- ▶ 顾客：“那……你们有什么可以推荐的？”
- ▶ 客服：“您可以试试我们的低脂健康披萨。”
- ▶ 顾客：“你怎么知道我会喜欢吃这种的？”
- ▶ 客服：“喔！您上星期一在中央图书馆借了一本《低脂健康食谱》。”

(3. 图书借阅数据库)

- 顾客：“哎呀！好……，我要一个家庭号特大披萨，要多少钱？”
- 客服：“嗯，这个足够您一家十口吃，六百九十九元。”
- 顾客：“可以刷卡吗？”
- 客服：“陈先生，对不起，请您付现，因为您的信用卡已经刷爆了，
- 您现在还欠银行十万四千八百零七元，而且还不包括房贷利息。”

(4. 金融数据库-信用卡)

- 顾客：“喔！那我先去附近的提款机领钱。”
- 客服：“陈先生，根据您的记录，您已经超过今日提款机提款限额。”

(5. 金融数据库-现金卡)



数据挖掘的经典故事和案例：一个网络流传的笑话



- 顾客：“算了！你们直接把披萨送来吧，我这里有现金。你们多久会送到？”
- 客服：“大约三十分钟，如果您不想等，可以自己骑车来。”
- 顾客：“什么?!”
- 客服：“根据“AIC CRM系统”记录，您有一辆摩托车，车号是GY-7878。”
- 客服：“请问还需要什么吗?”
- 顾客：“没有了，是不是有送三罐可乐?”
- 客服：“是的!不过根据“AIC CRM系统”您有糖尿病……”

(1. 客户数据库)

- ▶ 顾客: @\$%^&\$@\$%^&\$@\$%^&\$
- ▶ 客服: “陈先生, 请您说话小心一点。您在2000年四月一日用脏话侮辱警察, 被判了十日拘役。”
- ▶ 顾客: “……”




(6. 刑事刑案数据库)



数据挖掘的经典故事和案例：一个网络流传的笑话



智能客户关系管理





数据挖掘的经典故事和案例：啤酒与尿布



- 在一家超市里，有一个有趣的现象：尿布和啤酒赫然摆在一起出售。
- 但是这个奇怪的举措却使尿布和啤酒的销量双双增加了。
- 原因何在？
- 原来，美国的妇女们经常会嘱咐她们的丈夫下班以后要为孩子买尿布。而丈夫在**买完尿布之后又要顺手买回自己爱喝的啤酒**，因此啤酒和尿布在一起购买的机会还是很多的。
- 是什么让沃尔玛发现了尿布和啤酒之间的关系呢？
- 正是商家通过对超市一年多原始交易数字进行详细的分析，通过数据挖掘中的**关联规则**发现了这样的组合。





* DM在大型零售企业中的应用

(1)、优化商品组合布局，正确安排商品进货与库存

- 从众多的商品中发现创造价值最大的商品。然后，据此调整商品的结构，安排商品的库存和定货。
- 商品布局管理即商品**摆放位置**对销售起着至关重要的作用。

考虑购买者在商店里所穿行的路线、购买时间和地点、货架的使用效率、畅销商品的类别、不同商品一起购买的概率，进行挖掘。

英国safeway公司，研究发现某一种乳酪产品虽然销售额排名第209，可是消费额最高的客户中有25%都常常买这种乳酪，这些客户可是Safeway最不想得罪的客户。如果使用传统的分析方法的话，这种产品很快就会不卖了，可是事实上这种产品是相当重要的。

Safeway也发现在28种品牌的橘子汁中，有8种特别受到欢迎。因此，该公司重新安排货架的摆设，使橘子汁的销量能够增加到最大



数据挖掘的经典故事和案例：其他



- 运动领域

- IBM Advanced Scout分析**NBA的统计数据**(阻挡投篮,助攻,和犯规)获得了对纽约小牛队(New York Knicks)和迈阿密热火队(Miami Heat)的竞争优势

- 天文领域

- 借助于数据挖掘的帮助, JPL 和 Palomar Observatory 发现了22 颗类星体(quasars)

- Internet Web Surf-Aid

- IBM Surf-Aid 将数据挖掘算法用于有关交易的页面的**Web访问日志**, 以发现顾客喜爱的页面, 分析Web销售的效果, **改进Web 站点的组织**, 等.



数据挖掘的经典故事和案例：在企业中的应用



数据挖掘所能解决的典型商业问题包括：

- ◆ **银行**：反欺诈行为、关联销售、市场竞争分析。客户分类、客户价值分析与预测、客户偏好分析、客户信用分析以及欺诈检测等。
- **电信**：流失预警、客户分群、关联销售。
- **网上销售点**：购物车交叉销售、网上商品布局。

单选题 100分



什么是KDD?

- ☐ A 数据挖掘与知识发现
- ☐ B 领域知识发现
- ☐ C 文档知识发现
- ☐ D 动态知识发现



Data mining: 用词不当?



- 从数据中挖掘知识
- 相近的术语
 - 数据库中知识发现(挖掘) (Knowledge discovery in databases, **KDD**),
 - 知识提取(knowledge extraction),
 - 数据/模式分析(data/pattern analysis),
 - 数据考古(data archeology),
 - 数据捕捞(data dredging),
 - 信息收获(information harvesting),
 - 商务智能(business intelligence), 等.



数据挖掘的历史



数据挖掘技术的历史可以追溯到**1960年代**，当时的人工智能研究者开始研究如何从大量数据中发现隐藏的模式。随着计算机技术的发展，数据挖掘技术在1980年代和1990年代得到了更广泛的应用，尤其是在商业领域。**2000年代**以来，数据挖掘技术的发展得到了更大的推动，主要原因有以下几点：


- **数据量的增加**：随着互联网的发展，数据量不断增加，这使得数据挖掘技术的应用范围和深度得到了扩大。
- **计算能力的提高**：随着计算机硬件和软件的发展，数据挖掘技术的计算能力得到了大幅提高，这使得更复杂的算法和模型可以得到实现。
- **算法的创新**：随着机器学习、统计学等领域的发展，数据挖掘技术的算法得到了不断的创新和改进，这使得数据挖掘技术的效果得到了显著的提高。



KDD的出现



- 基于数据库的知识发现（KDD）一词首次出现在1989年举行的国际人工智能联合大会IJCAI-89 Workshop。
- 1995年在加拿大蒙特利尔召开了第一届KDD国际学术会议（KDD'95）。
- 由Kluwers Publishers出版，1997年创刊的《Knowledge Discovery and Data Mining》是该领域中的第一本学术刊物。






KDD的出现: Knowledge Discovery from Database



- 数据清理 • 数据变换
- 数据集成 • 数据挖掘 • 知识表示
- 数据选择 • 模式评估





数据挖掘是多学科交叉的产物




随着计算机技术发展和数据分析理论的更新，当前的数据分析逐步成为机器语言、统计知识两个学科的交集

- **数据分析工具**

各种厂商开发了数据分析的工具、模块，将分析模型封装，使不了解技术的人也能够快捷的实现数学建模，快速响应分析需求。

- **信息处理**

信息处理基于查询，可以发现有用的信息。但是这种查询的回答反映的是直接存放在数据库中的信息。它们不反映复杂的模式，或隐藏在数据库中的规律。



- **传统分析**

在数据量较少时，传统的分析已能够发现数据中包含的知识，包括结构分析、杜邦分析等模型，方法成熟，应用广泛，本文不展开介绍

- **数据挖掘**

就是充分利用了统计学和人工智能技术的应用程序，并把这些高深复杂的技术封装起来，使人们不用自己掌握这些技术也能完成同样的功能，并且更专注于自己所要解决的问题。



数据挖掘是多学科交叉的产物



随着计算机科学的进步，数据挖掘、商务智能、大数据等概念的出现，数据分析的手段和方法更加丰富

常规分析



- 揭示数据之间的静态关系
- 分析过程滞后
- 对数据质量要求高

结构分析

分组分析

预警分析

杜邦分析

.....

数据挖掘



- 统计学和计算机技术等学科的结合
- 揭示数据之间隐藏的关系
- 将数据分析的范围从“已知”扩展到“未知”，从“过去”推向“将来”

商务智能



- 一系列以事实为支持，辅助商业决策的技术和方法，曾用名包括专家系统、智能决策等
- 一般由数据仓库、联机分析处理、数据挖掘、数据备份和恢复等部分组成
- 对数据分析的体系化管理，数据分析的主体依然是数据挖掘

大数据技术



- 从多种类型的数据中，快速获取知识的能力
- 数据挖掘技术的衍生

数据可视化



- 大数据时代，展示数据可以更好辅助理解数据、演绎数据



数据挖掘是智能化技术的核心



- 数据挖掘作为一门新兴的交叉学科，涉及数据库系统、数据仓库、统计学、机器学习、可视化、信息检索和高性能计算等诸多领域。
- 此外，还与神经网络、模式识别、空间数据分析、图像处理、信号处理、概率论、图论和归纳逻辑等领域关系密切。



03

数据挖掘的内容





数据、信息、知识



客户信息表

年龄	收入 (万)	工作时间 (年)	顾客类型
25	10	数据 2	优
29	12	3	优
32	9	6	良
38	7	12	良
36	18	信息 13	中
30	15	4	优
...	...	...	...

25<年龄<30, 收入>10, 工作时间>2年的消费者是优质顾客

知识



什么是数据挖掘



● 广义技术角度的定义

数据挖掘(Data Mining)就是从大量的、不完全的、有噪声的、模糊的、随机的实际应用数据中,提取隐含在其中的、人们事先不知道的、但又是潜在有用的信息或知识的**非平凡过程**。

该定义包括好几层含义:

- 数据源必须是**真实的、大量的、含噪声的**;
- 发现的是**用户感兴趣**的知识;
- 发现的知识要**可接受、可理解、可运用**;
- 并不要求发现放之四海皆准的知识,仅**支持特定**的发现问题的。



什么是数据挖掘




● 狭义技术角度的定义

也有人把数据挖掘视为知识发现过程中的一个基本步骤。

例如：由这些步骤的迭代序列组成：

- ◆ 知识表示
- ◆ 数据清理
- ◆ 数据集成
- ◆ 数据选择
- ◆ 数据变换
- ◆ 数据挖掘
- ◆ 模式评估






什么是数据挖掘





什么是数据挖掘





数据挖掘技术的核心概念



1. **数据**：数据是数据挖掘技术的基础，数据可以是结构化的(如关系型数据库)或非结构化的(如文本、图像、音频等)。
2. **特征**：特征是数据中的一些属性，这些属性可以用来描述数据。例如，在一个客户数据集中，特征可以是年龄、性别、购买历史等。
3. **模式**：模式是数据中的一种规律或关系，这种规律或关系可以用来描述数据之间的关系。
4. **知识**：知识是数据挖掘技术的目标，知识可以用来描述数据的特征和模式。
5. **算法**：算法是数据挖掘技术的核心，算法可以用来发现数据中的模式和知识。例如，K-均值聚类、DBSCAN聚类、Apriori算法等。
6. **评估**：评估是数据挖掘过程中用于衡量模型性能的方法。例如，准确率、召回率、F1分数等。



认识数据



• 大数据的定义

- 大数据（英语：**big data**；亦称作巨量资料），指的是传统数据处理应用软件不足以处理的**大或复杂的数据集**的形容术语。--维基百科
- 大数据是需要新处理模式才能具有更强的决策力、洞察发现力和流程优化能力来适应**海量、高增长率和多样化的**信息资产。--大数据研究机构Gartner
- 一种规模大到在获取、存储、管理、分析方面大大超出了传统数据库软件工具能力范围的数据集合，具有**海量的数据规模、快速的数据流转、多样的数据类型和价值密度低**四大特征。--麦肯锡全球研究



• 大数据的特征

规模性

多样性

高速性




价值性



数据的来源



- 关系数据库
- 数据仓库
- 事务数据库
- 空间、时间数据库
- 文本和多媒体数据（异构的）
- 各种结构化、半结构化的数据
- 互联网、移动互联网数据源
-





• 常见的数据库

- MySQL
- SQL Server
- Oracle
- MongoDB

• 数据库特点

- 持久化存储数据
- 方便数据检索和更新
- 保证数据完整性
- 保证数据安全性

} 数据库数据

数据库管理系统 (DBMS) : 数据 + 软件

关系数据库: 表组成

关键字

属性

cust_ID	name	age	gender	income	...
001	Tom	25	1	4500	
...					

元组

customer表




- 数据库中数据的特点如下：
 - ✓ 数据动态性
 - ✓ 数据的不完全性
 - ✓ 噪声数据
 - ✓ 数据类型不一致
 - ✓ 异构性
 - ✓ 数据冗余性
 - ✓ 数据稀疏性
- 由于数据库中的数据具有以上特点，**使其在挖掘过程中难以直接使用**，因此在进行数据挖掘以前必须对数据进行预处理。



- 数据仓库（英语：Data Warehouse，简称数仓、DW），是一个用于存储、分析、报告的数据系统。数据仓库的目的是构建面向分析的集成化数据环境，为企业提供决策支持（Decision Support）。

数据仓库

从多个数据源收集的信息存储库，存放在**一致的模式**下，并且通常驻留在单个站点上。





数据仓库




- 数据仓库的特点如下：
 - ✓ 面向主题
 - ✓ 集成的数据
 - ✓ 随时间不断变化
- 高质量的挖掘结果依赖于高质量的数据，数据仓库为数据挖掘准备了良好的数据源，因此，数据仓库是数据挖掘的**最佳环境**。



场景案例：数据仓库为何而来？



- 先下结论：**为了分析数据而来，分析结果给企业决策提供支撑**。如数仓定义所说，数仓是一个用于存储、分析、报告的数据系统，目的是构建面向分析的集成化数据环境。我们把这种面向分析、支持分析的系统称之为**OLAP（联机分析处理）系统**。数据仓库是OLAP一种。中国人寿保险公司就可以基于分析决策需求，构建数仓平台。





事物数据

数据库事务(Database Transaction)，是指作为单个逻辑工作单元执行的一系列操作，要么完全地执行，要么完全不执行。

设想**网上购物**的一次交易，其付款过程至少包括以下几步数据库操作：

- 一、更新客户所购商品的库存信息
- 二、保存客户付款信息——可能包括与银行系统的交互
- 三、生成订单并且保存到数据库中
- 四、更新用户相关信息，例如购物数量等等

<i>trans_ID</i>	商品ID的列表
T100	11, 13, 18, 116
T200	12, 18
...	...



事务数据库

ID	Fisher's Iris Data				
	Sepal Length	Sepal Width	Petal Length	Petal Width	Species
	4.3	3.0	1.1	0.1	setosa
	4.4	2.9	1.4	0.2	setosa
	⋮	⋮	⋮	⋮	⋮
	4.9	2.4	3.3	1.0	versicolor
	5.0	2.0	3.5	1.0	versicolor
	⋮	⋮	⋮	⋮	⋮
	5.6	2.8	4.9	2.0	virginica
	5.7	2.5	5.0	2.0	virginica
⋮	⋮	⋮	⋮	⋮	

数据一个成, 每个代表务。

事务数据库由一个文件组成，其中每个记录代表一个事务。

2020-6-11




其他数据



交易数据



移动通信数据



音频数据



人为数据



机器和传感器数据



图片数据



数据清洗&数据探索



数据探索

- 特征描述
- 分布推断
- 结构优化

数据清洗

数据清洗

- 异常值判别
- 缺失值处理
- 数据结构统一（人为因素较多，无统一方法，本文不详述）

数据探索

- 数据清洗和数据探索通常交互进行
- 数据探索有助于选择数据清洗方法
- 数据清洗后可以更有效的进行数据探索



数据清洗——异常值判别



数据清洗的第一步是识别会影响分析结果的“异常”数据，然后判断是否剔除。目前常用的识别异常数据的方法有物理判别法和统计判别法

物理判别法

- 根据人们对客观事物、业务等已有的认识，判别由于外界干扰、人为误差等原因造成实测数据偏离正常结果，判断异常值。
- 比较困难

统计判别法

- 给定一个置信概率，并确定一个置信限，凡超过此限的误差，就认为它不属于随机误差范围，将其视为异常值。
- 常用的方法（数据来源于同一分布，且是正态的）：拉依达准则、肖维勒准则、格拉布斯准则、狄克逊准则、t检验。

注意

- **慎重对待删除异常值：**为减少犯错误的概率，可多种统计判别法结合使用，并尽力寻找异常值出现的原因；若有多个异常值，应逐个删除，即删除一个异常值后，需再行检验后方可再删除另一个异常值
- **检验方法以正态分布为前提，若数据偏离正态分布或样本较小时，则检验结果未必可靠，**校验是否正态分布可借助W检验、D检验



常见统计判别法



判别方法	判别公式	剔除范围	操作步骤	评价
拉依达准则 (3σ准则)	$p(x - u > 3\sigma) \leq 0.003$	大于 $\mu+3\sigma$ 小于 $\mu-3\sigma$	求均值、标准差，进行边界检验，剔除一个异常数据，然后重复操作，逐一剔除	适用于 $n>185$ 时的样本判定
肖维勒准则（等概率准则）	$ x_i - \bar{x} > Z_c(n) \sigma$	大于 $\mu + Z_c(n)\sigma$ 小于 $\mu - Z_c(n)\sigma$	求均值、标准差，比对系数读取 $Z_c(n)$ 值，边界检验，剔除一个异常数据，然后重复操作，逐一剔除	实际中 $Z_c(n)<3$ ，测算合理，当 n 处于 $[25, 185]$ 时，判别效果较好
格拉布斯准则	$ x_i - \bar{x} > T(n, \alpha) \sigma$	删除水平： $ x_i - \bar{x} > T(n, \alpha_1) \sigma$ 异常检出水平： $T(n, \alpha_1) \sigma < x_i - \bar{x} < T(n, \alpha_2) \sigma$	逐一判别并删除达到删除水平的数据；针对达到异常值检出水平，但未及删除水平的数据，应尽量找到数据原因，给以修正，若不能修正，则比较删除与不删除的统计结论，根据是否符合客观情况做去留选择	$T(n, \alpha)$ 值与重复测量次数 n 及置信概率 α 均有关，理论严密，概率意义明确。当 n 处于 $[25, 185]$ 时 $\alpha=0.05$ ，当 n 处于 $[3, 25]$ 时 $\alpha=0.01$ ，判别效果较好
狄克逊准则	$f_0 = \frac{x_{(n)} - x_{(n-1)}}{x_{(n)} - x_{(1)}}$ 或 $\frac{x_{(2)} - x_{(1)}}{x_{(n)} - x_{(1)}}$	$f_0 > f(n, \alpha)$ ，说明 $x(n)$ 离群远，则判定该数据为异常数据	将数据由小到大排成顺序统计量，求极差，比对狄克逊判断表读取 $f(n, \alpha)$ 值，边界检验，剔除一个异常数据，然后重复操作，逐一剔除	异常值只有一个时，效果好；同侧两个数据接近，效果不好；当 n 处于 $[3, 25]$ 时，判别效果较好
T检验	$ x_{(n)} - \bar{x} > K(n, \alpha) \sigma$ 或 $ x_{(1)} - \bar{x} > K(n, \alpha) \sigma$	最大、最小数据与均值差值大于 $K(n, \alpha) \sigma$	分别检验最大、最小数据，计算不含被检验最大或最小数据时的均值及标准差，逐一判断并删除异常值	异常值只有一个时，效果好；同侧两个极端数据接近时，效果不好；因而有时通过中位数代替平均数的调整方法可以有效消除同侧异常值的影响



数据清洗——缺失值处理



在数据缺失严重时，会对分析结果造成较大影响，因此对剔除的异常值以及缺失值，要采用合理的方法进行填补，常见的方法有平均值填充、K最近距离法、回归法、极大似线估计法等

平均值填充

取所有对象（或与该对象具有相同决策属性值的对象）的平均值来填充该缺失的属性值

K最近距离法

先根据欧式距离或相关分析确定距离缺失数据样本最近的K个样本，将这K个值加权平均来估计缺失数据值

回归

基于完整的数据集，建立回归方程（模型），对于包含空值的对象，将已知属性值代入方程来估计未知属性值，以此估计值来进行填充；但当变量不是线性相关或预测变量高度相关时会导致估计偏差

极大似线估计

在给定完全数据和前一次迭代所得到的参数估计的情况下计算完全数据对应的对数似然函数的条件期望（E步），后用极大化对数似然函数以确定参数的值，并用于下步的迭代（M步）

多重插补法

由包含m个插补值的向量代替每一个缺失值，然后对新产生的m个数据集使用相同的方法处理，得到处理结果后，综合结果，最终得到对目标变量的估计

随着数据量的增大，异常值和缺失值对整体分析结果的影响会逐渐变小，因此在“大数据”模式下，数据清洗可忽略异常值和缺失值的影响，而侧重对数据结构合理性的分析



数据探索




通过数据探索，初步发现数据特征、规律，为后续数据建模提供输入依据，常见的数据探索方法有数据特征描述、相关性分析、主成分分析等。

数据探索要遵循由浅入深、由易到难的步骤






数据特征描述



中心位置

- ❖ 众数
- ❖ 中位数/四分位数
- ❖ 均值




图形特征

- ❖ 偏度
数据分布偏斜程度的测度




- ❖ 峰度
数据分布扁平程度的测度



分散程度

- ❖ 方差和标准差
- ❖ 极差、四分位差
- ❖ 标准分数 z-score
- ❖ 离散系数





数据概率分布



概率分布可以表述随机变量取值的概率规律，是掌握数据变化趋势和范围的一个重要手段。

离散分布

均匀分布

离散型均匀分布是一个离散型概率分布，其中有限个数值拥有相同的概率

二项分布

1. 在每次试验中只有两种可能的结果，而且是互相对立的；
2. 每次实验是独立的，与其它各次试验结果无关；
3. 结果事件发生的概率在整个系列试验中保持不变，则这一系列试验称为伯努力试验。

几何分布

以下两种离散型概率分布中的一种：

- 在伯努力试验中，得到一次成功所需要的试验次数 X 。 X 的值域是 $\{1, 2, 3, \dots\}$
- 在得到第一次成功之前所经历的失败次数 $Y = X - 1$ 。 Y 的值域是 $\{0, 1, 2, 3, \dots\}$

泊松近似

泊松近似是二项分布的一种极限形式。其强调如下的试验前提：一次抽样的概率值相对很小，而抽取次数又相对很大。因此泊松分布又被称之为罕有事件分布。泊松分布指出，如果随机一次试验出现的概率为 p ，那么在 n 次试验中出现 k 次的概率按照泊松分布应该为

正态分布

若随机变量 X 服从一个数学期望为 μ 、方差为 σ^2 的高斯分布，记为 $N(\mu, \sigma^2)$ 。其概率密度函数为正态分布的期望值 μ 决定了其位置，其标准差 σ 决定了分布的幅度。因其曲线呈钟形，因此人们又经常称之为钟形曲线。我们通常所说的标准正态分布是 $\mu = 0, \sigma = 1$ 的正态分布

连续分布

均匀分布

如果连续型随机变量具有如下 $p=1/(b-a)$ 的概率密度函数，其中 $X[a, b]$ ，则称服从上的均匀分布

指数分布

指数分布可以用来表示独立随机事件发生的时间间隔，比如指数分布还用来描述大型复杂系统（如计算机）的平均故障间隔时间MTBF的失效分布

正态分布



数据分布初步推断



假设检验是数理统计学中根据一定假设条件由样本推断总体的一种方法，可以分为参数检验和非参数检验。

参数检验：数据的分布已知的情况下，对数据分布的参数是否落在相应范围内进行检验

检验方法名称	问题类型	假设	适用条件	抽样方法
单样本T—检验	判断一个总体平均数等于已知数	总体平均数等于A	总体服从正态分布	从总体中抽取一个样本
F—检验	判断两总体方差相等	两总体方差相等	总体服从正态分布	从两个总体中各抽取一个样本
独立样本 T—检验	判断两总体平均数相等	两总体平均数相等	1、总体服从正态分布 2、两总体方差相等	从两个总体中各抽取一个样本
配对样本T—检验	判断指标实验前后平均数相等	指标实验前后平均数相等	1、总体服从正态分布 2、两组数据是同一试验对象在试验前后的测试值	抽取一组试验对象，在试验前测得试验对象某指标的值，进行试验后再测得试验对象该指标的取值
二项分布假设检验	随机抽样实验的成功概率的检验	总体概率等于P	总体服从二项分布	从总体中抽取一个样本

非参数检验：一般是在不知道数据分布的前提下，检验数据的分布情况

检验方法名称	问题类型	假设
卡方检验	检测实际观测频数与理论频数之间是否存在差异	观测频数与理论频数无差异
K-S检验	检验变量取值是否为正态分布	服从正态分布
游程检验	检测一组观测值是否有明显变化趋势	无明显变化趋势
二项分布假设检验	通过样本数据检验样本来自的总体是否服从指定的概率为P的二项分布	服从概率为P的二项分布

总结

- 1、参数检验是针对参数做的假设，非参数检验是针对总体分布情况做的假设。
- 2、二者的根本区别在于参数检验要利用到总体的信息，以总体分布和样本信息对总体参数作出推断；非参数检验不需要利用总体的信息。




结构优化——相关性分析



用于分析的多个变量间可能会存在较多的信息重复，若直接用来分析，会导致模型复杂，同时可能会引起模型较大误差，因此要初步探索数据间的相关性，剔除重复因素。

相关系数是考察变量之间的相关程度的变量，相关分析是优化数据结构的基础






结构优化——主成分分析



Karl Pearson (1901) 探究如何通过少数几个主成分(principal component)来解释多个变量间的内部结构时提出主成分分析法, 旨在从原始变量中导出少数几个主分量, 使其尽可能多地保留原始变量的信息, 且彼此间互不相关

内涵: 将彼此相关的一组指标变量转化为彼此独立的一组新的指标变量, 并用其中较少的几个新指标变量就能综合反映原多个指标变量所包含主要信息的多元统计方法

- 应用: 数据的压缩和解释, 即常被用来寻找和简化判断事物或现象的综合指标, 并对综合指标所包含的信息进行适当的解释
- 原理: 设法将原来变量重新组合成一组新的互相无关的几个综合变量, 同时根据实际需要从中可以取出几个较少的综合变量尽可能多地反映原来变量的信息的统计方法叫做主成分分析或称主分量分析, 也是数学上用来降维的一种方法。





数据转换



数据转换或统一成适合于挖掘的形式，通常的做法有数据泛化、标准化、属性构造等

- 各方法都有缺点，要根据客观事物的特征及所选用的分析方法来确定，如聚类分析、关联分析等常用直线法，且聚类分析必须满足无量纲标准；而综合评价则折线和曲线方法用得较多
- 能简就简，能用直线尽量不用曲线。

基期标准化法

- 选择基期作为参照，
各期标准化数据 = 各期数据 / 基期数据

折线法

- 某些数据在不同值范围，
采用不同的标准化方法，
通常用于综合评价

$$x_i' = \begin{cases} 0 & (x_i < a) \\ \frac{x_i - a}{b - a} & (a \leq x_i < b) \\ 1 & (x_i \geq b) \end{cases} \quad \text{示例}$$

直线法 $x' = \log(x_i) / \log(\max(x_i))$


- 极值法 $x_i' = \frac{x_i - \min(x_i)}{\max(x_i) - \min(x_i)}$
- z-score法: $x_i' = \frac{x_i - \bar{x}}{s}$, 其中 $s = \sqrt{\frac{1}{n-1} \sum (x_i - \bar{x})^2}$

曲线法

- Log函数法:
- Arctan函数法:
- 对数函数法、模糊量化模式等



物联网与大数据



- 物联网采集的数据是大数据的重要基础。物联网是大数据的主要数据来源,占到了整个数据来源的百分之九十以上。



- 物联网平台的发展进一步整合大数据和人工智能。



数据的存储与管理



• 数据存储形式





Figure 1 : 集群基本模式图

集群



分布式存储

区别


集群：不同服务器实现同一功能，分散压力，每台服务器并非缺一不可
分布式存储：不同服务器实现不同功能，每台服务器缺一不可



数据的存储与管理



• 数据存储形式



云存储



NoSQL数据库，泛指非关系型数据库

大数据的存储问题一般采用**集群+分布式存储**的形式解决



数据分析



- 数据分析是有组织有目的地收集数据、分析数据，使之成为信息的过程
 - 数据分析的目的是把隐藏在一大批看来杂乱无章的数据中的信息集中和提炼出来，从而找出所研究对象的内在规律
 - 在实际应用中，数据分析可帮助人们做出判断，以便采取适当行动
- 四种分析形式



描述性分析

诊断性分析

预测型分析


指令型分析



数据可视化



- 数据可视化主要是借助于图形化手段，清晰有效地传达与沟通信息。
- 数据可视化设计流程



- | | | | |
|-----------------|-----------------|---------|------|
| ● 数据谁来配？谁来看？ | ● 每种图表的侧重点 | ● 图例与标注 | ● 颜色 |
| ● 我们对数据的把控力有多少？ | ● 哪种图表适合展示所选的数据 | ● 单位与格式 | ● 大小 |
| | | ● 隐藏信息 | ● 动效 |



大数据的应用





数据挖掘常见任务



数据挖掘任务是指根据某个特定的需求，对数据进行挖掘和分析的过程：

- **分类(Classification)**：将数据分为多个类别，以便更好地理解其特征和特点。
- **聚类(Clustering)**：根据数据之间的相似性，将数据分为多个组合，以便更好地发现数据之间的关系。是在未知数据的结构下，发现数据的类别与结构。
- **关联规则挖掘(Association Rule Mining) (关联分析)**：发现数据之间存在的相互依赖关系，以便更好地了解数据之间的联系。例如，超市顾客购买习惯。
- **序列挖掘(Sequential Pattern Mining)**：发现数据序列中存在的规律和模式，以便更好地预测数据的发展趋势。
- **回归 (Regression)**：建立连续值函数模型（一般线性回归，logistic回归），预测某些未知或遗漏的数值
- **异常检测(Anomaly Detection) (离群点检测)**：发现数据中存在的异常值，以便更好地识别问题和风险。



什么是数据挖掘





关联规则挖掘 [Descriptive]



设关联规则: $A \rightarrow B$, $\{A\}$ 或 $\{B\}$ 为项集, 支持度 = $\{A \cap B\} / \{A\} + \{B\}$, 表示同时包含A、B事务占总事务的百分比;
置信度 = $\{A \cap B\} / \{A\}$, 是预测性指标, 表示A事务发生B事务发生的可能性。显然支持度为对称指标, 即 $A \rightarrow B$ 或 $B \rightarrow A$ 都一样, 而置信度为非对称指标, 二者不同。我们以茶和咖啡的案例做指标说明。

	A	$\neg A$	合计
B	F11	F10	F1+
$\neg B$	F01	F00	F0+
合计	F+1	F+0	F

支持度 ($\{喝茶\} \rightarrow \{喝咖啡\}$) = $150/1000 = 15\%$;
置信度 ($\{喝茶\} \rightarrow \{喝咖啡\}$) = $150/200 = 75\%$ 。即一个人喝茶那么他75%可能喝咖啡。
再看, 不管一个人是否喝茶, 其喝咖啡的比例为 $800/1000 = 80\% > 75\%$ 。即一个人喝茶其喝咖啡的可能性由80%降低到75%, 因此 $\{喝茶\} \rightarrow \{喝咖啡\}$ 的高置信度实际上是一个误导, 其忽略了喝咖啡的支持度。因此, 支持度-置信度的评估框架是不完善的。

示例

	喝咖啡 (A)	不喝咖啡 ($\neg A$)	合计
喝茶 (B)	150	50	200
不喝茶 ($\neg B$)	650	150	800
合计	800	200	1000

兴趣因子

置信度除以喝咖啡的支持度, 即 $75\%/80\% = 0.94$ 。大于1表示正相关, 而且越大相关性越强; 等于1表示相互独立; 小于1表示负相关。

相关性

对于连续变量相关性用pearson相关系数, Pearson相关系数用来衡量两个数据集合是否在一条线上面, 它用来衡量定距变量间的线性关系。如衡量国民收入和居民储蓄存款、身高和体重、高中成绩和高考成绩等变量间的线性相关关系。



关联规则挖掘 [Descriptive]: 啤酒与尿布



- 在一家超市里，有一个有趣的现象：尿布和啤酒赫然摆在一起出售。
- 但是这个奇怪的举措却使尿布和啤酒的销量双双增加了。
- 原因何在？
- 原来，美国的妇女们经常会嘱咐她们的丈夫下班以后要为孩子买尿布。而丈夫在**买完尿布之后又要顺手买回自己爱喝的啤酒**，因此啤酒和尿布在一起购买的机会还是很多的。
- 是什么让沃尔玛发现了尿布和啤酒之间的关系呢？
- 正是商家通过对超市一年多原始交易数字进行详细的分析，通过数据挖掘中的**关联规则**发现了这样的组合。





关联规则挖掘 [Descriptive]: 网上书店关联销售案例



- 现在网上书店为了能够吸引更多读者购买图书，常常会运用一种叫做**关联销售分析**的方法。
- 这种方法是在客户购买了一种书籍之后，**推荐**给客户应该感兴趣的其他相关书籍。
- 例如：购买了《月光宝盒（2VCD）》的顾客，对什么样的VCD还比较感兴趣，购买的比较多呢？。
- 现在网上书店为了能够吸引更多读者购买图书，常常会运用一种叫做**关联销售分析**的方法。
- 这种方法是在客户购买了一种书籍之后，**推荐**给客户应该感兴趣的其他相关书籍。
- 例如：购买了《月光宝盒（2VCD）》的顾客，对什么样的VCD还比较感兴趣，购买的比较多呢？。



关联规则挖掘 [Descriptive]: 网上书店关联销售案例



对上述问题进行挖掘的结果:

Book Name	SUPPORT	\$PROBABILITY	\$ADJUSTED PROBABILITY
大圣娶亲	0.1317	0.8085	0.8085
大内密探零零发	0.1317	0.7070	0.7070
九品芝麻官	0.1317	0.7209	0.7209
千王之王2000	0.1317	0.6990	0.6990
百变金刚	0.1317	0.7031	0.7031
唐伯虎点秋香	0.1317	0.7211	0.7211
97家有喜事	0.1317	0.7017	0.7017
武状元苏乞儿	0.1317	0.7177	0.7177

支持度: 表示在购物篮分析中同时包含关联规则左右两边物品的交易次数百分比, 即支持这个规则的交易的次数百分比。

置信度: 是指在所有的购买了左边商品的交易中, 同时又购买了右边商品的交易概率。

解决上述问题的步骤:

- 首先, 确定数据源, 也就是**销售记录**。
- 这里要用到两张表, 一张表是**该书店的会员**, 用会员ID号来代替; 另一张表是**会员买了什么书**。然后, 应用Data Mining技术, 建立数据挖掘模型

◆ 结果: 购买《月光宝盒 (2VCD)》之后, 又购买《大圣娶亲(2VCD)》的次数是1317。



关联规则挖掘 [Descriptive]



- 关联规则

- 关联规则是形如 $X \rightarrow Y$ 的蕴含表达式, 其中 X 和 Y 是不相交的项集

- 例子:

$\{\text{Milk, Diaper}\} \rightarrow \{\text{Beer}\}$

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

- 关联规则的强度

- 支持度 Support (s)
 - 确定项集的频繁程度
- 置信度 Confidence (c)
 - 确定Y在包含X的事务中出现的频繁程度

Example:

$\{\text{Milk, Diaper}\} \Rightarrow \text{Beer}$

$$s = \frac{\sigma(\text{Milk, Diaper, Beer})}{|T|} = \frac{2}{5} = 0.4$$

$$c = \frac{\sigma(\text{Milk, Diaper, Beer})}{\sigma(\text{Milk, Diaper})} = \frac{2}{3} = 0.67$$



关联规则挖掘 [Descriptive]



关联规则挖掘问题:

给定事务的集合 T , 关联规则发现是指找出**支持度大于等于 minsup** 并且**置信度大于等于 minconf**的所有规则, minsup和minconf是对应的支持度和置信度阈值

事务Id	项集合
10	A, B, C
20	A, C
30	A, D
40	B, E, F

最小支持度 50%
最小置信度 50%

频繁模式	支持度
{A}	75%
{B}	50%
{C}	50%
{A, C}	50%

规则 $A \Rightarrow C$:

$$\text{支持度} = \text{support}(\{A\} \cup \{C\}) = 50\%$$

$$\text{置信度} = \text{support}(\{A\} \cup \{C\}) / \text{support}(\{A\}) = 66.6\%$$



关联规则挖掘 [Descriptive]



- 大多数关联规则挖掘算法通常采用的一种策略是，将关联规则挖掘任务分解为如下两个主要的子任务：
 - **频繁项集产生 (Frequent Itemset Generation)**
 - 其目标是发现满足最小支持度阈值的所有项集，这些项集称作频繁项集。
 - **规则的产生 (Rule Generation)**
 - 其目标是从上一步发现的频繁项集中提取所有高置信度的规则，这些规则称作强规则 (strong rule) 。



关联规则主要算法



主要的关联算法：Apriori关联算法、FP-growth关联算法等；

Apriori算法是最基本的一种关联规则算法，它采用布尔关联规则的挖掘频繁项集的算法，利用逐层搜索的方法挖掘频繁项集。





关联规则模型评估



关联规则

目的：识别有意义（有价值）的关联模式

客观度量

评价项集：对称度量指标

- 支持度
- 相关性
- 兴趣因子
- 余弦
- Jaccard
- 集体强度
-

评价关联规则：非对称客观度量

- 置信度
- J度量
- Gini指标
- 可信度因子
- 互信息
- 信任度
-

主观度量

- 可视化
- 基于主观模板的度量
- 基于主观兴趣的度量
-



关联规则挖掘 [Descriptive]: 关联分析的应用



- 比如人寿保险。 保险公司在接受保险前，往往需要记录投保人详尽的信息，有时还要到医院做身体检查。保单上记录有投保人的年龄、性别、健康状况、工作单位、工作地址、工资水平等。
- 通过分析这些数据，可以得到类似以下这样的**关联规则**：年龄在**40岁以上**，工作在**A区**的投保人当中，有**45%的人**曾经向保险公司索赔过。在这条规则中，
 - “年龄在40岁以上” $\cap$ “工作在A区” $\rightarrow$ “向保险公司索赔过”
- 可以看出来，A区**可能污染比较严重，环境比较差**，导致工作在该区的人健康状况不好，索赔率也相对比较高。



分类 [Predictive]





分类分析 —— 第一步：学习建模



目标ID	高度	速度	目标类别
001	<30	低	MQ-4C
002	<30	低	MQ-4C
003	30 ~ 40	高	F-20
...	...	...	...

训练样本

分类算法

If 高度=30 to 40
and 速度=高 则类
别=F-20

分类规则



分类分析 —— 第二步：分类测试



目标ID	高度	速度	目标类别
100	>40	高	?
101	<30	低	?
102	30 ~ 40	高	?
...	...	...	...

分类规则


测试数据

F-20

分类规则新数据：102，
30 ~ 40，速度高，
为什么类型目标？



分类模型评估





分类模型评估



测试集选取方法

方法	描述	图示
保持法	将原始数据集随机地划分到两个独立的集合:训练集和检验集。通常, 三分之二的的数据分配到训练集, 其余三分之一分配到检验集。模型的效果指标如准确率、误差等由训练集导出。	
随机二次抽样	多次重复使用保持法, 得到一组准确率等效果指标。	
交叉验证	最常用的是k-折交叉法, 将原始数据分成k份, 每次用其中一份为测试集, 其余为训练集运行, 总共运行k次, 记录误差。	
自助法	有放回抽样。训练集的样本为N, 放回原数据集, 重新有放回地均匀抽取N个样本后, 剩余的数据集作为测试集。	



分类模型评估



效果指标—基于比率

以二分类为例，说明几个重要效果指标概念。下图为混淆矩阵。通过银行办理信用卡的例子做指标的业务解释。

预测类 实际类	1	0	合计
1	a	b	a+b
0	c	d	c+d
合计	a+c	b+d	a+b+c+d

预测类 实际类	违约	不违约	合计
违约	80	120	200
不违约	20	980	1000
合计	100	1100	1200

准确率
 $= (a+d)/(a+b+c+d)$

最常用的评估指标，用以评价模型分类是否正确。但是，对于不平衡问题（即0类的占大多数），准确率去评价就不够。例如银行办理信用卡，模型只用一条规则“所有人不违约”，结果准确率达到 $1000/1200=83.3\%$ 。但这样的模型毫无意义。准确率适合于平衡问题。

敏感性 $= a/(a+b)$

正确识别正元组的百分比。如例中，敏感性为 $80/200=40\%$ ，因此该模型正确标识真元组（稀有类）的能力还是比较差的，但是还是高于违约的总占比 $200/1200=16.7\%$

特异性 $= d/(c+d)$

正确识别负元组的百分比。例子中为98%。

精度 $= a/(a+c)$

预测为正元类中实际为正元类所占的百分比。衡量预测类1的精确性。例子中为80%。


该案例中模型对于违约的人群，可以识别40%；如果一个人通过模型判断为违约类，则80%可能该人为违约的。敏感性和精度是两个重要指标，可以综合这两个指标，如F等。



分类模型评估




ROC曲线




以真正率及敏感性为纵轴，假正率=1-特异性为横轴做图。给定一个二类问题，我们可以对检验集的不同部分，显示模型可以正确识别正样本的比例与模型将负样本错误标识为正样本的比例之间的比较评定。敏感性的增加以错误正例的增加为代价。

增益图



和捕获率曲线是一样的，详见捕获率曲线。
理想模型：100%预测正确下的曲线。这里假设1类占总数为30%。
模型的曲线越靠近理想曲线，预测水平越高。可用Gini系数衡量。
Gini系数=模型曲线与随机曲线之间的面积/理想模型曲线与随机曲线之间的面积。越接近1越好。

KS曲线




模型预测为概率值，即为1类的概率为多少，为0类的概率为多少。将1类、0类的概率按照大小由高到底排列，并将各自的累计百分比画在一个图里。纵坐标代表累计百分比，横坐标为预测的概率区间。
0、1曲线的最大距离为KS值，反映模型区分0、1类的能力，越大代表模型将0、1分开程度越大。一般大于0.2较好。如图KS=0.47。



分类模型评估




Lift图




Lift值=响应率/随机概率。比如对10000名潜在顾客进行概率打分，预测其购买商品的可能性，若实际中有900人会购买，则9%为随机概率。抽取概率排名前10%的人数，即1000人，预测600人购买，则前10%的响应率为600/1000=60%，则Lift值=60%/9%=6.67。

响应率曲线



在每个区间里进行计算，1类的累计数占该区间累计的总数比例作为**响应率**。比如在排序前10%中，模型1得出1类样本占比80%，模型2为73%。响应率越高越好，改图显示模型1较模型2更好。

捕获率曲线



是在每个区间段，计算1类的累计值占总体1类的百分比作为**捕获率**。衡量的是某累计区间抓住1类的对象占总体的比例。

随机概率：不用模型随机抽取数据得到的比率。比如响应率，总数据中1类占比20%，那抽取10%数据理论占比应该还是20%。
横坐标：按照模型结果概率得分从高到底排序，分成10个区间。适合于模型输出值为概率得分，如贝叶斯分类、后向传播等。

三个指标在实际业务中使用比较多，因为其直观、通俗易懂；同时有利于划分不同的目标人群，前10%？、20%？根据业务需要挑选受众规模。



分类案例-目标类别预测



一个面积大小中等、速度良好、
机长短的空中目标

预测：该目标是否F16

机长	面积	空中	速度	是否F16
≤ 30	high	no	fair	no
≤ 30	high	no	excellent	no
31...40	high	no	fair	yes
> 40	medium	no	fair	yes
> 40	low	yes	fair	yes
> 40	low	yes	excellent	no
31...40	low	yes	excellent	yes
≤ 30	medium	no	fair	no
≤ 30	low	yes	fair	yes
> 40	medium	yes	fair	yes
≤ 30	medium	yes	excellent	yes
31...40	medium	no	excellent	yes
31...40	high	yes	fair	yes
> 40	medium	no	excellent	no





分类案例-军内人员稳定性预测



- 军内人员稳定性预测

从给定的影响人员离职的因素和人员是否离职的记录，建立一个模型预测有可能离职的人员。

属 性	说 明
Age	年龄
Attrition	是否已经离职，0：离职，1：未离职
BusinessTravel	商务差旅频率
DistanceFromHome	人员所在部门
Education	人员的教育程度，从1到5，5表示教育程度最高
.....	
YearsWithCurrManager	跟目前的管理者共事年数




回归



产生：英国统计学家F.GALTON (法兰西斯·高尔顿) (1822-1911)和其学生K.Pearson (卡尔·皮尔逊) (1856-1936)观察了1078对夫妇，以每对夫妇的平均身高为X，而取他们成年的儿子的身高为Y，得到如下经验方程： $Y=33.73+0.516X$

定义：假定同一个或多个独立变量存在相关关系，寻找相关关系的模型。不同于时间序列法的是：模型的因变量是随机变量，而自变量是可控变量。分为线性回归和非线性回归，通常指连续要素之间的模型关系，是因果关系分析的基础。（回归研究的是数据之间的非确定性关系）

线性回归算法寻找属性与预测目标之间的线性关系。通过属性选择与去掉相关性，去掉与问题无关的变量或存在线性相关性的变量。在建立回归模型之前，可先进行主成分分析，消除属性之间的相关性。最后通过最小二乘法，算法得到各属性与目标之间的线性系数。







回归



线性回归算法寻找属性与预测目标之间的线性关系。通过属性选择与去掉相关性，去掉与问题无关的变量或存在线性相关性的变量。在建立回归模型之前，可先进行主成分分析，消除属性之间的相关性。最后通过最小二乘法，算法得到各属性与目标之间的线性系数。





回归



分类:

一元线性回归

只有一个变量X与因变量Y有关, X与Y都是连续型变量, 因变量Y或其残差必须服从正态分布

多元线性回归

分析多个变量与因变量Y的关系, X与Y都是连续型变量, 因变量Y或其残差必须服从正态分布

LOGISTIC线性回归

分析多个变量与因变量Y的关系, Y通常是离散型或定性变量, 该模型对因变量Y的分布无要求

前提:

- 正态性假设: 总体误差项需服从正态分布, 反之则最小二乘估计不再是最佳无偏估计, 不能进行区间估计和假设检验
- 零均值性假设: 在自变量取一定值的条件下, 其总体各误差项的条件平均值为零, 反之无法得到无偏估计
- 等方差性假设: 在自变量取一定值的条件下, 其总体各误差项的条件方差为一常数, 反之无法得到无偏估计
- 独立性假设: 误差项之间相互独立(不相关), 误差项与自变量之间应相互独立, 否则最小二乘估计不再是有效估计

检验:

回归模型

样本容量: $n \geq 30$ 或 $n \geq 3(p+1)$; 其中n为样本容量, p为自变量数目

模型显著性: F检验, 读取p值并同置信度比较, 判断回归模型显著性

系数显著性: t检验, 读取p值并同置信度比较, 判断该自变量是否显著影响因变量

拟合优度

残差检验: 绘制残差图(标准化残差直方图及散点图), 检验残差的正态性及独立性, 若所描绘的点都在以0为横轴的直线上下随机散布, 则回归直线对各个观测值的拟合情况良好

决定系数: R^2 度量自变量对因变量变化的解释程度, 愈接近1则线性关系愈强



聚类



聚类是在要划分的**类未知**的情况下，将数据库中的记录划分为多个类或簇，使得同类内的对象之间具有较高的相似度，不同类间的差异较大。

- 类标号(Class label) 未知: 对数据分组, 形成新的类. 例如, 对房屋分类, 找出分布模式。
- 聚类原则: 最大化类内的相似性, 最小化类间的相似性。



分析数据对象，而不考虑已知类的标记



聚类技术：军用目标和民用目标区分



聚类与分类



- 从统计学的观点看，聚类分析是通过数据建模简化数据的一种方法。
- 从机器学习的角度看，簇相当于隐藏模式。聚类是搜索簇的无监督学习过程。
- 从实际应用的角度看，聚类分析是数据预处理（降维）和信息挖掘的主要任务之一。

聚类分析

过程：根据样本数据的特征，自动进行分类

核心：物以类聚，人以群分

目的：使属于同一类别的数据间的相似性尽可能大，不同类别中的数据间的相似性尽可能小


CSDN @银河初升



聚类——k-MEANS



- K-Means聚类算法的优势在于它的速度非常快，因为我们所做的只是计算点和群中心之间的距离；它有一个线性复杂度 $O(n)$ 。
- K-Means缺点：
 - 必须选择有多少组/类。这并不是不重要的事，理想情况下，我们希望它能帮我们解决这些问题，因为它的关键在于从数据中获得一些启示。
 - K-Means也从随机选择的聚类中心开始，因此在不同的算法运行中可能产生不同的聚类结果。因此，结果可能是不可重复的，并且缺乏一致性。其他聚类方法更加一致。






聚类——均值偏移聚类算法



- 均值偏移 (Mean shift) 聚类算法是一种基于滑动窗口 (sliding-window) 的算法，它试图找到密集的数据点。而且，它还是一种基于中心的算法，它的目标是定位每一组群/类的中心点，通过更新中心点的候选点来实现滑动窗口中的点的平均值。这些候选窗口在后期处理阶段被过滤，以消除几乎重复的部分，形成最后一组中心点及其对应的组。
- 与K-Means聚类相比，均值偏移不需要选择聚类的数量，因为它会自动地发现这一点。这是一个巨大的优势。聚类中心收敛于最大密度点的事实也是非常可取的，因为它非常直观地理解并适合于一种自然数据驱动。缺点是选择窗口大小/半径 r 是非常关键的，所以不能疏忽。






聚类——DBSCAN聚类算法




- DBSCAN(Density-Based Spatial Clustering of Applications with Noise)是一个比较有代表性的基于密度的聚类算法，类似于均值转移聚类算法。
- 它不需要一个预设定的聚类数量。它还将异常值识别为噪声，而不像均值偏移聚类算法，即使数据点非常不同，它也会将它们放入一个聚类中。此外，它还能很好地找到任意大小和任意形状的聚类。
- 缺点是，当聚类具有不同的密度时，它的性能不像其他聚类算法那样好。这是因为当密度变化时，距离阈值 ϵ 和识别邻近点的minPoints的设置会随着聚类的不同而变化。这种缺点也会出现在非常高维的数据中，因为距离阈值 ϵ 变得难以估计。





聚类——层次聚类算法



- 层次聚类算法实际上分为两类：自上而下或自下而上。自下而上的算法在一开始就将每个数据点视为一个单一的聚类，然后依次合并（或聚集）类，直到所有类合并成一个包含所有数据点的单一聚类。因此，**自下而上**的层次聚类称为**合成聚类或HAC**。聚类的层次结构用一棵树（或树状图）表示。树的根是收集所有样本的唯一聚类，而叶子是只有一个样本的聚类。



聚类模型评估



聚类

目的：评估聚类效果、确定合适的分类数量、聚类模型的选择

评估指标	公式定义	图示定义
凝聚度	衡量一个族内对象凝聚情况	
分离度	衡量族与族之间的差异	
轮廓系数	综合了凝聚度和分离度	
相似度矩阵	通过与理想相似矩阵比较，看聚类效果	
共性分类相关系数	衡量共性分类矩阵与原相异度矩阵之间的相关度，用以评估哪种层次聚类方法最好。	



离群点检测



- 异常值（离群点、孤立点）指的是数据库中不符合数据一般模型的数据对象。一个数据对象，它与数据的一般行为不一致。
- 从数据库中探测异常值很有意义，因为它们本身可能隐藏着重要的信息，比正常的数据更有用，忽略或删除它们都会导致信息的丢失。
 - 例如，发现金融和保险领域的欺诈行为、税款的脱逃、通信费用的恶意欠费、网络中的黑客入侵、追寻极低或极高收入者的消费行为以及对多种治疗方式不寻常反映的发现等。




图 12.2 黑色对象形成集体离群点



离群点检测




• 离群点的类型

分类标准	分类名称	分类描述
从数据范围	全局离群点和局部离群点	从整体来看，某些对象没有离群特征，但是从局部来看，却显示了一定的离群性。如图：C是全局离群点，D是局部离群点。
从数据类型	数值型离群点和分类型离群点	这是以数据集的属性类型进行划分的。
从属性的个数	一维离群点和多维离群点	一个对象可能有一个或多个属性。

离群点检测的挑战

- 正常对象和离群点的有效建模
- 针对应用的离群点检测
- 在离群点检测中处理噪声
- 可理解性





离群点检测



离群点检测方法	方法描述	方法评估
基于统计	大部分的基于统计的离群点检测方法是构建一个概率分布模型，并计算对象符合该模型的概率，把具有低概率的对象视为离群点。	基于统计模型的离群点检测方法的前提是必须知道数据集服从什么分布；对于高维数据，检验效果可能很差。
基于邻近度	通常可以在数据对象之间定义邻近性度量，把远离大部分点的对象视为离群点。	简单，二维或三维的数据可以做散点图观察；大数据集不适用；对参数选择敏感；具有全局阈值，不能处理具有不同密度区域的数据集。
基于密度	考虑数据集可能存在不同密度区域这一事实，从基于密度的观点分析，离群点是在低密度区域中的对象。一个对象的离群点得分是该对象周围密度的逆。	给出了对象是离群点的定量度量，并且即使数据具有不同的区域也能够很好的处理；大数据集不适用；参数选择是困难的。
基于聚类	一种是利用聚类检测离群点的方法是丢弃远离其他簇的小簇；另一种更系统的方法，首先聚类所有对象，然后评估对象属于簇的程度（离群点得分）。	基于聚类技术来发现离群点可能是高度有效的；聚类算法产生的簇的质量对该算法产生的离群点的质量影响非常大。
基于分类	如果训练数据中有类标号，则可以将其视为分类问题。该问题的解决思路是训练一个可以区分正常数据和离群点的分类模型。	构造分类器时，训练数据的分布可能极不平衡，相对正常数据，离群点的数目极少，这样会造成在构建分类器时精度收到很大影响。为了解决两类数据的不均衡问题，可以使用一类模型（One-class Model）进行检测。

04

相关技术及应用





数据挖掘常用技术

- 数据挖掘中常用的十三种技术：

统计技术，关联规则，基于历史的分析，遗传算法，聚集检测，连接分析，决策树，神经网络，粗糙集，模糊集，回归分析，差别分析，概念描述等。





机器学习算法地图





数据挖掘技术分类



• 按挖掘方法分类

归纳学习类
仿生计算类
公式发现类
统计分析类
模糊数学类
可视化技术类

• 按数据库类型分

对数据库进行挖掘
文本数据挖掘
多媒体数据挖掘
Web数据挖掘



• 根据挖掘的知识类型分类

概念描述
关联分析
分类
预测
聚类分析
孤立点分析




数据挖掘技术分类



• 按数据库类型分


根据数据模型分类，有关系的、事务的、面向对象的、对象-关系的、或数据仓库的数据挖掘系统。

根据所处理的数据的特定类型分类，有空间的、时间序列的、文本的、或多媒体的数据挖掘系统，或www数据挖掘系统





数据挖掘技术分类





为什么LLM能做数据挖掘?

大语言模型 (LLM) 本质上是一个强大的“模式识别器”，这与数据挖掘的核心目标一致。

LLM的三大核心能力

语义理解

理解文本的深层含义，而非仅匹配关键词
例：“这手机真是太‘好’了”→ 识别为讽刺/负面

上下文推理

根据上下文信息进行逻辑推理
用户搜索记录：“婴儿奶粉哪个牌子好”+ “新生儿睡眠时间”↓ LLM推理：用户可能是新手父母，可以推荐婴儿用品组合

少样本学习

仅需少量示例即可完成新任务

例：给2-3个分类例子→ 自动学会分类规则

核心转变：从“统计模式”到“语义模式”—— LLM理解的是“意义”而非“数字”

LLM做情感分类

传统方法：情感分类

1. 收集标注数据（数千条）
2. 文本预处理（分词、去停用词）
3. 特征提取（TF-IDF / Word2Vec）
4. 训练分类器（SVM / 随机森林）
5. 调参优化
6. 部署预测

需要：大量标注数据 + 特征工程 + 模型调优

对比总结

传统方法优势：

- 准确率高（大数据场景下）
- 推理成本低
- 适合高并发生产环境

LLM方法：零样本/少样本分类

提示词（Prompt）：

请判断以下评论的情感倾向：

评论："这个手机电池太差了，用半天就没电"

选项：A. 正面 B. 负面 C. 中性

LLM输出：B. 负面

需要：设计好的提示词（无需训练数据）

LLM方法优势：

- 无需标注数据，快速部署
- 适合冷启动和原型验证
- 可解释性强

LLM做聚类

传统方法: TF-IDF + K-Means

TF-IDF: 将文本转为数字向量

- TF (词频): 词在文档中出现的次数
- IDF (逆文档频率): 词的稀有程度
- 结果: 每个文本变成一个数字向量

K-Means: 在向量空间中聚类

- 计算向量之间的距离
- 距离近的文本分到同一簇

局限: 只看词汇是否相同, 不理解语义

LLM方法: 语义向量聚类

Embedding: 语义向量表示

- LLM将文本转为语义向量
- 语义相近 → 向量相近

或直接让LLM判断分组:

- 输入一组文本
- LLM理解语义后输出分组结果

优势: 理解语义, "充电""电池""续航"聚在一起

具体例子: 客户反馈聚类

输入: "电池不耐用"、"充电太慢"、"屏幕有划痕"、"续航差"、"显示屏碎了"

TF-IDF + K-Means 结果:

- 簇1: 电池不耐用
- 簇2: 充电太慢
- 簇3: 续航差
- 簇4: 屏幕有划痕
- 簇5: 显示屏碎了

LLM 结果:

电源问题组: 电池不耐用、充电太慢、续航差
屏幕问题组: 屏幕有划痕、显示屏碎了

LLM做关联分析：原理与例子

传统方法：Apriori算法

原理：统计商品共同出现的频率

- 支持度：A和B一起买的比例
- 置信度：买了A的人中买B的比例

经典案例：啤酒→尿布
(支持度5%，置信度60%)

局限：只发现"经常一起买"，不解释"为什么"

LLM方法：语义关联推理

原理：理解商品语义+常识推理

- 理解商品的用途和场景
- 结合常识推理潜在关联
- 可以解释关联的原因

啤酒→尿布的解釋：
"年轻爸爸下班顺路采购"

优势：不仅发现关联，还能解释原因

具体例子：电商推荐

输入：用户购买了「婴儿奶粉」「婴儿湿巾」，请推荐相关商品

Apriori算法结果：

基于历史交易统计：

- 婴儿尿布（支持度8%，置信度72%）
- 奶瓶（支持度6%，置信度65%）
- 婴儿洗衣液（支持度4%，置信度58%）

（只有数字，无解释）

LLM结果：

推荐及理由：

1. 婴儿尿布 - 新生儿必需品，护理三件套
2. 奶瓶消毒器 - 奶粉喂养需定期消毒
3. 婴儿爽身粉 - 配合湿巾护理皮肤

（有推荐理由）

LLM做异常检测

传统方法：统计/规则引擎

常用方法：

- 孤立森林：随机分割，异常点易隔离
- LOF：基于密度，稀疏区域为异常
- 规则引擎：设定阈值触发告警

局限：只看数值分布，不理解业务逻辑

LLM方法：语义异常检测

原理：

- 理解“正常模式”的语义
- 结合常识判断是否合理
- 综合多因素推理

优势：理解业务逻辑，减少误报，可解释

具体例子：信用卡欺诈检测

输入：上海用户，1小时内消费5次（单笔最高10000），共¥60000。历史月均消费¥3000，单笔最高¥1000

规则引擎结果：

异常评分：0.92（阈值0.7）

触发规则：

- 单笔金额超过历史最高10倍 ✓
- 单日消费超过月均20倍 ✓
- 短时间高频消费 ✓

结论：标记为异常，冻结

LLM分析结果：

消费地点：上海某奢侈品商场时间节点：情人节下午

历史记录：去年同期有类似大额消费

无地理矛盾，无异地登录

结论：高概率为节日礼品采购，建议不拦截（置信度88%）✓

什么时候用LLM，什么时候用传统方法？

场景	推荐方法	原因
有大量标注数据	传统方法	准确率更高，成本更低
冷启动/无标注数据	LLM	零样本/少样本学习
需要可解释性	LLM	可以生成解释文本
纯数值型数据	传统方法	统计方法更高效
文本/非结构化数据	LLM	语义理解能力强
实时高并发场景	传统方法	LLM推理成本高
快速原型验证	LLM	无需训练，即时可用
关键结论：LLM与传统方法不是替代关系，而是互补关系		



数据挖掘的应用



- 数据挖掘应用最集中的领域包括**金融、医疗、教育、零售、电商、电信和交通**等，而且每个领域都有特定的应用问题和应用背景。

- 以软件工程数据挖掘为例：

软件工程数据（软件开发过程中积累的各种数据）：
可行性分析和需求分析文档、设计文档、使用说明、软件代码和注释、软件版本及其演化数据、测试用例和测试结果、软件开发者之间的通信、用户反馈等。





数据挖掘的应用




Fig.1 The routemap of software engineering data mining

图 1 软件工程数据挖掘流程



应用领域的案例

- ✓ 电商领域：借助于交易记录挖出破坏规则的“害群之马”
- ✓ 交通领域：为打车平台的乘客订制弹性价格
- ✓ 医疗领域：为乔布斯寻找最佳的医疗方案



数据挖掘的应用



谷歌流感趋势项目

□ 谷歌发现，某些搜索字词可以很好地标示流感疫情的状况。**Google 流感趋势**使用了经过汇总的 **Google 搜索数据库**来**预测流感疫情**。

google.org 流感趋势

[Google.org 主页 \(英语\)](#)

[登录/注册趋势](#)

流感趋势

主页

请选择国家/地区

[Google 流感趋势的工作原理](#)

[常见问题解答](#)

流感疫情

极重
重
中等
轻
极轻

探索全球流感趋势

我们发现，某些搜索字词可以很好地标示流感疫情的状况。Google 流感趋势使用了经过汇总的 Google 搜索数据库来预测流感疫情。[了解详情](#)



下载全球流感趋势数据



新冠疫情预测—兰州大学

□兰州大学《新冠肺炎疫情全球预测系统》：将统计-动力气候预测的先进技术，与经典传染病模型结合，巧妙引入了温度、湿度、管控措施等可量化观测因素，对流行病学模型中的重要参数如传染率、治愈率、死亡率等进行动态估计和修正，这大大提高了预测精度。

□例如，对2021年7月河南省新冠疫情的预测中，系统预测河南省该轮疫情累计感染人数165人，实际感染172人




图1 2022年3月中国内地疫情初步预测结果



数据挖掘的应用



Farecast通过对于机票数据的趋势变化情况，提供**票价预测的服务**，准确度高达**75%**，到**2012**年为止，**Farecast**系统用了将近十亿条价格记录来帮助预测美国国内航班的票价。



利用短信、微博、微信和搜索引擎，可以收集**热点事件**，**挖掘舆情**，还可以追踪造谣信息的源头。





大数据帮助奥巴马成功连任

奥巴马的数据团队对数以千万计的选民邮件进行了**大数据挖掘**，精确预测出了更可能拥护奥巴马的选民类型，并进行了有针对性的宣传，从而帮助奥巴马成为了美国历史上唯一一位在竞选经费处于劣势下实现连任的总统。





里昂市用大数据治堵



里昂市开发了一套决策支持优化器，实时地报告交通的情况，并且来
侦测拥堵的时间。



数据挖掘的应用



零售商

购买过的店铺 我的收藏 天猫积分 我的优惠信息 我的评价 退款维权 我的足迹

最近访问

- 淘金币
- 免费试用
- 品牌街
- 天猫会员
- 聚划算
- 爱淘宝
- 夜淘宝

待付款 待发货 待收货 待评价 退款

根据浏览，猜我喜欢

御泥坊 美丽特惠 狂欢底价 39.9元

¥39.90 ¥79.90

御泥坊玫瑰混养矿物睡眠面膜补...

12.12购物券 减5元 月销: 5094

925纯银梅之耳钉 韩版女时尚水晶防过敏配饰饰品 韩国高档耳饰

¥88.00 ¥88.00

925纯银梅之耳钉 韩版女时尚水晶防过敏配饰饰品 韩国高档耳饰

好评: 96.76% 月销: 13

御泥坊 补水修复首选 特惠仅 59.9元

¥59.90 ¥129.90

御泥坊羊甘菊矿物睡眠面膜 修复...

12.12购物券 减5元 月销: 2247

电子商务



数据挖掘的应用



BOSS直聘 首页 职位 公司 APP 资讯 搜索职位 公司 上传简历 我要找工作 我要招聘 注册 登录

职位已关闭

数据挖掘 25k-50k

北京 · 3-5年 · 本科

[投递简历](#) [收藏职位](#) [不打卡](#) [美女招云](#) [偏干管理](#)

[填写在线简历](#) [上传附件简历](#)

**何先生** 招聘者 · 刚刚在线

[微信扫码分享](#) [感兴趣](#) [举报](#)

职位描述

岗位职责：

- 1、基于海量用户行为数据，使用数据挖掘模型和机器学习算法，挖掘危险驾驶行为、行车威胁行为，结合干预手段，为司机提供保驾护航；
- 2、通过海量数据，挖掘描述用户的安全风险画像，并常应用至分单、教育等各个环节。
- 3、安全场景下订单干预模型、用户干预模型研发以及调优。

岗位要求：

- 1、计算机相关专业重点大学硕士以上学历；扎实的推荐算法/机器学习/数据挖掘理论和技术基础；
- 2、精通数据挖掘与机器学习算法，对算法原理、实现、优化有较深入了解，熟悉以下任一领域：
 - 文本挖掘算法，如文本分类、聚类、语言模型、语义分析、情感分析等NLP相关算法；
 - 图像识别和检测算法，如图像分类、视频检测、OCR、算法等，有深度学习背景的优先；
 - 用户行为模型，熟练掌握行为特征处理、特征选择和建模的方法；
- 3、精通至少一种开发语言，如：Java、C++、Python、R等，能熟练使用SQL进行数据处理；
- 4、优秀的沟通表达能力和组织协调能力，能够快速掌握工作领域的业务和技术；

各大行业职位任你选

手机号

验证码

短信验证码

发送验证码

登录/注册

我已阅读并同意用户协议及隐私政策

公司基本信息

查询

1000-9999人

移动互联网

看过该职位的人还看了

[更多职位](#)

**数据挖掘...**
50k-70k
币世界 · 北京

**数据挖掘...**
20k-35k
汽车之家 · 北京

**数据挖掘**
18k-35k
轻松筹 · 北京

推荐职位

数据挖掘工程师 医渡云	15k-25k	数据挖掘工程师 同程艺龙	20k-40k
数据挖掘工程师 陌陌	20k-40k	数据挖掘 工程师 蓝壳投资	10k-15k
数据挖掘工程师 百度	35k-50k	数据挖掘工程师 小赢科技	26k-40k
优酷-数据挖掘专家 阿里巴巴文娱	30k-50k	数据挖掘专家 阿里巴巴集团	25k-40k
数据/数据挖掘工程师 小米	20k-35k	数据挖掘工程师-数据... 快手	20k-40k



相关工具



	操作		编程			
	Eviews	SPSS	SAS	Stata	Matlab	R
主导优势	时间序列分析	多元横截面数据	数据管理及挖掘	面板数据处理	数值分析, 复杂模型	算法及绘图
应用领域	经济	通信, 政府, 金融, 制造, 医药, 教育等	市场调研, 医药研发, 能源公共事业, 金融管理等	经济	建筑工程	学术研究, 医药研发, IT
处理功能	推断统计	推断及多元统计	批量数据集		统计预测, 优化建模	统计分析, 数据挖掘
界面设计	直观, 可视化	简易, 可视化	语言机械规范化	可视, 代码灵活	偏向底层	语言丰富灵活
数据安全	软件稳定	大数据易丢失	软件稳定	软件稳定	软件稳定	软件稳定
处理效率	高, 稳定	低, 不适宜大数据	高, 稳定	高, 稳定	高, 稳定	极适合大量数据
结合形式	Excel, SAS, SPSS	Excel	Excel, txt,	txt	All	All



相关工具——SAS



SAS 系统全称为Statistics Analysis System，最早由北卡罗来纳大学的两位生物统计学研究生编制，并于1976年成立了SAS软件研究所，正式推出了SAS软件。SAS是用于决策支持的大型集成信息系统，SAS 是由大型机系统发展而来，其核心操作方式就是程序驱动，经过多年的发展，现在已成为一套完整的计算机语言，其用户界面也充分体现了这一特点：它采用MDI（多文档界面），用户在PGM视窗中输入程序，分析结果以文本的形式在OUTPUT视窗中输出。使用程序方式，用户可以完成所有需要做的工作，包括统计分析、预测、建模和模拟抽样等。但是，这使得初学者在使用SAS时必须学习SAS语言，入门比较困难。

目前SAS已在全球100多个国家和地区拥有29000多个客户群，直接用户超过300万人。在我国，国家信息中心，国家统计局，卫生部，中国科学院等都是SAS系统的大用户。SAS已被广泛应用于政府行政管理，科研，教育，生产和金融等不同领域，并且发挥着愈来愈重要的作用。





相关工具——SPSS Clementine



Clementine是ISL(Integral Solutions Limited)公司开发的数据挖掘工具平台。1999年SPSS公司收购了ISL公司, 对Clementine产品进行重新整合和开发, 现在Clementine已经成为SPSS公司的又一亮点。

Clementine的图形化操作界面, 使得分析人员能够可视化数据挖掘过程的每一步。通过与数据流的交互, 分析人员和业务人员可以合作, 将业务知识融入到数据挖掘过程中。这样数据挖掘人员就可以把注意力集中于知识发现, 而不是陷入技术任务, 例如写代码, 所以他们可以尝试更多的分析思路, 更深入地探索数据, 揭示更多的隐含关系。

使用全面整合到Clementine的Text Mining, 您可以从任何类型的文本— 例如内部报告、呼叫中心记录、客户的邮件、媒体或者杂志文章、博客等中抽取内容和评论。使用WebMining for Clementine®, 您可以发现访问者网上行为模式。直接获取Dimension产品的调查数据, 您可以把人口统计信息、态度和行为信息用于模型—更深入地理解您的客户。



相关工具——SPSS Clementine



Clementine还提供大量的应用模板：

CRM CAT--针对客户的获取和增长，提高反馈率并减少客户流失；


Web CAT--点击顺序分析和访问行为分析；

cTelco CAT--客户保持和增加交叉销售；

Crime CAT--犯罪分析及其特征描述，确定事故高发区，联合研究相关犯罪行为；

Fraud CAT--发现金融交易和索赔中的欺诈和异常行为；

Microarray CAT--研究和疾病相关的基因序列并找到治愈手段





相关工具——R




R语言，一种自由软件编程语言与操作环境，主要用于统计分析、绘图、数据挖掘。R本来是由来自新西兰奥克兰大学的Ross Ihaka和Robert Gentleman。R主要是以命令行操作，同时有人开发了几种图形用户界面。开发（也因此称为R），现在由“R开发核心团队”负责开发。

R内置多种统计学及数字分析功能。R的功能也可以通过安装包（Packages，用户撰写的功能）增强。因为S的血缘，R比其他统计学或数学专用的编程语言有更强的面向对象（面向对象程序设计）功能。

R的另一强项是绘图功能，制图具有印刷的素质，也可加入数学符号。

虽然R主要用于统计分析或者开发统计相关的软件，但也有人用作矩阵计算。其分析速度可媲美专用于矩阵计算的自由软件GNU Octave和商业软件MATLAB。





相关工具——Stata



Stata是Statacorp于1985年开发出来的统计程序，在全球范围内被广泛应用于企业和学术机构中。许多使用者工作在研究领域，特别是在经济学、社会学、政治学及流行病学领域。

作为一个小型的统计软件，其统计分析能力远远超过了SPSS，在许多方面也超过了SAS！由于Stata在分析时是将数据全部读入内存，在计算全部完成后才和磁盘交换数据，因此计算速度极快（一般来说，SAS的运算速度要比SPSS至少快一个数量级，而Stata的某些模块和执行同样功能的SAS模块比，其速度又比SAS快将近一个数量级！）Stata也是采用命令行方式来操作，但使用上远比SAS简单。其生存数据分析、纵向数据（重复测量数据）分析等模块的功能甚至超过了SAS。用Stata绘制的统计图形相当精美，很有特色。在长远趋势上，Stata有超越SAS的可能（据消息灵通人士透露：在SAS的老家——北卡，真正搞生物统计的人青睐的反而是Stata！）

Stata最大的缺点应该是数据接口太简单，实际上只能读入文本格式的数据文件；其数据管理界面也过于单调





相关工具——MATLAB



MATLAB（矩阵实验室）是MATrix LABoratory的缩写，是一款由美国The MathWorks公司出品的商业数学软件。MATLAB是一种用于算法开发、数据可视化、数据分析以及数值计算的高级技术计算语言和交互式环境。除了矩阵运算、绘制函数/数据图像等常用功能外，MATLAB还可以用来创建用户界面及与调用其它语言（包括C，C++和FORTRAN）编写的程序。

MATLAB和Mathematica、Maple并称为三大数学软件。它在数学类科技应用软件中在数值计算方面首屈一指。MATLAB可以进行矩阵运算、绘制函数和数据、实现算法、创建用户界面、连接其他编程语言的程序等，主要应用于工程计算、控制设计、信号处理与通讯、图像处理、信号检测、金融建模设计与分析等领域。




相关工具——MATLAB



软件特点:

- 1) 高效的数值计算及符号计算功能,能使用户从繁杂的数学运算分析中解脱出来;
- 2) 具有完备的图形处理功能,实现计算结果和编程的可视化;
- 3) 友好的用户界面及接近数学表达式的自然化语言,使学者易于学习和掌握;
- 4) 功能丰富的应用工具箱(如信号处理工具箱、通信工具箱等),为用户提供了大量方便实用的处理工具





Eviews

是美国GMS公司1981年发行第1版的Micro TSP的Windows版本，通常称为计量经济学软件包。

EViews是Econometrics Views的缩写，它的本意是对社会经济关系与经济活动的数量规律，采用计量经济学方法与技术进行“观察”。计量经济学的核心是设计模型、收集资料、估计模型、检验模型、运用模型进行预测、求解模型和运用模型。正是由于EViews等计量经济学软件包的出现，使计量经济学取得了长足的进步，发展成为实用与严谨的经济学科。使用 EViews软件包可以对时间序列和非时间序列的数据进行分析，建立序列（变量）间的统计关系式，并用该关系式进行预测、模拟等等。



相关工具——其他



Minitab


同样是国际上流行的一个统计软件包，其特点是简单易懂，在国外大学统计学系开设的统计软件课程中，Minitab与SAS、BMDP并列，根本没有SPSS的份，甚至有的学术研究机构专门教授Minitab之概念及其使用。MiniTab for Windows统计软件比SAS、SPSS等小得多，但其功能并不弱，特别是它的试验设计及质量控制等功能。MiniTab提供了对存储在二维工作表中的数据进行分析的多种功能，包括：基本统计分析、回归分析、方差分析、多元分析、非参数分析、时间序列分析、试验设计、质量控制、模拟、绘制高质量三维图形等，从功能来看，Minitab除各种统计模型外，还具有许多统计软件不具备的功能 - - 矩阵运算。

WEKA

WEKA的全名是怀卡托智能分析环境（Waikato Environment for Knowledge Analysis），同时weka也是新西兰的一种鸟名，而WEKA的主要开发者来自新西兰。WEKA作为一个公开的数据挖掘工作平台，集合了大量能承担数据挖掘任务的机器学习算法，包括对数据进行预处理，分类，回归、聚类、关联规则以及在新的交互式界面上的可视化。



数据挖掘的工具及软件



数据挖掘工具新生态

传统工具（SAS、SPSS、R、MATLAB）之外，新一代AI驱动的数据挖掘工具正在崛起。

LLM平台	Agent框架	AutoML平台
• ChatGPT • Claude • Gemini • DeepSeek-R1	• LangChain • AutoGen • CrewAI • LlamaIndex	• FLAML • H2O AutoML • DataRobot • Google AutoML

里程碑：DeepSeek-R1（2025年1月）

中国团队发布的开源推理模型，671B参数，性能媲美OpenAI o1，训练成本仅\$5.6M（o1约\$100M+）。
开源地址：github.com/deepseek-ai/DeepSeek-R1
意义：为数据挖掘研究提供了低成本、可本地部署的强大工具。

05

数据挖掘相关问题





数据挖掘主要问题



有效性和可伸缩性

- ✓ 数据挖掘算法的有效性和可伸缩性
 - ✓ 并行、分布式和增量挖掘算法
- ## 数据库类型的多样性
- ✓ 处理复杂的数据类型
 - ✓ 挖掘动态的、网络的、全球的数据库

数据挖掘与社会

- ✓ 数据挖掘的社会影响
- ✓ 保护隐私的数据挖掘
- ✓ 无形的数据挖掘





数据挖掘主要问题



} 挖掘方法

- ✓ 挖掘各种新的知识类型
- ✓ 挖掘多维空间中的知识
- ✓ 数据挖掘——跨学科的努力
- ✓ 提升网络环境下的发现能力
- ✓ 处理不确定性、噪声或不完全数据
- ✓ 模式评估和模式或约束指导的挖掘

} 用户界面

- ✓ 交互挖掘
- ✓ 结合背景知识
- ✓ 特定的数据挖掘和数据挖掘查询语言
- ✓ 数据挖掘结果的表示和可视化





数据挖掘隐私权问题



- **个人数据隐私权**：个人对以数据形式收集和存储在信息系统中的有关自己的资料加以控制和保护的权力。
- 数据挖掘是**建立在大量真实数据分析**的基础之上的，这就会产生个人数据的隐私保护问题。
- 从数据挖掘的角度来看，**隐私既可能带来成功，亦可能带来威胁**。滥用隐私不仅破坏企业在客户心目中的良好形象，也会将数据挖掘推入灰暗的前景中，阻碍数据挖掘这一新兴技术的采纳、应用和推广。



典型案例（1）


- 2018年3月18日曝光的Facebook裙带公司剑桥分析公司（Cambridge Analytica）数据隐私丑闻事件。
- 剑桥分析公司是美国一家政治数据分析公司，被曝光在未经用户同意的情况下，**利用在 Facebook 上获得的5000万用户的个人隐私数据**，来创建档案，并在2016美国总统大选期间针对这些人进行定向宣传，有助推**特朗普**获胜的嫌疑。
- 该丑闻凸显了Facebook的“DNA”中存在的问题：数据挖掘。

谷歌、微软、微博、微信和百度？



典型案例（2）

- 2019年中央广播电视总台3·15晚会曝光众多App，**通过不平等、不合理条款强制索取用户隐私权、过度用权。**



- 例如社保掌上通App，用户在填写各种资料注册该App后，电脑远程就能截取到用户的几乎所有信息。



数据挖掘者可能从以下几个方面侵犯公民的个人数据隐私权：

- (1) 过度采集个人数据
- (2) 挖掘者超常使用个人数据
- (3) 挖掘者不当或错误分析个人数据
- (4) 挖掘者非法公开个人数据



保护隐私权的对策

- (1) 加强法律法规的建设和监督执行
- (2) 提高保护隐私的技术手段
- (3) 提高用户的隐私数据自我保护意识

数据挖掘隐私权的问题是数据挖掘中一个非常重要的问题，它的解决程度直接决定了数据挖掘的未来。



数据挖掘推荐期刊和会议



顶级会议

- **KDD** (Knowledge Discovery and Data Mining) - ACM SIGKDD会议, 是数据挖掘领域最著名的顶级会议之一。
- **ICDM** (International Conference on Data Mining) - IEEE主办的国际数据挖掘会议, 也是该领域的顶级会议。
- **SDM** (SIAM International Conference on Data Mining) - 由美国工业和应用数学学会 (SIAM) 主办的数据挖掘国际会议。
- **WSDM** (Web Search and Data Mining) - 关注网络搜索和数据挖掘的国际会议。
- **CIKM** (Conference on Information and Knowledge Management) - ACM主办, 围绕信息检索、知识管理和数据挖掘的国际会议。



顶级期刊

- **TKDE** (IEEE Transactions on Knowledge and Data Engineering) - IEEE出版的关于知识和数据工程的期刊。
- TIST (ACM Transactions on Intelligent Systems and Technology) - ACM出版的智能系统和技术领域的期刊。
- KDD (Knowledge Discovery and Data Mining) - ACM SIGKDD出版的数据挖掘专业期刊。
- DMKD (Data Mining and Knowledge Discovery) - 主要发表数据挖掘领域的原创文章。
- JMLR (Journal of Machine Learning Research) - 发表机器学习领域的原创研究，包括数据挖掘方面的研究。
- VLDBJ (The VLDB Journal) - 由Very Large Data Bases Endowment Inc. (VLDB Endowment)出版的数据库技术领域的期刊，也涵盖了数据挖掘的相关研究。



数据挖掘常用数据集



常用的基本上**UCI**和**w3c**，UCI收集的机器学习数据集

<ftp://pami.sjtu.edu.cn>

<http://www.ics.uci.edu/~mlearn/\\MLRepository.htm>

statlib

<http://liama.ia.ac.cn/SCILAB/scilabindexgb.htm>

<http://lib.stat.cmu.edu/>

● 样本数据库

<http://kdd.ics.uci.edu/>

<http://www.ics.uci.edu/~mlearn/MLRepository.html>

● 关于基金的数据挖掘的网站

<http://www.gotofund.com/index.asp>

<http://lans.ece.utexas.edu/~strehl/>

● reuters数据集

<http://www.research.att.com/~lewis/reuters21578.html>

● 各种数据集:

<http://kdd.ics.uci.edu/summary.data.type.html>

<http://www.mlnet.org/cgi-bin/mlnetois.pl/?File=datasets.html>

<http://lib.stat.cmu.edu/datasets/>

<http://dctc.sjtu.edu.cn/adaptive/datasets/>

<http://fimi.cs.helsinki.fi/data/>



数据挖掘最新进展：时空数据挖掘





时空数据挖掘的基本概念



- 时空数据挖掘是数据挖掘的一个子领域，专注于从涉及时间和空间维度的数据中提取有价值的信息。
- 时空数据包括但不限于气象数据、交通数据、地理信息系统（GIS）数据、遥感数据等。
- 时空维度意味着数据在空间和时间上都有分布，这使得挖掘过程比传统数据挖掘更加复杂。
- 时空模式是指在特定时间和空间中重复出现的特定行为或事件。
- 时空预测则是基于历史数据，预测未来时间和空间中的情况。
- 异常检测用于识别与正常模式显著不同的异常事件。
- 轨迹分析主要针对移动对象的路径数据，分析其运动规律。
- 时空数据挖掘的目标是通过对大量复杂数据的分析和处理，发现有用的模式和知识，从而为决策提供支持。例如，在城市规划中，通过分析交通流量数据，可以发现高峰期的交通瓶颈，进而优化交通管理和基础设施建设。在环境监测中，通过分析气象数据和污染物数据，可以发现污染源和污染扩散规律，帮助制定有效的环保政策。



时空数据挖掘的技术和方法



- **时空数据库管理**是时空数据挖掘的基础，涉及如何高效存储和检索大规模时空数据。常见的时空数据库包括Oracle Spatial、PostGIS等。
- **数据预处理**是挖掘过程中的关键步骤，包括数据清洗、数据集成、数据变换和数据归约。
- **模式挖掘**技术用于发现时空数据中的潜在模式，如频繁模式、时空关联规则等。
- **预测模型**则用于基于历史数据进行未来预测，常用的方法包括时空回归分析、时间序列分析、机器学习算法等。
- **异常检测算法**用于识别与正常模式显著不同的异常事件，如基于统计的方法、基于机器学习的方法等。
- **轨迹分析技术**主要针对移动对象的路径数据，常用的方法包括轨迹相似性分析、轨迹聚类、轨迹模式挖掘等。

例如，在**交通流量预测**中，首先需要通过时空数据库管理系统存储和检索交通数据，然后进行数据预处理，清洗和整合数据。接着，通过模式挖掘技术发现交通流量的时空模式，利用预测模型进行未来交通流量的预测，最后通过异常检测算法识别交通异常事件，如交通拥堵或事故。



时空数据挖掘的应用领域



- **城市规划**中，通过分析人口、交通、土地使用等时空数据，可以优化城市布局和基础设施建设。
- **环境监测**中，通过分析气象数据、污染物数据，可以发现污染源和污染扩散规律，帮助制定环保政策。
- **公共安全**中，通过分析犯罪数据、监控视频数据，可以发现犯罪热点区域，制定有效的治安措施。
- **交通管理**中，通过分析交通流量数据、交通事故数据，可以优化交通管理和应急预案。
- **商业分析**中，通过分析销售数据、客户行为数据，可以发现市场趋势和消费模式，制定营销策略。
- **医疗健康**中，通过分析患者数据、疾病传播数据，可以发现疾病传播规律，制定防控措施。
- **农业生产**中，通过分析气象数据、土壤数据、作物生长数据，可以优化种植方案，提高农业产量。



时空数据挖掘的挑战



挑战，主要包括数据的多样性和复杂性、数据的高维性和大规模性、模型的可解释性和计算效率。

- **数据的多样性和复杂性**是指时空数据来源广泛，数据格式多样，数据质量参差不齐，处理难度大。
- **数据的高维性和大规模性**是指时空数据通常具有高维属性和大规模特点，处理和存储难度大。
- **模型的可解释性和计算效率**是指时空数据挖掘模型需要具有良好的可解释性和高效的计算性能，以便在实际应用中得到广泛应用。

未来，随着物联网、云计算、大数据等技术的发展，时空数据挖掘将迎来更多的发展机遇和挑战。物联网技术的发展将带来海量的时空数据，**如何高效存储和处理**这些数据是一个重要课题。云计算技术的发展将提供强大的计算能力和存储资源，支持大规模时空数据的挖掘。大数据技术的发展将提供更加高效的数据处理和分析方法，提升时空数据挖掘的效率和效果。



时空数据挖掘的发展趋势



- **智能化**是指随着人工智能技术的发展，时空数据挖掘将越来越多地采用智能算法，如深度学习、强化学习等，提高挖掘效果和效率。
- **实时化**是指随着物联网和边缘计算技术的发展，时空数据挖掘将越来越多地采用实时数据处理和分析技术，实现实时监测和决策。
- **可视化**是指随着可视化技术的发展，时空数据挖掘将越来越多地采用高级可视化技术，如3D可视化、虚拟现实等，提高结果展示效果和用户体验。
- **集成化**是指随着大数据技术的发展，时空数据挖掘将越来越多地与其他数据挖掘和分析技术集成，如文本挖掘、图像挖掘、社交网络分析等，实现多源数据的综合分析。

例如，在智慧城市建设中，通过集成交通数据、环境数据、能源数据等多源数据，采用智能化和实时化的时空数据挖掘技术，可以实现城市的智能化管理和优化。在精准农业中，通过集成气象数据、土壤数据、作物生长数据等多源数据，采用智能化和可视化的时空数据挖掘技术，可以实现农业的精准管理和优化。



时空数据挖掘的未来研究方向



- **大规模时空数据处理**是指研究如何高效存储和处理海量时空数据，提高数据处理和挖掘的效率。
- **复杂时空模式挖掘**是指研究如何从复杂的时空数据中挖掘出更有价值的模式和知识，提高模式挖掘的效果。
- **高效预测模型构建**是指研究如何构建更加高效和准确的时空预测模型，提高预测的准确性和效率。
- **智能异常检测**是指研究如何采用智能算法，如深度学习、强化学习等，提高异常检测的效果和效率。
- **动态轨迹分析**是指研究如何分析和挖掘动态变化的轨迹数据，如移动对象的路径数据，提高轨迹分析的效果。

例如，在大规模时空数据处理方面，可以研究如何利用分布式计算和存储技术，如Hadoop、Spark等，提高大规模时空数据的处理效率。在复杂时空模式挖掘方面，可以研究如何采用深度学习等智能算法，提高复杂时空模式的挖掘效果。在高效预测模型构建方面，可以研究如何结合传统预测方法和机器学习算法，提高时空预测的准确性和效率。在智能异常检测方面，可以研究如何利用深度学习、强化学习等智能算法，提高异常检测的效果和效率。在动态轨迹分析方面，可以研究如何采用时空数据库和智能算法，提高动态轨迹数据的分析和挖掘效果。



时空数据挖掘



时间序列领域涌现了很多的基础模型：**统计量基础模型**（时空序列的预测，插补，异常检测等）和**轨迹基础模型**

统计量基础模型代表性工作：

最早的时空基础模型——UrbanGPT

[KDD]UrbanGPT: Spatio-Temporal Large Language Models (ADS Track)

本文提出了UrbanGPT，一种结合**时空依赖编码器**和指令微调范式的**时空大语言模型**，旨在解决数据稀缺情况下的时空预测问题。





Figure 2: The overall architecture of the proposed spatio-temporal language model UrbanGPT.



纯时空模型——UniST

[KDD]UniST: A Prompt-Empowered Universal Model for Urban Spatio-Temporal Prediction


本文提出了UniST，一个基于提示的通用模型，通过灵活处理多样化时空数据、有效的生成预训练和时空知识引导的提示，实现了在多个城市和领域中的卓越泛化能力和城市时空预测性能。





基于diffusion transformer的城市基础模型UrbanDiT

引入了开放世界城市时空学习的基础模型UrbanDiT，它集成了多种数据类型并解决多项任务(预测，插补，外推 (extrapolation) 等)。






时空数据挖掘-轨迹基础模型



第一个轨迹基础模型——TrajCogn

[arXiv] TrajCogn: Leveraging LLMs for Cognizing Movement Patterns and Travel Purposes from Trajectories

结合PLM（预训练语言模型）的优势提取轨迹的特征，提出了一种新颖的轨迹表示学习方法TrajCogn，在多个轨迹下游任务上均取得SOTA结果（行程时间估计，目的地预测，轨迹相似度搜索）






时空数据挖掘-轨迹基础模型



世界轨迹基础大模型——UniTraj

[arXiv] UniTraj: Learning a Universal Trajectory Foundation Model from Billion-Scale Worldwide Traces

整理了首个全球大规模轨迹数据集 **WorldTrace**，基于该数据集训练了世界轨迹基础大模型**UniTraj**。
(轨迹恢复，预测，分类和生成任务)





时空数据挖掘-轨迹基础模型

统一轨迹数据和交通状态数据的基础模型——BIGCity [arXiv]BIGCity: A Universal Spatiotemporal Model for Unified Trajectory and Traffic State Data Analysis

提出了**BIGCity**模型，通过统一的时空数据表示和多任务学习框架，能够处理和分析包括轨迹数据和交通状态数据在内的多样化异构任务。




Fig. 2: The model architecture of BIGCity.



时空数据挖掘



时空数据通常具有动态性，随着时间和空间的变化，数据分布会发生偏移。传统的静态模型难以适应这些变化，无法有效捕捉到时空分布的动态特性。因此，持续学习通过不断学习新的知识和适应数据的变化，能够确保模型在面对时空变化时仍然保持高效和准确的预测能力。

[ICDE]A Unified Replay-based Continuous Learning Framework for Spatio-Temporal Prediction on Streaming Data

为了应对时空数据流预测中的灾难性遗忘问题，提出了一个统一的基于回放的持续学习框架URCL。该框架通过时空混合机制融合历史样本与新数据，避免遗忘。同时，集成了时空自编码器和时空简单Siamese (STSimSiam) 网络，通过互信息最大化确保预测准确性，结合五种数据增强方法提升性能。




Fig. 1. URCL Framework Overview



(Oral) [NeurIPS] Get Rid of Task Isolation: A Continuous Multi-task Spatio-Temporal Learning Framework

CMuST是一种持续多任务时空学习框架，旨在提升城市智能，解决城市数据动态、多源和不平衡的问题。它提出了新颖的多维时空交互网络（MSTI），用于改进任务泛化和适应性，同时引入滚动适应训练方案（RoAda）实现持续的任务学习。




Figure 2: Framework overview of CMuST.



时空数据挖掘2026综述



Fang Y, Miao H, Liang Y, et al. Unraveling spatio-temporal foundation models via the pipeline lens: A comprehensive review[J]. IEEE Transactions on Knowledge and Data Engineering, 2026. (TKDE 2026)

时空数据在交通、天气、能源等众多现实世界领域中广泛存在。时空深度学习模型旨在利用此类数据中的有用模式来支持预测、插补和异常检测等任务。然而，以往针对特定任务设计的一对一深度学习模型通常需要针对每个用例进行单独训练，从而导致计算和存储成本增加。

为了解决这个问题，一对多的时空基础模型应运而生，提供了一个能够解决多个时空任务的统一框架。此外，综述提供了一个清晰且结构化的流程，帮助理解时空基础模型核心要素之间的联系，并指导研究人员快速入门。




Fig. 1. The paradigm of spatio-temporal foundation models (STFMs).




Fig. 2. The pipeline of STFMs.



谢谢!

THANK YOU FOR WATCHING!

