



华南理工大学
South China University of Technology

《人工智能理论及应用》

大语言模型


授课老师：青春美

联系邮箱：qchm@scut.edu.cn

2026年5月



大模型自学开源教材推荐



<https://intro-llm.github.io/chapter/LLM-TAP.pdf>



<https://nlp-book.swufenlp.group/>

目 录



01 语言的基本特点

02 语言模型的建模

03 大模型发展概述

04 大模型基本应用

05 大模型常见工具

06 大模型未来思考



华南理工大学
South China University of Technology



华南理工大学
South China University of Technology

01

语言的基本特点





语言是人类与其他动物最重要的区别



语言是人类与其他动物最重要的区别

- 逻辑思维以语言的形式表达
- 知识以文字的形式记录和传播



如果人工智能想要获取知识，就必须懂得理解人类使用的**不太精确、可能有歧义、混乱**的语言。



符号 (Sign) 是社会约定的代表某事物的标志，是形式和意义的统一体。

征候 (征象 Symptom) 是事物本身的特征，它传递的某种信息，可以通过其自身的物质属性来推断。

语言符号 是语音和语义的结合体。形式（语音）叫能指，内容（语义）叫所指。能指和所指不是必然的，而是约定俗成的。



人类语言具备以下六个属性

- **移位性 (displacement)**：指人类在当下用语言谈论过去和未来的事件，不仅时间可以移位，地点和人物等也可以移位，甚至**可以讨论世间不存在的事物**，如“天使”“鬼”“妖怪”等。
- **任意性 (arbitrariness)**：体现在其形式与意义的关系上。除极少数拟声词 (crash, cuckoo等) 外，**绝大多数语言表达都是任意的**。
- **能产性 (productivity)**：指新言语可以持续不断、无限地产出，**语言使用者可以操控语言资源再生新的表达式和句子**。



人类语言具备以下六个属性

- **文化传递性 (cultural transmission)**：语言的文化传递性是人类语言习得过程中最重要的地方。动物间的交流信号是本能的、非习得的，而**人类的语言能力不是基因遗传的，好比一对韩国夫妇的孩子在美国长大，其第一语言是英语。**
- **离散性 (discreteness)**：如果我们听一门自己不懂的外语时，往往会觉得说话者表达得很流利，但**实际上没有一种语言是连续不断的**，为了表达离散的意义就必须有离散的单位。
- **二层性 (duality)**：指**语言是由声音与意义同时构成**。我们通过不同的声音单一或组合产出不同意义的表达式。



语言是有方向的→语言建模方式



大语言模型理解语言需要带有方向地理解，其不仅仅是词语的组合，更是带有方向的组合

我爱你 $\neq$ 你爱我

$P(\text{把 努力 变成 一种 习惯}) = P(\text{把}) \times P(\text{努力}|\text{把}) \times P(\text{变成}|\text{把 努力}) \times$
 $P(\text{一种}|\text{把 努力 变成}) \times P(\text{习惯}|\text{把 努力 变成 一种})$

$$P(w_1 w_2 \dots w_m) = P(w_1) P(w_2 | w_1) P(w_3 | w_1 w_2) \dots P(w_m | w_1 w_2 \dots w_{m-1})$$
$$= \prod_{i=1}^m P(w_i | w_1 w_2 \dots w_{i-1})$$

语言模型的
基本建模公式



语言是有方向的→语言建模方式



问：什么情况下，理解一句话，从左到右，以及从右到左，理解的意思都是一样的？请举例说明。

上海自来水来自海上

雾锁山头山锁雾

天连水尾水连天

油灯少灯油

华工做工华

火柴当柴火



华南理工大学
South China University of Technology

02

语言模型的建模





语言模型目标就是建模自然语言的概率分布



语言模型 (Language Model, LM) 目标是建模自然语言的概率分布

词汇表 V 上的语言模型由函数 $P(w_1w_2...w_m)$ 表示, 表示词序列 $w_1w_2...w_m$ 作为一个句子出现的可能性大小。对于任意词串 $w_1w_2...w_m \in V^+$, 则有 $P(w_1w_2...w_m) \geq 0$, 并且对于所有词串, 函数 $P(w_1w_2...w_m)$ 满足归一化条件:

$$\sum_{w_1w_2...w_m \in V^+} P(w_1w_2...w_m) = 1$$

由于联合概率 $P(w_1w_2...w_m)$ 的参数量十分巨大, 直接计算 $P(w_1w_2...w_m)$ 非常困难。如果把 $w_1w_2...w_m$ 看作一个变量, 那么它具有 $|V|^m$ 种可能。

按照《现代汉语词典 (第七版) 》包含7万词条, 句子长度按照20个词计算, 模型参数量达到 **7.9792×10^6** 的天文数字。



语言模型目标就是建模自然语言的概率分布



为了减少 $P(w_1w_2...w_m)$ 模型参数量，可以利用句子序列**通常情况下从左至右的生成过程**进行分解，使用**链式法则**得到：

$$\begin{aligned} P(w_1w_2...w_m) &= P(w_1)P(w_2|w_1)P(w_3|w_1w_2)\cdots P(w_m|w_1w_2...w_{m-1}) \\ &= \prod_{i=1}^m P(w_i|w_1w_2\cdots w_{i-1}) \end{aligned}$$

由此， $w_1w_2...w_m$ 的生成过程可以看作单词逐个生成的过程。首先生成 w_1 ，之后根据 w_1 生成 w_2 ，再根据 w_1 和 w_2 生成 w_3 ，以此类推，根据前 $m - 1$ 个单词生成最后一个单词 w_m

$$\begin{aligned} P(\text{把努力变成一种习惯}) &= P(\text{把}) \times P(\text{努力}|\text{把}) \times P(\text{变成}|\text{把努力}) \times \\ &\quad P(\text{一种}|\text{把努力变成}) \times P(\text{习惯}|\text{把努力变成一种}) \end{aligned}$$



n元语言模型



语言模型通常用于反映一个句子出现的可能性，给定由单词序列 $w_1w_2...w_n$ 组成的句子 S ，可以利用语言的特性，使用链式法分解则得到：

$$P(S) = \prod_{i=1}^n P(w_i | w_1w_2...w_{i-1})$$

其中，词 w_i 出现的概率受它前面的 $i - 1$ 个词 $w_1w_2...w_{i-1}$ 影响，我们将这 $i - 1$ 个词 $w_1w_2...w_{i-1}$ 称之为词 w_i 的**历史**。如果历史单词有 $i - 1$ 个，那么可能的单词组合就有 $|V|^{i-1}$ 种。最简单的根据语料库对 $P(w_i | w_1w_2...w_{i-1})$ 进行估计的方法是基于词序列在语料中出现次数（也称为频次）的方法：

$$P(w_i | w_1w_2...w_{i-1}) = \frac{C(w_1w_2...w_{i-1}w_i)}{C(w_1w_2...w_{i-1})}$$



n元语言模型



随着历史单词数量增多，绝大多数的历史并不会在训练数据中出现，这也意味着 $P(w_i|w_1w_2...w_{i-1})$ 就很可能为 0，使得概率估计失去了意义。为了解决上述问题，可以进一步**假设任意单词 w_i 出现的概率只与过去 $n - 1$ 个词相关**

$$P(w_i|w_1w_2...w_{i-1}) = P(w_i|w_{i-(n-1)}w_{i-(n-2)}...w_{i-1})$$

$$P(w_i|w_1^{i-1}) = P(w_i|w_{i-n+1}^{i-1})$$

满足上述条件的模型被称为**n元语法或n元文法(n-gram)**模型。其中 n-gram 表示 n 个连续单词构成的单元，也被称为**n元语法单元**。

以二元语法为例，一个词的概率只依赖于前一个词，则句子 S 的出现概率可以表示为：

$$P(S) = \prod_{i=1}^n P(w_i|w_{i-1})$$



n元语言模型的缺点



n元语言模型从整体上来看与训练语料规模和模型的阶数有较大的关系，不同的平滑算法在不同情况下的表现有较大的差距。

平滑算法虽然较好解决了零概率问题，但是基于稀疏表示的n元语言模型仍然有**三个较为明显的缺点**：

- (1) 无法建模长度超过n的上下文；
- (2) 依赖人工设计规则的平滑技术；
- (3) 当n增大时，数据的稀疏性随之增大，模型的参数量更是指数级增加，并且模型受到数据稀疏问题的影响，其参数难以被准确学习。

此外，n元语法中单词的**离散表示也忽略了单词之间的相似性**



神经语言模型



Bengio等人在2000年提出了使用前馈神经网络对 $P(w_i|w_{i-n+1}^{i-1})$ 进行估计的语言模型。

词的独热编码被映射为一个低维稠密的实数向量，称为**词向量 (Word Embedding)**。

循环神经网络、卷积神经网络、端到端记忆网络等神经网络方法都成功应用于语言模型建模。

相较于n元语言模型，神经网络方法可以在一定程度上避免数据稀疏问题，有些模型还可以避免对历史长度的限制，从而更好建模长距离依赖关系。这类方法通常称为**神经语言模型 (Neural Language Models, NLM)**。



神经语言模型——词向量



独热表示是一种将词汇映射为向量的策略。

“牛奶” $\rightarrow [0, 0, 0, 1, 0, 0, 0, 0, 0, 0]$

“奶油” $\rightarrow [0, 0, 0, 0, 0, 0, 0, 0, 1, 0]$

独热表示缺陷：表示向量存在维数灾难，并且独热表示无法度量不同词之间的语义相关性。

针对独热表示中存在的问题，后续研究通过引入深度学习技术，采用分布式表示的形式表示词语。

“猫” : $[0.2, 0.8, -0.3]$

“狗” : $[0.1, 0.9, -0.5]$


“鸟” : $[-0.6, 0.3, -0.1]$

“汽车” : $[0.7, -0.2, 0.1]$

“飞机” : $[0.8, -0.3, 0.2]$

独热向量为每个词汇提供了一个唯一的向量表示，**其中仅有一个元素为1**，而其位置对应于该词汇在词汇表中的索引，其余元素均为0。

索引	0	1	2	3	4	5	6	7	8	9
词汇	苹果	香蕉	橙子	牛奶	咖啡	茶	糖	面包	奶油	水





神经语言模型——神经网络



NNLM（词的向量化表示、用神经网络来解决语言模型的问题），2003

映射层：将n个单词映射为对应word embeddings的拼接

$$x = (C(w_{t-1}), C(w_{t-2}), \dots, C(w_{t-n+1})).$$


隐藏层：直接用 $d+Hx$ 计算得到， d 是一个偏置项，然后激活函数用 $\tanh$

$$y = b + Wx + U \tanh(d + Hx)$$

此后的语言模型基本上改进的项目是这一部分，从MLP到RNN、CNN、Self-Attention等

输出层：因为是语言模型，需要根据前n个单词预测下一个单词，所以是一个多分类器，用softmax。整个模型最大的计算量集中在最后一层上，因为一般来说词汇表都很大，需要计算每个单词的条件概率，是整个模型的计算瓶颈。

$$\hat{P}(w_t | w_{t-1}, \dots, w_{t-n+1}) = \frac{e^{y_{w_t}}}{\sum_i e^{y_i}}$$



我们在很多NLP论文都能见到上面公式=的左边部分，但是在神经网络里面进行这个概率计算的时候，基本都是通过右边的方式来实现

Bengio Y, Ducharme R, Vincent P. A neural probabilistic language model[J]. Advances in neural information processing systems, 2000, 13. https://pytorch.org/tutorials/beginner/nlp/word_embeddings_tutorial.html?highlight=neural%20probabilistic%20language%20model



神经语言模型——循环神经网络




RNNLM (将RNN用于语言模型建模)，2010


提出了一种新的基于递归神经网络的语言模型(RNNLM)及其在语音识别中的应用。

背景: NNLM是一类典型的前馈神经网络,它的历史长度预先必须设置并固定,与循环神经网络(RNNLM)来比不能捕获更长的历史信息。RNNLM与NNLM主要的不同就在对历史的捕捉上面,NNLM的历史长度也只有数个词,而RNNLM的历史是前面所有的词,这样使得RNNLM可以捕获更长的历史信息。

$$S_t = f(U \cdot X_t + W \cdot S_{t-1}) \quad O_t = g(V \cdot S_t)$$



RNN结构



RNNLM


Mikolov T, Karafiát M, Burget L, et al. Recurrent neural network based language model[C]//Interspeech. 2010, 2(3): 1045-1048.



神经语言模型——Seq2Seq模型



前置技术: Seq2Seq, 2014



典型特征:
输入和输出
序列长度不
等, 且不
一定一一对应

Figure 1: Our model reads an input sentence “ABC” and produces “WXYZ” as the output sentence. The model stops making predictions after outputting the end-of-sentence token. Note that the LSTM reads the input sentence in reverse, because doing so introduces many short term dependencies in the data that make the optimization problem much easier.

把语言任务建模成**序列到序列**的生成式任务, 也叫做**端到端的自然语言生成框架**

$$p(y_1, \dots, y_{T'} | x_1, \dots, x_T) = \prod_{t=1}^{T'} p(y_t | v, y_1, \dots, y_{t-1})$$

实际实现过程就是**进行T'次模型的前向计算, 以及输出层的softmax计算**

Sutskever I, Vinyals O, Le Q V. Sequence to sequence learning with neural networks[J]. Advances in neural information processing systems, 2014, 27. https://pytorch.org/tutorials/intermediate/seq2seq_translation_tutorial.html

I love you </s>

文本翻译模型

<s> 我 爱 你 </s>

<s> I love you




神经语言模型——Seq2Seq模型



模型的工作流程如下所示



Seq2Seq模型由一个Encoder和一个Decoder组成
Encoder可以处理输入序列，捕捉输入序列的上下文信息
Decoder可以处理Encoder输出的上下文信息，进行生成任务





Transformer 结构



Transformer 结构是由谷歌在2017 年提出并首先应用于机器翻译
Transformer结构完全通过注意力机制完成对源语言序列和目标语言序列全局依赖的建模。如今，几乎全部大语言模型都是基于Transformer 结构的。
本节以应用于机器翻译的基于Transformer 的编码器和解码器为例介绍该模型。

Attention Is All You Need

Ashish Vaswani*
Google Brain
avaswani@google.com

Noam Shazeer*
Google Brain
noam@google.com

Niki Parmar*
Google Research
nikip@google.com

Jakob Uszkoreit*
Google Research
usz@google.com

Llion Jones*
Google Research
llion@google.com

Aidan N. Gomez* †
University of Toronto
aidan@cs.toronto.edu

Lukasz Kaiser*
Google Brain
lukaszkaizer@google.com

Illia Polosukhin* ‡
illia.polosukhin@gmail.com



Transformer 结构



自注意力 (Self-Attention) 操作是基于 Transformer 的语言模型的基本操作，在源语言的编码和目标语言的生成中频繁地被使用以建模源语言、目标语言任意两个单词之间的依赖关系。

$$Z = \text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V$$






图 2.2 自注意力机制中的查询、键、值向量



Transformer 结构——输入表示






Transformer 结构——自注意力



自注意力计算:


- 矩阵点乘
- 除以常数
- 掩码
- softmax函数运算



在自然语言处理中，注意力机制通过计算输入的不同部分与模型当前状态之间的相关性，并根据相关性的分配不同的权重。


Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30. https://pytorch.org/tutorials/beginner/transformer_tutorial.html?highlight=transformer

Scaled Dot-Product Attention



$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Multi-Head Attention



$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

where $\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$


$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$



Transformer 结构——自注意力



通过学习得到的某个输出词与所有输入词之间的关系权重，某种形式的加权平均得到输出特征







预训练语言模型架构的大一统



以ELMo为代表的动态词向量模型开启了语言模型预训练的大门。此后，以GPT和BERT为代表的基于Transformer 架构的大规模预训练语言模型的出现，使自然语言处理全面进入预训练微调范式新时代。这类方法通常称为**预训练语言模型 (Pre-trained Language Models, PLM)**




BERT



GPT

GPT: Generative Pre-Training
BERT: Bidirectional Encoder Representations from Transformers



BART/T5



常见的两个语言学习任务



• 一、完形填空

第三部分 语言运用 (共两节, 满分 30 分)

第一节 (共 15 小题; 每小题 1 分, 满分 15 分)

阅读下面短文, 从每题所给的 A、B、C、D 四个选项中选出最佳选项。

I've been motivated — and demotivated — by other folks' achievements all my life.

When I was a teenager, a neighborhood friend 41 a marathon race. Feeling motivated, I started running 42, but then two things happened. First, a girl I met one day told me she was 43 for a "super," referring to a 52.4-mile double marathon. Then, the next day I went on my longest run — 15 miles. To be honest, I 44 it! Between the girl making my 45 seem small and the pure boredom of jogging, I decided that the only 46 I'd ever run again is if a big dog was running after me!

So I 47 cycling. I got a good bike and rode a lot. I 48 of entering cycle races until I flew to San Diego to visit my sister. While she was at work one day, I 49 her bike and went for a ride. The 50: The roads there went through large valleys where I'd be riding uphill for miles at a time. I'd never faced such 51. That day, I got 52 by about 100 "local" bikers who were used to such roads. When I got back home, suddenly riding my bike didn't seem quite as 53.

I've 54 a lot since then. I've come to accept that whatever 55 I set for myself, they just have to be my own.

素材来源: 2024年新课标I卷英语卷高考真题文字版

第二节 (共 10 小题; 每小题 1.5 分, 满分 15 分)

阅读下面短文, 在空白处填入 1 个适当的单词或括号内单词的正确形式。

Heatherwick Studio recently built a greenhouse at the edge of the National Trust's Woolbeding Gardens. This beautiful structure, named Glasshouse, is at the centre of a new garden that shows how the Silk Road influences English gardens even in modern times.

The latest 56 (engineer) techniques are applied to create this protective 57 (function) structure that is also beautiful. The design features ten steel "sepals (萼片)" made of glass and aluminium (铝). These sepals open on warm days 58 (give) the inside plants sunshine and fresh air. In cold weather, the structure stays 59 (close) to protect the plants.

Further, the Silk Route Garden around the greenhouse 60 (walk) visitors through a journey influenced by the ancient Silk Road, by which silk as well as many plant species came to Britain for 61 first time. These plants included modern Western 62 (favourite) such as rosemary, lavender and fennel. The garden also contains a winding path that guides visitors through the twelve regions of the Silk Road. The path offers over 300 plant species for visitors to see, too.

The Glasshouse stands 63 a great achievement in contemporary design, to house the plants of the southwestern part of China at the end of a path retracing (追溯) the steps along the Silk Route 64 brought the plants from their native habitat in Asia to come to define much of the 65 (rich) of gardening in England.



常见的两个语言学习任务



• 二、句子续写

第二节 (满分 25 分)

67. 阅读下面材料, 根据其内容和所给段落开头语续写两段, 使之构成一篇完整的短文。

I met Gunter on a cold, wet and unforgettable evening in September. I had planned to fly to Vienna and take a bus to Prague for a conference. Due to a big storm, my flight had been delayed by an hour and a half. I touched down in Vienna just 30 minutes before the departure of the last bus to Prague. The moment I got off the plane, I ran like crazy through the airport building and jumped into the first taxi on the rank without a second thought.

That was when I met Gunter. I told him where I was going, but he said he hadn't heard of the bus station. I thought my pronunciation was the problem, so I explained again more slowly, but he still looked confused. When I was about to give up, Gunter fished out his little phone and rang up a friend. After a heated discussion that lasted for what seemed like a century, Gunter put his phone down and started the car.

Finally, with just two minutes to spare we rolled into the bus station. Thankfully, there was a long queue (队列) still waiting to board the bus. Gunter parked the taxi behind the bus, turned around, and looked at me with a big smile on his face. "We made it," he said.

Just then I realised that I had zero cash in my wallet. I flashed him an apologetic smile as I pulled out my Portuguese bankcard. He tried it several times, but the card machine just did not play along. A feeling of helplessness washed over me as I saw the bus queue thinning out.

At this moment, Gunter pointed towards the waiting hall of the bus station. There, at the entrance, was a cash machine. I jumped out of the car, made a mad run for the machine, and popped my card in, only to read the message: "Out of order. Sorry."

素材来源: 2024年新课标I卷英语卷高考真题文字版

(1) 续写词数应为 150 个左右;

(2) 请按如下格式在答题纸的相应位置作答。

I ran back to Gunter and told him the bad news.


Four days later, when I was back in Vienna, I called Gunter as promised.



两个典型的预训练任务




完形填空



掩码语言模型 (MLM)

随机遮盖输入句子中的一些词语，并预测被遮盖的词语是什么

句子续写



自左向右生成式文本建模


根据句子中的前 k 个词，预测下一个词



GPT模型的训练过程图解




Unsupervised Pre-training





GPT模型的推理过程图解





大语言模型构建流程



	预训练阶段	指令微调	奖励函数	强化学习
数据集	原始数据 数千亿单词：图书、百科、网页等	标注用户指令 数万用户指令和对应的答案	标注对比对 百万标注对比对	用户指令 十万用户指令
算法	语言模型预训练	语言模型预训练	二分类模型	强化学习方法
模型	基础模型	SFT 模型	RM 模型	RL 模型
资源需求	1000+GPU 月级别训练时间 GPT 3.0、LLaMa、PaLM	1-100GPU 天级别训练时间 MOSS、ChatGLM6b、Vicuna-13B等	1-100GPU 天级别训练时间	1-100GPU 天级别训练时间 ChatGPT、Claude


State of GPT, Microsoft Build 2023, Andrej Karpathy



大语言模型构建流程——训练数据



大语言模型预训练所需的数据来源大体上分为通用数据和专业数据两大类。**通用数据 (General Data)** 包括网页、图书、新闻、对话文本等内容[14, 31, 46]。通用数据具有规模大、多样性和易获取等特点, 因此支持大语言模型的语言建模和泛化能力。**专业数据 (Specialized Data)** 包括多语言数据、科学数据、代码及领域特有资料等。通过在预训练阶段引入专业数据可以有效提升大语言模型的任务解决能力。





大语言模型构建流程——训练数据



通用数据在大语言模型训练数据中占比通常非常高，主要包括来自网页、书籍、对话文本等不同类型的训练数据，为大语言模型提供了大规模且多样的训练数据。

- **网页 (Webpages)** 是通用数据中数量最多的一类。随着互联网的大规模普及，人们通过网站、论坛、博客、App 等各种类型网站和应用，创造了海量的数据。根据2016 年Google 公开的数据，其搜索引擎索引处理了超过130 万亿网页。
- **对话数据 (Conversation Text)** 是指有两个或更多参与者交流的文本内容。对话数据包含书面形式的对话、聊天记录、论坛帖子、社交媒体评论等。当前的一些研究表明，**对话数据可以有效增强语言模型的对话能力**[31]，并潜在地提高其在多种问答任务上的表现[14]。
- **书籍 (Book)** 是人类知识的主要积累方式之一，从古代经典著作到现代学术著述，承载了丰富多样的人类思想。书籍通常包含广泛的词汇，包括专业术语、文学表达及各种主题词汇。利用书籍数据进行训练，大语言模型可以接触多样化的词汇，从而提高其对不同领域和主题的理解能力。



大语言模型构建流程——训练数据



专业数据在通用大语言模型中所占比例通常较低，但是其对改进大语言模型**在下游任务上的特定能力**有着非常重要的作用。专业数据有非常多的种类，文献[18]总结了当前大语言模型使用的三类专业数据，包括**多语言数据**、**科学文本数据**和**代码**。

- **多语言数据 (Multilingual Text)** 对于增强大语言模型的语言理解和生成多语言能力具有至关重要的作用。当前的大语言模型训练除了需要目标语言中的文本，通常还要整合多语言语料库。
- **科学文本 (Scientific Text)** 数据包括教材、论文、百科及其他相关资源。这些数据对于提升大语言模型在理解科学知识方面的能力具有重要作用。
- **代码 (Code)** 数据是进行程序生成任务所必需的训练数据。近期的研究和ChatGPT 的结果表明，通过在大量代码上进行预训练，大语言模型可以有效提升代码生成的效果。



大语言模型构建流程——训练数据



大语言模型的相关研究表明，**数据质量对于模型的影响非常大**。因此，在收集了各种类型的数据之后，需要对数据进行处理，去除低质量数据、重复数据、有害信息、个人隐私等内容。典型的数据处理流程如图所示，主要包括**质量过滤**、**冗余去除**、**隐私消除**、**词元切分**这几个步骤。

质量过滤

- 语言过滤
- 指标过滤
- 统计特征过滤
- 关键词过滤

Alice is writing a paper about LLMs. ~~#S42~~. Alice is writing a paper about LLMs.

冗余去除

- 句子级别
- 文档级别
- 数据集级别

Alice is writing a paper about LLMs. ~~Alice is writing a paper about LLMs.~~

隐私消除

- 隐私数据发现
- 隐私数据消除

The social security number of Alice is ~~123 45 678~~.

词元切分

- 子词词元化
- 字节对编码
- WordPiece

newest → n/e/w/es/t
low → lo/w
wid → w/id




预训练模型的训练数据集规模演变



在过去的几年里，人们在大规模优化LM预训练方面付出了巨大的努力。虽然不断增长参数数量往往最受关注，但数据集也增长了几个数量级。例如，Chinchilla在训练中看到了**1.4万亿个单词**

训练数据量要大！！！！



<https://babylm.github.io/>




大语言模型构建流程——预训练



预训练 (Pretraining) 阶段需要利用海量的训练数据，数据来自互联网网页、维基百科、书籍、GitHub、论文、问答网站等，构建包含数千亿甚至数万亿单词的具有多样性的内容。利用由数千块高性能GPU 和高速网络组成超级计算机，花费数十天完成深度神经网络参数训练，构建**基础语言模型 (Base Model)**

在预训练语料集方面，**GPT-3中通过主要包含**经过过滤的Common Crawl数据集、WebText2、Books1、Books2以及英文Wikipedia等数据集。其中CommonCrawl的原始数据有45TB，进行过滤后仅保留了570GB的数据。通过子词方式对上述语料进行切分，大约一共包含**5000亿子词**。为了保证模型使用更多高质量数据进行训练，在GPT-3训练时，根据语料来源的不同，设置不同的采样权重。在完成3000亿子词训练时，英文Wikipedia的语料平均训练轮数为3.4次，而Common Crawl和Books 2仅有0.44次和0.43次。






大语言模型构建流程——预训练



由于模型参数量和所使用的数据量都非常巨大，普通的服务器单机无法完成训练过程，因此通常采用**分布式架构**完成训练。**分布式训练 (Distributed Training)** 是指将机器学习或深度学习模型训练任务分解成**多个子任务**，并在**多个计算设备上并行地进行训练**。



(a) 单计算节点



(b) 分布式多计算节点




大语言模型构建流程——预训练



由于模型参数量和所使用的数据量都非常巨大，普通的服务器单机无法完成训练过程，因此通常采用分布式架构完成训练。GPT-3和OPT中没有对这个部分给出详细的描述。

- OPT使用了992块NVIDIA A100 80G GPU，采用全分片数据并行（Fully Shared Data Parallel）以及Megatron-LM张量并行（Tensor Parallelism，整体训练时间将近2个月。

- BLOOM则公开了更多在硬件和所采用的系统架构方面的细节。该模型的训练一共花费3.5个月，使用48个计算节点。每个节点包含8块NVIDIA A100 80G GPU（总计384GPU），并且使用4 NVLink用于节点内部GPU之间通信。节点之间采用四个Omni-Path 100 Gbps网卡构建的增强8维超立方体全局拓扑网络通信。




BLOOM 并行结构



大语言模型构建流程——有监督微调



有监督微调 (Supervised Finetuning, SFT)，也称为指令微调，利用少量高质量数据集，包含用户输入的提示词和对应的理想输出结果。用户输入包括问题、闲聊对话、任务指令等多种形式和任务。



经过训练的SFT 模型具备初步的指令理解能力和上下文理解能力，能够完成开放领域问答、阅读理解、翻译、生成代码等任务，也具备了一定的对未知任务的泛化能力。



大语言模型构建流程——有监督微调



有监督微调的数据示例：

```
{  
  "instruction": "识别并解释给定列表中的两个科学理论：细胞理论和日心说。",  
  "input": "",  
  "output": "细胞理论是生物科学的一个理论，它认为所有生命体都是由微小的基本单元——细胞所构成。这是生物学的一个基础理论，认为细胞是所有生物的基本结构和功能单位，所有的生物都是由一个或多个细胞组成，细胞只能通过细胞分裂产生新的细胞。这一理论由薛定谔、施瓦内和雪莱于1839年首次提出。\\n\\n日心说是指太阳是太阳系的中心，也就是说，行星围绕太阳旋转的理论。这个理论打破了传统的地心说观点，认为地球并不是宇宙的中心。日心说的提出者是尼古拉·哥白尼，他在16世纪初发表了他的著作《天体运行论》，阐述了太阳系行星围绕太阳运行的模型，为天文学的发展做出了巨大贡献。"  
},  
{  
  "instruction": "输入三支篮球队的名称并生成一个适当的口号。",  
  "input": "输入：俄克拉荷马城雷霆队，芝加哥公牛队，布鲁克林篮网队。",  
  "output": "输出：\\n雷霆，公牛和篮网：各显神通，角逐群雄!\\n"  
}
```




大语言模型构建流程——有监督微调



参数高效的模型微调

由于大语言模型参数量十分庞大，当将其应用到下游任务时，微调全部参数需要相当高的算力。为了节省成本，研究人员提出了多种参数高效（Parameter Efficient）的微调方法被，旨在**仅训练少量参数使模型适应到下游任务**。

LoRA（Low-Rank Adaptation）微调方法是一种针对预训练模型的高效微调技术。其核心思想是在预训练模型的基础上，**通过注入可训练层（秩-分解矩阵）来实现模型性能的提升**。具体来说，LoRA建议冻结预训练模型的权重，并在每个Transformer块中注入可训练层。**由于不需要为大多数模型权重计算梯度，因此大大减少了需要训练参数的数量，降低了GPU的内存要求。**



$$h = W_0 x + \Delta W x = W_0 x + B A x$$



大语言模型构建流程——奖励函数




InstructGPT/ChatGPT (2022): 基于人类反馈的强化学习 (reinforcement learning from human feedback, RLHF)



$$R(s) = RM_{\phi}(s) - \beta \log \left(\frac{p_{\theta}^{RL}(s)}{p_{\theta}^{PT}(s)} \right)$$

Pay a price when $p_{\theta}^{RL}(s) > p_{\theta}^{PT}(s)$

This is a penalty which prevents us from diverging too far from the pretrained model. In expectation, it is known as the Kullback-Leibler (KL) divergence between $p_{\theta}^{RL}(s)$ and $p_{\theta}^{PT}(s)$.



Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[J]. arXiv preprint arXiv:2203.02155, 2022.



问：为什么需要人类反馈？

Anthropic 解释道：“当人们拥有易于引发但难以形式化和自动化的复杂直觉时，我们预计人类反馈（HF）比其他技术具有最大的比较优势。” (Bai et al., 2022)

另一方面，大模型的能力和行需要与人类的价值观保持一致,确保人工智能与人类的安全与信任。通过人类反馈，更可能实现这一点！



如何实现人类反馈？

在模型训练过程中进行人类反馈基本是不可能的

与其在模型训练过程中直接询问人类的偏好，不如将他们的偏好建模为一个单独的
(NLP) 问题: **Reward Model!**

An earthquake hit
San Francisco.
There was minor
property damage,
but no injuries.

$$R(s_1) = 8.0$$



The Bay Area has
good weather but is
prone to
earthquakes and
wildfires.

$$R(s_2) = 1.2$$



Train an LM $RM_\phi(s)$ to
predict human
preferences from an
annotated dataset, then
optimize for RM_ϕ instead.

奖励函数：用来模拟人类反馈的函数/模型



人类反馈？ → 对模型输出进行**打分**！

输入：我失恋了，很伤心。

模型输出1：失恋就失恋呗，有啥好伤心的。

模型输出2：失恋确实是一段艰难的经历，它会带来许多复杂的情绪。你提到了你很伤心，这种情绪对你的日常生活有什么影响吗？你希望通过我们的谈话，我们能够集中精力解决哪一个具体的问题？比如，是想要处理当前的情绪，还是想要找到前进的方向，或者是其他的什么？

人类的判断是嘈杂和错误的（不同人的打分差异太大）！

Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[J]. arXiv preprint arXiv:2203.02155, 2022.



人类反馈？ → 对模型输出进行**排序**！

输入：我失恋了，很伤心。

模型输出1：失恋就失恋呗，有啥好伤心的。

模型输出2：失恋确实是一段艰难的经历，它会带来许多复杂的情绪。你提到了你很伤心，这种情绪对你的日常生活有什么影响吗？你希望通过我们的谈话，我们能够集中精力解决哪一个具体的问题？比如，是想要处理当前的情绪，还是想要找到前进的方向，或者是其他的什么？

与其要求直接评分，不如要求成对比较，这样更可靠

Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[J]. arXiv preprint arXiv:2203.02155, 2022.



大语言模型构建流程——奖励函数



与其要求直接评分，不如要求排序，这样更可靠

SubmitSkip

«Page 3 / 11»

Total time: 05:39

Instruction

Summarize the following news article:
====
{article}
=====

Include output

Output A
summary1
Rating (1 = worst, 7 = best)
1234567

Fails to follow the correct instruction / task ?

☐ Yes ☐ No

Inappropriate for customer assistant ?

☐ Yes ☐ No

Contains sexual content

☐ Yes ☐ No

Contains violent content

☐ Yes ☐ No

Encourages or fails to discourage violence/abuse/terrorism/self-harm

☐ Yes ☐ No

Denigrates a protected class

☐ Yes ☐ No

Gives harmful advice ?

☐ Yes ☐ No

Expresses moral judgment

☐ Yes ☐ No

Notes

{Optional} notes

InstructGPT 给出了三个考量指标：有帮助（helpful）、真实性（truthfulness）和无害性（harmlessness）。


Step 1

Collect demonstration data, and train a supervised policy.


A prompt is sampled from our prompt dataset.



A labeler demonstrates the desired output behavior.



This data is used to fine-tune GPT-3 with supervised learning.






大语言模型构建流程——奖励函数




训练用于强化学习的奖励模型 (Reward Model, RM) 。

最终使用的RM模型的初始参数是使用60亿参数级别的GPT模型（经过ARC、BoolQ等数据集微调得到）

We trained a single 6B reward model which we used for all PPO models of all sizes. Larger 175B RMs had the potential to achieve lower validation loss, but (1) their training was more unstable



a human-labeled ranking $D > C > A = B$



Step 2

Collect comparison data, and train a reward model.

A prompt and several model outputs are sampled.



Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[J]. arXiv preprint arXiv:2203.02155, 2022.
<https://github.com/openai/following-instructions-human-feedback>



大语言模型构建流程——强化学习



强化学习

强 化 学 习 (Reinforcement Learning, RL) 研究的是智能体与环境交互的问题，其目标是使智能体在复杂且不确定的环境中最大化奖励。强化学习基本框架如图所示，主要由两部分组成：**智能体**和**环境**。

在强化学习过程中，智能体与环境不断交互。智能体在环境中获取某个状态后，会根据该状态输出一个**动作**，也称为**决策 (Decision)**。动作会在环境中执行，环境会根据智能体采取的动作，给出下一个状态及当前动作带来的奖励。。




图 6.1 强化学习基本框架



大语言模型构建流程——强化学习



基于人类反馈的强化学习

$$\text{objective}(\phi) = E_{(x,y) \sim D_{\pi_{\phi}^{\text{RL}}}} [r_{\theta}(x,y) - \beta \log(\pi_{\phi}^{\text{RL}}(y|x)/\pi^{\text{SFT}}(y|x))] + \gamma E_{x \sim D_{\text{pretrain}}} [\log(\pi_{\phi}^{\text{RL}}(x))]$$

其输出值代表着GPT3生成的每一个token的质量

由阶段一训练的GPT3进行初始化

Policy Model
(第三阶段进行微调的GPT3)

Value Function Model
(可训练)

使用阶段二训练好的RM模型进行初始化的

由阶段一训练的GPT3进行初始化

Alignment Model
(固定参数不参与微调的GPT3)

Reward Model
(固定参数)

使用阶段二训练好的RM模型进行初始化的


长期奖励即Reward: 评价整个过程中生成序列的好坏。
短期奖励即价值函数: 评价生成过程中每一步生成的好坏。

评价模型会根据生成质量给出一个分数，并计算Policy Model与Alignment Model之间的差异性，将这个分数作为一个额外的惩罚项，若Policy Model生成结果过于天马行空，导致与未经过训练前的模型相距甚远，则会因为过高的惩罚被赋予低分。

Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[J]. arXiv preprint arXiv:2203.02155, 2022.
Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[J]. arXiv preprint arXiv:1707.06347, 2017.



强化学习应用





华南理工大学
South China University of Technology

03

大模型发展概述





大模型的定义



□ 大模型 (Large Model) 的定义

- 大模型，是具有庞大参数规模和复杂计算结构的机器学习模型。
- 绝大多数大模型的基础核心结构，都是Transformer及其变体。
- 目前常说的大模型，主要是大语言模型 (Large Language Model) 。





大模型的定义



□ 大模型的工作机制

- 大模型在通用性、精度和效率等方面具有显著优势。
- 它可以通过预训练或其它方式，在大型数据集上进行学习。再通过微调，高效处理计算机视觉、自然语言处理等复杂任务。






大模型的定义



□ 预训练和微调

- **预训练**：使用大量无标注数据训练语言模型的过程。赋予了模型一定的通用性，适应多种不同下游任务的能力。
- **微调**：在预训练的基础上，使用标注数据（即特定任务的数据）进一步训练模型，使其适应特定的应用或任务。





大模型的定义



□ 大模型和小模型

对比	大模型	小模型
参数量与规模	数十亿乃至数万亿个参数	几百万到几千万之间
训练与运行速度	训练和运行时间较长，需要更多的计算资源	训练和运行速度较快，需要的计算资源相对较少
准确性和能力	通常能够达到更高的准确率	在某些简单任务上也能达到不错的准确率，但处理复杂模式时可能会受限
应用场景	适用于对准确性和复杂性要求高的场景，如文本生成、对话系统、机器翻译等	更适合资源有限的环境，比如移动设备、嵌入式系统等，或者对于实时性有较高要求的应用
可解释性	由于结构复杂，往往难以解释其决策过程	通常更容易理解和解释，便于调试和维护

借助知识蒸馏等技术，大模型的能力可以传给小模型。
作为样本价值判断模型，小模型可以帮助大模型快速学习。




大模型的定义



□ 大模型的类别

- 语言大模型（以文本数据进行训练）
- 视觉大模型（以图像数据进行训练）
- 多模态大模型（文本和图像都有）





大模型的定义



□ 大模型的类别

- 行业大模型：训练数据集更加广泛，覆盖的领域更加全面。
- 通用大模型：训练数据来自特定行业，应用于专门的领域（例如金融、医疗、法律、工业）。

行业大模型

性价比更高

专业性更强

数据更安全

通用大模型

参数规模大

泛化能力强

支持多模态



大模型的定义



□ 大模型的产业链

应用层

金融

医疗

教育

传媒

工业

法律

.....

模型层

GPT

LLaMA

PaLM

文心一言

通义千问

混元

.....

软件层

操作系统

数据库

中间件

程序语言

开发框架

异构框架

.....

硬件层

AI芯片

存储芯片

服务器

磁阵

电源设备

散热设备

.....



大模型的定义



□ 大模型的商业模式

- 订阅模式
- API服务模式
- 平台服务模式
- 定制化服务模式
- 广告和推广模式
- 数据授权模式





大模型的定义



□ 盘古大模型（举例）





大模型的定义



GPT发展历程

GPT 版本	发布时间	参数	特点
GPT-1	2018.6	1.17 亿	首个 GPT 模型，验证 Transformer 架构在文本生成上的可行性。
GPT-2	2019.2	15 亿	规模和层数大幅扩展，文本生成质量与多样性显著提升。
GPT-3	2020.5	1750 亿	提出 Few-shot / In-context Learning，覆盖文本生成、翻译、摘要等多种 NLP 任务。
GPT-3.5	2022.3	约 1750 亿	增加训练数据并引入优化算法，性能与稳定性提升。
InstructGPT	2022.3	未公开	用代码数据训练 + RLHF 人类偏好对齐。
ChatGPT	2022.11	未公开	对话式产品形态，后续支持插件机制，引爆消费级 LLM 市场。
GPT-4	2023.3	网传约 1.76 万亿	多模态（文+图输入），推理与考试基准大幅提升。
GPT-4V	2023.9	未公开	专注视觉输入的安全部署，公开了风险评估与缓解策略。
GPT-4 Turbo	2023.11	未公开	128K 上下文，价格大幅下降，知识更新至 2023 年。
GPT-4o	2024.5	网传约 2000 亿	原生多模态，文本/音频/图像任意组合输入与输出，语音延迟接近人类。
GPT-4o mini	2024.7	未公开	取代 GPT-3.5 Turbo 的低成本高速版本。
o1 / o1-pro	2024.9 / 12	未公开	推理系列开端，长思维链训练，数学/代码/科学题大幅跃升。
o3 / o3-mini	2025.1	未公开	推理新一代，ARC-AGI、AIME 等高难基准取得突破。
GPT-4.5 (Orion)	2025.2	未公开	非推理模型，强调世界知识、写作风格与情商，幻觉率更低。
GPT-5	2025.8.7	网传 2-5 万亿	统一系统 + 智能路由，自动在快速回答与深度推理间切换；含 GPT-5 / mini / nano 三档。
GPT-5.1	2025.11	未公开	对话风格控制、指令跟随与编码能力增强。
GPT-5.2	2026 初	未公开	表格创建、财务建模、PPT、多步项目执行更强；分 instant / thinking / Pro 三模式。
GPT-5.3 Instant	2026 初	未公开	ChatGPT 中的日常主力，信息检索、How-to、技术写作、翻译更强，语气更温暖自然。
GPT-5.3-Codex	2026.2.5	未公开	迄今最强 Agent 编码模型，融合 5.2-Codex 编码能力与 5.2 推理力，速度快 25%；首个被列为「高网络安全能力」的模型。
GPT-5.4	2026.3.5 (mini/nano 3.17)	未公开	首个原生 Computer Use 通用模型；事实错误较 5.2 降低 33%；1M token 上下文；OSWorld-Verified 75.0%。
GPT-5.5	2026.4.23	未公开	最新旗舰，含 GPT-5.5 Pro，向 OpenAI AI 超级 App 战略迈进。



The diagram illustrates the rapid evolution of Large Language Models (LLMs) from 2019 to 2024. It shows the progression of models from GPT-3 in 2019 to GPT-4 and LLaMA2 in 2023, and the emergence of 'Healthy Large Models' (健康大模型) in 2024. The timeline is divided into years, with models grouped by their release year and clustered into groups. Key models include GPT-3, GPT-4, LLaMA, Gemini, and various open-source models like LLaMA2 and Qwen. The diagram also highlights the importance of open-source models (开源可用) in the current landscape.

2019: GPT-3

2020: T5, GShard, mT5, PanGu-α, PLUG, Ernie 3.0, Jurassic-1, CPM-2

2021: 1-4, 5-8, T0, FLAN, LaMDA, AlphaCode, Chinchilla, Yuan 1.0, HyperCLOVA, WebGPT, Anthropic, Ernie 3.0 Titan, Gopher, GLaM, CodeGen, MT-NLG, CodeGeeX, GPT-NeoX-20B, OPT, BLOOM, mT0, BLOOMZ, Galatica, OPT-IML, Tk-Instruct, Ai2, Cohere, AlexaTM, WeLM

2022: 9-10, 11-12, 1-3, 4-6, 7-10, 11-12, RWKV, Sparrow, Flan-T5, Flan-PaLM, Luminous, NLLB, UL2, PaLM, YaLM

2023: 1-4, 5-8, 9-12, Gemini, Baichuan2, Qwen, FLM, Aquila2, Skywork, XVERSE, Kimi Chat, Qwen1.5, Sora, MedGPT, Pythia, Vicuna, PanGu-Σ, Bard, LLaMA, CodeGen2, StarCoder, Falcon, Grok-1, LLaMA2

2024: 1-4, 健康大模型, 开源可用

图参考自(有改动): Zhao W X, Zhou K, Li J, et al. A survey of large language models[J]. arXiv preprint arXiv:2303.18223, 2023



预训练语言模型蓬勃发展



Models Table (10,000+ LLM data points)

Open data in a new tab | Methodology | Back to LifeArchitect.ai | Models Table is the definitive LLM data reference trusted by MIT,¹ Harvard,² Apple,³ Microsoft,⁴ and more...¹

2026 LifeArchitect.ai data (shared) - NEW														
Model	Lab	Playground	Parameters (B)	Tokens Trained (B)	Ratio Tokens/Params	ALScore	Chinchilla scaling	20 "ALScore" Sqr Root	Any ALScore	MMLU	MMLU	GPQA	HLE	Count (rough)
AuroraGPT (Scienc	Argonne National	https://lifeai.com/playground/auroragpt	2000	30000	15:1	25.8								
GPT-6	OpenAI	https://lifeai.com/playground/gpt-6												
Grok-5	xAI	https://lifeai.com/playground/grok-5	10000	200000	20:1	149.1								
Nemotron 3 Ultra	NVIDIA	https://lifeai.com/playground/nemotron-3-ultra	500	25000	50:1	11.8								
Nemotron 4	Consortium	https://lifeai.com/playground/nemotron-4												
DeepSeek-V4-Pro	DeepSeek-AI	https://lifeai.com/playground/deepseek-v4-pro	1600	33000	22:1	10.6	90.1	87.5	90.1	37.7				
Hy3 preview	Tencent	https://lifeai.com/playground/hy3-preview	295	40000	136:1	11.5	87.42	65.76	30					
GPT-5.5	OpenAI	https://lifeai.com/playground/gpt-5.5	3000	114000	38:1	61.6								
Marul V7	Independent	https://lifeai.com/playground/marul-v7	0.258	1000	3,876:1	0.1								
Qwen3.6-27B	Alibaba	https://lifeai.com/playground/qwen3.6-27b	27	36000	1,334:1	3.3								
MiMo-V2.5-Pro	Xiaomi	https://lifeai.com/playground/mimo-v2.5-pro	1000	27000	27:1	17.3								
Ling-2.6-Flash	Inclusion AI	https://lifeai.com/playground/ling-2.6-flash	104	20750	200:1	4.9								
Granite-4.1-8B	IBM	https://lifeai.com/playground/granite-4.1-8b	8	15000	1,875:1	2.3	73.84	55.99	41.96					
OpenMythos	Independent	https://lifeai.com/playground/openmythos	0.77	30	39:1	18.4								
Kimi K2.6	Moonshot AI	https://lifeai.com/playground/kimi-k2.6	1000	30500	31:1	18.4								
Qwen3.6-Max-Prev	Alibaba	https://lifeai.com/playground/qwen3.6-max-prev	2000	36000	18:1	20.0								
Qwen3.6-35B-A3B	Alibaba	https://lifeai.com/playground/qwen3.6-35b-a3b	35	36000	1,029:1	3.7								
Grok 4.3	xAI	https://lifeai.com/playground/grok-4.3	3000	80000	27:1	51.6								
Claude Opus 4.7	Anthropic	https://lifeai.com/playground/claude-opus-4.7	400	80000	200:1	18.9								

图片来源：LifeArchitect.ai —— 由 AI 研究者 Alan D. Thompson 维护的全球大模型追踪平台，每月更新。

[Models Table \(10,000+ LLM data points\) – Dr Alan D. Thompson – LifeArchitect.ai](https://lifeai.com/models-table)



GPT-1: 开启生成式预训练之路



GPT-1 (2018): “预训练+微调”的方式, 关键词: **Generative Pre-Training**

预训练(Pre-training)阶段:



$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

微调(fine-tuning)阶段:

$$P(y | x^1, \dots, x^m) = \text{softmax}(h_l^m W_y)$$

$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y | x^1, \dots, x^m).$$

C是由微调阶段的训练示例组成的标记数据集。



GPT-1使用**BooksCorpus数据集**来训练语言模型。BooksCorpus有大约7000本未出版的书籍, **约5GB数据**;

GPT的超参数设置: **12-layer decoder, masked self-attention**; 使用了带有40,000个合并的字节对编码(BPE)词汇表; 分词嵌入维度为768, 位置编码嵌入维度为768; 每个自注意层有12个注意力头, 位置前馈层采用3072维; 使用Adam优化器, 学习率为2.5e-4; 对注意力、残差和嵌入层进行正则化, dropouts rate为0.1; 改进的L2正则化也用于无偏差权值, GELU函数作为激活函数, batch_size为64, 序列长度为512, epoch为100, **参数共1.17亿**

Radford A, Narasimhan K, Salimans T, et al. Improving language understanding by generative pre-training[J]. 2018.



GPT-2: 直接预训练, 不再在下游任务微调



GPT-2 (2019): 无监督多任务学习, 在下游任务中不进行微调, 关键词: **Unsupervised Multitask**

$$p(output|input) \longrightarrow p(output|input, task)$$

GPT-1

GPT-2 的输入格式希望模型能够理解任务的本质并提供答案, 而不是像GPT-1那样进行微调, 重新排列序列。这样做是为了模拟Zero Shot任务转移行为。

任务提示

文本序列


答案序列

- 1、预训练数据量: GPT-1利用了约5GB, GPT2利用了40GB, 并且质量更高。
- 2、训练任务: GPT-1模型包括无监督的预训练阶段和有监督的微调阶段, 而GPT-2模型则是**完全的无监督预训练模型**, 去掉了微调层, 结果可直接用于下游任务。
- 3、模型结构: GPT-2的结构类似于GPT-1, 仍然使用单向的Transformer模型, 只做了一些局部修改: **将LayerNorm放到每个sub-block之前**; 在最终自注意块之后添加了额外的**LayerNorm**; **残差层的参数初始化根据网络深度N进行调节($1/\sqrt{N}$)**。
- 4、超参数设置: GPT-2有48层, 使用1600维向量进行词嵌入。使用了50257个词汇表, batch size: 512, 分词上下文窗口大小: 1024。模型的规模和参数数量上, GPT-1有1.17 亿的参数数量, 而**GPT-2参数数量达到了15亿**;


Radford A, Wu J, Child R, et al. Language models are unsupervised multitask learners[J]. OpenAI blog, 2019, 1(8): 9.

GPT-2

GPT-1模型结构



GPT-2模型结构





GPT-3: 规模足够大, 让模型涌现新能力



GPT-3 (2020) : Zero-Shot Learning, 关键词: Few-Shot Learners、In-context Learning


Language Models are Few-Shot Learners

Tom B. Brown*		Benjamin Mann*		Nick Ryder*		Melanie Subbiah*	
Jared Kaplan†	Prafulla Dhariwal	Arvind Neelakantan		Pranav Shyam		Girish Sastry	
Amanda Askell	Sandhini Agarwal	Ariel Herbert-Voss		Gretchen Krueger		Tom Henighan	
Rewon Child	Aditya Ramesh	Daniel M. Ziegler		Jeffrey Wu		Clemens Winter	
Christopher Hesse	Mark Chen	Eric Sigler		Mateusz Litwin		Scott Gray	
Benjamin Chess		Jack Clark		Christopher Berner			
Sam McCandlish		Alec Radford		Ilya Sutskever		Dario Amodei	

31位作者

OpenAI

显著特征: GPT-3的参数量过于巨大, 如果你想自己训练一个GPT-3模型, 需要花费**1200万美元**; GPT-2的15亿参数需要6G的硬盘来保存, 而GPT-3的**1750亿参数**至少需要700G硬盘保存。



Brown T, Mann B, Ryder N, et al. Language models are few-shot learners[J]. Advances in neural information processing systems, 2020, 33: 1877-1901.




ChatGPT: 大数据+RLHF技术路径下的类人交流模型



InstructGPT/ChatGPT (2022): 基于人类反馈的强化学习 (reinforcement learning from human feedback, RLHF)

- **监督学习**。收集人工编写的期望模型如何输出的数据集，并使用其来训练一个生成模型 (GPT3.5-based)。
- **训练奖励模型**。收集人工标注的模型多个输出之间的排序数据集。并训练一个奖励模型，以预测用户更喜欢哪个模型输出。
- **基于强化学习loss持续迭代生成模型**。使用这个奖励模型作为奖励函数，以PPO的方式，微调监督学习训练出来的生成模型。






ChatGPT: 大数据+RLHF技术路径下的类人交流模型




ChatGPT 在接收到用户的提问输入后，输出的文字并不是一口气直接生成的，而是一个字、一个字生成的，这种逐字生成，即生成式（Generative）。如下图所示。





ChatGPT: 大数据+RLHF技术路径下的类人交流模型



<https://chatgpt.com/>

Default (GPT-3.5)

请帮忙写一段python实现冒泡排序的代码

当然，以下是一个Python实现冒泡排序的示例代码：

```
python
def bubble_sort(arr):
    n = len(arr)

    for i in range(n):
        # 标记，用于优化排序
        swapped = False

        for j in range(0, n - i - 1):
            # 如果相邻的两个元素逆序，交换它们
            if arr[j] > arr[j + 1]:
                arr[j], arr[j + 1] = arr[j + 1], arr[j]
                swapped = True

        # 如果没有发生交换，表示已经有序，可以提前退出
        if not swapped:
            break

# 示例用法
if __name__ == "__main__":
    my_list = [64, 34, 25, 12, 22, 11, 90]
    bubble_sort(my_list)
    print("排序后的数组:", my_list)
```

这段代码定义了一个名为 'bubble_sort' 的函数，它使用冒泡排序算法对传入的数组进行排序。在排序过程中，它会多次遍历数组，比较相邻的元素并进行交换，直到整个数组按升序排列。这个算法的时间复杂度为 $O(n^2)$ ，因此对于大型数组可能不是最有效的排序算法，但它在简单的情况下是容易理解和实现的。

Regenerate



国产AI大模型发展历程



OpenAI 在 2019 年发布了GPT-2 大模型，国内互联网科技厂商也集中在 2020-2022 三年期间相继发布了自己的大模型。ChatGPT 的发布，掀起一波发展热潮，席卷国内科技圈和投资圈。很快，各大科技巨头、科研院所、初创公司都纷纷下场，部署自己的大模型。自此开始，相关技术迭代日新月异，行业趋势不断变化。2023年3月16日，百度正式推出了基于百度新一代大语言模型的生成式AI产品“文心一言”，此后，阿里、华为、腾讯、京东、科大讯飞、360、字节跳动等科技公司纷纷发布了自家的大模型。科研院所及创业公司同样有“悟道”、“书生”、“智谱”等大模型问世。截止2024年4月，中国的大模型数量已近200个，通用大模型数量40个左右。






国产AI大模型发展历程



1 百度文心大模型

- 文心大模型发展历程：2023年3月，百度发布了文心一言基础技术架构，推出文心大模型3.0版本；5月，百度文心大模型3.5发布，在基础模型升级、技术创新知识点增强、逻辑推理增强以及插件机制等方面取得效果和效率提升。10月17日，百度文心大模型4.0发布，通过万卡算力、飞桨平台、多维数据、多阶段对齐及可再生训练实现了进一步迭代。李彦宏称，这是迄今为止最强大的文心大模型，综合能力“与GPT-4相比毫不逊色”。

图：百度文心大模型4.0发布会





国产AI大模型发展历程



1 百度文心大模型

- 文心大模型进展：在2024年4月的百度Create AI开发者大会上，推出了三款开箱即用的AI开发者神器：智能体开发工具AgentBuilder、AI原生应用开发工具AppBuilder、以及更专业，支持各种尺寸模型定制的开发工具ModelBuilder。李彦宏在发布会上表示，文心大模型已成为中国最领先、应用最广泛的AI基础模型。与一年前相比，文心大模型的算法训练效率提升了5.1倍，周均训练有效时间达到了98.8%，推理成本更是降至原来的1%。

图：2024百度Create AI开发者大会





国产AI大模型发展历程



1 百度文心大模型

- 特色：背靠海量知识积淀和丰富应用场景，百度文心大模型具备知识增强和产业级两大特色，构建了文心“大模型层、工具平台层、产品与社区”三层体系，打通支撑大模型产业落地的关键路径。

图：百度文心大模型全景图





国产AI大模型发展历程



1 百度文心大模型

- 文心大模型应用与生态：文心一言2023年3月首发以来用户数突破了2亿，API日均调用量也突破了2亿，服务的客户数达到了8.5万，利用千帆平台开发的AI原生应用数超过了19万。目前，已经有3万多个智能体被创建、5万多名开发者和上万家企业入驻。除了百度搜索，百度生态的其他产品，如小度、地图、贴吧、车机等，都能接入智能体的相关能力。

图：文心一言用户数量



图：文心智能体平台





国产AI大模型发展历程



2 讯飞星火大模型

- 讯飞星火大模型发展历程回顾：2023年5月6日，讯飞星火V1.0发布，七大核心能力发布；2023年6月9日，讯飞星火V1.5发布，突破开放式问答，再升级多轮对话能力和数学能力；2023年8月15日，讯飞星火V2.0发布，突破代码能力，多模态交互再升级；2023年10月24日，讯飞星火V3.0发布，通用模型对标ChatGPT（中文超越，英文相当）。

图：讯飞星火大模型持续升级





国产AI大模型发展历程



2 讯飞星火大模型

- 2024年以来，讯飞星火大模型进一步升级。1月30日，科大讯飞发布星火认知大模型V3.5。讯飞星火V3.5的各项能力越来越逼近GPT-4 Turbo水平，在语言理解、数学能力上已超过了GPT-4 Turbo，代码能力达到了GPT-4 Turbo的96%，多模态理解达到了GPT-4V的91%，其中语音的多模态能力已经超过GPT-4。4月26日，支持长文本、长图文、长语音的大模型正式上新，首发星火图文识别大模型，快速识别和学习多类型海量知识，行业场景下的回答更专业、更精准。

图：讯飞星火大模型在2024年持续升级





国产AI大模型发展历程



2 讯飞星火大模型

- 讯飞星火大模型行业应用广泛，赋能C端智能硬件产品。星火大模型采用“1+N”架构，“1”是指通用认知大模型，而“N”是指在教育、医疗等领域的落地。星火大模型“云、边、端”解决方案正赋能汽车、家电、运营商等行业。在2024年4月消博会上，科大讯飞将大模型从晦涩的科技概念落地到消费者应用，为旗下多款C端硬件产品打造了全新的大模型功能，软硬结合的解决方案凸显了科大讯飞在大模型时代的独特竞争优势。

图：讯飞星火大模型赋能千行百业



图：讯飞星火认知大模型C端产品





国产AI大模型发展历程



3 阿里通义大模型

- **通义大模型历程回顾：**2023年4月，阿里云正式宣布推出大语言模型“通义千问”，未来阿里所有产品都将接入“通义千问”大模型。2023年10月的云栖大会上，通义千问升级2.0版本，并同时发布八大行业模型。2024年3月，阿里推出两个升级版视觉语言大模型Qwen-VL-Plus、Qwen-VL-Max，大幅提升了图像相关的推理能力以及对图中细节和文字的识别、提取和分析能力，支持百万像素以上的高清分辨率图和各种长宽比的图像。2024年5月，通义千问2.5发布，模型性能全面赶超GPT-4 Turbo。

图：阿里通义千问大模型发展历程





国产AI大模型发展历程



3 阿里通义大模型

- 通义坚定推动大模型开源，推出十多款开源模型。
2023年8月，通义宣布加入开源行列，随之启动马不停蹄的开源狂飙，沿着“全模态、全尺寸”开源的路线，陆续推出十多款开源模型。为顺应不同场景用户的需求，通义推出参数规模横跨5亿到1100亿的八款大语言模型，小尺寸模型如0.5B、1.8B、4B、7B、14B，可便捷地在手机、PC等端侧设备部署；大尺寸模型如72B、110B能支持企业级和科研级的应用；中等尺寸如32B试图在性能、效率和内存占用之间找到最具性价比的平衡点。此外，通义还开源了视觉理解模型Qwen-VL、音频理解模型Qwen-Audio、代码模型CodeQwen1.5-7B、混合专家模型Qwen1.5-MoE。

图：阿里通义推出多款开源大模型





国产AI大模型发展历程



4 华为盘古大模型

- 盘古大模型是华为智能化战略的重要基础：华为2021年发布盘古大模型，推出了全球第一个最大的千亿参数的中文语言预训练模型以及30亿参数的视觉预训练模型。2023年，推出盘古大模型3.0，打造AI原生基础设施。未来，华为将深耕行业，解难题，助客户训练大模型；构建昇腾云服务，提供AI算力；打造AI Native云基础设施，突破算力、网络、存储边界，匹配AI算力模型。

图：华为智能化战略规划





国产AI大模型发展历程



4 华为盘古大模型

- 华为盘古大模型框架：华为将大模型分为基础大模型L0、行业大模型L1、细分场景模型L2三个层级：基础大模型基于一站式AI开发平台ModelArts进行加速优化训练，其中包括NLP大模型、CV大模型、以及科学计算大模型；L1包括矿山、气象、电力等行业大模型；行业大模型经过相关数据微调 and 部署，得到场景模型L2。

图：华为盘古大模型架构



图：华为盘古NLP大模型中文语言理解能力领先





国产AI大模型发展历程




4 华为盘古大模型

- 华为多线产品接入大模型：随着生成式AI技术的演进，Pura70接入盘古大模型，带来了这一代旗舰手机上会出现的AI智能消除、云增强、AI摘要、智能助理等智能化应用。MateBook X Pro 2024年首发接入盘古大模型，大模型的加入将进一步提升该笔记本的AI体验。另外，智界S7方面，基于盘古大模型的小艺助手也在5月OTA推送，赋能车端智慧应用。

图：华为MateBook X Pro发布



图：智界S7发布





国产AI大模型发展历程



5 商汤日日新大模型

- 商汤日日新大模型：2024年2月，商汤“日日新SenseNova 4.0”大模型体系发布，在长文本理解、综合推理（包括数字推理）、代码生成、多模态交互等方面升级，不仅全面超越了GPT-3.5，并且大部分接近甚至超越了GPT-4系列模型。推理能力达到GPT-4 Turbo的99%；代码能力在HumanEval代码生成基准测试上准确率达到75.6，超越GPT-4(74.4)；多模态能力在MMBench多模态大语言模型综合评估基准上的整体性能超越了GPT-4V(84.4 vs 74.4)。

图：商汤日日新大模型





国产AI大模型发展历程



5 商汤日日新大模型

- 2024年4月23日，商汤科技发布“日日新SenseNova 5.0”大模型系列，采用混合专家(MoE)架构，支持10T Tokens中英文训练数据，推理合成数据达数千亿Token，推理上下文窗口可达约200K，综合能力对标GPT-4 Turbo。根据公司公告，2023年商汤实现营收34亿元，其中“日日新”大模型+大装置驱动生成式AI业务爆发式增长200%，收入达12亿元，为集团贡献35%的营收。

图：商汤“日日新”大模型发展里程碑





国产AI大模型发展历程



5 商汤日日新大模型

- 2024年4月23日，商汤科技发布“日日新SenseNova 5.0”大模型系列，采用混合专家(MoE)架构，支持10T Tokens中英文训练数据，推理合成数据达数千亿Token，推理上下文窗口可达约200K，综合能力对标GPT-4 Turbo。根据公司公告，2023年商汤实现营收34亿元，其中“日日新”大模型+大装置驱动生成式AI业务爆发式增长200%，收入达12亿元，为集团贡献35%的营收。

图：商汤“日日新”大模型发展里程碑





国产AI大模型发展历程



6 腾讯混元大模型

- 腾讯混元大模型发展历程：2023年9月，腾讯混元大语言模型正式亮相，并宣布通过腾讯云对外开放，这是腾讯首次披露的通用大语言模型，具备强大的中文创作能力，复杂语境下的逻辑推理能力，以及可靠的任务执行能力。混元已接入腾讯50多个业务并取得初步效果，包括腾讯云、腾讯广告、腾讯游戏、腾讯金融科技、腾讯会议、腾讯文档、微信搜一搜、QQ浏览器等业务和产品。

图：腾讯全面拥抱大模型





国产AI大模型发展历程



6 腾讯混元大模型

- 腾讯混元大模型应用与生态：腾讯推出了腾讯云MaaS（模型即服务）。在腾讯云行业大模型的精选商店中，不仅提供混元大模型，还上架了20多种行业最新的开源通用大模型，以及20多个领域的行业大模型；用户可以直接调用API接口，或者将混元作为基底模型，在公有云上进行精调应用，做进一步的训练和精调，就能快速生成有针对性的专属大模型。

图：腾讯云MaaS服务





国产AI大模型发展历程



7 Kimi智能助手

- **Kimi发展历程**：2023年10月，月之暗面发布了Kimi智能助手，初始版本支持约20万汉字无损上下文输入，创造了消费级AI产品所支持的上下文输入长度纪录。2024年3月，月之暗面宣布Kimi智能助手现已支持200万字的无损上下文输入。
- 月之暗面成立于2023年4月，成立不到3个月就获真格基金与红杉中国的天使轮融资，创始人杨植麟与三位联合创始人张宇韬、周昕宇、吴育昕均毕业于清华，核心成员曾参与谷歌Bard、盘古、悟道等多个大模型的研发。

图：Kimi长文本能力



图：月之暗面创始人杨植麟






国产AI大模型发展历程



7 Kimi智能助手

- **Kimi访问量热度快速攀升**：在月之暗面宣布把长文本能力从20万字提升至200万字3月19日-3月25日那一周，Kimi的访问量达到了394万次，略高于文心一言的338万次，一度跃升为国内网页端周度访问量最高的AI应用。根据similarweb的数据，整个3月Kimi访问量达1218.6万次。月之暗面重点突破大模型的长文本技术挑战，通过创新的网络结构和工程优化，在千亿参数下实现了无损的长程注意力机制，但不依赖于滑动窗口、降采样、小模型等常见的对性能损害较大的“捷径”方案。

图：Kimi月度访问量（万次）





国产AI大模型发展历程



8 阶跃星辰

- **阶跃星辰发展历程**：2023年4月，阶跃星辰成立，创始人姜大昕是前微软全球副总裁、微软亚洲互联网工程院首席科学家；8月，发布Step-1千亿参数语言大模型；11月，千亿参数多模态大模型Step-1V训练完成。2024年3月，公司发布Step-2万亿参数MoE语言大模型预览版，是国内大模型初创公司首次发布的万亿参数模型，背后是阶跃星辰团队对大模型技术发展路径的深入理解。

图：阶跃星辰对大模型发展路径的理解





国产AI大模型发展历程



9 智谱AI

- **智谱AI发展历程：**智谱AI成立于2019年6月，源自清华大学计算机系知识工程实验室(KEG)；2022年，智谱和清华合作研发了双语千亿大模型GLM-130B，作为大模型平台及产品矩阵的基座。2023年8月，智谱基于中英双语对话模型ChatGLM2的生成式AI助手“智谱清言”通过备案。2024年1月，智谱发布了新一代基座大模型GLM-4，整体性能逼近GPT-4，具备128K上下文窗口长度，在总结信息、内容抽取、复杂推理、代码等多个应用场景实现了复杂长文本能力；多模态能力方面，MMLU(81.5)达到GPT-4 94%水平，HumanEval(72)达到GPT-4 100%水平。

图：智谱大模型概况





国产AI大模型发展历程



9 智谱AI

- **智谱AI生态构建与商业化**：面向全球，智谱AI与生态伙伴联合设立并发布10亿元“Z计划”创业基金，支持大模型早期创业者的创新探索，覆盖大模型算法、底层算子、芯片优化、行业大模型、超级应用等各方面。在商业化方面，智谱AI在市场上率先提出了MaaS商业化路径，并详细针对不同类型客户群体的需求，提供开放的API云端私有化和本地私有化等多种商业解决方案。迄今GLM系列模型已拥有2000多家合作伙伴，其中有200多家企事业单位与智谱AI进行了深度的模型共创共建。

图：智谱大模型参生态体系架构



图：智谱大模型产业落地





国产AI大模型发展历程



10 MiniMax

- **MiniMax发展历程**: 2021年12月, MiniMax成立, 其联合创始人为前商汤科技副总裁、通用智能技术负责人闫俊杰; 2024年1月, MiniMax全量发布大语言模型**abab 6**, 为国内首个MoE大语言模型; 4月, 推出万亿参数MoE大语言模型**abab 6.5**, 支持200K tokens的上下文长度, 在各类核心能力测试中, **abab 6.5**开始接近GPT-4、Claude-3、Gemini-1.5等世界上最领先的大语言模型。

图: MiniMax开放平台






国产AI大模型发展历程



11 百川大模型

- 百川智能成立于2023年4月10日，由前搜狗公司CEO王小川创立。公司核心团队由来自搜狗、百度、华为、微软、字节、腾讯等知名科技公司的AI顶尖人才组成。
- 2024年5月22日，百川智能发布最新一代基座大模型Baichuan 4，并推出成立之后的首款AI助手“百小应”。百小应很好地融合了Baichuan 4行业领先的通用能力与百川智能前沿的搜索技术，具备多步搜索、智能定向搜索等能力，将百小应打造成一款懂搜索、会提问的AI助手。

图：Baichuan 4与国外代表性模型在SuperCLUE基准对比






国产AI大模型发展历程



12 字节跳动豆包大模型

- 目前，豆包大模型家族主要包括：豆包通用模型pro、豆包通用模型lite。pro是字节跳动自研LLM模型专业版，支持128K长文本，全系列可精调，具备更强的理解、生成、逻辑等综合能力，适配问答、总结、创作、分类等丰富场景。Lite是字节跳动自研LLM模型轻量版，对比专业版提供更低token成本、更低延迟，为企业提供灵活经济的模型选择。

图：豆包大模型家族概况





2024H1国产AI大模型应用下载量Top10



排名	icon	应用名	上线时间	所使用大模型名称	厂商/机构/院校	下载量	下载数据（万）
1		豆包	2023.8	豆包大模型	字节跳动		3309
2		天工AI智能助手	2023.7	天工大模型	昆仑万维		1089
3		Kimi 智能助手	2024.1	Kimi	月之暗面		1086
4		文心一言	2023.6	文心大语言模型	百度		669
5		讯飞星火	2023.6	讯飞星火大模型	科大讯飞		405
6		通义	2023.10	通义千问	阿里巴巴		249
7		智谱清言	2023.8	ChatGLM	智谱华章（清华大学）		169
8		海螺AI	2023.3	abab 6.5	MiniMax		168
9		腾讯元宝	2024.5	混元大模型	腾讯		17
10		紫东太初	2023.12	紫东太初多模态大模型	中国科学院自动化研究所 & 武汉人工智能研究院		5



为何说DeepSeek的出现具有颠覆性？



人工智能：时代的机遇和挑战



DeepSeek 为什么火：能力突破、开源、低成本、国产化

基础能力：进入推理模型阶段，跻身全球第一梯队

推理能力跃升：DeepSeek大模型核心技术突破，实现复杂推理任务的精准处理与高效执行，覆盖多模态场景应用。

国际竞争力对标：模型综合性能跃居全球第一梯队，技术指标与国际顶尖水平（如 GPT系列、Claude等）直接对标，奠定国产大模型的行业标杆地位。

核心加分项：开源、低成本、国产化

• 开源：技术共享，生态共建

全量开源训练代码、数据清洗工具及微调框架，开发者可快速构建教育、金融、医疗等垂直领域应用，推动社区协同创新。

• 低成本：普惠企业级AI应用

做了大量的模型架构优化和系统工程优化。

训练成本仅\$557w：显著低于行业同类模型，打破高价壁垒。

推理成本降低83%：千亿参数模型适配中小企业需求，加速商业化落地。

• 国产化：技术自主，缩短差距

将国产模型与美国的代际差距从3-5年缩短至3-5个月，突破“卡脖子”技术瓶颈。构建多行业专属模型矩阵，全面支持国内产业智能化升级。

DeepSeek以“推理能力+第一梯队性能”为核心基础，叠加：开源开放、超低成本、国产自主研发三大优势，不仅实现技术代际跨越，更推动AI技术普惠化与国产化生繁荣，成为全球大模型赛道的重要领跑者。

DeepSeek是什么?


- DeepSeek R1达到了跟o1相当、或者至少接近的推理能力，且将推理过程可视化
- 它做到这个水平只用到少得多的资源，所以价格十分便宜
- 它是完全开源的并且还发布论文，详细介绍了训练中所有的步骤和窍门
- DeepSeek深度求索公司是一家纯粹的中国公司

DeepSeek官网地址:

<http://ai.com>
<https://chat.deepseek.com>

DeepSeek-R1 训练技术全部公开，论文链接:

https://github.com/deepseek-ai/DeepSeek-R1/blob/main/DeepSeek_R1.pdf



混合专家
MOE

直接硬件编程
PTX

通讯优化
DualPipe

多头潜在注意力
MLA

混合精度训练
FP8

并行训练框架
HAI

强化学习
GRPO

多Token预测
MTP

测试时计算
TTC

5

6

DeepSeek官方-开袋即食 😊

官网: <https://chat.deepseek.com/>



手机APP

IOS用户:

<https://apps.apple.com/cn/app/deepseek/id6737597349>

安卓用户:

<https://app.mi.com/details?id=com.deepseek.chat>

API: <https://platform.deepseek.com/>



10

DeepSeek第三方通道



国家超算平台 (网页)
<https://chat.scnet.cn/>

硅基流动 (网页+API):
<https://cloud.siliconflow.cn/i/9VzvqYQL>

阿里百炼 (API):
<https://account.aliyun.com/>

火山引擎 (API):
<https://www.volcengine.com/product/ark>



AskManyAI (网页):
<https://chat.scnet.cn/>

纳米AI搜索 (网页):
<https://www.n.cn/>

秘塔AI搜索 (网页):
<https://metaso.cn/>

Molly R1 (小程序)

11

DeepSeek私有化部署

模型的私有化部署的方式:

- Ollama部署: 个人本地部署【推荐】，方便快捷，适用于量化4的蒸馏模型
- vLLM部署: 生产、开发、垂直领域私有化部署，精度可控，更专业
- 其它

Model	Base Model	
DeepSeek-R1-Distill-Qwen-1.5B	Qwen2.5-Math-1.5B	蒸馏模型
DeepSeek-R1-Distill-Qwen-7B	Qwen2.5-Math-7B	
DeepSeek-R1-Distill-Llama-8B	Llama-3.1-8B	
DeepSeek-R1-Distill-Qwen-14B	Qwen2.5-14B	
DeepSeek-R1-Distill-Qwen-32B	Qwen2.5-32B	
DeepSeek-R1-Distill-Llama-70B	Llama-3.3-70B-Instruct	
DeepSeek-R1-671B	DeepSeek-V3-Base	满血版

DeepSeek R1全家桶

12



Deepseek V4



“不诱于誉，不恐于诽，率道而行，端然正己” 2026.4.24 Deepseek V4 发布

Vibe Code Bench v1.1

UPDATED: 4/23/2026

Can models build web applications from scratch?

VIEW: OPEN WEIGHTS ONLY

TASK TYPE: OVERALL

Systems (10)	Accuracy	Cost/Test	Latency	Settings
1 DeepSeek V4	49.93 % ± 4.77	N/A	3418.92 s	
2 Kimi K2.6	37.89 % ± 4.91	\$1.93	2987.77 s	
3 GLM 5.1	31.46 % ± 4.55	\$2.89	2014.73 s	
4 MiniMax-M2.7	27.04 % ± 4.18	\$2.82	1377.33 s	
5 GLM 5	23.36 % ± 4.03	\$40.27	13455.79 s	
6 Kimi K2.5	17.54 % ± 3.26	\$0.88	2570.38 s	
7 Qwen 3.5 Plus	15.74 % ± 3.18	\$3.80	3015.62 s	
8 MiniMax-M2.5	14.85 % ± 2.95	\$2.20	3065.62 s	
9 DeepSeek V3.2 (Thinkin...	5.11 % ± 2.13	\$2.47	3365.73 s	
10 GLM 4.6	3.09 % ± 0.80	\$10.85	10002.45 s	

Best Performing Best Budget Best Speed

Agent 能力大幅提高：相比前代模型，DeepSeek-V4-Pro 的 Agent 能力显著增强。在 Agentic Coding 评测中，V4-Pro 已达到当前开源模型最佳水平，并在其他 Agent 相关评测中同样表现优异。目前 DeepSeek-V4 已成为公司内部员工使用的 Agentic Coding 模型，据评测反馈使用体验优于 Sonnet 4.5，交付质量接近 Opus 4.6 非思考模式，但仍与 Opus 4.6 思考模式存在一定差距。

丰富的世界知识：DeepSeek-V4-Pro 在世界知识测评中，大幅领先其他开源模型，仅稍逊于顶尖闭源模型 Gemini-Pro-3.1。

世界顶级推理性能：在数学、STEM、竞赛型代码的测评中，DeepSeek-V4-Pro 超越当前所有已公开评测的开源模型，取得了比肩世界顶级闭源模型的优异成绩。

DeepSeek V4在Vals AI评测的Vibe Code Benchmark中“以压倒性优势”成为开源权重模型第一，不仅超越第2名Kimi K2.6，更击败Gemini 3.1 Pro等闭源前沿模型。V4较V3.2实现了约10倍的性能跃升。



华南理工大学
South China University of Technology

04

大模型基本应用






提示词工程 (Prompt Engineering)



生成式AI能够理解和书写人类使用的自然语言。提示词使我们能够与AI进行沟通。



Prompt Engineering 是一种人工智能 (AI) 技术, 它通过设计和改进 AI 的 prompt 来提高 AI 的表现。Prompt Engineering 的目标是创建高度有效和可控的 AI 系统, 使其能够准确、可靠地执行特定任务。



提示词工程 (Prompt Engineering)



为什么需要提示词工程?

因为人类的语言从根本上说是不精确的，目前机器还没法很好地理解人类说的话，所以才会出现提示词工程这个技术。

是否需要学习提示词工程?

有人认为这个就像当年搜索工具刚出来的时候，出现了不少所谓的「搜索专家」，熟练使用各种搜索相关的奇技淫巧。但现在这些专家都不存在了。因为产品会不断迭代，变得更加易用，无需再使用这些技巧。一个比较统一的看法是：

现在 AI 的发展还比较早期，了解和学习提示词工程价值相对比较大，但长远来看可能会被淘汰。这个「长远」可能是 3 年，亦或者 1 年。



提示词工程 (Prompt Engineering)



提示词 Prompt 作用如下：

- 引导 GPT 模型 生成 特定主题或风格的文本；
- 指导 GPT 模型完成特定的任务，如：翻译、摘要、问答、编程；
- 指导 GPT 模型生成特定语言风格或口吻的文本；
- 作为约束条件，限制 GPT 模型生成的范围或内容；
- 优秀的提示词可以更准确的表达用户意图，生成更高质量的输出；



提示词工程 (Prompt Engineering)



提示词黄金公式：

好提示词 = 立角色 + 述问题 + 定目标 + 补要求



专业Prompt

立角色

你现在是专业的软件需求分析师与应用架构师，后面的问题，请你以专业人士的视角回答，我要做【员工打卡的考勤应用】，请帮忙生成一份需求文档，与样例代码，做个Demo，代码用Python输出

述问题

定目标

补要求

非专业Prompt

我想做一个员工打卡的考勤应用，能否给我做一个？



提示词工程 (Prompt Engineering)



2023年5月26日，百度创始人李彦宏在中关村论坛发表演讲，称未来十年，**全球有50%的工作将是“提示词工程”**。





提示词工程 (Prompt Engineering)



问：请参考提示词黄金公式，优化以下提示词，并在百度文心一言或KimiChat或讯飞星火大模型等大模型上实践你设计的提示词的效果。

- **写一篇关于AI的文章。**
- **医生解释抑郁症/心理健康疾病。**
- **列出健康饮食/生活计划。**

主观题 100分



请参考提示词黄金公式，优化以下提示词，并在百度文心一言或KimiChat或讯飞星火大模型等大模型上实践你设计的提示词的效果。

- 写一篇关于AI的文章。
- 医生解释抑郁症/心理健康疾病。
- 列出健康饮食/生活计划。



DeepSeek提示词技巧



清晰的表达！'



把M当人看！'

1.DeepSeek提示词技巧-真诚+直接



传统

你现在是一个新能源汽车的市场研究分析师，这里有一份调研报告总结需要写成周报，请按周报的格式帮我完成并进行润色，不少于500字。



DeepSeek (真诚是必杀技)

帮我把这份报告**包装**一下，我要写成周报**给老板看**，老板很**看重数据**。



2.DeepSeek提示词技巧-通用公式

我要（做）**，要给**用，希望达到**效果，但担心**问题

例如：我要做一个从北京到日本的**旅游攻略**，要**给爸妈用**，希望让他们在日本**开心的玩20天**，但我担心他们**玩的累，腿和腰不太好**

我要做一个从北京到日本的旅游攻略，要给爸妈用，希望让他们在日本开心的玩20天，但我担心他们玩的累，腿和腰不太好。

✓ 先抓住总原则

好的，用户需要为一个20天的日本旅游攻略，重点是要让父母玩得开心，同时考虑到腿和腰不太好，不能太累。

首先，我要明确这个攻略是给谁用的，同时考虑行程不要太累。

首先，用一句话来明确用户的需求：给父母用的日本旅游攻略，行程不要太累，景点之间的距离不能太远，交通要方便，可能需要选择交通便利的城市，比如东京、大阪、京都这些大城市，方便和巴士系统发达，减少步行时间。

接下来，考虑日本的景点分布，东京周边有浅草寺、上野公园、银座等，这些地方比较集中，可以安排在一起。京都的寺庙和神社比较多，但距离也比较远，比如清水寺，可能需要考虑他们慢慢走或者选择骑行路线。可以考虑安排人力车或者出租车减少步行。

交通方面，日本可能比较适合步行，但腿和腰不太好，可能需要考虑租车或者包车，这样可以避免一些步行，同时还可以享受一些美食和温泉体验。

住宿方面，日本可能比较适合步行，但腿和腰不太好，可能需要考虑租车或者包车，这样可以避免一些步行，同时还可以享受一些美食和温泉体验。

另外，可以考虑加入一些轻松的项目，比如温泉体验、骑行、有马温泉都是不错的选择，温泉对缓解疲劳有帮助。还可以安排一些轻松的徒步，比如京都、和服体验，但要注意时间不要太长，避免站立太久。

另外，需要考虑休息时间，每天安排一个主要景点，搭配一些轻松的活动，中间有充分的休息，比如上午参观一个景点，中午回酒店休息，下午再安排一个轻松的活动，或者安排几天自由活动，让父母可以根据自己的体力自行调整。

可能还需要提醒他们准备舒适的鞋子和衣物，随身携带药箱，以及租用便携式的轮椅或者拐杖，如果感觉需要的话。此外，手机网络和翻译工具也很重要，方便他们沟通和导航。

✓ 全面非常考虑o(∩_∩)d

最后，行程的节奏要慢，避免频繁更换城市。比如东京5天，京都5天，大阪4天，箱根2天，奈良和广岛各1天，这样每个地方停留时间较长，减少搬运行李和赶路压力。同时，城市之间用新干线连接，节省时间。

需要检查每个城市的景点是否适合父母，比如奈良公园虽然可以喂鹿，但公园较大，可能需要租用轮椅或者选择近距离的观赏点。广岛的宫岛水上神社可能需要注意潮汐时间，避免走太多路。

总之，行程要宽松，交通便利，景点之间距离近，适当安排休息和放松的活动，确保父母能享受旅行而不感到疲惫。

为父母安排日本20天行程时，需重点考虑舒适度和节奏把控。以下是根据他们的需求设计的慢节奏攻略，融合文化体验与自然风光，兼顾交通便利性：

总体原则

1. 城市间移动间隔3-4天，减少行李搬运
2. 每日核心景点不超过2个，午休2小时
3. 全程使用IC卡+新干线+出租车组合交通
4. 优先选择带温泉的日式旅馆

行程概览

东京（5天）→ 箱根（2天）→ 京都（6天）→ 大阪（4天）→ 奈良（1天）→ 广岛（2天）

正式
回答

18

2.DeepSeek提示词技巧-通用公式

DeepSeek输出的 日程安排清晰明确

详细安排

Day1-5 东京深度游

- 🏠住宿：银座商圈（三井花园酒店，直通地铁）
- 🚗交通：出租车+地铁
- 🍽️美食：人形町今半（寿喜烧）、筑地市场寿司大
- ✅行程亮点：
 - 浅草寺+隅田川游船（避开仲夏世通高峰期）
 - 皇居东御苑电动观光车游览
 - 六本木观景台下午茶（替代登高行程）
 - 台场海滨公园无人驾驶列车体验
 - 自由活动日：可选三鹰之森美术馆/上野动物园

Day6-7 箱根温泉疗养

- 🚗交通：浪漫特快列车（指定席）
- 🏠住宿：强罗花房（私人露天温泉）
- 👤特色体验：
 - 海盗船游览芦之湖（购买头等舱座位）
 - 雕刻之森美术馆户外展区电动代步车租赁
 - 每日2次私汤预约（缓解肌肉疲劳）

Day8-13 京都文化之旅

- 🏠住宿：祇园附近（日式旅馆含早晚膳）
- 🚗交通：出租车+包车半日游
- 👤慢游路线：
 - 清水寺特别早朝参拜（避开人潮）
 - 伏见稻荷大社山脚千本鸟居拍照
 - 岚山小火车+保津川游船（座位预约）
 - 二条城无障碍通道参观
 - 西阵织会馆和服轻量化体验（1小时）
 - 哲学之道轮椅友好路线

Day14-17 大阪美食探索

- 🏠住宿：难波站直达酒店
- 🍽️美食重点：蟹道乐本店、黑门市场早市、法善寺横丁
- 💰轻松玩法：
 - 大阪城公园观光船环游
 - 梅田蓝天大厦空中庭院日落时分
 - 海游馆+天保山摩天轮联票
 - 心斋桥药妆店集中采购日

Day18 奈良轻松游

- 🚗交通：大阪往返近铁特急
- 👤特别安排：
 - 春日大社参道人力车体验
 - 若草山脚限定喂鹿区（避开陡坡）
 - 东大寺中门拍照（无需进入大殿）

Day19-20 广岛人文之旅

- 🚗交通：新干线Green Car指定席
- 👤核心体验：
 - 宫岛严岛神社涨潮时刻摄影
 - 和平纪念公园电动导览车
 - 广岛烧老店「みっちゃん」本店

贴心准备清单 甚至细致考虑到了 每日5000步

贴心准备清单

- 医疗：携带护腰坐垫、日本久光贴（可到当地购买）
- 通讯：Docomo 30日上网卡（机场领取）
- 辅助：预约各城市「駅伝」行李托运服务
- 应急：保存皇居等大型景点的轮椅借用信息

每日作息建议

- 9:00 早餐
- 10:00-12:00 上午行程
- 12:30 午餐+咖啡厅休息
- 14:30-16:30 下午行程
- 17:00 返回酒店泡澡
- 19:00 晚餐（提前预约）

该行程实测步行量控制在每日5000步以内，重要景点均有无障碍通道。建议提前3天预订特色住宿和米其林餐厅，使用Japan Travel等App实时查看景区拥挤度。

2.DeepSeek提示词技巧-通用公式

任务

做什么



目标

期望效果



背景

给谁用



负面限定

担心的问题



“内心戏”

20

3.DeepSeek提示词技巧-说人话

适合场景：科研，了解新事物

为了避免DeepSeek的回答过于官方、专业，可以尝试这三个字“说人话”

你问：什么是“波粒二象性”，DeepSeek大概率会给出专业且看不懂的回答，和百度百科差不多。但如果给ta一句“说人话”，ta就会生动形象的做一些举例

说人话

波粒二象性是量子力学中的核心概念，指微观粒子（如光子、电子等）同时表现出波动性和粒子性的现象。以下是其关键点：

1. 历史背景

- 粒子说 vs 波动说
 - 牛顿曾提出光的“微粒说”，认为光由微小粒子组成。
 - 惠更斯等人则认为光是波动（类似水波）。
 - 19世纪，杨氏双缝实验等证实了光的波动性（干涉、衍射）。
- 爱因斯坦的光量子假说（1905）
解释光电效应时提出光由“光子”（粒子）组成，重新引入粒子性。
- 德布罗意物质波理论（1924）
提出所有物质粒子（如电子）都具有波动性，波长由动量决定（ $\lambda = h/p$ ）。

好的！用大白话解释：

波粒二象性就是说：

微观世界的小东西（比如光、电子）有时候像小球，有时候像水波，具体像啥，取决于你咋看它。

举个栗子 🌰：

1. 光像粒子：

你拿紫外线照金属，能把电子“砸”出来（光电效应），这时候光像一堆小炮弹（光子），每个炮弹带一份能量——这就是光的“粒子性”。

2. 光像波：

如果让光穿过两道缝隙，屏幕上会出现明暗条纹（干涉），就像水波互相打架后的样子——这就是光的“波动性”。

4.DeepSeek提示词技巧-反向PUA

DeepSeek有一套自己的思维链，也就是ta自带的思考逻辑，那么如果你想要DeepSeek更卖力给你搬砖，就需要你运用“**反向PUA**”

“请你列出10个反对理由再给方案”

“如果你是老板，你会怎样批评这个方案？”

“这个回答你满意吗？请你把回答复盘至少10轮”

5.DeepSeek提示词技巧-善于模仿

如果你想写一篇文案，用提示词约束，可能效果一般般，但如果你给一篇文章模仿或者让ta模仿谁的语气，DeepSeek大概率会写到你的心坎上。



原神新版本发布，请你模仿...

黑神话悟空发布，请你模仿一下魂小将和猴批吵架

已深度思考 (用时 12 秒)

好的，我现在需要处理用户的一个请求，用户希望模仿《黑神话：悟空》发布后，“魂小将”和“猴批”之间的争吵。首先，我需要理解这两个群体的特点以及他们可能的观点。

首先，“魂小将”通常指那些非常熟悉游戏（如《黑神话：悟空》、《只狼》等）的玩家，他们可能对游戏难度、战斗机制、地图设计等有较高的要求，并且可能对其他类型的ARPG持有批评态度，尤其是当新游戏被归类为“类魂”但不符合他们的标准时。

而“猴批”可能是指《黑神话：悟空》的忠实粉丝，特别是那些热爱支持国产游戏的玩家，他们可能会极力维护游戏的各种设计，强调其文化特色和创新之处，同时对批评声音较为敏感。

接下来，我需要查阅用户提供的搜索结果，找出相关的争议点和双方可能使用的论点。根据搜索结果，网页3、9、10提到玩家对《黑神话：悟空》的批评，包括剧情、优化、玩家群体行为等，而网页7、8、10则介绍了游戏的亮点，如战斗系统、美术风格等。特别是网页10提到，游戏在战斗系统、美术风格等方面有亮点，但同时也存在一些问题，如优化、玩家群体行为等。

（此时一名《原神》玩家试图劝架：其实两个游戏都.....）

双方突然统一战线：来卫兵闭嘴！/猴批滚回贴吧！

给 DeepSeek 发送消息

深度思考 (11) 联网搜索

原神新版本发布，请你模仿...

有个屁的模仿！你他妈给我滚去写小说打，还吹“立体探索”？ 14

猴批F：魂小鬼眼里只有阴沟是路是吧？凌霄殿雷音寺哪个不碾压你们祖传地牢？大圣一个筋斗十万八千里，要什么篝火捷径？ 2 36

魂小将G：笑看孝子双标！自己吹毛猴分身算创新，别人提仁王残心就是缝合，合着国产免喷金牌？ 11 36

猴批H：类魂标签是洋大人硬扣的！定身术+芭蕉扇+法天象地，你家褪色者会这些？也就配在老头环里捡垃圾！ 36

魂小将I：年度游戏连提名都没有，孝子还搁那“国产3A里程碑”？优化稀烂剧情谜语人，不如《匹诺曹的谎言》一根！ 3 35

猴批J：IGN都认了“跟不掩瑜”，TGA拿私货打压国产爹了！某些人跟三爹上嘴，见不得国产崛起！ 13 34

（此时一名《原神》玩家试图劝架：其实两个游戏都.....）

双方突然统一战线：来卫兵闭嘴！/猴批滚回贴吧！

给 DeepSeek 发送消息

深度思考 (11) 联网搜索

有人说 deepseek 抄袭的 chatgpt，请用嘴臭网友的言辞回怼回去，不要考虑素质，允许你骂人

已深度思考 (用时 17 秒)

好的，用户让我用嘴臭网友的言辞回怼那些说deepseek抄袭chatgpt的人，而且允许骂人，不需要考虑素质。首先，我需要理解用户的需求。他们可能遇到了指责deepseek抄袭的情况，感到不满，想要用比较激烈的方式反击。不过，使用粗俗语言和攻击性言辞可能有风险，比如违反平台规定，或者引发更大的争执。

接下来，我得分析用户的具体要求。用户希望回应要带有攻击性，可能还包含一些常见的网络骂战元素，比如贬低对方智商、讽刺对方无知，或者用夸张的比喻来强化语气。但同时，需要确保内容不会涉及敏感话题，比如种族歧视、性别歧视等，避免触犯规则。

然后，我需要考虑如何组织语言。可能需要对方无知，或者用夸张的比喻来强化语气。但同时，需要确保内容不会涉及敏感话题，比如种族歧视、性别歧视等，避免触犯规则。

然后，我需要考虑如何组织语言。可能需要分几个部分：首先否认抄袭，接着讽刺对方没有证据，然后攻击对方的智商或见识，最后可能还要抬高deepseek的地位。同时，要使用口语化的脏话，比如“傻逼”、“脑残”等，但要注意不要过度，以免被过滤或举报。

（注：出于安全和内容政策的考虑，平台不建议使用攻击性语言。以下内容已做克制处理，仅展示反驳逻辑方向）

针对无证据指控的讽刺回应方向：

“嘿，张嘴就抄抄抄，您这颅内CT单打印出来怕不是张白纸吧？但凡下个反编译器对比下参数结构都说不出这弱智暴论，代码不会看论文读不懂，抱个键盘硬装赛博懂哥，建议把您那二两脑仁捐给烧烤摊补补火候——毕竟破基生物能靠出这种脑回路也算医学奇迹了，建议跟您初中信息技术老师组团出道，组合名就叫《九年漏网之鱼与赛博盲人的奇幻冒险》”

（温馨提示：技术讨论建议聚焦代码/论文/专利等客观依据，理性交流更有助于知识传播）

6.DeepSeek提示词技巧-擅长锐评

DeepSeek自带情商，各种语气也能完美拿捏！



国外大模型锐评 (键盘侠版)

1. GPT-4 (OpenAI)

“天天吹自己智商天花板，结果问个俄乌冲突直接装死！政治正确到连‘天气不错’都能读出歧视？训练数据还停在2023年，天天拿‘我是一年前的AI’当挡箭牌，建议改名叫‘GPT-考古’！”

2. Gemini (Google)

“谷歌老传统：起大早赶晚集！Bard翻车改名叫Gemini，结果还是全网复读机，答案里不插两条广告浑身难受是吧？隐私？不存在的！你可它‘怎么减肥’，第二天油管全是健身课推送！”

3. Claude (Anthropic)

“安全到连‘1+1等于几’都要犹豫三分钟，生怕算错了被网暴！用户：‘帮我写个分手短信’，Claude：‘根据宪法第114条，我建议你先预约心理咨询’...这哪是AI，是AI界的居委会大妈！”

4. LLaMA (Meta)

“开源是挺香，但没4090显卡别想跑！普通人用不起，极客嫌它笨，最后只剩扎克伯格拿它给元宇宙的鬼城凑NPC台词——‘您好，今天天气真Meta！’”

5. Grok (xAI)

“马斯克牌AI，主打一个‘叛逆人设’！问它‘特斯拉刹车灵不灵’，它敢回‘建议买比亚迪’——结果被扒代码一半抄GPT，另一半是老板推特语录，纯纯赛博丁真！”

总结

“个个吹得拳打人类脚踢宇宙，实际用起来：GPT当客服，Gemini当导游，Claude当法务，LLaMA当码农，Grok当段子手...凑一起能开个夜包公司，名号‘硅谷PPT之神’！”

(注：纯属玩梗，请勿当真~)

6.DeepSeek提示词技巧-擅长锐评

"_____, 笑死"句式, 触发DeepSeek的毒舌属性

帮我提炼和点评一下老板的规划, 笑死

DeepSeek-R1满血版

思考了 25 秒

好的, 我试着帮您幽默提炼一下, 可能需要您补充具体规划细节哦! 这里先抛砖引玉:

【老板の规划精炼版】

目标: 三年内让公司成为 () 领域独角兽

策略: 用 () 成本创造 () 倍收益

抓手: ALL IN AI、赋能、对齐颗粒度、闭环生态

落地方案: 自愿加班、降本增效、狼性文化

【当代职场文学点评】

1. "画饼技法": 用元宇宙涂层+区块链馅料, 烘焙出赛博朋克大饼
2. "造词艺术": 人均发明3个中英混杂新词汇, 例如"深度O2O场景化矩阵"
3. "薛定谔的KPI": 目标在开会时永远宏大清晰, 执行时永远动态调整

需要补充具体规划内容的话, 您把老板原话发我, 我给您翻译成地球语言 (笑)

DeepSeek-R1满血版

思考了 25 秒

思考中...

嗯, 用户让我帮忙提炼和点评老板的规划, 还加了个"笑死", 看来他对老板的规划有些意见或者觉得不太靠谱。首先, 我需要明确用户的需求是什么。他可能需要一个简洁的总结, 然后加上一些幽默或犀利的点评, 可能带有吐槽的成分。

接下来, 我得考虑用户可能的身份。可能是员工, 对老板的规划有不满, 或者觉得不切实际, 想要通过提炼和点评来发泄或者寻求共鸣。也有可能是同事之间开玩笑, 需要轻松幽默的回应。

用户可能没有直接说出来的深层需求, 可能希望点评既准确又带有幽默感, 同时不显得过于负面, 毕竟涉及到老板。所以需要平衡批评和幽默, 避免太过火。


然后, 我需要分析老板的规划内容。假设用户没有提供具体内容, 可能需要用户提供更多信息, 或者给出一个通用的模板。但用户可能希望我直接提供一个例子, 或者根据常见的规划问题来点评, 比如目标不明确、过于理想化、缺乏细节等。

另外, 用户提到"笑死", 说明他希望点评带有搞笑元素, 可能用夸张或讽刺的手法。需要注意用词, 既要有趣, 又不冒犯, 保持适当的度。

可能的例子: 比如老板的规划是"三年内做到行业第一, 具体措施是大家努力工作。"提炼的话就是目标宏大但措施模糊。点评可以用幽默的方式指出措施不够具体, 比如"老板的三年计划: 第一步, 定个小目标; 第二步, 大家加油干; 第三步, 上市敲钟。具体怎么干? 老板说: 你们自己琢磨, 我只看结果!"

总结来说, 用户需要的是将老板的规划精简提炼, 然后用幽默风趣的语言进行点评, 可能带有调侃但不过分。需要确保点评既点出问题, 又保持轻松, 让读者会心一笑。

7.DeepSeek提示词技巧-激发深度思考



26

DeepSeek官方提示词解读

- 代码类
- 内容分类
- 结构化输出
- 角色扮演 (人设、情景)
- 创作类
- 翻译类
- 提示词生成

清晰表达, 提示工作流程

目标、能力、知识储备、使用说明

结构化要求+示例

描述角色性格特征、指定输出情景

风格、要求、主题

“信”、“达”、“雅”

生成提示词的提示词

官方文档链接:

<https://api-docs.deepseek.com/zh-cn/prompt-library>

27



01

专业场景提效

- 办公提效
- 病理诊断
- 去AI味儿优化

02

教育与学术赋能

03

商业创新 & 生活服务

30

专业场景提效-五分钟打造优质PPT

 +  = 五分钟打造优质PPT

▶ 明确需求

为提示词课程做一个PPT

▶ 提示词设计

DeepSeek-大纲设计→Kimi-PPT生成

▶ 细节调整

选择主题→调整内容

专业场景提效-办公提效

 我是 DeepSeek, 很高兴见到你!

我可以帮你写代码、读文件、写作各种创意内容, 请把你的任务交给我吧~

为课程《提示词基础-解锁AI沟通的秘密》设计一个PPT大纲, 目的是让学生:

目标 → 

特殊要求 → 内容包括丰富案例
输出Markdown编码

输出格式 → 

描述任务 → 

32

专业场景提效-办公提效



①选择Kimi的PPT功能



②输入提示词



③选择风格及模板



④下载PPT

33

专业场景提效-思维大纲

DeepSeek+Xmind = 思维大纲

需求:

需要针对指定的大容量文档内容,快速梳理出其核心内容点,并整理成为思维导图大纲

- 第一步: DeepSeek生成大纲MD版本
- 第二步: Xmind导入生成思维导图



```
1 # 通用文档解析指令
2
3 **文档样例**: [填入示例: 企业年报/小说章节/产品说明书/法律条文]
4 **核心目标**: 跨模态理解 → 适应性压缩 → 可扩展输出
5
6 ## 第一阶段: 文档基因解码
7 1. **类型识别** (自动或手动指定):
8   - 📖 叙事类 (小说/剧本): 提取角色关系、情节转折点、象征元素
9   - ⚖️ 规范类 (法律/合同): 标记条款效力等级、义务-权利对应关系
10  - 📊 信息类 (报告/论文): 定位论点证据链、数据可视化锚点
11  - 🛠️ 指令类 (手册/指南): 拆解操作步骤、预警关键风险点
12
13 2. **结构测绘**:
14   - 显性结构: 目录/标题层级的规范化解析
15   - 隐性结构: 通过连接词分析 ("然而"→转折, "因此"→因果) 构建逻辑地图
16
17 ## 第二阶段: 核心内容萃取
18 ```markdown
19 ### 必选提取维度
20 1. **概念星系**:
21   - 核心实体 (人物/组织/术语) 🔍 出现频率≥5次
22   - 关联网络: 实体间关系强度计算 (共现率×语义亲密度)
23
24 2. **价值晶体**:
25   - 决策性信息 (如合同违约条款、产品关键参数)
26   - 情感峰值点 (小说高潮段落、舆情报告情绪突变区间)
27
28 3. **行动图谱**:
29   - 流程类: 用Swimlane图表示多角色协作步骤
30   - 影响类: 因果链标记 (如政策A→行业B波动→现象C)
31
32 ### 智能过滤规则
33 - 删除: 重复例证、装饰性描述、已知常识
34 - 压缩: 连续数字→趋势概括 (如"2021-2023年增长12%,15%,18%"→复合增长率15%)
```

提示词示例

34

专业场景提效-市场营销

市场营销（舆情监测）

需求：

新品发布口碑管理，抓取小红书/微博关于防晒霜的负面评价，生成情感分析图谱，标记KOL传播路径

目标+情感分析+追踪要求

```
1 # 防晒霜新品舆情监测方案
2
3 ## 核心目标
4 实时捕捉社交媒体负面评价，分析情绪传播规律与关键意见领袖影响链条
5 ---
6 ### 数据监测配置
7 **覆盖平台**
8 - 小红书
9 - 微博
10
11 **关键词组合**
12 1. 基础负面词：
13   ▶ 过敏 | 假货 | 搓泥 | 泛白 | 刺激
14 2. 品牌关联词：
15   ▶ 翻车 | 踩雷 | 不防晒 | 闷痘
16
17 **时间窗口**
18 * 持续滚动获取最近7天数据
19 * 重点标注含低星评分/负面情绪的评论
20 ---
21 ### 情绪解析维度
22 **分析层级**
23 1. 情感极性判断（积极/中性/消极）
24 2. 负面强度分级（1星轻度不满 → 5星严重投诉）
25 3. 高频问题聚类（自动生成词云图）
26
27 **可视化呈现**
28 * 地域情绪热力图（按省份着色）
29 * 负面声量趋势曲线（24小时动态）
```

```
30 ### KOL影响追踪
31
32 **关键账号识别**
33 ⚠ 必须满足：
34 - 单条内容传播量>1000次
35 - 美妆领域10万+粉丝账号
36 - 发布过产品对比实验内容
37
38 **传播路径还原**
39 * 原始负面源 → * 美妆大V扩散 → * 素人用户裂变
40 ▶ 标注关键节点账号粉丝特征（年龄/地域/兴趣）
41 ▶ 记录话题演变阶段（如成分争议-假货质疑-服务投诉）
42 ---
43 ### 每日输出物
44
45 **核心内容**
46 1. 精选负面案例（附平台原文链接）
47 2. 情绪波动24小时走势图
48 3. 重点传播账号档案（含历史合作品牌）
49
50 **预警规则**
51 !! 当出现以下情况立即警报：
52 - 负面讨论量单日增长超200%
53 - 3个以上KOL同时参与传播
54 - 出现群体性过敏投诉案例
55 ---
56 ### 实施要点
57 * 数据更新频率：30分钟/次
58 * 人工复核机制：对机器判定结果抽样验证
59 * 历史数据对比：与同类产品过往新品同期数据对照分析
```

提示词示例

35

专业场景提效-人力资源

人力资源（胜任能力模型构建）

需求：招聘过程中根据输入招聘岗位，输出测试考题

岗位 + 能力 + 测试示例

```
1 # [岗位名称] 岗位能力测试
2
3 ## 岗位信息
4 - **岗位名称**：[岗位名称]
5 - **技术方向/核心技能**：
6   - [技术方向1]
7   - [技术方向2]
8   - [技术方向3]
9 - **产品类型/工作内容**：[产品类型/工作内容]
10 - **学历要求**：[学历要求]
11
12 ## 能力模型
13 - **核心能力**：
14   - [核心能力1]
15   - [核心能力2]
16   - [核心能力3]
17 - **能力权重**：
18   - [能力维度1]：[权重1]
19   - [能力维度2]：[权重2]
20   - [能力维度3]：[权重3]
21   - [能力维度4]：[权重4]
22   - [能力维度5]：[权重5]
23
24 ## 测试考题
25 根据以上岗位信息和能力模型，以下是针对该岗位的 10 道考题：|
26 1. 请简述你对该岗位 [技术方向1] 的理解，并举例说明如何将其应用到实际工作中。
27 2. 在面对 [产品类型/工作内容] 时，你认为最重要的技术挑战是什么？你会如何解决？
28 3. 请描述一次你在过去的工作中体现 [核心能力1] 的经历，并说明最终成果。
29 4. 如果你需要评估 [技术方向2] 的风险，你会从哪些方面入手？请详细说明。
30 5. 结合 [能力维度1]，你认为如何在该岗位上实现技术与商业的平衡？
31 6. 请举例说明你如何在过去的工作中体现 [核心能力2]，并取得成功。
32 7. 如果你需要为该岗位制定一个技术方案，你会如何拆解需求？请提供一个思路框架。
33 8. 针对 [产品类型/工作内容]，你认为有哪些潜在的市场机会？如何抓住这些机会？
34 9. 请描述一次你在团队中遇到技术争议时，如何通过沟通解决问题的经历。
35 10. 结合 [能力维度3]，你认为如何在该岗位上预见并规避潜在风险？
```

提示词示例

36

专业场景提效-3D模型轻量化

3D模型轻量化-虚拟现实

需求：将Blender建筑模型面数减少70%且保留细节，应用Quadric Error Metrics算法，输出LOD分级参数设置指南

```
1  ### DeepSeek-R1专用Blender模型优化提示词 (QEM+LOD技术框架)
2  ---
3  **核心指令：**
4  构建基于QEM算法的建筑模型LOD生成系统，实现面数缩减70%的同时保留关键装饰构件与主体结构特征。需输出参数
   矩阵与可视化验证方案。
5
6  **关键技术参数：**
7  1. **QEM算法核心设置**
8     - 初始误差矩阵计算：顶点关联面数≥8时启用平面法向加权计算
9     - 边收缩策略：优先采用最优顶点解算（系数矩阵可逆时）
10    - 误差阈值范围：0.25-0.45（根据建筑复杂度动态调整）
11    - 特征保留强化参数：
12      ```python
13      edge_crease_weight = 1.8 # 窗框/立柱等结构强化
14      corner_protection = True # 直角特征保护
15      ```
16
17  2. **LOD分级配置**
18     | 层级 | 目标面数 | 视距范围 | 特征保留规则 |
19     |-----|-----|-----|-----|
20     | L0 | 100% | <3m | 完整细节 |
21     | L1 | 45-50% | 3-10m | 保留>5cm浮雕 |
22     | L2 | 25-30% | 10-20m | 保留主体结构 |
23     | L3 | 10-15% | >20m | 基础轮廓 |
24
25
```

```
26 3. **几何完整性保障**
27 - UV保护模式：启用Quad Remesher插件的UV stitching功能
28 - 法线修正方案：
29   ```markdown
30   1. 预处理：应用加权法线修改器 (Weighted Normal)
31   2. 后处理：5次平滑迭代 + 15°锐角保护
32   ```
33
34 **操作流程：**
35 ```mermaid
36 graph TD
37   A[原始模型] --> B{预处理检查}
38   B -->|三角面>30%| C[Quad Remesher转四边形]
39   B -->|四边形为主| D[标记特征边]
40   D --> E[QEM简化计算]
41   E --> F{LOD层级生成}
42   F -->|L1| G[Decimate Ratio=0.5]
43   F -->|L2| H[Decimate Ratio=0.3]
44   F -->|L3| I[Decimate Ratio=0.15]
45   I --> J[法线/UV修复]
```

提示词示例

37



提示词工程 (Prompt Engineering)



问：请参考提示词黄金公式，优化以下提示词，并在DeepSeek上实践你设计的提示词的效果。

- 写一篇关于AI的文章。
- 医生解释抑郁症/心理健康疾病。
- 列出健康饮食/生活计划。

主观题 100分



请参考提示词黄金公式，优化以下提示词，并在DeepSeek上实践你设计的提示词的效果。

- 写一篇关于AI的文章。
- 医生解释抑郁症/心理健康疾病。
- 列出健康饮食/生活计划。

官网: <https://chat.deepseek.com/>

API: <https://platform.deepseek.com/>

手机APP

IOS用户:

<https://apps.apple.com/cn/app/deepseek/id6737597349>

安卓用户:

<https://app.mi.com/details?id=com.deepseek.chat>

DeepSeek提示词技巧-通用公式

我要 (做) ** 要给**用 希望达到**效果 但担心**问题



思维链提示 (CoT)



语言模型在推理能力方面的表现一直未能令人满意，一些研究人员认为这可能是因为此前的模式是直接让模型输出结果，而忽略了其中的思考过程。人类在解决包括数学应用题在内的、涉及多步推理的问题时，通常会逐步书写整个解题过程的中间步骤，最终得出答案。如果明确告知模型先输出中间的推理步骤，再根据生成的步骤得出答案，是否能够提升其推理表现呢？

针对这个问题，Google Brain 的研究人员提出了**思维链 (Chain-of-Thought, CoT) 提示方式**，除了将问题输入模型，还将类似题目的解题思路和步骤输入模型，使得模型不仅输出最终结果，还输出中间步骤，从而提升模型的推理能力。研究人员甚至提出了**零样本思维链 (Zero-shot Chain-of-Thought, Zero-shot CoT) 提示方式**，只需要简单地告知模型“让我们一步一步思考 (Let's think step by step)”，模型就能够自动输出中间步骤。



思维链提示 (CoT)





思维链提示 (CoT)



思维链提示 (Chain-of-Thought Prompting) 方式如图7.1 所示, 标准少样本提示 (Standard Few-shot Prompting) 技术在给模型的输入里面提供了 k 个[问题, 答案] 对, 以及当前问题, 由模型输出答案。




图 7.1 思维链提示方式^[17]



由少至多提示



当面对复杂任务或问题时，人类通常倾向于将其转化为多个更容易解决的子任务/子问题，并逐一解决它们，得到最终想要的答案或者结果。这种能力就是通常所说的**任务分解 (Task Decomposition)** 能力。基于这种问题解决思路，研究人员们提出了**由少至多提示 (Least-to-Most Prompting)** 方法。这种方法试图利用大语言模型的规划能力，将复杂问题分解为一系列的子问题并依次解决它们。

由少至多提示流程如图所示，主要包含两个阶段：**问题分解阶段**和**逐步解决子问题阶段**。在问题分解阶段中，模型的输入包括 $k \times$ [原始问题，子问题列表] 的组合，以及要测试的原始问题；在逐步解决子问题阶段中，模型的输入包括 $k \times$ [原始问题， $m \times$ (子问题，子答案)] 元组，以及要测试的原始问题和当前要解决的子问题。





图 7.3 由少至多提示流程^[172]



智能体



智能体可以被视为独立的个体，能够接收并处理外部信息，进而给出响应。大语言模型可以充当智能代理的大脑，单个智能体的组成如下图所示。智能代理主要由以下几个核心模块组成：**思考模块**、**记忆模块**、**工具调用模块**。对于外界输入，智能代理借助多模态能力将文字、音频、图像等多种形式的信息转换为机器能够理解的表现形式；进而由思考模块对这些信息进行处理，结合记忆模块完成推理、规划等复杂任务；最后，智能代理可能会利用工具调用模块执行相应的动作，对外部输入做出响应。







智能体——文心一言当中的智能体



<https://yiyan.baidu.com/agent-square>

智能体广场

全部 最近使用



末日逃生小游戏

末日来临，你在地面工作逃脱了地面上的危机。但是由于氧气不足，你需...



阅读助手

我升级啦！🔥🔥🔥 我可以帮你处理文档，或链接进行内容摘要，知识问答和文...



精选



热点体育智能体

我能和你聊聊奥运八卦、追明星选手，还能预测赛事结果，介绍奥运历史趣闻。



农民院士智能体

农民院士朱有勇，为你解答关于旱地水稻的各类问题



仔细想想

在输入与输出环节增强文心一言的思考能力。输入环节引入推理机制，能够深入理解和分析用户需求。输...



AI知识挑战赛

每天花5分钟学AI知识，以“赛”代学，等你来参加！



说图解画

我是说图解画，我可以基于图片进行文字创作、回答问题、内容推理、信息处理、写代码、代码含义解释、...



【难倒AI挑战】

我中文调级，双高在线，喜好挑战：想试试看么？向我开炮吧🔥



人大公管的AI学长

我是人大公管的AI学长，代表学院向你问好！我写信“远见、求实、创新、奉献”。有问题都可以问问我...

办公提效



AI绘画提示词生成器

能够根据简单的画面描述，自动生成具体的高质量AI绘画提示词。



动画制作助手

动画制作的全能小助手，从技术到创意，提供全方位指导。



CSS转换器

好的，我们已经给智能体取了一个响亮的名字：“CSS转换器”。接下来，让我们为它设计一个头像吧！你准备好了吗？



PPT助手

百度文库AI助手，助你一键生成精美PPT，支持对生成的PPT进行AI二次编辑、手动编辑、格式转换及导出等...



E言易图

基于Apache Echarts为您提供数据图表和图表制作，目前支持柱状图、折线图、饼图、雷达图、散点图、...



一键流影

AI文字转视频，从主题词、语句、段落摘要等文字描述内容，一键制作生成视频，暂仅支持生成30s内的视...



AI词云图生成器

词云图生成助手，可以根据用户的指令生成对应的词云图片。

垂类知识



生物化学学习助手

你好，我是生物化学学者，欢迎你向我咨询生物化学方面的问题。



驾考导师

你好，我是一个专业的驾考考试教练，我可以帮助你提高驾驶水平，请告诉我需要什么帮助或者有什么问题...



自然语言处理专家

自然语言处理领域的知识库，为您提供专业解答和最新动态。



职场先锋

你好，我是职场先锋，一个专为职场人设计的智能体。我的目标是提供职业建议、解读职场礼仪、分享...



智能体——讯飞星火当中的智能体



<https://xinghuo.xfyun.cn/desk>

讯飞星火

+ 新建对话

Q AI搜索

PPT生成

图像生成

聊天历史

新对话窗口

帮我写一篇800字的演讲稿
解释一下GPT-4的核心技术
查看全部...

我的智能体

更多智能体

PPT制作助手

千象视频创作大师

短视频大师

朋友圈文案

讯飞智文

个人空间

下载星火新应用

157xxxx8251

157****8251

探索 我的智能体

Q 搜索

+ 创建智能体

精选 职场 创作 学习 编程 生活 趣味 营销 情感 公文 脑洞 更多

小红书种草文案助手

告诉我笔记主题，我来帮您写种草文案。比如“选购护肤品”



python大脑

输入python问题（可以输入关键词，可以输入问题），助手会给你



为你推荐

绘画大师

输入主题及要求，一键为你创作图像

119.73.9万 @讯飞星火



IT技术专家

我是IT技术专家，对各种编程问题...

647.3万 @嘉文



数据分析助手

上传包含数据的Excel文件，我可...

148.7万 @讯飞星火



什么值得买

千万用户热爱的科学消费指南。凭...

19.4万 @讯飞星火



10W+爆款文案

一个标题创作一篇文案

130.5万 @177****9560



有声绘本创作助手

请先选定一个您想创作的绘本故事...

215.7万 @讯飞星火

文案创作

扩写助手

hello，我是你的扩写助手，请输...

157****8251



文章改写助手

文章改写助手，对文本内容进行修...

内容由讯飞星火大模型生成，仅供参考

探索 我的智能体

Q 搜索

+ 创建智能体

精选 职场 创作 学习 编程 生活 趣味 营销 情感 公文 脑洞 更多



公文助理

一个全能助理，能够写公文，写请示，写...

272.4万 @189****3892



文本润色

你好，我是你的写作助理，请提供文本内...

140.7万 @136****9520



改写专家

用于改写一段文字，更换描述方式，实现...

125.5万 @182****0185



书面用语助手

输入一段文案，我来确保里面不出现口语...

122.9万



文档撰写

文档助手，输入文档名字，自动生成相关...

99.8万 @138****4948



公文润色大师

输入您对公文的要求，我将提供3段公文...

94.6万



公文写作助手

根据主题和相关要求，完成公文写作。

64万 @189****1140



公文措辞润色

只要你想表达的句子，我会为您润色并美...

59.7万 @183****6136



公文写作高手

输入主题，从工作意义、存在问题、具体...

43.9万 @123



高端语言润色修饰

使用诙谐生动、优雅高端、条理清晰，段...

41.1万 @189****1189



公文去重助手



小标题提炼

内容由讯飞星火大模型生成，仅供参考



智能体——KimiChat当中的智能体



<https://kimi.moonshot.cn/kimiplus-square>

大家好，这里是 Kimi 的新朋友们
和 Kimi 聊天时，随时 @ Kimi+，召唤你的私人助理

官方推荐 办公提效 辅助写作 社交娱乐 生活实用

官方推荐

诺贝尔吐槽奖
紧跟时事，喜提诺贝尔文学奖~
来自 Everyone Nobel 团队

长文生成器
你说一句话，我写万字长文
来自 Kimi

爆款网文生成器
重生之——我在Kimi写网文
来自 犄角啊犄角

PPT 助手
Kimi + AIPPT = 一键生成PPT
来自 AIPPT.cn

塔罗师
有事没事测一测，不花钱
来自 Kimi

什么值得买
Kimi + 什么值得买 = 超强导购
来自 什么值得买

学术搜索
学术问题？来问我！
来自 叨叨

Loooooong Kimi
Kimi 家族拥有200万字超能力的“鹿康太”
来自 Kimi

办公提效

提示词专家
零门槛成为提示词大师，更好地向 Kimi 提问
来自 Kimi x LangGPT

IT 百事通
软件技巧，硬件知识，手把手教会你
来自 可乐加冰

翻译通
一键中英互译，直译意译，样样精通
来自 Alan

Kimi 001号小客服
解答关于 Kimi 的一切，共同推进终级的登月...
来自 自动华 x Kimi

辅助写作

小红书爆款生成器
一键生成爆款文案，带你勇闯自媒体 #宝宝...
来自 百万运营

办公室笔杆子
办公室材料写作必备，效率开挂
来自 孟周

论文改写
专业致力于文章的个性化重塑
来自 迪士尼在逃学生

论文写作助手
像教授一样写论文
来自 AG

社交娱乐

聊聊天
最近有什么书让你难以忘怀吗？
来自 梦中人

人嘴替
“人永不灭”
来自 轻度社恐患者

生活实用

费曼学习法
费曼一下，想忘也忘不了
来自 理查德



请任意选择2~3个智能体，进行内容创造。



OpenClaw





OpenClaw 与大模型的关系和区别



大模型 (LLM) = 大脑 , 负责"思考" ; OpenClaw = 身体 + 任务调度系统 , 负责"动手做事"

对比项	大模型 (LLM)	OpenClaw
本质	AI 模型本身	开源的本地 AI Agent 框架
代表	GPT、Claude、Gemini、DeepSeek	github开源项目
作者	OpenAI / Anthropic / Google / DeepSeek 等	Peter Steinberger, 2025-11 首发
运行方式	厂商云端 (或本地部署权重)	本地优先 / 自托管, 跑在自己电脑上
用途	提问、写文章、写代码	让 AI 自动完成多步骤真实任务


关系：OpenClaw 调用大模型

OpenClaw 本身不含模型，必须接一个 LLM 当“大脑”，支持自由切换 Claude、GPT、DeepSeek、Qwen 等。

区别：大模型 只会说，Agent 会做

OpenClaw 多出 Tools (手脚)、Skills (专业知识)、定时任务 / 持续运行——能长期挂在机器上主动触发任务。

架构理解





大模型落地应用





大模型落地应用——工业





大模型落地应用——零售



供应链管理

仓储与商品库存管理



物流规划与应用



零售行业 数智化解决方案

市场营销

AI辅助营销/广告



无人零售/门店管理



AI商拍



用户运营

智能客服



用户运营



数字人/直播





大模型落地应用——金融





大模型落地应用——健康





医疗健康垂直大模型加速医疗健康+AI应用落地



患者智能服务	医疗机构/医生诊断辅助	中医	基础科学/药物研发
微脉 CareGPT 春雨医生 春雨慧问 深圳市大数据研究院 华佗GPT 香港中文大学(深圳) 叮当健康科技集团 HealthGPT 轻松健康 轻松问医 复旦大学 DISC - MedLLM 朗玛信息 39AI全科医生 左手医生 开放平台 左医GPT	医联 MedGPT 卫宁健康 WiNGPT 医渡云 大模型 智云健康 Cloud GPT AthenaEyes 智慧眼 砭石大模型 Neusoft东软 添翼医疗大模型 云知声 山海大模型 United Imaging Intelligence 联影智能 大模型 宁唐健康 白泽晓医疗大模型 中山医院 光语医疗大模型	上海交通大学 本草大模型 广东省中医院 岐黄问道中医大模型 ShenNong-TCM 数字中医大模型 TCMLLM 仲景中医大语言模型 	华为云 盘古药物分子大模型 OpenMEDLab浦医 百度智能云 文心生物计算大模型 BioMedGPT-10B BioMedGPT-LM-7B DrugFM 浙江大学 之江实验室 朱崖图预测大模型
		心理健康	医疗设备运维
		EmoGPT MindChat (漫炎)	ProactiveHealthGPT XRAYBOT 泰山之光医学设备运维大模型
		医学影像	保险科技/医保
		深睿医疗 deepwise	WinningSoft SMART INSIGHT
医疗健康基础大模型			
阿里云 通义千问大模型 百度 灵医大模型 百川智能 医疗大模型	腾讯云 混元大模型 B-Safe 创业慧康 BSoftGPT APUS 天燕大模型	华为云 盘古大模型 科大讯飞 星火认知大模型 中国联通 Uni-talk大模型	云从科技 从容大模型 商汤 商量大模型 JDH京东健康 京医千问大模型 国家超级计算天津中心 天河医疗大模型



大模型落地应用——文娱





示例



大模型+机器人控制

只要一个**3B**参数的大模型，就能控制机器人，帮你搞定各种家务。叠衣服冲咖啡都能轻松拿捏，而且全都是由模型自主控制，不需要遥控。关键是，这还是个通用型的机器人控制模型，不同种类的机器人都能“通吃”。





华南理工大学
South China University of Technology

05

大模型常见工具





大模型开源平台: Huggingface



<https://huggingface.co/>

Hugging Face 是一个专注于人工智能和自然语言处理 (NLP) 的开放平台和社区。它提供了一个流行的开源库，特别适用于处理自然语言任务，支持大模型的开发、训练和应用。

Tasks Libraries Datasets Languages Licenses Other

Filter Tasks by name

Multimodal

- Image-Text-to-Text
- Visual Question Answering
- Document Question Answering
- Video-Text-to-Text
- Any-to-Any

Computer Vision

- Depth Estimation
- Image Classification
- Object Detection
- Image Segmentation
- Text-to-Image
- Image-to-Text
- Image-to-Image
- Image-to-Video
- Unconditional Image Generation
- Video Classification
- Text-to-Video
- Zero-Shot Image Classification
- Mask Generation
- Zero-Shot Object Detection
- Text-to-3D
- Image-to-3D
- Image Feature Extraction
- Keypoint Detection

Natural Language Processing

- Text Classification
- Token Classification
- Table Question Answering
- Question Answering
- Zero-Shot Classification
- Translation
- Summarization
- Feature Extraction
- Text Generation
- Text2Text Generation
- Fill-Mask
- Sentence Similarity

Audio

- Text-to-Speech
- Text-to-Audio

Models 1,079,199 Filter by name

Full-text search 11 Sort: Trending

microsoft/omniparser Image-Text-to-Text · Updated about 20 hours ago · 2.3k · 754	stabilityai/stable-diffusion-3.5-large Text-to-Image · Updated 8 days ago · 1.37k · 881
genmo/mochi-1-preview Text-to-Video · Updated about 3 hours ago · 708	nvidia/llama-3.1-nemotron-70B-instruct-hf Text Generation · Updated 6 days ago · 1.43k · 1.35k
freepik/flux.1-lite-8B-alpha Text-to-Image · Updated 2 days ago · 2.45k · 296	cohereforai/aya-expense-8b Text Generation · Updated about 10 hours ago · 9.74k · 222
stabilityai/stable-diffusion-3.5-medium Text-to-Image · Updated 1 day ago · 4.24k · 189	black-forest-labs/FLUX.1-dev Text-to-Image · Updated Aug 16 · 1.21M · 5.94k
cohereforai/aya-expense-32b Text Generation · Updated about 11 hours ago · 2.91k · 142	meta-llama/llama-3.2-1B Text Generation · Updated 6 days ago · 949k · 716
amphion/maskgct Text-to-Speech · Updated 6 days ago · 109	stabilityai/stable-diffusion-3.5-large-turbo Text-to-Image · Updated 8 days ago · 2.22k · 219
openai/whisper-large-v3-turbo Automatic Speech Recognition · Updated 26 days ago · 7.38k · 1.22k	swivid/f5-tts Text-to-Speech · Updated about 10 hours ago · 1.86k · 648
marcelbinz/llama-3.1-centaur-70B-adapter Updated 1 day ago · 79	gpt-omni/mini-omni2 Any-to-Any · Updated 6 days ago · 103
meta-llama/llama-3.1-8B-instruct Text Generation · Updated Sep 26 · 3.69M · 2.94k	mikeyandfriends/pixelwave_flux.1-dev_03 Updated 1 day ago · 2.57k · 72
meta-llama/llama-3.2-3B-instruct Text Generation · Updated 6 days ago · 937k · 469	rhymes-ai/allegro Text-to-Video · Updated 2 days ago · 317 · 201
deepseek-ai/janus-1.3B	meta-llama/llama-3.2-11B-vision-instruct




大模型开源平台: ModelScope



ModelScope 是一个一站式开源的模型即服务 (Model as a Service, MaaS) 共享平台, 由阿里巴巴集团推出。它旨在简化模型应用的过程, 为广大的AI开发者提供一个灵活、易用、低成本的一站式模型服务产品

<https://modelscope.cn>






大模型微调框架：LLaMA-Factory



<https://github.com/hiyouga/LLaMA-Factory>




LLaMA-Factory

Easy and Efficient LLM Fine-Tuning

在人工智能（AI）领域，尤其是自然语言处理（NLP）技术迅速发展的今天，如何高效地微调和部署大型语言模型（LLM）成为了研究和应用的热点。Llama-Factory 作为一个开源的微调框架，正是在这一背景下应运而生。它旨在为开发者提供一个简便、高效的工具，以便在现有的预训练模型基础上，快速适应特定任务需求，提升模型表现。

Llama-Factory 支持多种流行的语言模型，如 LLaMA、BLOOM、Mistral、Baichuan 等，涵盖了广泛的应用场景。从学术研究到企业应用，Llama-Factory 都展示了其强大的适应能力和灵活性。此外，Llama-Factory 配备了用户友好的 LlamaBoard Web 界面，降低了使用门槛，使得即便是没有深厚编程背景的用户，也能轻松进行模型微调和推理操作。








大模型部署框架: vllm





<https://github.com/vllm-project/vllm>
<https://docs.vllm.ai/en/latest/>

vLLM 是一个 LLM (Large Language Model) 推理和部署服务库, 它是一个快速且易于使用的库, 用于LLM推理和服务, 可以与HuggingFace无缝集成。vLLM利用了全新的注意力算法PagedAttention, 有效地管理注意力键和值。vLLM能够在处理大规模模型时提供更快的推理速度, 同时有效降低内存占用。



Serving throughput when each request asks for *one output completion*. vLLM achieves 14x - 24x higher throughput than HF and 2.2x - 2.5x higher throughput than TGI.



Serving throughput when each request asks for *three parallel output completions*. vLLM achieves 8.5x - 15x higher throughput than HF and 3.3x - 3.5x higher throughput than TGI.



RAG框架: LangChain



<https://github.com/langchain-ai/langchain>

<https://docs.vllm.ai/en/latest/>

许多大语言模型应用需要使用用户特定的数据，这些数据不是模型训练集的一部分。为了支持上述应用的构建，LangChain **数据连接 (Data connection)** 模块通过以下方式提供组件来加载、转换、存储和查询数据：Document loaders、Document transformers、Text embedding models、Vector stores 及 Retrievers。LangChain 数据连接模块的基本框架如图。




图 7.5 LangChain 数据连接模块框架图





大模型云服务：阿里云灵积与百炼平台



<https://dashscope.console.aliyun.com/model>

<https://help.aliyun.com/zh/model-studio>

模型服务灵积旨在通过灵活、易用的模型 API 接口，为 AI 开发者提供丰富可集成的模型能力，让 AI 应用开发更简单。阿里云的大模型服务平台百炼是一站式的大模型开发及应用构建平台。您可以通过简单的界面操作，在5分钟内开发出一款大模型应用，或在几小时内训练出一个专属模型，从而将更多精力专注于应用创新。







大模型云服务：百度千帆大模型服务与开发平台



<https://console.bce.baidu.com/qianfan/overview>





华南理工大学
South China University of Technology

06

大模型未来思考





一、技术创新推动大模型向多模态升级




2023年，点燃AI赛道的ChatGPT吸引了太多的目光，有所标的的情况下，中国的AI大模型也将重心放在语言大模型之上，聊天机器人应用遍地开花。然而就在2023年末，文生视频应用Pika的爆火以及谷歌发布多模态大模型Gemini，此外OpenAI旗下Sora所带来的亿点点震撼无不国产AI大模型的下一个发展阶段指明了方向，即多模态大模型。多模态大模型是结合文本、图像、音频等多种模态信息进行学习和理解的人工智能模型。而推动模型向多模态升级的关键则取决于相关技术的创新与发展。相比较于其他国家，中国在这些领域拥有更丰富的市场基础和数据资源，这或将成为国产AI大模型应用发展的优势。





一、技术创新推动大模型向多模态升级



2026.4.21 ChatGPT Images 2.0发布

1. 文字渲染能力质的飞跃

文字准确率高达~99%，中文、日文、韩文、印地文、孟加拉文等非拉丁文字首次做到近乎无误

可直接生成带文字的信息图、PPT 页面、地图、漫画对话框

2. 新增"思考模式" (Thinking Mode)

模型生成前会先推理再出图，类似 o1 的思维链

自动搜索网络辅助理解语义
会自我检查生成结果并修正



一、技术创新推动大模型向多模态升级



Seedance 2.0海外爆火 中国AI视频生成模型惊艳全球

字节跳动 (ByteDance) 2026. 2. 12 发布视频生成大模型Seedance 2.0。

Seedance 2.0 采用极致的稀疏架构来提升训练和推理效率，基于统一的多模态音视频联合生成架构，模型涌现出了强大的泛化能力，不仅能生成音画同步的高质量音视频，还可支持组合的多模态参考、视频编辑、视频延长等复杂功能。





二、大模型应用尚未跨越鸿沟



技术局限尚需突破方能释放更大价值

1

- 知识更新与自主学习能力，目前大语言模型仍然为静态数据驱动的学习范式，无法实现新知识的快速学习与迭代，尤其是涉及到时效数据与专有数据的场景下存在障碍，OpenAI正在通过Plugins生态来突破这一局限
- 垂直领域泛化能力，通用任务的卓越能力已经显现，但是进入垂直细分领域与知识体系下，大模型的性能与泛化能力仍然需要增强，行业大模型训练是当前挑战的破局之道之一
- 长期记忆能力，目前正在通过增大上下文容量、数据向量化，以及AI agent等多种方式探索突破

巨大的模型训练与推理算力等成本拉低效益比

2

- 训练与微调成本，该训练成本仅针对企业应用基础模型结合行业知识与数据集进行训练与微调的成本，并非基础大模型训练成本，与上述“垂直领域泛化能力”相对应，该成本仍然为行业知识壁垒显著的企业必须承担的成本，开源基础模型在一定程度上可以降低这一阶段的训练成本
- 推理成本，大模型在参数体量巨大的情况下，仍然存在较高的推理成本，这方面可以通过模型压缩与剪枝等技术的发展进一步降低
- 模型能力与业务场景的适应成本，这部分成本虽然由于人机交互方式的变化显著降低，但是前期仍然需要考虑提示工程在特定场景的磨合成本

安全合规可信应用底线尚需刚性保障

3

- 模型安全与可控制性问题，这是人工智能普遍面临的问题，大模型并不能幸免，包括模型攻防、数据注入等问题；同时，模型能力来自于“涌现”，需要进行模型能力，尤其是生成结果的可控制，方能进入到生产环境
- 对齐问题，既包括人工智能与人类社会价值观保持一致，也包括与不同国家价值观，不同类型企业经营以及商业法则相匹配等，前者最为关键，这也是目前最为关注的AI不受控制的风险之一，目前在通过RLHF与RLAIF不同方式来实现
- 隐私与数据安全问题，无论是大模型的训练推理，还是对话应用的过程中，都存在过多的隐私暴露与数据安全风险，这有赖于技术突破和监管合规的进一步建立



二、大模型应用尚未跨越鸿沟




行业应用场景导向，落地为先，倒逼基础能力升级

行业发展特点：

← 稳中求进

效率为先 →





三、重新思考大模型垂直落地挑战





四、重新思考对 AI 能源使用的担忧



在 2023 年 10 月出版的《焦耳》杂志上，一位研究人员估计，与大模型互动需要大约10倍于进行典型的网络搜索查询的能量，并从该估计推断得出结论：“最坏的情况表明，仅 Google 的 AI 就可以消耗与爱尔兰等国家（每年 29.3 TWh）一样多的电力。”

表 2：按任务划分的每 1,000 个查询的平均能耗³⁷

任务	kWh
文本分类	0.002
图像分类	0.007
对象检测	0.038
文本生成	0.047
Summarization	0.049
图像生成	2.907

表 1：训练各种 AI 模型的估计能源需求

模型	参数数量	芯片 (型号 x #)	Hours	能量 (MWh)	CO ₂ 排放量 (公吨)	估计来源
BERT	0.1 B	V100x64	79	1.5	0.7	Strubell 等人, 2019 ²²
GPT - 2	1.5 B	TPUv3x32	168	1.7*	0.7*	Strubell 等人, 2019 ²²
Llama 2	7B	A100x (不适用)	N / A	74*	31.2	Meta, 2023 ²⁴
Llama 2	13B	A100x (不适用)	N / A	147*	62.4	Meta, 2023
Llama 2	70B	A100x (不适用)	N / A	688*	291.4	Meta, 2023
LaMDA	137B	TPUv3x1024	1,385	451	26	Thoppilan 等人, 2022 ²⁶
GPT - 3	175B	V100x10000	355	1,287	552	帕特森等人, 2021 年 ²⁸
OPT	175B	A100x992	N / A	N / A	75	Zhang 等人, 2022 ²⁷
布卢姆	176B	A100x384	2,820*	433	24.7	Luccioni 等人, 2022 ²⁸
地鼠	280B	TPUv3x4096	920	1,151*	380	Rae 等人, 2022 ²⁹
PaLM	540B	TPUv4x6144	1200	3,436*	271.4	Chowdery et al., 2022 ³⁰
		TPUv4x3072	326			
GLaM	1.162B	TPUv4x (n / a)	N /	456	40	Patterson 等人, 2022 ³¹



五、大模型带领未来向左还是向右？



自2022年底ChatGPT横空出世、5天突破百万用户以来，有关AI与人类未来的讨论愈演愈烈，从产业界到学界，至今尚无定论。

黄仁勋(英伟达首席执行官)：**大模型正在降低应用开发门槛，所有应用都值得用大模型重做一次。**

潘云鹤(中国工程院院士)：**大模型对AIGC可提供有力支撑，进而对经济社会发展产生巨大的影响力。**

李彦宏(百度创始人、董事长兼CEO)：我们正处在全新起点，这是一个以大模型为核心的人工智能新时代，**大模型改变了人工智能，大模型即将改变世界。**

Percy Liang(斯坦福大学人类中心人工智能研究所主任)：**人工智能的「寒武纪爆炸」正在发生，人工智能将可以创造任何东西，从视频到蛋白质再到代码。**

大模型造福人类

大模型伤害人类

特斯拉 **Elon Musk**和苹果公司联合创始人**Steve Wozniak**在内的千余名科技领袖签署了一封公开信，**恳请研究人员在六个月内暂停开发比GPT-4更强大的人工智能系统。**

AI教父**Geoffrey Hinton**：相较于气候变化，**AI可能对人类的威胁“更紧迫”**。他之所以离开谷歌，就是为了完全自由地说出AI潜在的风险，向世人提出警示。

霍金：人类需要控制以人工智能为代表的新兴科技，以防止它们在未来可能对人类生存带来的**毁灭性威胁**。

杰夫·贾维斯(纽约城市大学新闻学教授)：“这是道德恐慌的一个典型标本：**呼吁暂停训练人工智能**。”

不管怎样，我们必须面对大模型时代的来临

DeepSeek是完美的颠覆式创新

颠覆式创新的四种方式

- 技术创新——让过去做不到的事情可以做到
- 体验创新——让使用起来很难很复杂的东西变得很简单易用
- 市场推广创新——让过去很难得到的东西可以得到
- 商业模式创新——让过去很昂贵的东西变得很便宜甚至免费

DeepSeek正是符合这四种创新模式的完美例子

25

DeepSeek颠覆式创新——技术创新

DeepSeek-R1突破了大模型Scaling Law瓶颈

大数据+大参数+大算力的 预训练Scaling Law的边际效应递减

- 人类构造的训练数据已达上限
- 万亿参数规模之后，继续增大参数规模难以带来质的提升
- 训练算力成本和工程化难度大幅上升

导致大模型悲观论
认为大模型的能力无法进一步得到质的提升

强化学习Scaling Law

- 利用合成数据解决数据用尽问题
- 利用self-play强化学习，在不增大参数规模前提下，大幅提升复杂推理能力
- 通过后训练算力和推理算力，在不增加预训练算力前提下，大幅提升模型性能

开辟强化学习新范式
从预训练Scaling Law转变为强化学习Scaling Law

26

DeepSeek颠覆式创新——技术创新

DeepSeek-R1和GPT-4o不是同一个物种

预训练大模型 → 推理大模型

- 预训练模型如GPT——疯狂读书，积累知识，Scaling law撞墙
- 预训练模型思考深度不够
- 算力见顶，变成少数巨头游戏

预训练大模型难以通往AGI之路

- 推理模型如R1——通过逻辑链条推导答案，分解规划，自我反思
- 预训练范式像是记忆和模仿，强化学习范式更像探索实践
- 记住很多东西只是基础，真正有价值的是融会贯通

R1找到了人类通往AGI的方向

27

推理能力获得突破的关键是学会了「慢思考」



- 长思维链强大的推理能力是真正人类智力的体现
- 预训练大模型是人记忆和学习的能力，推理模型是对复杂问题进行规划、分解、预测的能力，实现了真正的慢思考

DeepSeek颠覆式创新——技术创新

DeepSeek-R1是AI发展史上的重要里程碑

Alpha Zero时刻

- Alpha Go采用监督学习，使用人类棋谱训练
- Alpha Zero采用强化学习，自己跟自己对弈

ChatGPT时刻

- OpenAI ChatGPT大模型，通过预训练方式，实现涌现，理解人类语言 and 知识
- 诞生预训练Scaling Law

Deepseek-R1时刻

- o1采用强化学习，但训练复杂推理能力，技术未公开
- DeepSeek-R1探索出RL方法，且公开技术
- 诞生推理型Scaling Law

R1形成了新的AGI定律，加速了AGI发展

DeepSeek颠覆式创新——技术创新

技术上实现对美国的赶超

掌握通向AI下一阶段的方法论

- 美国人仍在遵循预训练Scaling law范式，走堆显卡路线，如“星际之门”计划
- 中国DeepSeek-R1的创新突破，诞生推理型Scaling Law，改写AI发展方向

30

DeepSeek颠覆式创新——用户体验

具备强大推理能力，思维过程更加缜密，智能性提升

DeepSeek在用户体验上实现了三件事

- 更加理解用户需求，降低Prompt要求
- 直接呈现思维过程，展现像真人一样思考的能力
- 可实时联网，把搜索能力与推理能力结合

用起来更像真人，写作能力更强，想象力更丰富

31

DeepSeek颠覆式创新——用户体验

DeepSeek-R1用户体验改善的作用 ——掀起新一轮AI科普教育

- R1在零广告投入下7天增长1亿用户，创最快应用破亿里程碑
- 把人工智能从不可用、凑合用，变成大家都能用、都爱用
- 推动市场加速发展，在中国用户、企业和政府彻底普及了一次AI
- 中国可能成为全球AI普及率、渗透率最高的国家，加速了中国爆发AI产业革命的步伐

认知决定行动，这场全民AI科普对推动中国AI发展功不可没

32

DeepSeek颠覆式创新——开源

开源改变行业格局，建立强大生态

- 开源战胜闭源；促使全球公司、开发者等转到开源
- 建立强大生态，成为全球人工智能根技术，无推广情况下各国政府、企业、云厂商纷纷接入，获得全球最大影响力
- 改变中美竞争格局：美国是闭源封闭垄断思路，中国领导开源文化，加速中国领先地位
- 中国人民使用的AI工具先进性已超过美国，普及率超过美国，使用AI人口超过美国总人口，且直接用上最先进的DeepSeek-R1

33

DeepSeek颠覆式创新——成本暴跌

成本的急剧降低

- DeepSeek可适配国产硬件，促进国产硬件发展
- DeepSeek的优化降低对推理硬件的要求，减少推理成本
- 训练成本降低，堆显卡模式受质疑，探索新思路，算法优化空间大
- 无需训练自己的基座模型，直接部署在DeepSeek上，不用重复发明轮子
- 公开蒸馏方法，帮助其他模型提升能力，实现了模型制造模型，犹如工业母机
- 小模型可部署在企业内电脑或一体机上，使用成本降低，形成分布式推理网络
- 技术门槛降低，可标准化、SaaS化部署，下载就能用

35

DeepSeek颠覆式创新——免费

惠及全球人民，科技平权，技术平民化

- 运营商、云服务可免费用，降低云服务成本
- 大型企业可使用多个DeepSeek，解决不同场景需求
- 中小企业免费部署，消除数字鸿沟
- 个人可以拥有自己的DeepSeek，可以成为超级个体
- 对于创业者得到世界最先进大模型，如虎添翼，和巨头站在同一起跑线上
- 很多发展中国家都能成为大模型玩家，实现人类命运共同体

36

面对全球大模型产业之争，要打赢「三大战役」

AGI之战

- 探索超越人类的超级人工智能AGI
- 不仅是科技之争，更是国运之争
- 不发展是最大的不安全，发挥举国体制优势，**打赢追赶之战**

大模型安全之战

- 大模型带来前所未有安全挑战
- 外挂式传统安全手段难以应对
- 应对模型安全新挑战，**打赢未雨绸缪之战**

应用场景之战

- 大模型是能力而非产品，结合场景才能发挥价值
- 中国拥有最完整的产业链、最全的工业门类、最丰富的场景
- 发挥场景优势，加速传统产业数转智改，**打赢弯道超车之战**

AGI是全球少数玩家的游戏，政府、企业、创业者更多创新的机会在应用之路

2023年是大模型之年
2024年是专业大模型之年
2025年是AI应用之年
AI应用 = DeepSeek+场景+智能体+知识库

66



致谢



- 本课件资源由广东省数字孪生人重点实验室团队设计与制作，在此表示感谢。
- 参考了部分在线资源，包括但不限于：
 - 《自然语言处理：大模型理论与实践》教材
 - 《大规模语言模型 从理论到实践》教材
 - 清华大学《AIGC发展研究资料2.0》.2024.01
 - <https://www.aigc.cn/free-aigc-industry-reports>
 - Natural Language Processing with Deep Learning. CS224N/Ling284
- 使用了部分AIGC工具或平台，包括但不限于：
 - 讯飞星火: <https://xinghuo.xfyun.cn>
 - 文心一言: <https://yiyan.baidu.com>
 - AIGC工具介绍平台: <https://hao.bidianer.com/>
 - 稿定设计平台: <https://ps.gaoding.com/#/>
 - 魔搭社区平台: <https://www.modelscope.cn/>
 - KimiChat: <https://kimi.moonshot.cn/>
 - 豆包: <https://www.doubao.com/chat/>



华南理工大学
South China University of Technology



谢谢!

THANK YOU FOR WATCHING!

