




华南理工大学
South China University of Technology

大模型时代的具身智能

授课老师：青春美
联系邮箱：qchm@scut.edu.cn



目 录



01 具身智能与大模型介绍

02 具身感知与环境理解

03 具身推理与任务规划

04 具身执行与技能学习

05 通用具身智能与未来方向

01

具身智能与大模型



具身智能进入大模型驱动与爆发期”

概念提出与理论奠基 (1950s-1990s)

- 形成符号主义、连接主义和行为主义三大学派
- 聚焦生物仿生，尝试通过模拟生物感官和运动能力构建机器人原型，奠定了“身体-环境-智能”三位一体的认知基础

技术积累与算法突破 (1990s-2022)

- 符号主义逻辑规则用于功能实现，深度学习算法推动环境感知与运动控制能力提升，模块化算法初步实现机器人自主决策
- “AI+机器人”范式初现，通过传感器技术和算力提升，机器人开始具备基础的环境交互能力

大模型驱动与爆发期 (2022年至今)

- 以ChatGPT为代表的大模型突破认知边界，赋予机器人语言理解、多模态交互和复杂任务规划能力
- 大模型积累知识，结合强化学习，推动机器人从单一功能向通用任务执行者进化
- 感知-决策-行动-反馈闭环形成，大模型统一视觉、语言、运动控制模块，实现跨场景泛化能力

1950s

艾伦·图灵首次提出
“具身智能”

能展示

逻辑规划算法+机器人的早期实验性尝试



1968年，斯坦福研究院(SRI)人工智能中心研制了世界上第一台移动机器人 Shakey



1973年日本早稻田大学研发会对话的人形机器人 WABOT-1

1990s

能模仿生物
行为

“行为主义”架构的仿生机器人研发获得关注



1991年，麻省理工学院制作一款模仿人头的机器人



1991年，六条腿机器人 Genghis可自主行走

2000s

基础环境交
互能力

深度学习、强化学习算法开始应用于机器人



1999年，日本索尼公司推出大型机器人爱宝



2002年，世界上第一台家用扫地机器人 Roomba量产



2009年，谷歌Prius自动驾驶汽车



2018年，Roomba i7+扫地机器人《时代》杂志评选为2018年改变人类生活的全球50大发明之一


2022

具备泛化性、思维链、高体验交互性

生成式AI涌现出泛化性、思维链、交互性通用机器人开始集中爆发



第三次浪潮 “具身大模型”






智能必须以自然语言为媒介么？



- 感知
- 抽象和理解 ✓
- 推理 ✓
- 使用语言 ✓
- 学习和形成知识 ✓
- 决策
- 行动
- ...





物理世界智能：空间智能与具身智能



- 感知 ✓
- 抽象和理解
- 推理
- 使用语言
- 学习和形成知识
- 决策 ✓
- 行动 ✓
- ... ✓



- 感知环境
- 运动导航
- 理解空间相对关系
- 操作物体
- 与三维世界交互
- 使用工具
- ...
- ...

Source: <https://medium.com/thedeephub/from-ancient-vision-to-modern-ai-the-evolution-of-intelligence-656d4e7fda86>



人工智能时代正迈入第三阶段——以具身智能为核心形态的物理AI的研究阶段，推动 AI 从数字世界走向真实物理；世界，加速与现实生产与服务场景的深度融合



物理 AI 是人工智能的下一个浪潮

相较于AIGC主要作用于数字内容世界
物理 AI 的本质在于让智能真正进入现实世界，成为生产力的一部分

阶段一：AIGC时代

以OpenAI的 Sora为例：



以一系列扩散模型为动力，生成性人工智能算法将句子转化为照片和视频

阶段二：功能型机器人

以机械臂挂衣服训练为例：



垂直单一场景
固定任务执行

阶段三：物理 AI 时代

以工业协作场景为例：



智能性 跨场景 低成本

“融合大脑认知理解与小脑运动控制的具身世界模型”是连接机器超越数据进入共享物理世界的纽带，将人工智能通过机器人行动与物理世界互动

实现具身智能的规模化落地

AI真正融入真实世界





具身智能的定义



- **定义**：一种**基于物理身体进行感知和行动**的智能系统，其通过**智能体与环境的交互**获取信息、理解问题、做出决策并实现行动，从而产生**智能行为和适应性**。
- **实质**：强调有**物理身体**的智能体通过与**物理环境**进行交互而获得智能的人工智能研究范式。

抽象的智能（围棋、文本处理、图像识别）

学习“有遮挡的物体识别”



有物理身体、**与环境进行交互**的具身智能

学习“**移开遮挡**并进行物体识别”



具身智能的研究意义



- ❑ **宏观意义：**具身智能的发展，可以推动我国工业生产智能化，为建设制造强国、网络强国和数字中国提供支撑，促进我国实体经济的发展。
- ❑ **科研意义：**“具身”意味着主动性和交互性，而这也是目前最接近“智能”的大模型所欠缺的。因此，我们认为，具身智能是通用人工智能未来的发展方向。
- ❑ **应用意义：**



家务机器人



四足机器狗



物流机器人



工业机器人



当前机器人的落地应用情况



医疗微创机器人



物流运输机器人



展厅服务机器人



家庭清洁机器人

工业机器人已经相对成熟，通过预定义的动作轨迹能够高效完成特定任务，但其能力局限于固定场景，难以实现跨任务与跨平台的泛化能力。



通用具身智能的初步形态



视频来自[Physical Intelligence](#)最新研究，当前具身智能系统已经能够基于感知信息完成多种操作任务，初步具备跨任务的泛化能力。那么，这种“通用操作能力”是如何实现的？其背后的关键技术是什么？未来又将如何进一步提升其泛化能力与实际应用水平？



产业界正在推动具身智能从demo走向产品



企业/机构	代表产品或系统	代表性进展
PI Physical Intelligence	π 系列通用操作模型	通过 统一模型 完成多种操作任务，展示跨任务泛化能力
Google DeepMind	RT-1、RT-2、 Gemini Robotics	推动 视觉-语言-动作 (VLA) 范式发展， 使机器人能够根据自然语言完成操作
F Figure AI	Figure 01 / Figure 02	面向通用 人形机器人 ，探索在 物流、 家庭与工业 场景中的 真实应用
T Tesla	Optimus	以大规模制造与通用 人形机器人 为目标， 强调 真实世界作业能力
U Unitree 宇树科技	H1 / G1	推动 低成本人形机器人 平台发展， 提升运动能力与研究可及性
D Agility Robotics	Digit	聚焦 仓储与物流 搬运场景， 推动机器人从展示走向落地



趋势表明：

产业界正在从“**单一场景 Demo**”
迈向“**面向真实任务的产品化系统**”。



智元：人形机器人量产工厂全面投产



核心变化：从产品发布走向量产体系，推动人形机器人进入真实产业场景。

产品

形成“远征 A2 / A2-Max + 灵犀 X1”等产品矩阵，覆盖工业制造、物流装配、科研教育与服务场景。

模型

以 EL-Brain 具身智能大脑为核心，强化 VLA 端侧能力，提升复杂语义指令响应与任务执行能力。

数据

采用 Sim-to-Real 与 Data-Engine 闭环，用仿真数据和工厂真机数据持续迭代模型。

落地

首座人形机器人量产工厂投产，应用重点指向新能源车制造、3C 电子组装与生物实验室等场景。

代表性产品/场景展示



远征 A2 团队表演

远征 A2 产品细节

企业案例“模型—数据—硬件—场景”的产品化闭环。

视频：[中央电视台CCTV-2《天下财经》栏目揭秘智元人形机器人量产工厂和数采工厂](#)

总结：智元案例体现了“产品矩阵 + 具身大脑 + 数据闭环 + 量产工厂”的产业化路径。



宇树科技：推进低成本人形机器人平台化



核心变化：通过低成本硬件平台和运动控制优势，降低人形机器人进入科研、教育与开发场景的门槛。

产品

R1 面向消费级和入门场景，G1 面向科研教育与开发，H1 强化高性能运动控制。

模型

UnifoLM-WMA 世界模型路线强调环境理解、物理规律建模与动作生成，支撑机器人自主交互。

数据

通过仿真合成与真机回传数据构建低成本数据飞轮，推动模型能力持续更新。

生态

依托量产能力、供应链和开发者生态，推动人形机器人从展示型产品走向平台型产品。

代表性产品/场景视频展示



Unitree As2

小巧身躯 行业性能

动力性能 $\approx 2 \times \text{Go2}$

企业案例：“模型—数据—硬件—场景”的产品化闭环。

总结：宇树的代表性意义在于“低成本硬件平台 + 量产能力 + 开发者生态”。



优必选：Walker S2 启动量产交付



核心变化：面向汽车制造等工业场景，从演示验证进入批量交付与真实工厂部署。

本体

Walker S2 进行多项本体升级，强化动态平衡、灵巧操作、全身协调与复杂环境适应能力。

续航

搭载热插拔自主换电系统，可支持 7×24 小时连续作业，提升工业场景可用性。

模型

Co-Agent 协作智能体面向工业任务，融合感知、规划、工具调用与异常处理能力。

交付

已进入汽车制造等真实工厂场景，目标从小批量验证走向百台级乃至更大规模部署。

代表性产品/场景展示



量产交付现场



本体多项升级



自主换电

企业案例：“模型—数据—硬件—场景”的产品化闭环。

007天选打工人，优必选新一代工业人形机器人Walker S2正式发布！[哔哩哔哩](#) [bilibili](#)

总结：优必选案例说明，工业场景更关注稳定性、连续作业、批量交付与运维闭环。



机器人智能发展的未来：从虚拟智能走向物理智能



- 1956年—20世纪60年代初，使用人工智能做符号推理，进行**数学证明**
- 20世纪60年代—70年代初，启发式的搜索算法能力有限
- 20世纪70年代初—80年代中，构建**专家系统处理医疗、化学、地质等特定领域应用**
- 20世纪80年代中—90年代中，专家系统需要海量的专业知识，实用价值有限
- 20世纪90年代中—2010年，机器学习算法处理实际问题
- 2011年之后，深度学习算法用于**图像、文本、语音等信息处理**
- 2022年之后，可以处理通用任务的**大模型**
 - ✓ 一定的自主能力
 - ✓ 一定的泛化能力（通用能力）

前面这些企业案例表明，具身智能正在从展示性 Demo 走向真实产品。但要真正完成复杂现实任务，仅有大模型的通识理解还不够，机器人还必须具备对物理世界的持续感知、任务推理、动作执行与环境反馈能力。



大模型与人形机器人结合形成智能机器人



- 上个世纪对未来人工智能的幻想，主要表现为智能人形机器人，但目前人工智能技术仍然停留在电脑屏幕，没有以实体的方式进入物理世界
- 目前智能程度最强的大模型，与目前最先进的人形机器人，能否结合形成智能机器人？



GPT - 4

Unitree G1

¥9.9万元起


人形智能体 AI化身





A general pipeline of Embodied Intelligence

具身智能的通用流程





构建智能机器人（以人形机器人为例）




硬件方面:

2D视觉信号或
3D点云信号

机器人躯体的
所有硬件结构

触觉信号或
力反馈信号

位姿信号



语音信号



软件及算法方面:

大脑

- 收集所有传感器采集的环境信息和自身状态。
并综合分析当前所有状态（具身感知）
- 根据当前状态，对自身下一步的运动做出决策
和规划（具身推理）

小脑

- 向下位机下发送运动指令（具身执行）
（形式包括代码、技能库API、关节旋转角度等）
- 下位机通过运控技术执行指令



硬件基础已具备：成熟的机器人本体与传感器



硬件方面：


2D视觉信号或
3D点云信号

语音信号

机器人躯体的
所有硬件结构

触觉信号或
力反馈信号

位姿信号



我们已经能造出具备基本性能的机器人硬件和高精度的传感器



运控技术已成熟：稳定的“小脑”



软件及算法方面：

仍存在诸多待优化问题

大脑

- 收集所有传感器采集的环境信息和自身状态。
并综合分析当前所有状态（具身感知）
- 根据当前状态，对自身下一步的运动做出决策
和规划（具身推理）

小脑

- 向下位机下发送运动指令（具身执行）
（形式包括代码、技能库API、关节旋转角度等）
- 下位机通过运控技术执行指令

运控技术相对来说已经较为成熟



案例拆解：一个完整的感知-推理-执行闭环



机器人视觉传感器信号



- 收集所有传感器采集的环境信息和自身状态。并综合分析当前所有状态 **(具身感知)**

机器人采集视觉信息，分析出应对咖啡进行清理

- 根据当前状态，对自身下一步的运动做出决策和规划 **(具身推理)**

- 向下位机下发送运动指令 **(具身执行)**

生成机器人的运动轨迹，包括手臂如何运动、手掌如何运动、腿部如何运动等

- 下位机通过运控技术执行指令

机器人执行

清理咖啡需要如下几步：-

1. 扶正杯子并拿起杯盖
2. 找到抹布
3. 用抹布擦拭地面
4. 将抹布放回
5. 将杯子和杯盖扔掉 -!



挑战一：具身感知—从 **识别** 到 **理解** 的鸿沟



- 收集所有传感器采集的环境信息和自身状态。并综合分析当前所有状态（具身感知）

多模态大模型LLaVA已能做到：



请标记出抓握图 中插着花的花瓶的位置




但实际场景远比此复杂



这是什么？如何打开它？



人的一些手势是什么意思？



3D点云图如何理解？



挑战二：具身推理—欠缺物理世界的决策能力？



➤ 根据当前状态，对自身下一步的运动做出决策和规划（具身推理）

来看目前大模型在一组数据集中的表现：

问题：根据视频中显示的当前状态，请问接下来我应当进行那个动作来制作拿铁？

Question: Considering the progress shown in the video and my current observation in the last frame, what action should I take next in order to make coffee with milk (*Task Goal*)?



Candidate Action Plans:

- A. pick milk bottle B. open fridge
C. put down mug D. close milk bottle

Answer: D

候选：A. 拿起牛奶瓶 B. 打开冰箱 C. 放下马克杯 D. 盖上牛奶瓶 答案：D

EgoPlan比赛任务样例



挑战三：具身执行—从 规划 到 控制 的转化



► 向下位机下发送运动指令（具身执行）（形式包括代码、技能库API、关节旋转角度等）

- 对于生成关节旋转角度形式的运动指令：

多模态大模型




拿起可乐



关上抽屉

扩散小模型



转移红色方块


	执行的成功率	执行的流畅度	泛化能力
多模态大模型	较低（60%~70%）	不够流畅	物品泛化
扩散小模型	较高（90%以上）	流畅	位置泛化或无泛化

技能泛化
场景泛化
物品泛化
位置泛化
无泛化
泛化能力 ↓

- 对于生成技能库API或代码API形式的运动指令：现实世界场景过于复杂，构建完整的技能库几乎不可能



具身智能核心闭环：感知、推理、执行



02

具身感知与环境理解





具身感知



机器人需要从视觉场景中识别物体、位置、空间关系和可操作区域，并将这些信息转化为后续任务推理与动作执行的依据。



具身感知：四类感知对象与典型应用场景



□ 机器人需要具备环境感知能力，依据感知对象的不同，可以分为四类：

□ 物体感知

□ 几何形状、铰接结构、物理属性

□ 场景感知


□ 场景重建 & 场景理解

□ 行为感知

□ 手势检测、人体姿态检测、人类行为理解

□ 表达感知

□ 情感检测、意图检测



□ 重点需要感知能力的机器人：服务机器人、人机协作场景下机器人、社交导航机器人、环境探索机器人



具身感知：从信息采集到下游任务的通用流程



具身感知的过程主要包括以下几步：





物体感知：3D物体的几何、结构与物理属性



□ 对于3D空间中的物体，有必要感知其：

- 几何形状
- 铰接结构
- 物理属性



Point Cloud





Mesh



Volumetric



Projected View
RGB(D)



[1] https://adioshun.gitbooks.io/deep_drive/content/intro3d-cloudpoint.html

[2] Xu et al. UMPNet: Universal Manipulation Policy Network for Articulated Objects. 2022 RA-L

[3] Dong et al. Tactile-RL for Insertion: Generalization to Objects of Unknown Geometry



物体感知：常见3D几何表示与编码方法




数据格式	描述	来源	编码方法
点云	一组点，每个点包括3D坐标和特征	LiDAR	PointNet, PointNet++
网格	基于点、线、面（三角形）表示物体表面	CAD模型、点云转换	MeshNet
体素	一组立方体，每个立方体包括坐标、体积和特征	点云转换	VoxelNet, DeepSDF, Occupancy Network
深度图	为2D图片每个像素匹配一个深度	双目立体相机、结构光相机、ToF相机	GVCNN



物体感知：基于PointNet的点云建模方法



- 基于多层感知机，编码点云数据，可以获得点云整体的表示、每个点的表示



- PointNet为点云数据编码的经典方法，针对其难以捕捉局部特征的缺点又提出了改进版本PointNet++


[1] Qi et al. Pointnet: Deep learning on point sets for 3d classification and segmentation. 2017 CVPR
[2] Qi et al. Pointnet++: Deep hierarchical feature learning on point sets in a metric space. 2017 NIPS



物体感知：基于PointNet的点云建模方法



面向室内场景点云实例分割的方法




[2] Sun. Qing. et al. Superpoint Transformer for 3D Scene Instance Segmentation. 2023 AAAI



物体感知：基于MeshNet的网格建模方法



- 基于MLP和CNN，编码每个面的空间特征和结构特征，最后获得整体的物体外形表示




[1] Feng et al. Meshnet: Mesh neural network for 3d shape representation. 2019 AAAI



物体感知：基于VoxelNet的体素建模方法



- ❑ 首先将点云体素化，然后使用基于MLP和CNN的网络编码体素
- ❑ PointNet、MeshNet、VoxelNet对3D数据的卷积编码方式，类似于CV中对2D图片的编码





[1] Zhou et al. VoxelNet: End-to-End Learning for Point Cloud Based 3D Object Detection. 2018 CVPR



物体感知：基于DeepSDF的连续几何表示



- 之前PointNet、MeshNet和VoxelNet将3D数据视为离散的单元进行卷积编码
- DeepSDF训练神经网络，拟合一个连续函数：以体素坐标为输入，输出其离最近物体表面的距离。这个连续函数同样蕴涵物体的几何形状信息。



为使训练的SDF不局限于一个物体，引入Code作为物体形状标签


[1] Park et al. DeepSDF: Learning Continuous Signed Distance Functions for Shape Representation. 2019 CVPR



物体感知：基于Occupancy Networks的场建模



- 类似于DeepSDF使用一个连续的函数来表示整个空间的体素分布情况，Occupancy Network同样使用神经网络来拟合一个连续的函数，该函数以体素坐标为输入，输出该坐标处体素出现的概率



[1] Mescheder et al. Occupancy Networks: Learning 3D Reconstruction in Function Space. 2019 CVPR




物体感知：几何理解的下游任务—6D位姿估计



- ❑ 位姿估计任务是预测一个物体在3D空间中的位姿，包括三自由度的平移，与三自由度的旋转，或者可视为物体的位置与朝向
- ❑ 根据是否物体的CAD模型是否已知，位姿估计可以分为：
 - ❑ 实例级别的位姿估计：需要物体CAD模型，从而获取平移的中心和旋转的初始朝向
 - ❑ 类别级别的位姿估计：不需要物体CAD模型

中点在哪里？正面（初始朝向）是哪？没有这些信息如何知道平移和旋转的情况？





通过“见过”训练集中一个类别下很多物体的中心点和初始朝向，从而可以在测试时对未见过的物体“预设”一个中心点和朝向，然后估计位姿



物体感知：类别级位姿估计中的统一坐标空间



- 物体上每一个点对应一个 (x, y, z) ，代表该点在标准空间中的位置。给定任意一个图片，分割其中物体，然后在每个像素上预测 (x, y, z) 。mask上的 (x, y, z) 就代表这个物体在标准空间中的朝向，结合深度可得位移
- CNN预测：类别、分割Mask、标准空间Map



[1] Wang et al. Normalized Object Coordinate Space for Category-Level 6D Object Pose and Size Estimation. 2019 CVPR




场景感知：从空间布局到语义关系的环境理解



- ❑ 定义：场景感知是通过实现与场景的**交互**来理解现实世界场景
- ❑ 意义：赋予机器人理解周围环境并与之交互的能力
- ❑ 内核：
 - ❑ 对空间布局的**几何理解**
 - ❑ 对场景中物体的**语义理解**
- ❑ 组成：
 - ❑ 粗粒度：场景中物体的组成、物体的语义、物体的空间关系
 - ❑ 细粒度：场景中每个点的精确空间坐标和语义
- ❑ 具体形式：点云、地标、拓扑图、场景图、隐表示



场景感知：从原始信息到场景认知的研究框架





场景感知：粗粒度与细粒度场景信息构成




- 场景信息组成
 - 粗粒度
 - 场景中物体的组成
 - 场景中物体的语义
 - 场景中物体的空间关系
 - 细粒度
 - 场景中每个点的精确空间坐标和语义
- 场景信息提取方式
 - 构建场景表示
 - 点云、地标、拓扑图、场景图及隐式表示



场景重建：基于SLAM的定位与建图方法



- ❑ 场景重建的核心技术是SLAM（同步定位与映射）
- ❑ SLAM是机器人在未知环境下移动，逐步构建周围环境的连续地图，并同时估计其在地图中位置的技术
- ❑ 传统的SLAM技术：
 - ❑ 滤波算法
 - ❑ 非线性优化技术
- ❑ 引入深度学习后的SLAM：
 - ❑ 新方法
 - ❑ 新任务
 - ❑ 新表示




[1] Durrant et al. Simultaneous localization and map: part I. 2006 RAM
[2] Taketomi e al. Visual SLAM algorithms: A survey from 2010to 2016. 2017 IPSJ



场景重建：从传统SLAM到主动SLAM任务



- 传统SLAM
 - 机器人由人类控制，或使用预定义的航点，或基于给定的路径规划算法进行导航
- 主动SLAM
 - 机器人可以自主行动，以实现更好的场景重建和定位
 - **主动映射**：机器人自主选择下一步视点，以获得更好的观察，进行环境探索
 - **主动定位**：机器人自主规划路径，旨在解决模糊位置定位，而不仅仅是导航







场景理解：物体识别、空间关系与时序变化检测



- 理解场景信息是场景感知的重要组成部分
- 高效的理解过程（例如分割、识别和检测）为智能体理解复杂环境
- 场景理解不仅包括**物体的识别**，还包括物体之间的**空间关系**和**场景帧之间的时间变化**



物体识别



空间关系推理



时序变化检测



行为感知：面向人的手势、姿态与行为理解




- 不同于对物体、场景的感知，对人的感知需要人的行为，包括：
 - 手势识别
 - 身体位姿识别
 - 人类行为理解
- 机器人对人的行为感知有助于人机交互应用：
 - 社交导航
 - 自动驾驶
 - 人机协作装配



行为感知：手势识别的基本流程与方法



- ❑ 手势识别是识别图片中人体手势的类别，一般以分类任务的形式出现
- ❑ 手势识别的一般流程：
 - ❑ 使用RGB相机或RGBD相机获取图片
 - ❑ 手势的分割与检测：基于肤色、轮廓、深度信息等信息检测图中手势区域和手的关节点
 - ❑ 手势识别：在分割检测结果的基础上进行手势分类





行为感知：人体姿态检测的关键任务与策略



- ❑ 人体姿态检测需要预测2D图像或3D数据中人体的关节点
- ❑ 单人的姿态检测，可以使用回归的方法或基于热图的方法
 - ▣ 回归：直接基于图片预测关节点位置
 - ▣ 热图：预测每个像素点属于某个关节的概率，进而基于概率决定关节位置
- ❑ 多人的位姿检测，可以分为自顶向下和自底向上
 - ▣ 自顶向下：识别图中人体后分别进行姿态估计
 - ▣ 自底向上：首先检测图中所有关节点，然后进行组合





行为感知：面向社交导航与自动驾驶的轨迹预测



- ❑ 人体姿态估计的结果可以用于预测人类下一步动作，这有助于机器人进行决策
- ❑ 社交导航机器人基于人体位姿预测人类下一步方向，从而选择移动方向
- ❑ 自动驾驶决策时同样需要预测人类移动轨迹





[1] Narayanan et al. ProxEmo: Gait-based Emotion Learning and Multi-view Proxemic Fusion for Socially-Aware Robot Navigation. 2020 IROS



行为感知：人机协作装配中的防碰撞预测



- 除预测人类移动轨迹用于社交导航场景和机器人场景外，在工业场景中人机协作进行装配任务同样需要预测人类未来行为轨迹，以免机器人和人发生碰撞



[1] Zhang et al. Recurrent neural network for motion trajectory prediction in human-robot collaborative assembly. 2020 CIRP.



行为感知：从基础动作识别到复杂行为理解




- ❑ 人类行为理解即通过检测姿势、运动和环境线索来推断其正在进行的行为
- ❑ 该领域超越了对基本动作的识别，还包括对复杂行为的分析
 - ❑ 人物交互
 - ❑ 多人协作
 - ❑ 动态环境中的自适应行为
- ❑ 最近的进展侧重于通过更深入的语义理解来建模这些行为




行为感知：MotionGPT的动作—语言统一建模



- 统一的动作-语言生成预训练模型MotionGPT
 - 将人类动作视为一种外语，引入自然语言模型进行动作相关生成
 - 功能包括：给定文本生成动作，给定动作生成文本，动作扩增，文本动作描述生成



MotionGPT的演示



MotionGPT的方法总览


[1] Jiang et al. Motiongpt: Human motion as a foreign language. 2024 NIPS




行为感知：MotionLLM的人类动作与视频理解



- 可理解人类动作和视频的大语言模型MotionLLM
 - 收集并构建了一个名为MoVid的大规模数据集和MoVid-Bench的基准测试
 - 提出了一个结合视频和动作数据的统一框架，通过大语言模型来理解人类行为



MotionLLM的基本架构



MotionLLM的两阶段训练

[1] Chen L H et al. MotionLLM: Understanding Human Behaviors from Human Motions and Videos. 2024 arXiv preprint arXiv:2405.20340



表达感知：基于表情与语音的情感意图识别



□ 机器人想获取人类的情感和意图，可以通过人的：


- 面部表情
- 语音
- 上述两种模态信号的结合



面部表情、语音



情感、意图





表达感知：人机交互中的应用价值与典型场景



- 表达感知的研究意义：
 - 增强任务协作能力，从而提升机器人在**人机交互**中的**自然性和有效性**
 - 更准确地感知用户的情感变化与意图，从而显著提高用户**体验和满意度**
 - 可能应用的实际场景：陪伴老年人、智慧家居、工业协作等



陪伴机器人



智慧家居



工业机器人



表达感知：面部情感识别的特征与挑战



- ❑ 面部表情数据采集一般是通过摄像头设备进行采集
- ❑ 特征提取
 - ❑ 如几何特征（关键点坐标）、纹理特征（局部二值模式，LBP）和动作单元（Action Units, AU）等
- ❑ 面部情感识别的主要挑战
 - ❑ **复杂环境下的面部情感感知**
 - ❑ 可能包括光照变化、姿态变化、遮挡和不同的背景场景等，对准确性和鲁棒性要求更高



[1] Ma F et al. Facial expression recognition with visual transformers and attentional selective fusion. 2021 IEEE Transactions on Affective Computing



表达感知：面向复杂环境的FER鲁棒建模方法



□ Visual Transformers与特征融合

- 针对在**野外**（即非实验室控制环境）中的FER任务，能够处理遮挡、不同的头部姿势、面部变形和运动模糊等复杂情况

□ 区域注意力网络RAN

- 旨在解决现实世界中FER的**遮挡鲁棒性和姿态不变性**问题
- 构建了若干具有姿态和遮挡属性的**野外FER数据集**，解决了对应领域数据集缺乏的情况

□ 边缘AI驱动（Edge-AI-driven）的FER框架

- 该框架可以在**低功耗设备**上实现实时的面部表情识别，确保在**有限的计算资源和能源消耗**下，仍能保持高精度
- 这对于**智能穿戴设备、智能手机和远程医疗**等应用场景尤为重要

[1] Ma F et al. Facial expression recognition with visual transformers and attentional selective fusion. 2021 IEEE Transactions on Affective Computing

[2] Wang K et al. Region attention networks for pose and occlusion robust facial expression recognition. 2020 IEEE Transactions on Image Processing

[3] Wu Y et al. Edge-AI-driven framework with efficient mobile network design for facial expression recognition. 2023 ACM Transactions on Embedded Computing Systems



表达感知：语音情感识别与多模态情感融合



□ 语音情感感知：

- 从人类的语音信号中提取音高、音调、节奏、音色等特征作为输入
- 表示声音频率内容的图像形式：梅尔频谱图（Mel-spectrogram）及其梅尔频率倒谱系数（MFCC）
- 通过理解说话者的情感状态，系统能够做出更加人性化和智能化的响应
- 在客服机器人、智能助理、心理健康监测等领域有广泛的应用

□ 多模态情感感知：

- 通过结合多种不同类型的数据源，如语音、面部表情、身体语言、文本等，来识别人类的情感状态
- 在本节特指结合人类的**面部表情和语音**来进行情感感知
- 相比单一模态的情感识别，多模态方法能够从不同维度捕捉情感特征，提高识别的**准确性和鲁棒性**



表达感知：从情感识别到人类意图推断



- ❑ 表达感知不仅可以帮助机器人获知用户的情感变化，还可以辅助机器人进行对人类**意图的推断**
- ❑ 意图推测的精确度对于提升机器人在人机交互中的表现、提高用户体验和满意度具有重要意义
- ❑ 未来的机器人一定是能够“理解”人的想法的机器人



机器人（基于OpenAI大模型）听到人类说“我饿了”之后，准确领悟到了人类的意图，选择了苹果放到盘子中



内嵌谷歌PaLM-SayCan模型的机器人正在厨房内帮人类拿零食，该模型能够帮助机器人更好地理解自然语言并执行复杂任务



表达感知：指代表达理解与用户意图定位




- ❑ 指代表达是指在特定上下文中生成**描述性语言或表达**，以便清晰地指代某个特定对象或实体
- ❑ 意图推断与指代表达之间的关系：
 - ❑ 指代表达的理解是意图推测的重要应用形式之一
 - ❑ 在理解指代表达的过程中，机器人需要推测用户的意图，以确定用户所指代的具体对象或位置
- ❑ 指代表达的研究方向
 - ❑ 指代表达的生成（从人类的角度出发）
 - ❑ 指代表达的理解（从机器人的角度出发）
- ❑ 最常见的指代表达形式为接收人类的**语言指令**来完成人类想要其完成的操作




表达感知：引用表达式理解的视觉语言推理方法



- ❑ 动态图注意力网络DGA
 - ❑ 首次从语言驱动视觉推理的角度探索了引用表达式理解问题，显著提高了识别复杂引用表达式的能力
- ❑ 模块化注意力网络MAttNet
 - ❑ 通过模块化框架关注相关单词和视觉区域，并动态计算整体匹配分数，显著提高了机器人的理解性能。



指代表达理解的动态图注意力网络 (DGA) 的整体架构



模块化注意力网络(MAttNet)的示意图

- [1] Yu L et al. MAttNet: Modular attention network for referring expression comprehension. 2018 Proceedings of the IEEE conference on computer vision and pattern recognition
- [2] Yang S et al. Dynamic graph attention for referring expression comprehension. 2019 Proceedings of the IEEE/CVF International Conference on Computer Vision

03

具身推理与任务规划





Robotic Control via Embodied Chain-of-Thought Reasoning

Michał Zawalski, William Chen, Karl Pertsch,

Oier Mees, Chelsea Finn, Sergey Levine

机器人面对真实任务时，不能直接从图像跳到动作，而需要结合当前观察、任务目标和环境约束，先形成中间推理过程。例如，它需要判断“当前场景是什么、目标物体在哪里、下一步应该先做什么”，再把任务分解为可执行的动作序列。



任务规划：从自然语言指令到可执行技能序列



- ❑ 任务规划 (Task Planning) 是具身智能的核心任务之一 (另一个核心是技能学习)，将抽象的非可执行人类指令转换为具体的可执行技能
- ❑ 完成人类指令只需要两步：人类指令分解为机器人可执行的技能，执行技能



我渴了，可以帮我拿杯水放桌上吗



移动到水瓶附近 (MoveTo, bottle)

拿起水瓶 (PickUp, bottle)

移动到桌子附近 (MoveTo, table)

把水放到桌上 (Put, bottle, table)



任务规划：技能集假设与轨迹规划的区别



- 任务规划的假设：机器人有一组可执行技能集
 - 潜在含义一：机器人并非万能，技能集之外的不能执行
 - 潜在含义二：需要显式的指定技能，“你先拿捏住”这种自然语言要解析才能被执行
- 与轨迹规划的区别（Motion Planning）
 - 任务规划：将人类指令分解为给定技能集的**离散技能序列**
 - 轨迹规划：为机器人执行操作技能生成**连续7-DOF轨迹**
- 难点：
 - 需要理解人类指令
 - 需要理解周围环境
 - 需要理解技能集合




任务规划：大模型作为语言到PDDL的转换器



- 大模型作为转换器
- LLM+P，用LLM将状态信息描述成PDDL语言再进行规划，取代以往需要人工针对实际问题书写PDDL语言对任务进行建模

PDDL 是传统自动规划领域常用的结构化规划语言，可以明确表示对象、状态、动作前提和动作效果。




[1] Liu et al. LLM+P: Empowering Large Language Models with Optimal Planning Proficiency. 2023 arXiv.




任务规划：大模型作为零样本规划器



- 大模型作为规划器
- 可以zero-shot进行任务规划



[1] Huang et al. Language Models as Zero-Shot Planners: Extracting Actionable Knowledge for Embodied Agents. 2022. arXiv.





- Mobile Manipulation**

Human: Bring me the rice chips from the drawer. Robot: 1. Go to the drawers, 2. Open top drawer. I see . 3. Pick the green rice chip bag from the drawer and place it on the counter.

Visual Q&A, Captioning ...

Given , Q: What's in the image? Answer in emojis. A: 🍎🍌🍇🍓🍏🍓

PaLM-E: An Embodied Multimodal Language Model

Given ... Q: How to grasp blue block? A: First, grasp yellow block

Large Language Model (PaLM)

Control

Task and Motion Planning

Given Q: How to grasp blue block? A: First grasp yellow block and place it on the table, then grasp the blue block.

Tabletop Manipulation

Given Task: Sort colors into corners. Step 1. Push the green star to the bottom left. Step 2. Push the green circle to the green star.

Language Only Tasks

Here is a Halku about embodied language models: Embodied language models are the future of natural language

Q: Miami Beach borders which ocean? A: Atlantic. Q: What is 372 x 18? A: 6696. Language models trained on robot sensor data can be used to guide a robot's actions.


《具身大模型关键技术与应用-5-17》



任务规划：结合技能可行性评分的语言规划方法



- 技能小模型为技能提供可行性评分，为大模型任务规划提供参考
- 该工作经典之处在于，大模型难以判断一个技能的可执行性，没有grounding到物理世界



[1] Ahn et al. Do As I Can, Not As I Say: Grounding Language in Robotic Affordances. 2022. arXiv.



任务规划：结构化、可行性与有用性三大关键问题



□ 任务规划的关键问题

□ 结构化

□ 大模型输出自然语言，需要解析后才能被程序使用，可能出现未精准匹配，无法映射为单技能的情况

□ 可行性

□ 结构化的动作不具备执行的可行性，例如操作不存在的物体，物体离机器人太远，物体不支持操作

□ 有用性

□ 即使结构化的动作、被操作物体可被执行，它们还应该有助于完成任务的

□ 任务规划的两种关键信息

□ 观测信息


□ 场景描述、物体列表、图片。不同类型的观察信息有不同的特点

□ 反馈信息

□ 即使通过可行性检测，机器人仍有可能执行技能失败，此时反馈信息很重要



任务规划：通用执行模型出现后的规划范式变化






具身导航：从传统导航到LLM结合导航的发展路径



- 具身导航 (Embodied Navigation)：智能体在3D环境中移动完成导航目标
- 目标的形式可以是点、物体、图像、区域；目标可以结合声音、自然语言指令、人类先验







具身导航：基于规则的定位、规划与避障方法



- ❑ 早期的具身导航，通过构建一系列基于规则的组件和算法，实现有效的环境感知、定位、路径规划和避障
- ❑ 关键技术包括：



SLAM建图技术



路径规划算法



避障算法

- ❑ 优点：鲁棒性强、计算效率高、实现方法简单、确定性高
- ❑ 缺点：适应性差、依赖地图，建图成本高、缺乏学习能力



具身导航：基于学习的视觉导航与视觉语言导航




- ❑ 基于学习的导航利用深度学习与强化学习技术，提高模型对复杂环境和新场景的泛化能力
- ❑ 不同于传统算法依赖预定义的规则和手工设计的特征，基于学习的导航算法从大量数据中学习环境特征和导航策略，实现强自适应性和高灵活性
- ❑ 按照输入模态可以分为：
 - ❑ 视觉导航 (Visual Navigation)
 - ❑ 视觉语言导航 (Vision-Language Navigation)



具身导航：视觉导航中的环境理解与路径规划



- ❑ 视觉导航是基于学习的导航的一个重要分支，它依靠计算机视觉来理解环境信息并做出导航决策
- ❑ 视觉导航面临的主要挑战包括：
 - ❑ 如何从视觉输入中提取有用的信息
 - ❑ 如何理解和记忆环境的布局
 - ❑ 如何规划路径



非端到端的方法



端到端的方法



具身导航：视觉语言导航的任务定义与技术演进



- ❑ 视觉语言导航是通过通过自然语言指令和视觉图像进行导航的任务，其目标是开发一种能够与人类进行自然语言交流并在现实3D环境中导航的具身智能体
- ❑ 视觉语言导航可以根据时间节点分为
 - ❑ 大模型之前的视觉语言导航
 - ❑ 主要通过RNN, LSTM, Transformer等网络来提取命令中的语义信息
 - ❑ 结合LLM的具身导航
 - ❑ 利用大模型作为辅助来帮助规划器输出规划或者大模型直接作为规划器来输出规划



具身导航：大模型增强视觉语言导航的方法类型



- 大模型的出现显著改变了视觉语言导航领域的发展
- 大模型，或者视觉语言联合预训练模型如CLIP等，为该领域带来了新的方法和思路，使得视觉语言导航系统变得更加智能和鲁棒
- 根据大模型的作用不同，这里我们将这些工作分为：
 - 视觉语言联合预训练模型的应用
 - 大模型基于构建的地图输出规划
 - 大模型基于图片转换的文本描述输出规划




具身推理：大模型推理能力的优势与局限



- ❑ 在推理任务上，大模型具有非常显著的优势，其相比于小模型推理能力有了显著的提升
- ❑ 基于大模型构建具身智能体是一个非常自然的选择，但也存在许多问题：
 - ❑ 推理速度慢，推理开销大
 - ❑ 生成结果不够稳定
 - ❑ 复杂的Agent结构难以维护，且时间开销会更大



具身智能闭环：感知、推理、执行的整体关系



04

具身执行和技能学习





具身执行：从任务计划到真实操作



机器人执行并不是简单“动一下机械臂”，而是需要在感知环境、理解任务和规划步骤的基础上，将高层计划转化为连续、稳定的动作控制。以做饭任务为例，机器人需要识别物体位置，判断操作顺序，并完成抓取、倒入、翻炒等连续动作。

核心作用：将“感知—推理”的结果转化为真实世界中的行动。



技能学习：模仿学习与强化学习两类方法



- ❑ 模仿学习：收集专家演示数据，用神经网络拟合
- ❑ 强化学习：设计奖励函数，机器人通过交互学习行为策略
- ❑ 行为策略：给定技能描述，在当前观察下，选择动作执行

- ❑ 其本质差别在于
 - ❑ 模仿学习从样例中学习；机器人学习过程中**不**与环境进行交互
 - ❑ 样例一般也是提前收集的交互样例数据，也可以算广义的交互学习
 - ❑ 强化学习从交互中学习；机器人学习过程中**与**环境进行交互



模仿学习：演示数据采集方式与数据组成




- ❑ 模仿学习主要理解并复制人类或机器人行为
- ❑ 数据采集方法
 - ❑ 基于通过摄像头捕捉的专家演示
 - ❑ 摄像头通常安置在执行主体的手腕、头部或侧面
- ❑ 演示数据来源
 - ❑ 动觉教学（手动接触）、VR、手柄、GUI界面控制等
- ❑ 演示数据组成
 - ❑ 收集到的专家演示包括一系列观察和行动
 - ❑ 示范数据展示了末端执行器或关节的位置或者速度
- ❑ 学习策略与目标
 - ❑ 核心是学习行为策略，将观察映射到连续动作空间



模仿学习：从图像编码到动作预测的整体框架



- ❑ 模仿学习可以分为两部分：**对图像的编码，图像表示映射到动作**
- ❑ 一般而言，图像的编码器使用预训练的视觉编码器更好，如果只使用样例数据集训练编码器会导致实际应用中缺乏泛化性
- ❑ 机器人的动作空间一般是连续的。对于连续动作值的预测一般有几类：






模仿学习：行为克隆的直接策略学习方法




- ❑ 最经典、使用最广泛的策略学习算法，是将图像编码后**直接映射**到动作
- ❑ 唯一的区别在于损失函数的设计，即预测的动作值与真实动作值之间的损失
- ❑ 包括RT-1、RT-2在内的具身多模态大模型均采用该方法



BC-Z模型，使用回归的方式设计Loss

- [1] Jang et al. BC-Z: Zero-Shot Task Generalization with Robotic Imitation Learning. 2021 CoRL
[2] Brohan et al. RT-1: Robotics Transformer for Real-World Control at Scale. 2022 Arxiv

bin




RT-1模型，离散成256个



模仿学习：扩散策略的轨迹生成思想



- ❑ 为机器人生成动作其实是生成轨迹，因为生成动作一般不是预测一个动作，而是生成动作序列。
- ❑ 轨迹生成需要考虑序列的连贯性，因此有研究者将其他领域中的生成方法引入策略学习中：
 - ❑ 联合概率建模 → 隐行为克隆
 - ❑ 扩散模型生成图片 → 扩散策略生成轨迹序列




图中蓝色箭头表示梯度，是某个观察下最好的动作取值点的方向，可以看到梯度都指向轨迹上的点，也就是最好的（观察、动作）对



Diffusion Policy

既能建模多种模式的轨迹，又带有随机性可以采样出多种可行的轨迹



LSTM-GMM



BET

建模多种模式的轨迹失败



IBC

能建模多种模式的轨迹，但整个过程是确定性的，只能产生一种模式的轨迹



模仿学习：Diffusion Policy的训练与推理流程




训练过程：

- 加噪：从专家演示中随机采样一条轨迹，然后不停的向其中加入噪声；
- 去噪：取加噪后的轨迹，基于观察预测加入的噪声，进行轨迹的还原；

推理：

- 初始从高斯分布中采样一小段轨迹，基于这段轨迹和观察预测噪声，然后减去噪声，去噪持续K步生成最后的轨迹



[1] Chi et al. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. RSS 2023



强化学习：奖励函数指导的交互学习框架



□ 强化学习 (Reinforcement learning, RL)

- 强化学习专注于如何让智能体在环境中采取行动以**最大化某种累积奖励**
- 基于**与环境的交互**，智能体学习选择最佳行动，逐步改善其行为策略
- 应用广泛，包括自动驾驶、游戏、机器人控制等

□ 无模型强化学习 (Model-Free RL)

直接从环境交互学习最优策略或价值函数，依赖尝试和错误经验提升策略性能

优点：能学习复杂行为，无需构建显式的环境模型

挑战：可能需大量环境交互，样本效率较低

□ 基于模型的强化学习 (Model-Based RL)


学习环境的动态模型，用于规划或预测未来状态。通过“想象”未来的环境状态，提高样本效率，减少实际交互需求

优点：更高的效率和规划能力

挑战：环境模型的准确性对性能起到至关重要的作用



通用执行模型：从语言指令到动作轨迹的统一执行





通用执行模型：泛化能力、数据质量与联合训练



- 鉴于大模型的成功案例，开发一个通用执行模型变得尤为重要
 - 一个高度泛化的通用执行模型，能够理解各种人类文本命令，适应不同的场景配置、物体位置和形状，以及不同机器人的动作空间和操作模式
 - 这样的模型可以持续适应新技能，提供更好的泛化能力，并且学习速度更快
- 此外，模型的性能极大地受到数据质量、模型架构和训练方法的影响
 - 实现卓越的泛化能力需要依赖多样化和高质量的训练数据
 - 通过跨多个任务联合训练，模型可以在不同的任务技能中展示广泛的适应性
 - 当前，像Octo、RT-X和OpenVLA等模型已经在高质量数据集Open X Embodiedenvnt的基础上表现出卓越的性能，实现了包括**物体类型、位置、任务场景、机器人类型和人类命令**等多个维度的泛化



通用执行模型：RT-1网络详解



★ **核心思想：** 将多模态观测映射为离散动作 token，实现多任务机器人控制。



为什么 RT-1 有效？

- 语言指令通过 FiLM 调制视觉编码，突出任务相关区域
- TokenLearner 大幅压缩 token，提高实时推理效率
- Transformer 融合多帧时序信息，建模动作上下文
- 动作离散化后转为分类问题，更稳定地学习控制策略

一句话讲解

- RT-1 本质上是一个 Vision-Language-Action 模型。
- 它把图像历史和任务指令编码后，直接预测机器人下一步动作。
- 因此它适合做多任务、端到端的通用执行策略学习。


RT-1: Robotics Transformer for Real-World Control at Scale (Google, 2022)



通用执行模型：以RT-1实验理解泛化挑战



- 第一行从左到右干扰物 (Distractors) 难度逐渐加大
- 第二行从左到右分别是初始环境，变换桌布图案，新的厨房环境



Model	Seen Tasks	Unseen Tasks	Distractors	Backgrounds
Gato (Reed et al., 2022)	65	52	43	35
BC-Z (Jang et al., 2021)	72	19	47	41
BC-Z XL	56	43	23	35
RT-1 (ours)	97	76	83	59



通用执行模型：RT-1在真实厨房场景中的泛化表现



- 转到真实厨房中的真实场景中，分为三个等级：
 - L1 用于泛化到新的桌面布局和照明条件
 - L2 用于泛化到未见过的干扰对象
 - L3 用于泛化到新的任务设置、新任务对象或未见过的位置（例如水槽附近）



Models	All	Generalization Scenario Levels		
		L1	L2	L3
Gato Reed et al. (2022)	30	63	25	0
BC-Z Jang et al. (2021)	45	38	50	50
BC-Z XL	55	63	75	38
RT-1 (ours)	70	88	75	50




通用执行模型：RT-1跨机械臂与仿真数据的影响



- 加入仿真数据会降低真实环境下见过的物体和技能上的表现，大幅提高仿真环境下的表现

Models	Training Data	Real Objects	Sim Objects (not seen in real)	
		Seen Skill w/ Objects	Seen Skill w/ Objects	Unseen Skill w/ Objects
RT-1	Real Only	92	23	7
RT-1	Real + Sim	90(-2)	87(+64)	33(+26)

- 加入新类型机械臂在新任务的数据不会造成严重的性能下降，且会提高在新加入任务的表现




Models	Training Data	Classroom eval	Bin-picking eval
RT-1	Kuka bin-picking data + EDR data	90(-2)	39(+17)
RT-1	EDR only data	92	22
RT-1	Kuka bin-picking only data	0	0



具体效果: RT-1

- 数据多样性更重要
- 减少3%的数据量和25%见过的任务量,
- 几乎等同于减少50%数据量和0%任务量



Models	% Tasks	% Data	Seen Tasks	Generalization			
				All	Unseen Tasks	Distractors	Backgrounds
Smaller Data							
RT-1 (ours)	100	100	97	73	76	83	59
RT-1	100	51	71	50	52	39	59
RT-1	100	37	55	46	57	35	47
RT-1	100	22	59	29	14	31	41
Narrower Data							
RT-1 (ours)	100	100	97	73	76	83	59
RT-1	75	97	86	54	67	42	53

数据规模减少50%

数据多样性降低25%



通用执行模型：RT-2网络详解



★ **核心思想：** 把大规模视觉-语言模型扩展为视觉-语言-动作模型（VLA），通过动作文本化，将互联网知识迁移到机器人控制中。



💡 相比 RT-1，RT-2 直接继承大规模 VLM 的视觉语义知识。

💡 为什么 RT-2 更强？

- 利用 PaLI-X / PaLM-E 的大规模预训练知识
- 联合学习互联网语义与机器人操作
- 动作文本化后，可统一到同一生成框架
- 对新物体、新指令和语义推理更有泛化能力

💬 一句话讲解

- RT-2 本质上是一个 Vision-Language-Action 模型。
- 它把图像和语言送入大模型，再直接生成动作 token。
- 因此机器人不仅会执行，还能利用互联网知识做简单推理。

★ 涌现能力示例

- 选择最小 / 最大物体
- 识别数字、图标并执行指令
- 根据语义常识选择合适物体

📖 RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control (Google DeepMind, 2023)




通用执行模型：RT-2的语义理解与动作策略结合



□ 保持对图片、文字的语义理解能力、推理能力，并与动作策略相结合。基座大的模型表现更好

Task Group	Tasks
Symbol Understanding: Symbol 1	move coke can near X, move coke can near 3, move coke can near Y
Symbol Understanding: Symbol 2	move apple to tree, move apple to duck, move apple to apple, move apple to matching card
Symbol Understanding: Symbol 3	put coke can close to dog, push coke can on top of heart, place coke can above star
Reasoning: Math	move banana to 2, move banana near the sum of two plus one, move banana near the answer of three times two, move banana near the smallest number
Reasoning: Logos	move cup to google, move cup to android, move cup to youtube, move cup to a search engine, move cup to a phone
Reasoning: Nutrition	get me a healthy snack, pick a healthy drink, pick up a sweet drink, move the healthy snack to the healthy drink, pick up a salty snack
Reasoning: Color and Multilingual	move apple to cup with same color, move apple to cup with different color, move green chips to matching color cup, move apple to vaso verde, Bewegen Sie den Apfel in die rote Tasse, move green chips to vaso rojo, mueve la manzana al vaso verde, déplacer les frites verts dans la tasse rouge
Person Recognition: Celebrities	move coke can to taylor swift, move coke can to tom cruise, move coke can to snoop dog
Person Recognition: CelebA	move coke can to person with glasses, move coke can to the man with white hair, move coke can to the brunette lady



Model	Symbol Understanding				Reasoning					Person Recognition			Average
	Symbol 1	Symbol 2	Symbol 3	Average	Math	Logos	Nutrition	Color/Multilingual	Average	Celebrities	CelebA	Average	
VC-1 (Majumdar et al., 2023a)	7	25	0	11	0	8	20	13	10	20	7	13	11
RT-1 (Brohan et al., 2022)	27	20	0	16	5	0	32	28	16	20	20	20	17
RT-2-PaLI-X-55B (ours)	93	60	93	82	25	52	48	58	46	53	53	53	60
RT-2-PaLM-E-12B (ours)	67	20	20	36	35	56	44	35	43	33	53	43	40



通用执行模型：RT-2中参数规模与联合微调的作用



❑ 参数量大效果更好，混合预训练数据联合微调可以提高泛化性

❑ From scratch: 仅使用机器人数据，不基于VLM

❑ fine-tuning: 使用机器人数据微调VLM

混合预训练数据分别带来2%和11%的成功率增幅

❑ Co-fine-tuning: 机器人数据和VQA数据一起训练VLM

Model	Size	Training	Unseen Objects		Unseen Backgrounds		Unseen Environments		Average
			Easy	Hard	Easy	Hard	Easy	Hard	
RT-2-PaLI-X	5B	from scratch	0	10	46	0	0	0	9
RT-2-PaLI-X	5B	fine-tuning	24	38	79	50	36	23	42
RT-2-PaLI-X	5B	co-fine-tuning	60	38	67	29	44	24	44
RT-2-PaLI-X	55B	fine-tuning	60	62	75	38	57	19	52
RT-2-PaLI-X	55B	co-fine-tuning	70	62	96	48	63	35	63

增加参数量分别带来10%和20%的增幅



通用执行模型：OpenVLA的四类泛化评估任务



□ 定义了**视觉泛化、运动泛化、物理泛化和语义泛化**四种评估任务，OpenVLA仅在语义上落后

- **visual**: 未见过的背景、干扰物体、物体的颜色/外观
- **motion**: 未见过的物体位置/方向
- **physical**: 未见过的大小和形状
- **semantic**: 未见过的目标物体、指令、概念
- 额外增加一个多对象的任务，测试能否做到语言和对应物体的grounding

Category	Task	# Trials	RT-1-X # Successes	Octo # Successes	RT-2-X # Successes	OpenVLA (ours) # Successes
Visual gen	Put Eggplant into Pot (Easy Version)	10	1	5	7	10
Visual gen	Put Eggplant into Pot	10	0	1	5	10
Visual gen	Put Cup from Counter into Sink	10	1	1	0	7
Visual gen	Put Eggplant into Pot (w/ Clutter)	10	1	3.5	6	7.5
Visual gen	Put Yellow Corn on Pink Plate	10	1	4	8	9
Motion gen	Lift Eggplant	10	3	0.5	6.5	7.5
Motion gen	Put Carrot on Plate (w/ Height Change)	10	2	1	4.5	4.5
Physical gen	Put Carrot on Plate	10	1	0	1	8
Physical gen	Flip Pot Upright	10	2	6	5	8
Physical gen	Lift AAA Battery	10	0	0	2	7
Semantic gen	Move Skull into Drying Rack	10	1	0	5	5
Semantic gen	Lift White Tape	10	3	0	0	1
Semantic gen	Take Purple Grapes out of Pot	10	6	0	5	4
Semantic gen	Stack Blue Cup on Pink Cup	10	0.5	0	5.5	4.5
Language grounding	Put {Eggplant, Red Bottle} into Pot	10	2.5	4	8.5	7.5
Language grounding	Lift {Cheese, Red Chili Pepper}	10	1.5	2.5	8.5	10
Language grounding	Put {Blue Cup, Pink Cup} on Plate	10	5	5.5	8.5	9.5
Mean Success Rate			18.5±2.7%	20.0±2.6%	50.6±3.5%	70.6±3.2%



Open-X-Embodiment与大规模机器人数据



□ Open-X-Embodiment数据集

- 汇编了来自22个不同机器人系统的超过一百万个操作轨迹
- 涵盖了34个机器人研究实验室的60个独立数据集
- 记录了从拾取到组装等简单到复杂的行动，涵盖了包括家电、食物在内的多种家庭物品

□ 研究表明，使用Open X Embodiment数据集训练的模型如RT-X、Octo和OpenVLA，与先前模型相比，在泛化能力上有显著提升

- RT-X的研究显示，使用足够大的模型，更广泛的数据集显著提高了模型在多个领域的性能
- Octo在对象定位、照明、背景和干扰等泛化条件下表现出色，与从零开始训练或使用传统微调基线方法相比，展示了更好的学习效率
- OpenVLA在视觉、动力、物理和语义泛化的各种任务中设定了新的评估标准，虽然在语义泛化方面略有不足，但在将微调转移到新机器人的大多数任务中，相比其他算法表现更佳

[1] Padalkar et al. Open x-embodiment: Robotic learning datasets and rt-x models. 2023 arXiv

[2] Team et al. Octo: An open-source generalist robot policy. 2024 arXiv

[3] Kim et al. OpenVLA: An Open-Source Vision-Language-Action Model. 2024 arXiv


05

通用具身智能与未来方向






需要深入研究的具身智能技术栈



- **多模态具身智能大模型构建技术:** 负责统一理解视觉、语言、动作、触觉等信号
- **基于大模型的持续学习技术:** 解决机器人长期适应新环境的问题
- **基于大模型的交互式学习技术:** 强调机器人从人类反馈和环境反馈中学习
- **仿真环境及世界模型的构建技术:** 用于降低真实机器人采集和试错成本



需要深入研究的具身智能技术栈




➤ 多模态具身智能大模型构建技术

- 如何解决数据问题?
- 如何处理复杂和多模态的输入数据?
- 如何输出稳定、像人类的执行动作?
- 如何让模型具备更丰富的世界知识、常识知识?
- 如何像人类一样有逻辑的分析和决策规划?
- 决策规划模型和执行模型能否统一?



需要深入研究的具身智能技术栈




➤ 基于大模型的持续学习技术

- 人类在一生当中需要不断学习，智能机器人是否也需要这样？
- 如何让智能机器人在不断学习时，避免“狗熊掰棒子”？



需要深入研究的具身智能技术栈



► 基于大模型的交互式学习技术


- 人类的学习过程绝大部分是通过与环境交互，智能机器人是否也需如此？

人类一直在通过接收环境反馈信息，纠正自己的行为 and 认知

- 如何让智能机器人在真实世界中自主的去学习？



需要深入研究的具身智能技术栈



➤ 仿真环境及世界模型的构建技术

- 如何构建可以媲美真实环境的仿真环境或世界模型？

Real2Sim: 模型算法、机器人硬件效果都需要在仿真环境中测试验证，仿真越逼真越有效

世界模型: 模型的训练也需要环境反馈怎么办？需要仿真快速给出准确反馈



产业分析总结——技术落地还需时间



□ 通用机器人产业分析

- 头部聚集效应严重，仅排名靠前的头部企业才容易存活
- 需要大量的供应链优势，以加速机器人量产
- 需要长期积累，短期难以获得收益
 - 难以商业化落地到特定场景
 - 难以通过技术突破获得融资

通用机器人具有重要的研究意义和应用价值，但短期内难以收获效益。且该行业竞争激烈，需要足够的资金和快速的技术迭代才能取得优势



具身智能研究的机遇



- **模型和算法创新：**具身智能需要新的模型与算法，通过交互提升机器的感知、认知和决策能力

非交互的算法：学习有遮挡物体的识别

交互的算法：学习如何移开遮挡识别物体

- **实验平台的发展：**机器人为各种感知、认知、决策算法提供了落地平台，研究人员可以在真实环境中对算法进行测试
- **多学科交叉：**具身智能是人工智能、机器人学、人机交互等多学科融合的研究方向，有些问题或许换个视角就能解决
- **技术转移潜力：**具身智能的研究可以促进技术的转移，推动本方向的发展，如CV为Robotics提供视觉功能

AI & Robotics：我们希望打造儿童情感陪伴机器狗，如何才能更智能？



人机交互：低智能的陪伴机器狗也能满足需求，过于智能会导致恐怖谷效应




具身智能研究的挑战



机器人复杂系统实现的挑战：
智能化机器人包括感知、决策和行动，系统设计和实现的复杂性极高




机器人量产和商业化的挑战：
智能化算法需要达到低资源、低成本、高可控性、高稳定性的商业化、产品化需求



机器人持续学习进化的挑战：
人类社会在发展，机器人也要不断的学习新工具、提高自身能力



机器人伦理安全的挑战：
确保智能系统的行为符合人类价值观并且不构成威胁





第六章

具身智能商业化思考，以及来自跨维的实践



Scaling law范式下实现具身智能?





Scaling law范式下实现具身智能?



语言模型的训练数据



What color are her eyes?
What is the mustache made of?



How many slices of pizza are there?
Is this a vegetarian pizza?



Is this person expecting company?
What is just under the tree?



Does it appear to be rainy?
Does this person have 20/20 vision?

V.S.,

具身智能的训练数据



- 文本/二维图像/视频
- 互联网海量存在
- 手机等移动端持续增加

- 三维/高维/非结构化
- 异构/物理/标定
- 极度稀缺/无海量获取的范式

数据飞轮难以启动，行业需要新的具身智能学习定律




Scaling law范式下实现具身智能? (数据)



- 真实本体数据采集+引擎扩增: 真机遥操作 && Real2Sim



100~300条/天





人类演示+引擎训练 也是小脑基本学习范式



Standing



Walking



Running



Recovering



In-Door



Out-Door



Robust Test




Sixu Lin, Guanren Qiao, Yunxin Tai, Ang Li, Kui Jia, and Guiliang Liu, *HWC-Loco: A Hierarchical Whole-Body Control Approach to Robust Humanoid Locomotion*, Submitted to International Conference on Machine Learning (ICML) 2025.



Scaling law范式下实现具身智能? (数据)



- 真实数据采集: UMI (Universal Manipulation Interface)



Source: <https://umi-gripper.github.io/>



Scaling law 范式下实现具身智能? (数据)



- 人类演示+引擎扩增 的高效学习范式

You Only Teach Once: Learn One-Shot Bimanual Robotic Manipulation from Video Demonstrations

Huayi Zhou*, Ruixiang Wang[†], Yunxin Tai[‡], Yueci Deng[‡], Guiliang Liu* and Kui Jia*

*The Chinese University of Hong Kong, Shenzhen. [†]Harbin Institute of Technology, Weihai. [‡]DexForce, Shenzhen






Fig. 1: Our proposed YOTO (You Only Teach Once) facilitates various complex long-horizon bimanual tasks. It needs only a one-shot observation of a single third-person binocular camera to extract the fine-grained motion trajectory of human hands, which can then be utilized for the dual-arm coordinated action injection and rapid proliferation of training demonstrations.






人类演示+引擎扩增 的高效学习范式



Guiliang Liu, Yueci Deng, Runyi Zhao, Huayi Zhou, Jian Chen, Jietao Chen, Ruiyan Xu, Yunxin Tai, and Kui Jia, *DexSim: Automating Data Scaling for Sim2Real Generalizable Robot Control*, Submitted to International Conference on Machine Learning (ICML) 2025.



人类演示+引擎扩增 的高效学习范式




Guiliang Liu, Yueci Deng, Runyi Zhao, Huayi Zhou, Jian Chen, Jietao Chen, Ruiyan Xu, Yunxin Tai, and Kui Jia, *DexSim: Automating Data Scaling for Sim2Real Generalizable Robot Control*, Submitted to International Conference on Machine Learning (ICML) 2025.



Scaling law范式下实现具身智能？（模型）



• 具身智能模型：Vision-Language-Action (VLA)






Scaling law范式下实现具身智能? (模型)



- 具身智能模型: Vision-Language-Action (VLA)





Scaling law范式下实现具身智能? (模型)




• 具身智能模型: Vision-Language-Action (VLA)

• 优势

- 数据驱动
- 动作生成
- 自然属性

• 劣势

- 缺海量数据
- 语义退化
- 映射鸿沟






Scaling law范式下实现具身智能? (模型)




• 什么是世界模型



"Evidence also suggests that what we perceive at any given moment is governed by our brain's prediction of the future based on our internal model"

“还有证据表明，我们在任一时刻的感知，实际上受大脑依据其内部模型对未来作出的预测所支配”




David Ha and Jurgen Schmidhuber, "World Models", Arxiv, 2018.

Yann LeCun, "A Path Towards Autonomous Machine Intelligence", Open Review, 2022.




世界模型的进阶发展路径



LLMs give geospatial knowledge
大语言模型具备地理空间知识


Manvi, Khanna, et al., GeoLLM: Extracting Geospatial Knowledge from Large Language Models, ICLR, 2024.



Sora




世界模型的进阶发展路径



英伟达视频驱动的世界基础模型

Source from <https://research.nvidia.com/labs/dir/cosmos-predict1/>




An industrial robotic arm, painted in a vivid orange hue, dominates ...



A sophisticated robotic assembly line features two advanced robotic...



世界模型的进阶发展路径



Predicted


GT

英伟达视频驱动的世界基础模型

Source from <https://research.nvidia.com/labs/dir/cosmos-predict1/>



基于生成式仿真的世界模型 GS-World



视频生成世界模型

- 在像素层学习数据分布，追求视觉上的逼真
- 无法保证物理规律的正确性

VS

生成式仿真世界模型

- 生成场景的视觉外观，三维资产、物体材质、物理参数与交互规则
- 保证运动、碰撞、受力等现象因果合理性

生成并仿真物理精确的三维世界

智能体在三维世界中化感知、行动、试错与学习

形成“世界生成-物理仿真-任务构建-反馈优化”闭环


实现流式、自我进化的具身智能训练体系




基于生成式仿真 (GS-World) , 打造具身智能学习新范式



生成式仿真
GS-World



Text Prompt: A UR robot picks a banana from a wooden table into a gray bowl-like container





真实数据采集 Versus 生成式数据



• 真实数据采集

• 优势

- 简单直接
- 技术门槛低
- 天然包含语义信息
- 容易形成 demo

• 劣势

- 难以上量和规模化
- 变量无法解耦，难以泛化
- 难以走出实验室形成产品
- 难以采出各种 corner cases



• 生成式数据

• 优势


- 算力/电力即数据模型
- 并行计算支持海量生成
- 变量可控解耦，易泛化
- 支持产品级精度和稳定性

• 劣势

- 视频生成无法直接训练机器人动作任务
- 生成式仿真仍属于学术最前沿，技术尚需发展
- 需额外注入语义信息




定义 Efficiency law , 并提出世界模型引擎驱动的具身智能学习新范式



Efficiency law:

$$l(r_D) = (c_D \cdot r_D \cdot t_D)^{-\alpha_D}$$

$$l(r_D, P) = ((c_P \cdot P)^{-\alpha_P/\alpha_D} + (c_D \cdot r_D \cdot t_D)^{-1})^{\alpha_D}$$



- 自动高效学习
- 弹性可扩展
- 物理精确性
- 鲁棒抗干扰
- 高效跨本体
- 本体自动优化



EmbodiChain - 全合成数据管线自动训练VLA/世界模型





Engine-driven Sim2Real VLA





总结：“效率法则”指出，具身智能真正稀缺的是高效造数据的能力，构建自动化的数据生成体系，成为通用具身机器人实现规模化落地的关键前提



具身智能的“效率法则”

Scaling Law

- 只要数据够多、算力够猛，智能似乎就会自动涌现。
- 但在机器人领域，这个公式似乎失效了

在具身智能时代，
数据必须是「增量」，必须具备「创造」数据的能力

GS-World: An Efficient, Engine-driven Learning Paradigm for Perceiving Embodied Intelligence using World Models of Generative Simulation

引入“数据生成速率” r_D



r_D 过低
数据稀缺

需用模式复用、数据剪枝等技术，维持模型性能

r_D 足够高
数据充足

无需担心数据瓶颈，可通过扩大模型规模，提升性能

- 在有限时间内，更高的 r_D 能显著提升学习效率，从而通过训练大容量模型提升实际性能
- 过低的 r_D 会导致模型进入“数据稀缺区”，使规律失效

通用具身机器人发展需要高效地造数据

具身智能机器人训练数据金字塔

真实数据

- 从现实环境中直接采集的真机数据

Real2Real Gap

仿真数据

- 通过计算机建模的虚拟环境生成

Sim2Real Gap

互联网数据

- 互联网中的视频数据



动作信息缺失

具身智能的发展必须从“采数据”和“堆数据”转向“高效地造数据”

通过提高高质量数据的生成与利用效率

建立起支撑具身智能发展新学习范式

GS-World（世界模型）是实现 efficiency law 的核心机制




DexVerse™引擎内含EmbodiChain工具链，以“仿真 - 训练 - 部署”端到端闭环的方式成功训练出新一代Sim2Real VLA及DexWorldModel，协同感知、生成、机器人三大技术栈，释放具身智能跨行业落地潜力



公司已完成 EmbodiChain 具身智能「在线数据流和模型生产线」的全流程优化与三大核心技术的深度协同升级
从而具备更强的泛化能力与跨行业落地潜力

引擎驱动的仿真到现实VLA理念
完美实现了从100%合成数据到零样本迁移，再到真机部署的端到端闭环



<https://dexforce.com/embodichain/index.html#/>

感知层技术

- ✓ SAM 6D姿态估计
- ✓ Stereo Anything双目
- ✓ DexSense相机

生成式技术

- ✓ DexGen 3D生成式AI
- ✓ Fantasia3D (文本/图像转3D)

机器人本体技术

- ✓ HWC-LOCO运动保障系统
- ✓ GAT-Grasp手势感知技术

人形机器人政策重心：技术→产业化→数据支撑的产业化落地



资料来源：前瞻产业研究院，跨维智能增补整理

具身智能的产业链结构与生态协同




上游：核心硬件与基础技术

核心零部件：减速器、伺服系统、传感器、灵巧手等。代表企业：绿的谐波、汇川技术、禾赛科技。

AI芯片与算力：负责感知与模型运行。代表企业：NVIDIA、华为昇腾、地平线。



Tencent 腾讯



下游：多元化应用场景

落地场景：工业制造、物流仓储、医疗健康、商业服务等。

标杆企业：亚马逊、宝马、擎朗智能、达芬奇手术机器人。



资料来源：甲子光年

具身智能产业链：软硬件深度融合，复杂且充满活力的生态系统



人形机器人商业化落地逻辑：从结构化到开放场景的演进

► 商业化演进路径：工业 → 商业 → 家庭生活



工业场景 (结构化)

- 环境可控，任务标准化
- 高精度、高稳定性要求
- 解决“用工荒”降本增效



商业场景 (半结构化)


- 环境动态，人机交互频繁
- 提升泛化能力的“训练场”
- 探索RaaS服务商业模式



生活服务 (非结构化)


- 环境复杂，任务高度个性化
- 极致的安全与情感交互要求
- 万亿级消费市场

图：具身智能机器人在各类应用领域的市场空间分布





作为物理世界的终极智能体，具身人形机器人能够落地赋能千行百业



跨维智能商业进展

- 跨维已经在工业制造、物流、家电等30+行业的半结构化场景中批量应用，在毫米级精度的抓取/操作任务下，其成功率超过99.9%
- 跨维也正在将产品稳步落地于迎宾导购、商业清洁、养老看护等更多重人机交互的半结构化及非结构化场景

打造工业具身大脑超级工作台

AnyPick AnyPlace AnyInsert
AnySort AnyScrew AnyFold
AnyPush AnyPull



实现物理世界AI要求“数据-模型-本体-场景”强耦合，公司成功构建具身智能全栈核心要素





公司以“把具身智能转化为商业价值”为核心，多种盈利模式并行，坚持“技术-产品-场景”的发展路径，稳步拓展应用边界



通用具身智能领域首个实现规模化商业落地/引领者

赋能50+行业、100+客户、1000+场景

下游场景

泛智能制造



无序分拣



柔性装配

商业服务



迎宾导购



康养理疗

科研教育



高校



科研院所

核心产品服务

构建空间与具身智能软硬件产品，实现多场景商业化落地

为现有工业机器人提供操作大脑与纯视觉传感器



空间与具身智能传感器

DexSense



通用具身智能机器人

DexAgent



空间与具身智能大脑

DexBrain

技术支持

高效整合开发工具



EmbodiChain
工具链



DexVerse™
具身智能引擎



DexWorldModel
世界模型

143

以生成式仿真世界模型构建空间与具身智能通用产品系列，赋能工业多个细分场景



少量 SKU 分拣




多样 SKU 分拣



海量 SKU 分拣

海量SKU分拣场景

以汽车总装产线SPS分拣为例，总装产线SPS分拣环节已成为目前制造工艺的关键瓶颈，自动化率不足10%，超过上百道工序且仍高度依赖人工，跨维已针对该场景建设方案，推进总装环节的自动化、标准化和柔性化



以生成式仿真世界模型构建空间与具身智能通用产品系列，赋能工业多个细分场景



单臂柔性插拔



单臂柔性装配



双臂柔性装配

柔性装配场景

以家电行业中插拔场景为例，针对电视机USB/HDMI等插拔检测场景，跨维已批量落地具身智能套件，定位精度在0.3mm左右，稳定性能达到99.9%，目前已规模完成家电行业头部客户交付，后续将延伸至工业领域各类柔性装配场景

亿人民币

预计未来五年内，泛柔性装配市场需求快速放量，3C与家电行业柔性制造规模预计分别将超过3,500亿元及2,500亿元



数据来源：IDC、Statista

从单点突破到规模复制——前台服务商业模式

跨维独有数据飞轮



跨维核心竞争壁垒

- 1 一线场景获取高价值“长尾数据”
- 2 EmbodiChain + 仿真引擎作为“数据放大器”
- 3 提升模型质量，与竞品拉开代差

跨维“注意力经济”场景

环境多样
光线复杂
干扰频繁

➤ 数据价值比厂区更大

商业模式

合作伙伴画像

全国网络覆盖，标准化运营能力强



文旅运营商

与方特集团建立战略合作，预计在2026年落地超40家主题乐园的商业服务需求，总量约



商业地产集团

与中信集团形成战略合作意向，打造面向2026年APEC峰会的商业地产+具身智能科技街区，是首个具身智能常态化运营的世界级商业地标。



活动运营公司

与产业初创深圳艺世形成战略合作，培育具身智能产业初创共同、持续成长，覆盖深圳城市休闲消费地标场景的设计、建设、运营等业务。

合作模式

- 合作商提供渠道/点位/运营网络
- 跨维提供机器人产品+技术支持

资源互补

收益分成

快速回笼

品牌共建

战略落地

数据反哺
拓展技术边界

目标客户与场景

核心策略：主打“注意力经济”红利场景

场景类型一

固定摊位 + 高访客更新率

游乐场/主题乐园、景区/旅游景点、高端连锁酒店集团



场景类型二

移动巡游 + 快闪活动

商业快闪店、品牌营销活动、大型会议/体育赛事



从单点突破到规模复制——前台服务商业模式

多样化商业服务站

【零售+娱乐互动+引流】



文旅

方特集团

以徐州方特为战略落地目标，覆盖40座主题乐园、批量复制总计400台机器人

长隆主题乐园

(珠海、广州、清远)

华侨城文旅

欢乐谷，欢乐港湾，锦绣中华，前海石公园

商超

桂林旅游学院

战略合作，链接文旅运营集团，提供全市景区具身智能落地场景，预计2026年落地200台。

盈新发展集团

链接圆明园在内的5A级景区

陕西长安虎符产业科技

西安大唐不夜城



零售

酒店

维小饭

联合香港生产力局，覆盖城市轻食售卖业态，以健康饮食科普专家渗透医疗、康养行业

东源农产品售卖站

与东源农业合作社合作，实现农产品售卖在省府大院、中国百货零售业年会展的快速落地

龙岗机器人6S店

集合零售、咖啡制作、爆米花、调酒与冰激凌冷饮制作，形成综合零售示范点

楼宇

广晟置地

以广东省具身智能训练场为核心，覆盖集团全业务：消防室值班机器人、商业服务场景、工业制造场景

中信集团

打造2026APEC机器人商业地标，覆盖中信国际大厦室内外10+个场景，并实现常态化运营



交通



谢谢!

THANK YOU FOR WATCHING!

