

总 序

研究生教材建设是研究生教育的基础工程,是提高研究生培养质量的重要环节。自 1978 年恢复研究生招生以来,我校先后编写了供工科研究生使用的数学教材或教学参考书,其中一些教材出版后,不仅本校使用,许多兄弟院校也选作教材或教学参考书,受到读者好评;另有一些教材则采用讲义形式在校内印发、使用。为适应研究生教育事业迅速发展的需求,我校决定在原有“工科研究生用书”的基础上,通过修订和新编,出版“工科研究生教材·数学系列”。

现代科学技术的发展,特别是计算机技术的高度发展,使得数学科学在人类生产、管理及科学研究中发挥越来越突出的促进作用,也使得人类社会生活的各个领域使用数学技术成为可能。“工科研究生教材·数学系列”作为工科硕士研究生和博士研究生公共课的选用教材,我们希望每本教材既要介绍该学科分支的历史沿革与发展、基本理论和方法,又能反映该学科分支的最新成果。对于后者,主要是从基本思想和实际运用技巧方面进行概括和阐述。这就要求每本教材既要有严谨的解析论证,又要有概括性的分析和介绍,不宜过分追求教材内容的自我完备。

我校研究生教材建设(特别是公共数学课程教材建设)还处在不断完善过程中,限于学术水平和教学经验,本系列教材难免有疏漏和不足之处,恳请读者指正,以便日后修订时加以更正。

华南理工大学研究生院

2005 年 6 月

前 言

最优化问题是人们在工程技术、科学研究和经济管理等诸多领域中经常遇到的问题。最优化计算方法则是解决各种各样最优化问题的科学方法，它基于对实际问题的数学建模和探求解法来实现问题的最优化处理。随着现代科学技术的发展，特别是计算机技术的高速发展，使得应用该方法解决人类生活各个领域遇到的各种优化问题成为可能，并且应用越来越广泛、深入，同时也极大地促进了该方法的理论研究和实际运用研究的高速发展。掌握优化思想方法并善于对遇到的问题进行优化处理，是现代工程技术人员、科研人员和管理者必须具备的基本素质。

最优化理论和方法所包含的内容很多，大致分为经典方法和现代方法两大方面。经典方法如线性规划、非线性规划、整数规划、动态规划等，现代方法如随机规划、模糊规划、模拟退火算法、遗传算法、禁忌搜索和人工神经网络等。对于如此庞杂的内容，多年来国内外已陆续出版专著介绍每个分支，也有不少教材或专门介绍经典方法，或专门介绍现代法。本书集经典算法和现代算法于一体，希望读者既能理解和掌握经典算法，又对现代算法有尽可能多的了解和体会。这是一种大胆的甚至是冒险的尝试。首先，我们认为在这知识爆炸的年代，研究生教材不宜刻意追求自我完备，而应是开放式的、与时俱进的。其次，我们认为工科研究生修读公共数学课，目的不外乎培养理解和运用两方面的素养，在理解方面分为两个层次：第一个层次是问题的数学建模、解法的基本思想和一般步骤，第二个层次是严格的数学论证和分析（我们坚持认为这是不可或缺的）。在运用方面，首先培养用数量分析解决实际问题的自觉性和找到合适的数学方法的敏锐性，其次是问题求解借助于计算机和计算机软件进行。

基于以上的理解和认识，我们在教材内容的选择和处理上，基本上是从模型的实际背景和求解方法的思想来源及一般步骤入手，进而进行必要的、严格的数学分析论证（对部分超出学生现有知识层次的证明只给出参考文献，而对诸如马尔科夫链这样多次用到的知识则先作简单介绍），再辅以计算实例或指出有关计算实例的参考文献。本书内容分为三篇：第一篇为线性规划，包括线性规划的定义和基本性质、单纯形法、对偶理论、灵敏度分析和应用实例等；第二篇为非线性规划，包括非线性规划基本概念与基本原理、一维搜索无约束问题的最优化方法、有约束问题的最优化方法和二次规划问题；第三篇介绍现代优化方法，包括优化问题及计算复杂性、模拟退火算法、遗

传算法和人工神经网络等，每章都配备了一定数量的练习题，并提供了较为详尽和具体的参考文献。本教材是作者在多年讲授工学硕士生“最优化计算”和工学博士生“智能计算方法”的基础上集体讨论编写而成的。第一篇由潘少华博士执笔，第二篇和第三篇第十三章由蒋金山博士执笔，第三篇第十章、第十一章和第十二章由何春雄博士执笔。由于编者知识和能力所限，谬误与不足之处有待在教学实践中加以更正和补充，也恳请读者不吝赐教。

编 者

2007 年 8 月于华南理工大学
数学科学院

目 录

第一篇 线性规划

第1章 线性规划的数学模型和基本性质	1	对偶关系	44
1.1 线性规划问题及其数学模型	1	3.2 对偶性定理	48
1.1.1 问题的提出	1	3.3 对偶单纯形法	53
1.1.2 线性规划问题的数学模型	3	3.3.1 对偶单纯形法的基本思路	53
1.2 线性规划问题的图解法	5	3.3.2 对偶单纯形法的计算步骤	53
1.2.1 图解法的步骤	5	3.3.3 初始对偶基本可行解的求法	56
1.2.2 线性规划问题求解的几种可能结果	6	习题	59
1.3 线性规划的基本性质	8	第4章 灵敏度分析和参数线性规划	61
1.3.1 线性规划的基本概念	8	4.1 灵敏度分析	61
1.3.2 凸集与凸集的顶点	10	4.1.1 参数 c_j 的灵敏度分析	61
1.3.3 线性规划的基本定理	11	4.1.2 参数 b_i 的灵敏度分析	63
习题	13	4.1.3 约束条件的系数列向量 A_k 的灵敏度分析	65
第2章 单纯形法	15	4.1.4 增加一个新变量 x_{n+1} 的分析	65
2.1 单纯形法的原理	15	4.1.5 增加一个新约束条件的分析	67
2.1.1 确定初始基本可行解	15	4.2 参数线性规划	69
2.1.2 最优性检验和解的判别	16	习题	73
2.1.3 从一个基本可行解转换到相邻且改善了的基本可行解	19	第5章 线性规划应用实例	76
2.2 单纯形法的计算步骤	20	5.1 套裁下料问题	76
2.3 人工变量的处理方法	25	5.2 配料问题	77
2.3.1 大 M 法	26	5.3 生产工艺优化问题	79
2.3.2 两阶段法	28	5.4 多周期动态生产计划问题	80
2.4 单纯形法的有限终止性	30	5.5 有配套约束的资源优化问题	81
2.5 改进单纯形法	33	5.6 投资问题	82
2.5.1 单纯形法的矩阵描述	33	5.6.1 投资项目组合选择	83
2.5.2 改进单纯形法	35	5.6.2 连续投资问题	83
习题	40	5.7 运输问题及其扩展	84
第3章 线性规划的对偶理论	43	5.7.1 产销平衡的运输问题	85
3.1 线性规划的对偶问题	43		
3.1.1 对偶问题的提出	43		
3.1.2 原问题与对偶问题之间的			

5.7.2 产销不平衡的运输问题·····	86	习题·····	88
5.7.3 有转运的运输问题·····	87		

第二篇 非线性规划

第6章 非线性规划基本概念与基本

原理·····	91
---------	----

6.1 非线性规划的数学模型和基本

概念·····	91
---------	----

6.1.1 非线性规划问题举例·····

6.1.2 非线性规划问题的一般

数学模型·····	92
-----------	----

6.1.3 基本概念·····

6.2 凸函数和凸规划·····

6.2.1 凸函数定义与性质·····

6.2.2 凸函数的判别·····

6.2.3 凸规划·····

6.3 无约束问题的极值条件·····

6.3.1 用海赛矩阵判断驻点的 性质·····	102
-----------------------------	-----

6.3.2 极值点的必要条件和 充分条件·····	102
------------------------------	-----

6.4 下降迭代算法·····

6.4.1 下降迭代算法的概念·····

6.4.2 下降方向与可行下降 方向·····	105
----------------------------	-----

6.4.3 下降迭代算法的一般 步骤·····	105
----------------------------	-----

6.4.4 算法终止条件·····

习题·····	107
---------	-----

第7章 一维搜索·····

7.1 黄金分割法·····

7.1.1 单谷函数及其性质·····

7.1.2 黄金分割法基本原理 与步骤·····	109
-----------------------------	-----

7.2 牛顿法·····

7.2.1 牛顿法的基本原理·····

7.2.2 牛顿法的算术步骤·····

7.2.3 计算举例·····

7.3 抛物线逼近法·····

7.3.1 经过三点 $(x_1, f(x_1))$ 、 $(x_2, f(x_2))$ 和 $(x_3, f(x_3))$ 作抛物线 $\varphi(x)$ ·····	114
--	-----

7.3.2 用抛物线 $\varphi(x)$ 的极小点作 为 $f(x)$ 的近似极小点·····	114
---	-----

7.3.3 迭代·····	115
---------------	-----

7.4 外推内插法·····

7.4.1 基本原理与步骤·····

7.4.2 计算举例·····

习题·····	117
---------	-----

第8章 无约束问题最优化方法·····

8.1 变量轮换法·····

8.1.1 基本原理·····

8.1.2 算法步骤·····

8.1.3 计算举例·····

8.2 模式搜索方法·····

8.2.1 探测移动·····

8.2.2 模式移动·····

8.2.3 算法的基本思想·····

8.2.4 算法终止准则·····

8.2.5 算法步骤·····

8.2.6 计算举例·····

8.3 可变单纯形法·····

8.3.1 基本原理和步骤·····

8.3.2 计算举例·····

8.4 最速下降法·····

8.4.1 基本原理与步骤·····

8.4.2 计算举例·····

8.4.3 最速下降法性能分析·····

8.5 牛顿法·····

8.5.1 牛顿法基本原理·····

8.5.2 阻尼牛顿法及其计算 步骤·····	131
----------------------------	-----

8.5.3 计算举例	131	9.2.1 线性近似规划的构成	150
8.6 共轭梯度法	132	9.2.2 近似规划法的算法 步骤	151
8.6.1 基本概念和基本原理	132	9.2.3 计算举例	151
8.6.2 正定二次函数的共轭梯 度法	134	9.3 可行方向法	153
8.6.3 正定二次函数共轭梯度 法的计算步骤	136	9.3.1 基本原理与算法步骤	154
8.6.4 计算举例	136	9.3.2 计算举例	155
8.6.5 用于一般函数的共轭梯 度法	138	9.4 罚函数法	157
8.7 拟牛顿法	138	9.4.1 外点法	157
8.7.1 拟牛顿条件	139	9.4.2 内点法	161
8.7.2 DFP 法	139	9.4.3 混合法	163
8.7.3 DFP 变尺度法的计算 步骤	140	9.5 乘子法	165
8.7.4 计算举例	141	9.5.1 只有等式约束的问题	165
习题	142	9.5.2 只有不等式约束的 问题	167
第9章 约束问题最优化方法	144	9.5.3 同时含有等式约束与不等 式约束的问题	170
9.1 约束优化问题的最优性条件 ...	144	9.6 二次规划	170
9.1.1 基本概念	144	9.6.1 二次规划的基本概念与 基本性质	170
9.1.2 Kuhn—Tucker 条件(一阶 必要条件)	146	9.6.2 等式约束二次规划问题 ...	172
9.1.3 关于凸规划的全局最优解 定理	149	9.6.3 有效集法	176
9.1.4 二阶充分条件	149	9.6.4 对偶问题	180
9.2 近似规划法	150	9.6.5 二次规划的应用——支持 向量机简介	180
		习题	183

第三篇 现代最优化算法

第10章 最优化问题概论	186	10.4 启发式算法	195
10.1 最优化问题	186	10.4.1 启发式算法的概念	195
10.1.1 函数优化问题	186	10.4.2 启发式算法的分类	197
10.1.2 组合优化问题	187	10.4.3 启发式算法的性能 分析	198
10.2 计算复杂性与 NP 完全 问题	188	10.5 小结与注记	199
10.2.1 计算复杂性的概念	188	习题	200
10.2.2 NP, NP - C 和 NP - hard 概念	191	第11章 模拟退火算法	201
10.3 邻域概念	195	11.1 物理退火过程与 SA 算法 的马氏链描述	201

11.1.1 物理退火过程与 Metropolis 准则	201	性分析	248
11.1.2 物理退火过程的统计力学模型	202	12.5 遗传算法的技术实现	251
11.1.3 SA 算法的基本步骤	203	12.5.1 编码方案的确定	251
11.1.4 SA 算法的马尔科夫 (Markov) 链描述	205	12.5.2 遗传算法的性能评估	252
11.2 马尔科夫链简介	206	12.5.3 初始参数的选取和停止原则	253
11.3 时齐算法的收敛性	210	12.5.4 控制参数的选取和进化技术	254
11.4 非时齐 SA 算法的收敛性简介	215	12.6 遗传算法的改进与注记	258
11.5 SA 算法实现的技术问题	217	习题	259
11.5.1 初温的选择	217	第 13 章 人工神经网络	260
11.5.2 时齐 SA 算法的退温过程控制方法	219	13.1 概述	260
11.5.3 时齐 SA 算法各温度下的迭代长度规则	221	13.2 人工神经网络的基本概念	261
11.5.4 SA 算法的停止准则	222	13.2.1 基本人工神经网络模型	261
11.5.5 组合优化问题解的形式和邻域结构设计	222	13.2.2 人工神经网络的学习算法	261
11.6 改进 SA 算法及注记	223	13.2.3 人工神经元及感知器模型	262
习题	224	13.3 前馈神经网络及其主要算法	266
第 12 章 遗传算法	225	13.3.1 多层前馈网络	267
12.1 遗传算法的基本概念与计算流程	225	13.3.2 反向传播算法 (BP 算法)	267
12.1.1 遗传算法的基本概念	225	13.4 自组织映射神经网络	269
12.1.2 遗传算法的计算流程	227	13.4.1 竞争学习	269
12.2 遗传算法的数学模型	228	13.4.2 自组织特征映射	270
12.2.1 生物进化概念的数学描述	228	13.5 反馈型神经网络	271
12.2.2 遗传机制的数学描述	230	13.5.1 离散 Hopfield 网络	272
12.3 遗传算法的模式理论	238	13.5.2 连续 Hopfield 网络	276
12.3.1 模式与遗传算子	238	13.6 人工神经网络应用案例	278
12.3.2 模式定理	242	13.6.1 自组织网络用于模式识别	279
12.4 遗传算法的收敛性分析	246	13.6.2 Hopfield 人工神经网络在 TSP 中的应用	279
12.4.1 矩阵序列的收敛性与马氏链	246	习题	282
12.4.2 标准遗传算法的收敛		参考文献	283

第一篇 线性规划

第1章 线性规划的数学模型和基本性质

线性规划是理论和求解方法都比较成熟,且具有广泛应用的一个运筹学分支.本章介绍它的数学模型并讨论其基本性质.

1.1 线性规划问题及其数学模型

1.1.1 问题的提出

在生产管理和经营活动中,经常会遇到这样两类问题:一类是如何合理地使用有限的劳动力、设备、资金等资源,以获得最大的利润;另一类是为了达到一定的目标,应如何组织生产,或合理安排生产工艺流程,或调整产品的成分……以使消耗的资源(人力、设备台时、资金、原材料等)为最少.

例 1-1 某制药厂生产甲、乙两种药品,生产这两种药品要消耗某种维生素.生产每吨药品所需要的维生素量、所占用的设备时间,以及所获得的利润见表 1-1.已知该厂每周所能得到的维生素量为 160 kg,每周设备最多能开 15 个台班,而且根据市场需求,甲种产品每周产量不应超过 4 t.试问该厂应如何安排两种产品的每周产量以使获取的利润最大?

表 1-1

	甲	乙	每天可用能力
维生素/kg	30	20	160
设备/台班	5	1	15
利润/万元	5	2	

解 设该厂每周安排生产甲、乙两种药品的产量分别为 $x_1(t)$ 和 $x_2(t)$,则每周所能获得的利润总额为 $z = 5x_1 + 2x_2$ (万元).但生产量的大小要受到维生素量、设备的台班和市场最大需求量的限制,即 x_1 和 x_2 要满足下述一组不等式条件

$$30x_1 + 20x_2 \leq 160$$

$$5x_1 + x_2 \leq 15$$

$$x_1 \leq 4$$

另外, x_1 和 x_2 显然只能取非负值, 故有

$$x_1 \geq 0, \quad x_2 \geq 0$$

于是, 问题可以写成下列数学形式

$$\begin{aligned} \max z &= 5x_1 + 2x_2 \\ \text{s. t. } 30x_1 + 20x_2 &\leq 160 \\ 5x_1 + x_2 &\leq 15 \\ x_1 &\leq 4 \\ x_1 \geq 0, \quad x_2 &\geq 0 \end{aligned} \quad (1-1)$$

其中, $\max z = 5x_1 + 2x_2$ 表示要求函数 $z = 5x_1 + 2x_2$ 达到最大, s. t. 为英文“subject to”(受约束于)的缩写. 因此, 要求在上面所列出的全部条件下, 求 x_1 和 x_2 的一组值, 使函数 $z = 5x_1 + 2x_2$ 达到最大.

例 1-2 某公司经销一种产品, 现要将三个生产点 $A_i (i=1, 2, 3)$ 生产的产品分别运往四个销售点 $B_j (j=1, 2, 3, 4)$. 已知三个生产点的每日产量、各销售点的每日销量, 以及每吨产品从各生产点到销售点的运价见表 1-2. 试问该公司应如何调运产品, 可在满足各销售点需要量的前提下, 使总运费最少?

表 1-2

生产点 A_i \ 运价(元/t)	销售点 B_j				生产量(t)
	B_1	B_2	B_3	B_4	
A_1	4	11	3	10	5
A_2	1	9	2	8	7
A_3	7	4	10	5	8
需求量(t)	3	4	5	8	

解 设从生产点 A_i 到销售点 B_j 的调运数量为 $x_{ij}(t)$, 则总运费为

$$z = 4x_{11} + 11x_{12} + 3x_{13} + 10x_{14} + x_{21} + 9x_{22} + 2x_{23} + 8x_{24} + 7x_{31} + 4x_{32} + 10x_{33} + 5x_{34}$$

我们的目标是在一定条件下使函数 z 达到最小值. 由于从各生产点运出的数量不能超过它的产量, 故应有

$$x_{11} + x_{12} + x_{13} + x_{14} \leq 5$$

$$x_{21} + x_{22} + x_{23} + x_{24} \leq 7$$

$$x_{31} + x_{32} + x_{33} + x_{34} \leq 8$$

同时, 还应保证各销售点所需产品都得到满足, 因此有

$$x_{11} + x_{21} + x_{31} = 3$$

$$x_{12} + x_{22} + x_{32} = 4$$

$$x_{13} + x_{23} + x_{33} = 5$$

$$x_{14} + x_{24} + x_{34} = 8$$

此外, 调运量 $x_{ij} (i=1, 2, 3; j=1, 2, 3, 4)$ 都应取非负值:

$$x_{ij} \geq 0 \quad (i = 1, 2, 3; j = 1, 2, 3, 4)$$

于是,问题可写成下列数学形式:

$$\begin{aligned} \min z = & 4x_{11} + 11x_{12} + 3x_{13} + 10x_{14} + x_{21} + 9x_{22} \\ & + 2x_{23} + 8x_{24} + 7x_{31} + 4x_{32} + 10x_{33} + 5x_{34} \\ \text{s. t. } & x_{11} + x_{12} + x_{13} + x_{14} \leq 5 \\ & x_{21} + x_{22} + x_{23} + x_{24} \leq 7 \\ & x_{31} + x_{32} + x_{33} + x_{34} \leq 8 \\ & x_{11} + x_{21} + x_{31} = 3 \\ & x_{12} + x_{22} + x_{32} = 4 \\ & x_{13} + x_{23} + x_{33} = 5 \\ & x_{14} + x_{24} + x_{34} = 8 \\ & x_{ij} \geq 0 \quad (i = 1, 2, 3; j = 1, 2, 3, 4) \end{aligned} \quad (1-2)$$

注意到,此问题中三个生产点的生产总量恰好等于四个销售点的需求总量,因此,要保证各个销售点的需求量都得到满足,三个生产点的生产量应全部运走.故,式(1-2)中的三个不等式也可以改写成等式.

在上述两个例题中,都首先要确定一组具有明确含义的变量,称之为**决策变量**.问题的目标是选取这些决策变量的值使得一个函数取得最大值或最小值,此函数称之为**目标函数**.我们又利用决策变量把问题的条件表示成等式或不等式,并称这些等式和不等式为**约束条件**.如果目标函数是决策变量的线性函数,而且约束条件也都是关于决策变量的线性等式或线性不等式,则相应的数学问题就称为一个**线性规划问题**.显然,上述两个例子都是线性规划问题.

1.1.2 线性规划问题的数学模型

从实际问题得到的线性规划模型是多种多样的,为了方便讨论,规定下列形式的线性规划为标准型:

$$\begin{aligned} \min z = & \sum_{j=1}^n c_j x_j \\ \text{s. t. } & \sum_{j=1}^n a_{ij} x_j = b_i \quad (i = 1, 2, \dots, m) \\ & x_j \geq 0 \quad (j = 1, 2, \dots, n) \end{aligned} \quad (1-3)$$

其中 $b_i \geq 0$ ($i = 1, 2, \dots, m$). 也就是说,以后谈及的标准型线性规划都是指:对目标函数一律求最小值;决策变量一律要求为非负变量;约束条件除非负约束条件外一律为等式约束;约束条件的右端项一律非负.定义如下矩阵和向量:

$$A_j = (a_{1j}, a_{2j}, \dots, a_{mj})^T, \quad A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} = [A_1 \ A_2 \ \cdots \ A_n]$$

$$\mathbf{c} = (c_1, c_2, \dots, c_n)^T, \quad \mathbf{x} = (x_1, x_2, \dots, x_n)^T, \quad \mathbf{b} = (b_1, b_2, \dots, b_m)^T$$

其中 $A_j \in \mathbb{R}^m$ 是约束条件的系数列向量, $A \in \mathbb{R}^{m \times n}$ 为约束条件的系数矩阵, $\mathbf{c} \in \mathbb{R}^n$ 为价值向量, $\mathbf{b} \in \mathbb{R}^m$ 为限定向量, $\mathbf{x} \in \mathbb{R}^n$ 为决策变量, 则式(1-3)的标准型线性规划可重新写为向量形式:

$$\begin{aligned} \min z &= \mathbf{c}^T \mathbf{x} \\ \text{s. t. } \sum_{j=1}^n A_j x_j &= \mathbf{b} \\ \mathbf{x} &\geq 0 \end{aligned} \quad (1-4)$$

或矩阵形式:

$$\begin{aligned} \min z &= \mathbf{c}^T \mathbf{x} \\ \text{s. t. } A\mathbf{x} &= \mathbf{b} \\ \mathbf{x} &\geq 0 \end{aligned} \quad (1-5)$$

本书将式(1-3)、式(1-4)和式(1-5)的标准型线性规划统一记为(LP). 这三种表达形式在本书中都会用到, 请读者熟练掌握.

虽然线性规划模型是多种多样的, 但通过下面几种办法都可化为标准型.

(1) 若问题的目标是求函数 $z' = \mathbf{c}^T \mathbf{x}$ 的最大值, 即求 $\max z' = \mathbf{c}^T \mathbf{x}$, 则令 $z = -z'$, 新问题为在相同的约束条件下求 $\min z = -\mathbf{c}^T \mathbf{x}$. 显然, 新问题与原问题的最优决策变量是相同的, 只是它们的目标函数值相差一个符号而已.

(2) 若某个等式约束的右端项 $b_i < 0$, 只需将该等式两端同乘以 -1 ; 若某个不等式约束的右端项 $b_i < 0$, 则将该不等式两端同乘以 (-1) , 然后再利用下面介绍的方法将其化为等式约束.

(3) 如果约束条件中具有不等式 $\sum_{j=1}^n a_{ij} x_j \leq b_i$ 且 $b_i \geq 0$, 则可引进一个新变量 x'_i , 称为松弛变量, 并用下面两个约束条件取代这个不等式:

$$\sum_{j=1}^n a_{ij} x_j + x'_i = b_i \quad (x'_i \geq 0)$$

(4) 如果约束条件中含有不等式 $\sum_{j=1}^n a_{ij} x_j \geq b_i$ 且 $b_i \geq 0$, 则可引进一个新变量 x''_i , 称为剩余变量, 并用下面两个约束条件代替这个不等式:

$$\sum_{j=1}^n a_{ij} x_j - x''_i = b_i \quad (x''_i \geq 0)$$

(5) 若约束条件中出现 $x_j \geq h_j$ ($h_j \neq 0$), 则可引进新变量 y_j , 并令 $x_j = h_j + y_j$, 将它代入问题的目标函数和约束条件中消去 x_j , 于是原来的约束条件 $x_j \geq h_j$ 就化为 $y_j \geq 0$.

(6) 如果决策变量 x_j 的符号不受限制 (称这种变量为自由变量), 即 $x_j > 0$, $x_j = 0$ 或 $x_j < 0$, 则为了满足标准型中关于每个变量的非负要求, 可引进两个新变量 y'_j 和 y''_j , 并以 $x_j = y'_j - y''_j$ 代入问题的目标函数和约束条件中消去 x_j , 同时在约束条件中添加 $y'_j \geq 0$ 和 $y''_j \geq 0$ 两个约束条件.

例 1-3 把下列线性规划问题化成标准型:

$$\max z = 3x_1 - 4x_2 + 2x_3 - 5x_4$$

$$\begin{aligned} \text{s. t. } & 4x_1 - x_2 + 2x_3 - x_4 = -2 \\ & x_1 + x_2 + 3x_3 - x_4 \leq 14 \\ & -2x_1 + 3x_2 - x_3 + 2x_4 \geq 2 \\ & x_1 \geq 0, \quad x_2 \geq 0, \quad x_4 \geq 0 \end{aligned}$$

解 该问题共有五处不符合标准型的要求:目标函数 z 求最大值; x_3 为自由变量;第二、第三个约束条件为右端项大于0的不等式;第一个约束条件的右端项小于0. 为此,通过以下步骤把该模型标准化:

- (1) 令 $z' = -z$, 把求 $\max z$ 改为求 $\min z'$;
- (2) 将第一个约束条件两端同乘以 (-1) ;
- (3) 用 $(x_5 - x_6)$ 替换自由变量 x_3 , 其中 $x_5 \geq 0, x_6 \geq 0$;
- (4) 对第二、第三个约束条件分别引进松弛变量 x_7 和剩余变量 x_8 .

最后得到标准型为

$$\begin{aligned} \min z' &= -3x_1 + 4x_2 - 2x_5 + 2x_6 + 5x_4 + 0 \cdot x_7 + 0 \cdot x_8 \\ \text{s. t. } & -4x_1 + x_2 - 2x_5 + 2x_6 + x_4 = 2 \\ & x_1 + x_2 + 3x_5 - 3x_6 - x_4 + x_7 = 14 \\ & -2x_1 + 3x_2 - x_5 + x_6 + 2x_4 - x_8 = 2 \\ & x_j \geq 0 \quad (j = 1, 2, \dots, 8 \text{ 且 } j \neq 3) \end{aligned}$$

1.2 线性规划问题的图解法

对于线性规划问题,我们更关心的是如何进行求解. 一个线性规划问题有解,是指能找出一组 x_j ($j=1, 2, \dots, n$) 满足所有约束条件,称这组 x_j 为问题的可行解. 通常线性规划问题总是含有多个可行解,称全部可行解的集合为可行域,可行域中使目标函数值达到最优的可行解称为最优解. 若线性规划问题不存在可行解,则称该线性规划问题无解. 对于只有两个决策变量的线性规划问题,可以通过在平面上作图的方法来判别它是否有解,并在存在最优解的条件下,把问题的最优解找出来. 这种方法不仅直观,而且从此方法中还可得到有关线性规划问题的许多重要结论,从而有助于理解线性规划问题求解方法的基本原理.

1.2.1 图解法的步骤

图解法的步骤可概括为:在平面上建立直角坐标系;图示约束条件,找出可行域;图示目标函数和寻找最优解. 下面通过一个例子来具体说明.

例 1-4 试用图解法求解如下线性规划问题:

$$\begin{aligned} \min z &= 2x_1 - x_2 \\ \text{s. t. } & 3x_1 + 2x_2 \leq 18 \\ & -x_1 + 4x_2 \leq 8 \\ & x_1 \geq 0, \quad x_2 \geq 0 \end{aligned}$$

第1步 作一个以变量 x_1, x_2 为坐标轴的直角坐标系(见图 1-1),并适当选取单位坐

标长度.

第2步 约束条件, 找出可行域. 约束条件 $3x_1 + 2x_2 \leq 18$ 可以分解为 $3x_1 + 2x_2 = 18$ 和 $3x_1 + 2x_2 < 18$, 前者在坐标系中是一条直线, 记为 L_1 ; 而后者位于这条直线左下方的半平面, 由此, $3x_1 + 2x_2 \leq 18$ 是位于含直线 L_1 的点及其左下方的半平面, 见图 1-1. 同理, 设直线 $-x_1 + 4x_2 = 8$ 为 L_2 , 则 $-x_1 + 4x_2 \leq 8$ 为 L_2 的右下半平面. 满足非负约束条件 $x_1 \geq 0$ 和 $x_2 \geq 0$ 的点分别为坐标轴的右半平面和上半平面. 因此, 满足所有约束条件的点应是上述 4 个半平面的交集, 即图 1-1 中四边形 $OABC$ 区域(含边界), 称之为可行域.




图 1-1

第3步 图示目标函数. 由于 z 是一个线性的目标函数值, 因此, 随着 z 的变化, $z = 2x_1 - x_2$ 是斜率为 2 的一簇互相平行的直线. 在同一直线 $2x_1 - x_2 = z_0$ 上的点 (x_1, x_2) , 它们的目标函数值相等, 因此称为等值线.

第4步 最优解的确定. 在等值线簇 $z = 2x_1 - x_2$ 中, z 取得最大且又在可行域内(或说与可行域相切)的直线 l^* 便是我们要寻找的, 其与可行域的交点就是最优解 x^* . 具体做法是, 首先求出函数 $z = 2x_1 - x_2$ 的梯度 $\nabla z = \left(\frac{\partial z}{\partial x_1}, \frac{\partial z}{\partial x_2} \right) = (2, -1)^T$, 记梯度向量 ∇z 的方向为 d ; 在坐标平面上画出 d , 然后将任意一条等值线如 l_1 , 沿 d 的反方向(即 z 值减少的方向)移动, 直到该直线与约束条件包围成的凸多边形相切为止, 切点即是最优解.

在本例中, 目标函数的等值线与凸多边形的切点是 C 点. 容易计算, C 点的坐标为 $(0, 2)$. 因此, 本题的最优解 $x^* = (0, 2)^T$, 最优值为 $z^* = -2$.

注意到, 若数学模型中对目标函数 z 是求极大值, 等值线显然应按梯度方向 d 移动, 从而求得 l^* 及最优解 x^* .

1.2.2 线性规划问题求解的几种可能结果

解的情形

从图解法作图结果来分析, 线性规划问题求解应有以下几种可能结果:

(1) 有唯一最优解. 如例 1-4.

(2) 有无穷多最优解. 如果将例 1-4 中的目标函数改为 $\max z = -2x_1 + 8x_2$, 则表示目

标函数的直线簇恰好与约束条件 $-x_1 + 4x_2 \leq 8$ 的直线平行, 当目标函数向优化方向移动时, 与可行域不是在一处点而是在线段 CB 上相切, 见图 1-2. 这时, 点 B 、 C 及 C 与 B 之间的所有点都使目标函数 z 达到最大值, 即有无穷多最优解.




图 1-2

(3) 无界解(也称无最优解). 如果将例 1-4 中的约束条件修改为

$$2x_2 \geq 12$$

$$x_1 \geq 0, \quad x_2 \geq 0$$

则所得到的线性规划的可行域可伸展到无穷, 即变量 x_2 的取值可无限增大, 不受限制, 由此目标函数值也可减少至负无穷(见图 1-3). 这种情况下问题的最优解无界. 产生无界解的原因是由于在建立实际问题数学模型时遗漏了某些必要资源约束条件.




图 1-3

(4) 无解或无可行解. 例如下述线性规划模型,

$$\max z = 2x_1 + x_2$$

$$\text{s. t. } x_1 + x_2 \leq 2$$

$$2x_1 + 2x_2 \geq 6$$

$$x_1 \geq 0, \quad x_2 \geq 0$$

用图解法求解时看出不存在满足所有约束的公共区域(可行域), 说明问题无解. 其原因是

模型的约束条件之间存在矛盾,建模时有错误.

从上面两小节的讨论中,不难得到两个变量线性规划问题的下述结论:

(1) 如果可行域非空且有界,则可行域是一个多边形,其顶点个数是有限个;若可行域非空但无界,其顶点个数也只有有限个.

(2) 若可行域非空且有界,则必有最优解;若可行域无界,则可能有最优解,也可能无最优解.

(3) 若线性规划问题有最优解(无论可行域有界还是无界),其最优解必可以在某个顶点达到. 最优解的个数或者是唯一的,或者有无穷多个.

事实上,对多变量线性规划问题也有类似结论,这可从下一节的讨论中看到.

1.3 线性规划的基本性质

本节以如下标准型线性规划为例来讨论一般线性规划的基本性质.

$$\begin{aligned} \min z &= c^T x \\ (\text{LP}) \quad \text{s.t.} \quad Ax &= b \\ x &\geq 0 \end{aligned}$$

不失一般性,假设(LP)的变量个数 n 大于约束条件个数 m 且矩阵 A 的秩为 m .

1.3.1 线性规划的基本概念

定义 1-1 凡是满足约束条件 $Ax = b$ 的非负向量 x 称为线性规划(LP)的可行解;全体可行解的集合称为可行域,记作 $X = \{x \in \mathbb{R}^n \mid Ax = b, x \geq 0\}$;而使目标函数 $z = c^T x$ 达到最小的可行解称为最优解.

定义 1-2 设约束条件的系数矩阵 A 的秩为 m ,则 A 中任一 m 阶可逆矩阵 B 称为线性规划(LP)的一个基矩阵,简称为一个基.若记 $B = [A_1 A_2 \cdots A_m]$,则称 A_j ($j=1,2,\cdots,m$) 为基 B 中的一个基向量,而 A 中其余 $n-m$ 个列向量称为非基向量.与基向量 A_j 相对应的决策变量 x_j 称为关于基 B 的一个基变量,而非基向量相对应的决策变量称为非基变量.

显然,线性规划(LP)最多有 C_n^m 个基,而关于每一个基的基变量共有 m 个,非基变量有 $n-m$ 个.

定义 1-3 取 A 中的一个基 B ,当令所有非基变量为 0 时,所求出的满足约束条件 $Ax = b$ 的解称为线性规划(LP)的一个基本解.

假设基 $B = [A_{j_1} A_{j_2} \cdots A_{j_m}]$,则对应的基变量为 $x_{j_1}, x_{j_2}, \cdots, x_{j_m}$,非基变量为 $x_{j_{m+1}}, x_{j_{m+2}}, \cdots, x_{j_n}$.若令 $x_B = (x_{j_1}, x_{j_2}, \cdots, x_{j_m})^T$, $x_N = (x_{j_{m+1}}, x_{j_{m+2}}, \cdots, x_{j_n})^T$,并将 A 中 $n-m$ 个非基向量组成的矩阵记为 $N = [A_{j_{m+1}} A_{j_{m+2}} \cdots A_{j_n}]$,则考虑到 $Ax = b \Leftrightarrow \sum_{j=1}^n A_j x_j = b \Leftrightarrow Bx_B + Nx_N = b$,便有

$$x_B = B^{-1}b - B^{-1}Nx_N \quad (1-6)$$

令非基变量 $x_{j_{m+1}} = x_{j_{m+2}} = \cdots = x_{j_n} = 0$,则由式(1-6)可求得

$$x_B = B^{-1}b \quad (1-7)$$

若记 $B^{-1}b = (\bar{b}_1, \dots, \bar{b}_m)^T$, 则 $x = (\bar{b}_1, \dots, \bar{b}_m, 0, \dots, 0)^T$ 就是关于基 B 的一个基本解.

由此可见, 对应于 A 中的每一个基 B , 就可找出一个基本解, 而 A 中最多有 C_n^m 个基, 因此线性规划问题最多有 C_n^m 个基本解.

定义 1-4 若 (LP) 的基本解 x 满足非负性, 则称 x 为 (LP) 的一个基本可行解, 而与 x 相对应的基 B 称为可行基. 若基本可行解 x 中所有基变量的值都严格大于 0, 则称 x 为 (LP) 的一个非退化基本可行解, 否则称之为退化基本可行解.

综上所述, 线性规划的各种解之间的关系可用文氏图 1-4 来表示.




图 1-4

例 1-5 试找出下面线性规划问题的所有基本解, 指出哪些是基本可行解, 并确定最优解.

$$\begin{aligned} \min z &= 5x_1 - 2x_2 + 3x_3 + 2x_4 \\ \text{s. t. } &x_1 + 2x_2 + 3x_3 + 4x_4 = 7 \\ &2x_1 + 2x_2 + x_3 + 2x_4 = 3 \\ &x_j \geq 0 \quad (j = 1, 2, 3, 4) \end{aligned}$$

解 在此问题中, $A = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 2 & 2 & 1 & 2 \end{bmatrix}$, $b = \begin{pmatrix} 7 \\ 3 \end{pmatrix}$, $m = 2$, $n = 4$ 且 $\text{rank}(A) = 2$.

设 $B_1 = \begin{bmatrix} 1 & 2 \\ 2 & 2 \end{bmatrix}$, 则 B_1 是一个基, x_1, x_2 是基变量, x_3, x_4 是非基变量. 由公式 (1-7) 知,

$$x_{B_1} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = B_1^{-1}b = \begin{bmatrix} -1 & 1 \\ 1 & -\frac{1}{2} \end{bmatrix} \cdot \begin{pmatrix} 7 \\ 3 \end{pmatrix} = \begin{pmatrix} -4 \\ \frac{11}{2} \end{pmatrix}$$

故基本解 $x^{(1)} = \left(-4, \frac{11}{2}, 0, 0\right)^T$. 由于 $-4 < 0$, 所以 $x^{(1)}$ 不是基本可行解.

设 $B_2 = \begin{bmatrix} 1 & 3 \\ 2 & 1 \end{bmatrix}$, 则 B_2 是一个基, x_1, x_3 是基变量, x_2, x_4 是非基变量. 由于

$$x_{B_2} = \begin{pmatrix} x_1 \\ x_3 \end{pmatrix} = B_2^{-1}b = \begin{bmatrix} -\frac{1}{5} & \frac{3}{5} \\ \frac{2}{5} & -\frac{1}{5} \end{bmatrix} \cdot \begin{pmatrix} 7 \\ 3 \end{pmatrix} = \begin{pmatrix} \frac{2}{5} \\ \frac{11}{5} \end{pmatrix}$$

所以基本解 $x^{(2)} = \left(\frac{2}{5}, 0, \frac{11}{5}, 0\right)^T$. 现在, $x^{(2)}$ 的所有分量都非负, 故 $x^{(2)}$ 是一个基本可行解, 而且是非退化的.

设 $B_3 = \begin{bmatrix} 1 & 4 \\ 2 & 2 \end{bmatrix}$, 则 B_3 是一个基, x_1, x_4 是基变量, x_2, x_3 是非基变量. 因为

$$x_{B_3} = \begin{pmatrix} x_1 \\ x_4 \end{pmatrix} = B_3^{-1}b = \begin{bmatrix} -\frac{1}{3} & \frac{2}{3} \\ \frac{1}{3} & -\frac{1}{6} \end{bmatrix} \cdot \begin{pmatrix} 7 \\ 3 \end{pmatrix} = \begin{pmatrix} -\frac{1}{3} \\ \frac{11}{6} \end{pmatrix}$$

所以基本解 $x^{(3)} = \left(-\frac{1}{3}, 0, 0, \frac{11}{6}\right)^T$. 由于 $x^{(3)}$ 的第一个分量为负, 故 $x^{(3)}$ 不是一个基本可行解.

设 $B_4 = \begin{bmatrix} 2 & 3 \\ 2 & 1 \end{bmatrix}$, 则 B_4 是一个基, x_2, x_3 是基变量, x_1, x_4 是非基变量. 由式(1-7)知,

$$x_{B_4} = \begin{pmatrix} x_2 \\ x_3 \end{pmatrix} = B_4^{-1}b = \begin{bmatrix} -\frac{1}{4} & \frac{3}{4} \\ \frac{1}{2} & -\frac{1}{2} \end{bmatrix} \cdot \begin{pmatrix} 7 \\ 3 \end{pmatrix} = \begin{pmatrix} \frac{1}{2} \\ 2 \end{pmatrix}$$

故基本解 $x^{(4)} = \left(0, \frac{1}{2}, 2, 0\right)^T$. 由于 $x^{(4)}$ 的所有分量为非负, 故 $x^{(4)}$ 是一个基本可行解, 并且是非退化的.

设 $B_5 = \begin{bmatrix} 2 & 4 \\ 2 & 2 \end{bmatrix}$, 则 B_5 是一个基, x_2, x_4 是基变量, x_1, x_3 是非基变量. 由于

$$x_{B_5} = \begin{pmatrix} x_2 \\ x_4 \end{pmatrix} = B_5^{-1}b = \begin{bmatrix} -\frac{1}{2} & 1 \\ \frac{1}{2} & -\frac{1}{2} \end{bmatrix} \cdot \begin{pmatrix} 7 \\ 3 \end{pmatrix} = \begin{pmatrix} -\frac{1}{2} \\ 2 \end{pmatrix}$$

因而基本解 $x^{(5)} = \left(0, -\frac{1}{2}, 0, 2\right)^T$. 由于 $-\frac{1}{2} < 0$, 故 $x^{(5)}$ 不是基本可行解.

设 $B_6 = \begin{bmatrix} 3 & 4 \\ 1 & 2 \end{bmatrix}$, 则 B_6 是一个基, x_3, x_4 是基变量, x_1, x_2 是非基变量. 因为

$$x_{B_6} = \begin{pmatrix} x_3 \\ x_4 \end{pmatrix} = B_6^{-1}b = \begin{bmatrix} 1 & -2 \\ -\frac{1}{2} & \frac{3}{2} \end{bmatrix} \cdot \begin{pmatrix} 7 \\ 3 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

所以基本解 $x^{(6)} = (0, 0, 1, 1)^T$. 由于 $x^{(6)}$ 的所有分量为非负, 故 $x^{(6)}$ 是一个基本可行解, 并且是非退化的.

由此可见, 该问题共有三个基本可行解 $x^{(2)}$, $x^{(4)}$ 和 $x^{(6)}$, 它们的目标函数值分别为 $\frac{43}{5}$, 5 和 5. 这样, 该问题的最优解为 $x^{(4)}$ 和 $x^{(6)}$, 最优值为 5.

1.3.2 凸集与凸集的顶点 线性规划的几何意义

为了研究线性规划的基本性质, 本节引入凸集和凸集顶点的概念.

我们知道, 平面上的长方形与圆、空间中的平行六面体和椭球体等都是凸的. 它们的共

同特性是:形体中任何两点的连线段整个地落在该形体中. 没有这个特性的形体就不是凸的,如图1-5中画出的集合 S_1 是凸的,而 S_2 不是凸的. 所以,以此特性作为一般凸集的定义.



图1-5

定义1-5 设 S 是 $\mathbb{R}^n$ 空间中的任一点集,若对任意 $x^{(1)}, x^{(2)} \in S$ 以及 $\alpha \in [0, 1]$,都有 $\alpha x^{(1)} + (1 - \alpha)x^{(2)} \in S$,则称 S 为一个凸集.

定义1-6 设 $x^{(1)}, x^{(2)}, \dots, x^{(k)}$ 是 $\mathbb{R}^n$ 空间中的 k 个点. 若存在实数 $\alpha_1, \alpha_2, \dots, \alpha_k$,其中 $\alpha_i \in [0, 1] (i = 1, 2, \dots, k)$ 且 $\sum_{i=1}^k \alpha_i = 1$,使得下式成立:

$$x = \alpha_1 x^{(1)} + \alpha_2 x^{(2)} + \dots + \alpha_k x^{(k)}$$

则称 x 为点 $x^{(1)}, x^{(2)}, \dots, x^{(k)}$ 的一个凸组合. 若式中的 $\alpha_i \in (0, 1) (i = 1, 2, \dots, k)$ 且 $\sum_{i=1}^k \alpha_i = 1$,则称 x 为点 $x^{(1)}, x^{(2)}, \dots, x^{(k)}$ 的一个严格凸组合.

显然,凸集 S 中任意两点 $x^{(1)}, x^{(2)}$ 连线上的任一点 x 都是 $x^{(1)}, x^{(2)}$ 的一个凸组合.

现在来说明什么是凸集的顶点. 在例1-4中,由图1-1看出,可行区域 X 中有四个“顶点”,即 $O(0,0), A(6,0), B(4,3)$ 和 $C(0,2)$. 容易看到,可行域 X 中除了这四个点以外,无论是边线上的点,还是区域内部的点,都能表示成 X 中另外两点连线中某一点,但这四个“顶点”却不能. 以此为特征,我们给出如下凸集顶点的定义.

定义1-7 设 S 是一个凸集,且 $x \in S$. 若对任何 $y \in S, z \in S$ 且 $y \neq z$ 以及 $\alpha \in (0, 1)$,都有 $x \neq \alpha y + (1 - \alpha)z$,即 x 不能表示为 S 中任意两个不同点的一个严格凸组合,则称 x 为凸集 S 的一个顶点.

换句话说,若 x 是 S 中的一个顶点,且有 $x = \alpha y + (1 - \alpha)z$,其中 $\alpha \in (0, 1), x, y \in S$,则必有 $x = y = z$. 按照此定义,长方形的四个角点就是长方形区域的全部顶点,而圆周上的点则是圆形区域的全部顶点. 在图1-1中,可行域 X 的四个点 O, A, B 和 C 的确是 X 的顶点. 与顶点 A 相邻的顶点是原点 O 和点 B ,与顶点 B 相邻的顶点是点 A 和 C ,如此等等.

1.3.3 线性规划的基本定理

定理1-1 若线性规划问题(LP)的可行域 X 非空,则 X 是一个凸集.

证 任取 $x^{(1)}, x^{(2)} \in X$ 和 $\alpha \in [0, 1]$. 一方面,显然有 $\alpha x^{(1)} + (1 - \alpha)x^{(2)} \geq 0$;另一方面, $A[\alpha x^{(1)} + (1 - \alpha)x^{(2)}] = \alpha Ax^{(1)} + (1 - \alpha)Ax^{(2)} = \alpha b + (1 - \alpha)b = b$. 将这两方面结合知, $\alpha x^{(1)} + (1 - \alpha)x^{(2)} \in X$. 这样,根据凸集的定义, X 是一个凸集. $\square$

引理1-1 线性规划问题(LP)的可行解 x 为基本可行解的充分必要条件是 x 的正分

量所对应的系数列向量线性无关.

证 设 $x = (x_1, x_2, \dots, x_n)^T$ 是线性规划问题 (LP) 的一个可行解, 则 x 的第 j 个分量 x_j 所对应的系数列向量为 A_j .

必要性 不失一般性, 假设可行解 x 是相应于基 $B = [A_1 A_2 \cdots A_m]$ 的一个基本可行解, 即 $x_1, x_2, \dots, x_m$ 为基变量. 设 x 中共有 k 个正分量且它们所对应的系数列向量为 $A_{i_1}, A_{i_2}, \dots, A_{i_k}$, 则必有 $k \leq m$ 且 $\{A_{i_1}, A_{i_2}, \dots, A_{i_k}\} \subseteq \{A_1, A_2, \dots, A_m\}$. 考虑到向量组 $A_1, A_2, \dots, A_m$ 线性无关, 故它的部分向量组 $A_{i_1}, A_{i_2}, \dots, A_{i_k}$ 也线性无关.

充分性 设可行解 x 的正分量所对应的系数列向量 $A_{i_1}, A_{i_2}, \dots, A_{i_k}$ 线性无关, 则考虑到 $\text{rank}(A) = m$, 显然有 $k \leq m$. 若 $k = m$, 则 x 是对应基阵 $[A_{i_1}, A_{i_2}, \dots, A_{i_k}]$ 的一个基本解且满足非负约束条件, 因而是 (LP) 的一个基本可行解. 若 $k < m$, 则一定可以从 A 中剩余 $n - k$ 个列向量中选出 $m - k$ 个与 $A_{i_1}, A_{i_2}, \dots, A_{i_k}$ 一起构成一个基, 其所确定的基本解恰是 x . 根据定义知, x 是 (LP) 的一个基本可行解. 至此, 我们证得引理结论成立.

定理 1-2 线性规划问题 (LP) 的每一个基本可行解 x 都对应于可行域 X 的一个顶点.

证 本定理需要证明: x 是可行域 X 的顶点 $\Leftrightarrow x$ 是 (LP) 的基本可行解.

(1) x 是可行域 X 上的一个顶点 $\Rightarrow x$ 是 (LP) 的基本可行解.

采用反证法. 假设 x 不是 (LP) 的基本可行解. 由于 x 是凸集 X 上的一个点, 故 x 必是 (LP) 的一个可行解, 从而它的非零分量必是正分量. 设 x 有 k 个正分量, 不失一般性, 令

$$x_1 > 0, x_2 > 0, \dots, x_k > 0, x_{k+1} = 0, \dots, x_n = 0$$

因为 x 不是 (LP) 的基本可行解, 故由引理知, 正分量 $x_1, x_2, \dots, x_k$ 所对应的列向量 $A_1, A_2, \dots, A_k$ 线性相关. 因此, 由线性代数知识知, 必存在一组不全为零的数组 $\delta_1, \delta_2, \dots, \delta_k$ 使得

$$\delta_1 A_1 + \delta_2 A_2 + \dots + \delta_k A_k = 0 \quad (1-8)$$

而由 x 是 (LP) 的一个可行解知,

$$x_1 A_1 + x_2 A_2 + \dots + x_k A_k = b \quad (1-9)$$

将式 (1-8) 乘上一个不为零的数 μ , 然后分别与式 (1-9) 相加和相减, 得到

$$(x_1 + \mu\delta_1)A_1 + (x_2 + \mu\delta_2)A_2 + \dots + (x_k + \mu\delta_k)A_k = b \quad (1-10)$$

和

$$(x_1 - \mu\delta_1)A_1 + (x_2 - \mu\delta_2)A_2 + \dots + (x_k - \mu\delta_k)A_k = b \quad (1-11)$$

令

$$x^{(1)} = [(x_1 + \mu\delta_1), (x_2 + \mu\delta_2), \dots, (x_k + \mu\delta_k), 0, \dots, 0]^T$$

$$x^{(2)} = [(x_1 - \mu\delta_1), (x_2 - \mu\delta_2), \dots, (x_k - \mu\delta_k), 0, \dots, 0]^T$$

则由式 (1-10) 和式 (1-11), $Ax^{(1)} = b, Ax^{(2)} = b$. 另外, 通过取 $\mu = \min_{\substack{\delta_j \neq 0 \\ 1 \leq j \leq k}} \left\{ \frac{x_j}{|\delta_j|} \right\}$ 可以保证

$x^{(1)} \geq 0, x^{(2)} \geq 0$. 这样, 就有 $x^{(1)} \in X, x^{(2)} \in X$ 且 $x^{(1)} \neq x^{(2)}$. 注意到 $x = \frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)}$, 即 x

可以表示为 X 中两个不同点 $x^{(1)}$ 与 $x^{(2)}$ 的凸组合, 这显然与 x 是 X 的一个顶点相矛盾. 故假设不成立, 从而证得结论成立. $\square$

(2) x 是 (LP) 的基本可行解 $\Rightarrow x$ 是可行域 X 上的一个顶点.

采用反证法. 假设 x 不是可行域 X 上的一个顶点, 则必可找到 X 中另外两个不同点 $x^{(1)}$ 与 $x^{(2)}$ 使得 $x = \alpha x^{(1)} + (1 - \alpha)x^{(2)}$ ($0 < \alpha < 1$), 或写为

$$x_j = \alpha x_j^{(1)} + (1 - \alpha)x_j^{(2)} \quad (0 < \alpha < 1) \quad (j = 1, 2, \dots, n)$$

由于 $\alpha > 0, 1 - \alpha > 0$, 故当 $x_j = 0$ 时, 必有 $x_j^{(1)} = x_j^{(2)} = 0$. 不失一般性, 假设 x 的前 m 个分量为基变量, 即

$$\sum_{j=1}^n A_j x_j = \sum_{j=1}^m A_j x_j = b \quad (1-12)$$

这样, 考虑到 $x^{(1)}$ 与 $x^{(2)}$ 是 (LP) 的可行解, 便有

$$\sum_{j=1}^n A_j x_j^{(1)} = \sum_{j=1}^m A_j x_j^{(1)} = b \quad (1-13)$$

和

$$\sum_{j=1}^n A_j x_j^{(2)} = \sum_{j=1}^m A_j x_j^{(2)} = b \quad (1-14)$$

将式 (1-13) 与式 (1-14) 相减, 得到

$$\sum_{j=1}^m A_j (x_j^{(1)} - x_j^{(2)}) = 0$$

由于 $x_j^{(1)} - x_j^{(2)}, j = 1, 2, \dots, m$ 不全为零, 因此 $A_1, A_2, \dots, A_m$ 线性无关, 即 x 不是 (LP) 的基本可行解. 这与已知条件矛盾, 故结论成立. $\square$

定理 1-3 若线性规划问题 (LP) 有最优解, 则一定存在一个基本可行解是最优解.

证 设 $x^* = (x_1^*, \dots, x_n^*)^T$ 是线性规划 (LP) 的一个最优解, $z = c^T x^*$ 是目标函数的最小值. 若 x^* 不是基本可行解, 则由定理 1-2 知, x^* 不是可行域 X 的顶点, 故必能在 X 内找到通过 x^* 的两点 $x^* - \mu\delta \geq 0$ 和 $x^* + \mu\delta \geq 0$, 其中 $\mu > 0$. 将这两点代入目标函数, 有 $c^T(x^* + \mu\delta) = c^T x^* + \mu c^T \delta$ 和 $c^T(x^* - \mu\delta) = c^T x^* - \mu c^T \delta$. 由于 $c^T x^*$ 为目标函数的最小值, 故有 $c^T x^* \leq c^T x^* + \mu c^T \delta$ 和 $c^T x^* \leq c^T x^* - \mu c^T \delta$. 由此得到 $c^T \delta = 0$, 即有

$$c^T(x^* + \mu\delta) = c^T x^* = c^T(x^* - \mu\delta)$$

如果 $x^* + \mu\delta$ 或 $x^* - \mu\delta$ 仍不是基本可行解, 按照上面的办法继续做下去, 最后一定可以找到一个基本可行解, 其目标函数值等于 $c^T x^*$. 故定理的结论成立.

将定理 1-2 和定理 1-3 结合, 即有如下结论:

定理 1-4 若线性规划问题 (LP) 有最优解, 则目标函数的最优值一定可以在可行域 X 的某个顶点上达到.

这一结论说明, 虽然可行域 X 中不是顶点的点也可能是最优解, 但我们可以不去管它, 只从顶点中寻找线性规划 (LP) 的最优解就行了.

习 题

1-1 用图解法求解下列线性规划问题, 并指出问题具有唯一最优解、无穷多最优解、无界解还是无可行解.

$$(1) \min z = 6x_1 + 4x_2$$

$$\text{s. t. } 2x_1 + x_2 \geq 1$$

$$3x_1 + 4x_2 \geq 1.5$$

$$x_1, x_2 \geq 0$$

$$(2) \max z = 4x_1 + 8x_2$$

$$\text{s. t. } 2x_1 + 2x_2 \leq 10$$

$$-x_1 + x_2 \geq 8$$

$$x_1, x_2 \geq 0$$

$$\begin{aligned}
 (3) \max z &= x_1 + x_2 \\
 \text{s. t. } 6x_1 + 10x_2 &\leq 120 \\
 5 &\leq x_1 \leq 10 \\
 3 &\leq x_2 \leq 8
 \end{aligned}$$

$$\begin{aligned}
 (4) \max z &= 3x_1 + 9x_2 \\
 \text{s. t. } x_1 + 3x_2 &\leq 22 \\
 -x_1 + x_2 &\leq 4 \\
 x_2 &\leq 6 \\
 2x_1 - 5x_2 &\leq 0 \\
 x_1, x_2 &\geq 0
 \end{aligned}$$

1-2 将下列线性规划问题化成标准型.

$$\begin{aligned}
 (1) \max z &= 3x_1 - x_2 + 2x_3 \\
 \text{s. t. } 2x_1 - x_2 + x_3 &\geq 4 \\
 -4x_1 + x_2 + 3x_3 &= 8 \\
 3x_1 + 2x_2 + x_3 &\leq 9 \\
 x_1, x_2 &\geq 0, x_3 \text{ 自由变量}
 \end{aligned}$$

$$\begin{aligned}
 (2) \min z &= |x_1| + |x_2| + |x_3| \\
 \text{s. t. } x_1 + x_2 &\leq 1 \\
 2x_1 + x_3 &= 3
 \end{aligned}$$

1-3 求出下列线性规划问题的所有基本解,指出哪些是基本可行解,并确定最优解.

$$\begin{aligned}
 (1) \max z &= 3x_1 + 5x_2 \\
 \text{s. t. } x_1 + x_3 &= 4 \\
 2x_2 + x_4 &= 12 \\
 3x_1 + 2x_2 + x_5 &= 18 \\
 x_j &\geq 0 \quad (j=1,2,\dots,5)
 \end{aligned}$$

$$\begin{aligned}
 (2) \max z &= 5x_1 - 2x_2 + 3x_3 + 2x_4 \\
 \text{s. t. } x_1 + 2x_2 + 3x_3 + 4x_4 &= 7 \\
 2x_1 + 2x_2 + x_3 + 2x_4 &= 3 \\
 x_j &\geq 0 \quad (j=1,2,3,4)
 \end{aligned}$$

1-4 已知某线性规划问题的约束条件为

$$\begin{cases} 2x_1 + x_2 - x_3 = 25 \\ x_1 + 3x_2 - x_4 = 30 \\ 4x_1 + 7x_2 - x_3 - 2x_4 - x_5 = 85 \\ x_j \geq 0 \quad (j=1,2,\dots,5) \end{cases}$$

判断下列各点是否为该线性规划问题的可行域凸集的顶点:

$$(1) x = (5, 15, 0, 20, 0)^T$$

$$(2) x = (9, 7, 0, 0, 8)^T$$

$$(3) x = (15, 5, 10, 0, 0)^T$$

第2章 单纯形法

由上章的定理1-3知,若线性规划问题有最优解,则一定存在一个基本可行解是最优解.因此,一种最直接的想法是,把线性规划问题的所有基本可行解都找出来,然后通过比较目标函数值大小来求最优解,如例1-5的求解方法.但这种方法一般是不可取的,因为线性规划(LP)的基本解个数最多可达到 C_n^m ,而 C_n^m 的值随 m 与 n 的增加而迅速增大,如当 $m=20, n=40$ 时, $C_n^m=1.3 \times 10^{11}$.要通过计算这么多个基本解来找出所有的基本可行解显然是行不通的.

G. B. Dantzig 在1947年提出了一种非常实用的寻找最优基本可行解的方法,称为单纯形法.它的基本思想是:先找出一个基本可行解(称之为初始基本可行解),然后判断其是否为最优解;如果不是,则转换到相邻且能改善当前目标函数值的基本可行解,一直找到最优解为止.换句话说,它通过沿着可行集的边界,从一个顶点转移到改善当前目标函数值的相邻顶点,以此来寻找最优解.该方法无论在理论上还是在实际应用中都取得了巨大成功,并且今天仍是求解线性规划问题的最有效方法之一.

2.1 单纯形法的原理

单纯形法的迭代过程主要由以下三个基本部分构成:确定初始基本可行解、判别当前基本可行解是否是最优解、从一个基本可行解转换到相邻且改善了的基本可行解.下面,依次介绍它的工作原理.

2.1.1 确定初始基本可行解

对任意线性规划问题,总可以在标准化过程中设法使所得到的标准型线性规划(LP)的约束系数矩阵 A 中存在一个 m 阶单位阵.因为:

(1)若线性规划的 m 个约束条件都是“ $\leq$ ”的形式且右端项都为非负,则在标准化时,每一个约束条件的左边都加上一个松弛变量 x_{n+i} ,该松弛变量所对应的系数列向量是 m 维单位向量 e_i .因此, m 个松弛变量 $x_{n+1}, x_{n+2}, \dots, x_{n+m}$ 所对应的系数向量组成的矩阵就为 m 阶单位阵.

(2)若第 i 个约束条件为“ $\geq$ ”的形式且右端项非负,则在该约束条件左端减去剩余变量化成标准形式后,再加上一个非负的新变量,称为人工变量.显然,该人工变量的系数列向量也为 m 维单位向量 e_i .

(3)若第 i 个约束条件为等式且右端项非负,则直接在该等式左端添加人工变量.

例如,某线性规划问题的约束条件为

$$3x_1 + 2x_2 - 4x_3 \geq -3$$

$$2x_1 - x_2 + 3x_3 \geq 5$$

$$x_1 + x_2 + x_3 = 20$$

$$x_1 \geq 0, \quad x_2 \geq 0, \quad x_3 \geq 0$$

则在第一个不等式约束的两端乘以 -1 , 将其变换为“ $\leq$ ”形式, 然后在不等式的左端添加松弛变量 x_4 ; 在第二个不等式约束左端减去剩余变量 x_5 后, 再加上人工变量 x_6 ; 在第三个等式约束的左端添加人工变量 x_7 , 得到

$$\begin{aligned} -3x_1 - 2x_2 + 4x_3 + x_4 &= 3 \\ 2x_1 - x_2 + 3x_3 - x_5 + x_6 &= 5 \\ x_1 + x_2 + x_3 + \cdots + x_7 &= 20 \\ x_j &\geq 0 \quad (j = 1, 2, \dots, 7) \end{aligned}$$

显然, 向量 A_4, A_6, A_7 就构成一个 3 阶单位矩阵.

当然, 在引进人工变量后, 所得到的线性规划的约束条件与原来的约束条件不完全等价. 为此, 需要在线性规划的目标函数上作些“修正”, 这将在第 2.3 节中进行详细讨论.

为了讨论方便, 将标准型线性规划(LP)中的变量次序重新调整并编号, 使对应单位阵的变量排在前 m 个变量的位置上(这对所讨论的结果没有影响, 而在实际计算时, 可不必调换次序). 这样, 可得到如下线性规划模型:

$$\begin{aligned} \min z &= \sum_{j=1}^n c_j x_j \\ \text{s. t. } x_1 + a_{1,m+1}x_{m+1} + \cdots + a_{1n}x_n &= b_1 \\ x_2 + a_{2,m+1}x_{m+1} + \cdots + a_{2n}x_n &= b_2 \\ &\vdots \\ x_m + a_{m,m+1}x_{m+1} + \cdots + a_{mn}x_n &= b_m \\ x_j &\geq 0 \quad (j = 1, 2, \dots, n) \end{aligned} \quad (2-1)$$

由于约束条件的系数矩阵中含有一个 m 阶单位矩阵 $[A_1 A_2 \cdots A_m]$, 故 $x_1, x_2, \dots, x_m$ 为基变量, $x_{m+1}, x_{m+2}, \dots, x_n$ 为非基变量. 令 $x_{m+1} = 0, x_{m+2} = 0, \dots, x_n = 0$, 并将其代入到上述模型的 m 个等式约束中, 得到基变量的值 $x_i = b_i \quad (i = 1, 2, \dots, m)$. 因为 $b_i \geq 0 \quad (i = 1, 2, \dots, m)$, 故得到初始基本可行解 $x^{(0)} = (b_1, b_2, \dots, b_m, 0, \dots, 0)^T$.

2.1.2 最优性检验和解的判别

下面我们来建立最优性准则. 根据这些准则, 不仅可以判别已得到的初始基本可行解或经过若干次迭代后得到的新基本可行解(统称为当前基本可行解)是否为最优解, 而且还可清楚地了解所要求解的线性规划问题的解的情况.

由问题(2-1)的 m 个等式约束知, 初始基本可行解 $x^{(0)}$ 的基变量用非基变量表示的式子为

$$x_i = b_i - \sum_{j=m+1}^n a_{ij}x_j \quad (i = 1, 2, \dots, m) \quad (2-2)$$

式中的 b_i 和 a_{ij} 为原始数据. 为了不引起混淆, 对当前基本可行解 $\bar{x}$ (可能是经若干次迭代后得到的基本可行解), 其基变量用非基变量表示的式子的一般形式为

$$\begin{aligned}
x_1 &= \bar{b}_1 - \bar{a}_{1,m+1}x_{m+1} + \cdots + \bar{a}_{1n}x_n \\
x_2 &= \bar{b}_2 - \bar{a}_{2,m+1}x_{m+1} + \cdots + \bar{a}_{2n}x_n \\
&\vdots \\
x_m &= \bar{b}_m - \bar{a}_{m,m+1}x_{m+1} + \cdots + \bar{a}_{mn}x_n
\end{aligned} \tag{2-3}$$

或简记作

$$x_i = \bar{b}_i - \sum_{j=m+1}^n \bar{a}_{ij}x_j \quad (i = 1, 2, \cdots, m) \tag{2-4}$$

将式(2-4)代入问题(2-1)的目标函数中,得到

$$\begin{aligned}
z = \mathbf{c}^T \mathbf{x} &= \sum_{i=1}^m c_i x_i + \sum_{j=m+1}^n c_j x_j = \sum_{i=1}^m c_i (\bar{b}_i - \sum_{j=m+1}^n \bar{a}_{ij}x_j) + \sum_{j=m+1}^n c_j x_j \\
&= \sum_{i=1}^m c_i \bar{b}_i - \sum_{i=1}^m \sum_{j=m+1}^n c_i \bar{a}_{ij}x_j + \sum_{j=m+1}^n c_j x_j \\
&= \sum_{i=1}^m c_i \bar{b}_i + \sum_{j=m+1}^n (c_j - \sum_{i=1}^m c_i \bar{a}_{ij})x_j
\end{aligned} \tag{2-5}$$

若用 $\bar{z}$ 表示当前基本可行解 $\bar{\mathbf{x}} = (\bar{b}_1, \bar{b}_2, \cdots, \bar{b}_m, 0, \cdots, 0)^T$ 对应的目标函数值,则容易计算

$\bar{z} = \sum_{i=1}^m c_i \bar{b}_i$, 即 $\bar{z}$ 为式(2-5)的第一项. 这样,引进如下记号:

$$\sigma_j = c_j - \sum_{i=1}^m c_i \bar{a}_{ij} \quad (j = 1, 2, \cdots, n) \tag{2-6}$$

则式(2-5)可简单地记为

$$z = \bar{z} + \sum_{j=m+1}^n \sigma_j x_j \tag{2-7}$$

我们称式(2-6)定义的 σ_j 为变量 x_j 的检验数. 注意到,当 $j = 1, 2, \cdots, m$ 时,

$$\bar{a}_{ij} = \begin{cases} 0 & i \neq j \\ 1 & i = j \end{cases}$$

故

$$c_j - \sum_{i=1}^m c_i \bar{a}_{ij} = 0 \quad (j = 1, 2, \cdots, m) \tag{2-8}$$

即基变量所对应的检验数为0. 为了书写方便,后面用 J_B 表示基变量的下标集, J_N 表示非基变量的下标集.

综上所述,相应于基本可行解 $\bar{\mathbf{x}} = (\bar{b}_1, \bar{b}_2, \cdots, \bar{b}_m, 0, \cdots, 0)^T$, 标准型线性规划(LP)可表述为如下典则形式:

$$\begin{aligned}
\min z &= \bar{z} + \sum_{j=m+1}^n \sigma_j x_j \\
\text{s. t. } x_i &= \bar{b}_i - \sum_{j=m+1}^n \bar{a}_{ij}x_j \quad (i = 1, 2, \cdots, m) \\
x_j &\geq 0 \quad (j = 1, 2, \cdots, n)
\end{aligned} \tag{2-9}$$

该形式充分反映了当前基本可行解 $\bar{\mathbf{x}}$ 的特征,根据其系数的情况,则有下面定理.

定理 2-1 若当前基本可行解 $\bar{\mathbf{x}}$ 的所有非基变量的检验数 $\sigma_j \geq 0 \quad (j \in J_N)$, 则基本可

行解 $\bar{x}$ 为线性规划 (LP) 的最优解. $\square$

证 设 x 为线性规划 (LP) 的任一可行解. 由 $x \geq 0$ 可知, $\sum_{j \in J_N} \sigma_j x_j \geq 0$, 而根据 (LP) 的典则形式 (2-9),

$$z = c^T x = \bar{z} + \sum_{j \in J_N} \sigma_j x_j \geq \bar{z} = c^T \bar{x}$$

这说明 $\bar{x}$ 是线性规划 (LP) 的最优解. $\square$

定理 2-2 假设当前基本可行解 $\bar{x}$ 是非退化的. 若它的所有非基变量检验数 $\sigma_j \geq 0$ ($j \in J_N$) 且存在某个 $k \in J_N$ 使 $\sigma_k = 0$, 则线性规划 (LP) 有无穷多最优解.

证明 根据定理 2-1 知, $\bar{x}$ 是线性规划问题 (LP) 的最优解. 记式 (2-3) 中变量 x_i 所对应的系数向量为 $\bar{A}_i$. 那么, 当 $i = 1, 2, \dots, m$ 时, $\bar{A}_i$ 为 m 维单位向量 e_i , 而当

$$i = m+1, m+2, \dots, n$$

时, $\bar{A}_i = (\bar{a}_{1i}, \bar{a}_{2i}, \dots, \bar{a}_{mi})^T$. 下面分两种情形讨论:

(1) 非基变量 x_k 所对应的系数向量 $\bar{A}_k$ 中至少有一个分量 $\bar{a}_{ik} > 0$. 令

$$\theta = \min_{1 \leq i \leq m} \left\{ \frac{\bar{x}_i}{\bar{a}_{ik}} \mid \bar{a}_{ik} > 0 \right\} = \frac{\bar{x}_l}{\bar{a}_{lk}}$$

则由 $\bar{x}$ 的非退化性知, $\theta > 0$. 定义如下向量:

$$\hat{x} = (\bar{x}_1 - \theta \bar{a}_{1k}, \bar{x}_2 - \theta \bar{a}_{2k}, \dots, \bar{x}_m - \theta \bar{a}_{mk}, 0, \dots, \theta, \dots, 0)^T \quad (2-10)$$

其中 θ 是 $\hat{x}$ 的第 k 个坐标的值, 则显然有 $\hat{x} \geq 0$ 成立. 另外,

$$\sum_{i=1}^n \bar{A}_i \hat{x}_i = \sum_{i=1}^m \bar{A}_i \bar{x}_i - \sum_{i=1}^m \bar{A}_i \theta \bar{a}_{ik} + \theta \bar{A}_k = \bar{b} - \theta \bar{A}_k + \theta \bar{A}_k = \bar{b}$$

即 $\hat{x}$ 满足式 (2-3) 中的方程组, 从而满足 (LP) 的等式约束 $Ax = b$. 这说明式 (2-10) 定义的 $\hat{x}$ 是 (LP) 的一个可行解. 而由 (LP) 的典则形式 (2-9),

$$c^T \hat{x} = \bar{z} + \sum_{j \in J_N} \sigma_j \hat{x}_j = \bar{z} + \sigma_k \hat{x}_k = \bar{z}$$

故 $\hat{x}$ 也是 (LP) 的最优解, 而且由 $\theta > 0$ 知, $\hat{x}$ 不同于 $\bar{x}$. 这样, 由 (LP) 的可行域为凸集的性质知, $\hat{x}$ 与 $\bar{x}$ 连线上的任意一点都是 (LP) 的可行解, 并且它们的目标函数值为 $\bar{z}$. 因此, (LP) 有无穷多个最优解. $\square$

(2) 非基变量 x_k 所对应的系数向量 $\bar{A}_k \leq 0$. 此时, 任取 $\theta > 0$, 并按式 (2-10) 定义向量 $\hat{x}$, 则类似情形 (1) 的讨论, 也可证明 (LP) 有无穷多个最优解.

定理 2-3 若当前基本可行解 $\bar{x}$ 的某个非基变量的检验数 $\sigma_k < 0$, 而相应的系数向量 $\bar{A}_k \leq 0$, 则线性规划问题 (LP) 具有无界解.

证 令 $d = \begin{pmatrix} -\bar{A}_k \\ 0 \end{pmatrix} + e_k$, 其中 e_k 是第 k 个元素为 1, 而其他元素为 0 的一个 n 维单位向量. 由 $\bar{A}_k \leq 0$ 知, 向量 $d \geq 0$. 注意到,

$$\begin{aligned} \bar{A}d &= [\bar{A}_1 \cdots \bar{A}_m \bar{A}_{m+1} \cdots \bar{A}_k \cdots \bar{A}_n] \begin{pmatrix} -\bar{A}_k \\ 0 \end{pmatrix} + [\bar{A}_1 \cdots \bar{A}_m \bar{A}_{m+1} \cdots \bar{A}_k \cdots \bar{A}_n] e_k \\ &= [e_1 \cdots e_m \bar{A}_{m+1} \cdots \bar{A}_k \cdots \bar{A}_n] \begin{pmatrix} -\bar{A}_k \\ 0 \end{pmatrix} + [e_1 \cdots e_m \bar{A}_{m+1} \cdots \bar{A}_k \cdots \bar{A}_n] e_k \\ &= -\bar{A}_k + \bar{A}_k = 0 \end{aligned}$$

因此, 对充分大的正数 θ , $\bar{x} + \theta d \geq 0$ 且 $\bar{A}(\bar{x} + \theta d) = \bar{A}\bar{x} + \theta \bar{A}d = \bar{b}$. 这说明 $\bar{x} + \theta d$ 是线性规划

(LP)的可行解,它所对应的目标函数值为

$$c^T(\bar{x} + \theta d) = \bar{z} + \sum_{j \in J_N} \sigma_j(\bar{x}_j + \theta d_j) = \bar{z} + \theta \sum_{j \in J_N} \sigma_j d_j = \bar{z} + \theta \sigma_k$$

由于 $\sigma_k < 0$, 而 $\theta > 0$ 可任意地大, 故线性规划的目标函数无下界. $\square$

2.1.3 从一个基本可行解转换到相邻且改善了的基本可行解

定义 2-1 两个基本可行解之间变换且仅变换了一个基变量, 则称它们是互为相邻的.

例如, 在例 1-5 中, 基本可行解 $x^{(2)} = \left(\frac{2}{5}, 0, \frac{11}{5}, 0\right)^T$ 与 $x^{(4)} = \left(0, \frac{1}{2}, 2, 0\right)^T$ 和 $x^{(6)} = (0, 0, 1, 1)^T$ 都相邻.

假设当前基本可行解 $\bar{x}$ 非退化且不是最优解. 将式(2-3)改写为向量形式

$$\sum_{i=1}^m \bar{A}_i x_i + \sum_{j=m+1}^n \bar{A}_j x_j = \bar{b} \quad (2-11)$$

式中 $\bar{A}_i, i=1, 2, \dots, n$ 同上, $\bar{b} = (\bar{b}_1, \bar{b}_2, \dots, \bar{b}_m)^T$. 考虑到 $\bar{x}_{m+1} = 0, \dots, \bar{x}_n = 0$, 基本可行解 $\bar{x}$ 显然满足

$$\sum_{i=1}^m \bar{A}_i \bar{x}_i = \bar{b} \quad (2-12)$$

另外, 写出式(2-11)中系数矩阵的增广矩阵

$$\begin{array}{ccccccc} \bar{A}_1 & \bar{A}_2 & \cdots & \bar{A}_m & \bar{A}_{m+1} & \cdots & \bar{A}_j & \cdots & \bar{A}_n & \bar{b} \\ \left[\begin{array}{ccccccc} 1 & 0 & \cdots & 0 & \bar{a}_{1,m+1} & \cdots & \bar{a}_{1j} & \cdots & \bar{a}_{1n} & \bar{b}_1 \\ 0 & 1 & \cdots & 0 & \bar{a}_{2,m+1} & \cdots & \bar{a}_{2j} & \cdots & \bar{a}_{2n} & \bar{b}_2 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & \bar{a}_{m,m+1} & \cdots & \bar{a}_{mj} & \cdots & \bar{a}_{mn} & \bar{b}_m \end{array} \right] \end{array} \quad (2-13)$$

由于 $\bar{A}_1, \bar{A}_2, \dots, \bar{A}_m$ 是一个基, 其他向量 $\bar{A}_j$ 可用这个基的线性组合来表示, 因而有

$$\bar{A}_j - \sum_{i=1}^m \bar{a}_{ij} \bar{A}_i = 0 \quad (j = m+1, m+2, \dots, n)$$

特别地, 对检验数小于零的非基变量 $x_k (m+1 \leq k \leq n)$ 的系数向量 $\bar{A}_k$, 有

$$\bar{A}_k - \sum_{i=1}^m \bar{a}_{ik} \bar{A}_i = 0 \quad (2-14)$$

将式(2-14)乘上一个正数 θ , 然后与式(2-12)相加, 经过整理后有

$$\sum_{i=1}^m (\bar{x}_i - \theta \bar{a}_{ik}) \bar{A}_i + \theta \bar{A}_k = \bar{b} \quad (2-15)$$

由式(2-15), 可以找到满足式(2-13)或 $Ax = b$ 的另一个点 $\bar{x}$:

$$\bar{x} = (\bar{x}_1 - \theta \bar{a}_{1k}, \bar{x}_2 - \theta \bar{a}_{2k}, \dots, \bar{x}_m - \theta \bar{a}_{mk}, 0, \dots, \theta, \dots, 0)^T \quad (2-16)$$

其中 θ 是 $\bar{x}$ 的第 k 个坐标值. 由于 $\theta > 0$, 要使 $\bar{x}$ 是 (LP) 的一个可行解, 则必须有

$$\bar{x}_i - \theta \bar{a}_{ik} \geq 0 \quad (i = 1, 2, \dots, m) \quad (2-17)$$

而且这 m 个不等式中至少有一个等号成立. 因为当 $\bar{a}_{ik} \leq 0$ 时, 式(2-17)显然成立, 因此可按如下公式来定义 θ :

$$\theta = \min_{1 \leq i \leq m} \left\{ \frac{\bar{x}_i}{\bar{a}_{ik}} \mid \bar{a}_{ik} > 0 \right\} = \min_{1 \leq i \leq m} \left\{ \frac{\bar{b}_i}{\bar{a}_{ik}} \mid \bar{a}_{ik} > 0 \right\} = \frac{\bar{x}_l}{\bar{a}_{lk}} \quad (2-18)$$

由式(2-18), $\bar{x}_i - \theta \bar{a}_{ik} \begin{cases} = 0 & (i=l) \\ \geq 0 & (i \neq l) \end{cases}$, 故 $\bar{x}$ 是(LP)的一个可行解. 此时, 与变量 $\bar{x}_1, \dots, \bar{x}_{l-1}, \bar{x}_{l+1}, \dots, \bar{x}_m, \theta$ 对应的向量, 经重新排列后加上 $\bar{b}$ 列, 构成如下形式矩阵:

$$\begin{array}{cccccccc|c} \bar{A}_1 & \bar{A}_2 & \cdots & \bar{A}_{l-1} & \bar{A}_k & \bar{A}_{l+1} & \cdots & \bar{A}_m & \bar{b} \\ \hline 1 & 0 & \cdots & 0 & \bar{a}_{1k} & 0 & \cdots & 0 & \bar{b}_1 \\ 0 & 1 & \cdots & 0 & \bar{a}_{2k} & 0 & \cdots & 0 & \bar{b}_2 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & \bar{a}_{l-1,k} & 0 & \cdots & 0 & \bar{b}_{l-1} \\ 0 & 0 & \cdots & 0 & \bar{a}_{lk} & 0 & \cdots & 0 & \bar{b}_l \\ 0 & 0 & \cdots & 0 & \bar{a}_{l+1,k} & 1 & \cdots & 0 & \bar{b}_{l+1} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & 0 & \bar{a}_{mk} & 0 & \cdots & 1 & \bar{b}_m \end{array} \quad (2-19)$$

因 $\bar{a}_{lk} > 0$, 由 m 个列向量 $\bar{A}_1, \dots, \bar{A}_{l-1}, \bar{A}_k, \bar{A}_{l+1}, \dots, \bar{A}_m$ 的元素组成的行列式不为零, 故

$$[\bar{A}_1 \cdots \bar{A}_{l-1} \bar{A}_k \bar{A}_{l+1} \cdots \bar{A}_m]$$

是一个基. 因此, $\bar{x}$ 是标准型线性规划(LP)的一个基本可行解, 而且, 由 $\bar{x}$ 的非退化性知, 式(2-18)定义的 $\theta > 0$, 从而 $\bar{x}$ 也是非退化的. 这意味着, 如果初始基本可行解 $x^{(0)}$ 为非退化的, 则通过上述办法得到的后续迭代点也都是非退化的, 即(LP)存在着非退化的最优解. 至于(LP)只有退化最优解的情形, 将在2.4节中进行讨论.

在式(2-19)的增广矩阵中进行行初等变换, 将第 l 行乘以 $\frac{1}{\bar{a}_{lk}}$, 再分别乘以 $-\bar{a}_{ik} (i=1, \dots, l-1, l+1, \dots, m)$ 加到各行中去, 则增广矩阵的左半部变成单位矩阵, 又因 $\theta = \frac{\bar{b}_l}{\bar{a}_{lk}}$, 故 $\bar{b}$ 列元素相应地变成

$$\bar{b}_1 - \theta \bar{a}_{1k}, \dots, \bar{b}_{l-1} - \theta \bar{a}_{l-1,k}, \theta, \bar{b}_{l+1} - \theta \bar{a}_{l+1,k}, \dots, \bar{b}_m - \theta \bar{a}_{mk}$$

因此, $\bar{x}$ 是同 $\bar{x}$ 相邻的基本可行解, 且基向量组成的矩阵仍为单位阵. 而由式(2-9)和 $\sigma_k < 0$ 知, 其目标函数值

$$\bar{z} = c^T \bar{x} = \bar{z} + \sum_{j \in J_N} \sigma_j \bar{x}_j = \bar{z} + \theta \sigma_k < \bar{z}$$

这说明 $\bar{x}$ 是一个改善了的基本可行解.

2.2 单纯形法的计算步骤

由上一节的讨论知, 若初始可行基为单位阵, 则由式(2-16)和式(2-18)确定的后续迭代点所对应的可行基仍是单位阵. 这样, 就可以通过表格形式用单纯形法来求解线性规划问题. 我们将这种表格称为单纯形表. 下面介绍单纯形表的格式, 然后根据上一节中讲述的原理, 给出单纯形法的计算步骤.

由于通过变量次序重新调整并编号, 线性规划(LP)可写为式(2-1)的形式, 即

$$\begin{aligned}
\min z &= c_1 x_1 + c_2 x_2 + \cdots + c_n x_n \\
\text{s. t. } x_1 &+ a_{1,m+1} x_{m+1} + \cdots + a_{1n} x_n = b_1 \\
x_2 &+ a_{2,m+1} x_{m+1} + \cdots + a_{2n} x_n = b_2 \\
&\vdots \\
x_m &+ a_{m,m+1} x_{m+1} + \cdots + a_{mn} x_n = b_m \\
x_j &\geq 0 \quad (j = 1, 2, \cdots, n)
\end{aligned} \tag{2-20}$$

注意到,式(2-1)中的等式约束条件是一个由 m 个方程 n 个未知量组成的线性非齐次方程组,其增广矩阵是一个 m 行 $n+1$ 列的矩阵,见表 2-1。

表 2-1

x_1	x_2	$\cdots$	x_m	x_{m+1}	$\cdots$	x_j	$\cdots$	x_n	右
1	0	$\cdots$	0	$a_{1,m+1}$	$\cdots$	a_{1j}	$\cdots$	a_{1n}	b_1
0	1	$\cdots$	0	$a_{2,m+1}$	$\cdots$	a_{2j}	$\cdots$	a_{2n}	b_2
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	
0	0	$\cdots$	1	$a_{m,m+1}$	$\cdots$	a_{mj}	$\cdots$	a_{mn}	b_m

为了在计算过程中能同时计算检验数,将式(2-20)中的目标函数表达式改写为

$$-z + c_1 x_1 + c_2 x_2 + \cdots + c_n x_n = 0 \tag{2-21}$$

将式(2-21)作为式(2-20)的第 $m+1$ 个方程,并将 $-z$ 看作一个变量,则得到如下 $m+1$ 个方程 $n+1$ 个变量的方程组:

$$\begin{aligned}
x_1 &+ a_{1,m+1} x_{m+1} + \cdots + a_{1n} x_n = b_1 \\
x_2 &+ a_{2,m+1} x_{m+1} + \cdots + a_{2n} x_n = b_2 \\
&\vdots \\
x_m &+ a_{m,m+1} x_{m+1} + \cdots + a_{mn} x_n = b_m \\
c_1 x_1 + c_2 x_2 + \cdots + c_m x_m - z + c_{m+1} x_{m+1} + \cdots + c_n x_n &= 0
\end{aligned} \tag{2-22}$$

上述方程组所对应的增广矩阵为表 2-2(变量 z 在前 m 个方程中系数总为 0,而在最后一个方程中系数总为 1,故在表 2-2 中不再列出 z 的系数)所列:

表 2-2

x_1	x_2	$\cdots$	x_m	x_{m+1}	$\cdots$	x_j	$\cdots$	x_n	右
1	0	$\cdots$	0	$a_{1,m+1}$	$\cdots$	a_{1j}	$\cdots$	a_{1n}	b_1
0	1	$\cdots$	0	$a_{2,m+1}$	$\cdots$	a_{2j}	$\cdots$	a_{2n}	b_2
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	
0	0	$\cdots$	1	$a_{m,m+1}$	$\cdots$	a_{mj}	$\cdots$	a_{mn}	b_m
c_1	c_2	$\cdots$	c_m	c_{m+1}	$\cdots$	c_j	$\cdots$	c_n	0

如果对表 2-2 中的矩阵实行初等行变换:将第 1 行的 $(-c_1)$ 倍,第 2 行的 $(-c_2)$ 倍, $\cdots$,第 m 行的 $(-c_m)$ 倍都加到第 $m+1$ 行就变成以下结果:

$$\left(0, 0, \cdots, 0, c_{m+1} - \sum_{i=1}^m c_i a_{i,m+1}, \cdots, c_n - \sum_{i=1}^m c_i a_{in}, - \sum_{i=1}^m c_i b_i \right)$$

注意到式(2-6)中的 $\sigma_j = c_j - \sum_{i=1}^m c_i \bar{a}_{ij}$ 及 $z_0 = \mathbf{c}^T \mathbf{x}^{(0)} = \sum_{i=1}^m c_i b_i$, 表2-2就变为

表2-3

x_1	x_2	$\cdots$	x_m	x_{m+1}	$\cdots$	x_j	$\cdots$	x_n	右
1	0	$\cdots$	0	$a_{1,m+1}$	$\cdots$	a_{1j}	$\cdots$	a_{1n}	b_1
0	1	$\cdots$	0	$a_{2,m+1}$	$\cdots$	a_{2j}	$\cdots$	a_{2n}	b_2
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	
0	0	$\cdots$	1	$a_{m,m+1}$	$\cdots$	a_{mj}	$\cdots$	a_{mn}	b_m
0	0	$\cdots$	0	σ_{m+1}	$\cdots$	σ_j	$\cdots$	σ_n	$-z_0$

表2-3中最后一行体现了检验数,因此又称检验数行.

依据表2-3的矩阵,对单纯形法的计算设计了一种专门表格,称为单纯形表(见表2-4).表中第1行是价值系数行,标出了决策变量 x_j 的价值系数 c_j ($j=1,2,\cdots,n$);第2行是标识行,标出表中主体各列的含义;最后一行是检验数行,其各元素为对应决策变量 x_j 的检验数 σ_j ($j=1,2,\cdots,n$),其中基变量的检验数为零.表中的第1列是 c_B 列,标出基变量的价值系数;第2列是 x_B 列,标出当前基变量的名称;第3列是右端项,其 m 个元素是当前基本可行解的基变量的值;其余各列标出等式约束条件中决策变量 x_j 的系数列向量 A_j ($j=1,\cdots,n$).

表2-4

$c_j \rightarrow$			c_1	$\cdots$	c_m	$\cdots$	c_j	$\cdots$	c_n
c_B	基	$\bar{b}$	x_1	$\cdots$	x_m	$\cdots$	x_j	$\cdots$	x_n
c_1	x_1	b_1	1	$\cdots$	0	$\cdots$	a_{1j}	$\cdots$	a_{1n}
c_2	x_2	b_2	0	$\cdots$	0	$\cdots$	a_{2j}	$\cdots$	a_{2n}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\cdots$	$\vdots$	$\cdots$	$\vdots$
c_m	x_m	b_m	0	$\cdots$	1	$\cdots$	a_{mj}	$\cdots$	a_{mn}
σ_j			0	$\cdots$	0	$\cdots$	$c_j - \sum_{i=1}^m c_i a_{ij}$	$\cdots$	$c_n - \sum_{i=1}^m c_i a_{in}$

一旦建立了初始单纯形表2-4,就可按下述单纯形法的步骤在单纯形表中求解线性规划问题.具体步骤如下:

第1步 求初始基本可行解,列出初始单纯形表2-4.对非标准型线性规划问题首先要化成标准形式.由于总可以设法使(LP)的约束条件系数矩阵 A 中包含一个单位阵,故可以此单位阵作为基求出初始基本可行解.

第2步 最优性检验.如果表中所有非基变量的检验数 $\sigma_j \geq 0$ ($j \in J_N$),且基变量中不含有工变量,则表中的基本可行解即为最优解,计算结束(对基变量中含人工变量时的解的最优性检验将在下一节中讨论).当表中存在某个 $\sigma_k < 0$,而 $A_k \leq 0$,则问题为无界解,计算结束;否则转下一步.

第3步 从一个基本可行解转换到相邻的目标函数值更小的基本可行解,列出新的单纯形表.

(1)确定换入基的变量. 只要有检验数 $\sigma_j < 0$, 对应的变量 x_j 就可作为换入基的变量. 当有一个以上变量的检验数小于零时,一般从中找出最小的 σ_k :

$$\sigma_k = \min_j \{ \sigma_j \mid \sigma_j < 0 \}$$

其对应的变量 x_k 作为换入基的变量(简称**进基变量**).

(2)确定换出基的变量. 根据前一节确定 θ 的规则,对 A_k 列由式(2-18)计算得到

$$\theta = \min_{1 \leq i \leq m} \left\{ \frac{b_i}{a_{ik}} \mid a_{ik} > 0 \right\} = \frac{b_l}{a_{lk}} \quad (2-23)$$

由此确定 x_l 是换出基的变量(简称**离基变量**). 元素 a_{lk} 决定了从一个基本可行解到相邻基本可行解的转移去向,取名**主元素**.

(3)用进基变量 x_k 替换基变量中的离基变量 x_l , 得到一个新基 $[A_1 A_2 \cdots A_m]$ 对应此基可以找出一个新的基本可行解,并相应地画出一张新单纯形表(表2-5). 在这个新表中的基仍应是单位矩阵,即 A_k 应变换成单位向量. 为此,在表2-4中进行初等行变换,并将运算结果填入表2-5中的相应位置.

(a)将主元素所在 l 行数字除以主元素 a_{lk} , 即有

$$\bar{b}_l = \frac{b_l}{a_{lk}}, \quad \bar{a}_{lj} = \frac{a_{lj}}{a_{lk}} \quad (2-24)$$

(b)将表2-5中刚计算得到的第 l 行数字乘上 $(-a_{ik})$ 加到表2-4的第 i 行数字上,并将所得到的结果记入表2-5的相应行,即有

$$\bar{b}_i = b_i - \frac{b_l}{a_{lk}} \cdot a_{ik}, \quad \bar{a}_{ij} = a_{ij} - \frac{a_{lj}}{a_{lk}} \cdot a_{ik} \quad (i \neq l) \quad (2-25)$$

(c)表2-5中检验数行的各元素的求法见式(2-6), 其中

$$\begin{aligned} \bar{\sigma}_l &= c_l - \frac{1}{a_{lk}} \left[- \sum_{i=1}^{l-1} c_i a_{ik} + c_k - \sum_{i=l+1}^m c_i a_{ik} \right] \\ &= - \frac{c_k}{a_{lk}} + \frac{1}{a_{lk}} \sum_{i=1}^m c_i a_{ik} = - \frac{\sigma_k}{a_{lk}} \end{aligned} \quad (2-26)$$

$$\begin{aligned} \bar{\sigma}_j &= c_j - \left[\sum_{i=1}^{l-1} c_i a_{ij} + \sum_{i=l+1}^m c_i a_{ij} \right] - \frac{a_{lj}}{a_{lk}} \left[- \sum_{i=1}^{l-1} c_i a_{ik} + c_k - \sum_{i=l+1}^m c_i a_{ik} \right] \\ &= \left(c_j - \sum_{i=1}^m c_i a_{ij} \right) - \frac{a_{lj}}{a_{lk}} \left(c_k - \sum_{i=1}^m c_i a_{ik} \right) = \sigma_j - \frac{a_{lj}}{a_{lk}} \cdot \sigma_k \end{aligned} \quad (2-27)$$

由上述两式可以看到,表2-5中的检验数行实际是将表2-5中刚计算得到的第 l 行数字乘上 $(-\sigma_k)$ 加到表2-4的检验数行而得到的.

第4步 重复第2、3两步,直到找到最优解.

表 2-5

$c_j \rightarrow$			c_1	...	c_l	...	c_m	...	c_j	...	c_k	...
c_B	基	$\bar{b}$	x_1	...	x_l	...	x_m	...	x_j	...	x_k	...
c_1	x_1	$b_1 - b_l \cdot \frac{a_{1k}}{a_{lk}}$	1	...	$-\frac{a_{1k}}{a_{lk}}$	...	0	...	$a_{1j} - a_{1k} \cdot \frac{a_{lj}}{a_{lk}}$	...	0	...
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
c_k	x_k	$\frac{b_l}{a_{lk}}$	0	...	$\frac{1}{a_{lk}}$	...	0	...	$\frac{a_{lj}}{a_{lk}}$	...	1	...
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
c_m	x_m	$b_m - b_l \cdot \frac{a_{mk}}{a_{lk}}$	0	...	$-\frac{a_{mk}}{a_{lk}}$	...	1	...	$a_{mj} - a_{mk} \cdot \frac{a_{lj}}{a_{lk}}$	...	0	...
σ_j			0	...	$-\frac{\sigma_k}{a_{lk}}$	...	0	...	$\sigma_j - \sigma_k \cdot \frac{a_{lj}}{a_{lk}}$	...	0	...

下面以一个例子来说明用单纯形法解线性规划的具体过程.

例 2-1 用单纯形法求解例 1-1 中的线性规划问题.

解 将该问题化成标准形式有

$$\begin{aligned} \min z' &= -5x_1 - 2x_2 + 0 \cdot x_3 + 0 \cdot x_4 + 0 \cdot x_5 \\ \text{s. t. } 30x_1 + 20x_2 + x_3 &= 160 \\ 5x_1 + x_2 + x_4 &= 15 \\ x_1 + x_5 &= 4 \\ x_j &\geq 0 \quad (j = 1, 2, \dots, 5) \end{aligned}$$

(2-28)

其约束条件的系数矩阵的增广矩阵为

$$\begin{matrix} A_1 & A_2 & A_3 & A_4 & A_5 & b \\ \begin{bmatrix} 30 & 20 & 1 & 0 & 0 & 160 \\ 5 & 1 & 0 & 1 & 0 & 15 \\ 1 & 0 & 0 & 0 & 1 & 4 \end{bmatrix} \end{matrix}$$

由于 $[A_3A_4A_5]$ 是单位矩阵,构成一个基,对应变量 x_3, x_4, x_5 是基变量. 令非基变量 x_1, x_2 等于0,即可找到一个初始基本可行解 $x^{(0)} = (0, 0, 160, 15, 4)^T$,以此列出初始单纯形表 2-6:

表 2-6

$c_j \rightarrow$			-5	-2	0	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5
0	x_3	160	30	20	1	0	0
0	x_4	15	[5]	1	0	1	0
0	x_5	4	1	0	0	0	1
σ_j			-5	-2	0	0	0

由于表2-6中有小于0的检验数,故表中的基本可行解不是最优解. 由于 $\sigma_1 < \sigma_2$,故确定 x_1 为进基变量. 将 b 列除以 A_1 列的同行且大于零的数,得到

$$\theta = \min \left\{ \frac{160}{30}, \frac{15}{5}, \frac{4}{1} \right\} = \frac{15}{5} = 3$$

故5为主元素,作为标志对主元素5加上方括号[14],主元素所在行的基变量 x_4 为离基变量. 用 x_1 替换基变量 x_4 ,得到一个新的基 $[A_3, A_1, A_5]$. 按照上述单纯形法计算步骤的第(3)步中的(c),可找到一个新基本可行解,并列出新单纯形表2-7:

表2-7

$c_j \rightarrow$			-5	-2	0	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5
0	x_3	70	0	[14]	1	-6	0
-5	x_1	3	1	$\frac{1}{5}$	0	$\frac{1}{5}$	0
0	x_5	1	0	$-\frac{1}{5}$	0	$-\frac{1}{5}$	1
σ_j			0	-1	0	1	0

由于表2-7中还存在小于0的检验数 σ_2 ,故重复上述步骤得到表2-8. 表2-8中所有 $\sigma_j \geq 0$,且基变量中不含人工变量,故表中的基本可行解 $x^* = (2, 5, 0, 0, 2)^T$ 为最优解,代入目标函数得 $z' = -20$.

表2-8

$c_j \rightarrow$			-5	-2	0	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5
-2	x_2	5	0	1	$\frac{1}{14}$	$-\frac{3}{7}$	0
-5	x_1	2	1	0	$-\frac{1}{70}$	$\frac{2}{7}$	0
0	x_5	2	0	0	$\frac{1}{70}$	$-\frac{2}{7}$	1
σ_j			0	0	$\frac{1}{14}$	$\frac{4}{7}$	0

2.3 人工变量的处理方法

在第2.1节中提到,为了使线性规划标准形式的约束矩阵中含有一个单位阵,需要在某些约束条件中引入人工变量. 考虑标准型线性规划问题:

$$\min z = c^T x$$

$$\text{s. t. } \sum_{j=1}^n A_j x_j = b$$

$$x_j \geq 0 \quad (j = 1, 2, \dots, n)$$

在每一个等式约束的左边加上一个人工变量 x_{n+i} ($i=1,2,\dots,m$), 得到如下线性规划问题:

$$\begin{aligned}
 \min z &= c^T x \\
 \text{s. t. } & a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n + x_{n+1} = b_1 \\
 & a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n + x_{n+2} = b_2 \\
 & \vdots \\
 & a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n + x_{n+m} = b_m \\
 & x_1 \geq 0, \dots, x_n \geq 0, x_{n+1} \geq 0, \dots, x_{n+m} \geq 0
 \end{aligned} \tag{2-29}$$

该问题的约束矩阵中含有一个 m 阶单位阵 $[A_{n+1} A_{n+2} \cdots A_{n+m}]$, 因此很容易得到一个初始基本可行解 $x^{(0)} = (0, \dots, 0, b_1, b_2, \dots, b_m)^T$, 从而可应用单纯形法进行迭代求解. 但是, 问题 (2-29) 与原问题 (LP) 一般不等价. 为了保证能通过求解含人工变量的线性规划问题 (2-29) 得到原问题 (LP) 的最优解, 本节给出两种处理人工变量的方法, 即大 M 法和两阶段法.

2.3.1 大 M 法

注意到, 只有当问题 (2-29) 的最优解中的人工变量都取零值时, 才能从中得到线性规划 (LP) 的最优解, 即将 (2-29) 的最优解中去掉人工变量后的剩余部分. 基于这一观察, 我们将问题 (2-29) 的目标函数修改为

$$\min z = \sum_{j=1}^n c_j x_j + Mx_{n+1} + Mx_{n+2} + \cdots + Mx_{n+m}$$

式中, M 是一个很大的正数, 其作用是使人工变量取值大于零时, 目标函数就不能实现最优. 这样, 以 $x^{(0)} = (0, \dots, 0, b_1, b_2, \dots, b_m)^T$ 为初始基本可行解, 应用单纯形法解如下线性规划问题, 便可得到原问题 (LP) 的最优解.

$$\begin{aligned}
 \min z &= \sum_{j=1}^n c_j x_j + Mx_{n+1} + Mx_{n+2} + \cdots + Mx_{n+m} \\
 \text{s. t. } & a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n + x_{n+1} = b_1 \\
 & a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n + x_{n+2} = b_2 \\
 & \vdots \\
 & a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n + x_{n+m} = b_m \\
 & x_1 \geq 0, \dots, x_n \geq 0, x_{n+1} \geq 0, \dots, x_{n+m} \geq 0
 \end{aligned} \tag{2-30}$$

一般将问题 (2-30) 称为是标准型线性规划 (LP) 的大 M 问题.

例 2-2 用单纯形法解下述线性规划问题.

$$\begin{aligned}
 \min z &= 3x_1 - x_3 \\
 \text{s. t. } & x_1 + x_2 + x_3 \leq 4 \\
 & -2x_1 + x_2 - x_3 \geq 1 \\
 & 3x_2 + x_3 = 9 \\
 & x_1 \geq 0, \quad x_2 \geq 0, \quad x_3 \geq 0
 \end{aligned} \tag{2-31}$$

解 将第一个约束的左端加上松弛变量 x_4 , 第二个约束左端减去剩余变量 x_5 后, 再加上人工变量 x_6 , 第三个约束左端加上人工变量 x_7 , 则得到大 M 问题:

$$\min z = 3x_1 - x_3 + 0 \cdot x_4 + 0 \cdot x_5 + Mx_6 + Mx_7$$

$$\text{s. t. } x_1 + x_2 + x_3 + x_4 = 4$$

$$-2x_1 + x_2 - x_3 - x_5 + x_6 = 1$$

$$3x_2 + x_3 + x_7 = 9$$

$$x_j \geq 0 \quad (j = 1, 2, \dots, 7)$$

式中, M 是一个很大的正数. 由于约束矩阵中含有一个 3 阶单位矩阵 $[A_4 A_6 A_7]$, 因此, 以其对应的基本可行解 $x^{(0)} = (0, 0, 0, 4, 0, 1, 9)^T$ 作为初始基本可行解, 应用单纯形法进行求解, 迭代过程见表 2-9.

表 2-9

$c_j \rightarrow$			3	0	-1	0	0	M	M
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5	x_6	x_7
0	x_4	4	1	1	1	1	0	0	0
M	x_6	1	-2	[1]	-1	0	-1	1	0
M	x_7	9	0	3	1	0	0	0	1
σ_j			$3+2M$	$-4M$	-1	0	M	0	0
0	x_4	3	3	0	2	1	1	-1	0
0	x_2	1	-2	1	-1	0	-1	1	0
M	x_7	6	[6]	0	4	0	3	-3	1
σ_j			$3-6M$	0	$-4M-1$	0	$-3M$	$4M$	0
0	x_4	0	0	0	0	1	$-\frac{1}{2}$	$\frac{1}{2}$	$-\frac{1}{2}$
0	x_2	3	0	1	$\frac{1}{3}$	0	0	0	$\frac{1}{3}$
3	x_1	1	1	0	$[\frac{2}{3}]$	0	$\frac{1}{2}$	$-\frac{1}{2}$	$\frac{1}{6}$
σ_j			0	0	-3	0	$-\frac{3}{2}$	$M+\frac{3}{2}$	$M-\frac{1}{2}$
0	x_4	0	0	0	0	1	$-\frac{1}{2}$	$\frac{1}{2}$	$-\frac{1}{2}$
0	x_2	$\frac{5}{2}$	$-\frac{1}{2}$	1	0	0	$-\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$
-1	x_3	$\frac{3}{2}$	$\frac{3}{2}$	0	1	0	$\frac{3}{4}$	$-\frac{3}{4}$	$\frac{1}{4}$
σ_j			$\frac{9}{2}$	0	0	0	$\frac{3}{4}$	$M-\frac{3}{4}$	$M+\frac{1}{4}$

从表 2-9 中得到最优解 $x^* = (0, \frac{5}{2}, \frac{3}{2}, 0, 0, 0, 0)^T$, 最优值为 $z^* = -\frac{3}{2}$. 因为人工变量 x_6, x_7 已不在基变量中, 故 x^* 是原问题的最优解.

$$\begin{aligned} \min \omega &= x_6 + x_7 \\ \text{s. t. } \quad &x_1 + x_2 + x_3 + x_4 = 4 \\ &-2x_1 + x_2 - x_3 - x_5 + x_6 = 1 \\ &3x_2 + x_3 + x_7 = 9 \\ &x_j \geq 0 \quad (j = 1, 2, \cdots, 7) \end{aligned}$$

用单纯形法的求解过程见表 2-10.

表 2-10

$c_j \rightarrow$			0	0	0	0	0	1	1
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5	x_6	x_7
0	x_4	4	1	1	1	1	0	0	0
1	x_6	1	-2	[1]	-1	0	-1	1	0
1	x_7	9	0	3	1	0	0	0	1
σ_j			2	-4	0	0	1	0	0
0	x_4	3	3	0	2	1	1	-1	0
0	x_2	1	-2	1	-1	0	-1	1	0
1	x_7	6	[6]	0	4	0	3	-3	1
σ_j			-6	0	-4	0	-3	4	0
0	x_4	0	0	0	0	1	$-\frac{1}{2}$	$\frac{1}{2}$	$-\frac{1}{2}$
0	x_2	3	0	1	$\frac{1}{3}$	0	0	0	$\frac{1}{3}$
0	x_1	1	1	0	$[\frac{2}{3}]$	0	$\frac{1}{2}$	$-\frac{1}{2}$	$\frac{1}{6}$
σ_j			0	0	0	0	0	1	1

第二阶段是将表 2-10 中的人工变量 x_6, x_7 除去, 目标函数改为

$$\min z = 3x_1 + 0 \cdot x_2 - x_3 + 0 \cdot x_4 + 0 \cdot x_5 + 0 \cdot x_6 + 0 \cdot x_7$$

再从表 2-10 中的最后一个表出发, 继续用单纯形法求解, 求解过程见表 2-11.

表 2-11

$c_j \rightarrow$			3	0	-1	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5
0	x_4	0	0	0	0	1	$-\frac{1}{2}$
0	x_2	3	0	1	$\frac{1}{3}$	0	0
3	x_1	1	1	0	$[\frac{2}{3}]$	0	$\frac{1}{2}$

续表 2-11

σ_j			0	0	-3	0	$-\frac{3}{2}$
0	x_4	3	3	0	0	1	1
0	x_2	$\frac{5}{2}$	$-\frac{1}{2}$	1	0	0	$-\frac{1}{4}$
-1	x_3	$\frac{3}{2}$	$\frac{3}{2}$	0	1	0	$\frac{3}{4}$
σ_j			$\frac{9}{2}$	0	0	0	$\frac{3}{4}$

将表 2-11 中的结果与表 2-9 对照, 可以看到, 两种方法所求得的结果相一致, 最优解都是 $x^* = \left(0, \frac{5}{2}, \frac{3}{2}, 0, 0\right)^T$, 最优值为 $-\frac{3}{2}$.

2.4 单纯形法的有限终止性

在前几节里, 对单纯形法作了介绍, 但还有一个问题没有解决, 即当 (LP) 的最优解存在时, 单纯形法能否保证通过有限次迭代找到一个最优解, 也就是算法是否具有有限终止性的问题.

由 2.1.3 节中的讨论可知, 当 (LP) 存在最优解, 在非退化的情况下, 单纯形法的每次迭代都使目标函数值严格下降. 这样, 经过有限次迭代必达到最优解. 但对于退化情形, 即使存在最优解, 也可能出现循环现象, 即迭代过程总是重复解的某一部分序列, 目标函数值总是不变, 因而永远达不到最优解. 下面是由 E. Beale 给出的一个循环例子.

例 2-4 用单纯形法求解下列线性规划

$$\begin{aligned}
 \min z &= -\left(\frac{3}{4}\right)x_4 + 20x_5 - \left(\frac{1}{2}\right)x_6 + 6x_7 \\
 \text{s. t. } x_1 &+ \left(\frac{1}{4}\right)x_4 - 8x_5 - x_6 + 9x_7 = 0 \\
 x_2 &+ \left(\frac{1}{2}\right)x_4 - 12x_5 - \left(\frac{1}{2}\right)x_6 + 3x_7 = 0 \\
 x_3 &+ x_6 = 1 \\
 x_j &\geq 0 \quad (j = 1, 2, \dots, 7)
 \end{aligned}$$

解 取 $[A_1 A_2 A_3]$ 作为初始可行基, 应用单纯形表可得下列各表:

表 2-12

$c_j \rightarrow$			0	0	0	$-\frac{3}{4}$	20	$-\frac{1}{2}$	6
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5	x_6	x_7
0	x_1	0	1	0	0	$\left[\frac{1}{4}\right]$	-8	-1	9
0	x_2	0	0	1	0	$\frac{1}{2}$	-12	$-\frac{1}{2}$	3
0	x_3	1	0	0	1	0	0	1	0
σ_j			0	0	0	$-\frac{3}{4}$	20	$-\frac{1}{2}$	6
$-\frac{3}{4}$	x_4	0	4	0	0	1	-32	-4	36
0	x_2	0	-2	1	0	0	[4]	$\frac{3}{2}$	-15
0	x_3	1	0	0	1	0	0	1	0
σ_j			3	0	0	0	-4	$-\frac{7}{2}$	33
$-\frac{3}{4}$	x_4	0	-12	8	0	1	0	[8]	-84
20	x_5	0	$-\frac{1}{2}$	$\frac{1}{4}$	0	0	1	$\frac{3}{8}$	$-\frac{15}{4}$
0	x_3	1	0	0	1	0	0	1	0
σ_j			1	1	0	0	0	-2	18
$-\frac{1}{2}$	x_6	0	$-\frac{3}{2}$	1	0	$\frac{1}{8}$	0	1	$-\frac{21}{2}$
20	x_5	0	$\frac{1}{16}$	$-\frac{1}{8}$	0	$-\frac{3}{64}$	1	0	$\left[\frac{3}{16}\right]$
0	x_3	1	$\frac{3}{2}$	-1	1	$-\frac{1}{8}$	0	0	$\frac{21}{2}$
σ_j			-2	3	0	$\frac{1}{4}$	0	0	-3
$-\frac{1}{2}$	x_6	0	[2]	-6	0	$-\frac{5}{2}$	56	1	0
6	x_7	0	$\frac{1}{3}$	$-\frac{2}{3}$	0	$-\frac{1}{4}$	$\frac{16}{3}$	0	1
0	x_3	1	-2	6	1	$\frac{5}{2}$	-56	0	0
σ_j			-1	1	0	$-\frac{1}{2}$	16	0	0
0	x_1	0	1	-3	0	$-\frac{5}{4}$	28	$\frac{1}{2}$	0
6	x_7	0	0	$\frac{1}{3}$	0	$\frac{1}{6}$	-4	$-\frac{1}{6}$	1
0	x_3	1	0	0	1	0	0	1	0
σ_j			0	-2	0	$-\frac{7}{4}$	44	$\frac{1}{2}$	0

继续迭代,又将回到初始表,也即形成了计算上的死循环,从而使算法永远不能终止. 我们看到,上表中6次迭代得到的基本可行解都对应着同一个顶点 $x = (0, 0, 1, 0, 0, 0, 0)^T$. 造成此结果的原因是:按如下最小比原则

$$\theta = \min_{1 \leq i \leq m} \left\{ \frac{b_i}{a_{ik}} \mid a_{ik} > 0 \right\} = \frac{b_l}{a_{lk}}$$

确定换出基变量时,总有 $b_l = 0$,从而 $\theta = 0$. 因此,根据2.1.2节中从当前基本可行解构造一个与其相邻的基本可行解的方法知,前后两个基本可行解总相同.

为了避免在单纯形法的迭代过程中出现这种死循环,Bland提出了一种简单的确定进基变量指标 k 和离基变量指标 l 的规则,现将它用定理的形式给出.

定理2-4 如果在单纯形法中采用如下规则来确定进基变量指标 k 和离基变量指标 l ,则在迭代中就决不会出现死循环:

$$(1) k = \min \{j \mid \sigma_j < 0, j \in J_N\}$$

$$(2) B_l = \min \left\{ B_r \mid \frac{b_r}{a_{rk}} = \min_{1 \leq i \leq m} \left\{ \frac{b_i}{a_{ik}} \mid a_{ik} > 0 \right\} \right\}, \text{其中 } B_l \text{ 表示基变量 } x_{B_l} \text{ 所对应的系数向量在 } B$$

中排在第 l 个向量位置上.

也就是说,按Bland法则,在迭代过程中如果有多个检验数 σ_j 都是负的,则选其中下标最小的检验数的相应下标作为进基变量指标 k ;如果有几个 $\frac{b_r}{a_{rk}}$ 同时达到 $\min_{1 \leq i \leq m} \left\{ \frac{b_i}{a_{ik}} \mid a_{ik} > 0 \right\}$,那么选其中下标最小的基变量作为离基变量.

例2-5 采用Bland规则求解例2-4.

解 前三次迭代过程与表2-12中开始的三次迭代相同,后面的迭代过程为

表2-13

$c_j \rightarrow$			0	0	0	$-\frac{3}{4}$	20	$-\frac{1}{2}$	6
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5	x_6	x_7
$-\frac{1}{2}$	x_6	0	$-\frac{3}{2}$	1	0	$\frac{1}{8}$	0	1	$-\frac{21}{2}$
20	x_5	0	$\left[\frac{1}{16}\right]$	$-\frac{1}{8}$	0	$-\frac{3}{64}$	1	0	$\frac{3}{16}$
0	x_3	1	$\frac{3}{2}$	-1	1	$-\frac{1}{8}$	0	0	$\frac{21}{3}$
σ_j			-2	3	0	$\frac{1}{4}$	0	0	-3
$-\frac{1}{2}$	x_6	0	0	-2	0	-1	24	1	-6
0	x_1	0	1	-2	0	$-\frac{3}{4}$	16	0	3
0	x_3	1	0	[2]	1	1	-24	0	6

续表 2-13

σ_j			0	-1	0	$-\frac{5}{4}$	32	0	3
$-\frac{1}{2}$	x_6	1	0	0	1	0	0	1	0
0	x_1	1	1	0	1	$\frac{1}{4}$	-8	0	9
0	x_2	$\frac{1}{2}$	0	1	$\frac{1}{2}$	$[\frac{1}{2}]$	-12	0	3
σ_j			0	0	$\frac{1}{2}$	$-\frac{3}{4}$	20	0	6
$-\frac{1}{2}$	x_6	1	0	0	1	0	0	1	0
0	x_1	$\frac{3}{4}$	1	$-\frac{1}{2}$	$\frac{3}{4}$	0	-2	0	$\frac{15}{2}$
$-\frac{3}{4}$	x_4	1	0	2	1	1	-24	0	6
σ_j			0	$\frac{3}{2}$	$\frac{5}{4}$	0	2	0	$\frac{21}{2}$

至此得到原问题的最优解 $x^* = \left(\frac{3}{4}, 0, 0, 1, 0, 1, 0\right)^T$ 和最优值 $z^* = -\frac{5}{4}$.

由于(LP)的基只有有限个,而采用 Bland 规则的单纯形法又保证不会出现死循环,故从理论上说这种单纯形法经有限次迭代后必将终止.但这种算法在具体计算时的迭代次数往往会比一般单纯形法的迭代次数多,而在实际计算中出现死循环只是罕见的现象,因此实用中通常采用一般单纯形法.

2.5 改进单纯形法

在前面讲述的单纯形法中,每次迭代不仅需要存储一个 $m \times n$ 维的矩阵 A 而且 A 中所有数据都必须计算一遍.当 m 与 n 的数值较大时,这既占据了较大的内存空间又浪费了很多的工作量.事实上,系数矩阵 A 中换入列以外的其他列没有必要计算.改进单纯形法正是从这点出发,每次迭代只计算换入列、常数列和检验数行,从而大大减少了所需的计算机存储量,提高了计算效率.特别是当问题的变量个数 n 远比约束条件数 m 大时,改进单纯形法更显优势.

为了便于改进单纯形法的讲述,下面先采用向量和矩阵符号来描述单纯形法的迭代过程.

2.5.1 单纯形法的矩阵描述

考虑标准型线性规划问题

$$\begin{aligned} \min z &= c^T x \\ (\text{LP}) \quad \text{s. t.} \quad Ax &= b \\ x &\geq 0 \end{aligned}$$

假设其可行域 X 非空, 且存在非退化的最优解.

假定已找到 (LP) 的一个非退化基本可行解 $\bar{x}$, 即找到了一个基阵 B . 不失一般性, 假设 B 是由 A 中前 m 个列向量组成的 m 阶方阵 (若不是, 通过调整基变量次序或重新编号总可以做到). 记 A 中剩余 $n-m$ 个列向量组成的 $m \times (n-m)$ 矩阵为 N , 则 A 的分块矩阵表达式为 $A = (B, N)$. 将基变量组成的向量记为 x_B , 非基变量组成的向量记作 x_N , 则向量 x 分成两块:

$$x = \begin{pmatrix} x_B \\ x_N \end{pmatrix}, \quad x_B = (x_1, x_2, \dots, x_m)^T, \quad x_N = (x_{m+1}, x_{m+2}, \dots, x_n)^T$$

相应地, 将目标函数系数向量 c 也分成两块:

$$c = (c_B, c_N)^T, \quad c_B = (c_1, c_2, \dots, c_m), \quad c_N = (c_{m+1}, c_{m+2}, \dots, c_n)$$

利用上面定义的符号, (LP) 的等式约束条件 $Ax = b$ 可改写为

$$(B, N) \begin{pmatrix} x_B \\ x_N \end{pmatrix} = b \Leftrightarrow Bx_B + Nx_N = b \Leftrightarrow x_B + B^{-1}Nx_N = B^{-1}b \quad (2-33)$$

而目标函数 $z = c^T x$ 可重新写为

$$\begin{aligned} z &= (c_B, c_N) \begin{pmatrix} x_B \\ x_N \end{pmatrix} = c_B x_B + c_N x_N = c_B (B^{-1}b - B^{-1}Nx_N) + c_N x_N \\ &= c_B B^{-1}b + (c_N - c_B B^{-1}N) x_N \end{aligned} \quad (2-34)$$

这样, 标准型线性规划 (LP) 可以表示为如下典则形式:

$$\begin{aligned} \min z &= c_B B^{-1}b + (c_N - c_B B^{-1}N) x_N \\ \text{s. t.} \quad x_B + B^{-1}Nx_N &= B^{-1}b \\ x &\geq 0 \end{aligned} \quad (2-35)$$

另外, 注意到:

$$\bar{x}_B = B^{-1}b, \quad \bar{z} = c^T \bar{x} = c_B \bar{x}_B = c_B B^{-1}b \quad (2-36)$$

$$\begin{aligned} B^{-1}Nx_N &= \sum_{j=m+1}^n B^{-1}A_j x_j \\ (c_N - c_B B^{-1}N)x_N &= \sum_{j=m+1}^n (c_j - c_B B^{-1}A_j) x_j \end{aligned}$$

因此, 典则形式 (2-35) 还可重新写为

$$\begin{aligned} \min z &= \bar{z} + \sum_{j=m+1}^n (c_j - c_B B^{-1}A_j) x_j \\ \text{s. t.} \quad x_B &= B^{-1}b - \sum_{j=m+1}^n B^{-1}A_j x_j \\ x &\geq 0 \end{aligned} \quad (2-37)$$

下面, 用向量和矩阵符号来描述单纯形法计算步骤中的各项准则.

(1) 最优性准则. 将典则形式 (2-37) 与前面的式 (2-9) 相对照, 得

$$\sigma_j = c_j - c_B B^{-1} A_j \quad (j = 1, 2, \dots, n) \quad (2-38)$$

这说明 $c_j - c_B B^{-1} A_j$ 就是变量 x_j 的检验数. 因此, 若用 σ_N 表示由非基变量的检验数构成的行向量, 则线性规划(LP)的最优性准则为

$$\sigma_N = c_N - c_B B^{-1} N \geq 0 \quad (2-39)$$

(2) 进基变量的选择准则. 若

$$\sigma_k = \min_{j \in J_N} \{\sigma_j\} = \min_{j \in J_N} \{c_j - c_B B^{-1} A_j\} \quad (2-40)$$

则非基变量 x_k 作为进基变量.

(3) 离基变量的选择准则. 由(LP)的典则形式(2-9)和式(2-37)知

$$\bar{b} = B^{-1} b, \quad \bar{A}_j = B^{-1} A_j \quad (j = 1, 2, \dots, n) \quad (2-41)$$

这样, 式(2-18)的最小比原则可写为

$$\begin{aligned} \theta &= \min \left\{ \frac{\bar{b}_j}{(\bar{A}_k)_j} \mid (\bar{A}_k)_j > 0 \right\} = \min \left\{ \frac{(B^{-1}b)_j}{(B^{-1}A_k)_j} \mid (B^{-1}A_k)_j > 0 \right\} \\ &= \frac{(B^{-1}b)_l}{(B^{-1}A_k)_l} \end{aligned} \quad (2-42)$$

即第 l 个基变量离基. 注意, 这里的下标 l 不是变量的自然下标, 而是变量在当前基本可行解的基变量中所排顺序的下标. 因此, 第 l 个基变量离基, 一般应写成 x_{B_l} 离基 (只有当基变量的下标都是自然下标, 即 $x_B = (x_1, x_2, \dots, x_m)^T$ 时, 才有 $x_{B_l} = x_l$). 若 x_{B_l} 是 x_r , 则取基变量 x_r 为离基变量. 这样, 就从当前的可行基 B 出发找到了下一个可行基 $\hat{B}$.

2.5.2 改进单纯形法

从上一节用向量和矩阵形式描述的单纯形法迭代过程, 我们看到, 从当前可行基 B 过渡到下一个可行基 $\hat{B}$ 时, 只需要计算 B^{-1} , 而其他所需要的数据都可从原始数据中找出, 不需要重新计算. 因为, 式(2-36)、式(2-39)、式(2-40)和式(2-41)中的 $c_B, c_N, N, b, c_j, A_k, A_j$ 等都可从原始数据表中取出, 而不是每次迭代时需要重新计算的数据. 因此, 如果能以较少的计算量及较小的占用存储空间方法从 B^{-1} 计算出 $(\hat{B})^{-1}$, 则不仅可以使迭代过程持续下去, 而且还能克服上述单纯形法的不足. 这种方法通常称为改进单纯形法或修正单纯形法. 从 B^{-1} 计算出 $(\hat{B})^{-1}$ 的方法有多种, 下面介绍常用的基逆乘积形式的方法.

假设当前可行基为

$$B = [A_{B_1} A_{B_2} \cdots A_{B_l} \cdots A_{B_m}], \quad (2-43)$$

它所对应的基变量为 $x_{B_1}, x_{B_2}, \dots, x_{B_l}, \dots, x_{B_m}$. 注意, 这里的 B_i 表示基变量 x_{B_i} 在 x_B 中排在第 i 个分量位置上, 而不是决策变量的自然下标. 若已判别当前基本可行解不是最优解, x_k 为进基变量, x_{B_l} 为离基变量, 则有

$$\hat{B} = [A_{B_1} A_{B_2} \cdots A_{B_{l-1}} A_k A_{B_{l+1}} \cdots A_{B_m}] \quad (2-44)$$

根据基 B 的定义式(2-43), 有

$$B \cdot e_i = [A_{B_1} A_{B_2} \cdots A_{B_l} \cdots A_{B_m}] \begin{pmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{pmatrix} = A_{B_i} \quad (i = 1, 2, \dots, m) \quad (2-45)$$

式中, e_i 是 m 维单位向量. 而由式(2-41), $\bar{A}_k = B^{-1}A_k$, 故

$$A_k = B\bar{A}_k \quad (2-46)$$

将式(2-45)和式(2-46)代入式(2-44)中, 得

$$\hat{B} = B[e_1 \cdots e_{l-1} \bar{A}_k e_{l+1} \cdots e_m] = BT \quad (2-47)$$

其中, $[e_1 \cdots e_{l-1} \bar{A}_k e_{l+1} \cdots e_m]$ 是将 m 阶单位矩阵的第 l 列换成 $\bar{A}_k$ 而得到的. 根据式(2-47)可得

$$\hat{B}^{-1} = (BT)^{-1} = T^{-1}B^{-1} \quad (2-48)$$

若记 $\bar{A}_k = (\bar{a}_{1k}, \bar{a}_{2k}, \cdots, \bar{a}_{lk}, \cdots, \bar{a}_{mk})^T$, 其中 $\bar{a}_{lk}$ 为主元素, 则容易验证

$$T^{-1} = \begin{bmatrix} 1 & 0 & \cdots & -\frac{\bar{a}_{1k}}{\bar{a}_{lk}} & \cdots & 0 \\ 0 & 1 & \cdots & -\frac{\bar{a}_{2k}}{\bar{a}_{lk}} & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & \frac{1}{\bar{a}_{lk}} & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & -\frac{\bar{a}_{mk}}{\bar{a}_{lk}} & \cdots & 1 \end{bmatrix} \quad (2-49)$$

与 T 类似, T^{-1} 也是将 m 阶单位矩阵的第 l 列换去, 只是换成如下列向量而已:

$$\xi = \left(-\frac{\bar{a}_{1k}}{\bar{a}_{lk}}, -\frac{\bar{a}_{2k}}{\bar{a}_{lk}}, \cdots, \frac{1}{\bar{a}_{lk}}, \cdots, \frac{\bar{a}_{mk}}{\bar{a}_{lk}} \right)^T \quad (2-50)$$

ξ 可看成是将 $\bar{A}_k$ 的主元素 $\bar{a}_{lk}$ 换成 $\frac{1}{\bar{a}_{lk}}$ 、其余各元素均由 $-\bar{a}_{ik}$ 除以 $\bar{a}_{lk}$ 而得.

记

$$E = T^{-1} = [e_1 e_2 \cdots e_{l-1} \xi e_{l+1} \cdots e_m] \quad (2-51)$$

将其代入式(2-48), 则

$$\hat{B}^{-1} = EB^{-1}. \quad (2-52)$$

由此可见, 要从当前的基逆 B^{-1} 计算下一个基逆 $(\hat{B})^{-1}$, 只需计算和存储矩阵 E , 而 E 的存储只需要列向量 ξ 及 ξ 所在列位置的信息, 故存储量大大减少.

若记第 i 次迭代的基矩阵为 B^i , 第 i 次迭代使用的矩阵 E 为 $E^{(i)}$, 则一般有

$$(B^{(i+1)})^{-1} = E^{(i)}(B^{(i)})^{-1} \quad (2-53)$$

这样, 便得到如下迭代公式:

$$\begin{aligned} (B^{(1)})^{-1} &= E^{(0)}(B^{(0)})^{-1}, \\ (B^{(2)})^{-1} &= E^{(1)}(B^{(1)})^{-1} = E^{(1)}E^{(0)}(B^{(0)})^{-1} \\ &\vdots \\ (B^{(i+1)})^{-1} &= E^{(i)}E^{(i-1)}\cdots E^{(0)}(B^{(0)})^{-1} \end{aligned} \quad (2-54)$$

其中 $B^{(0)}$ 表示初始可行基矩阵, $E^{(0)}$ 为式(2-51)定义的矩阵 E .

若迭代次数较多, 为了消除计算累计误差, 可直接从 $B^{(i+1)}$ 用初等变换法求逆矩阵

$(B^{(i+1)})^{-1}$. 即首先在矩阵 $B^{(i+1)}$ 的右边补上一个 $m \times m$ 单位矩阵, 构成一个 $m \times (2m)$ 的新矩阵, 然后对这个新矩阵进行一系列的行变换, 使左边原来的 $B^{(i+1)}$ 矩阵化为单位矩阵, 而右边原来的单位矩阵即变成 $(B^{(i+1)})^{-1}$.

根据上述讨论, 改进单纯形法的计算步骤如下:

第1步 构造初始可行基 $B^{(0)}$ (一般取 $B^{(0)} = I$), 计算 $(B^{(0)})^{-1}$ 、初始基本可行解 $x^{(0)} = \begin{pmatrix} (B^{(0)})^{-1}b \\ 0 \end{pmatrix}$ 及其相应的目标函数值 $z^{(0)} = c_{B^{(0)}}(B^{(0)})^{-1}b$. 令 $i=0$.

第2步 进行最优性检验. 根据公式 $\sigma_{N(i)} = c_{N(i)} - c_{B(i)}(B^{(i)})^{-1}N^{(i)}$ 计算第 i 次迭代的非基变量的检验数向量 $\sigma_{N(i)}$. 若 $\sigma_{N(i)} \geq 0$ 且基变量中不含人工变量, 则已经得到最优解 $x^* = x^{(i)}$ 和最优值 $z^* = z^{(i)}$, 停止迭代; 否则转下步.

第3步 确定第 i 次迭代的换入基的变量. 若

$$\sigma_k^{(i)} = \min_{j \in J_{N(i)}} \{c_j - c_{B(i)}(B^{(i)})^{-1}A_j\}$$

则非基变量 x_k 作为第 i 次迭代的换入基的变量.

第4步 确定第 i 次迭代的换出基的变量. 首先计算

$$\bar{b}^{(i)} = (B^{(i)})^{-1}b, \quad \bar{A}_k^{(i)} = (B^{(i)})^{-1}A_k$$

然后根据如下最小比原则确定换出基变量的下标:

$$\min \left\{ \frac{\bar{b}_l^{(i)}}{(\bar{A}_k^{(i)})_l} \mid (\bar{A}_k^{(i)})_l > 0 \right\} = \frac{\bar{b}_l^{(i)}}{(\bar{A}_k^{(i)})_l} = \frac{\bar{b}_l^{(i)}}{\bar{a}_{lk}^{(i)}}$$

即 $x_{B_l}^{(i)}$ 为离基变量, 其中 $\bar{b}_l^{(i)}$ 和 $(\bar{A}_k^{(i)})_l$ 分别表示向量 $\bar{b}^{(i)}$ 和 $\bar{A}_k^{(i)}$ 的第 l 个分量.

第5步 根据式(2-51)来确定矩阵 $E^{(i)}$, 然后由迭代公式(2-53)计算 $(B^{(i+1)})^{-1}$, 并由此求出基本可行解 $x^{(i+1)} = \begin{pmatrix} (B^{(i+1)})^{-1}b \\ 0 \end{pmatrix}$ 及目标值 $z^{(i+1)} = c_{B^{(i+1)}}(B^{(i+1)})^{-1}b$.

第6步 令 $i=i+1$, 返回第2步.

例2-6 用改进单纯形法解如下线性规划问题:

$$\begin{aligned} \min z &= -x_1 - 2x_2 + x_3 \\ \text{s. t. } x_1 + x_2 + x_3 &\leq 4 \\ -x_1 + 2x_2 - 2x_3 &\leq 6 \\ 2x_1 + x_2 &\leq 5 \\ x_1 \geq 0, \quad x_2 \geq 0, \quad x_3 \geq 0 \end{aligned}$$

解 将上述问题化成标准形式:

$$\begin{aligned} \min z &= -x_1 - 2x_2 + x_3 + 0 \cdot x_4 + 0 \cdot x_5 + 0 \cdot x_6 \\ \text{s. t. } x_1 + x_2 + x_3 + x_4 &= 4 \\ -x_1 + 2x_2 - 2x_3 + x_5 &= 6 \\ 2x_1 + x_2 + x_6 &= 5 \\ x_j &\geq 0 \quad (j=1, 2, \dots, 6) \end{aligned}$$

由此可知, $c = (-1, -2, 1, 0, 0, 0)^T$, $b = (4, 6, 5)^T$.

第0次迭代 初始可行基 $B^{(0)} = [A_4 A_5 A_6] = I_3$, 非基阵 $N^{(0)} = [A_1 A_2 A_3]$.

$$\mathbf{x}_{B(0)} = (x_4, x_5, x_6)^T = (4, 6, 5)^T, \quad \mathbf{x}_{N(0)} = (x_1, x_2, x_3)^T = (0, 0, 0)^T;$$

$$\mathbf{c}_{B(0)} = (c_4, c_6, c_5) = (0, 0, 0), \quad \mathbf{c}_{N(0)} = (c_1, c_2, c_3) = (-1, -2, 1);$$

$$\sigma_N^{(0)} = \mathbf{c}_{N(0)} - \mathbf{c}_{B(0)}(\mathbf{B}^{(0)})^{-1}\mathbf{N}^{(0)} = (-1, -2, 1) - (0, 0, 0)\mathbf{I}_3[\mathbf{A}_1\mathbf{A}_2\mathbf{A}_3] = (-1, -2, 1).$$

由于 $\sigma_1^{(0)} < 0, \sigma_2^{(0)} < 0$, 故 $\mathbf{x}^{(0)} = (4, 6, 5, 0, 0, 0)^T$ 不是最优解.

第1次迭代 由 $\sigma_2^{(0)} = \min_{j \in \{1, 2, 3\}} \{\sigma_j^{(0)}\}$ 知, x_2 为进基变量. 因为

$$\bar{\mathbf{b}}^{(0)} = (\mathbf{B}^{(0)})^{-1}\mathbf{b} = (4, 6, 5)^T, \quad \bar{\mathbf{A}}_2^{(0)} = (\mathbf{B}^{(0)})^{-1}\mathbf{A}_2 = (1, 2, 1)^T,$$

所以

$$\theta = \min\left\{\frac{4}{1}, \frac{6}{2}, \frac{5}{1}\right\} = 3 = \frac{\bar{b}_2^{(0)}}{(\bar{\mathbf{A}}_2^{(0)})_2}$$

故, $x_{B_2(0)} = x_5$ 为离基变量. 因此, 新基

$$\mathbf{B}^{(1)} = [\mathbf{A}_4\mathbf{A}_2\mathbf{A}_6], \quad \mathbf{N}^{(1)} = [\mathbf{A}_1\mathbf{A}_5\mathbf{A}_3]$$

由于 $\bar{\mathbf{A}}_2^{(0)} = (1, 2, 1)^T$, 主元素为 $\bar{a}_{22}^{(0)} = 2$, 故 $\boldsymbol{\xi}^{(0)} = \left(-\frac{1}{2}, \frac{1}{2}, -\frac{1}{2}\right)^T$, 从而

$$\mathbf{E}^{(0)} = \begin{bmatrix} 1 & -\frac{1}{2} & 0 \\ 0 & \frac{1}{2} & 0 \\ 0 & -\frac{1}{2} & 1 \end{bmatrix}, \quad (\mathbf{B}^{(1)})^{-1} = \mathbf{E}^{(0)}(\mathbf{B}^{(0)})^{-1} = \begin{bmatrix} 1 & -\frac{1}{2} & 0 \\ 0 & \frac{1}{2} & 0 \\ 0 & -\frac{1}{2} & 1 \end{bmatrix}$$

计算

$$\mathbf{Y}^{(1)} = \mathbf{c}_{B(1)}(\mathbf{B}^{(1)})^{-1} = (0, -2, 0) \begin{bmatrix} 1 & -\frac{1}{2} & 0 \\ 0 & \frac{1}{2} & 0 \\ 0 & -\frac{1}{2} & 1 \end{bmatrix} = (0, -1, 0)$$

$$\mathbf{z}^{(1)} = \mathbf{c}_{B(1)}(\mathbf{B}^{(1)})^{-1}\mathbf{b} = \mathbf{Y}^{(1)}\mathbf{b} = -6$$

$$\mathbf{x}_{B(1)} = (x_4, x_2, x_6)^T = (\mathbf{B}^{(1)})^{-1}\mathbf{b} = \begin{bmatrix} 1 & -\frac{1}{2} & 0 \\ 0 & \frac{1}{2} & 0 \\ 0 & -\frac{1}{2} & 1 \end{bmatrix} \begin{pmatrix} 4 \\ 6 \\ 5 \end{pmatrix} = \begin{pmatrix} 1 \\ 3 \\ 2 \end{pmatrix}$$

计算非基变量的检验数向量

$$\begin{aligned} \sigma_N^{(1)} &= \mathbf{c}_{N(1)} - \mathbf{c}_{B(1)}(\mathbf{B}^{(1)})^{-1}\mathbf{N}^{(1)} = (c_1, c_5, c_3) - \mathbf{Y}^{(1)}[\mathbf{A}_1\mathbf{A}_5\mathbf{A}_3] \\ &= (-1, 0, 1) - (0, -1, 0) \begin{bmatrix} 1 & 0 & 1 \\ -1 & 1 & -2 \\ 2 & 0 & 0 \end{bmatrix} = (-2, 1, -1) \end{aligned}$$

由于 $\sigma_1^{(1)} < 0, \sigma_3^{(1)} < 0$, 故 $\mathbf{x}^{(1)} = (0, 3, 0, 1, 0, 2)^T$ 不是最优解.

第2次迭代 由 $\sigma_1^{(1)} = \min_{j \in \{1, 5, 3\}} \{\sigma_j^{(1)}\}$ 知 x_1 为进基变量, 故有

$$\bar{A}_1^{(1)} = (B^{(1)})^{-1}A_1 = \begin{bmatrix} 1 & -\frac{1}{2} & 0 \\ 0 & \frac{1}{2} & 0 \\ 0 & -\frac{1}{2} & 1 \end{bmatrix} \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix} = \begin{pmatrix} \frac{3}{2} \\ -\frac{1}{2} \\ \frac{5}{2} \end{pmatrix}$$

$$\text{又 } \theta = \min \left\{ \frac{((B^{(1)})^{-1}b)_j}{((B^{(1)})^{-1}A_k)_j} \mid ((B^{(1)})^{-1}A_k)_j > 0 \right\} = \min \left\{ \frac{1}{3}, \frac{2}{5} \right\} = \frac{2}{5} = \frac{((B^{(1)})^{-1}b)_1}{((B^{(1)})^{-1}A_k)_1}$$

所以, $x_{B_1^{(1)}} = x_4$ 为离基变量. 因此, 新基

$$B^{(2)} = [A_1 A_2 A_6], \quad N^{(2)} = [A_4 A_5 A_3]$$

由于 $\bar{A}_1^1 = \left(\frac{3}{2}, -\frac{1}{2}, \frac{5}{2}\right)^T$, 主元素为 $\bar{a}_{11}^{(1)} = \frac{3}{2}$, 故 $\xi^{(1)} = \left(\frac{2}{3}, \frac{1}{3}, -\frac{5}{3}\right)^T$, 从而

$$E^{(1)} = \begin{bmatrix} \frac{2}{3} & 0 & 0 \\ \frac{1}{3} & 1 & 0 \\ -\frac{5}{3} & 0 & 1 \end{bmatrix}$$

$$(B^{(2)})^{-1} = E^{(1)}(B^{(1)})^{-1} = \begin{bmatrix} \frac{2}{3} & 0 & 0 \\ \frac{1}{3} & 1 & 0 \\ -\frac{5}{3} & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} 1 & -\frac{1}{2} & 0 \\ 0 & \frac{1}{2} & 0 \\ 0 & -\frac{1}{2} & 1 \end{bmatrix} = \begin{bmatrix} \frac{2}{3} & -\frac{1}{3} & 0 \\ \frac{1}{3} & \frac{1}{3} & 0 \\ -\frac{5}{3} & \frac{1}{3} & 1 \end{bmatrix}$$

计算

$$\begin{aligned} Y^{(2)} &= c_{B^{(2)}}(B^{(2)})^{-1} = (c_1, c_2, c_6)(B^{(2)})^{-1} \\ &= (-1, -2, 0) \begin{bmatrix} \frac{2}{3} & -\frac{1}{3} & 0 \\ \frac{1}{3} & \frac{1}{3} & 0 \\ -\frac{5}{3} & \frac{1}{3} & 1 \end{bmatrix} = \left(-\frac{4}{3}, -\frac{1}{3}, 0\right) \end{aligned}$$

$$x_{B^{(2)}} = (B^{(2)})^{-1}b = \begin{bmatrix} \frac{2}{3} & -\frac{1}{3} & 0 \\ \frac{1}{3} & \frac{1}{3} & 0 \\ -\frac{5}{3} & \frac{1}{3} & 1 \end{bmatrix} \begin{pmatrix} 4 \\ 6 \\ 5 \end{pmatrix} = \begin{pmatrix} \frac{2}{3} \\ \frac{10}{3} \\ 0 \end{pmatrix}$$

$$z^{(2)} = c_{B^{(2)}}(B^{(2)})^{-1}b = Y^{(2)}b = -\frac{22}{3}$$

计算非基变量的检验数向量

$$\begin{aligned}\sigma_N^{(2)} &= c_{N^{(2)}} - c_{B^{(2)}}(B^{(2)})^{-1}N^{(2)} = (c_4, c_5, c_3) - Y^{(2)}[A_4 A_5 A_3] \\ &= (0, 0, 1) - \left(-\frac{4}{3}, -\frac{1}{3}, 0\right) \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & -2 \\ 0 & 0 & 0 \end{bmatrix} = \left(\frac{4}{3}, \frac{1}{3}, \frac{9}{3}\right) > 0\end{aligned}$$

故 $x^{(2)} = \left(\frac{2}{3}, \frac{10}{3}, 0, 0, 0, \frac{1}{3}\right)^T$ 是最优解, $z^* = z^{(2)} = \frac{22}{3}$.

逆乘积形式在一定程度上能保持稀疏性,又能节省存储空间,因此对大规模稀疏问题是一种较为有效的方法.

习 题

2-1 用单纯形法求解下列线性规划问题,并指出问题的解属于哪一类.

$$(1) \min z = -5x_1 - 4x_2$$

$$\text{s. t. } x_1 + 2x_2 \leq 6$$

$$2x_1 - x_2 \leq 4$$

$$5x_1 + 3x_2 \leq 15$$

$$x_1, x_2 \geq 0$$

$$(2) \max z = -x_1 + 2x_2 - x_3$$

$$\text{s. t. } x_1 + x_2 - 2x_3 + x_4 = 10$$

$$2x_1 - x_2 + 4x_3 \leq 8$$

$$-x_1 + 2x_2 - 4x_3 \leq 4$$

$$x_j \geq 0 \quad (j=1, 2, 3, 4)$$

$$(3) \max z = x_1 + 6x_2 + 4x_3$$

$$\text{s. t. } -x_1 + 2x_2 + 2x_3 \leq 13$$

$$4x_1 - 4x_2 + x_3 \leq 20$$

$$x_1 + 2x_2 + x_3 \leq 17$$

$$x_1 \geq 1, \quad x_2 \geq 2, \quad x_3 \geq 3$$

2-2 分别用单纯形法中的大 M 法和两阶段法求解下列线性规划问题,并指出问题的解属于哪一类.

$$(1) \max z = 2x_1 - x_2 + 2x_3$$

$$\text{s. t. } x_1 + x_2 + x_3 \geq 6$$

$$-2x_1 + x_3 \geq 2$$

$$2x_2 - x_3 \geq 0$$

$$x_1, x_2, x_3 \geq 0$$

$$(2) \min z = 4x_1 + x_2$$

$$\text{s. t. } 3x_1 + x_2 = 3$$

$$4x_1 + 3x_2 - x_3 = 6$$

$$x_1 + 2x_2 + x_4 = 4$$

$$x_j \geq 0 \quad (j=1, 2, 3, 4)$$

$$(3) \max z = 10x_1 + 15x_2 + 12x_3$$

$$\text{s. t. } 5x_1 + 3x_2 + x_3 \leq 9$$

$$-5x_1 + 6x_2 + 15x_3 \leq 15$$

$$2x_1 + x_2 + x_3 \geq 5$$

$$x_1, x_2, x_3 \geq 0$$

2-3 已知某线性规划问题的初始单纯形表和用单纯形法迭代后得到的表 2-14,试求括号中未知数 $a \sim l$ 的值.

表 2-14

		x_1	x_2	x_3	x_4	x_5
x_4	6	(b)	(c)	(d)	1	0
x_5	1	-1	3	(e)	0	1
σ_j		(a)	-1	2	0	0
x_1	(f)	(g)	2	-1	$\frac{1}{2}$	0
x_5	4	(h)	(i)	1	$\frac{1}{2}$	1
σ_j		0	-7	(j)	(k)	(l)

2-4 表 2-15 为用单纯形法计算时某一步的表格. 已知该线性规划的目标函数为 $\min z = -5x_1 - 3x_2$, 约束形式为“ $\leq$ ”, x_3, x_4 为松弛变量, 表中解代入目标函数后得 $z = 10$.

表 2-15

	基	b	x_1	x_2	x_3	x_4
	x_3	2	c	0	1	$\frac{1}{5}$
	x_1	a	d	e	0	1
σ_j			b	-1	f	g

(1) 求 a, b, c, d, e, f, g 的值.

(2) 问表中所给出的解是否为最优解?

2-5 在极小化的下列表格中, 6 个常数 a_1, a_2, a_3, a_4, a_5 和 a_6 之值为未知 (假定 $x_j \geq 0 (j=1, 2, \dots, 6)$ 且诸 x_j 都不是人工变量), 说出对六个未知参数的要求, 使以下的说法对表 2-16 为真: (1) 现行解是最优解, 但存在多个最优解; (2) 现行解不可行; (3) 有一个约束条件有矛盾; (4) 现行解是退化的基本可行解; (5) 现行解可行, 但问题无最优解; (6) 现行解是唯一最优解; (7) 现行解可行, 但是将 x_1 取代 x_5 后, 目标函数能够改进, 在转轴后, 目标函数值的总变化是多少?

表 2-16

基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5	x_6
x_2	a_2	0	1	0	0	0	a_1
x_5	$\frac{21}{2}$	a_3	0	0	$-\frac{1}{2}$	1	$\frac{3}{2}$
x_3	$\frac{1}{2}$	$\frac{1}{2}$	0	1	a_4	0	$-\frac{1}{2}$
σ_j		a_5	0	0	a_6	0	$\frac{1}{2}$

2-6 现有线性规划问题

$$\begin{aligned}
 \max z &= \alpha x_1 + 2x_2 + x_3 - x_4 \\
 \text{s. t. } &x_1 + x_2 - x_4 = 4 + 2\beta \quad (1) \\
 &2x_1 - x_2 + 3x_3 - 2x_4 = 5 + 7\beta \quad (2) \\
 &x_1, x_2, x_3, x_4 \geq 0
 \end{aligned}$$

模型中 α, β 为参数, 现要求:

(1) 组成两个新的约束: $(1)' = (1) + (2)$, $(2)' = 2 \times (1) - (2)$, 根据 $(1)'$ 及 $(2)'$, 以 x_1, x_2 为基变量列出初始单纯形表;

(2) 若 $\beta = 0$, 则问 α 为何值时, x_1, x_2 为问题的最优基的基变量;

(3) 若 $\alpha = 3$, 问 β 为何值时, x_1, x_2 为最优基的基变量。

2-7 线性规划问题

$$\begin{aligned}
 \max z &= c^T x \\
 \text{s. t. } &Ax = b \\
 &x \geq 0
 \end{aligned}$$

设 $x^{(0)}$ 为问题的最优解. 若目标函数中用 c^* 代替 c 后, 问题的最优解变为 x^* , 求证:

$$(c^* - c)^T (x^* - x^{(0)}) \geq 0$$

2-8 用修正单纯形法求解线性规划问题

$$\begin{aligned}
 (1) \max z &= 5x_1 + 8x_2 + 7x_3 + 4x_4 + 6x_5 \\
 \text{s. t. } &2x_1 + 3x_2 + 3x_3 + 2x_4 + 2x_5 \leq 20 \\
 &3x_1 + 5x_2 + 4x_3 + 2x_4 + 4x_5 \leq 30 \\
 &x_j \geq 0 \quad (j=1, 2, \dots, 5) \\
 (2) \min z &= -x_1 - 2x_2 + x_3 - x_4 - 4x_5 + 2x_6 \\
 \text{s. t. } &x_1 + x_2 + x_3 + x_4 + x_5 + x_6 \leq 6 \\
 &2x_1 + x_2 - 2x_3 + x_4 \leq 4 \\
 &x_3 + x_4 + 2x_5 + x_6 \leq 4 \\
 &x_j \geq 0 \quad (j=1, 2, \dots, 6)
 \end{aligned}$$

第3章 线性规划的对偶理论

任意线性规划问题都伴随着另一个与之有密切联系的线性规划问题,我们将其中的一个称为原问题,另一个就称为对偶问题.对偶理论深刻揭示了原问题与对偶问题之间的内在联系,在线性规划的理论研究和算法设计中起着重要的作用.例如,成功的线性规划原-对偶内点算法就是基于互补松弛定理而提出来的.

3.1 线性规划的对偶问题

3.1.1 对偶问题的提出

下面,通过一个例子引出线性规划的对偶问题.

例3-1 某家具厂木器车间生产木门与木窗两种产品.加工木门收入为56元/扇,加工木窗收入为30元/扇.生产一扇木门需要木工4小时、油漆工2小时;生产一扇木窗需要木工3小时、油漆工1小时.该车间每日可用木工总工时为120小时,油漆工总工时为50小时.试问车间应如何安排生产才能使每日收入最大?

解 令该车间每日安排生产木门 y_1 扇、木窗 y_2 扇,则由题意,数学模型为

$$\begin{aligned} \max z &= 56y_1 + 30y_2 \\ \text{s. t. } &4y_1 + 3y_2 \leq 120 \\ &2y_1 + y_2 \leq 50 \\ &y_1 \geq 0, \quad y_2 \geq 0 \end{aligned} \quad (3-1)$$

用图解法或单纯形法可求得最优解为: $y_1^* = 15, y_2^* = 20, z^* = 1440$ (元).即该车间每日安排生产木门15扇、木窗20扇时收入最大,为1440元.

现在从另一角度来考虑该车间的生产问题.假若有一位个体经营者,手中有一批木器家具生产订单.他想利用该木器车间的木工和油漆工来加工完成他的订单,就要事先考虑付给该车间每个工时的价格.他可以建立一个数学模型来研究如何定价,才能既使木器车间觉得有利可图从而愿意替他加工这批订单,又使自己所付的工时费用总数最少.

设 x_1 为付给木工每个工时的价格, x_2 为付给油漆工每个工时的价格,则该个体经营者的目标函数为每日所付工时总费用最小:

$$\min z = 120x_1 + 50x_2$$

但该个体经营者所付的价格不能太低,至少不能低于该车间生产木门、木窗时所得到的收入,否则该车间觉得无利可图就不会替他加工这批订单.即 x_1 与 x_2 的取值应满足如下约束条件:

$$\begin{aligned} 4x_1 + 2x_2 &\geq 56 \\ 3x_1 + x_2 &\geq 30 \end{aligned}$$

$$x_1 \geq 0, \quad x_2 \geq 0$$

故该个体经营者的数学模型应为

$$\begin{aligned} \min z &= 120x_1 + 50x_2 \\ \text{s. t.} \quad &4x_1 + 2x_2 \geq 56 \\ &3x_1 + x_2 \geq 30 \\ &x_1 \geq 0, \quad x_2 \geq 0 \end{aligned} \quad (3-2)$$

解之得: $x_1^* = 2, x_2^* = 24, z^* = 1440$.

我们将线性规划模型(3-1)和(3-2)称为一对互为对偶的线性规划模型,两者之间有着密切联系,也有区别. 它们使用了相同的数据,只是这些数据在模型中所处的位置不同,所要表达的含义也不同. (3-1)反映追求木器生产车间收入最大的模型,而(3-2)是寻求个体经营者付给木器生产车间最少的工时费用模型. 若将(3-1)称为原问题,则(3-2)就是其对偶问题. 可以看出,原问题的价值系数在对偶问题中成为约束条件的右端项,而对偶问题的价值系数成为原问题约束条件的右端项;原问题中第一(二)个不等式的变量系数,在对偶问题中成为决策变量 x_1 (x_2) 的系数列向量,而对偶问题第一(二)个不等式的变量系数,在原问题中成为变量 y_1 (y_2) 的系数列向量.

下面,抽象到一般形式来研究原问题与其对偶问题之间的对应关系.

3.1.2 原问题与对偶问题之间的对偶关系

(1) 对称形式的对偶关系

对称形式下线性规划原问题的一般形式为

$$\begin{aligned} \min z &= \sum_{j=1}^n c_j x_j \\ \text{s. t.} \quad &\sum_{j=1}^n a_{ij} x_j \geq b_i \quad (i = 1, 2, \dots, m) \\ &x_j \geq 0 \quad (j = 1, 2, \dots, n) \end{aligned} \quad (3-3)$$

则其对偶问题的数学模型为

$$\begin{aligned} \max \omega &= \sum_{i=1}^m b_i y_i \\ \text{s. t.} \quad &\sum_{i=1}^m a_{ij} y_i \leq c_j \quad (j = 1, 2, \dots, n) \\ &y_i \geq 0 \quad (i = 1, 2, \dots, m) \end{aligned} \quad (3-4)$$

其中 $y_1, y_2, \dots, y_m$ 为对偶问题(3-4)的决策变量,称为**对偶变量**.

若用矩阵形式来表示模型(3-3)和(3-4),则可更清楚地看出两者之间的对称性. 原问题为

$$\begin{aligned} \min z &= c^T x \\ \text{s. t.} \quad &Ax \geq b \\ &x \geq 0 \end{aligned} \quad (3-5)$$

其对偶问题为

$$\begin{aligned}
 \max \omega &= b^T y \\
 \text{s. t. } &A^T y \leq c \\
 &y \geq 0
 \end{aligned} \tag{3-6}$$

其中 A, b, c 的定义与第一章的定义相同, $y = (y_1, y_2, \dots, y_m)^T$. 即原问题求最小化, 对偶问题求最大化; 原问题的约束为“ $\geq$ ”形式, 对偶问题的约束为“ $\leq$ ”形式; 原问题的价值向量 c 在对偶问题中成为约束的右端项, 而对偶问题的价值向量 b 恰好是原问题约束的右端项; 原问题的约束条件左端为 Ax , 而对偶问题的约束条件左端为 $A^T y$. 这说明原问题和对偶问题在形式上恰好是对称的, 故称为一对对称形式的对偶关系.

注意到, 若令 $\omega' = -\omega$, 对偶问题(3-6)可改写为

$$\begin{aligned}
 -\min \omega' &= -b^T y \\
 \text{s. t. } &-A^T y \geq -c \\
 &y \geq 0
 \end{aligned} \tag{3-7}$$

若将其作为原问题, 则按照上述对称形式的对偶关系, 可写出它的对偶问题

$$\begin{aligned}
 -\max z' &= -c^T x \\
 \text{s. t. } &-Ax \geq -b \\
 &x \geq 0
 \end{aligned} \tag{3-8}$$

再令 $z = -z'$, 则式(3-8)可改写为

$$\begin{aligned}
 \min z &= c^T x \\
 \text{s. t. } &Ax \leq b \\
 &x \geq 0
 \end{aligned} \tag{3-9}$$

这恰恰是原问题(3-5). 这说明原问题和对偶问题是相对而言的, 若把对偶问题看成原问题, 则原问题就是其对偶问题, 即对偶问题的对偶是原问题.

(2) 非对称形式的对偶关系

因为并非所有线性规划问题都具有对称形式, 所以下面讨论如何写出一般非对称形式的线性规划问题的对偶问题.

非对称形式下线性规划原问题的一般形式为

$$\begin{aligned}
 \min z &= \sum_{j=1}^n c_j x_j \\
 \text{s. t. } &\sum_{j=1}^n a_{ij} x_j \geq b_i \quad (i \in M_1) \\
 &\sum_{j=1}^n a_{ij} x_j = b_i \quad (i \in M_2) \\
 &x_j \geq 0 \quad (j \in N_1) \\
 &x_j \text{ 自由变量} \quad (j \in N_2)
 \end{aligned} \tag{3-10}$$

其中 $M_1 \cap M_2 = \emptyset, M_1 \cup M_2 = \{1, 2, \dots, m\}, N_1 \cap N_2 = \emptyset, N_1 \cup N_2 = \{1, 2, \dots, n\}$.

对 $j \in N_2$, 令 $x_j = x_j^{(1)} - x_j^{(2)}, x_j^{(1)} \geq 0, x_j^{(2)} \geq 0$, 则将其代入式(3-10)中, 并把式(3-10)

中的等式约束 $\sum_{j=1}^n a_{ij} x_j = b_i$ 化为两个“ $\geq$ ”形式的不等式约束

$$\sum_{j=1}^n a_{ij}x_j \geq b_i \quad \text{和} \quad -\sum_{j=1}^n a_{ij}x_j \geq -b_i$$

则得到

$$\begin{aligned} \min z &= \sum_{j \in N_1} c_j x_j + \sum_{j \in N_2} c_j (x_j^{(1)} - x_j^{(2)}) \\ \text{s. t. } &\sum_{j \in N_1} a_{ij} x_j + \sum_{j \in N_2} a_{ij} (x_j^{(1)} - x_j^{(2)}) \geq b_i \quad (i \in M_1) \\ &\sum_{j \in N_1} a_{ij} x_j + \sum_{j \in N_2} a_{ij} (x_j^{(1)} - x_j^{(2)}) \geq b_i \quad (i \in M_2) \\ &\sum_{j \in N_1} (-a_{ij}) x_j + \sum_{j \in N_2} (-a_{ij}) (x_j^{(1)} - x_j^{(2)}) \geq -b_i \quad (i \in M_2) \\ &x_j \geq 0 \quad (j \in N_1) \\ &x_j^{(1)} \geq 0, \quad x_j^{(2)} \geq 0 \quad (j \in N_2) \end{aligned} \quad (3-11)$$

由对称形式的对偶关系知, (3-11) 的对偶规划为

$$\begin{aligned} \max \omega &= \sum_{i \in M_1} b_i y_i + \sum_{i \in M_2} b_i (y_i^{(1)} - y_i^{(2)}) \\ \text{s. t. } &\sum_{i \in M_1} a_{ij} y_i + \sum_{i \in M_2} a_{ij} (y_i^{(1)} - y_i^{(2)}) \leq c_j \quad (j \in N_1) \\ &\sum_{i \in M_1} a_{ij} y_i + \sum_{i \in M_2} a_{ij} (y_i^{(1)} - y_i^{(2)}) \leq c_j \quad (j \in N_2) \\ &\sum_{i \in M_1} (-a_{ij}) y_i + \sum_{i \in M_2} (-a_{ij}) (y_i^{(1)} - y_i^{(2)}) \leq -c_j \quad (j \in N_2) \\ &y_i \geq 0 \quad (i \in M_1) \\ &y_i^{(1)} \geq 0, \quad y_i^{(2)} \geq 0 \quad (i \in M_2) \end{aligned} \quad (3-12)$$

对 $i \in M_2$, 令 $y_i = y_i^{(1)} - y_i^{(2)}$, $y_i^{(1)} \geq 0, y_i^{(2)} \geq 0$, 则对偶规划 (3-12) 可整理为

$$\begin{aligned} \max \omega &= \sum_{i \in M_1} b_i y_i + \sum_{i \in M_2} b_i y_i \\ \text{s. t. } &\sum_{i \in M_1} a_{ij} y_i + \sum_{i \in M_2} a_{ij} y_i \leq c_j \quad (j \in N_1) \\ &\sum_{i \in M_1} a_{ij} y_i + \sum_{i \in M_2} a_{ij} y_i \leq c_j \quad (j \in N_2) \\ &\sum_{i \in M_1} (-a_{ij}) y_i + \sum_{i \in M_2} (-a_{ij}) y_i \leq -c_j \quad (j \in N_2) \\ &y_i \geq 0 \quad (i \in M_1) \\ &y_i \text{ 自由量} \quad (i \in M_2) \end{aligned}$$

将第二、第三组不等式约束合为一组等式约束, 同时利用 $M_1 \cup M_2 = \{1, 2, \dots, m\}$ 将求和号合并在一起, 得到一般线性规划问题 (3-10) 的对偶问题:

$$\begin{aligned}
 \max \omega &= \sum_{i=1}^m b_i y_i \\
 \text{s. t. } \sum_{i=1}^m a_{ij} y_i &\leq c_j \quad (j \in N_1) \\
 \sum_{i=1}^m a_{ij} y_i &= c_j \quad (j \in N_2) \\
 y_i &\geq 0 \quad (i \in M_1) \\
 y_i &\text{ 自由量} \quad (i \in M_2)
 \end{aligned} \tag{3-13}$$

由于(3-10)和它的对偶问题(3-13)的约束中既有不等式也有等式,而决策变量中既有非负限制的也有无任何符号限制的,所以这种形式的对偶关系在有些书中也称为混合形式的对偶关系。

若将原问题(3-10)中的不等式约束和自由变量去掉,则它具有标准化形式,从而上述对偶关系具体化为标准型线性规划及其对偶规划之间的对偶关系:

$$\begin{aligned}
 \min z &= \sum_{j=1}^n c_j x_j \\
 \text{(LP)} \quad \text{s. t. } \sum_{j=1}^n a_{ij} x_j &= b_i \quad (i = 1, 2, \dots, m) \\
 x_j &\geq 0 \quad (j = 1, 2, \dots, n)
 \end{aligned}$$

和

$$\begin{aligned}
 \max \omega &= \sum_{i=1}^m b_i y_i \\
 \text{(LD)} \quad \text{s. t. } \sum_{i=1}^m a_{ij} y_i &\leq c_j \quad (j = 1, 2, \dots, n)
 \end{aligned}$$

总结上面所述,线性规划原问题与对偶问题在数学模型上的对应关系可归纳为表3-1。根据这些对应关系,可由原问题的模型直接写出对偶问题的模型。

表 3-1 原问题与对偶问题间的对应关系

原问题(对偶问题)		对偶问题(原问题)	
目标函数形式	min	目标函数形式	max
变量	n 个变量 变量 ≥ 0 变量 ≤ 0 无正负限制	约束	n 个约束 约束 $\leq$ 约束 $\geq$ 约束 $=$
约束	m 个约束 约束 $\geq$ 约束 $\leq$ 约束 $=$	变量	m 个变量 变量 ≥ 0 变量 ≤ 0 无正负限制
约束条件的右端项		目标函数中变量的系数	
目标函数中变量的系数		约束条件的右端项	

例 3-2 写出下列线性规划问题的对偶问题

$$\begin{aligned}
 \min z &= 3x_1 + 2x_2 - 3x_3 + 4x_4 \\
 \text{s. t. } &x_1 - 2x_2 + 3x_3 + 4x_4 \leq 3 \\
 &x_2 + 3x_3 + 4x_4 \geq -5 \\
 &2x_1 - 3x_2 - 7x_3 - 4x_4 = 2 \\
 &x_1 \geq 0, \quad x_4 \leq 0, \quad x_2, x_3 \text{ 为自由变量}
 \end{aligned} \tag{3-14}$$

解 由于该问题的不等式和等式约束共有三个,故对偶问题有三个决策变量,设为 y_1, y_2, y_3 . 由表 3-1 知,其对偶规划为

$$\begin{aligned}
 \max \omega &= 3y_1 - 5y_2 + 2y_3 \\
 \text{s. t. } &y_1 + 2y_3 \leq 3 \\
 &-2y_1 + y_2 - 3y_3 = 2 \\
 &3y_1 + 3y_2 - 7y_3 = -3 \\
 &4y_1 + 4y_2 - 4y_3 \geq 4 \\
 &y_1 \leq 0, \quad y_2 \geq 0, \quad y_3 \text{ 为自由变量}
 \end{aligned} \tag{3-15}$$

再令 $y_1 = -y'_1$, 将其代入式(3-15), 得到

$$\begin{aligned}
 \max \omega &= -3y'_1 - 5y_2 + 2y_3 \\
 \text{s. t. } &-y'_1 + 2y_3 \leq 3 \\
 &2y'_1 + 2y_2 - 3y_3 = 2 \\
 &-3y'_1 + 3y_2 - 7y_3 = -3 \\
 &-4y'_1 + 4y_2 - 4y_3 \geq 4 \\
 &y'_1 \geq 0, \quad y_2 \geq 0, \quad y_3 \text{ 为自由变量}
 \end{aligned} \tag{3-16}$$

或

$$\begin{aligned}
 \max \omega &= -3y'_1 - 5y_2 + 2y_3 \\
 \text{s. t. } &-y'_1 + 2y_3 \leq 3 \\
 &2y'_1 + 2y_2 - 3y_3 = 2 \\
 &-3y'_1 + 3y_2 - 7y_3 = -3 \\
 &4y'_1 - 4y_2 + 4y_3 \leq -4 \\
 &y'_1 \geq 0, \quad y_2 \geq 0, \quad y_3 \text{ 为自由变量}
 \end{aligned} \tag{3-17}$$

式(3-15)、式(3-16)和式(3-17)都可作为问题(3-14)的对偶规划.

3.2 对偶性定理

对标准型线性规划(LP)与其对偶问题(LD), 有下面的基本定理, 其中这些定理同样适用于一般线性规划(3-10)和其对偶规划(3-13).

定理 3-1 (弱对偶性定理) 设 $\bar{x}$ 和 $\bar{y}$ 分别是(LP)和(LD)的可行解, 则它们的目标函数值满足不等式关系: $c^T \bar{x} \geq b^T \bar{y}$.

证 令 $\bar{u} = c - A^T \bar{y}$, 因为 $\bar{y}$ 是 (LD) 的可行解, 故 $\bar{u} \geq 0$. 因为

$$A\bar{x} = b, \quad A^T \bar{y} = c - \bar{u}, \quad \bar{x} \geq 0, \quad \bar{u} \geq 0,$$

所以有

$$b^T \bar{y} = (A\bar{x})^T \bar{y} = \bar{x}^T (A^T \bar{y}) = \bar{x}^T (c - \bar{u}) = c^T \bar{x} - \bar{x}^T \bar{u} \leq c^T \bar{x} \quad (3-18)$$

因此, 定理的结论成立. $\square$

根据此定理结果, 可以得到下述推论:

推论 3-1 如果 (LP) 的目标函数值在可行域上无下界, 则 (LD) 必无可行解; 如果 (LD) 的目标函数值在可行域上无上界, 则 (LP) 必无可行解.

证 假设 (LD) 有可行解 $\bar{y}$ 存在, 则对 (LP) 的任一可行解 x 都应有 $c^T x \geq b^T \bar{y}$, 这就与 (LP) 的目标函数值在可行域上无下界矛盾, 故 (LD) 必无可行解. 类似地, 可以证明推论中的后一个结果. $\square$

定理 3-2 (最优性定理) 若 $\bar{x}$ 和 $\bar{y}$ 分别是 (LP) 和 (LD) 的可行解, 则 (LP) 和 (LD) 都有最优解, 且当 $c^T \bar{x} = b^T \bar{y}$ 时, $\bar{x}$ 和 $\bar{y}$ 分别是 (LP) 和 (LD) 的最优解.

证 根据定理 3-1 的结论, 对线性规划 (LP) 的任一可行解 x , 均有

$$c^T x \geq b^T \bar{y}. \quad (3-19)$$

这说明 (LP) 的目标函数在其可行域内有下界, 故有有限的最小值, 从而 (LP) 有最优解. 类似地, 可以证明 (LD) 也有最优解.

当 $c^T \bar{x} = b^T \bar{y}$, 根据式 (3-19) 知, $c^T x \geq c^T \bar{x}$, 因此 $\bar{x}$ 为 (LP) 的最优解. 同理, 可以证明 $\bar{y}$ 是 (LD) 的最优解. $\square$

定理 3-3 (强对偶性定理) 若 (LP) 和 (LD) 中有一个有最优解, 则另一个问题也必存在最优解, 且两个问题最优解的目标函数值必相等.

证 假设原问题 (LP) 存在最优解, 根据定理 1-3 知, 一定存在一个基本可行解 x^* 是其最优解. 设 x^* 所对应的基为 B , 则由 2.5.1 节的分析知, x^* 的目标函数值为

$$z^* = c^T x^* = c_B B^{-1} b$$

且各变量的检验数

$$\sigma_j = c_j - c_B B^{-1} A_j \geq 0 \quad (j = 1, 2, \dots, n)$$

取 $y^* = (c_B B^{-1})^T$, 于是上式可化成

$$c_j - (y^*)^T A_j = c_j - A_j^T y^* \geq 0 \quad (j = 1, 2, \dots, n)$$

即 y^* 满足 (LD) 的约束条件 $A^T y \leq c$, 从而 y^* 是 (LD) 的一个可行解. 又

$$b^T y^* = (y^*)^T b = c_B B^{-1} b = c^T x^*$$

根据定理 3-2 知, y^* 是 (LD) 的最优解. $\square$

给定线性规划 (LP) 的一个基 B , 我们称 $y = (c_B B^{-1})^T$ 是 (LP) 关于基 B 的一个单纯形乘子. 根据定理 3-3 的证明过程, 可得到如下单纯形乘子定理.

定理 3-4 (单纯形乘子定理) 假设 (LP) 有一个对应于基 B 的最优基本可行解, 则此时的单纯形乘子 $y = (c_B B^{-1})^T$ 是相应于对偶问题 (LD) 的一个最优解.

根据此结论, 可以从原问题的最优单纯形表中直接获得对偶问题的最优解. 因为, 若在原问题 (LP) 的系数矩阵 A 中有一个对应于初始基本可行解的 $m \times m$ 阶单位矩阵, 则由初等变换求逆矩阵的方法, 在最终单纯形表中与此初始可行基对应位置上的 m 个系数列向量即组成最优基的逆 B^{-1} . 这样, 由 $y = (c_B B^{-1})^T$ 便可求得对偶问题的最优解. 例如, 用单纯形法

求解线性规划问题(3-1)的标准形式时:

$$\begin{aligned}
 \min z' &= -56y_1 - 30y_2 + 0 \cdot y_3 + 0 \cdot y_4 \\
 \text{s. t. } &4y_1 + 3y_2 + y_3 = 120 \\
 &2y_1 + y_2 + y_4 = 50 \\
 &y_i \geq 0 \quad (i = 1, 2, 3, 4)
 \end{aligned} \tag{3-20}$$

所得到的初始和最终单纯形表如表3-2和表3-3所示. 由于初始可行基为 $[A_3 A_4]$, 最优基为 $B = [A_2 A_1]$, 因此从最终单纯形表中有

$$B^{-1} = \begin{bmatrix} 1 & -2 \\ -\frac{1}{2} & \frac{3}{2} \end{bmatrix}$$

故

$$x^* = (c_B B^{-1})^T = (B^{-1})^T c_B = \begin{bmatrix} 1 & -\frac{1}{2} \\ -2 & \frac{3}{2} \end{bmatrix} \begin{pmatrix} -30 \\ -56 \end{pmatrix} = \begin{pmatrix} -2 \\ -24 \end{pmatrix}$$

即为(3-20)的对偶解, 即下述线性规划问题的解

$$\begin{aligned}
 \max \omega' &= 120x_1 + 50x_2 \\
 \text{s. t. } &4x_1 + 2x_2 \leq -56 \\
 &3x_1 + x_2 \leq -30 \\
 &x_1 \leq 0, \quad x_2 \leq 0
 \end{aligned}$$

表 3-2

$c_j \rightarrow$			-56	-30	0	0
c_B	基	$\bar{b}$	y_1	y_2	y_3	y_4
0	y_3	120	4	3	1	0
0	y_4	50	[2]	1	0	1
σ_j			-56	-30	0	0

表 3-3

$c_j \rightarrow$			-56	-30	0	0
c_B	基	b	y_1	y_2	y_3	y_4
-30	y_2	20	0	[1]	1	-2
-56	y_1	15	1	0	$-\frac{1}{2}$	$\frac{3}{2}$
σ_j			0	0	2	24

定理 3-5 (互补松弛定理) 设 $\bar{x}$ 和 $\bar{y}$ 分别是 (LP) 和 (LD) 的可行解, 则它们分别是 (LP) 和 (LD) 的最优解的充要条件是 $\bar{x}^T (c - A^T \bar{y}) = 0$.

证 必要性 设 $\bar{x}$ 和 $\bar{y}$ 分别是各自问题的最优解, 则

$$b^T \bar{y} = (A\bar{x})^T \bar{y} = \bar{x}^T (A^T y) = \bar{x}^T (A^T y + c - c) = c^T \bar{x} - \bar{x}^T (c - A^T \bar{y}) \leq c^T \bar{x} \quad (3-21)$$

而根据强对偶性定理知

$$b^T \bar{y} = c^T \bar{x}$$

将上述两式结合,便有 $\bar{x}^T (c - A^T \bar{y}) = 0$ 成立.

充分性 因为 $\bar{x}$ 和 $\bar{y}$ 分别是 (LP) 和 (LD) 的可行解,故由式 (3-21) 知,

$$b^T \bar{y} = c^T \bar{x} - \bar{x}^T (c - A^T \bar{y})$$

将其与已知条件 $\bar{x}^T (c - A^T \bar{y}) = 0$ 相结合,得到 $c^T \bar{x} = b^T \bar{y}$. 这样,根据弱对偶性定理,对 (LP) 的任一可行解 x ,都有 $c^T x \geq b^T \bar{y} = c^T \bar{x}$;而对 (LD) 的任一可行解 y ,有 $b^T y \leq c^T \bar{x} = b^T \bar{y}$. 这两个不等式说明 $\bar{x}$ 和 $\bar{y}$ 分别是 (LP) 和 (LD) 的最优解. 至此,定理的结论证毕. $\square$

根据定理 3-5 的结论,我们可以证明下面的对称形式的互补松弛定理.

推论 3-2 设 $\bar{x}$ 和 $\bar{y}$ 分别是对称形式的原问题 (3-5) 及其对偶问题 (3-6) 的可行解,则 $\bar{x}$ 和 $\bar{y}$ 分别是各自问题最优解的充要条件为

$$\begin{cases} \bar{x}^T (c - A^T \bar{y}) = 0 \\ \bar{y}^T (A\bar{x} - b) = 0 \end{cases} \quad \text{或} \quad \begin{cases} \bar{x}_j (c_j - \sum_{i=1}^m a_{ij} \bar{y}_i) = 0 & (j = 1, 2, \dots, n) \\ \bar{y}_i (\sum_{j=1}^n a_{ij} \bar{x}_j - b_i) = 0 & (i = 1, 2, \dots, m) \end{cases}$$

证 在线性规划 (3-5) 的每个不等式约束左端引进非负松弛变量,将其化为如下标准形式

$$\begin{aligned} \min z &= c^T x \\ \text{s. t. } Ax - s &= b \\ x &\geq 0, \quad s \geq 0 \end{aligned} \quad (3-22)$$

将问题 (3-22) 进一步写为

$$\begin{aligned} \min z &= (c^T, 0^T) \begin{pmatrix} x \\ s \end{pmatrix} \\ \text{s. t. } [A - I] \begin{pmatrix} x \\ s \end{pmatrix} &= b \\ x &\geq 0, \quad s \geq 0 \end{aligned} \quad (3-23)$$

其中 $s = (s_1, s_2, \dots, s_m)^T$. 根据定理 3-5, $\begin{pmatrix} \bar{x} \\ \bar{s} \end{pmatrix}$ 和 $\bar{y}$ 分别是问题 (3-23) 和其对偶问题 (3-6) 的最优解的充要条件是

$$\begin{pmatrix} \bar{x} \\ \bar{s} \end{pmatrix}^T \left(\begin{pmatrix} c \\ 0 \end{pmatrix} - [A - I]^T \bar{y} \right) = 0 \quad (3-24)$$

考虑到 $\bar{s} = A\bar{x} - b$, 式 (3-24) 可进一步整理为

$$\bar{x}^T (c - A^T \bar{y}) + (A\bar{x} - b)^T \bar{y} = 0 \quad (3-25)$$

这样,考虑到 $\bar{x}^T (c - A^T \bar{y})$ 和 $(A\bar{x} - b)^T \bar{y}$ 的非负性,式 (3-25) 等价于

$$\bar{x}^T (c - A^T \bar{y}) = 0, \quad \bar{y}^T (A\bar{x} - b) = 0$$

注意到

$$\bar{x}^T (c - A^T \bar{y}) = 0 \Leftrightarrow \sum_{j=1}^n \bar{x}_j (c_j - \sum_{i=1}^m a_{ij} \bar{y}_i) = 0 \Leftrightarrow \sum_{j=1}^n \bar{x}_j (c_j - \sum_{i=1}^m a_{ij} \bar{y}_i) = 0$$

而对所有 $j=1, 2, \dots, n$, $\bar{x}_j$ 和 $c_j - \sum_{i=1}^m a_{ij}\bar{y}_i$ 都非负, 故 $\sum_{j=1}^n \bar{x}_j(c_j - \sum_{i=1}^m a_{ij}\bar{y}_i) = 0$ 当且仅当求和项中的每一项 $\bar{x}_j(c_j - \sum_{i=1}^m a_{ij}\bar{y}_i)$ 都为 0, 即

$$\bar{x}^T(c - A^T\bar{y}) = 0 \Leftrightarrow \bar{x}_j(c_j - \sum_{i=1}^m a_{ij}\bar{y}_i) = 0 \quad (j = 1, 2, \dots, n)$$

类似地, 可以证明

$$\bar{y}^T(A\bar{x} - b) = 0 \Leftrightarrow \bar{y}_i(\sum_{j=1}^n a_{ij}\bar{x}_j - b_i) = 0 \quad (i = 1, 2, \dots, m)$$

至此, 证得推论中的结论成立. $\square$

利用互补松弛定理, 可在已知一个问题的最优解时, 求其对偶问题最优解.

例 3-3 给定如下线性规划问题

$$\begin{aligned} \max \omega &= 2y_1 + 4y_2 + 3y_3 \\ \text{s. t. } &3y_1 + 4y_2 + 2y_3 \leq 60 \\ &2y_1 + y_2 + 2y_3 \leq 40 \\ &y_1 + 3y_2 + 2y_3 \leq 80 \\ &y_i \geq 0 \quad (i = 1, 2, 3) \end{aligned}$$

试应用互补松弛定理证明: $(y_1, y_2, y_3)^T = (0, \frac{20}{3}, \frac{50}{3})^T$ 为它的最优解.

解 若把给定的线性规划问题看作对偶问题, 则其原问题为

$$\begin{aligned} \min z &= 60x_1 + 40x_2 + 80x_3 \\ \text{s. t. } &3x_1 + 2x_2 + x_3 \geq 2 \\ &4x_1 + x_2 + 3x_3 \geq 4 \\ &2x_1 + 2x_2 + 2x_3 \geq 3 \\ &x_i \geq 0 \quad (i = 1, 2, 3) \end{aligned}$$

直接验证便知 $(y_1, y_2, y_3)^T = (0, \frac{20}{3}, \frac{50}{3})^T$ 是对偶问题的一个可行解. 如果它是对偶问题的最优解, $(x_1, x_2, x_3)^T$ 为原问题的最优解, 则根据互补松弛定理可知, x_1, x_2, x_3 除了必须是原问题的一个可行解外, 还必须满足下列条件:

$$\begin{cases} 4x_1 + x_2 + 3x_3 = 4 & \left(\text{因为 } y_2 = \frac{20}{3} > 0 \right) \\ 2x_1 + 2x_2 + 2x_3 = 3 & \left(\text{因为 } y_3 = \frac{50}{3} > 0 \right) \\ x_3 = 0 & \left(\text{因为 } y_1 + 3y_2 + 2y_3 = \frac{160}{3} < 80 \right) \end{cases}$$

由此方程组可解得 $(x_1, x_2, x_3)^T = (\frac{5}{6}, \frac{2}{3}, 0)^T$. 直接验证可知它是原问题的一个可行解. 现 $(y_1, y_2, y_3)^T = (0, \frac{20}{3}, \frac{50}{3})^T$ 和 $(x_1, x_2, x_3)^T = (\frac{5}{6}, \frac{2}{3}, 0)^T$ 分别是对偶问题和原问题的可行解, 又满足互补松弛条件, 故分别是对偶问题和原问题的最优解.

3.3 对偶单纯形法

根据对偶性定理,可以构造一个新的求解线性规划问题(LP)的单纯形法——对偶单纯形法.

3.3.1 对偶单纯形法的基本思路

根据第二章的知识,单纯形法从一个基本可行解迭代到下一个基本可行解时,总是保持解的可行性不变,即总有 $x_B = B^{-1}b \geq 0$,变化的只是检验数向量 σ ,即 σ 由 $\sigma \geq 0$ 不成立逐步过渡到 $\sigma \geq 0$ 成立,一旦达到 $\sigma \geq 0$,也就达到了最优解.由单纯形乘子的定义 $y = (c_B B^{-1})^T$,

$$\sigma_j = c_j - c_B B^{-1} A_j = c_j - A_j^T (c_B B^{-1})^T = c_j - A_j^T y \quad (j = 1, 2, \dots, n)$$

故,当 $\sigma \geq 0$ 时,就有 $A^T y \leq c$,即 $y = (c_B B^{-1})^T$ 是对偶问题(LD)的可行解,而且,对偶问题的目标值 $\omega = b^T (c_B B^{-1})^T = c_B B^{-1} b$ 与原问题的目标值 $z = c_B x_B = c_B B^{-1} b$ 相同.因此,单纯形法的迭代过程也可以理解为:在始终保持原问题解的可行性条件下,使其对偶解由不可行向可行转化,一旦对偶解也成了可行解,原问题和对偶问题同时达到了最优.

当然,也可以设想另一条求解思路,即在迭代过程中,始终保持对偶问题解的可行性条件,而原问题的解由不可行向可行转化,一旦原问题的解也满足了可行性条件,对偶问题和原问题同时达到了最优.这正是对偶单纯形法的基本思路.

3.3.2 对偶单纯形法的计算步骤

定义3-1 设 x 是线性规划(LP)对应于基阵 B 的一个基本解,若它所对应的检验数向量 $\sigma = c^T - c_B B^{-1} A \geq 0$,则称 x 是(LP)的一个对偶可行的基本解.

假定已得到(LP)一个对偶可行的基本解 $\bar{x}$,它所对应的基阵为 B ,即这时有

$$\sigma = c^T - c_B B^{-1} A \geq 0,$$

但 $\bar{x}_B = \bar{b} = B^{-1}b \geq 0$ 不成立(否则, $\bar{x}$ 就是(LP)的最优解).由于进行迭代的目标是使原问题的解由不可行向可行转化,因此,很自然地采用

$$\bar{b}_l = \min \{ \bar{b}_i \mid 1 \leq i \leq m \} \quad (3-26)$$

的方式确定离基变量的指标 l .由弱对偶性定理3-1,若(LP)的最优值 z^* 存在,则一定有 $z^* \geq b^T y = c_B B^{-1} b = \bar{z} = c_B \bar{x}_B$.因此,选择换入基变量时应保证新对偶可行基本解的目标值要比当前迭代点的目标值大,即保证下一个迭代点 $\hat{x}$ 是一个改善了的对偶可行的基本解.注意

到,下一个迭代点 $\hat{x}$ 的第 l 个分量值 $\hat{x}_l$ 必为正的,而 $\hat{x}_l$ 只能取 $\left\{ \frac{\bar{b}_l}{a_{lj}} \mid (j \in J_N) \right\}$ 中的某一个,

故只有对应 $\bar{a}_{lj} < 0$ ($j \in J_N$) 的非基变量才可以考虑作为换入基变量(因为 $\bar{b}_l < 0$).下面根据第 l 行非基变量的系数 $\bar{a}_{lj}$ ($j \in J_N$) 情况分如下两种情形讨论.

情形1 若存在某个 $j_0 \in J_N$,使得 $\bar{a}_{lj_0} < 0$,则由下述规则确定进基变量指标 k

$$\frac{\sigma_k}{a_{lk}} = \max \left\{ \frac{\sigma_j}{a_{lj}} \mid \bar{a}_{lj} < 0 \quad (j \in J_N) \right\} \quad (3-27)$$

不仅可以保证下一个迭代点 $\hat{x}$ 仍为对偶可行的基本解,而且其目标函数值大于当前迭代点

的目标函数值. 这是因为, 根据式(2-25), $\hat{x}$ 的所有变量的检验数为

$$\hat{\sigma}_j = \sigma_j - \frac{\bar{a}_{lj}}{a_{lk}} \cdot \sigma_k \quad (j = 1, 2, \dots, n)$$

对 $\bar{a}_{lj} \geq 0$, 由于 σ_j 与 σ_k 都是非负的, $\bar{a}_{lk} < 0$, 故有 $\hat{\sigma}_j \geq 0$; 而对 $\bar{a}_{lj} < 0$, 由于 $\frac{\sigma_k}{a_{lk}} \geq \frac{\sigma_j}{a_{lj}}$, 即

$$\sigma_j - \frac{\bar{a}_{lj}}{a_{lk}} \cdot \sigma_k \geq 0$$

也有 $\hat{\sigma}_j \geq 0$. 而根据(LP)的典则形式(2-37)知, $\hat{x}$ 的目标函数值 $\hat{z} = \bar{z} + \sigma_k \hat{x}_k \geq \bar{z}$. 即根据上述确定离基和进基规则, 可得到一个新的改善了的对偶可行的基本解 $\hat{x}$.

情形 2 若对非基变量的指标集 J_N 中所有元素 j , 都有 $\bar{a}_{lj} \geq 0$, 则根据(LP)的典则形式(2-37)知, 第 l 个等式约束条件为 $x_l + \sum_{j \in J_N} \bar{a}_{lj} x_j = \bar{b}_l$. 由于 $\bar{a}_{lj} \geq 0$ ($j \in J_N$), 而 $\bar{b}_l < 0$, 因此不可能存在 $x_j \geq 0$ ($j = 1, 2, \dots, n$) 的解, 即原问题无可行解. 这时, 根据推论 3-1, 对偶问题的目标函数值无上界.

现将对偶单纯形法的算法步骤归纳如下:

第 1 步 选取一个初始对偶可行的基本解, 对应的基阵为 B , 列出初始单纯形表.

第 2 步 最优性检验. 计算 $\bar{b} = B^{-1}b$, 若 $\bar{b} \geq 0$, 则停止计算, 当前的对偶可行基本解 $x = \begin{pmatrix} B^{-1}b \\ 0 \end{pmatrix}$ 便是最优解; 否则转下步.

第 3 步 确定离基变量. 根据公式 $\bar{b}_l = \min \{ \bar{b}_i \mid 1 \leq i \leq m \}$ 确定离基变量的指标为 l , 故 x_{B_l} 为离基变量.

第 4 步 检查单纯形表中第 l 行的系数. 若对所有的 $j = 1, 2, \dots, n$, 都有 $\bar{a}_{lj} \geq 0$, 则原问题(LP)无可行解; 否则转下一步.

第 5 步 确定进基变量. 根据如下公式确定进基变量的指标 k :

$$\theta = \frac{\sigma_k}{a_{lk}} = \max \left\{ \frac{\sigma_j}{a_{lj}} \mid \bar{a}_{lj} < 0, (j \in J_N) \right\}.$$

故, x_k 为进基变量.

第 6 步 用进基变量替换离基变量, 构造一个新的基, 并以 $\bar{a}_{lk}$ 为主元进行消元变换, 迭代到一个新的对偶可行的基本解.

例 3-4 试求解下列线性规划问题:

$$\begin{aligned} \min z &= 5x_1 + 2x_2 + 4x_3 \\ \text{s. t. } 3x_1 + x_2 + 2x_3 &\geq 4 \\ 6x_1 + 3x_2 + 5x_3 &\geq 10 \\ x_1, x_2, x_3 &\geq 0 \end{aligned} \quad (3-28)$$

解 将两个不等式约束分别引进剩余变量 x_4 和 x_5 , 原问题化为标准形式:

$$\begin{aligned} \min z &= 5x_1 + 2x_2 + 4x_3 + 0 \cdot x_4 + 0 \cdot x_5 \\ \text{s. t. } 3x_1 + x_2 + 2x_3 - x_4 &= 4 \\ 6x_1 + 3x_2 + 5x_3 - x_5 &= 10 \\ x_i &\geq 0 \quad (i = 1, 2, 3, 4, 5) \end{aligned} \quad (3-29)$$

对此标准型线性规划问题,若要得到其初始基本可行解,需要引进人工变量并对目标函数进行修正,因而采用第二章的单纯形法进行求解并不方便.然而,若选 $B = [A_4, A_5]$ 作为初始基,则可立即得到该问题的初始对偶可行的基本解,因为对 $j = 1, 2, \dots, 5$

$$\sigma_j = c_j - c_B B^{-1} A_j = c_j \geq 0$$

因此,我们用对偶单纯形法进行求解.

为了利用 $B = [A_4, A_5]$ 作为初始基,将式(3-29)中两个等式约束左右两边各乘以 (-1) 得到

$$\begin{aligned} \min z &= 5x_1 + 2x_2 + 4x_3 + 0 \cdot x_4 + 0 \cdot x_5 \\ \text{s. t. } &-3x_1 - x_2 - 2x_3 + x_4 = -4 \\ &-6x_1 - 3x_2 - 5x_3 + x_5 = -10 \\ &x_i \geq 0 \quad (i = 1, 2, 3, 4, 5) \end{aligned} \quad (3-30)$$

列出初始单纯形表,见表3-4.

表3-4

$c_j \rightarrow$			5	2	4	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5
0	x_4	-4	-3	-1	-2	1	0
0	x_5	-10	-6	[-3]	-5	0	1
σ_j			5	2	4	0	0

当取初始基 $B = [A_4, A_5]$ 时, $\bar{b} = b = (-4, -10)^T$ 不是非负向量,而 $\sigma_j \geq 0$ 均成立,故 $x^{(0)} = (0, 0, 0, -4, -10)^T$ 为对偶可行的基本解,但不是最优解.由于 $\bar{b}_2 < \bar{b}_1$,故确定 x_5 为离基变量.将检验数行除以 x_5 所在行的负系数,得到

$$\theta = \max \left\{ \frac{5}{-6}, \frac{2}{-3}, \frac{4}{-5} \right\} = \frac{2}{-3}$$

故 x_2 为进基变量, $\bar{a}_{22} = -3$ 为主元素,按单纯形法进行迭代得表3-5.

表3-5

$c_j \rightarrow$			5	2	4	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5
0	x_4	$-\frac{2}{3}$	[-1]	0	$-\frac{1}{3}$	1	$-\frac{1}{3}$
2	x_2	$\frac{10}{3}$	2	1	$\frac{5}{3}$	0	$-\frac{1}{3}$
σ_j			1	0	$\frac{2}{3}$	0	$\frac{2}{3}$

在表3-5中, $\bar{b}_1 < 0$,故当前的对偶可行的基本解仍不是最优解.由于只有 $\bar{b}_1 < 0$,故确定 x_4 为离基变量.将检验数行除以 x_4 所在行的负系数,得到

$$\theta = \max \left\{ \frac{1}{-1}, \frac{\frac{2}{3}}{-\frac{1}{3}}, \frac{\frac{2}{3}}{-\frac{1}{3}} \right\} = \frac{1}{-1} = -1$$

故 x_1 为进基变量, $\bar{a}_{11} = -1$ 为主元素, 按单纯形法进行迭代得表 3-6.

表 3-6

$c_j \rightarrow$			5	2	4	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5
5	x_1	$\frac{2}{3}$	1	0	$\frac{1}{3}$	-1	$\frac{1}{3}$
2	x_2	2	0	1	1	2	-1
σ_j			0	0	$\frac{1}{3}$	1	$\frac{1}{3}$

由于表 3-6 中的 $\bar{b} \geq 0$, 检验数向量 $\sigma \geq 0$, 故当前的对偶可行的基本解 $x^* = \left(\frac{2}{3}, 2, 0, 0, 0\right)^T$ 为最优解, 最优基 $B^* = [A_1, A_2] = \begin{bmatrix} 3 & 1 \\ 6 & 3 \end{bmatrix}$. 而根据最终单纯形表 3-6 可以

看到, $(B^*)^{-1} = -\begin{bmatrix} -1 & \frac{1}{3} \\ 2 & -1 \end{bmatrix}$, 故对偶问题的最优解

$$y^* = (c_{B^*} (B^*)^{-1})^T = \left((5, 2) \begin{bmatrix} 1 & -\frac{1}{3} \\ -2 & 1 \end{bmatrix} \right)^T = \left(1, \frac{1}{3} \right)^T$$

对偶单纯形法由于不需要初始解满足可行性, 因此对有些问题使用起来比较方便, 如下一章介绍的灵敏度分析. 但注意到, 对偶单纯形法要求初始解是对偶可行的基本解, 这个条件并不是总能得到满足. 这时, 需要构造一个扩充问题, 以此得到一个初始的对偶可行的基本解. 下面, 我们来介绍这种求初始对偶可行基本解的方法.

3.3.3 初始对偶基本可行解的求法

假设已得到标准型线性规划原问题 (LP) 的一个基本解, 即得到 (LP) 的一个基阵 B . 不失一般性, 假设 B 是由矩阵 A 的前 m 列向量构成. 根据基阵 B , 线性规划 (LP) 可以化为

$$\begin{aligned} \min z &= c^T x \\ x_B + \sum_{j \in J_N} \bar{A}_j x_j &= \bar{b} \\ x_i &\geq 0 \quad (i = 1, 2, \dots, n) \end{aligned} \quad (3-31)$$

其中 x_B 的定义与第 2.5.1 节的相同, J_N 是非基变量下标的集合. 将问题 (3-31) 再增加一个变量 x_{n+1} 和一个约束条件

$$x_{n+1} + \sum_{j \in J_N} x_j = M$$

其中 M 是很大的正数, 则得到 (3-31) 的一个扩充问题

$$\begin{aligned} \min z &= c^T x \\ x_B + \sum_{j \in J_N} \bar{A}_j x_j &= \bar{b} \\ \sum_{j \in J_N} x_j + x_{n+1} &= M \\ x_i &\geq 0 \quad (i = 1, 2, \dots, n+1) \end{aligned} \quad (3-32)$$

以系数矩阵的前 m 列和第 $(n+1)$ 列组成的 $(m+1)$ 阶单位矩阵为基, 容易得到问题 (3-32) 的一个基本解 $\bar{x}^{(0)} = ((x_B^{(0)})^T, (x_\Pi^{(0)})^T)^T$, 其中

$$x_B^{(0)} = \begin{bmatrix} x_B \\ M \end{bmatrix} = \begin{bmatrix} \bar{b} \\ M \end{bmatrix}, \quad x_\Pi = 0$$

这个基本解不一定是对偶可行的, 但由此出发很容易求出 (3-32) 的一个对偶可行的基本解.

若基本解 $\bar{x}^{(0)}$ 不是对偶可行的, 即检验数中有负的, 并假设负检验数中最小的一个为 σ_k , 则以 σ_k 相对应的变量 x_k 作为换入变量, 以 x_{n+1} 为换出变量, 即以 $a_{m+1,k}$ 为主元素进行变换, 可得到全部检验数非负, 从而求得一个对偶可行的基本解. 这是因为: 变换前、后检验数之间的关系是

$$\sigma'_j = \sigma_j - \frac{a_{m+1,j}}{a_{m+1,k}} \cdot \sigma_k$$

其中 σ'_j 是变换后在新基下的检验数. 当 $j \in J_N \cup \{n+1\}$ 时, $a_{m+1,j} = 1$, 而 $a_{m+1,k} = 1$, 故有 $\sigma'_j = \sigma_j - \sigma_k \geq 0$; 而当 $j \notin J_N \cup \{n+1\}$ 时, $\sigma_j = 0$, $a_{m+1,j} = 0$, 故有 $\sigma'_j = 0$.

由于扩充问题 (3-32) 的对偶问题总是可行的, 因此, 根据弱对偶定理 3-1 和推论 3-1 可知, 扩充问题 (3-32) 或无可行解或有有限最优解. 而从问题 (3-31) 和 (3-32) 的可行域之间的关系可以看到, 若扩充问题无可行解, 则原问题 (LP) 也无可行解; 若扩充问题的最优解为 $\bar{x}^* = (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_n, \bar{x}_{n+1})^T$, 则 $\bar{x} = (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_n)^T$ 是原问题 (LP) 的可行解, 并且当扩充问题的最优值与大 M 无关时, $\bar{x}$ 就是原问题 (LP) 的最优解.

例 3-5 用对偶单纯形法求解下列线性规划问题:

$$\begin{aligned} \min z &= -2x_1 + 2x_2 \\ \text{s. t. } x_1 + 4x_2 + x_3 &\geq 8 \\ x_1 + 2x_2 + 2x_3 &\leq 6 \\ x_1, x_2, x_3 &\geq 0 \end{aligned} \quad (3-33)$$

解 引入剩余变量 x_4 和松弛变量 x_5 , 把问题化为标准形式:

$$\begin{aligned} \min z &= -2x_1 + 2x_2 \\ \text{s. t. } x_1 + 4x_2 + x_3 - x_4 &= 8 \\ x_1 + 2x_2 + 2x_3 + x_5 &= 6 \\ x_j &\geq 0 \quad (j = 1, 2, \dots, 5) \end{aligned}$$

把第一个约束两端同乘以 (-1) , 再增加约束条件 $x_1 + x_2 + x_3 + x_6 = M$, 得到扩充问题

$$\begin{aligned} \min z &= -2x_1 + 2x_2 \\ \text{s. t. } -x_1 - 4x_2 - x_3 + x_4 &= -8 \\ x_1 + 2x_2 + 2x_3 + x_5 &= 6 \\ x_1 + x_2 + x_3 + x_6 &= M \\ x_j &\geq 0 \quad (j = 1, 2, \dots, 6) \end{aligned}$$

把扩充问题的数据列入表 3-7 中, 并计算各检验数 σ_j .

表 3-7

$c_j \rightarrow$			-2	2	0	0	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5	x_6
0	x_4	-8	-1	-4	-1	1	0	0
0	x_5	6	1	2	2	0	1	0
0	x_6	M	[1]	1	1	0	0	1
σ_j			-2	2	0	0	0	0

因 $\sigma_1 = -2$, 故此时的基本解还不是对偶可行的. 选择 x_1 为换入变量, x_6 为换出变量, 即以 $a_{31} = 1$ 为主元素进行变换, 得到表 3-8. 该表中的基本解即为扩充问题的初始对偶可行的基本解. 以该表为初始表, 用对偶单纯形法经两次迭代即可得到扩充问题的最优解, 也即得到原问题的一个可行解, 又因此时扩充问题的最优目标值与 M 无关, 故得到原问题的最优解为 $x^* = (4, 1, 0, 0, 0)^T$, 最优值为 $z^* = -6$.

表 3-8

$c_j \rightarrow$			-2	2	0	0	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5	x_6
0	x_4	$-8 + M$	0	-3	0	1	0	1
0	x_5	$6 - M$	0	1	1	0	1	[-1]
-2	x_1	M	1	1	1	0	0	1
σ_j			0	4	2	0	0	2
0	x_4	-2	0	[-2]	1	1	1	0
0	x_6	$M - 6$	0	-1	-1	0	-1	1
-2	x_1	6	1	2	2	0	1	0
σ_j			0	6	4	0	2	0
2	x_2	1	0	1	$-\frac{1}{2}$	$-\frac{1}{2}$	$-\frac{1}{2}$	0
0	x_6	$M - 5$	0	0	$-\frac{3}{2}$	$-\frac{1}{2}$	$-\frac{3}{2}$	1
-2	x_1	4	1	0	3	1	2	0
σ_j			0	0	7	3	5	0

习 题

3-1 写出下列线性规划问题的对偶问题:

$$(1) \min z = 2x_1 + 3x_2 + 5x_3 - 7x_4$$

$$\text{s. t. } x_1 + 2x_2 - 3x_3 + x_4 \geq 2$$

$$-2x_1 + x_2 - x_3 + 3x_4 \leq -3$$

$$7x_1 - 5x_2 + 4x_3 - 6x_4 = 10$$

$$x_1 \geq 0, \quad x_2, \quad x_3 \text{ 自由}, \quad x_4 \leq 0$$

$$(2) \max z = 3x_1 - 2x_2 - 5x_3 - 8x_5$$

$$\text{s. t. } 2x_1 + 3x_2 - 3x_3 - x_4 - 5x_5 \geq -2$$

$$x_2 - 2x_3 + 3x_4 + 4x_5 = -5$$

$$-x_1 + 2x_3 - 2x_4 - 3x_5 \leq -5$$

$$x_1, x_3, x_5 \geq 0, \quad x_2, x_4 \text{ 自由}$$

3-2 已知线性规划问题

$$\max z = 3x_1 + 2x_2$$

$$\text{s. t. } -x_1 + 2x_2 \leq 4$$

$$3x_1 + 2x_2 \leq 14$$

$$x_1 - x_2 \leq 3$$

$$x_1, x_2 \geq 0$$

(1) 写出对偶问题.

(2) 应用对偶理论证明原问题与对偶问题都存在最优解(不必求解).

3-3 已知线性规划问题

$$\min z = 2x_1 - x_2 + 2x_3$$

$$\text{s. t. } -x_1 + x_2 + x_3 = 4$$

$$-x_1 + x_2 - kx_3 \leq 6$$

$$x_1 \leq 0, \quad x_2 \geq 0, \quad x_3 \text{ 自由}$$

其最优解为 $x_1 = -5, x_2 = 0, x_3 = -1$.

(1) 求 k 的值.

(2) 写出对偶问题并求其最优解.

3-4 考虑有界变量的线性规划问题

$$\max z = x_1 - x_2 + x_3 - x_4$$

$$\text{s. t. } x_1 + x_2 + x_3 + x_4 = 8$$

$$0 \leq x_1 \leq 8$$

$$-4 \leq x_2 \leq 4$$

$$-2 \leq x_3 \leq 4$$

$$0 \leq x_4 \leq 10$$

(1) 写出对偶问题.

(2) 应用互补松弛条件证明 $x = (8, -4, 4, 0)^T$ 是最优解.

3-5 用对偶单纯形法求解下列线性规划问题:

$$(1) \min z = 2x_1 + 3x_2 + 5x_3 + 6x_4$$

$$\text{s. t. } x_1 + 2x_2 + 3x_3 + x_4 \geq 2$$

$$-2x_1 + x_2 - x_3 + 3x_4 \leq -3$$

$$x_j \geq 0 \quad (j=1,2,3,4)$$

$$(2) \min z = 3x_1 + 4x_2 + 2x_3 + x_4 + 5x_5$$

$$\text{s. t. } x_1 - 2x_2 - x_3 + x_4 + x_5 \leq -3$$

$$-x_1 - x_2 - x_3 + x_4 + x_5 \leq -2$$

$$x_1 + x_2 - 2x_3 + 2x_4 - 3x_5 \leq 4$$

$$x_j \geq 0 \quad (j=1,2,\cdots,5)$$

第4章 灵敏度分析和参数线性规划

本章主要研究线性规划的数据 a_{ij} , b_i 和 c_j 发生变化对最优解所产生的影响. 灵敏度分析主要研究 a_{ij} , b_i 和 c_j 等参数改变到某一值时, 对问题最优解的影响; 而参数线性规划主要研究 c_j 或 b_i 沿某一方向连续变动时, 最优解的变化情况.

4.1 灵敏度分析

在前面讲述的线性规划问题中, 我们都假定问题中的 a_{ij} , b_i , c_j 是已知常数. 但实际上这些数据有的是统计数据、有的是预测数字、有的是专家评估得到的数据, 它们并非是绝对精确且也不是绝对不变的. 因此就会提出以下问题: 当这些参数中的一个或几个发生变化时, 问题的最优解会有什么变化, 或者这些参数在一个多大范围内变化时, 问题的最优解不变. 这就是灵敏度分析要研究解决的问题.

当线性规划问题中的一个或几个参数变化时, 当然可以用单纯形法从头计算, 看最优解有无变化. 但这样做既麻烦又没有必要, 因为前面已经讲到, 单纯形法的迭代计算是从一组基向量变换为另一组基向量, 表中每步迭代得到的数字只随基向量的不同选择而改变, 因此有可能把个别参数的变化直接在计算得到最优解的最终单纯形表上反映出来. 这样就不需要从头计算, 而直接对计算得到最优解的单纯形表进行审查, 看一些数字变化后, 是否仍满足最优解的条件, 如果不满足的话, 再从这个表开始进行迭代计算, 求得最优解.

对标准型线性规划(LP), 本节假定其最终表上已得到最优基 B , 最优解为

$$x^* = \begin{pmatrix} x_B \\ x_N \end{pmatrix} = \begin{pmatrix} B^{-1}b \\ 0 \end{pmatrix}$$

4.1.1 参数 c_j 的灵敏度分析

若 c_j ($j=1, 2, \dots, n$) 中的某个参数 c_r 发生了变化(其他 c_j 均不变化), 则由式(2-38)和式(2-41)可知, c_r 的变化只会影响单纯形表中的检验数向量 σ . 设 c_r 变为 $c'_r = c_r + \Delta c_r$, 下面分两种情形来讨论:

情形1 在最终单纯形表中, c_r 所对应的变量 x_r 是关于 B 的一个非基变量. 这时, 由于 c_B 没有改变, 故受影响的仅是检验数 σ_r :

$$\sigma'_r = c'_r - c_B B^{-1} A_j = c_r + \Delta c_r - c_B B^{-1} A_j = \sigma_r + \Delta c_r \quad (4-1)$$

因此, 若 $\sigma'_r \geq 0$, 即

$$\Delta c_r \geq -\sigma_r \quad (4-2)$$

则最优解不变; 否则, 原最优基不再是最优的了, 以 x_r 为换入变量, 把最终单纯形表上的 σ_r 换成 σ'_r , c_r 换成 c'_r , 继续用单纯形法求解.

情形2 在最终单纯形表中, c_r 所对应的变量 x_r 是关于 B 的一个基变量. 不妨设 x_r 是

第 k 行约束式的基变量, 即有 $x_r = x_{B_k}$. 此时, c_B 有了变化:

$$c'_B = c_B + \Delta c_{B_k} e_k^T = c_B + \Delta c_r e_k^T$$

其中, e_k 是一个第 k 个元素为 1 而其他元素为 0 的 m 维的单位向量, 因此, 非基变量的检验数向量 σ_N 将受到影响:

$$\begin{aligned} \sigma'_j &= c_j - c'_B B^{-1} A_j = c_j - c_B B^{-1} A_j - \Delta c_{B_k} e_k^T B^{-1} A_j \\ &= \sigma_j - \Delta c_r \bar{a}_{kj} \quad (j \in J_N) \end{aligned} \quad (4-3)$$

因此, 若要 $\sigma'_j \geq 0$ ($j \in J_N$), 则 Δc_r 必须满足条件:

$$\Delta c_r \leq \frac{\sigma_j}{\bar{a}_{kj}} \quad (j \in J_N, \bar{a}_{kj} > 0) \quad \text{和} \quad \Delta c_r \geq \frac{\sigma_j}{\bar{a}_{kj}} \quad (j \in J_N, \bar{a}_{kj} < 0)$$

考虑到 $\{\bar{a}_{kj} | \bar{a}_{kj} > 0, j \in J_N\}$ 或 $\{\bar{a}_{kj} | \bar{a}_{kj} < 0, j \in J_N\}$ 可能为空, 故 Δc_{B_k} 的变化范围为

$$\max \left\{ -\infty, \frac{\sigma_j}{\bar{a}_{kj}} \mid j \in J_N, \bar{a}_{kj} < 0 \right\} \leq \Delta c_r \leq \min \left\{ +\infty, \frac{\sigma_j}{\bar{a}_{kj}} \mid j \in J_N, \bar{a}_{kj} > 0 \right\} \quad (4-4)$$

即, 当 Δc_r 没有超出式 (4-4) 的范围, 则最优解不变; 否则, 把最终单纯形表上的 σ_N 换成 σ'_N , c_r 换成 c'_r , 继续用单纯形法求解.

例 4-1 已知线性规划问题的标准形式为

$$\min z = x_1 - 2x_2 - x_3 + 0 \cdot x_4 + 0 \cdot x_5$$

$$\text{s. t. } x_1 + x_2 + x_3 + x_4 = 6$$

$$2x_1 - x_2 + x_5 = 10$$

$$x_j \geq 0 \quad (j = 1, 2, \dots, 5)$$

其最优单纯形表见表 4-1.

表 4-1

$c_j \rightarrow$			1	-2	-1	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5
-2	x_2	6	1	1	1	1	0
0	x_5	10	3	0	1	1	1
σ_j			3	0	1	2	0

问: (1) 当 c_1 由 1 变为 $c_1 + \Delta c_1 = -4$ 时, 求新问题的最优解.

(2) 讨论 c_2 在什么范围内变化时, 原有的最优解仍是最优解.

解 (1) 由表 4-1 知, c_1 是非基变量 x_1 的系数, 故当 c_1 由 1 变为 $c_1 + \Delta c_1 = -4$ 时, 受影响的只是 x_1 自己的检验数 σ_1 . 因为 $\Delta c_1 = -5 < -\sigma_1 = -3$, 故最优性准则已不满足. 根据式 (4-1), $\sigma'_1 = \sigma_1 + \Delta c_1 = 3 + (-5) = -2$. 用 σ'_1 和 c'_1 分别替换表 4-1 中的 σ_1 和 c_1 , 重新迭代, 可得到新问题的最优解, 见表 4-2.

表 4-2

$c_j \rightarrow$			-4	-2	-1	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5
-2	x_2	6	1	1	1	1	0
0	x_5	10	[3]	0	1	1	1
σ_j			-2	0	1	2	0
-2	x_2	$\frac{8}{3}$	0	1	$\frac{2}{3}$	$\frac{2}{3}$	$-\frac{1}{3}$
-4	x_1	$\frac{10}{3}$	1	0	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{1}{3}$
σ_j			0	0	$\frac{5}{3}$	$\frac{8}{3}$	$\frac{2}{3}$

因此,当 c_1 由 1 变为 -4 时,新问题的最优解为 $\hat{x}^* = \left(\frac{10}{3}, \frac{8}{3}, 0, 0, 0\right)^T$.

(2) 由于 c_2 是基变量 x_2 的系数,因此,要使原有的最优解仍是最优,只要 Δc_2 不超出式 (4-4) 的范围. 由于

$$\min \left\{ +\infty, \frac{\sigma_j}{\bar{a}_{kj}} \mid j \in J_N, \bar{a}_{kj} > 0 \right\} = \min \left\{ +\infty, \frac{3}{1}, \frac{1}{1}, \frac{2}{1} \right\} = 1$$

而

$$\max \left\{ -\infty, \frac{\sigma_j}{\bar{a}_{kj}} \mid j \in J_N, \bar{a}_{kj} < 0 \right\} = -\infty$$

故当 $\Delta c_2 \leq 1$ 时,原有的最优解保持不变.

4.1.2 参数 b_i 的灵敏度分析

若 b_i ($i=1, 2, \dots, m$) 中的某个参数 b_s 发生了变化(其他 b_i 均不变化),则由式 (2-38) 和式 (2-41) 可知, b_s 的变化只会影响单纯形表中的第三列 $\bar{b} = B^{-1}b$. 设 b_s 变为 $b'_s = b_s + \Delta b_s$. 为了保持 B 的最优基的地位,则新的 $\bar{b}' = B^{-1}b' \geq 0$ 仍应成立. 为了方便起见,令

$$B^{-1} = [g_{ij}]_{m \times m} = [g^{(1)}, g^{(2)}, \dots, g^{(m)}]$$

其中 $g^{(i)}$ 表示 B^{-1} 的第 i 列. 于是,

$$\bar{b}' = B^{-1}(b + \Delta b_s e_s) = \bar{b} + \Delta b_s B^{-1} e_s = \bar{b} + \Delta b_s g^{(s)} \quad (4-5)$$

其中 e_s 是一个第 s 个元素为 1 而其他元素为 0 的 m 维向量. 因此,由 $\bar{b}' \geq 0$ 可得

$$\Delta b_s \geq -\frac{\bar{b}_i}{g_{is}} \quad (g_{is} > 0) \quad \text{和} \quad \Delta b_s \leq -\frac{\bar{b}_i}{g_{is}} \quad (g_{is} < 0)$$

考虑到可能会出现 $g^{(s)} \leq 0$ 或 $g^{(s)} \geq 0$ 的情况,所以 Δb_s 应满足

$$\max \left\{ -\infty, -\frac{\bar{b}_i}{g_{is}} \mid g_{is} > 0, 1 \leq i \leq m \right\} \leq \Delta b_s \leq \min \left\{ +\infty, -\frac{\bar{b}_i}{g_{is}} \mid g_{is} < 0, 1 \leq i \leq m \right\} \quad (4-6)$$

如果 Δb_s 超出上述范围,则新得到的解为不可行解. 但由于 b_s 的变化不影响检验数,故仍保

持所有检验数 ≥ 0 ,即满足对偶可行性.这时,可在原最终单纯形表的基础上,换上改变后的 b' ,用对偶单纯形法继续迭代求出新的最优解.

例 4-2 已知线性规划问题及其最优单纯形表(见表 4-3):

$$\begin{aligned} \min z &= x_1 + x_2 - 4x_3 \\ \text{s. t. } x_1 + x_2 + 2x_3 + x_4 &= 9 \\ x_1 + x_2 - x_3 + x_5 &= 2 \\ -x_1 + x_2 + x_3 + x_6 &= 4 \\ x_j &\geq 0 \quad (j = 1, 2, \dots, 6) \end{aligned}$$

若右端列向量 $b = (9, 2, 4)^T$ 变化为 $b' = (3, 2, 3)^T$,求新问题的最优解.

表 4-3

$c_j \rightarrow$			1	1	-4	0	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5	x_6
1	x_1	$\frac{1}{3}$	1	$-\frac{1}{3}$	0	$\frac{1}{3}$	0	$-\frac{2}{3}$
0	x_5	6	0	2	0	0	1	1
-4	x_3	$\frac{13}{3}$	0	$\frac{2}{3}$	1	$\frac{1}{3}$	0	$\frac{1}{3}$
σ_j			0	4	0	1	0	2

解 根据题意,向量 b 的变化量为 $\Delta b = (-6, 0, -1)^T$.而从单纯形表 4-3 中知,最优

基 $B = [A_1 A_5 A_3]$ 的逆 $B^{-1} = \begin{bmatrix} \frac{1}{3} & 0 & -\frac{2}{3} \\ 0 & 1 & 1 \\ \frac{1}{3} & 0 & \frac{1}{3} \end{bmatrix}$.这样,根据式(4-5),有

$$\bar{b}' = B^{-1}(b + \Delta b) = \bar{b} + B^{-1}\Delta b = \begin{pmatrix} \frac{1}{3} \\ 6 \\ \frac{13}{3} \end{pmatrix} + \begin{bmatrix} \frac{1}{3} & 0 & -\frac{2}{3} \\ 0 & 1 & 1 \\ \frac{1}{3} & 0 & \frac{1}{3} \end{bmatrix} \begin{pmatrix} -6 \\ 0 \\ -1 \end{pmatrix} = \begin{pmatrix} -1 \\ 5 \\ 2 \end{pmatrix}$$

由于 $\bar{b}' \geq 0$ 不成立,故最优解发生改变.将表 4-3 中的第三列修改为 $(-1, 5, 2)^T$,得到表 4-4,再用对偶单纯形法求解,得到新问题的最优解 $\hat{x}^* = (0, 0, \frac{3}{2}, 0, \frac{7}{2}, \frac{3}{2})^T$.

表 4-4

$c_j \rightarrow$			1	1	-4	0	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5	x_6
1	x_1	-1	1	$-\frac{1}{3}$	0	$\frac{1}{3}$	0	$-\left[\frac{2}{3}\right]$
0	x_5	5	0	2	0	0	1	1
-4	x_3	2	0	$\frac{2}{3}$	1	$\frac{1}{3}$	0	$\frac{1}{3}$
σ_j			0	4	0	1	0	2
0	x_6	$\frac{3}{2}$	$-\frac{3}{2}$	$\frac{1}{2}$	0	$-\frac{1}{2}$	0	1
0	x_5	$\frac{7}{2}$	$\frac{3}{2}$	$\frac{3}{2}$	0	$\frac{1}{2}$	1	0
-4	x_3	$\frac{3}{2}$	$\frac{1}{2}$	$\frac{1}{2}$	1	$\frac{1}{2}$	0	0
σ_j			3	3	0	2	0	0

4.1.3 约束条件的系数列向量 A_k 的灵敏度分析

若系数矩阵 A 中的某个列向量 A_k ($k=1,2,\dots,n$) 发生了变化(其他列均不变化),则由式(2-39)和式(2-41)可知, A_k 的变化可能会影响单纯形表中的所有系数,也可能只影响单纯形表中的第 k 列数据,这依赖于 A_k 是否是基阵 B 中的列向量. 假设 A_k 变化为 $A'_k = A_k + \Delta A_k$. 下面分两种情形来讨论.

情形1 A_k 不是基阵 B 中的列向量,即 x_k 不是基变量. 这时, A_k 的变化只会影响到最终单纯形表上的第 k 列数据和第 k 个检验数. 最终表上的第 k 列数据变为 $B^{-1}A'_k$, 而新的检验数 $\sigma'_k = c_k - c_B B^{-1}A'_k$. 若 $\sigma'_k \geq 0$, 则原最优解仍为最优解; 否则, 最优性准则已不满足, 分别用 $B^{-1}A'_k$ 和 σ'_k 代替单纯形表中的第 k 列 $B^{-1}A_k$ 及 σ_k 后, 以 x_k 作为进基变量进行迭代, 求出新问题的最优解.

情形2 A_k 是基阵 B 中的列向量, 即 x_k 是基变量. 此时, 表中的所有系数都要发生改变, 因此还是用单纯形法重新计算比较方便.

4.1.4 增加一个新变量 x_{n+1} 的分析

在建立实际问题的数学模型时, 可能漏掉了一些内容或只考虑了主要内容, 忽略了次要内容. 在得到了最优解后, 再追加这些次要内容, 讨论新变量对原最优解的影响.

假设已得到原问题(LP)的最优解 $x^* = (x_1^*, x_2^*, \dots, x_n^*)^T$, 它所对应的最优基为 B . 现在增加一个新的非负变量 x_{n+1} , 其价值系数为 c_{n+1} , 相应的系数列向量为

$$A_{n+1} = (a_{1,n+1}, a_{2,n+1}, \dots, a_{m,n+1})^T$$

即新问题为

$$\begin{aligned} \min z &= c_1 x_1 + \cdots + c_n x_n + c_{n+1} x_{n+1} \\ (\text{LP}') \quad \text{s. t.} \quad &a_{i1} x_1 + \cdots + a_{in} x_n + a_{i,n+1} x_{n+1} = b_i \quad (i = 1, 2, \cdots, m) \\ &x_j \geq 0 \quad (j = 1, 2, \cdots, n+1) \end{aligned}$$

显然,原问题(LP)的最优基 B 是新问题(LP')的可行基,原有变量的检验数没有改变,而 $\sigma_{n+1} = c_{n+1} - c_B B^{-1} A_{n+1}$. 若

(1) $\sigma_{n+1} \geq 0$, 则新问题的最优性准则仍满足,故 $\hat{x}^* = (x_1^*, x_2^*, \cdots, x_n^*, 0)^T$ 是新问题(LP')的最优解. 此时说明新增加的变量 x_{n+1} 对最优解没有影响,或说新增加的内容对总的结果是不利的(因为若 $x_{n+1} > 0$, 则达不到最优解).

(2) $\sigma_{n+1} < 0$, 说明新增加的内容对总的结果是有利的,但 $\hat{x}^*$ 不是新问题的最优解. 在原问题(LP)的最优单纯形表上增加一列 $\begin{pmatrix} \bar{A}_{n+1} \\ \sigma_{n+1} \end{pmatrix} = \begin{pmatrix} B^{-1} A_{n+1} \\ c_{n+1} - c_B B^{-1} A_{n+1} \end{pmatrix}$, 以 x_{n+1} 为进基变量,用单纯形法继续迭代,求得新问题的最优解.

例 4-3 仍以例 4-2 问题为例,其最优单纯形表为表 4-3,现增加一个新变量 x_7 , 且已知 $c_7 = -3, A_7 = (3, 1, -3)^T$, 求新问题的最优解.

$$\text{解 由表 4-3 知, } B^{-1} = \begin{bmatrix} \frac{1}{3} & 0 & -\frac{2}{3} \\ 0 & 1 & 1 \\ \frac{1}{3} & 0 & \frac{1}{3} \end{bmatrix}, c_B = (1, 0, -4), \text{ 故}$$

$$\sigma_7 = c_7 - c_B B^{-1} A_7 = -3 - (1, 0, -4) \begin{bmatrix} \frac{1}{3} & 0 & -\frac{2}{3} \\ 0 & 1 & 1 \\ \frac{1}{3} & 0 & \frac{1}{3} \end{bmatrix} \begin{pmatrix} 3 \\ 1 \\ -3 \end{pmatrix} = -6 < 0$$

因此,在表 4-3 中增加一列 $\begin{pmatrix} \bar{A}_7 \\ \sigma_7 \end{pmatrix} = \begin{pmatrix} B^{-1} A_7 \\ -6 \end{pmatrix} = (3, -2, 0, -6)^T$, 得到表 4-5, 然后以 x_7 作

基变量进行迭代,求得新问题的最优解为 $\hat{x}^* = (0, 0, \frac{13}{3}, 0, \frac{56}{9}, 0, \frac{1}{9})^T$.

表 4-5

$c_j \rightarrow$			1	1	-4	0	0	0	-3
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5	x_6	x_7
1	x_1	$\frac{1}{3}$	1	$-\frac{1}{3}$	0	$\frac{1}{3}$	0	$-\frac{2}{3}$	[3]
0	x_5	6	0	2	0	0	1	1	-2
-4	x_3	$\frac{13}{3}$	0	$\frac{2}{3}$	1	$\frac{1}{3}$	0	$\frac{1}{3}$	0

续表 4-5

σ_j			0	4	0	1	0	2	-6
-3	x_7	$\frac{1}{9}$	$\frac{1}{3}$	$-\frac{1}{9}$	0	$\frac{1}{9}$	0	$-\frac{2}{9}$	1
0	x_5	$\frac{56}{9}$	$\frac{2}{3}$	$\frac{16}{9}$	0	$\frac{2}{9}$	1	$\frac{5}{9}$	0
-4	x_3	$\frac{13}{3}$	0	$\frac{2}{3}$	1	$\frac{1}{3}$	0	$\frac{1}{3}$	0
σ_j			2	$\frac{10}{3}$	0	$\frac{5}{3}$	0	$\frac{2}{3}$	0

4.1.5 增加一个新约束条件的分析

现考虑在原问题(LP)中增加一个新的约束条件后对原最优解 x^* 的影响. 设新增加的约束为

$$P_{m+1}x \leq b_{m+1} \quad (4-7)$$

其中 $P_{m+1} = (a_{m+1,1}, a_{m+1,2}, \dots, a_{m+1,n})$. 下面分两种情形讨论:

情形 1 x^* 满足新增的约束条件(4-7). 由于新问题的可行域总是包含在原问题的可行域内, 因此, 此时的 x^* 也是新问题的最优解. 即, 新增加的约束对总的结果没有影响.

情形 2 x^* 不满足新增的约束条件(4-7). 这时, 需重新求解新问题的最优解. 不失一般性, 设原最优基 B 是由矩阵 A 的前 m 列组成的.

把新增加的约束(4-7)增加一个松弛变量 x_{n+1} , 则变为

$$P_{m+1}x + x_{n+1} = b_{m+1} \quad (4-8)$$

将(4-8)中的 P_{m+1} 再按基变量 x_B 与非基变量 x_N 分为 $(P_{m+1})_B$ 和 $(P_{m+1})_N$ 两部分, 即

$$(P_{m+1})_B x_B + (P_{m+1})_N x_N + x_{n+1} = b_{m+1} \quad (4-9)$$

显然, x_{n+1} 是约束(4-9)的基变量. 新问题的基变量为 $\begin{pmatrix} x_B \\ x_{n+1} \end{pmatrix}$, 新问题的基 B' 、 $(B')^{-1}$ 及右端

向量 b' 如下

$$B' = \begin{bmatrix} B & 0 \\ (P_{m+1})_B & 1 \end{bmatrix}, \quad (B')^{-1} = \begin{bmatrix} B^{-1} & 0 \\ -(P_{m+1})_B B^{-1} & 1 \end{bmatrix}, \quad b' = \begin{pmatrix} b \\ b_{m+1} \end{pmatrix}$$

对于增加约束后的新问题, 在现行基 B' 下对应变量 $x_j (j \neq n+1)$ 的检验数是

$$\sigma'_j = c_j - c_{B'} (B')^{-1} A'_j = c_j - (c_B \ 0) \begin{bmatrix} B^{-1} & 0 \\ -(P_{m+1})_B B^{-1} & 1 \end{bmatrix} \begin{pmatrix} A_j \\ a_{m+1,j} \end{pmatrix} = c_j - c_B B^{-1} A_j = \sigma_j$$

而 $\sigma'_{n+1} = 0$. 因此, 现行的基本解 $\begin{pmatrix} x_{B'} \\ 0 \end{pmatrix}$ 是对偶可行的, 其中

$$x_{B'} = \begin{pmatrix} x_B \\ x_{n+1} \end{pmatrix} = (B')^{-1} b' = \begin{bmatrix} B^{-1} & 0 \\ -(P_{m+1})_B B^{-1} & 1 \end{bmatrix} \begin{pmatrix} b \\ b_{m+1} \end{pmatrix} = \begin{pmatrix} B^{-1} b \\ b_{m+1} - (P_{m+1})_B B^{-1} b \end{pmatrix}$$

因此, 若 $b_{m+1} - (P_{m+1})_B B^{-1} b \geq 0$, 则现行的对偶可行的基本解是新问题的可行解, 即为最优

解;否则,在原来最终单纯形表的基础上,增加新的约束式(4-9)的数据,通过矩阵行的初等变换,把原最终单纯形表上的各基向量列及新增列 A_{n+1} 化为单位矩阵,再用对偶单纯形法求解.

值得注意的是,在上述讨论中并未要求 b_{m+1} 非负,因而,当所增约束是“ $\geq$ ”不等式时,只需用“-1”乘以约束的左右两端,就能变成上面讨论过的形式.此外,若需在新约束中引入人工变量,由于其相应的价值系数为大 M ,各检验数不再保持不变.这时,可用单纯形法求新的最优解.

例 4-4 已知线性规划问题

$$\begin{aligned} \min z &= x_1 + x_2 - 4x_3 \\ \text{s. t. } x_1 + x_2 + 2x_3 &\leq 9 \\ x_1 + x_2 - x_3 &\leq 2 \\ -x_1 + x_2 + x_3 &\leq 4 \\ x_1, x_2, x_3 &\geq 0 \end{aligned} \quad (4-10)$$

在三个不等式约束中分别引进松弛变量 x_4, x_5, x_6 , 将其化为标准型线性规划,然后用单纯形法求解得到最优单纯形表 4-3. 现增加新约束 $-3x_1 + x_2 + 6x_3 \leq 17$, 求新问题的最优解.

解 增加约束后的新问题为

$$\begin{aligned} \min z &= x_1 + x_2 - 4x_3 \\ \text{s. t. } x_1 + x_2 + 2x_3 &\leq 9 \\ x_1 + x_2 - x_3 &\leq 2 \\ -x_1 + x_2 + x_3 &\leq 4 \\ -3x_1 + x_2 + 6x_3 &\leq 17 \\ x_1, x_2, x_3 &\geq 0 \end{aligned} \quad (4-11)$$

由表 4-3 知,原问题的最优解为 $x^* = \left(\frac{1}{3}, 0, \frac{13}{3}, 0, 6, 0\right)^T$. 容易验证, x^* 不满足(4-11)中的新增加的约束,故不是新问题的最优解.

在新增加的约束中引入松弛变量 x_7 后,得到等式约束

$$-3x_1 + x_2 + 6x_3 + x_7 = 17 \quad (4-12)$$

将式(4-12)加进原问题的最优表 4-3 中成为表 4-6.

表 4-6

$c_j \rightarrow$			1	1	-4	0	0	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5	x_6	x_7
1	x_1	$\frac{1}{3}$	1	$-\frac{1}{3}$	0	$\frac{1}{3}$	0	$-\frac{2}{3}$	0
0	x_5	6	0	2	0	0	1	1	0
-4	x_3	$\frac{13}{3}$	0	$\frac{2}{3}$	1	$\frac{1}{3}$	0	$\frac{1}{3}$	0
0	x_7	17	-3	1	6	0	0	0	1
σ_j			0	4	0	1	0	2	0

将第一行的3倍、第三行的(-6)倍分别加到第四行上,使基变量 x_1, x_5, x_6, x_7 的系数列向量构成单位矩阵,得到表4-7.在表4-7中,所有检验数 $\sigma_j \geq 0$ ($j=1, 2, \dots, 7$),但 $\bar{b}_4 < 0$,故当前解是对偶可行基本解.用对偶单纯形法求解, x_7 是离基变量.因

$$\theta = \max \left\{ -\frac{4}{4}, -\frac{1}{1}, -\frac{2}{4} \right\} = -\frac{1}{2}$$

故 x_6 是进基变量, $\bar{a}_{46} = -4$ 是主元,进行迭代得到表4-8.由表4-8可得新问题的最优解为 $\hat{x}^* = \left(\frac{5}{3}, 0, \frac{11}{3}, 0, 4, 2, 0 \right)^T$.

表4-7

$c_j \rightarrow$			1	1	-4	0	0	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5	x_6	x_7
1	x_1	$\frac{1}{3}$	1	$-\frac{1}{3}$	0	$\frac{1}{3}$	0	$-\frac{2}{3}$	0
0	x_5	6	0	2	0	0	1	1	0
-4	x_3	$\frac{13}{3}$	0	$\frac{2}{3}$	1	$\frac{1}{3}$	0	$\frac{1}{3}$	0
0	x_7	-8	0	-4	0	-1	0	[-4]	1
σ_j			0	4	0	1	0	2	0

表4-8

$c_j \rightarrow$			1	1	4	0	0	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5	x_6	x_7
1	x_1	$\frac{5}{3}$	1	$\frac{1}{3}$	0	$\frac{1}{2}$	0	0	$-\frac{1}{6}$
0	x_5	4	0	1	0	$-\frac{1}{4}$	1	0	$\frac{1}{4}$
-4	x_3	$\frac{11}{3}$	0	$\frac{1}{3}$	1	$\frac{1}{4}$	0	0	$\frac{1}{12}$
0	x_7	2	0	1	0	$\frac{1}{4}$	0	1	$-\frac{1}{4}$
σ_j			0	2	0	$\frac{1}{2}$	0	0	$\frac{1}{2}$

4.2 参数线性规划

考虑标准型线性规划问题(LP),若令参数 c_j 或 b_i 沿着某一方向连续变动,则目标函数 z 将随着 c_j 或 b_i 的变动而呈线性变动.由于 z 是这个变动参数的线性函数,因而称为参数线性规划.

当目标函数中的 c_j 值连续变化时,其参数线性规划的形式为

$$\begin{aligned}
 \min z(\lambda) &= (c + \lambda c^*)^T x \\
 \text{s. t. } Ax &= b \\
 x &\geq 0
 \end{aligned} \tag{4-13}$$

式中, c 为原线性规划问题(LP)的价值向量, c^* 为变动向量 λ 为参数.

当约束条件右端项发生变化时, 其参数线性规划的形式为

$$\begin{aligned}
 \min z(\lambda) &= c^T x \\
 \text{s. t. } Ax &= b + \lambda b^* \\
 x &\geq 0
 \end{aligned} \tag{4-14}$$

式中的 b 为原线性规划问题(LP)的资源向量, b^* 为变动向量, λ 为参数.

参数线性规划问题分析的步骤是:

- (1) 令 $\lambda = 0$, 用单纯形法或对偶单纯形法求解, 得到最终单纯形表;
- (2) 将 λc^* 或 λb^* 项反映到最终单纯形表中去;
- (3) 随 λ 值的增大或减小, 观察原问题或对偶问题: 一是确定表中现有解(基)允许 λ 值的变动范围, 二是当 λ 值的变动超出这个范围时, 用单纯形法或对偶单纯形法求取新的解;
- (4) 重复第(3)步一直到 λ 值继续增大或减小时, 表中的解(基)不再出现变化为止.

例 4-5 分析 λ 值变化时, 下述参数线性规划问题最优解的变化:

$$\begin{aligned}
 \min z &= (3 - \lambda)x_1 - (2 + \lambda)x_2 \\
 \text{s. t. } 2x_1 + 5x_2 &\leq 10 \\
 6x_1 + x_2 &\leq 12 \\
 x_1 - x_2 &\leq 1 \\
 x_1 &\geq 0, \quad x_2 \geq 0
 \end{aligned}$$

解 先令 $\lambda = 0$ 求得最优解, 并将 λc^* 反映到最终单纯形表中, 得表 4-9. 在表 4-9 中, 当 $-2 \leq \lambda \leq \frac{19}{3}$ 时, 表中的解 $x^* = (0, 2, 0, 10, 3)^T$ 为最优解, 最优值为 $z = -4 - 2\lambda$; 当 $\lambda > \frac{19}{3}$ 时, x_1 的检验数 $\sigma_1 < 0$, 用单纯形表计算得表 4-10. 在表 4-10 中, 只要 $\lambda \geq \frac{19}{3}$, 表中的解 $x^* = \left(\frac{25}{14}, \frac{9}{7}, 0, 0, \frac{1}{2}\right)^T$ 为最优解, 最优值为 $z = \frac{[39 - 43\lambda]}{14}$.

表 4-9

$c_j \rightarrow$			$(3 - \lambda)$	$-(2 + \lambda)$	0	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5
$-2 - \lambda$	x_2	2	$\frac{2}{5}$	1	$\frac{1}{5}$	0	0
0	x_4	10	$\frac{28}{5}$	0	$-\frac{1}{5}$	1	0
0	x_5	3	$\frac{7}{5}$	0	$\frac{1}{5}$	0	1
σ_j			$\frac{19 - 3\lambda}{5}$	0	$\frac{2 + \lambda}{5}$	0	0

表 4-10

$c_j \rightarrow$			$(3-\lambda)$	$-(2+\lambda)$	0	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5
$-2-\lambda$	x_2	$\frac{9}{7}$	0	1	$\frac{3}{14}$	$-\frac{1}{14}$	0
$3-\lambda$	x_1	$\frac{25}{14}$	1	0	$-\frac{1}{28}$	$\frac{5}{28}$	0
0	x_5	$\frac{1}{2}$	0	0	$\frac{1}{4}$	$-\frac{1}{4}$	1
σ_j			0	0	$\frac{25+5\lambda}{28}$	$\frac{-19+3\lambda}{28}$	0

又在表 4-9 中,当 $\lambda < -2$ 时, x_3 的检验数 $\sigma_3 < 0$,用单纯形表计算得表 4-11.

表 4-11

$c_j \rightarrow$			$(3-\lambda)$	$-(2+\lambda)$	0	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5
0	x_3	10	2	5	1	0	0
0	x_4	12	6	1	0	1	0
0	x_5	1	1	-1	0	0	1
σ_j			$3-\lambda$	$-(2+\lambda)$	0	0	0

在表 4-11 中,当 $\lambda \leq -2$ 时,表中的解 $x^* = (0,0,10,12,1)^T$ 为最优解,最优值 $z=0$. 图 4-1 表明了例 4-5 中目标函数值 $z(\lambda)$ 随 λ 的变化情况.




图 4-1

例 4-6 分析 λ 值变化时,下述参数线性规划问题最优解的变化:

$$\begin{aligned} \min z &= x_1 + x_2 + 2x_3 + x_4 \\ \text{s. t. } x_1 - 2x_3 - x_4 &= 2 - 3\lambda \\ x_2 - x_3 + x_4 &= -1 - \lambda \\ x_j &\geq 0 \quad (j = 1, 2, 3, 4) \end{aligned}$$

解 令 $\lambda = 0$ 求解得最终单纯形表, 见表 4-12.

表 4-12

$c_j \rightarrow$			1	1	2	1
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4
1	x_1	4	1	-2	0	-3
2	x_3	1	0	-1	1	-1
σ_j			0	5	0	6

又因 $\Delta b' = B^{-1} \Delta b = \begin{bmatrix} 1 & -2 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} -3\lambda \\ -\lambda \end{bmatrix} = \begin{bmatrix} -\lambda \\ \lambda \end{bmatrix}$, 将其反映到最终单纯形表 4-12 中, 得到新表 4-13. 表 4-13 中最优基不变的条件是 $-1 \leq \lambda \leq 4$, 这时表中最优解为 $x^* = (4 - \lambda, 0, 1 + \lambda, 0)^T$, 最优值为 $z = 6 + \lambda$.

表 4-13

$c_j \rightarrow$			1	1	2	1
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4
1	x_1	$4 - \lambda$	1	-2	0	-3
2	x_3	$1 + \lambda$	0	-1	1	1
σ_j			0	5	0	6

当 $\lambda > 4$ 时, 表 4-13 中的基变量 x_1 将小于 0, 这时可用对偶单纯形法继续求解得表 4-14. 表 4-14 中的最优解为 $x^* = \left(0, 0, \frac{7+2\lambda}{3}, \frac{\lambda-4}{3}\right)^T$, 最优值为 $z = \frac{5\lambda+10}{3}$.

表 4-14

$c_j \rightarrow$			1	1	2	1
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4
1	x_4	$\frac{\lambda-4}{3}$	$-\frac{1}{3}$	$\frac{2}{3}$	0	1
2	x_3	$\frac{7+2\lambda}{3}$	$\frac{1}{3}$	$-\frac{5}{3}$	1	0
σ_j			$\frac{2}{3}$	$\frac{11}{3}$	3	0

当 $\lambda < -1$ 时, 表 4-13 中的基变量 x_3 将小于 0, 这时可用对偶单纯形法继续求解得表 4-15. 表 4-15 中的最优解为 $x^* = (2 - 3\lambda, -1 - \lambda, 0, 0)^T$, 最优值 $z = 1 - 4\lambda$.

综合表 4-13 至表 4-15, 将例 4-6 的 $z(\lambda)$ 随参数 λ 的变化情况图示, 见图 4-2.

表 4-15

$c_j \rightarrow$			1	1	2	1
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4
1	x_1	$2-3\lambda$	1	0	-2	-5
1	x_2	$-1-\lambda$	0	1	-1	-1
σ_j			0	0	5	7




图 4-2

习 题

4-1 已知线性规划问题

$$\begin{aligned} \min z &= -3x_1 - 8x_2 \\ \text{s. t. } x_1 + 2x_2 &\leq 800 \\ 3x_1 + x_2 &\leq 900 \\ x_2 &\leq 350 \\ x_1, x_2 &\geq 0. \end{aligned}$$

用单纯形法求解时得到的最终单纯形表如表 4-16 所示.

表 4-16

$c_j \rightarrow$			-3	-8	0	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5
-3	x_1	100	1	0	1	0	-2
0	x_4	250	0	0	-3	1	5
-8	x_2	350	0	1	0	0	1
σ_j			0	0	3	0	2

若其中的约束条件 $x_2 \leq 350$ 变为 $x_2 \leq 500$, 试分析最优解的变化.

4-2 已知线性规划问题

$$\min z = -10x_1 - 5x_2$$

$$\text{s. t. } 3x_1 + 4x_2 \leq 9$$

$$5x_1 + 2x_2 \leq 8$$

$$x_1, x_2 \geq 0$$

用单纯形法求解时得到的最终单纯形表如表 4-17 所示.

表 4-17

$c_j \rightarrow$			-10	-5	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4
-5	x_2	$\frac{3}{2}$	0	1	$\frac{5}{14}$	$-\frac{3}{14}$
-10	x_1	1	1	0	$-\frac{1}{7}$	$\frac{2}{7}$
σ_j			0	0	$\frac{5}{14}$	$\frac{25}{14}$

试用灵敏度分析的方法分别判别:

(1) 目标函数中价值系数 c_1 或 c_2 分别在什么范围内变动, 上述最优解不变.

(2) 约束条件右端项 b_1, b_2 当一个保持不变时, 另一个在什么范围内变化时, 原问题的最优基保持不变.

(3) 问题的目标函数变为 $\min z = -12x_1 - 4x_2$ 时, 最优解如何变化?

(4) 约束条件右端项由 $\begin{pmatrix} 9 \\ 8 \end{pmatrix}$ 变为 $\begin{pmatrix} 11 \\ 9 \end{pmatrix}$ 时, 最优解为多少?

4-3 给定线性规划问题

$$\min z = -2x_1 - 3x_2 - x_3$$

$$\text{s. t. } \frac{1}{3}x_1 + \frac{1}{3}x_2 + \frac{1}{3}x_3 \leq 1$$

$$\frac{1}{3}x_1 + \frac{4}{3}x_2 + \frac{7}{3}x_3 \leq 3$$

$$x_1, x_2, x_3 \geq 0$$

用单纯形法求解时得到的最终单纯形表如表 4-18 所示.

表 4-18

$c_j \rightarrow$			-2	-3	-1	0	0
c_B	基	$\bar{b}$	x_1	x_2	x_3	x_4	x_5
-2	x_1	1	1	0	-1	4	-1
-3	x_2	2	0	1	2	-1	1
σ_j			0	0	3	5	1

试分析下列各种条件下最优解(基)的变化:

(1) 目标函数中变量 x_3 的系数变为 6.

(2) 分别确定目标函数中变量 x_1 和 x_2 的系数 c_1, c_2 在什么范围内变动时, 最优解保持不变.

(3) 约束条件右端项由 $\begin{pmatrix} 1 \\ 3 \end{pmatrix}$ 变为 $\begin{pmatrix} 2 \\ 3 \end{pmatrix}$.

(4) 增加一个新变量 $x_6, P_6 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, c_6 = 7$.

(5) 增添一个新的约束 $x_1 + 2x_2 + x_3 \leq 4$.

4-4 分析 λ 值变化时, 下述参数线性规划问题最优解的变化:

$$(1) \min z(\lambda) = -2x_1 - x_2$$

$$\text{s. t.} \quad 5x_2 \leq 15$$

$$6x_1 + 2x_2 \leq 24 + \lambda$$

$$x_1 + x_2 \leq 5$$

$$x_1, x_2 \geq 0$$

$$(2) \min z(\lambda) = -3x_1 - 2x_2 - 5x_3$$

$$\text{s. t.} \quad x_1 + 2x_2 + x_3 \leq 40 - \lambda$$

$$3x_1 + 2x_3 \leq 60 + 2\lambda$$

$$x_1 + 4x_2 \leq 30 - 7\lambda$$

$$x_1, x_2, x_3 \geq 0$$

第5章 线性规划应用实例

线性规划有着非常广泛的应用. 这一方面是由于许多实际问题可直接模型化为线性规划; 另一方面是由于线性规划存在着比较成熟的求解方法, 如第二章介绍的单纯形法和过去20年里发展起来的内点法, 通常将许多实际问题的非线性规划模型进行处理而转化为线性规划. 本章仅举出一部分应用实例, 以此使读者了解如何将一个复杂的实际问题转化为一个合理的线性规划模型. 这些实例主要选自本书参考文献, 在此处不再一一列出.

5.1 套裁下料问题

套裁下料问题是一类常见且比较简单的应用问题, 我们用一个例子来说明如何建立该类问题的数学模型.

例5-1 某化工厂生产宽度为60个单位长的标准玻璃纸. 现需将这种玻璃纸裁剪为三种规格, 宽度分别为28、20和15个单位长. 市场对这三种规格的需求分别是30、60和80卷. 问应以怎样的方法裁剪, 可使耗费的标准玻璃纸最少而又能满足市场的需要?

解 通过简单的计算, 可以事先设计出几种裁剪的方法, 如表5-1中所示. 但这几种方法单独使用都不能满足市场的需要, 只有巧妙地搭配混合使用, 才能既满足市场要求又使耗费的标准玻璃纸最少, 这就是所谓套裁.

表 5-1

裁剪张数 宽度	方法	一	二	三	四	五	六	七
28		2	1	1	0	0	0	0
20		0	1	0	3	2	1	0
15		0	0	2	0	1	2	4
合计		56	48	58	60	55	50	60
耗费		4	12	2	0	5	10	0

假设按方法一、二、三、四、五、六、七种方式裁剪的标准玻璃纸的卷数分别为 $x_1, x_2, x_3, x_4, x_5, x_6, x_7$, 则耗费掉的总玻璃纸的单位长为

$$z = 4x_1 + 12x_2 + 2x_3 + 0 \cdot x_4 + 5x_5 + 10x_6 + 0 \cdot x_7$$

由于市场对宽度为28、20和15个单位长规格的玻璃纸的需求分别为30、60和80卷, 因此有

$$2x_1 + x_2 + x_3 = 30$$

$$x_2 + 3x_4 + 2x_5 + x_6 = 60$$

$$2x_3 + x_5 + 2x_6 + 4x_7 = 80$$

另外, $x_1, x_2, x_3, x_4, x_5, x_6, x_7$ 还应是非负的整数. 因为我们希望所选用的裁剪方法在满足市场需求的情况下, 能使耗费的标准玻璃纸最少, 故问题的数学模型为

$$\min z = 4x_1 + 12x_2 + 2x_3 + 0 \cdot x_4 + 5x_5 + 10x_6 + 0 \cdot x_7$$

$$\text{s. t. } 2x_1 + x_2 + x_3 = 30$$

$$x_2 + 3x_4 + 2x_5 + x_6 = 60$$

$$2x_3 + x_5 + 2x_6 + 4x_7 = 80$$

$$x_j \geq 0 \text{ 且为整数 } (j = 1, 2, \dots, 7)$$

用大 M 法解上述线性规划, 得最优解为 $x^* = (15, 0, 0, 20, 0, 0, 20)^T$, $z^* = 60$. 此结果表明, 最优裁剪方案为: 按表 5-1 中的第一种方式裁剪 15 卷; 第四种方式裁剪 20 卷; 第七种方式裁剪 20 卷, 即可满足市场对三种宽度规格玻璃纸的需要, 耗费掉的标准玻璃纸共 60 个单位长.

5.2 配料问题

配料问题, 又称调和问题, 是另一类常见的线性规划应用问题. 它是研究将若干种不同的原料按一定的技术指标配成不同产品的方法. 例如, 化工生产、塑料加工、冶金工业、石油加工、洗涤用品生产、轻工业中一些药液的配方以及营养配餐等都属于这类问题. 典型的配料问题中除了包含具有不同技术特性的原料和一定技术要求的产品数量外, 同时有相应的成本与价格. 配料问题的目标通常是在满足产品的技术要求及数量前提下, 使成本最小. 我们举例如下:

例 5-2 某炼油厂生产三种规格的汽油: 70 号、80 号和 85 号, 它们各有不同的辛烷值与含硫量的质量要求. 这三种汽油由三种原料油调和而成, 每种原料油每日可用量、质量指标及生产成本见表 5-2, 每种汽油的质量要求和销售价格见表 5-3. 假定在调和中辛烷值与含硫量指标都符合线性可加性, 试问该炼油厂如何安排生产才能使其利润最大?

表 5-2 原料油的质量及成本数据

序号(i)	原料	辛烷值	含硫量/%	成本/(元 $\cdot$ t $^{-1}$)	可用量/(日 $\cdot$ t $^{-1}$)
1	直馏汽油	62	1.5	600	2000
2	催化汽油	78	0.8	900	1000
3	重整汽油	90	0.2	1400	500

表 5-3 汽油产品的质量要求与销售价

序号(i)	产品	辛烷值	含硫量/%	销售价/(元·t ⁻¹)
1	70 号汽油	≥ 70	≤ 1	900
2	80 号汽油	≥ 80	≤ 1	1200
3	85 号汽油	≥ 85	≤ 0.6	1500

解 建立本例题数学模型的关键是决策变量的选择. 如果选择各种汽油产品的产量作为决策变量, 在建立数学模型时会遇到一些困难. 我们定义决策变量 x_{ij} 为第 i 种产品油中调入第 j 种原料的数量. 记 p_i 为单位第 i 种产品的销售价格, c_j 为单位第 j 种原料的生产成本, e_i 及 $\bar{e}_j$ 分别为单位产品油和原料油的辛烷值, h_i 及 $\bar{h}_j$ 分别为单位产品油和原料油的含硫量, s_j 为原料油每日的可用量. 首先来考虑问题的目标函数. 第 i 种汽油产品所产生的利润应为

$$p_i(x_{i1} + x_{i2} + x_{i3}) - c_1x_{i1} - c_2x_{i2} - c_3x_{i3} = \sum_{j=1}^3 (p_i - c_j)x_{ij}$$

因此目标函数为

$$\sum_{i=1}^3 \sum_{j=1}^3 (p_i - c_j)x_{ij}$$

约束条件应有三组: 汽油产品的辛烷值要求为

$$\bar{e}_1x_{i1} + \bar{e}_2x_{i2} + \bar{e}_3x_{i3} \geq e_i(x_{i1} + x_{i2} + x_{i3}) \quad (i = 1, 2, 3)$$

汽油产品的含硫量要求为

$$\bar{h}_1x_{i1} + \bar{h}_2x_{i2} + \bar{h}_3x_{i3} \leq h_i(x_{i1} + x_{i2} + x_{i3}) \quad (i = 1, 2, 3)$$

原料油可用量的限制为

$$x_{1j} + x_{2j} + x_{3j} \leq s_j \quad (j = 1, 2, 3)$$

因此, 本题的数学模型为

$$\begin{aligned} \max \quad & \sum_{i=1}^3 \sum_{j=1}^3 (p_i - c_j)x_{ij} \\ \text{s. t.} \quad & \sum_{j=1}^3 (\bar{e}_j - e_i)x_{ij} \geq 0 \quad (i = 1, 2, 3) \\ & \sum_{j=1}^3 (h_i - \bar{h}_j)x_{ij} \geq 0 \quad (i = 1, 2, 3) \\ & \sum_{i=1}^3 x_{ij} \leq s_j \quad (j = 1, 2, 3) \\ & x_{ij} \geq 0 \quad (i, j = 1, 2, 3) \end{aligned}$$

将已知数值代入并化简后, 其数学模型为

$$\begin{aligned} \max z = & 300x_{11} + 0 \cdot x_{12} - 500x_{13} + 600x_{21} + 300x_{22} \\ & - 200x_{23} + 900x_{31} + 600x_{32} + 100x_{33} \\ \text{s. t.} \quad & -8x_{11} + 8x_{12} + 20x_{13} \geq 0 \end{aligned}$$

$$-18x_{21} - 2x_{22} + 10x_{23} \geq 0$$

$$-23x_{31} - 7x_{32} + 5x_{33} \geq 0$$

$$-0.5x_{11} + 0.2x_{12} + 0.8x_{13} \geq 0$$

$$-0.5x_{21} + 0.2x_{22} + 0.8x_{23} \geq 0$$

$$-0.9x_{31} - 0.2x_{32} + 0.4x_{33} \geq 0$$

$$x_{11} + x_{21} + x_{31} \leq 2000$$

$$x_{12} + x_{22} + x_{32} \leq 1000$$

$$x_{13} + x_{23} + x_{33} \leq 500$$

$$x_{ij} \geq 0 \quad (i, j = 1, 2, 3)$$

5.3 生产工艺优化问题

有不少产品的生产过程是要通过许多道工序来完成的,而各道工序之间的联系是可以利用数学模型来描述的.运用数学模型来优化其生产过程能够提高设备的利用率,从而提高经济效益.这里,我们只关心通过建立线性规划模型就能达到优化目的的问题.

例5-3 某日化厂生产洗衣粉和洗涤剂,生产原料由市场供应:5元/kg,供应量无限.该厂加工1kg原料可产出0.5kg普通洗衣粉和0.3kg普通洗涤剂.工厂还可以对普通洗衣粉及普通洗涤剂进行精加工,加工1kg普通洗衣粉可得到0.5kg浓缩洗衣粉,加工1kg普通洗涤剂可产出0.25kg高级洗涤剂,加工示意图见图5-1.市场售价:每kg普通洗衣粉为8元,每kg浓缩洗衣粉为24元,每kg普通洗涤剂为12元,每kg高级洗涤剂为55元.每加工1kg原料的加工成本为1元,每kg精加工产品的加工成本为3元,工厂设备每天最多可处理4000kg原料,而对精加工没有限制.若市场对产品也没有限制,问该厂应如何安排生产才能使每日利润最大?




图5-1 某日化工厂生产示意图

解 设每日生产普通洗衣粉的产量为 x_1 kg, 生产浓缩洗衣粉的产量为 x_2 kg, 生产普通洗涤剂的产量为 x_3 kg, 生产高级洗涤剂的产量为 x_4 kg, 每日加工原料为 x_0 kg, 则工厂利润 z 等于每日产品售价减去原料成本与加工成本, 即目标函数为

$$z = 8x_1 + 24x_2 + 12x_3 + 55x_4 - 3x_2 - 3x_4 - x_0 - 5x_0$$

而约束条件为加工过程中物流的平衡约束及原料的供应限制:

$$0.5x_0 = x_1 + \frac{x_2}{0.5}, \quad 0.3x_0 = x_3 + \frac{x_4}{0.25}, \quad x_0 \leq 4000$$

故,此问题的数学模型为

$$\begin{aligned} \max z &= 8x_1 + 24x_2 + 12x_3 + 55x_4 - 3x_2 - 3x_4 - 6x_0 \\ \text{s. t. } &0.5x_0 - x_1 - 2x_2 = 0 \\ &0.3x_0 - x_3 - 4x_4 = 0 \\ &x_0 \leq 4000 \\ &x_i \geq 0 \quad (j = 0, 1, \dots, 4) \end{aligned}$$

5.4 多周期动态生产计划问题

线性规划还可以用来描述多周期的动态生产计划问题. 企业管理者经常会面临这样的问题:各个时期对产品的需求数量不同,但企业管理者希望尽可能地均衡生产,且可采用加班生产及库存进行调节,使得在满足各个时期需求的条件下生产总成本最低. 下面是一个简单的多周期生产计划的例子.

例 5-4 考虑安排某一产品在以后四周的周生产计划. 每件产品的生产成本在第一周与第二周是 10 元,后两周为 15 元. 各周需求量分别是 600 件、800 件、1000 件和 800 件. 工厂每周最多能生产 700 件. 在第二周和第三周可以加班生产. 加班后每周增产 200 件,但生产成本每件增加 5 元,过剩产品的单位存贮费用是每周 3 元. 问如何安排生产计划使总成本为最小.

解 设 x_{i1} 为第 i 周正常生产的件数, x_{i2} 为第 i 周加班生产的件数, x_{i3} 为第 i 周初的库存数, $i = 1, 2, 3, 4$, 其中第一周初及第四周末的库存数为零. 若记 d_i 为第 i 周的需求量, c_i 为每周正常生产每件产品的成本, α 和 β 是加班生产、库存(每周)每件产品的成本,则本例题的数学模型为

$$\begin{aligned} \min z &= \sum_{i=1}^4 (c_i x_{i1} + \alpha x_{i2} + \beta x_{i3}) \\ \text{s. t. } &x_{i1} + x_{i2} + x_{i3} - x_{(i+1),3} = d_i \quad (i = 1, 2, 3, 4) \\ &x_{12} = x_{42} = x_{53} = 0 \\ &x_{i1}, x_{i2}, x_{i3} \geq 0 \quad (i = 1, 2, 3, 4) \end{aligned}$$

代入具体数据,本例题的数学模型如下:

$$\begin{aligned} \min z &= 10x_{11} + (10x_{21} + 5x_{22} + 3x_{23}) + (15x_{31} + 5x_{32} + 3x_{33}) + (15x_{41} + 3x_{43}) \\ \text{s. t. } &x_{11} + x_{12} - x_{23} = 600 \\ &x_{21} + x_{22} + x_{23} - x_{33} = 800 \\ &x_{31} + x_{32} + x_{33} - x_{43} = 1000 \\ &x_{41} + x_{42} + x_{43} = 800 \\ &x_{i1} \leq 700 \quad (i = 1, 2, 3, 4) \\ &x_{22} \leq 200 \\ &x_{32} \leq 200 \\ &x_{i1}, x_{i2}, x_{i3} \geq 0 \quad (i = 1, 2, 3, 4) \end{aligned}$$

5.5 有配套约束的资源优化问题

此类线性规划问题不仅在一定资金(或其他资源)限制条件下,而且所研究的对象有配套要求.属于这类问题的有购买产品问题、产品加工的设备分配问题等.

例5-5 某公司计划用资金60万元来购买A,B,C三种运输汽车.已知A种汽车每辆1万元,每班需一名司机,可完成2100t·km;B种汽车每辆2万元,每班需两名司机,可完成3600t·km;C种汽车每辆2.3万元,每班需两名司机,可完成3780t·km.每辆汽车每天最多安排三班,每个司机每天最多安排一班,购买汽车的数量不超过30辆,司机不超过145人.问每种汽车应购买多少辆,可使该公司今后每天可完成的t·km数最大?

解 设购买的A种汽车中,每天只安排一班的为 x_{11} 辆,每天安排两班的为 x_{12} 辆,每天安排三班的为 x_{13} 辆;同样设购买B种汽车中,分别安排三种班次的车辆数为 x_{21},x_{22},x_{23} ;同样设购买C种汽车中,分别安排三种班次的车辆数为 x_{31},x_{32},x_{33} ,因此有

$$\begin{aligned} \max z &= 2.1x_{11} + 2.4x_{12} + 6.3x_{13} + 3.6x_{21} + 7.2x_{22} + 10.8x_{23} \\ &\quad + 3.78x_{31} + 7.56x_{32} + 11.34x_{33} \\ \text{s. t. } &1.0 \sum_{i=1}^3 x_{1i} + 2.0 \sum_{i=1}^3 x_{2i} + 2.3 \sum_{i=1}^3 x_{3i} \leq 60 \\ &\sum_{i=1}^3 x_{1i} + \sum_{i=1}^3 x_{2i} + \sum_{i=1}^3 x_{3i} \leq 30 \\ &x_{11} + 2x_{12} + 3x_{13} + 2x_{21} + 4x_{22} + 6x_{23} + 2x_{31} + 4x_{32} + 6x_{33} \leq 145 \\ &x_{ij} \geq 0 \text{ 且为整数 } (i,j=1,2,3) \end{aligned}$$

例5-6 产品加工的设备分配问题:

某工厂生产三种产品I、II、III,每种产品均要经过A,B两道工序加工.该厂现有两种规格的设备 A_1,A_2 均能完成A道工序;有三种规格的设备 B_1,B_2,B_3 能完成B道工序.产品I可在A,B的任一种规格的设备上加工;产品II可在 A_1,A_2 的任一种设备上完成A工序,但只能在 B_1 上完成B工序;产品III只能在 A_2 与 B_2 设备上加工.已知在各种设备上加工的单件工时、原料单价、产品销售单价、各种设备的有效台时,以及满负荷操作时的设备费用,见表5-4.

表5-4

设备	产品的单件工时			设备的有效台时	满负荷时的设备费用/元
	I	II	III		
A_1	5	10		6000	300
A_2	7	9	12	10000	321
B_1	6	8		4000	250
B_2	4		11	7000	783
B_3	7			4000	200
原料单价/(元/件)	0.25	0.35	0.50		
销售单价/(元/件)	1.25	2.00	2.80		

解 本例题比例 5-4 稍复杂些,产品与设备的配套不仅呈多样化,而且有可选择性.

现在将产品与设备的配套方案全部列出,以它们作为决策变量,这样建立数学模型较为方便. 产品 I 的加工方案有 6 种:分别采用 A_1 与 B_1 , A_1 与 B_2 , A_1 与 B_3 , A_2 与 B_1 , A_2 与 B_2 , A_2 与 B_3 的设备组合,记 $x_{11}, x_{12}, x_{13}, x_{14}, x_{15}, x_{16}$ 分别表示这 6 种方案加工产品 I 的件数;产品 II 的加工方案为: A_1 与 B_1 , A_2 与 B_1 的设备组合,记 x_{21}, x_{22} 分别表示用这两个方案加工产品 II 的件数;产品 III 的加工方案只有一种,为 A_2 与 B_2 的设备组合,记 x_{31} 表示设备 A_2 与 B_2 加工产品 III 的件数.

该厂一个加工周期的利润为

$$\sum_{i=1}^3 [(\text{销售单价} - \text{原料单价}) \times \text{该产品的件数}] - \sum_{j=1}^5 (\text{每台时的设备费用} \times \text{该设备实际使用的总台时})$$

故目标函数为

$$\begin{aligned} z = & (1.25 - 0.25) \sum_{j=1}^6 x_{1j} + (2.00 - 0.35)(x_{21} + x_{22}) + (2.80 - 0.50)x_{31} \\ & - \frac{300}{6000} [5(x_{11} + x_{12} + x_{13}) + 10x_{21}] - \frac{321}{10000} [7(x_{14} + x_{15} + x_{16}) + 9x_{22} + 12x_{31}] \\ & - \frac{250}{4000} [6(x_{11} + x_{14}) + 8(x_{21} + x_{22})] \\ & - \frac{783}{7000} [4(x_{12} + x_{15}) + 11x_{31}] - \frac{200}{4000} [7(x_{13} + x_{16})] \end{aligned}$$

因此,该问题的数学模型为

$$\begin{aligned} \max z = & 0.375x_{11} + 0.3024x_{12} + 0.40x_{13} + 0.4003x_{14} + 0.3277x_{15} + 0.4523x_{16} \\ & + 0.65x_{21} + 0.8611x_{22} + 0.6839x_{31} \\ \text{s. t. } & 5(x_{11} + x_{12} + x_{13}) + 10x_{21} \leq 6000 \\ & 7(x_{14} + x_{15} + x_{16}) + 9x_{22} + 12x_{31} \leq 10000 \\ & 6(x_{11} + x_{14}) + 8(x_{21} + x_{22}) \leq 4000 \\ & 4(x_{12} + x_{15}) + 11x_{31} \leq 7000 \\ & 7(x_{13} + x_{16}) \leq 4000 \\ & \text{所有变量} \geq 0, \text{且为整数} \end{aligned}$$

5.6 投资问题

最基本而又常见的投资问题有两类:一类是对投资项目的选择,而这些投资项目是期初一次性投资;另一类是动态连续投资问题,即每个项目可能需连续几年进行投资,这期间有投资也可能有收益.

5.6.1 投资项目组合选择

投资者经常会遇到投资项目的组合选择问题,即通过考虑收益率、风险、增长潜力等因素,并进行综合权衡,以求得一个最佳投资方案.

例 5-7 某投资者有 50 万元可用于长期投资,可供选择的投资项目包括购买国库券、购买公司债券、投资房地产、购买股票、银行短期或长期储蓄,各种投资方式的投资期限、年收益率、风险系数、增长潜力的具体参数见表 5-5. 若投资者希望投资组合的平均年限不超过 5 年,平均的期望收益率不低于 13%,风险系数不超过 4,收益的增长潜力不低于 10%. 问在满足上述要求的前提下,投资者该如何选择投资组合使平均年收益率最高?

表 5-5 各种投资项目的参数表

序号	投资方式	投资期限/年	年收益率/%	风险系数	增长潜力/%
1	国库券	3	11	1	0
2	公司债券	10	15	3	15
3	房地产	6	25	8	30
4	股票	2	20	6	20
5	短期储蓄	1	10	1	5
6	长期储蓄	5	12	2	10

解 设 x_i 为第 i 种投资方式在总投资中所占比例,则平均年收益率为

$$z = 11x_1 + 15x_2 + 25x_3 + 20x_4 + 10x_5 + 12x_6$$

而平均年限的约束、平均的期望收益率的限制、风险系数的限制以及收益的增长潜力的约束可表达为

$$3x_1 + 10x_2 + 6x_3 + 2x_4 + x_5 + 5x_6 \leq 5$$

$$11x_1 + 15x_2 + 25x_3 + 20x_4 + 10x_5 + 12x_6 \geq 13$$

$$x_1 + 3x_2 + 8x_3 + 6x_4 + x_5 + 2x_6 \leq 4$$

$$15x_2 + 30x_3 + 20x_4 + 5x_5 + 10x_6 \geq 10$$

此外, x_i 还应满足非负约束和归一化约束. 这样,本问题的数学模型为

$$\max z = 11x_1 + 15x_2 + 25x_3 + 20x_4 + 10x_5 + 12x_6$$

$$\text{s. t. } 3x_1 + 10x_2 + 6x_3 + 2x_4 + x_5 + 5x_6 \leq 5$$

$$11x_1 + 15x_2 + 25x_3 + 20x_4 + 10x_5 + 12x_6 \geq 13$$

$$x_1 + 3x_2 + 8x_3 + 6x_4 + x_5 + 2x_6 \leq 4$$

$$15x_2 + 30x_3 + 20x_4 + 5x_5 + 10x_6 \geq 10$$

$$x_1 + x_2 + x_3 + x_4 + x_5 + x_6 = 1$$

$$x_i \geq 0 \quad (i = 1, 2, \dots, 6)$$

5.6.2 连续投资问题

在项目的投资期内,需要对项目进行连续投资,同时也可获得收益,因此,在投资期内可能需要不断进行选择. 这本身是一个与时间有关的连续投资问题(动态问题),现在利用线性

规划化为静态来处理.

例 5-8 某投资者拥有资金 10 万元,考虑在今后 5 年内给下列 4 个项目进行投资,已知:

项目 A:从第 1 年到第 4 年每年年初需要投资,并于此年末回收本利 115%;

项目 B:第 3 年初需要投资,到第 5 年末能回收本利共 125%,但规定投资额不超过 4 万元;

项目 C:第 2 年初需要投资,到第 5 年末能回收本利 140%,但规定投资额不超过 3 万元;

项目 D:5 年内每年年初可购买公债,于当年末归还,并加利息 6%.

问该投资者应如何安排他的资金,确定给这些项目每年的投资额,使到第 5 年末能拥有的资金本利总额为最大?

解 记 $x_{i1}, x_{i2}, x_{i3}, x_{i4}$ ($i = 1, 2, \dots, 5$) 分别表示 i 年年初给项目 A, B, C, D 的投资额,则根据项目 A, B, C, D 的不同情况,在第 5 年末能回收的本利分别为 $1.15x_{41}, 1.25x_{32}, 1.40x_{23}$ 及 $1.06x_{54}$. 因此,到第 5 年末能拥有的资金本利总额为

$$z = 1.15x_{41} + 1.25x_{32} + 1.40x_{23} + 1.06x_{54}$$

考虑到投资者每年年初的投资额应等于他年初所拥有的资金,故决策变量 $x_{i1}, x_{i2}, x_{i3}, x_{i4}$ ($i = 1, 2, \dots, 5$) 应受到如下几个约束限制:

第一年年初该投资者拥有 10 万元资金,故有

$$x_{11} + x_{14} = 100\,000$$

第二年年初该投资者拥有 $(1 + 6\%)x_{14}$ 万元资金,故有

$$x_{21} + x_{23} + x_{24} = 1.06x_{14}$$

第三年年初该投资者拥有资金为从 D 项目收回的本金 $1.06x_{24}$ 及从项目 A 中第一年投资收回的本金 $1.15x_{11}$, 故有

$$x_{31} + x_{32} + x_{34} = 1.06x_{24} + 1.15x_{11}$$

同理,第四年、第五年有约束为

$$x_{41} + x_{44} = 1.06x_{34} + 1.15x_{21}$$

$$x_{54} = 1.06x_{44} + 1.15x_{31}$$

故本例题的数学模型经化简后为

$$\max z = 1.15x_{41} + 1.25x_{32} + 1.40x_{23} + 1.06x_{54}$$

$$\text{s. t. } x_{11} + x_{14} = 100\,000$$

$$x_{21} + x_{23} + x_{24} = 1.06x_{14}$$

$$x_{31} + x_{32} + x_{34} = 1.06x_{24} + 1.15x_{11}$$

$$x_{41} + x_{44} = 1.06x_{34} + 1.15x_{21}$$

$$x_{54} = 1.06x_{44} + 1.15x_{31}$$

$$x_{i1}, x_{i2}, x_{i3}, x_{i4} \geq 0 \quad (i = 1, 2, \dots, 5)$$

5.7 运输问题及其扩展

运输问题是实际应用中经常遇到的一类线性规划问题. 由于其本身的特定结构形式, 对它有较单纯形法更为简单的求解方法——表上作业法. 但考虑到该方法实质是单纯形法, 这

里不再作介绍,而是把重点放在该类问题的数学模型建立上.

5.7.1 产销平衡的运输问题

有 m 个生产地(发点) $A_1, A_2, \dots, A_m$ 可供应某种物资,其生产量(或称为供给量、发运量)分别为 $a_1, a_2, \dots, a_m$; 另有 n 个销售点(收点) $B_1, B_2, \dots, B_n$, 其销售量(或称为需求量、接受量)分别为 $b_1, b_2, \dots, b_n$. 已知从 A_i 到 B_j 运输单位物资的运价为 c_{ij} , 且 m 个产地的总产量 $\sum_{i=1}^m a_i$ 与 n 个销地的总销量 $\sum_{j=1}^n b_j$ 相等. 试求在产销平衡条件下总运费最小的调运方案.

下面来建立此问题的数学模型. 设从 A_i 到 B_j 的物资运输量为 x_{ij} , 则总运费

$$z = \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij}$$

另外,考虑到第 i 个发点 A_i ($i=1, 2, \dots, m$) 发往 n 个收点的总量等于 A_i 的生产量(供给量), 而第 j 个收点 B_j ($j=1, 2, \dots, n$) 收到 m 个发点的总量等于 B_j 的需求量, 故有如下约束条件:

$$\begin{aligned} \sum_{j=1}^n x_{ij} &= a_i \quad (i=1, 2, \dots, m) \\ \sum_{i=1}^m x_{ij} &= b_j \quad (j=1, 2, \dots, n) \end{aligned}$$

这样,此问题的数学模型就为

$$\begin{aligned} \min \quad & \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} \\ \text{s. t.} \quad & \sum_{j=1}^n x_{ij} = a_i \quad (i=1, 2, \dots, m) \\ & \sum_{i=1}^m x_{ij} = b_j \quad (j=1, 2, \dots, n) \\ & x_{ij} \geq 0 \quad (i=1, 2, \dots, m; j=1, 2, \dots, n) \end{aligned}$$

该模型是线性规划模型,它有 $m \times n$ 个变量, $m+n-1$ 个独立约束方程. 若记

$$\mathbf{x} = (x_{11}, x_{12}, \dots, x_{1n}, x_{21}, x_{22}, \dots, x_{2n}, \dots, x_{m1}, x_{m2}, \dots, x_{mn})^T$$

$$\mathbf{c} = (c_{11}, c_{12}, \dots, c_{1n}, c_{21}, c_{22}, \dots, c_{2n}, \dots, c_{m1}, c_{m2}, \dots, c_{mn})^T$$

$$\mathbf{b} = (a_1, a_2, \dots, a_m, b_1, b_2, \dots, b_n)^T$$

$$\mathbf{A} = [A_{11}, A_{12}, \dots, A_{1n}, A_{21}, A_{22}, \dots, A_{2n}, \dots, A_{m1}, A_{m2}, \dots, A_{mn}]$$

其中 $A_{ij} = \mathbf{e}_i + \mathbf{e}_{m+j}$ ($i=1, 2, \dots, m; j=1, 2, \dots, n$), $\mathbf{e}_i$ 为第 i 个分量为 1 其余分量为 0 的 $m+n$ 维单位向量; $\mathbf{e}_{m+j}$ 为第 $m+j$ 个分量为 1、其余分量为 0 的 $m+n$ 维单位向量, 则上述模型用矩阵形式表示为

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} \\ \text{s. t.} \quad & \mathbf{A} \mathbf{x} = \mathbf{b}, \quad \mathbf{x} \geq 0 \end{aligned}$$

其中

$$A = \begin{matrix} & x_{11} & x_{12} & \cdots & x_{1n} & x_{21} & x_{22} & \cdots & x_{2n} & \cdots & x_{m1} & x_{m2} & \cdots & x_{mn} \\ \begin{bmatrix} 1 & 1 & \cdots & 1 & & & & & & & & & & \\ & & & & 1 & 1 & \cdots & 1 & & & & & & \\ & & & & & & & & \ddots & 1 & 1 & \cdots & 1 \\ 1 & & & & 1 & & & & \cdots & 1 & & & & \\ & 1 & & & & 1 & & & & & 1 & & & \\ & & \ddots & & & & \ddots & & & & & \ddots & & \\ & & & 1 & & & & 1 & & & & & 1 & \\ & & & & & & & & & & & & & 1 \end{bmatrix} \end{matrix}$$

是一个 $(m+n) \times mn$ 矩阵. 此矩阵中的元素均为 0 或 1 (其中零元素未写), 每一列中正好有两个非零元素. 这意味着每个变量在前 m 个等式约束中出现一次, 在后 n 个等式约束中也出现一次.

5.7.2 产销不平衡的运输问题

当产量大于销量时, 即有 $\sum_{i=1}^m a_i > \sum_{j=1}^n b_j$, 运输问题的数学模型为

$$\begin{aligned} \min & \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} \\ \text{s. t. } & \sum_{j=1}^n x_{ij} \leq a_i \quad (i = 1, 2, \dots, m) \\ & \sum_{i=1}^m x_{ij} = b_j \quad (j = 1, 2, \dots, n) \\ & x_{ij} \geq 0 \quad (i = 1, 2, \dots, m; j = 1, 2, \dots, n) \end{aligned} \quad (5-1)$$

为了利用产销平衡的运输模型及其解法, 就要将 5-1 中第一组约束不等式化作等式, 即要考虑一个“需求”量为 $b_{n+1} = \sum_{i=1}^m a_i - \sum_{j=1}^n b_j$ 的假想销地 B_{n+1} , 用于贮存多余物资. 设从 A_i “运往” B_{n+1} 的运输量为 $x_{i,n+1}$, 则有 $\sum_{i=1}^m x_{i,n+1} = b_{n+1}$, 故 (5-1) 中不等式约束就成为

$$\sum_{j=1}^n x_{ij} + x_{i,n+1} = \sum_{j=1}^{n+1} x_{ij} = a_i \quad (i = 1, 2, \dots, m)$$

而需求约束要增加一个方程

$$\sum_{i=1}^m x_{i,n+1} = b_{n+1}$$

现来考虑 B_{n+1} 的运输单价. 因为 B_{n+1} 是假想的销地, 实际上从第 i 个发点 A_i 供给前 n 个收点 B_j ($j=1, 2, \dots, n$) 后仍没有发完的话, 多余的量就地贮存, 因此实际上 $c_{i,n+1} = 0$ ($i=1, 2, \dots, m$).

综上所述, 当产大于销时, 其数学模型 (5-1) 可化为

$$\begin{aligned}
\min z &= \sum_{i=1}^m \sum_{j=1}^{n+1} c_{ij} x_{ij} = \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} \\
\text{s. t. } &\sum_{j=1}^{n+1} x_{ij} = a_i \quad (i = 1, 2, \dots, m) \\
&\sum_{i=1}^m x_{ij} = b_j \quad (j = 1, 2, \dots, n, n+1) \\
&x_{ij} \geq 0 \quad (i = 1, 2, \dots, m; j = 1, 2, \dots, n, n+1)
\end{aligned} \tag{5-2}$$

因为在此模型中, $\sum_{i=1}^m a_i = b_{n+1} + \sum_{j=1}^n b_j = \sum_{j=1}^{n+1} b_j$, 故(5-2)是一个产销平衡的运输模型.

类似地, 当销量大于产量时, 可以在产销平衡表中增加一个产量为 $a_{m+1} = \sum_{j=1}^n b_j - \sum_{i=1}^m a_i$ 的假想产地 A_{m+1} , 并令它到各销地的运输单价 $c_{m+1,j} = 0$ ($j = 1, \dots, n$), 则同样可得到一个产销平衡的运输问题数学模型

$$\begin{aligned}
\min z &= \sum_{i=1}^{m+1} \sum_{j=1}^n c_{ij} x_{ij} = \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} \\
\text{s. t. } &\sum_{j=1}^n x_{ij} = a_i \quad (i = 1, 2, \dots, m, m+1) \\
&\sum_{i=1}^{m+1} x_{ij} = b_j \quad (j = 1, 2, \dots, n) \\
&x_{ij} \geq 0 \quad (i = 1, 2, \dots, m+1; j = 1, 2, \dots, n)
\end{aligned} \tag{5-3}$$

5.7.3 有转运的运输问题

在上面讨论的运输问题中, 假定物品由产地直接运送到销售地, 而不经中间转运. 但是, 常常会遇到这种情形: 需先将物品由产地运到某个中间转运站(可能是另外的产地、销地或中间转运仓库), 然后再转运到销售地. 有时, 经转运比直接运到目的地更为经济, 因此, 在很多情况下, 在决定运输方案时有必要把转运也考虑进去. 当然, 考虑转运将使运输问题变得更为复杂.

假定 m 个产地 $A_1, A_2, \dots, A_m$ 和 n 个销地 $B_1, B_2, \dots, B_n$ 都可以作为中间转运站使用, 从而发送物资的地点和接收物资的地点都有 $m+n$ 个. 这样一来, 我们就得到一个扩大了运输问题. 为了建立模型, 令

- a_i 为第 i 个产地的产量(净供应量);
- b_j 为第 j 个销地的销量(净需要量);
- x_{ij} 为由第 i 个发运地运到第 j 个接收地的物资数量;
- c_{ij} 为由第 i 个发运地到第 j 个接收地的单位运价;
- t_i 为第 i 个地点转运物品的数量;
- c_i 为第 i 个地点转运单位物品的费用.

现将产地和销地统一编号, 并把产地排在前面, 销地排在后面, 则有

$$a_{m+1} = a_{m+2} = \dots = a_{m+n} = 0, \quad b_1 = b_2 = \dots = b_m = 0$$

假定为平衡运输问题, 即有

$$\sum_{i=1}^m a_i = \sum_{j=m+1}^{m+n} b_j = Q$$

根据前面对平衡问题的讨论, 可得扩大的运输问题的数学模型如下

$$\begin{aligned} \min z = & \sum_{i=1}^{m+n} \sum_{j=1}^{m+n} c_{ij} x_{ij} + \sum_{i=1}^{m+n} c_i t_i \\ \text{s. t. } & x_{i1} + x_{i2} + \cdots + x_{i,i-1} + x_{i,i+1} + \cdots + x_{i,m+n} = a_i + t_i \quad (i = 1, 2, \cdots, m) \\ & x_{i1} + x_{i2} + \cdots + x_{i,i-1} + x_{i,i+1} + \cdots + x_{i,m+n} = t_i \quad (i = m+1, m+2, \cdots, m+n) \\ & x_{1j} + x_{2j} + \cdots + x_{j-1,j} + x_{j+1,j} + \cdots + x_{m+n,j} = t_j \quad (j = 1, 2, \cdots, m) \\ & x_{1j} + x_{2j} + \cdots + x_{j-1,j} + x_{j+1,j} + \cdots + x_{m+n,j} = b_j + t_j \quad (j = m+1, \cdots, m+n) \\ & x_{ij} \geq 0 \quad (i, j = 1, 2, \cdots, m+n) \end{aligned} \quad (5-4)$$

在上述模型中, 第一组等式约束指的是: 由第 i 个产地发送到各个地方的物资数量之和等于该产地的产量加上经它转运的物品数量; 第二组等式约束的意义同上, 但由于它们原为销地, 不生产物品, 故约束条件的右侧常数仅为该地的转运量; 第三和第四组等式约束的意义为由各地运到第 j 地的物资数量之和, 前者等于其转运量, 后者等于净需要量加上转运量.

将式(5-4)中的各约束等式右侧的 t_i 或 t_j 移到等号左侧, 然后在各式等号两端分别加上 Q , 并令 $x_{ii} = Q - t_i$ 或 $x_{jj} = Q - t_j$, 则可把模型(5-4)写为

$$\begin{aligned} \min z = & \sum_{i=1}^{m+n} \sum_{j=1}^{m+n} c_{ij} x_{ij} + \sum_{i=1}^{m+n} c_i Q \\ \text{s. t. } & \sum_{j=1}^{m+n} x_{ij} = Q + a_i \quad (i = 1, 2, \cdots, m) \\ & \sum_{j=1}^{m+n} x_{ij} = Q \quad (i = m+1, m+2, \cdots, m+n) \\ & \sum_{i=1}^{m+n} x_{ij} = Q \quad (j = 1, 2, \cdots, m) \\ & \sum_{i=1}^{m+n} x_{ij} = Q + b_j \quad (j = m+1, \cdots, m+n) \\ & x_{ij} \geq 0 \quad (i, j = 1, 2, \cdots, m+n) \end{aligned} \quad (5-5)$$

要特别注意, 在模型(5-5)中, 对所有 $i=j$, $c_{ij} = -c_i$.

习 题

5-1 某项生产需要成套钢梁. 每套由 7 根 2 m 长及 2 根 7 m 长的钢梁组成. 现有 15 m 长的钢梁 150 根, 问如何下料才能使料头最小(只建立数学模型, 不必求解)?

5-2 某动物饲养场, 每天每头动物至少需 700 g 蛋白质、30 g 矿物质、100 mg 维生素, 现有 5 种饲料可供选用, 各种饲料营养成分含量及单价如表 5-6 所示:

表 5-6

饲 料	蛋白质/g	矿物质/g	维生素/mg	价格/(元·kg ⁻¹)
1	3	1	0.5	0.2
2	2	0.5	1.0	0.7
3	1	0.2	0.2	0.4
4	6	2	2	0.3
5	18	0.5	0.8	0.8

要求确定既满足动物生长的营养需要,又使费用最省的饲料选用方案(建立数学模型,不必求解).

5-3 市场对 I、II 两种产品的需求量为:产品 I 在 1~4 月份每月需 10 000 件,5~9 月份每月 30 000 件,10~12 月份每月 100 000 件;产品 II 在 3~9 月份每月需 15 000 件,其他每月 50 000 件.某厂生产这两种产品成本为:产品 I 在 1~5 月份生产每件 5 元,6~12 月份生产每件 4.50 元;产品 II 在 1~5 月份生产每件 8 元,6~12 月份生产每件 7 元.该厂每月生产两种产品能力总和应不超过 120 000 件.产品 I 的体积为每件 0.2 m³,产品 II 的体积为每件 0.4 m³,而该厂仓库容积为 15 000 m³,要求:(1)说明上述问题无可行解;(2)若该厂仓库不足时,可从外厂租借.若占用本厂每月每立方米库容需 1 元,而租用外厂上述费用增加为 1.5 元,试问在满足市场需求的情况下,该厂应如何安排生产,使总的生产加库存费用为最少(建立数学模型,不必求解).

5-4 某厂 I、II、III 三种产品下一年各季度的合同预定数如表 5-7 所示.该三种产品 1 季度初无库存,要求在 4 季度末各库存 150 件.已知该厂每季度生产工时为 15 000 小时,生产 I、II、III 产品每件需工时 2、4、3 小时.因更换工艺装备,产品 I 在 2 季度无法生产.规定当产品不能按期交货时,产品 I、II 每件每迟交一个季度赔偿 20 元,产品 III 赔偿 10 元;又生产出来产品不在本季度交货时,每件每季度的库存费用为 5 元.问该厂应如何安排生产,使总的赔偿加库存的费用为最小(建立数学模型,不必求解).

表 5-7

产 品	季 度			
	1	2	3	4
I	1500	1000	2000	1200
II	1500	1500	1200	1500
III	1000	2000	1500	2500

5-5 某工厂的机械加工车间需要加工 1 号和 2 号两种零件.这两种零件可以在三种不同类型的机床上进行加工.机床台数及生产效率由表 5-8 给出,要求 1 号和 2 号零件在保持 1:1 的配套比例条件下,合理安排机床在五日内加工任务,使成套产品的数量达到最大(建立数学模型,不必求解).

表 5-8

机床类型 i	机床数/台	日产 1 号零件/(千件/台)	日产 2 号零件/(千件/台)
1	30	15	20
2	30	20	30
3	10	30	55

5-6 某工厂现有 A、B、C 三个等级的原油,提炼成甲、乙、丙三类不同的汽油产品,有关数据如表 5-9 所示. 问生产各类产品应如何分配各个等级的原油可使工厂获利最大(建立数学模型,不必求解).

表 5-9

产品(j) 原油(i)	甲(1)	乙(2)	丙(3)	资源限量 /kg	每公斤成本/元
A(1)	$\geq 60\%$	$\geq 15\%$		2000	7.00
B(2)				2500	6.00
C(3)	$\leq 20\%$	$\leq 60\%$	$\leq 70\%$	2200	4.00
售价/(元/公斤)	7.50	5.90	5.20		

5-7 某厂生产 I、II 两种食品,现有 50 名熟练工人,已知一名熟练工人每小时可生产 10 kg 食品 I 或 6 kg 食品 II. 据合同预定,该两种食品每周的需求量将急剧上升,见表 5-10. 为此该厂决定到第 8 周末培训出 50 名新工人,两班生产. 已知一名工人每周工作 40 小时,一名熟练工人用两周时间可培训出不多于 3 名的新工人(培训期间熟练工人和培训人员均不参加生产). 熟练工人每周工资 360 元,新工人培训期间工资每周 120 元,培训结束参加工作后每周工资 240 元,生产效率同熟练工人. 在培训的过渡期间,很多熟练工人愿意加班工作,工厂决定安排部分工人每周工作 60 小时,工资每周 540 元. 又若预定的食品不能按期交货,每推迟交货一周的赔偿食品 I 为 0.50 元,食品 II 为 0.60 元. 在上述各种条件下,工厂应如何作出全面安排,使各项费用的总和为最小(建立数学模型,不必求解).

表 5-10

周次 食品	1	2	3	4	5	6	7	8
I	10	10	12	12	16	16	20	20
II	6	7.2	8.4	10.8	10.8	10.8	12	12

第二篇 非线性规划

第6章 非线性规划基本概念与基本原理

6.1 非线性规划的数学模型和基本概念

6.1.1 非线性规划问题举例

非线性规划问题也是一类优化问题,在这类问题中,目标函数或约束函数至少有一个不是决策变量的线性函数.显然,非线性规划问题相对于线性规划问题而言更具一般性,在工程实际中也更普遍.

例6-1 某公司专门生产储藏用的容器,订货合同要求该公司制造一种敞口的长方体容器,容积恰好为 12 m^3 . 该种容器的底必须作正方形,容器总重量不超过 68 kg ,已知用作容器四壁的材料为每平方米 10 元 ,重 3 kg ;用作容器底的材料每平方米 20 元 ,重 2 kg . 试问制造该容器所需的最小费用是多少? 列出数学模型.

解 设该容器的底边长和高分别为 $x_1 \text{ m}$ 和 $x_2 \text{ m}$,则有

目标函数: $\min f(x) = 40x_1x_2 + 20x_1^2$

约束条件: $x_1^2x_2 = 12$

$$12x_1x_2 + 2x_1^2 \leq 68$$

$$x_1 \geq 0, \quad x_2 \geq 0$$

记为

$$\min f(x) = 40x_1x_2 + 20x_1^2$$

$$\text{s. t. } x_1^2x_2 = 12$$

$$12x_1x_2 + 2x_1^2 \leq 68$$

$$x_1 \geq 0$$

$$x_2 \geq 0$$

例6-2(定位问题) 假设要选定一个供应中心的位置,由这个中心向城市中位置固定的 m 个用户提供服务中心供应的商品,可以是电、水、牛奶和其他货物,供应中心的设置定位准则是使从中心到用户的“距离”最小.例如,可以是使中心到各用户的最大距离为最小.假定在这个城市里货物必须沿互相垂直的路线(街道)供应,那么合适的距离函数就是

矩形距离. 列出其数学模型.

解 设 (x_1, x_2) 表示供应中心的待定位置(坐标), 而 (a_i, b_i) 是第 i 个用户的所在位置, 则问题的目标函数是

$$\min_{x_1, x_2} \left\{ \max_{1 \leq i \leq m} [|a_i - x_1| + |b_i - x_2|] \right\}$$

这个式子意味着首先对 (x_1, x_2) 的每个可能值求出指标 I , 使方括号中的矩形距离最大; 其次在依赖于 (x_1, x_2) 的所有最大距离中求出最小的. 如果每一位置 (x_1, x_2) 都可以接受, 那么问题是无约束的; 如果还有其他限制, 例如供应中心到某几个用户的距离必须在某个范围内, 则问题是有约束的.

例 6-3 设要设计一个如图 6-1 所示的半球形和圆柱形相连接的构件, 要求在构件体积一定的条件下确定构件的尺寸, 使其表面积最小.

解 构件的大小取决于其中圆柱体的底半径和高. 设该圆柱体的底半径为 x_1 , 高为 x_2 , 由于构件的表面由半球顶面、侧面和底面构成, 因此其表面积为

$$S = 2\pi x_1^2 + 2\pi x_1 x_2 + \pi x_1^2$$

构件的体积为半球体和圆柱体之和, 所以若要使构件的体积为定值 V_0 , 应该满足条件

$$\frac{2}{3}\pi x_1^3 + \pi x_1^2 x_2 = V_0$$

又构件的底半径和圆柱体之高显然非负, 故还要求

$$x_1 \geq 0, \quad x_2 \geq 0$$

因此本例的数学模型为

$$\min S = 2\pi x_1^2 + 2\pi x_1 x_2 + \pi x_1^2$$

$$\text{s. t. } \frac{2}{3}\pi x_1^3 + \pi x_1^2 x_2 = V_0$$

$$x_1 \geq 0, x_2 \geq 0$$




图 6-1 半球形和圆柱形相连接的构件

6.1.2 非线性规划问题的一般数学模型

一般非线性规划的数学模型可表示为

$$\min f(\mathbf{x})$$

$$\text{s. t. } h_i(\mathbf{x}) = 0 \quad (i = 1, 2, \dots, m) \quad (6-1)$$

$$g_j(\mathbf{x}) \geq 0 \quad (j = 1, 2, \dots, l)$$

式中, $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$, 是 n 维向量, f, h_i ($i = 1, 2, \dots, m$); g_j ($j = 1, 2, \dots, l$) 都是 $\mathbb{R}^n \rightarrow \mathbb{R}$ 的映射(即自变量是 n 维向量, 因变量是实数的函数关系).

显然, 任何非线性规划问题的数学模型都可以化为一般形式(6-1). 与线性规划类似, 把满足约束条件的解称为可行解, 全体可行解的集合称为可行域. 若记

$$\mathcal{R} = \{ \mathbf{x} \mid h_i(\mathbf{x}) = 0; i = 1, 2, \dots, m; g_j(\mathbf{x}) \geq 0; j = 1, 2, \dots, l \} \quad (6-2)$$

称 $\mathcal{R}$ 为非线性规划问题的可行域. 因此模型(6-1)可简记为

$$\min_{x \in \mathcal{H}} f(x) \quad (6-3)$$

当一个非线性规划问题的自变量 x 没有任何约束,或者说可行域是整个 n 维向量空间, $\mathcal{H} = \mathbb{R}^n$, 则称这样的非线性规划问题为无约束问题

$$\min f(x) \quad \text{或} \quad \min_{x \in \mathbb{R}^n} f(x) \quad (6-4)$$

有约束问题(6-1)与无约束问题(6-4)是非线性规划问题的两大类问题,它们在求解思路和方法上有很大的不同.

从数学上来讲,在非线性规划(6-1)中引入不等式约束是一个进步.因为在微积分里也讨论过极值问题,在那里讨论的是无约束问题或只有等式约束的问题,如果一个极值问题包含等式约束,则利用 Lagrange 乘子法将等式约束极值问题化为无约束极值问题来求解,这些极值问题统称经典极值问题.而在极值问题中引入不等式约束,标志着现代数学规划理论的开始.不等式约束的引入使极值问题的处理变得复杂;但也使得部分经典极值处理不了的问题得到解决,从而扩大了极值问题的应用范围.

由于一个等式约束等价于两个不等式约束,如 $h(x) = 0$ 等价于 $h(x) \geq 0, -h(x) \leq 0$, 两个不等式同时成立,即任何等式约束都可以用两个不等式约束代替,因此非线性规划问题有时也可以写成以下形式

$$\begin{aligned} \min f(x) \\ \text{s. t. } g_j(x) \geq 0 \quad (j = 1, 2, \dots, l) \end{aligned} \quad (6-5)$$

有些教材将不等式约束统一写为“ ≤ 0 ”的形式,也只是形式上的不同而已,因为不等式两端同时乘以 -1 即可以化为“ ≥ 0 ”的不等式形式,注意两种写法在运用一些结论和定义时会有所不同.

与线性规划类似,对于只含有两个决策变量的非线性规划问题,也可以使用图解法求出可行域和目标函数的等值面,通过移动等值面求出目标函数的极小值,还可以获得直观的几何解释,并且可把这种几何解释通过思维上的抽象推广到 n 元问题中去,这对于理解有关理论与方法是有益的.

6.1.3 基本概念

6.1.3.1 局部极值与全局极值

定义 6-1 设 $x^* \in \mathbb{R}^n, \delta > 0$, 集合 $\{x | x \in \mathbb{R}^n, \text{且 } \|x - x^*\| < \delta\}$ 称为 x^* 的 δ 邻域,记为 $N(x^*, \delta)$, 其中 $\|x - x^*\|$ 表示 x 与 x^* 之间的距离(通常为欧几里德距离).

定义 6-2 设 $f(x)$ 为定义在 n 维欧氏空间 $\mathbb{R}^n$ 中的某一区域 S 上的 n 元实函数,其中 $x = (x_1, x_2, \dots, x_n)^T$. 对于 $x^* \in S$, 若存在某个 $\delta > 0$, 对任意的 $x \in N(x^*, \delta) \cap S$ 均有 $f(x) \geq f(x^*)$, 则称 x^* 为 $f(x)$ 在 S 上的局部极小点, $f(x^*)$ 为局部极小值. 若对于所有 $x \in N(x^*, \delta) \cap S$ 且 $x \neq x^*$ 都有 $f(x) > f(x^*)$, 则称 x^* 为 $f(x)$ 在 S 上的严格局部极小点, $f(x^*)$ 为严格局部极小值.

定义 6-3 设 $f(x)$ 为定义在 n 维欧氏空间 $\mathbb{R}^n$ 中的某一区域 S 上的 n 元实函数,其中 $x = (x_1, x_2, \dots, x_n)^T$. 对于 $x^* \in S$, 对任意的 $x \in S$ 均有 $f(x) \geq f(x^*)$, 则称 x^* 为 $f(x)$ 在 S 上的全局极小点, $f(x^*)$ 为全局极小值. 若对于所有 $x \in S$, 且 $x \neq x^*$ 都有 $f(x) > f(x^*)$, 则

称 $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 在 S 上的严格全局极小点, $f(\mathbf{x}^*)$ 为严格全局极小值.

如果将定义 6-2 和 6-3 中的不等式反向, 即可得到相应的极大点和极大值的定义. 本教材主要就极小点和极小值进行讨论, 而且主要研究局部极小. 对于极大化问题可通过恒等式 $\max f(\mathbf{x}) = -\min(-f(\mathbf{x}))$ 转化为极小化问题.

6.1.3.2 梯度

可微函数 $f(\mathbf{x})$ 的梯度, 记为 $\nabla f(\mathbf{x})$, 它是以 $f(\mathbf{x})$ 对 x_i ($i=1, 2, \dots, n$) 的偏导数为元素的 n 维向量 (本书规定为列向量), 于是有

$$\nabla f(\mathbf{x}) = \left(\frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right)^T \quad (6-6)$$

梯度又称为函数 $f(\mathbf{x})$ 关于向量 $\mathbf{x}$ 的一阶导数. 函数 $f(\mathbf{x})$ 在某一点 $\mathbf{x}^{(0)}$ 的梯度就是将 $\mathbf{x}^{(0)}$ 的各分量代入式 (6-6) 即可, 即

$$\nabla f(\mathbf{x}^{(0)}) = \left(\frac{\partial f(\mathbf{x}^{(0)})}{\partial x_1}, \frac{\partial f(\mathbf{x}^{(0)})}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x}^{(0)})}{\partial x_n} \right)^T \quad (6-7)$$

特别地, 一元函数的梯度就是一阶导数.

下面介绍梯度的两个重要性质, 假设在所考察的区间内梯度是连续的.

性质 1 函数 $f(\mathbf{x})$ 在某一点 $\mathbf{x}^{(0)}$ 的梯度 $\nabla f(\mathbf{x}^{(0)})$, 必与过该点的等值面 (其方程为 $f(\mathbf{x}) = f(\mathbf{x}^{(0)})$) 的切平面相垂直 (假定 $\nabla f(\mathbf{x}^{(0)}) \neq 0$). 或者说 $\nabla f(\mathbf{x}^{(0)})$ 表示过 $\mathbf{x}^{(0)}$ 的 $f(\mathbf{x})$ 的等值面在 $\mathbf{x}^{(0)}$ 处的法向量.

性质 2 梯度方向是函数值增加最快的方向, 即函数变化率最大的方向, 而负梯度方向则是函数值减小最快的方向.

在本书中, 我们采用欧几里德度量, 函数 $f(\mathbf{x})$ 在 $\mathbf{x}^{(0)}$ 处的梯度的模取为

$$\|\nabla f(\mathbf{x}^{(0)})\| = \sqrt{\left(\frac{\partial f(\mathbf{x}^{(0)})}{\partial x_1}\right)^2 + \left(\frac{\partial f(\mathbf{x}^{(0)})}{\partial x_2}\right)^2 + \dots + \left(\frac{\partial f(\mathbf{x}^{(0)})}{\partial x_n}\right)^2} \quad (6-8)$$

如果不用欧几里德度量而选用某些别的度量, 则梯度方向就不是函数值增加最快的方向.

满足 $\nabla f(\mathbf{x}^*) = 0$ 的点 $\mathbf{x}^*$ 称为驻点或平稳点, 在定义域内部可微函数的极值点必为驻点, 反之未必.

6.1.3.3 海赛 (Hesse) 矩阵

假定函数 $f(\mathbf{x})$ 二阶可微, 则以其二阶偏导数为元素构成的下述 $n \times n$ 矩阵称为 $f(\mathbf{x})$ 的海赛矩阵, 记为 $\nabla^2 f(\mathbf{x})$, 有

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f(\mathbf{x})}{\partial x_1^2} & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_2^2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \dots & \vdots \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_n^2} \end{bmatrix} \quad (6-9)$$

它又称为 n 元函数 $f(\mathbf{x})$ 对向量 $\mathbf{x}$ 的二阶导数, 即 $\nabla f(\mathbf{x})$ 对向量 $\mathbf{x}$ 的一阶导数. 特别地, 一元函数的海赛矩阵就是二阶导数.

在微积分中已经证明过,当 $f(\mathbf{x})$ 的二阶偏导数连续时,混合偏导数与求导顺序无关,即

$$\frac{\partial^2 f(\mathbf{x})}{\partial x_i \partial x_j} = \frac{\partial^2 f(\mathbf{x})}{\partial x_j \partial x_i} \quad (i = 1, 2, \dots, n; \quad j = 1, 2, \dots, n)$$

此时, $\nabla^2 f(\mathbf{x})$ 是对称矩阵. 函数在某一点 $\mathbf{x}^{(0)}$ 处的海赛矩阵就是将 $\mathbf{x}^{(0)}$ 的各分量值代入式(6-9)中矩阵各元素(二阶偏导函数)即可.

特别地,当 $f(\mathbf{x})$ 是二次函数时,则 $f(\mathbf{x})$ 必可写成下列形式:

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{B}^T \mathbf{x} + C \quad (6-10)$$

这里 $\mathbf{A}$ 是 $n \times n$ 实对称矩阵, $\mathbf{B}$ 为 n 维列向量, C 为常数. 容易验证,函数 $f(\mathbf{x})$ 的海赛矩阵为 $\nabla^2 f(\mathbf{x}) = \mathbf{A}$, 即二次函数的海赛矩阵是一个常数矩阵,它与 $\mathbf{x}$ 的位置无关. 反过来,如果要把一个二次函数化为式(6-10)的形式,可以通过求该二次函数的海赛矩阵和梯度求出相应的 $\mathbf{A}$, $\mathbf{B}$ 和 C 即可.

当 $f(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x} = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j$ 时, $f(\mathbf{x})$ 是关于变量 $x_1, x_2, \dots, x_n$ 的一个二次齐次多项式,称为变量 $x_1, x_2, \dots, x_n$ 的一个实二次型,它是一种特殊的实二次函数,它的海赛矩阵是 $2\mathbf{A}$. 在线性代数中,我们学习过实二次型的正定性、负定性、半定性和不定性的概念,实二次型的正定性、负定性和不定性由实对称矩阵 $\mathbf{A}$ 的正定性、负定性、半定性和不定性决定. 在本章后面将学到,对于二次函数和一般函数,点 $\mathbf{x}^{(0)}$ 处的海赛矩阵的正定性、负定性、半定性和不定性也是 $\mathbf{x}^{(0)}$ 是否是极值点的重要判据.

6.1.3.4 实对称矩阵的正定性、负定性、半定性和不定性

设有实对称矩阵

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \cdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

方阵 $\mathbf{A}$ 的行列式用 $\det \mathbf{A}$ 表示,其各阶顺序主子式为 A_i , 则

一阶顺序主子式

$$A_1 = a_{11}$$

二阶顺序主子式

$$A_2 = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11} \cdot a_{22} - a_{21} \cdot a_{12}$$

三阶顺序主子式

$$A_3 = \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = a_{11} \begin{vmatrix} a_{22} & a_{23} \\ a_{32} & a_{33} \end{vmatrix} - a_{21} \begin{vmatrix} a_{12} & a_{13} \\ a_{32} & a_{33} \end{vmatrix} + a_{31} \begin{vmatrix} a_{12} & a_{13} \\ a_{22} & a_{23} \end{vmatrix}$$

其余各阶顺序主子式依此类推. 表 6-1 给出了各矩阵的定义及充分必要条件.

表 6-1

名称	定 义	充分必要条件
正定矩阵	特征值都大于零的实对称矩阵	所有各阶顺序主子式都大于零, 即 $\det A_i > 0 \quad (i = 1, 2, \dots, n)$
半正定矩阵	特征值都不小于零的实对称矩阵	$\det A = 0$ 且 $\det A_i \geq 0 \quad (i = 1, 2, \dots, n-1)$
负定矩阵	特征值都小于零的实对称矩阵	$\det A_i \begin{cases} < 0 (i \text{ 为奇数}) \\ > 0 (i \text{ 为偶数}) \end{cases} \quad (i = 1, 2, \dots, n)$
半负定矩阵	特征值都不大于零的实对称矩阵	$\det A = 0$ 且 $\det A_i \begin{cases} \leq 0 (i \text{ 为奇数}) \\ \geq 0 (i \text{ 为偶数}) \end{cases} \quad (i = 1, 2, \dots, n-1)$
不定矩阵	特征值既有大于零又有小于零的实对称矩阵	有两个奇数阶顺序主子式, 其中一个为正, 另一个为负

6.2 凸函数和凸规划

6.2.1 凸函数定义与性质

6.2.1.1 凸函数与凹函数

形如“ $\cup$ ”的函数, 我们称之为(下)凸函数反之; 形如“ $\cap$ ”的函数, 称之为(下)凹函数. 从数学上讲, 凸函数与凹函数有很好的极值性质. 为了研究这些性质, 首先从数学上给出凸、凹函数的定义并从数量上进行描述.

定义 6-4 设 $f(x)$ 为定义在 n 维欧氏空间 $\mathbb{R}^n$ 中某个凸集 S 上的函数, 若对任何实数 λ ($0 < \lambda < 1$) 以及 S 中任意两点 $x^{(1)}$ 和 $x^{(2)}$ ($x^{(1)} \neq x^{(2)}$), 恒有

$$f(\lambda x^{(1)} + (1 - \lambda)x^{(2)}) \leq \lambda f(x^{(1)}) + (1 - \lambda)f(x^{(2)}) \quad (6-11)$$

则称 $f(x)$ 为定义在凸集 S 上的凸函数.

若对每一个 λ ($0 < \lambda < 1$) 以及 S 中任意两点 $x^{(1)}$ 和 $x^{(2)}$ ($x^{(1)} \neq x^{(2)}$), 恒有

$$f(\lambda x^{(1)} + (1 - \lambda)x^{(2)}) < \lambda f(x^{(1)}) + (1 - \lambda)f(x^{(2)}) \quad (6-12)$$

则称 $f(x)$ 为定义在凸集 S 上的严格凸函数.

从几何上看, 定义在凸集上的严格凸函数 $f(x)$ 有这样的性质:

在 S 上任取两点 $x^{(1)}$ 和 $x^{(2)}$ ($x^{(1)} \neq x^{(2)}$), 则这两点连线上的任一点 $x^{(0)}$ (可表示为: $x^{(0)} = \lambda x^{(1)} + (1 - \lambda)x^{(2)}$ ($0 \leq \lambda \leq 1$)) 的函数值 $f(x^{(0)}) = f(\lambda x^{(1)} + (1 - \lambda)x^{(2)})$ 总小于这两点函数值的加权平均值 $\lambda f(x^{(1)}) + (1 - \lambda)f(x^{(2)})$.

或说曲线(面)上任意两点的连线总在曲线(面)的上方, 即“弦在弧上”, 见图 6-2.

对于定义在凸集上的一般凸函数 $f(x)$, 曲线(面)上任意两点的连线总不在曲线(面)的下方.

将式(6-11)和式(6-12)中不等式反向就是凹函数和严格凹函数的定义, 读者可以自行写出它们各自的定义.




图 6-2 严格凸函数

请思考一下,在讨论凸函数时,为什么要求函数的定义域一定为凸集?
利用凸函数的定义,我们可以证明一些形式比较简单的函数是凸函数.

例 6-4 $f(x) = x^2$ 定义在 $(-\infty, +\infty)$, 试证 $f(x)$ 是凸函数.

证 在 $(-\infty, +\infty)$ 上任取两个不同点 $x^{(1)}$ 和 $x^{(2)}$, 任取 $\alpha (0 < \alpha < 1)$, 取

$$x^{(0)} = \alpha x^{(1)} + (1 - \alpha)x^{(2)}$$

则

$$\begin{aligned} f(x^{(0)}) &= f(\alpha x^{(1)} + (1 - \alpha)x^{(2)}) = (\alpha x^{(1)} + (1 - \alpha)x^{(2)})^2 \\ &= \alpha^2 (x^{(1)})^2 + 2\alpha(1 - \alpha)x^{(1)}x^{(2)} + (1 - \alpha)^2 (x^{(2)})^2 \end{aligned}$$

而

$$\alpha f(x^{(1)}) + (1 - \alpha)f(x^{(2)}) = \alpha(x^{(1)})^2 + (1 - \alpha)(x^{(2)})^2$$

故

$$\begin{aligned} &f(\alpha x^{(1)} + (1 - \alpha)x^{(2)}) - [\alpha f(x^{(1)}) + (1 - \alpha)f(x^{(2)})] \\ &= \alpha^2 (x^{(1)})^2 + 2\alpha(1 - \alpha)x^{(1)}x^{(2)} + (1 - \alpha)^2 (x^{(2)})^2 - \alpha(x^{(1)})^2 - (1 - \alpha)(x^{(2)})^2 \\ &= (\alpha^2 - \alpha)(x^{(1)})^2 + [(1 - \alpha)^2 - (1 - \alpha)](x^{(2)})^2 + 2\alpha(1 - \alpha)x^{(1)}x^{(2)} \\ &= \alpha(\alpha - 1)(x^{(1)})^2 + (1 - \alpha)(-\alpha)(x^{(2)})^2 + 2\alpha(1 - \alpha)x^{(1)}x^{(2)} \\ &= -\alpha(\alpha - 1)[(x^{(1)})^2 - 2x^{(1)}x^{(2)} + (x^{(2)})^2] \\ &= -\alpha(\alpha - 1)(x^{(1)} - x^{(2)})^2 \end{aligned}$$

因 $\alpha > 0, 1 - \alpha > 0, x^{(1)} \neq x^{(2)}$, 所以上式右端 < 0 . 故 $f(x) = x^2$ 在 $(-\infty, +\infty)$ 上是凸函数. $\square$

容易验证线性函数既是凸函数又是凹函数,但都不是严格凸函数和严格凹函数.

对于多元函数,因为计算复杂,一般不能直接运用凸(凹)函数的定义判断它的凸(凹)性,在下一节将介绍凸函数的两个判别准则.

6.2.1.2 凸函数的性质

利用凸函数的定义可以研究凸函数的性质.

性质 1 设 $f(x)$ 为定义在凸集 S 上的凸函数,则对任意实数 $\beta \geq 0$, 函数 $\beta f(x)$ 也是定义在凸集 S 上的凸函数.

性质 2 设 $f_1(x)$ 和 $f_2(x)$ 都是定义在凸集 S 上的凸函数,则 $f_1(x) + f_2(x)$ 也是定义在凸集 S 上的凸函数.

以上两个性质,利用凸函数定义很容易证明,请读者自行完成.

性质3 设 $f(x)$ 为定义在凸集 S 上的凸函数, 则对任意实数 β , 集合

$$S_\beta = \{x | x \in S, f(x) \leq \beta\}$$

是凸集.

证 $\forall x^{(1)}, x^{(2)} \in S_\beta$, 则有 $f(x^{(1)}) \leq \beta, f(x^{(2)}) \leq \beta, \forall \alpha (0 < \alpha < 1)$, 令

$$x^{(0)} = \alpha x^{(1)} + (1 - \alpha)x^{(2)}$$

因为 $x^{(1)}, x^{(2)} \in S$, 而 S 为凸集, 因此有

$$x^{(0)} = \alpha x^{(1)} + (1 - \alpha)x^{(2)} \in S$$

即 $x^{(0)}, x^{(1)}, x^{(2)}$ 都同属于 S , 又因为 $f(x)$ 是定义在 S 上的凸函数, 故有

$$\begin{aligned} f(x^{(0)}) &= f(\alpha x^{(1)} + (1 - \alpha)x^{(2)}) \leq \alpha f(x^{(1)}) + (1 - \alpha)f(x^{(2)}) \\ &\leq \alpha f(\beta) + (1 - \alpha)f(\beta) = \beta \end{aligned}$$

即 $x^{(0)} = \alpha x^{(1)} + (1 - \alpha)x^{(2)} \in S_\beta$, 则由凸集定义可知, S_β 是凸集. $\square$

性质4 若 $f(x)$ 是定义在凸集 S 上的凸函数, 则 $f(x)$ 的任一个极小点就是它在 S 上的全局极小点, 而且所有极小点的集合是凸集.

证 利用性质3来证明性质4. 设 x^* 是 $f(x)$ 的一个局部极小点, 即存在 $\delta > 0$, 在 x^* 的 δ 邻域 $N(x^*, \delta)$ 内, 所有的 x 都满足: $f(x) \geq f(x^*)$.

在 S 中任取一点 $x^{(0)}$, 连 $x^{(0)}$ 和 x^* , 则存在一个 $\lambda \in (0, 1)$, 使

$$(1 - \lambda)x^* + \lambda x^{(0)} \in N(x^*, \delta)$$

记 $x^{(1)} = (1 - \lambda)x^* + \lambda x^{(0)}$, 则有

$$f(x^{(1)}) = f((1 - \lambda)x^* + \lambda x^{(0)}) \geq f(x^*) \quad (6-13)$$

又因 $f(x)$ 是 S 上的凸函数, 所以有

$$f((1 - \lambda)x^* + \lambda x^{(0)}) \leq (1 - \lambda)f(x^*) + \lambda f(x^{(0)}) \quad (6-14)$$

由式(6-13)和式(6-14)有

$$(1 - \lambda)f(x^*) + \lambda f(x^{(0)}) \geq f(x^*)$$

即

$$\lambda f(x^{(0)}) \geq \lambda f(x^*)$$

又因为 $\lambda > 0$, 有

$$f(x^{(0)}) \geq f(x^*)$$

因为 $x^{(0)}$ 是 S 上的任意一点, 说明 x^* 是 $f(x)$ 在 S 上的全局极小点. 下面用性质3来证明, 若凸函数 $f(x)$ 在 S 上的极小点不止一个, 则全体极小点必连成一片构成凸集.

设 x^* 是 $f(x)$ 在 S 上的一个极小点, $f(x^*)$ 为其极小值, 记 $f(x^*) = \beta$, 则由性质3可知, 集合 $S_\beta = \{x | x \in S, f(x) \leq \beta\}$ 是凸集, 对凸集 S_β 中的任何一点 x 均有

$$f(x) \leq f(x^*) = \beta$$

但由前面证明已知, x^* 必同时为 S 上的全局极小点, 故不可能存在 x , 使 $f(x) < \beta$ 成立. 故 S_β 中的点 x , 只有满足

$$f(x) = f(x^*) = \beta$$

因此 S_β 中的点必是 $f(x)$ 在 S 中极小点, 又由 S_β 的定义, $f(x)$ 在 S 中极小点也必然全在 S_β 中, 故 $f(x)$ 在 S 中极小点必构成凸集, 即连成一片. $\square$

性质4是凸函数的一个重要性质, 它对非线性规划有很重要的意义.

6.2.2 凸函数的判别

判断一个函数是否为凸函数,当然可以根据凸函数的定义,但有时计算比较复杂,使用不够方便.对于可微函数,我们介绍两个定理,它们分别是判别凸函数的一阶和二阶的充要条件.

定理 6-1 (一阶条件) 设 $f(x)$ 在凸集 S 上具有一阶连续偏导数,则 $f(x)$ 为 S 上凸函数的充分必要条件是,对 S 中任意两个不同点 $x^{(1)}, x^{(2)}$, 恒有

$$f(x^{(2)}) \geq f(x^{(1)}) + \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)}) \quad (6-15)$$

证 必要性 设 $f(x)$ 在凸集 S 上是凸函数且具有一阶连续偏导数,则对任意 α ($0 < \alpha < 1$) 及 S 中任意两个不同点 $x^{(1)}, x^{(2)}$ ($x^{(1)} \neq x^{(2)}$), 有

$$f(\alpha x^{(2)} + (1 - \alpha)x^{(1)}) \leq \alpha f(x^{(2)}) + (1 - \alpha)f(x^{(1)})$$

又因为 $\alpha x^{(2)} + (1 - \alpha)x^{(1)} = x^{(1)} + \alpha(x^{(2)} - x^{(1)})$, 代入上式左端并移项, 有

$$f(x^{(1)} + \alpha(x^{(2)} - x^{(1)})) - f(x^{(1)}) \leq \alpha(f(x^{(2)}) - f(x^{(1)}))$$

$$\text{或者} \quad \frac{f(x^{(1)} + \alpha(x^{(2)} - x^{(1)})) - f(x^{(1)})}{\alpha} \leq f(x^{(2)}) - f(x^{(1)})$$

或者

$$\frac{f(x^{(1)} + \alpha(x^{(2)} - x^{(1)})) - f(x^{(1)})}{\alpha(x^{(2)} - x^{(1)})} (x^{(2)} - x^{(1)}) \leq f(x^{(2)}) - f(x^{(1)}) \quad (6-16)$$

令 $\alpha \rightarrow 0^+$ (即 $\alpha(x^{(2)} - x^{(1)}) \rightarrow 0$), 两边取极限, 则式(6-16)左端第一项即为 $f(x)$ 在点 $x^{(1)}$ 处的梯度定义, 即

$$\text{左端} = \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)}) \leq f(x^{(2)}) - f(x^{(1)})$$

或

$$f(x^{(2)}) \geq f(x^{(1)}) + \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)})$$

充分性 设 $\forall x^{(1)}, x^{(2)} \in S$, 都有

$$f(x^{(2)}) \geq f(x^{(1)}) + \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)}) \quad (6-17)$$

令 $x^{(0)} = \alpha x^{(1)} + (1 - \alpha)x^{(2)}$ ($0 < \alpha < 1$), 以 $x^{(0)}$ 及 $x^{(1)}$ 作为式(6-17)中的 $x^{(1)}$ 及 $x^{(2)}$, 代入式(6-17)有

$$f(x^{(1)}) \geq f(x^{(0)}) + \nabla f(x^{(0)})^T (x^{(1)} - x^{(0)}) \quad (6-18)$$

再以 $x^{(2)}$ 及 $x^{(0)}$ 作为式(6-17)中的 $x^{(1)}$ 及 $x^{(2)}$, 代入该式有

$$f(x^{(2)}) \geq f(x^{(0)}) + \nabla f(x^{(0)})^T (x^{(2)} - x^{(0)}) \quad (6-19)$$

作 $\alpha \times$ 式(6-18) + $(1 - \alpha) \times$ 式(6-19)有

$$\begin{aligned} & \alpha f(x^{(1)}) + (1 - \alpha)f(x^{(2)}) \geq \alpha f(x^{(0)}) + (1 - \alpha)f(x^{(0)}) \\ & \quad + \nabla f(x^{(0)})^T [\alpha x^{(1)} - \alpha x^{(0)} + (1 - \alpha)x^{(2)} - (1 - \alpha)x^{(0)}] \\ & = f(x^{(0)}) + \nabla f(x^{(0)})^T [\alpha x^{(1)} + (1 - \alpha)x^{(2)} - x^{(0)}] \\ & = f(x^{(0)}) + \nabla f(x^{(0)})^T \cdot 0 \\ & = f(x^{(0)}) = f(\alpha x^{(1)} + (1 - \alpha)x^{(2)}) \quad \square \end{aligned}$$

上述最后第三个等式是利用了 $x^{(0)}$ 的定义, 也表明了 $f(x)$ 是凸函数. 将式(6-15)改为严格不等式, 则它就是严格凸函数的充要条件. 一般来说, 直接使用定理 6-1 判断函数的凸性并不方便, 该定理更重要的意义在于它可以用来证明以下的定理 6-2.

定理 6-2 (二阶条件) 设 $f(x)$ 在开凸集 S 上具有二阶连续偏导数, 则 $f(x)$ 为 S 上凸函数的充分必要条件是, $f(x)$ 的海赛矩阵 $\nabla^2 f(x)$ 在 S 上处处半正定.

证 充分性 设 $f(x)$ 在开凸集 S 上任一点处的海赛矩阵 $\nabla^2 f(x)$ 都是半正定矩阵, 现从开凸集 S 上任取 x 和 $\bar{x}$, 由 Taylor 展开式

$$f(x) = f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x}) + \frac{1}{2}(x - \bar{x})^T \cdot \nabla^2 f(\bar{x} + \lambda(x - \bar{x}))(x - \bar{x}) \quad (6-20)$$

式中, $\lambda \in (0, 1)$, 又因 $\bar{x} + \lambda(x - \bar{x}) = \lambda x + (1 - \lambda)\bar{x}$, 及 $x, \bar{x} \in S$, 故 $\bar{x} + \lambda(x - \bar{x}) \in S$ (因为 S 是凸集), 由充分性假设

$$(x - \bar{x})^T \nabla^2 f(\bar{x} + \lambda(x - \bar{x}))(x - \bar{x}) \geq 0 \quad (6-21)$$

代入式(6-20)得

$$f(x) \geq f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x})$$

由定理 6-1 一阶判别条件可知 $f(x)$ 为开凸集 S 上的凸函数.

必要性 设 $f(x)$ 在开凸集 S 上为凸函数, $\forall \bar{x} \in S$ 因 $S \subseteq \mathbb{R}^n$, $\forall z \in \mathbb{R}^n (z \neq 0)$, 则必存在一个 α_1 , 使当 $\alpha \in [-\alpha_1, \alpha_1]$ 时, $\bar{x} + \alpha z \in S$ (即虽然 z 不在 S 内, 但总可使 $\bar{x} + \alpha z$ 在开集 S 内), 见图 6-3 (请读者思考: 若 S 是闭凸集, 则某些 $\bar{x}$ 点不一定能做到这一点, 当 S 是开凸集时, S 内任一点 $\bar{x}$ 都可做到这一点).




图 6-3

因为 $f(x)$ 在 S 内为凸函数, 由定理 6-1 一阶条件:

$$\begin{aligned} f(\bar{x} + \alpha z) &\geq f(\bar{x}) + \nabla f(\bar{x})^T \cdot \alpha z \\ &= f(\bar{x}) + \alpha \cdot \nabla f(\bar{x})^T \cdot z \end{aligned} \quad (6-22)$$

又由 Taylor 展开式:

$$f(\bar{x} + \alpha z) = f(\bar{x}) + \alpha \cdot \nabla f(\bar{x})^T \cdot z + \frac{1}{2} \alpha^2 z^T \nabla^2 f(\bar{x}) z + o(\alpha^2) \quad (6-23)$$

其中 $o(\alpha^2)$ 是比 α^2 高阶的无穷小量, 即有

$$\lim_{\alpha \rightarrow 0} \frac{o(\alpha^2)}{\alpha^2} = 0 \quad (6-24)$$

由式(6-22)和式(6-23)可得

$$\frac{1}{2} \alpha^2 z^T \nabla^2 f(\bar{x}) z + \frac{o(\alpha^2)}{\alpha^2} \geq 0$$

令 $\alpha \rightarrow 0$, 两边取极限, 并注意到式(6-24), 有

$$z^T \nabla^2 f(\bar{x}) z \geq 0$$

因为 $\bar{x}$ 是 S 内任一点, 而 $z \neq 0$ 是 $\mathbb{R}^n$ 中任意一个非零向量, 故由半正定矩阵定义可知, $f(x)$ 在开凸集上处处半正定. $\square$

对于定理 6-2, 有两点要说明:

(1) 若 $f(x)$ 在开凸集 S 上具有二阶连续偏导数, 则 $f(x)$ 为 S 上凹函数的充分必要条件是, $f(x)$ 的海赛矩阵 $\nabla^2 f(x)$ 在 S 上处处半负定. 这是显而易见的.

(2) 若 $f(x)$ 在开凸集 S 上具有二阶连续偏导数, 并且 $f(x)$ 的海赛矩阵 $\nabla^2 f(x)$ 在 S 上处处正定, 则 $f(x)$ 是 S 上的严格凸函数, 但这只是充分条件, 而不是必要条件(试举一例说明).

例 6-5 试证明函数 $f(x) = (x_1 - 1)^4 + (x_1 - x_2)^2$ 是凸函数.

证 计算 $\nabla f(x) = (4(x_1 - 1)^3 + 2(x_1 - x_2), 2(x_2 - x_1))^T$

$$\nabla^2 f(x) = \begin{bmatrix} 12(x_1 - 1)^2 + 2 & -2 \\ -2 & 2 \end{bmatrix},$$

可见 $\nabla^2 f(x)$ 的各阶顺序主子式都是大于 0 的, 从而 $\nabla^2 f(x)$ 处处正定, 因此 $f(x)$ 是凸函数.

6.2.3 凸规划

考虑如下非线性规划问题:

$$\begin{aligned} \min & f(x) \\ \text{s. t. } & h_i(x) = 0 \quad (i = 1, 2, \dots, m) \\ & g_j(x) \geq 0 \quad (j = 1, 2, \dots, l) \end{aligned}$$

设 $f(x)$ 是凸函数, $g_j(x)$ 是凹函数, $h_i(x)$ 是线性函数. 由于 $-g_j(x)$ 是凸函数, 故满足 $g_j(x) \geq 0$ 亦即 $-g_j(x) \leq 0$ 的点的集合是凸集(根据凸函数的性质 3). 而线性函数 $h_i(x)$ 既是凸函数也是凹函数, 故满足 $h_i(x) = 0$ 的点的集合也是凸集. 问题的可行域 $\mathcal{R}$ 是 $m + l$ 个凸集的交集仍为凸集. 这样, 上述问题就是求凸函数 $f(x)$ 在凸集 $\mathcal{R}$ 上的极小点, 这类问题称为凸规划.

若 $h_i(x)$ 是非线性的凸函数, 满足 $h_i(x) = 0$ 的点的集合不一定是凸集, 因此问题就不属于凸规划.

凸规划是非线性规划中一类比较简单而又具有重要理论意义的特殊问题, 它具有很好的性质, 即凸规划的局部极小点就是全局极小点, 且极小点的集合是凸集. 凸规划的这些性质实质上就是定义在凸集上的凸函数的具体运用. 若凸规划的目标函数是严格凸函数, 同时又存在极小点, 则它的极小点是全局极小点且是唯一的. 在第八章我们还将学习凸规划极小点的充要条件.

6.3 无约束问题的极值条件

所谓非线性规划的最优性条件, 是指非线性规划模型最优解所要满足的必要条件或充分条件. 本节从非线性规划(无约束)问题最优解的角度来讨论各种判定条件.

设无约束最优化问题:

$$\min f(\mathbf{x}), \quad \mathbf{x} \in \mathbb{R}^n$$

其中 $f(\mathbf{x})$ 是定义在 n 维欧氏空间 $\mathbb{R}^n$ 上的实函数. 上述问题即求 $f(\mathbf{x})$ 在 $\mathbb{R}^n$ 中的极小点, 叫做无约束极值问题.

6.3.1 用海赛矩阵判断驻点的性质

已知函数 $f(\mathbf{x})$ 的驻点 $\mathbf{x}^*$, 可以利用驻点 $\mathbf{x}^*$ 处的海赛矩阵 $\nabla^2 f(\mathbf{x}^*)$ 来判断驻点的性质:

若 $\nabla^2 f(\mathbf{x}^*)$ 是正定的, 则驻点 $\mathbf{x}^*$ 是极小点(局部或全局).

若 $\nabla^2 f(\mathbf{x}^*)$ 是负定的, 则驻点 $\mathbf{x}^*$ 是极大点(局部或全局).

若 $\nabla^2 f(\mathbf{x}^*)$ 是不定的, 则驻点 $\mathbf{x}^*$ 不是极值点(或者说 $\mathbf{x}^*$ 是鞍点).

若 $\nabla^2 f(\mathbf{x}^*)$ 是半定的, 则驻点 $\mathbf{x}^*$ 可能是极值点, 也可能不是极值点, 须视高阶导数的性质而定. 特别当一切二阶导数在驻点处都为 0 时, 应引用高阶导数.

6.3.2 极值点的必要条件和充分条件

为研究无约束问题最优解要满足的必要条件, 首先介绍一个定理.

定理 6-3 设实值函数 $f(\mathbf{x}) \in \mathbb{R}, \mathbf{x} \in \mathbb{R}^n$, 在点 $\mathbf{x}^*$ 处可微. 若存在向量 $\mathbf{p} \in \mathbb{R}^n$, 使 $\nabla f(\mathbf{x}^*)^T \cdot \mathbf{p} < 0$, 则存在 $\delta > 0$, 当 $\lambda \in (0, \delta)$ 时, 有

$$f(\mathbf{x}^* + \lambda \mathbf{p}) < f(\mathbf{x}^*)$$

证 由可微函数的定义, 将 $f(\mathbf{x})$ 在点 $\mathbf{x}^*$ 处作一阶 Taylor 公式展开, 对于任意的 $\lambda > 0$, 有

$$f(\mathbf{x}^* + \lambda \mathbf{p}) = f(\mathbf{x}^*) + \lambda \nabla f(\mathbf{x}^*)^T \mathbf{p} + o(\|\lambda \mathbf{p}\|) \quad (6-25)$$

由于 $\lambda > 0$ 及 $\nabla f(\mathbf{x}^*)^T \cdot \mathbf{p} < 0$, 故有 $\lambda \cdot \nabla f(\mathbf{x}^*)^T \cdot \mathbf{p} < 0$. 又因为式 (6-25) 中 $o(\|\lambda \mathbf{p}\|)$ 是指比 $\|\lambda \mathbf{p}\|$ ($\lambda \mathbf{p}$ 的模) 更高阶的无穷小量, 因此存在 $\delta > 0$, 当 $\lambda \in (0, \delta)$ 时, 恒有

$$\lambda \nabla f(\mathbf{x}^*)^T \mathbf{p} + o(\|\lambda \mathbf{p}\|) < 0$$

代入式 (6-25) 有

$$f(\mathbf{x}^* + \lambda \mathbf{p}) < f(\mathbf{x}^*), \quad \forall \lambda \in (0, \delta). \quad \square$$

定理 6-4 (一阶必要条件) 设实值函数 $f(\mathbf{x}) \in \mathbb{R}, \mathbf{x} \in \mathbb{R}^n$, 在点 $\mathbf{x}^*$ 处可微, 若 $\mathbf{x}^*$ 是无约束问题 $\min f(\mathbf{x})$ 的局部极小点, 则梯度

$$\nabla f(\mathbf{x}^*) = \mathbf{0}$$

证 用反证法. 若 $\nabla f(\mathbf{x}^*) \neq \mathbf{0}$. 现令 $\mathbf{p} = -\nabla f(\mathbf{x}^*)$, 则有

$$\nabla f(\mathbf{x}^*)^T \mathbf{p} = -\nabla f(\mathbf{x}^*)^T \cdot \nabla f(\mathbf{x}^*) = -\|\nabla f(\mathbf{x}^*)\|^2 < 0$$

由定理 6-3, 必存在 $\delta > 0$, 使当 $\lambda \in (0, \delta)$ 时, 有

$$f(\mathbf{x}^* + \lambda \mathbf{p}) < f(\mathbf{x}^*)$$

成立. 但这与 $\mathbf{x}^*$ 是局部最优解相矛盾. 因此必有 $\nabla f(\mathbf{x}^*) = \mathbf{0}$. $\square$

定理 6-5 (二阶必要条件) 设实值函数 $f(\mathbf{x}) \in \mathbb{R}, \mathbf{x} \in \mathbb{R}^n$, 在点 $\mathbf{x}^*$ 处二阶可微, 若 $\mathbf{x}^*$ 是无约束问题 $\min f(\mathbf{x})$ 的局部极小点, 则梯度 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ 且海赛矩阵 $\nabla^2 f(\mathbf{x}^*)$ 半正定.

证明从略, 详见参考文献[5].

定理 6-6 (二阶充分条件) 设实值函数 $f(\mathbf{x}) \in \mathbb{R}, \mathbf{x} \in \mathbb{R}^n$, 在点 $\mathbf{x}^*$ 处二阶可微, 若

$\nabla f(\mathbf{x}^*) = \mathbf{0}$ 且海赛矩阵 $\nabla^2 f(\mathbf{x}^*)$ 正定, 则 $\mathbf{x}^*$ 是无约束问题 $\min f(\mathbf{x})$ 的严格局部极小点.

证明从略, 详见参考文献[5].

定理 6-7 (充要条件) 设 $f(\mathbf{x})$ 是定义在 n 维欧氏空间 $\mathbb{R}^n$ 上的可微凸函数, $\mathbf{x}^* \in \mathbb{R}^n$, 则 $\mathbf{x}^*$ 为无约束问题 $\min f(\mathbf{x})$ 的全局极小点的充要条件是 $\nabla f(\mathbf{x}^*) = \mathbf{0}$.

证 必要性是显然的. 若 $\mathbf{x}^*$ 为无约束问题 $\min f(\mathbf{x})$ 的全局极小点, 自然是局部极小点, 根据定理 6-4 可知, $\nabla f(\mathbf{x}^*) = \mathbf{0}$.

再证充分性. 设 $\nabla f(\mathbf{x}^*) = \mathbf{0}$, 则对任意的 $\mathbf{x} \in \mathbb{R}^n$, 有 $\nabla f(\mathbf{x}^*)^T \cdot (\mathbf{x} - \mathbf{x}^*) = 0$. 由于 $f(\mathbf{x})$ 是可微凸函数, 根据定理 6-1, 有

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) = f(\mathbf{x}^*)$$

即 $\mathbf{x}^*$ 是全局极小点. $\square$

在上述定理中, 若 $f(\mathbf{x})$ 是严格凸函数, 则全局极小点是唯一的.

以上介绍的几个极值条件, 是针对无约束极小化问题给出的. 对于无约束极大化问题, 可以给出类似的定理.

例 6-6 利用极值条件求解以下问题

$$\min f(\mathbf{x}) = \frac{1}{3}x_1^3 + \frac{1}{3}x_2^3 - x_2^2 - x_1$$

解 先求 $f(\mathbf{x})$ 的梯度函数 $\nabla f(\mathbf{x}) = \left(\frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2} \right)^T$:

$$\frac{\partial f(\mathbf{x})}{\partial x_1} = x_1^2 - 1, \quad \frac{\partial f(\mathbf{x})}{\partial x_2} = x_2^2 - 2x_2$$

令 $\nabla f(\mathbf{x}) = \mathbf{0}$, 即

$$\begin{cases} x_1^2 - 1 = 0 \\ x_2^2 - 2x_2 = 0 \end{cases}$$

解此方程组, 求得驻点

$$\mathbf{x}^{(1)} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad \mathbf{x}^{(2)} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad \mathbf{x}^{(3)} = \begin{pmatrix} -1 \\ 0 \end{pmatrix}, \quad \mathbf{x}^{(4)} = \begin{pmatrix} -1 \\ 2 \end{pmatrix}$$

而 $f(\mathbf{x})$ 的海赛矩阵为

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} 2x_1 & 0 \\ 0 & 2x_2 - 2 \end{bmatrix}$$

因此 $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \mathbf{x}^{(3)}, \mathbf{x}^{(4)}$ 处的海赛矩阵依次为

$$\nabla^2 f(\mathbf{x}^{(1)}) = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}, \quad \nabla^2 f(\mathbf{x}^{(2)}) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

$$\nabla^2 f(\mathbf{x}^{(3)}) = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix}, \quad \nabla^2 f(\mathbf{x}^{(4)}) = \begin{bmatrix} -2 & 0 \\ 0 & 2 \end{bmatrix}$$

因为 $\nabla^2 f(\mathbf{x}^{(1)}), \nabla^2 f(\mathbf{x}^{(4)})$ 是不定矩阵, 因此 $\mathbf{x}^{(1)}, \mathbf{x}^{(4)}$ 不是极值点或者说是鞍点. 而矩阵 $\nabla^2 f(\mathbf{x}^{(3)})$ 为负定矩阵, 因此驻点 $\mathbf{x}^{(3)}$ 是极大点. 而 $\nabla^2 f(\mathbf{x}^{(2)})$ 是正定矩阵, 根据定理 6-7, $\mathbf{x}^{(2)}$ 是严格局部最优解 (极小点).

6.4 下降迭代算法

前面讨论了无约束问题的极值条件,从理论上讲,可以用这些条件求相应的非线性规划的最优化解.但是对大多数实际的非线性规划问题,直接运用极值条件求解是很困难的.有的问题导数不存在,有的问题导数即使存在,计算也很麻烦,多数问题由条件 $\nabla f(x) = 0$ 得到的是一个非线性方程组,求解非常困难,甚至根本无法得到解释解;此外,大多数非线性规划问题都是有约束条件的,上一节的极值条件也不能直接套用.因此,求解非线性规划问题一般都采用数值计算的迭代方法.用数值方法求解非线性规划问题的基本思路有:

- (1) 尽可能将多元函数优化问题转化为一系列的一元函数的优化问题求解;
- (2) 尽可能将非线性规划问题转化为一系列线性规划问题求解;
- (3) 尽可能将有约束的优化问题转化为一系列无约束优化问题求解.

从这些思路可以看到,单纯的一元函数优化和无约束问题的优化在非线性规划求解中有着举足轻重的作用,在本书的后两章将分别介绍这两类优化计算方法.以上基本思路实际上就是各种不同形式的迭代算法,通常这些迭代算法都是下降迭代算法.

6.4.1 下降迭代算法的概念

所谓迭代,就是从已知点 $x^{(k)}$ 出发,按照某种规则(即算法)求出后继点 $x^{(k+1)}$,用 $k+1$ 代替 k ,重复以上过程,这样便产生点列 $\{x^{(k)}\}$ 和数列 $\{f(x^{(k)})\}$;所谓下降,就是对于某个函数,在每次迭代中,后继点的函数值都比原来的函数值有所减小.在一定条件下,下降迭代算法产生的点列收敛于原问题的解.由于所讨论的问题是运用数值算法求解有约束的极小化非线性规划问题,因此要求算法是下降迭代算法.

设 $x^{(k)} \in \mathbb{R}^n$ 是某种迭代算法的第 k 轮迭代点, $x^{(k+1)} \in \mathbb{R}^n$ 是第 $k+1$ 轮迭代点,记 Δx_k 为两者之差,即

$$\Delta x_k = x^{(k+1)} - x^{(k)} \quad (6-26)$$

或记为

$$x^{(k+1)} = x^{(k)} + \Delta x_k \quad (6-27)$$

由式(6-26)可知, Δx_k 应是以 $x^{(k)}$ 为起点、 $x^{(k+1)}$ 为终点的 n 维向量(见图6-4).




图 6-4

现令 $d^{(k)} \in \mathbb{R}^n$ 是向量 Δx_k 方向上的单位向量,则有

$$\Delta x_k = \lambda_k d^{(k)}$$

此处 $\lambda_k > 0, \lambda_k \in \mathbb{R}$, 即为正实数. 将上式代入式(6-27)有

$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)} \quad (6-28)$$

这里 $\|d^{(k)}\| = 1, d^{(k)}$ 的方向就是从 $x^{(k)}$ 向着点 $x^{(k+1)}$ 的方向, 式(6-28)就是求解非线性规划问题的基本迭代形式.

通常将式(6-28)中的 $d^{(k)}$ 称为迭代的第 k 轮搜索方向(可以不是单位向量), λ_k 称为第 k 轮的步长或沿 $d^{(k)}$ 方向的步长. 从式(6-28)可以看出, 求解非线性规划问题的关键在于如何构造每一轮的搜索方向和确定步长.

6.4.2 下降方向与可行下降方向

今后为书写方便, 引入记号: $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 它表示多元函数 $f(x)$, 其自变量 x 是 n 维向量: $x \in \mathbb{R}^n$, 而函数值 $f(x)$ 是实数, $f(x) \in \mathbb{R}$.

定义 6-5 设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 点 $\bar{x} \in \mathbb{R}^n$, 向量 $p \in \mathbb{R}^n$ ($p \neq 0$), 若存在一个实数 $\delta > 0$, 使 $\forall \lambda \in (0, \delta)$ 都有

$$f(\bar{x} + \lambda p) < f(\bar{x}) \quad (6-29)$$

成立. 则称 p 为 $f(x)$ 在点 $\bar{x}$ 处的下降方向.

一般来说, 点 $\bar{x}$ 如同一个“点光源”, 它有无穷多个方向, 也可能有无穷多个下降方向, 如何在点 $\bar{x}$ 处选择使函数值下降最快的方向, 是一个重要的问题.

对于有约束的非线性规划问题

$$\begin{aligned} \min f(x) \\ x \in \mathcal{H} \end{aligned} \quad (6-30)$$

$\mathcal{H}$ 为其可行域, 则算法不仅要保证搜索方向为下降方向, 而且还要保证

$$x^{(k+1)} (= x^{(k)} + \lambda_k d^{(k)})$$

仍然在可行域 $\mathcal{H}$ 内(当然 $x^{(k)}$ 在 $\mathcal{H}$ 内).

定义 6-6 设 $\mathcal{H} \subset \mathbb{R}^n, \bar{x} \in \mathcal{H}, n$ 维向量 $d \in \mathbb{R}^n$ ($d \neq 0$), 若存在 $\delta > 0$, 当 $\forall \lambda \in [0, \delta]$ 时, 使 $\bar{x} + \lambda d \in \mathcal{H}$ 仍成立, 则称向量 d 为点 $\bar{x}$ 处关于可行域 $\mathcal{H}$ 的可行方向.

特别地, 当 $\bar{x}$ 处在可行域 $\mathcal{H}$ 内部时, 任一个方向 d 都是可行方向. 当 $\bar{x}$ 处在可行域的边界上时, 有一部分方向是可行方向, 有一部分是不可行方向(读者自己可以图示出来).

因此对于求解有约束的非线性规划问题(6-30), 其算法要保证搜索方向 $d^{(k)}$ 既是 $f(x)$ 在 $x^{(k)}$ 处的下降方向, 又是该点 $x^{(k)}$ 关于区域 $\mathcal{H}$ 的可行方向, 并称之为 $f(x)$ 在点 $x^{(k)}$ 处关于 $\mathcal{H}$ 的可行下降方向.

6.4.3 下降迭代算法的一般步骤

下降迭代算法的一般步骤如下:

(1) 选取初始点 $x^{(1)}$, 令 $k = 1$.

(2) 构造搜索方向 $d^{(k)}$. 若已得到迭代点 $x^{(k)}$, 且 $x^{(k)}$ 不是极小点, 则对于 $x^{(k)}$ 点按照一定的规则构造出一个有利的搜索方向 $d^{(k)}$: 对于无约束问题, $d^{(k)}$ 应是下降方向; 对于有约束问题, $d^{(k)}$ 应是可行下降方向.

(3) 确定最优步长 λ_k (或称最优步长因子 λ_k). 从 $\mathbf{x}^{(k)}$ 点出发, 沿 $\mathbf{d}^{(k)}$ 方向进行搜索, 设步长为变量 λ ($\lambda \geq 0$), 由于 $\mathbf{x}^{(k)}$ 和 $\mathbf{d}^{(k)}$ 均为已知, 故 $f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})$ 是关于 λ 的一元函数, 求以 λ 为变量的一元函数 $f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})$ 的极小点 λ_k , 即

$$f(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}) = \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)}) \quad (6-31)$$

称上式中的 λ_k 为最优步长, 又称上述求最优步长 λ_k 的过程为一维搜索 (或线搜索).

(4) 令 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}$, 得到一个新点 $\mathbf{x}^{(k+1)}$, 若 $\mathbf{x}^{(k+1)}$ 已满足实现规定的算法终止条件, 停止迭代, 以 $\mathbf{x}^{(k+1)}$ 为近似极小点; 否则, 令 $k := k + 1$, 返回步骤(2), 继续迭代.

在以上各步骤中, 确定搜索方向 $\mathbf{d}^{(k)}$ 是最关键的一步, 各种寻优方法的不同, 主要在于它们选择的有利搜索方向不同.

一维搜索的步长 λ_k 有一个十分重要的性质: 在搜索方向上所求得的最优点处的梯度和该搜索方向正交, 即

$$\nabla f(\mathbf{x}^{(k+1)})^T \cdot \mathbf{d}^{(k)} = \nabla f(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)})^T \cdot \mathbf{d}^{(k)} = 0$$

定理 6-8 设目标函数 $f(\mathbf{x})$ 具有连续的一阶偏导数, $\mathbf{x}^{(k+1)}$ 按以下规则产生

$$\begin{cases} f(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}) = \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)}) \\ \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)} \end{cases} \quad (6-32)$$

则有

$$\nabla f(\mathbf{x}^{(k+1)})^T \cdot \mathbf{d}^{(k)} = 0 \quad (6-33)$$

成立.

证 设 $\varphi(\lambda) = f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})$, 若 λ_k 是最优步长, 则 λ_k 应是 $\varphi(\lambda)$ 的驻点, 即有

$$\left. \frac{d\varphi}{d\lambda} \right|_{\lambda=\lambda_k} = 0 \quad (6-34)$$

而

$$\begin{aligned} \frac{d\varphi}{d\lambda} &= \frac{df(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})}{d(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})} \cdot \frac{d(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})}{d\lambda} \\ &= \nabla f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})^T \cdot \mathbf{d}^{(k)} \end{aligned} \quad (6-35)$$

将式(6-35)代入式(6-34), 有

$$\nabla f(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)})^T \cdot \mathbf{d}^{(k)} = 0$$

即

$$\nabla f(\mathbf{x}^{(k+1)})^T \cdot \mathbf{d}^{(k)} = 0. \quad \square$$

一维搜索的具体方法将在下一章介绍.

6.4.4 算法终止条件

下降迭代算法中, 常用的算法终止条件有以下几种:

(1) 当自变量的改变量充分小时, 即相继两次迭代的绝对误差

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| < \varepsilon_1$$

或者相继两次迭代的相对误差

$$\frac{\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|}{\|\mathbf{x}^{(k)}\|} < \varepsilon_2$$

时,算法终止.

(2)当目标函数的下降量充分小时,即相继两次迭代的绝对误差

$$f(\mathbf{x}^{(k)}) - f(\mathbf{x}^{(k+1)}) < \varepsilon_3$$

或者相继两次迭代的相对误差

$$\frac{f(\mathbf{x}^{(k)}) - f(\mathbf{x}^{(k+1)})}{|f(\mathbf{x}^{(k)})|} < \varepsilon_4$$

时,算法终止.

(3)在无约束最优化中,当目标函数(设目标函数一阶可微)梯度的模充分小(即目标函数梯度近似为零向量)

$$\|\nabla f(\mathbf{x}^{(k+1)})\| < \varepsilon_5$$

时,算法终止.

习 题

6-1 试判断下列函数的凸凹性:

(1) $f(x) = (4-x)^2 \quad (x < 4)$

(2) $f(x) = x_1^2 + 2x_1x_2 + 3x_2^2$

(3) $f(x) = \frac{1}{x}$

(4) $f(x) = x_1x_2$

(5) $f(x) = (x_1 - 1)^4 + (x_1 - x_2)^2$

6-2 求下列函数的驻点,并判别它们是极大点、极小点或鞍点:

(1) $f(x) = 4x^4 - x^2 + 5$

(2) $f(x) = (3x - 2)^2(2x - 3)^2$

(3) $f(x) = 5x_1^2 + 12x_1x_2 - 16x_1x_3 + 10x_2^2 - 26x_2x_3 + 17x_3^2 - 2x_1 - 4x_2 - 6x_3$

(4) $f(x) = -x_1^2 + x_1 - x_2^2 + x_2x_3 + 2x_3$

6-3 判定下列非线性规划是否为凸规划

(1) $\min f(x) = x_1^2 + x_2^2 - 2x_1 + x_1x_2$

s. t. $g_1(x) = 3x_1 + 5x_2 - 4 \geq 0$

$g_2(x) = 3x_1^2 + x_2^2 - 2x_1x_2 - 8x_2 + 10 \geq 0$

$x_1, x_2 \geq 0$

(2) $\min f(x) = x_1 + 2x_2$

s. t. $g_1(x) = x_1^2 + x_2^2$

$g_2(x) = x_2 \geq 0$

(3) $\min f(x) = 2x_1^2 + 2x_1x_2 + x_2^2 - 10x_1 - 10x_2$

s. t. $g_1(x) = 5 - x_1^2 - x_2^2 \geq 0$

$g_2(x) = 6 - 3x_1 - x_2 \geq 0$

第7章 一维搜索

在上一章讲述过,求解非线性规划问题的下降迭代算法包含了两个最关键的步骤:一步是由 $\mathbf{x}^{(k)}$ 出发,按算法规则构造出搜索方向 $\mathbf{d}^{(k)}$;另一步是在已知 $\mathbf{x}^{(k)}$ 和 $\mathbf{d}^{(k)}$ 后,由 $\mathbf{x}^{(k)}$ 出发,沿 $\mathbf{d}^{(k)}$ 求步长因子 λ_k ,要求 λ_k 满足

$$f(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}) = \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})$$

因为 $f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})$ 只是 λ 的一元函数,称求这样的极小点问题为一维搜索. 求解 λ_k 近似值的方法主要分为两类:一类为区间收缩法;一类为函数逼近法.

由于一维搜索是所有非线性规划迭代算法都要遇到的共同问题,而且它相对于构造搜索方向问题来说要简单. 本章介绍的黄金分割法属于区间收缩法;牛顿法及抛物线法属于函数逼近法.

显然,一维搜索法不仅可用在求最优步长上,而且也是求单变量函数极小点的一种方法,因此一维搜索又称为单变量函数寻优法.

7.1 黄金分割法

黄金分割法也叫 0.618 法,属于区间收缩法. 首先找出包含极小点的初始搜索区间,然后按黄金分割点通过对函数值的比较不断缩小搜索区间. 当然,要保证极小点始终在搜索区间内,当区间长度小到精度范围之内时,可以粗略地认为区间中点为极小点的近似值. 黄金分割法适用于单谷函数,即在某一区间中存在唯一极小点的函数.

7.1.1 单谷函数及其性质

定义 7-1 设单变量函数 $f(x)$ 在区间 $[a_1, b_1]$ 内存在唯一的极小点 x^* , $x^* \in (a_1, b_1)$, 且 $f(x)$ 在 x^* 点的左侧严格下降,在 x^* 点的右侧严格上升,则称 $f(x)$ 在区间 $[a_1, b_1]$ 上是单谷函数或者下单峰函数, $[a_1, b_1]$ 为 $f(x)$ 的单谷区间,见图 7-1.

单谷区间与单谷函数有如下性质:

若 $f(x)$ 是单谷区间 $[a_1, b_1]$ 上的单谷函数,极小点为 x^* ,在 $[a_1, b_1]$ 任取两点 a 和 b ,且 $a < b$,计算这两点的函数值 $f(a)$ 和 $f(b)$,则:
(1) 当 $f(a) < f(b)$ 时, $x^* \in [a_1, b]$. (2) 当 $f(a) \geq f(b)$ 时, $x^* \in [a, b_1]$.

对于情况(1),我们可以推断出 b 一定不在 x^* 的左侧,无论 a 在 x^* 的左侧还是右侧,结论都成立;对于情况(2),一样可以推断出 a 一定不在 x^* 的右侧.




图 7-1

由单谷函数的性质可知,在单谷区间 $[a_1, b_1]$ 任取两点 a 和 b 都可以求得一个相对更小的单谷区间.显然,这个过程可以一直重复下去,如果某个单谷区间的长度足够小,该区间的中点就可以作为极小点的近似.在单谷区间中取两点,能不能按照一定的规律去取呢?也就是说,单谷区间不断缩小的比例能不能明确化.回答是肯定的,本节将要介绍的黄金分割法就是对这一问题的具体实现.

7.1.2 黄金分割法基本原理与步骤

1. 在区间 $[a_1, b_1]$ 上选择第一个试点 x_1 ,并计算 $f(x_1)$

第一个试点 x_1 怎么选呢?我们希望试点 x_1 将总长为 l 的区间 $[a_1, b_1]$ 分为两部分,令长的那一部分长度为 z ,则短的那一段的长度为 $l-z$,如图7-2所示.要求满足 x_1




图 7-2

$$\frac{l-z}{z} = \frac{z}{l} \quad (7-1)$$

即

$$z^2 + zl - l^2 = 0 \quad (7-2)$$

也可写为

$$\left(\frac{z}{l}\right)^2 + \left(\frac{z}{l}\right) - 1 = 0 \quad (7-3)$$

解这个一元二次方程并舍去负根,得

$$\frac{z}{l} = \frac{-1 + \sqrt{5}}{2} \approx 0.618 \quad (7-4)$$

即

$$z \approx 0.618l \quad (7-5)$$

称试点 x_1 为区间 $[a_1, b_1]$ 的黄金分割点,有

$$x_1 = a_1 + 0.618(b_1 - a_1) \quad (7-6)$$

再计算出 $f(x_1)$.

2. 选择 x_1 的对称点 x'_1 作为第二个试点,并计算 $f(x'_1)$

试点 x'_1 具有哪些特点呢?在区间 $[a_1, b_1]$ 上, x'_1 是黄金分割点 x_1 的对称点,有

$$x'_1 = a_1 + 0.382(b_1 - a_1) \quad (7-7)$$

可以验证,在区间 $[a_1, x_1]$ 上, x'_1 又是黄金分割点,在区间 $[a_1, x'_1]$ 上, x_1 是黄金分割点的对称点.

再计算出 $f(x'_1)$,并令 $k=1$.

3. 比较计算 $f(x_k)$ 和 $f(x'_k)$

我们规定区间 $[a_k, b_k]$ 上的黄金分割点用 x_k 表示,黄金分割对称点用 x'_k 表示.

第一种情况 当 $f(x_k) > f(x'_k)$ 时

因为 $f(x)$ 是单谷函数,故其极小点不可能在区间 $[x_k, b_k]$ 上,将原区间缩短为 $[a_k, x_k]$.

(1) 进行区间端点的置换. 令新的区间端点 $a_{k+1} = a_k, b_{k+1} = x_k$.

(2) 判断精度. 若 $\frac{b_{k+1} - a_{k+1}}{b_1 - a_1} < \delta$,则停止计算,可取 $x^* = \frac{1}{2}(a_{k+1} + b_{k+1})$ 为近似极小点,

$f(x^*)$ 为近似极小值. 否则, 转下一步.

(3) 进行保留试点的坐标的变换. 在新区间 $[a_{k+1}, b_{k+1}]$ 上, 原试点 x'_k 为保留试点且成为黄金分割点, 故有

$$x_{k+1} = x'_k, \quad f(x_{k+1}) = f(x'_k)$$

(4) 找到保留试点的对称点 x'_{k+1} , 并计算 $f(x'_{k+1})$. 有

$$x'_{k+1} = a_{k+1} + 0.382(b_{k+1} - a_{k+1})$$

再计算出 $f(x'_{k+1})$.

(5) 令 $k := k + 1$, 返回步骤(3).

第二种情况 当 $f(x_k) \leq f(x'_k)$ 时, 第二种情况与第一种情况完全类似. 因为 $f(x)$ 是单谷函数, 故其极小点不可能在区间 $[a_k, x'_k]$ 上, 将原区间缩短为 $[x'_k, b_k]$.

(1) 进行区间端点的置换. 令新的区间端点 $a_{k+1} = x'_k$, $b_{k+1} = b_k$.

(2) 判断精度. 若 $\frac{b_{k+1} - a_{k+1}}{b_1 - a_1} < \delta$, 则停止计算, 可取 $x^* = \frac{1}{2}(a_{k+1} + b_{k+1})$ 为近似极小点,

$f(x^*)$ 为近似极小值. 否则, 转下一步.

(3) 进行保留试点的坐标的变换. 在新区间 $[a_{k+1}, b_{k+1}]$ 上, 原试点 x_k 为保留试点且成为黄金分割点的对称, 故有

$$x'_{k+1} = x_k, \quad f(x'_{k+1}) = f(x_k)$$

(4) 找到保留试点的对称点 x_{k+1} , 并计算 $f(x_{k+1})$. 有

$$x_{k+1} = a_{k+1} + 0.618(b_{k+1} - a_{k+1})$$

再计算出 $f(x_{k+1})$.

(5) 令 $k := k + 1$, 返回步骤(3).

以上介绍了黄金分割法的基本原理与步骤. 由分析可知, 采用黄金分割法时, 计算 n 对试点的函数值可以把原始区间 $[a_1, b_1]$ 连续缩短 $n - 1$ 次, 且每次的区间缩短率都是 0.618, 故最后所剩区间的长度为 $b_n - a_n = 0.618^{n-1}(b_1 - a_1)$. 黄金分割法原理简单, 计算容易, 使用效果也相当好, 特别是它不要求函数是否可导, 因而在实际中得到了广泛的应用. 取 0.618 作为区间缩短率只是近似的黄金分割法, 通常又称为 0.618 法. 一般情况下黄金分割法指的就是 0.618 法.

在应用黄金分割法时, 需要注意的是: 黄金分割法只适用于单谷函数. 因此, 必须先确定目标函数的单谷区间, 再运用黄金分割法. 确定单谷区间的方法可采用本章后面将要介绍的寻找极小点存在区间的外推内插法.

例 7-1 用 0.618 法求函数

$$f(x) = \begin{cases} \frac{x}{2} & \text{当 } x \leq 2 \\ -x + 3 & \text{当 } x > 2 \end{cases}$$

在区间 $[0, 3]$ 上的极大点, 要求缩短后区间的长度不大于原区间长度的 15%.

解 本例函数 $f(x)$ 在区间 $[0, 3]$ 上是单谷函数, 即存在唯一极大点, 也可以运用黄金分割法求解, 只是在确定保留试点时与单谷函数的黄金分割法略有不同而已.

$$a_1 = 0, b_1$$

$$x_1 = a_1 + 0.618(b_1 - a_1) = 1.854$$

$$x'_1 = a_1 + 0.382(b_1 - a_1) = 1.146$$

$$f(x_1) = \frac{x_1}{2} = 0.927$$

$$f(x'_1) = \frac{x'_1}{2} = 0.573$$

因为 $f(x_1) > f(x'_1)$, 极大点不可能在区间 $[a_1, x'_1]$ 上, 故将原区间缩短为 $[x'_1, b_1]$, 即令

$$a_2 = x'_1 = 1.146$$

$$b_2 = b_1 = 3$$

$$x'_2 = x_1 = 1.854$$

$$f(x'_2) = f(x_1) = 0.927$$

继续用黄金分割法迭代:

$$x_2 = a_2 + 0.618(b_2 - a_2) = 2.292, \quad f(x_2) = -x_2 + 3 = 0.708$$

因为 $f(x_2) < f(x'_2)$, 故将原区间缩短为 $[a_2, x_2]$, 即令

$$a_3 = a_2 = 1.146$$

$$b_3 = x_2 = 2.292$$

$$x_3 = x'_2 = 1.854$$

$$f(x_3) = f(x'_2) = 0.927$$

计算

$$x'_3 = a_3 + 0.382(b_3 - a_3) = 1.584, \quad f(x'_3) = \frac{x'_3}{2} = 0.792$$

因为 $f(x_3) > f(x'_3)$, 故将原区间缩短为 $[x'_3, b_3]$, 即令

$$a_4 = x'_3 = 1.584$$

$$b_4 = b_3 = 2.292$$

$$x'_4 = x_3 = 1.854$$

$$f(x'_4) = f(x_3) = 0.927$$

计算

$$x_4 = a_4 + 0.618(b_4 - a_4) = 2.022, \quad f(x_4) = -x_4 + 3 = 0.792$$

因为 $f(x_4) > f(x'_4)$, 故将原区间缩短为 $[x'_4, b_4]$, 即 $[1.854, 2.292]$.

计算精度

$$\frac{2.292 - 1.854}{3 - 0} = 14.6\% < 15\%$$

已达到要求精度, 可停止迭代, 得近似极大点和极大值:

$$x = \frac{1}{2}(1.854 + 2.292) = 2.073$$

$$f(x) = -2.073 + 3 = 0.927$$

本例的精确最优结果是

$$x^* = 2, \quad f(x^*) = 1$$

值得注意的是, 0.618 法是一种近似黄金分割法. 由式(7-4)可知, 0.618 只是黄金分割比 $\frac{\sqrt{5}-1}{2}$ 的一个近似值. 现在已从理论上证明, 当取黄金分割比 $\frac{\sqrt{5}-1}{2} \approx 0.618$ 时, 试点最大个数为 10, 即不超过 10 个试点才有意义, 亦即 0.618 法最多只能作 9 次迭代, 或说 0.618 法的最小精度为 $\delta_{\min} = \frac{b_{10} - a_{10}}{b_1 - a_1} = 0.618^9 \approx 0.013$.

好在对大多数问题作 9 次(或者少于 9 次)迭代都能满足原先给出的要求. 如果不满足, 只能将黄金分割比的近似值取得比 0.618 更接近精确值的数. 因为

$$\frac{\sqrt{5}-1}{2} \approx 0.6180339887\ldots$$

如此时可取 0.6180339 作为近似值, 则试点个数可以增加到 15 个(即可作 14 次迭代), 其最小精度也相应地提高.

7.2 牛顿法

牛顿法是一种函数逼近法. 它的基本思想就是, 在极小点附近用二阶 Taylor 多项式近似代替目标函数 $f(x)$, 从而求出 $f(x)$ 极小点的估计值. 在数值分析中, 牛顿法用于求方程的根, 而求函数极值点等价于求导函数的根(如果函数可微的话). 因此, 牛顿法作为一种优化方法, 其实质就是将一个求函数极值点的问题转化为一个求另一个函数(目标函数的导函数)的根的问题.

7.2.1 牛顿法的基本原理

1. 用二阶 Taylor 多项式 $\varphi(x)$ 来近似 $f(x)$

将 $f(x)$ 在点 x_k 处展开成 Taylor 级数, 取其前三项, 即得到 $\varphi(x)$:

$$\varphi(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2}f''(x_k)(x - x_k)^2 \approx f(x)$$

上述 $\varphi(x)$ 在点 x_k 处的 $\varphi(x_k)$ 、 $\varphi'(x_k)$ 、 $\varphi''(x_k)$ 分别与 $f(x)$ 在点 x_k 处的 $f(x_k)$ 、 $f'(x_k)$ 、 $f''(x_k)$ 相等.

2. 用 $\varphi(x)$ 的极小点近似 $f(x)$ 的极小点

令

$$\varphi'(x) = f'(x_k) + f''(x_k)(x - x_k) = 0$$

得到 $\varphi(x)$ 的驻点 x_{k+1} :

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)} \quad (7-8)$$

因为在 x_k 附近, $\varphi(x) \approx f(x)$, 故可用 $\varphi(x)$ 的极小点作为 $f(x)$ 的极小点的估计值. 如果 x_k 是 $f(x)$ 的极小点的一个估计值, 则利用公式(7-8)可以得到极小点的一个进一步的估计值 x_{k+1} .

3. 判断精度

若 x_{k+1} 满足允许精度, 则停止计算. 否则, 在点 x_{k+1} 处, 用公式(7-8)计算出 x_{k+2} ……如此继续下去, 可得到一个点列(数列). 可以证明, 在一定条件下, 这个点列收敛于 $f(x)$ 的极小点.

7.2.2 牛顿法的算法步骤

- (1) 给定初始点 x_1 , 给定允许精度 $\varepsilon > 0$, 并令 $k = 1$.
- (2) 计算 $f'(x_k)$ 与 $f''(x_k)$.
- (3) 若 $|f'(x_k)| < \varepsilon$, 则停止迭代, 得到近似极小点 x_k . 否则转下一步.
- (4) 计算 $x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$.
- (5) 令 $k := k + 1$, 返回步骤(2).

7.2.3 计算举例

例 7-2 用牛顿法求函数 $f(x) = \int_0^x \arctan t dt$ 的极小点, 取 $x_1 = 1, \varepsilon = 0.01$.

解 因 $f'(x) = \arctan x, f''(x) = \frac{1}{1+x^2}$, 取 $x_1 = 1$, 计算

$$f'(x_1) = 0.7854, \quad \frac{1}{f''(x_1)} = 2$$

故有 $x_2 = x_1 - \frac{f'(x_1)}{f''(x_1)} = -0.5708$. 同理有

$$x_3 = x_2 - \frac{f'(x_2)}{f''(x_2)} = -0.5708 - (-0.5178) \times 1.3258 = 0.1169$$

$$x_4 = x_3 - \frac{f'(x_3)}{f''(x_3)} = 0.1169 - 0.1163 \times 1.0137 = -0.00106$$

而 $|f'(x_4)| \approx 0.0010 < 0.01$, 故迭代停止, 输出近似极小解 $x^* \approx -0.00106$.

本例精确解应是 $x^* = 0$, 因此牛顿法经过 3 次迭代已非常接近最优解.

牛顿法的收敛速度相当快, 但是它要求计算函数在一系列迭代点上的一阶导数和二阶导数值, 这往往很不方便甚至是不可能的. 要注意的是, 牛顿法的初始点 x_1 的选择非常重要, 要求 x_1 充分接近 x^* , 否则点列 $\{x_k\}$ 就有可能不收敛于极小点.

顺便提一下, 牛顿法的思想可以直接推广到求多元函数 $f(x) = f(x_1, x_2, \dots, x_n)$ 的无约束极值问题. 只是公式(7-8)中的 $f'(x_k)$ 应为 $\nabla f(x^{(k)})$, $\frac{1}{f''(x_k)}$ 应为 $[\nabla^2 f(x^{(k)})]^{-1}$, 见第 8 章.

此外, 牛顿法又叫切线法, 说的是牛顿法的几何意义, 即 x_{k+1} 是函数 $f'(x)$ 在 x_k 处的切线与 x 轴的交点, 以次类推, 牛顿法的迭代公式也可以通过其几何意义推导出来. 有关牛顿法的几何意义的详细解释见参考文献[9].

7.3 抛物线逼近法

抛物线逼近法又叫三点二次插值法,其基本思想是在极小点附近,用二次三项式 $\varphi(x)$ 逼近目标函数 $f(x)$.

设 x_1, x_2, x_3 为 $f(x)$ 的极小点附近三点,且满足以下条件:

$$x_1 < x_2 < x_3$$

$$f(x_1) > f(x_2), \quad f(x_3) > f(x_2)$$

则称 x_1, x_2, x_3 为“两头大中间小”的三点. 抛物线逼近法就是过三点 $(x_1, f(x_1))$ 、 $(x_2, f(x_2))$ 和 $(x_3, f(x_3))$ 作抛物线 $\varphi(x)$, 然后求 $\varphi(x)$ 的极小点作为 $f(x)$ 的近似极小点. 如果不满足精度要求,则需要迭代直到满足精度要求为止. 下面简要介绍抛物线逼近法的基本原理,并给出迭代公式.

7.3.1 经过三点 $(x_1, f(x_1))$ 、 $(x_2, f(x_2))$ 和 $(x_3, f(x_3))$ 作抛物线 $\varphi(x)$

假设 x_1, x_2, x_3 为“两头大中间小”的三点,令

$$\varphi(x) = ax^2 + bx + c$$

其中, a, b, c 是待定系数,可通过求解以下线性方程组得到:

$$\begin{cases} \varphi(x_1) = ax_1^2 + bx_1 + c = f(x_1) \\ \varphi(x_2) = ax_2^2 + bx_2 + c = f(x_2) \\ \varphi(x_3) = ax_3^2 + bx_3 + c = f(x_3) \end{cases} \quad (7-9)$$

7.3.2 用抛物线 $\varphi(x)$ 的极小点作为 $f(x)$ 的近似极小点

令

$$\varphi'(x) = 2ax + b = 0$$

则

$$x = -\frac{b}{2a}$$

由方程组(7-9)消去 c , 得

$$b = \frac{(x_2^2 - x_3^2)f(x_1) + (x_3^2 - x_1^2)f(x_2) + (x_1^2 - x_2^2)f(x_3)}{(x_1 - x_2)(x_2 - x_3)(x_3 - x_1)}$$

$$a = \frac{(x_2 - x_3)f(x_1) + (x_3 - x_1)f(x_2) + (x_1 - x_2)f(x_3)}{(x_1 - x_2)(x_2 - x_3)(x_3 - x_1)}$$

即

$$x = \frac{1}{2} \cdot \frac{(x_2^2 - x_3^2)f(x_1) + (x_3^2 - x_1^2)f(x_2) + (x_1^2 - x_2^2)f(x_3)}{(x_2 - x_3)f(x_1) + (x_3 - x_1)f(x_2) + (x_1 - x_2)f(x_3)} = x_k \quad (7-10)$$

把 $\varphi(x)$ 的驻点 x 记作 x_k 作为 $f(x)$ 极小点的一个估计值.

7.3.3 迭代

求出 x_k 以后,从 x_1, x_2, x_3, x_k 中选择目标函数值最小的点(实际上只要比较 $f(x_1)$ 和 $f(x_k)$ 即可.想一想,为什么?)及其左、右两个邻点,令其中目标函数值最小的点为 x_2 ,其左右两个邻点分别为 x_1 和 x_3 ,这样就得到新的“两头大中间小”的三点(注意新三点中 x_1 和 x_3 之间的距离变小了),然后代入公式(7-10)求出新的估计值 x_{k+1} ,以此类推,产生一个点列,在一定条件下,这个点列收敛于 $f(x)$ 的极小点.

值得注意的是,三个初始点 x_1, x_2, x_3 必须满足

$$\begin{aligned} x_1 < x_2 < x_3 \\ f(x_1) > f(x_2), \quad f(x_3) > f(x_2) \end{aligned}$$

才能保证 $\varphi(x)$ 的二次项系数 $a > 0$ (即抛物线图像开口朝上),且 $\varphi(x)$ 的极小点在 $[x_1, x_3]$ 内,因此利用公式(7-10)迭代前必须求出满足上述条件的三个初始点.在下一节将介绍解决这个问题的外推内插法.

7.4 外推内插法

黄金分割法和抛物线逼近法等一维搜索方法都要事先给定一个包含极小点的初始搜索区间,外推内插法就是用来解决这个问题的.外推内插法又叫加步探索法,它本身就是一种区间试探法.主要思路就是从一点出发,按一定的步长,试图确定出函数值呈现“高一低一高”(即“两头大中间小”)的三点.首先从一个方向去找,若不成功,就退回来,再沿反方向寻找,若方向正确,则加大步长进行探索,最终找到 x_1, x_2, x_3 三点,满足

$$\begin{aligned} x_1 < x_2 < x_3 \\ f(x_1) > f(x_2), \quad f(x_3) > f(x_2) \end{aligned}$$

为止.

7.4.1 基本原理与步骤

1. 给定初始区间,初始点 x_1 及初始步长 $h_0 > 0$
2. 用加倍步长的外推法找出初始区间

由初始点 x_1 向某个方向,比如向 x 增大的方向走一步,步长为 h_0 ,得 $x_2 = x_1 + h_0$,计算函数值 $f(x_1)$ 、 $f(x_2)$ 并比较它们的大小.

(1) 若 $f(x_2) < f(x_1)$,说明方向选对了,则步长加倍,继续往前走,有 $x_3 = x_2 + 2h_0$.若仍有 $f(x_3) < f(x_2)$,则将步长再加倍,有 $x_4 = x_3 + 4h_0, \dots$,直到 x_k 点的函数值刚刚变为增加为止.这样就得到满足“两头大中间小”的三点:

$$\begin{aligned} x_{k-2} < x_{k-1} < x_k \\ f(x_{k-2}) > f(x_{k-1}), \quad f(x_k) > f(x_{k-1}) \end{aligned}$$

故极小点一定在区间 $[x_{k-2}, x_k]$ 上,可舍弃初始区间的其他部分,上述过程见图 7-3a.

(2) 若 $f(x_2) > f(x_1)$,说明方向选错了,因此仍由 x_1 出发向相反方向(x 减小方向)走一步:有 $x_3 = x_1 - h_0$,若此时有 $f(x_3) < f(x_1)$,说明方向正确,仍需要在此方向上迈出,取 $x_4 = x_3 - 2h_0$;若仍有 $f(x_4) < f(x_3)$,则加倍步长继续同方向迈出, $x_5 = x_4 - 4h_0, \dots$,直到函




图 7-3

数值刚刚变为增加为止. 这样就得到满足“两头大中间小”的三点:

$$x_k < x_{k-1} < x_{k-2}$$

$$f(x_k) > f(x_{k-1}), \quad f(x_{k-2}) > f(x_{k-1})$$

故极小点一定在区间 $[x_k, x_{k-2}]$ 上, 上述过程见图 7-3b.

3. 在 x_{k-1}, x_k 之间插一点, 再一次缩短并最后确定极值点存在区间
在上述三个点 x_{k-2}, x_{k-1}, x_k 之间, 因为步长是逐次加倍的, 故有

$$x_k - x_{k-1} = 2(x_{k-1} - x_{k-2})$$

现于 x_{k-1}, x_k 之间内插一点 x_{k+1} , 令

$$x_{k+1} = \frac{1}{2}(x_{k-1} + x_k)$$

这样得到等距的四个点: $x_{k-2}, x_{k-1}, x_{k+1}, x_k$.

比较上述 4 个点的函数值, 令其中函数值最小的点为 x_2 , x_2 的左右邻点为 x_1 和 x_3 , 至此得到了尽可能小的极值点存在区间 $[x_1, x_3]$, 且 x_1, x_2, x_3 三点满足“两头大中间小”的条件:

$$x_1 < x_2 < x_3$$

$$f(x_1) > f(x_2), \quad f(x_3) > f(x_2)$$

从以上步骤可以看出, 外推内插法实际上分为外推和内插两个阶段.

7.4.2 计算举例

在外推内插法中, 若能估计最优解大体位置的话, 初始点 x_1 要尽量取接近函数最优解的值. 步长为 h_0 , 倍数一般取两倍.

例 7-3 用外推内插法确定一维最小化问题

$$\min_{x \geq 0} f(x) = x^3 - 2x + 1$$

的搜索区间, 要求选取 $x_1 = 0, h_0 = 1$, 步长加倍倍数为 2.

解 取 $x_1 = 0$, 令 $x_2 = x_1 + h_0 = 0 + 1 = 1$, 计算函数值并作比较: $f(x_1) = 1, f(x_2) = 0$, 故有 $f(x_2) < f(x_1)$, 说明走的方向正确; 取步长 $h_1 = 2h_0 = 2$, 即有 $x_3 = x_2 + 2h_0 = 1 + 2 = 3$, 计算函数值: $f(x_3) = f(3) = 22$, 即 $f(x_3) > f(x_2)$. 对 x_1, x_2, x_3 , 有

$$x_1 < x_2 < x_3$$

且有

$$f(x_1) > f(x_2), \quad f(x_3) > f(x_2)$$

在 x_2 和 x_3 之间插入 x_4 点:

$$x_4 = \frac{1}{2}(x_2 + x_3) = \frac{1}{2}(1 + 3) = 2$$

$f(x_4) = 5$, 比较 $f(x_1)$ 、 $f(x_2)$ 、 $f(x_3)$ 、 $f(x_4)$ 可见, $f(x_2) = 0$ 为最小值, 因此 $[x_1, x_4]$ 为初始区间, 函数 $f(x)$ 的极小点位于该区间 $[0, 2]$ 之中.

习 题

7-1 用黄金分割法求解

$$\min f(x) = 2x^2 - x - 1$$

初始区间为 $[-1, 1]$, 区间精度 $\delta = 0.06$.

7-2 用外推内插法确定一维优化问题

$$\min_{0 \leq x \leq 10} f(x) = (x - 3)\sqrt{x}$$

的一个搜索区间, 要求取 $x_1 = 0$, $h_0 = 0.2$.

7-3 用牛顿法求 $f(x) = e^x - 5x$ 在区间 $[1, 2]$ 上的极小点的近似值(只迭代3次), 给定初始点 $x_1 = 1$.

7-4 用抛物线法求 $f(x) = x^2 - 6x + 2$ 的近似极小点, 给定初始点 $x_1 = 1$, 初始步长 $h_0 = 0.1$.

7-5 用抛物线法进行一维搜索求

$$\min_{x \geq 0} f(x) = x^3 - 2x + 1$$

的近似最优解, 设初始搜索区间为 $[0, 3]$, 初始插值点为 $x_1 = 1$, 算法终止条件为

$$|x_{k+1} - x_k| < \delta = 0.01$$

第8章 无约束问题最优化方法

关于“无约束问题的极值条件”和“下降迭代类算法”已在第7章中做过介绍,本章介绍几种常用的无约束条件下多变量函数的最优化方法.

无约束问题的最优化方法大致分为两类:一类在计算过程中只用到目标函数值,而无需计算导数,通常称为直接搜索法;另一类在计算过程中需要计算目标函数的导数,称为解析法或使用导数的最优化方法.各种不同的无约束问题的最优化方法的根本不同之处在于迭代过程中选择的搜索方向不同.变量轮换法、可变单纯形法和模式搜索法等属于直接搜索法,而最速下降法、牛顿法、共轭梯度法和拟牛顿法等属于后一类.本章先介绍直接法,再介绍几种使用导数的方法.

8.1 变量轮换法

在求解无约束非线性规划问题时,如果遇到问题的目标函数不可导或导函数的解析式难以表示时,人们一般需要使用直接搜索方法.同时,由于这些方法一般都比较直观和易于理解,因而在实际应用中常为人们所采用.变量轮换法又叫坐标轮换法(Cyclic Coordinate Method),是一种最简单的直接搜索方法,也称为交替方向法(Alternating Directions Method).

8.1.1 基本原理

变量轮换法是多变量函数寻优方法中原理最简单的一种方法,它把多变量函数的优化问题转化为一系列单变量函数的优化问题来解.其基本思路是:该方法认为有利的搜索方向是各坐标轴方向,因此它轮流按各坐标轴方向搜索最优点.从某一给定点出发,按第 i 个坐标轴 x_i 的方向搜索时,在 n 个变量中,只有单变量 x_i 在变化,其余 $n-1$ 个变量都取给定点的坐标值保持不变.这样依次从 x_1 到 x_n 作了 n 次单变量的一维搜索,完成了变量轮换法的一次迭代,如果所得到的新点尚未满足给定精度的要求,则以新点为出发点进行新一轮的迭代,这个过程可以重复下去直到所得到的新点满足给定的精度为止.

8.1.2 算法步骤

设 e_i 为第 i 个坐标轴的单位向量,即

$$e_i = \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \quad (i = 1, 2, \dots, n)$$

(1) 给定初始点 $\mathbf{x}^{(1)} = (c_1, c_2, \dots, c_n)^T$, 其中 $c_1, c_2, \dots, c_n$ 为常数.

(2) 从 $\mathbf{x}^{(1)}$ 出发, 先沿第一个坐标轴方向 $\mathbf{e}_1$ 进行一维搜索, 求出最优步长 λ_1 , 得新点 $\mathbf{x}^{(2)}$, 即

$$\begin{cases} f(\mathbf{x}^{(2)}) = f(\mathbf{x}^{(1)} + \lambda_1 \mathbf{e}_1) = \min_{\lambda} f(\mathbf{x}^{(1)} + \lambda \mathbf{e}_1) \\ \mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda_1 \mathbf{e}_1 \end{cases} \quad (8-1)$$

其中, $f(\mathbf{x}^{(1)} + \lambda \mathbf{e}_1)$ 是步长 λ 的一维函数, $f(\mathbf{x}^{(1)} + \lambda \mathbf{e}_1)$ 的极小点 λ_1 就是 $\mathbf{e}_1$ 方向上的最优步长. 上式表明: 从 $\mathbf{x}^{(1)}$ 出发, 沿 $\mathbf{e}_1$ 进行一维搜索, 最优步长为 λ_1 , 可求得新点 $\mathbf{x}^{(2)}$. 显然新点 $\mathbf{x}^{(2)}$ 与 $\mathbf{x}^{(1)}$ 相比, 只有 x_1 的坐标值不同.

类似地, 以 $\mathbf{x}^{(2)}$ 为出发点, 沿第二个坐标轴方向 $\mathbf{e}_2$ 进行一维搜索, 求出最优步长 λ_2 , 得新点 $\mathbf{x}^{(3)}$:

$$\begin{cases} f(\mathbf{x}^{(3)}) = f(\mathbf{x}^{(2)} + \lambda_2 \mathbf{e}_2) = \min_{\lambda} f(\mathbf{x}^{(2)} + \lambda \mathbf{e}_2) \\ \mathbf{x}^{(3)} = \mathbf{x}^{(2)} + \lambda_2 \mathbf{e}_2 \end{cases} \quad (8-2)$$

就这样依次沿各坐标轴方向进行一维搜索, 直到 n 个坐标轴方向全部搜索一遍, 最后可得到点 $\mathbf{x}^{(n+1)}$:

$$\begin{cases} f(\mathbf{x}^{(n+1)}) = f(\mathbf{x}^{(n)} + \lambda_n \mathbf{e}_n) = \min_{\lambda} f(\mathbf{x}^{(n)} + \lambda \mathbf{e}_n) \\ \mathbf{x}^{(n+1)} = \mathbf{x}^{(n)} + \lambda_n \mathbf{e}_n \end{cases} \quad (8-3)$$

从初始点 $\mathbf{x}^{(1)}$ 出发, 经上述 n 个坐标轴方向的一维搜索得到点 $\mathbf{x}^{(n+1)}$, 就完成了变量轮换法的一次迭代.

(3) 令 $\mathbf{x}^{(1)} = \mathbf{x}^{(n+1)}$, 返回步骤(2)继续迭代.

以上步骤一直进行到所得新点 $\mathbf{x}^{(n+1)}$ 满足给定精度为止.

变量轮换法的基本原理非常简单, 它对目标函数的解析性质没有特别的要求, 适用于各变量之间本质上无联系或沿各坐标轴方向搜索比较容易的特殊结构. 而对一般的目标函数, 它的收敛速度较慢, 搜索效率低. 但是变量轮换法的依次沿各坐标轴方向寻优的思想, 是多变量函数寻优的一种基本思想, 在这种思想的基础上, 又发展出了模式搜索法(见本章下一节)及旋转方向法等(有兴趣的读者可参阅参考文献[13]).

8.1.3 计算举例

例 8-1 用变量轮换法求解

$$\min f(\mathbf{x}) = 3x_1^2 + 2x_2^2 + x_3^2$$

已知初始点 $\mathbf{x}^{(1)} = (1, 2, 3)^T$, 当 $\|\mathbf{x}^{(n+1)} - \mathbf{x}^{(1)}\| < 0.01$ 时停止迭代.

解 令 $\mathbf{e}_1 = (1, 0, 0)^T, \mathbf{e}_2 = (0, 1, 0)^T, \mathbf{e}_3 = (0, 0, 1)^T$. 首先从初始点 $\mathbf{x}^{(1)} = (1, 2, 3)^T$ 出发, 沿 x_1 轴方向 $\mathbf{e}_1$ 进行一维搜索:

$$\mathbf{x}^{(1)} + \lambda \mathbf{e}_1 = (1, 2, 3)^T + \lambda(1, 0, 0)^T = (1 + \lambda, 2, 3)^T$$

则有

$$f(\mathbf{x}^{(1)} + \lambda \mathbf{e}_1) = 3 \cdot (1 + \lambda)^2 + 2 \cdot 2^2 + 3^2 = 3(1 + \lambda)^2 + 17$$

现在 $f(\mathbf{x}^{(1)} + \lambda \mathbf{e}_1)$ 是关于 λ 的一元函数, 令

$$f'_\lambda = 6(1 + \lambda) = 0$$

则

$$\lambda_1 = -1$$

故

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda \mathbf{e}_1 = (1, 2, 3)^T + (-1)(1, 0, 0)^T = (0, 2, 3)^T$$

$$f(\mathbf{x}^{(2)}) = 17$$

再从初始点 $\mathbf{x}^{(2)} = (0, 2, 3)^T$ 出发, 沿 x_2 轴方向 $\mathbf{e}_2$ 进行一维搜索:

$$\mathbf{x}^{(2)} + \lambda \mathbf{e}_2 = (0, 2, 3)^T + \lambda(0, 1, 0)^T = (0, 2 + \lambda, 3)^T,$$

$$f(\mathbf{x}^{(2)} + \lambda \mathbf{e}_2) = 2 \cdot (2 + \lambda)^2 + 9$$

令

$$f'_\lambda = 4(2 + \lambda) = 0$$

有

$$\lambda_2 = -2$$

故

$$\mathbf{x}^{(3)} = \mathbf{x}^{(2)} + \lambda_2 \mathbf{e}_2 = (0, 2, 3)^T + (-2)(0, 1, 0)^T = (0, 0, 3)^T$$

$$f(\mathbf{x}^{(3)}) = 9$$

再从初始点 $\mathbf{x}^{(3)} = (0, 0, 3)^T$ 出发, 沿 x_3 轴方向 $\mathbf{e}_3$ 进行一维搜索:

$$\mathbf{x}^{(3)} + \lambda \mathbf{e}_3 = (0, 0, 3)^T + \lambda(0, 0, 1)^T = (0, 0, 3 + \lambda)^T,$$

$$f(\mathbf{x}^{(3)} + \lambda \mathbf{e}_3) = (\lambda + 3)^2$$

令

$$f'_\lambda = 2(\lambda + 3) = 0$$

有

$$\lambda_3 = -3$$

故

$$\mathbf{x}^{(4)} = \mathbf{x}^{(3)} + \lambda_3 \mathbf{e}_3 = (0, 0, 3)^T + (-3)(0, 0, 1)^T = (0, 0, 0)^T$$

$$f(\mathbf{x}^{(4)}) = 0$$

因为 $\|\mathbf{x}^{(4)} - \mathbf{x}^{(1)}\| > 0.01$, 故以 $\mathbf{x}^{(4)}$ 作为新的 $\mathbf{x}^{(1)}$ 进行新一轮迭代.

令

$$\mathbf{x}^{(1)} = \mathbf{x}^{(4)} = (0, 0, 0)^T$$

以 $\mathbf{x}^{(1)}$ 为起点, 沿 $\mathbf{e}_1$ 方向进行一维搜索:

$$\mathbf{x}^{(1)} + \lambda \mathbf{e}_1 = (0, 0, 0)^T + \lambda(1, 0, 0)^T = (\lambda, 0, 0)^T,$$

则有

$$f(\mathbf{x}^{(1)} + \lambda \mathbf{e}_1) = 3 \cdot \lambda^2$$

令

$$f'_\lambda = 6\lambda = 0$$

有

$$\lambda = 0$$

故有

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda \mathbf{e}_1 = (0, 0, 0)^T + 0(1, 0, 0)^T = (0, 0, 0)^T$$

同理可得

$$\mathbf{x}^{(3)} = \mathbf{x}^{(4)} = (0, 0, 0)^T$$

现有

$$\|\mathbf{x}^{(4)} - \mathbf{x}^{(1)}\| = 0 < 0.01$$

故 $\mathbf{x}^{(4)} = (0, 0, 0)^T$ 即为极小点, $f(\mathbf{x}^{(4)}) = 0$.

8.2 模式搜索方法

模式搜索方法 (Pattern Search Method) 是 R. Hooke 和 T. A. Jeeves 于 1961 年提出的, 因此也称为 Hook - Jeeves 方法. 此方法有明显的几何意义, 为介绍这种方法, 从求一个二元函数的极小点谈起. 这相当于寻找某个曲面的最低点, 或者形象地说, 相当于从一座山岭的某处出发, 设法走到附近某一盆地的最低点. 怎样才能尽快达到这一目标呢? 很显然, 如果能找到一条山谷, 沿山谷行进是最好的方法.

模式搜索方法就是根据上述思想设计的. 它由两部分组成, 包括探测移动和模式移动.

利用这种算法建立的迭代点移动不需要使用一维搜索技巧.

8.2.1 探测移动

这种移动是在某个已知点附近,沿坐标轴 e_i 方向进行探测,其目的是获得一个更小值的点.

取初始点 $x^{(1)}$,探测移动的具体过程如下:

记 $t_1^{(1)} = x^{(1)}$,先在坐标方向 e_1 上作探测,设 α 是固定步长,如果

$$f(t_1^{(1)} + \alpha e_1) < f(t_1^{(1)})$$

则沿 e_1 方向探测成功,置 $t_2^{(1)} = t_1^{(1)} + \alpha e_1$;否则探测失败,考虑相反的方向. 如果

$$f(t_1^{(1)} - \alpha e_1) < f(t_1^{(1)})$$

则沿 $-e_1$ 方向探测成功,置 $t_2^{(1)} = t_1^{(1)} - \alpha e_1$;否则探测失败,置 $t_2^{(1)} = t_1^{(1)}$.

再沿 e_2 方向进行探测,如果 $f(t_2^{(1)} + \alpha e_2) < f(t_2^{(1)})$,则置 $t_3^{(1)} = t_2^{(1)} + \alpha e_2$;否则若 $f(t_2^{(1)} - \alpha e_2) < f(t_2^{(1)})$,则置 $t_3^{(1)} = t_2^{(1)} - \alpha e_2$;否则置 $t_3^{(1)} = t_2^{(1)}$.

重复以上过程,最后得到 $t_{n+1}^{(1)}$.

8.2.2 模式移动

在探测移动后,若 $f(t_{n+1}^{(1)}) < f(x^{(1)})$,则作模式移动,即令

$$\begin{cases} x^{(2)} = t_{n+1}^{(1)}, \\ t_1^{(2)} = x^{(2)} + (x^{(2)} - x^{(1)}) \end{cases} \quad (8-4)$$

8.2.3 算法的基本思想

算法的基本思想是将探测移动和模式移动有机地结合在一起. 设已得到 $x^{(k)}$ 和 $t_1^{(k)}$,从 $t_1^{(k)}$ 出发,沿各个坐标轴作探测移动得到 $t_2^{(k)}, t_3^{(k)}, \dots, t_{n+1}^{(k)}$.

如果 $f(t_{n+1}^{(k)}) < f(t^{(k)})$,则作模式移动,即令

$$\begin{cases} t^{(k+1)} = t_{n+1}^{(k)} \\ t_1^{(k+1)} = t^{(k+1)} + (t^{(k+1)} - t^{(k)}) \end{cases} \quad (8-5)$$

置 $k := k + 1$,重复上述计算,如果

$$f(t_{n+1}^{(k)}) \geq f(t^{(k)}) \quad (8-6)$$

分两种情况讨论:

(1) 若 $t_1^{(k)} \neq x^{(k)}$,则 $t_1^{(k)}$ 是由上一次的模式移动得到的,而式(8-6)表明该模式移动使目标函数值上升,即模式移动失败,应将 $t_1^{(k)}$ 退回到 $x^{(k)}$ 处,即令 $t_1^{(k)} = x^{(k)}$,重复上述计算.

(2) 若 $t_1^{(k)} = x^{(k)}$,这说明上次的模式移动失败,且在 $t_1^{(k)}$ 周围的探测移动全部失败. 这是由于步长 α 过大的原因引起的,应减少步长,再重复上述计算.

8.2.4 算法终止准则

当步长 α 充分小,就认为 $x^{(k)}$ 在极小点附近了,终止计算. 因此终止准则为

$$\alpha < \varepsilon \quad (8-7)$$

其中, ε 是预先给定的精度.

8.2.5 算法步骤

(1) 取初始点 $x^{(1)}$, 初始步长 $\alpha > 0$, 精度要求 $\varepsilon > 0$, 令 $t_1 = x^{(1)}$, $k = 1$.

(2) 对于 $i = 1, 2, \dots, n$, 进行如下操作或计算:

如果 $f(t_i + \alpha e_i) < f(t_i)$, 则令 $t_{i+1} = t_i + \alpha e_i$; 否则若 $f(t_i - \alpha e_i) < f(t_i)$, 则令 $t_{i+1} = t_i - \alpha e_i$; 否则令 $t_{i+1} = t_i$.

(3) $f(t_{n+1}) < f(x^{(k)})$, 则令

$$\begin{cases} t^{(k+1)} = t_{n+1} \\ t_1 = t^{(k+1)} + (t^{(k+1)} - t^{(k)}) \end{cases}$$

令 $k := k + 1$, 转第(2)步.

(4) 若 $t_1 \neq t^{(k)}$, 则令 $t_1 = t^{(k)}$, 转步骤(2).

(5) 若 $\alpha < \varepsilon$, 则停止计算; 否则令 $\alpha = \alpha/2$, 转步骤(2).

8.2.6 计算举例

例 8-2 用模式搜索法求解无约束问题

$$\min f(x) = (x_1 - 1)^2 + 5(x_1^2 - x_2)^2$$

取初始点 $x^{(1)} = (2, 0)^T$, 步长 $\alpha = \frac{1}{2}$.

解 令 $t_1 = x^{(1)} = (2, 0)^T$, $f(t_1) = 81$, 首先在 e_1 方向上做探测移动:

$$t_1 + \alpha e_1 = (2, 0)^T + \frac{1}{2}(1, 0)^T = \left(\frac{5}{2}, 0\right)^T$$

$$f(t_1 + \alpha e_1) = 197 \frac{9}{16} > f(t_1)$$

$$t_1 - \alpha e_1 = (2, 0)^T - \frac{1}{2}(1, 0)^T = \left(\frac{3}{2}, 0\right)^T$$

$$f(t_1 - \alpha e_1) = 25 \frac{9}{16} < f(t_1)$$

所以

$$t_2 = t_1 - \alpha e_1 = \left(\frac{3}{2}, 0\right)^T, \quad f(t_2) = 25 \frac{9}{16}$$

再在 e_2 方向上做探测移动:

$$t_2 + \alpha e_2 = \left(\frac{3}{2}, 0\right)^T + \frac{1}{2}(0, 1)^T = \left(\frac{3}{2}, \frac{1}{2}\right)^T$$

$$f(t_2 + \alpha e_2) = 15 \frac{9}{16} < f(t_2)$$

所以

$$t_3 = t_2 + \alpha e_2 = \left(\frac{3}{2}, \frac{1}{2}\right)^T, \quad f(t_3) = 15 \frac{9}{16}$$

探测移动完成.

因为 $f(t_3) < f(x^{(1)}) = 81$, 作模式移动, 令

$$\begin{cases} x^{(2)} = t_3 = \left(\frac{3}{2}, \frac{1}{2}\right)^T \\ t_1 = x^{(2)} + (x^{(2)} - x^{(1)}) = 2x^{(2)} - x^{(1)} \\ \quad = 2\left(\frac{3}{2}, \frac{1}{2}\right)^T - (2, 0)^T = (1, 1)^T \end{cases}$$

第一轮计算完成.

作第二轮计算, 从 t_1 出发作探测移动, 对于 e_1 方向有

$$f(t_1) = 0, \quad f(t_1 + \alpha e_1) = 8 \frac{1}{16} > f(t_1)$$

$$f(t_1 - \alpha e_1) = 3 \frac{1}{16} > f(t_1)$$

所以 $t_2 = t_1 = (1, 1)^T$. 对于 e_2 方向有

$$f(t_2) = 0, \quad f(t_2 + \alpha e_2) = 1 \frac{1}{4} > f(t_2)$$

$$f(t_2 - \alpha e_2) = 1 \frac{1}{4} > f(t_2)$$

所以 $t_3 = t_2 = (1, 1)^T$, $f(t_3) = 0$.

因为 $f(t_3) < f(x^{(2)}) = 15 \frac{9}{16}$, 再作模式移动

$$\begin{cases} x^{(3)} = t_3 = (1, 1)^T \\ t_1 = x^{(3)} + (x^{(3)} - x^{(2)}) = 2x^{(3)} - x^{(2)} \\ \quad = 2(1, 1)^T - \left(\frac{3}{2}, \frac{1}{2}\right)^T \\ \quad = \left(\frac{1}{2}, \frac{3}{2}\right)^T \end{cases}$$

第二轮计算完成.

作第三轮计算, 从 t_1 出发作探测移动, 对于 e_1 方向有

$$f(t_1) = 8 \frac{1}{16}, \quad f(t_1 + \alpha e_1) = 1 \frac{1}{4} < f(t_1)$$

所以 $t_2 = t_1 + \alpha e_1 = \left(1, \frac{3}{2}\right)^T$, $f(t_2) = 1 \frac{1}{4}$. 对于 e_2 方向有

$$f(t_2) = 1 \frac{1}{4}, \quad f(t_2 + \alpha e_2) = 5, \quad f(t_2 - \alpha e_2) = 0 < f(t_2)$$

此时, $f(t_3) = f(x^{(3)})$, 而 $t_1 \neq x^{(3)}$, 说明第二轮中的探测移动失败, 将 t_1 退回 $x^{(3)}$ 处, 即取

$t_1 = x^{(3)} = \left(1, 1\right)^T$, 再作探测移动, 我们发现全部探测移动失败, 减小步长 $\alpha = \frac{1}{2} = \frac{1}{4}$.

再次作探测移动, 仍然失败, 再次减小步长, 最后得到最优解 $x^{(3)} = (1, 1)^T$.

8.3 可变单纯形法

可变单纯形法也是一种直接搜索方法,最初是由 W. Spendley, G. R. Hext 和 F. R. Himsworth 设计的(1962 年),随后为 J. Nelder, R. Mead 所改进(1964 年).

这里的单纯形指的是 n 维欧氏空间 $\mathbb{R}^n$ 中具有 $n+1$ 个顶点的凸多面体. 例如,一维空间的线段、二维空间的三角形、三维空间的四面体等,均为相应空间的单纯形.

可变单纯形法的基本思想是,给定 $\mathbb{R}^n$ 中的一个单纯形,求出 $n+1$ 个顶点的函数值,并确定这些函数值中的最大值、次大值和最小值,然后通过反射、扩张、内缩、缩边等方法(几种方法不一定同时使用)求出一个较好点,用它取代最大值的点,以构成新的单纯形,通过多次迭代逼近极小点,迭代过程中逐渐把单纯形向最优点移动.

考虑无约束最小化问题:

$$\min f(x), \quad x \in \mathbb{R}^n$$

设 $x^{(1)}, x^{(2)}, \dots, x^{(n+1)}$ 是构成单纯形的 $\mathbb{R}^n$ 中的 $n+1$ 个顶点,并定义这些顶点中的最大值点 $x^{(H)}$,次大值点 $x^{(G)}$ 和最小值点 $x^{(L)}$ 分别为满足以下条件的点:

$$\begin{cases} f_H = f(x^{(H)}) = \max \{ f(x^{(1)}), f(x^{(2)}), \dots, f(x^{(n+1)}) \} \\ f_G = f(x^{(G)}) = \max_{1 \leq i \leq n+1} \{ f(x^{(i)}) \mid x^{(i)} \neq x^{(H)} \} \\ f_L = f(x^{(L)}) = \min \{ f(x^{(1)}), f(x^{(2)}), \dots, f(x^{(n+1)}) \} \end{cases} \quad (8-8)$$

其中, f_H, f_G, f_L 为 $n+1$ 个顶点中函数的最大值、次大值和最小值.

8.3.1 基本原理和步骤

(1) 给定初始单纯形,其顶点为

$$x^{(i)} \in \mathbb{R}^n \quad (i = 1, 2, \dots, n+1)$$

反射系数 $\alpha > 0$, 扩展系数 $\gamma > 1$, 压缩系数 $\beta \in (0, 1)$, 允许误差 $\varepsilon > 0$, 计算函数值

$$f(x^{(i)}), \quad (i = 1, 2, \dots, n+1)$$

并置 $k = 1$.

(2) 按式(8-8)确定最大值点 $x^{(H)}$, 次大值点 $x^{(G)}$ 和最小值点 $x^{(L)}$, 其中

$$H, G, L \in \{1, 2, \dots, n+1\}$$

计算出相应的 f_H, f_G, f_L , 计算除 $x^{(H)}$ 以外的 n 个顶点的形心 $\bar{x}$, 令

$$\bar{x} = \frac{1}{n} \left[\sum_{i=1}^{n+1} x^{(i)} - x^{(H)} \right]$$

再计算 $f(\bar{x})$.

以下各步骤就是要找到一个较好点,用以取代最大值点 $x^{(H)}$,以构成新的单纯形.

(3) 确定有利的搜索方向.

可变单纯形法认为,极小点在最大值点与其余点的形心的连线上的可能性较大,此方法力图在上述方向上找到一个较好点.

(4) 进行反射,令

$$x^{(n+2)} = \bar{x} + \alpha(\bar{x} - x^{(H)}) \quad (8-9)$$

计算 $f(\mathbf{x}^{(n+2)})$.

(5) 若 $f(\mathbf{x}^{(n+2)}) < f(\mathbf{x}^{(L)})$, 则进行扩展, 令

$$\mathbf{x}^{(n+3)} = \bar{\mathbf{x}} + \gamma(\mathbf{x}^{(n+2)} - \mathbf{x}^{(H)}) \quad (8-10)$$

计算 $f(\mathbf{x}^{(n+3)})$, 转步骤(6).

若 $f(\mathbf{x}^{(L)}) \leq f(\mathbf{x}^{(n+2)}) \leq f(\mathbf{x}^{(G)})$, 则置 $\mathbf{x}^{(H)} = \mathbf{x}^{(n+2)}$, $f(\mathbf{x}^{(H)}) = f(\mathbf{x}^{(n+2)})$, 转步骤(8).

若 $f(\mathbf{x}^{(n+2)}) > f(\mathbf{x}^{(G)})$, 则进行压缩, 令

$$f(\mathbf{x}^{(H')}) = \min \{ f(\mathbf{x}^{(H)}), f(\mathbf{x}^{(n+2)}) \}, H' \in \{H, n+2\}$$

再令

$$\mathbf{x}^{(n+4)} = \bar{\mathbf{x}} + \beta(\mathbf{x}^{(H')} - \bar{\mathbf{x}}) \quad (8-11)$$

计算 $f(\mathbf{x}^{(n+4)})$, 转步骤(7).

(6) 若 $f(\mathbf{x}^{(n+3)}) < f(\mathbf{x}^{(n+2)})$, 则置

$$\mathbf{x}^{(H)} = \mathbf{x}^{(n+3)}, \quad f(\mathbf{x}^{(H)}) = f(\mathbf{x}^{(n+3)})$$

转步骤(8); 否则, 置 $\mathbf{x}^{(H)} = \mathbf{x}^{(n+2)}$, $f(\mathbf{x}^{(H)}) = f(\mathbf{x}^{(n+2)})$, 转步骤(8).

(7) 若 $f(\mathbf{x}^{(n+4)}) \leq f(\mathbf{x}^{(H')})$, 则置

$$\mathbf{x}^{(H)} = \mathbf{x}^{(n+4)}, \quad f(\mathbf{x}^{(H)}) = f(\mathbf{x}^{(n+4)})$$

转步骤(8); 否则, 进行收缩, 令

$$\mathbf{x}^{(i)} := \mathbf{x}^{(i)} + \frac{1}{2}(\mathbf{x}^{(L)} - \mathbf{x}^{(i)}) \quad (i = 1, 2, \dots, n+1)$$

计算 $f(\mathbf{x}^{(i)})$ ($i = 1, 2, \dots, n+1$), 转步骤(8).

(8) 检验是否满足收敛标准, 若

$$\left\{ \frac{1}{n+1} \sum_{i=1}^{n+1} [f(\mathbf{x}^{(i)}) - f(\bar{\mathbf{x}})]^2 \right\}^{\frac{1}{2}} < \varepsilon \quad (8-12)$$

则停止计算, 现行最好点可作为极小点的近似; 否则, 置 $k := k+1$, 返回步骤(2).

8.3.2 计算举例

例8-3 用可变单纯形法求解下列问题:

$$\min f(\mathbf{x}) = (x_1 - 3)^2 + 2(x_2 + 2)^2$$

取初始单纯形的顶点为

$$\mathbf{x}^{(1)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \mathbf{x}^{(2)} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{x}^{(3)} = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

$$\alpha = 1, \quad \gamma = 2, \quad \beta = \frac{1}{2}, \quad \varepsilon = 2$$

解 第一次迭代: 计算各初始顶点处的目标函数值分别为

$$f(\mathbf{x}^{(1)}) = 17, \quad f(\mathbf{x}^{(2)}) = 12, \quad f(\mathbf{x}^{(3)}) = 27$$

记顶点

$$\mathbf{x}^{(H)} = \mathbf{x}^{(3)}, \quad \mathbf{x}^{(G)} = \mathbf{x}^{(1)}, \quad \mathbf{x}^{(L)} = \mathbf{x}^{(2)}$$

进行反射, 求 $\mathbf{x}^{(3)}$ 关于 $\mathbf{x}^{(1)}$ 和 $\mathbf{x}^{(2)}$ 的形心的反射点. 先求形心 $\bar{\mathbf{x}}$ 及其函数值 $f(\bar{\mathbf{x}})$, 有

$$\bar{\mathbf{x}} = \frac{1}{2}(\mathbf{x}^{(1)} + \mathbf{x}^{(2)}) = \left(\frac{1}{2}, 0 \right)^T, \quad f(\bar{\mathbf{x}}) = \frac{57}{4}$$

计算反射点 $\mathbf{x}^{(4)}$ 及其目标函数值 $f(\mathbf{x}^{(4)})$, 有

$$\mathbf{x}^{(4)} = \bar{\mathbf{x}} + \alpha(\bar{\mathbf{x}} - \mathbf{x}^{(3)}) = (1, -1)^T, \quad f(\mathbf{x}^{(4)}) = 6$$

由于 $f(\mathbf{x}^{(4)}) < f(\mathbf{x}^{(L)})$, 故进行扩展, 令

$$\mathbf{x}^{(5)} = \bar{\mathbf{x}} + \gamma(\mathbf{x}^{(4)} - \bar{\mathbf{x}}) = \left(\frac{3}{2}, -2\right)^T$$

由于 $f(\mathbf{x}^{(5)}) = \frac{9}{4} < f(\mathbf{x}^{(4)})$, 因此用 $\mathbf{x}^{(5)}$ 替换 $\mathbf{x}^{(3)}$, 得到新的单纯形. 把 $\mathbf{x}^{(5)}$ 仍记作 $\mathbf{x}^{(3)}$, 则新的单纯形顶点为

$$\mathbf{x}^{(1)} = (0, 0)^T, \quad \mathbf{x}^{(2)} = (1, 0)^T, \quad \mathbf{x}^{(3)} = \left(\frac{3}{2}, -2\right)^T$$

由于

$$\left\{ \frac{1}{3} \sum_{i=1}^3 [f(\mathbf{x}^{(i)}) - f(\bar{\mathbf{x}})]^2 \right\}^2 = 7.23 > \varepsilon$$

不满足精度要求, 需要重新计算.

容易验证, 经过 3 次迭代, 得到的单纯形的顶点为

$$\mathbf{x}^{(1)} = \left(\frac{5}{2}, -2\right)^T, \quad \mathbf{x}^{(2)} = \left(\frac{5}{2}, -3\right)^T, \quad \mathbf{x}^{(3)} = \left(\frac{3}{2}, -2\right)^T$$

各顶点的函数值为

$$f(\mathbf{x}^{(1)}) = \frac{1}{4}, \quad f(\mathbf{x}^{(2)}) = \frac{9}{4}, \quad f(\mathbf{x}^{(3)}) = \frac{9}{4}$$

由于

$$\left\{ \frac{1}{3} \sum_{i=1}^3 [f(\mathbf{x}^{(i)}) - f(\bar{\mathbf{x}})]^2 \right\}^2 = 1.11 < \varepsilon$$

已满足精度要求, 得近似解 $\mathbf{x}^{(1)} = \left(\frac{5}{2}, -2\right)^T$. 实际上问题的极小点为 $\mathbf{x}^* = (3, -2)^T$.

关于可变单纯形法的使用效果, 有人在许多问题上进行了实验, 并取得了成功. 但也有人认为, 对于变量很多的情况, 比如 $n \geq 10$ 的问题, 是无效的.

8.4 最速下降法

本节介绍的最速下降法及后面各节将要介绍的牛顿法、共轭梯度法等都属于使用导数的最优化方法.

考虑无约束最优化问题

$$\min f(\mathbf{x}), \quad \mathbf{x} \in \mathbb{R}^n$$

其中 $f(\mathbf{x})$ 具有一阶连续偏导数.

在求解上述问题时, 人们希望选择一个使目标函数值下降最快的方向, 以迅速达到极小点. 正是基于这一点, 法国数学家于 1847 年首先提出了最速下降法 (Steepest Descent Method). 在 6.1 节介绍梯度的性质时, 已经介绍负梯度方向是函数值减小最快的方向. 最速下降法的基本思想正是在每一次迭代中, 选择最速下降方向 (负梯度方向) 作为搜索方向, 正因为如此, 最速下降法又称一阶梯度法或梯度法. 最速下降法在许多非线性规划算法的一个基础, 例如, 著名的人工神经网络反向传播算法 (即 BP 算法) 就是基于最速下降法原理的.

8.4.1 基本原理与步骤

(1) 给定初始点 $\mathbf{x}^{(1)} \in \mathbb{R}^n$, 允许误差 $\varepsilon > 0$, 并令 $k = 1$.

(2) 求 $\mathbf{x}^{(k)}$ 处梯度向量的模的值 $\|\nabla f(\mathbf{x}^{(k)})\|$, 并判断精度.

若 $\|\nabla f(\mathbf{x}^{(k)})\| < \varepsilon$, 则停止计算, 输出 $\mathbf{x}^{(k)}$ 作为近似极小点, 否则转下一步.

(3) 选择 $\mathbf{x}^{(k)}$ 处的负梯度方向作为搜索方向, 即取

$$\mathbf{d}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$$

(4) 从 $\mathbf{x}^{(k)}$ 点出发, 沿 $\mathbf{d}^{(k)}$ 进行一维搜索, 即求最优步长 λ_k , 使得

$$f(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}) = \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})$$

(5) 令 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}$, 置 $k := k + 1$, 转步骤(2).

在步骤(4)中确定最优步长可以采用任何一种一维寻优方法, 如果目标函数二阶可微的话, 还可以推导出最优步长的近似计算公式, 推导过程如下:

由于 $f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)}) = f(\mathbf{x}^{(k)} - \lambda \nabla f(\mathbf{x}^{(k)}))$ 是关于 λ 的一元函数, 因此, 可令

$$\varphi(\lambda) = f(\mathbf{x}^{(k)} - \lambda \nabla f(\mathbf{x}^{(k)}))$$

再令

$$\varphi'(\lambda) = 0$$

以解出近似最优步长 λ_k 的值.

一般情况下, 可根据单变量函数 $f(x)$ 的 Taylor 公式, 取其前三项作为 $f(x)$ 的近似式:

$$f(a+h) \approx f(a) + f'(a)h + \frac{1}{2}f''(a)h^2 \quad (\text{当 } h \rightarrow 0) \quad (8-13)$$

式(8-13)是 $f(x)$ 在点 a 的邻域 h 内的展开式.

因为 $f(\mathbf{x}^{(k)} - \lambda \nabla f(\mathbf{x}^{(k)}))$ 是关于 λ 的一元函数, 根据式(8-13), $f(x)$ 在 $\mathbf{x}^{(k)}$ 点的邻域 $(-\lambda \cdot \nabla f(\mathbf{x}^{(k)}))$ 内可展开为

$$\begin{aligned} & f(\mathbf{x}^{(k)} - \lambda \cdot \nabla f(\mathbf{x}^{(k)})) \\ & \approx f(\mathbf{x}^{(k)}) - \nabla f(\mathbf{x}^{(k)})^T \cdot \lambda \cdot \nabla f(\mathbf{x}^{(k)}) + \frac{1}{2} \lambda \cdot \nabla f(\mathbf{x}^{(k)})^T H(\mathbf{x}^{(k)}) \lambda \nabla f(\mathbf{x}^{(k)}) \\ & = \varphi(\lambda) \end{aligned}$$

令

$$\varphi'(\lambda) = 0$$

即

$$-\nabla f(\mathbf{x}^{(k)})^T \cdot \nabla f(\mathbf{x}^{(k)}) + \lambda \cdot \nabla f(\mathbf{x}^{(k)})^T \cdot H(\mathbf{x}^{(k)}) \cdot \nabla f(\mathbf{x}^{(k)}) = 0$$

可得近似最优步长 λ_k 的计算公式如下:

$$\lambda_k = \frac{\nabla f(\mathbf{x}^{(k)})^T \cdot \nabla f(\mathbf{x}^{(k)})}{\nabla f(\mathbf{x}^{(k)})^T \cdot H(\mathbf{x}^{(k)}) \cdot \nabla f(\mathbf{x}^{(k)})} \quad (8-14)$$

从式(8-14)可以看出, λ_k 不仅与 $\mathbf{x}^{(k)}$ 点的梯度有关, 还与海赛矩阵有关.

8.4.2 计算举例

例 8-4 用最速下降法求解下列问题

$$\min f(\mathbf{x}) = 2x_1^2 + x_2^2$$

给定初始点 $\mathbf{x}^{(1)} = (1, 1)^T$, $\varepsilon = \frac{1}{10}$.

解 目标函数 $f(\mathbf{x})$ 的梯度及 $\mathbf{x}^{(1)}$ 处的最速下降方向为

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 4x_1 \\ 2x_2 \end{bmatrix}, \quad \mathbf{d}^{(1)} = -\nabla f(\mathbf{x}^{(1)}) = \begin{bmatrix} -4 \\ -2 \end{bmatrix}$$

$\|\mathbf{d}^{(1)}\| = 2\sqrt{5} > \frac{1}{10}$, 不满足精度要求. 故从 $\mathbf{x}^{(1)} = (1, 1)^T$ 出发, 沿 $\mathbf{d}^{(1)}$ 方向进行一维搜索, 通过求关于 λ 的一元函数 $f(\mathbf{x}^{(1)} - \lambda \nabla f(\mathbf{x}^{(1)}))$ 的驻点可求得最优步长 $\lambda_1 = \frac{5}{18}$, 从而可得一个新点

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda_1 \mathbf{d}^{(1)} = \left(-\frac{1}{9}, \frac{4}{9}\right)^T$$

目标函数 $f(\mathbf{x})$ 在 $\mathbf{x}^{(2)}$ 处的最速下降方向为

$$\mathbf{d}^{(2)} = -\nabla f(\mathbf{x}^{(2)}) = \left(\frac{4}{9}, -\frac{8}{9}\right)^T$$

$\|\mathbf{d}^{(2)}\| = \frac{4}{9}\sqrt{5} > \frac{1}{10}$, 不满足精度要求, 需要继续迭代. 从 $\mathbf{x}^{(2)} = \left(-\frac{1}{9}, \frac{4}{9}\right)^T$ 出发, 沿方向 $\mathbf{d}^{(2)}$ 进行一维搜索, 通过求关于 λ 的一元函数 $f(\mathbf{x}^{(2)} - \lambda \nabla f(\mathbf{x}^{(2)}))$ 的驻点可求得最优步长 $\lambda_2 = \frac{5}{12}$, 从而可得一个新点

$$\mathbf{x}^{(3)} = \mathbf{x}^{(2)} + \lambda_2 \mathbf{d}^{(2)} = \left(\frac{2}{27}, \frac{2}{27}\right)^T$$

目标函数 $f(\mathbf{x})$ 在 $\mathbf{x}^{(3)}$ 处的最速下降方向为

$$\mathbf{d}^{(3)} = -\nabla f(\mathbf{x}^{(3)}) = \left(-\frac{8}{27}, -\frac{4}{27}\right)^T$$

由于 $\|\mathbf{d}^{(3)}\| > \frac{1}{10}$, 不满足精度要求, 需要继续迭代. 再从 $\mathbf{x}^{(3)}$ 出发, 沿方向 $\mathbf{d}^{(3)}$ 进行一维搜索, 通过求关于 λ 的一元函数 $f(\mathbf{x}^{(3)} - \lambda \nabla f(\mathbf{x}^{(3)}))$ 的驻点可求得最优步长 $\lambda_3 = \frac{5}{18}$, 从而可得一个新点

$$\mathbf{x}^{(4)} = \mathbf{x}^{(3)} + \lambda_3 \mathbf{d}^{(3)} = \left(-\frac{2}{243}, \frac{4}{243}\right)^T$$

此时有 $\|\nabla f(\mathbf{x}^{(4)})\| < \frac{1}{10}$, 已满足精度要求, 得到问题的近似解为

$$\bar{\mathbf{x}} = \left(-\frac{2}{243}, \frac{4}{243}\right)^T$$

实际上, 问题的最优解为 $\mathbf{x}^* = (0, 0)^T$.

8.4.3 最速下降法性能分析

最速下降法在一定条件下是收敛的. 最速下降法产生的序列是线性收敛 (Linear Convergence) 的, 而且收敛性质与极小点处海赛矩阵 $\nabla^2 f(\mathbf{x}^*)$ 的特征值有关. 我们给出一

个定理,作为一个结论,其证明过程读者可以参考本书参考文献.

定理 8-1 设 $f(x)$ 存在连续二阶偏导数, $\bar{x}$ 是局部极小点,海赛矩阵 $\nabla^2 f(\bar{x})$ 的最小特征值 $a > 0$, 最大特征值为 A , 算法产生的序列 $\{x^{(k)}\}$ 收敛于 $\bar{x}$, 则目标函数值的序列 $\{f(x^{(k)})\}$ 以不大于 $\left(\frac{A-a}{A+a}\right)^2$ 的收敛比线性地收敛于 $f(\bar{x})$.

上述定理中,若令 $r = \frac{A}{a}$, 则

$$\left(\frac{A-a}{A+a}\right)^2 = \left(\frac{r-1}{r+1}\right)^2 < 1$$

r 是对称正定矩阵 $\nabla^2 f(\bar{x})$ 的条件数 (Condition Number). 条件数越小,收敛越快;条件数越大,收敛越慢.

用最速下降法极小化目标函数时,相邻两个搜索方向是正交的(由定理 6-8 可以推出),因此迭代产生的序列 $\{x^{(k)}\}$ 所循路径是“之”字形的,当 $x^{(k)}$ 接近极小点 $\bar{x}$ 时,每次迭代移动的步长很小,这样就呈现出锯齿现象. 当海赛矩阵 $\nabla^2 f(\bar{x})$ 的条件数比较大时,锯齿现象的影响尤为严重. 对此可作如下分析:

粗略地讲,在极小点附近,目标函数一般可用二次函数近似,其等值面接近椭球面,长轴和短轴分别位于对应最小特征值和最大特征值的特征向量方向,其大小与特征值的平方根成反比. 最小特征值与最大特征值相差越大,椭球面越扁,这就使得一维搜索沿着“斜长谷”进行. 因此,当条件数很大时,要使迭代点充分接近极小点,就需要走很大的弯路,计算效率很低.

最速下降方向反映了目标函数的一种局部性质. 最速下降法对初始点的选择要求不高,每一轮迭代工作量较少,它可以比较快地从初始点达到极小点附近. 从局部看,最速下降方向的确是目标函数值下降最快的方向,选择这样的方向进行搜索是有利的. 但从全局看,由于锯齿现象的影响,即使向着极小点移近不太大的距离,也要经历不小的“弯路”,因此收敛速率大为减慢. 最速下降法并不是收敛最快的方法,相反,从全局看,它的收敛是比较慢的. 因此,最速下降法一般适用于计算过程的前期迭代,或作为间插步骤. 当接近极小点时,再使用此方法,试图达到迭代的终止,并非有利.

此外,从最速下降法的终止条件可以看出,用最速下降法求出的近似极小点,仅仅是驻点而已(也就是说仅仅满足极值点的必要条件),它未必是真正的极小点,即使是极小点,也可能是局部的极小点. 最速下降法容易陷入局部极小,已被许多算例所证实. 即便如此,最速下降法作为一种最基本的算法在最优化计算方法中占有重要的地位.

8.5 牛顿法

本节介绍的多变量函数牛顿(Newton)法是单变量函数牛顿法的推广.

8.5.1 牛顿法基本原理

设无约束问题的目标函数 $f(x)$ 为二次可微的实函数,考虑目标函数 $f(x)$ 在点 $x^{(k)}$ 处的二次逼近式

$$f(x) \approx Q(x) = f(x^{(k)}) + \nabla f(x^{(k)})^T (x - x^{(k)}) + \frac{1}{2} (x - x^{(k)})^T \nabla^2 f(x^{(k)}) (x - x^{(k)})$$

假定 $x^{(k)}$ 点的海赛矩阵

$$\nabla^2 f(x^{(k)}) = \begin{bmatrix} \frac{\partial^2 f(x^{(k)})}{\partial x_1^2} & \dots & \frac{\partial^2 f(x^{(k)})}{\partial x_1 \partial x_n} \\ \vdots & \dots & \vdots \\ \frac{\partial^2 f(x^{(k)})}{\partial x_n \partial x_1} & \dots & \frac{\partial^2 f(x^{(k)})}{\partial x_n^2} \end{bmatrix}$$

正定.

由于 $\nabla^2 f(x^{(k)})$ 正定, 函数 $Q(x)$ 的驻点 $x^{(k+1)}$ 是 $Q(x)$ 的极小点. 为求此极小点, 令

$$\nabla Q(x) = \nabla f(x^{(k)}) + \nabla^2 f(x^{(k)}) (x - x^{(k)}) = 0$$

即可解得

$$x^{(k+1)} = x^{(k)} - [\nabla^2 f(x^{(k)})]^{-1} \nabla f(x^{(k)}) \quad (8-15)$$

对照非线性规划问题的基本迭代格式(6-28), 可知从点 $x^{(k)}$ 出发沿搜索方向

$$d^{(k)} = -[\nabla^2 f(x^{(k)})]^{-1} \nabla f(x^{(k)})$$

并取步长 $\lambda_k = 1$ 即可得 $Q(x)$ 的极小点 $x^{(k+1)}$. 通常, 把方向 $d^{(k)}$ 叫做从点 $x^{(k)}$ 出发的牛顿方向. 从一初始点开始, 每一轮从当前迭代点出发, 沿牛顿方向并取步长为 1 的求解方法, 称之为牛顿法的纯形式(或称原始牛顿法). 用牛顿法的纯形式产生的点列 $\{x^{(k)}\}$ 在适当条件下收敛. 下面给出一个定理.

定理 8-2 设 $f(x)$ 为二次连续可微函数, $x \in \mathbb{R}^n$, $\bar{x}$ 满足 $\nabla f(\bar{x}) = 0$, 且 $[\nabla^2 f(\bar{x})]^{-1}$ 存在, 由设初始点 $x^{(1)}$ 充分接近 $\bar{x}$, 使得存在 $k_1, k_2 > 0$, 满足 $k_1 \cdot k_2 < 1$, 且对每一个

$$x \in \{x \mid \|x - \bar{x}\| \leq \|x^{(1)} - \bar{x}\|\}$$

有以下关系式成立

$$(1) \|\nabla^2 f(x)^{-1}\| \leq k_1$$

$$(2) \frac{\|\nabla f(\bar{x}) - \nabla f(x) - \nabla^2 f(x)(\bar{x} - x)\|}{\|\bar{x} - x\|} \leq k_2$$

则牛顿法产生的点列 $\{x^{(k)}\}$ 收敛于 $\bar{x}$.

当牛顿法收敛时, 有下列关系:

$$\|x^{(k+1)} - \bar{x}\| \leq C \|x^{(k)} - \bar{x}\|^2 \quad (8-16)$$

其中 C 是某个常数. 由此可知, 牛顿法至少二阶收敛. 特别地, 当 $f(x)$ 为二次凸函数时, 运用牛顿法, 经 1 次迭代达极小点.

值得注意的是, 当初始点远离极小点时, 牛顿法可能不收敛. 原因之一是牛顿方向 $d = -[\nabla^2 f(x)]^{-1} \nabla f(x)$ 不一定是下降方向, 经迭代, 目标函数值可能上升. 此外, 即使目标函数值下降, 得到的点 $x^{(k+1)}$ 也不一定是沿牛顿方向的最好点, 因此产生了阻尼牛顿法(或称修正牛顿法).

8.5.2 阻尼牛顿法及其计算步骤

阻尼牛顿法与牛顿法的纯形式的区别在于增加了沿牛顿方向的一维搜索,也就是说不是按固定步长1进行搜索,而是按牛顿方向上的最优步长进行搜索.其迭代公式为

$$\begin{cases} \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}, \\ \mathbf{d}^{(k)} = -[\nabla^2 f(\mathbf{x}^{(k)})]^{-1} \nabla f(\mathbf{x}^{(k)}), \\ \lambda_k: f(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}) = \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)}) \end{cases}$$

可以证明阻尼牛顿法在适当条件下具有全局收敛性.

阻尼牛顿法的计算步骤如下:

(1) 给定初始点 $\mathbf{x}^{(1)} \in \mathbb{R}^n$, 允许误差 $\varepsilon > 0$, 并令 $k = 1$.

(2) 求 $\mathbf{x}^{(k)}$ 处梯度向量的模的值 $\|\nabla f(\mathbf{x}^{(k)})\|$ 并判断精度.

若 $\|\nabla f(\mathbf{x}^{(k)})\| < \varepsilon$, 则停止计算, 输出 $\mathbf{x}^{(k)}$ 作为近似极小点, 否则转下一步.

(3) 构造 $\mathbf{x}^{(k)}$ 处的牛顿方向并作为搜索方向, 即取

$$\mathbf{d}^{(k)} = -[\nabla^2 f(\mathbf{x}^{(k)})]^{-1} \nabla f(\mathbf{x}^{(k)})$$

(4) 从 $\mathbf{x}^{(k)}$ 点出发, 沿 $\mathbf{d}^{(k)}$ 进行一维搜索, 即求最优步长 λ_k , 使得

$$f(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}) = \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})$$

(5) 令 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}$, 置 $k := k + 1$, 转步骤(2).

可以看出, 阻尼牛顿法的算法步骤与最速下降法完全类似, 只是有利的搜索方向换成牛顿方向.

8.5.3 计算举例

例8-5 用牛顿法求解下列问题:

$$\min f(\mathbf{x}) = x_1 - x_2 + 2x_1^2 + 2x_1x_2 + x_2^2$$

给定初始点 $\mathbf{x}^{(1)} = (0, 0)^T$.

解 目标函数 $f(\mathbf{x})$ 的梯度和海赛矩阵如下:

$$\nabla f(\mathbf{x}) = [1 + 4x_1 + 2x_2, -1 + 2x_1 + 2x_2]^T$$

$$H(\mathbf{x}) = \nabla^2 f(\mathbf{x}) = \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix}$$

在 $\mathbf{x}^{(1)}$ 处, 目标函数 $f(\mathbf{x})$ 的梯度和海赛矩阵是

$$\nabla f(\mathbf{x}^{(1)}) = [1, -1]^T, \quad H(\mathbf{x}^{(1)}) = \nabla^2 f(\mathbf{x}^{(1)}) = \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix}$$

牛顿方向

$$\begin{aligned} \mathbf{d}^{(1)} &= -(H(\mathbf{x}^{(1)}))^{-1} \cdot \nabla f(\mathbf{x}^{(1)}) \\ &= -\begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix}^{-1} \cdot \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= -\begin{bmatrix} \frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & 1 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} -1 \\ \frac{3}{2} \end{bmatrix} \end{aligned}$$

从 $x^{(1)}$ 出发,沿 $d^{(1)}$ 作一维搜索,令步长变量为 λ ,最优步长为 λ_1 ,则有

$$x^{(1)} + \lambda d^{(1)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \lambda \begin{bmatrix} -1 \\ \frac{3}{2} \end{bmatrix} = \begin{bmatrix} -\lambda \\ \frac{3}{2}\lambda \end{bmatrix}$$

即

$$x_1 = -\lambda, \quad x_2 = \frac{3}{2}\lambda$$

故

$$f(x^{(1)} + \lambda d^{(1)}) = -\lambda - \frac{3}{2}\lambda + 2\lambda^2 - 3\lambda^2 + \frac{9}{4}\lambda^2 = \frac{5}{4}\lambda^2 - \frac{5}{2}\lambda$$

令

$$f'_\lambda(x^{(1)} + \lambda d^{(1)}) = \frac{5}{2}\lambda - \frac{5}{2} = 0$$

则有

$$\lambda_1 = 1$$

故

$$x^{(2)} = x^{(1)} + \lambda_1 d^{(1)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \begin{bmatrix} -1 \\ \frac{3}{2} \end{bmatrix} = \begin{bmatrix} -1 \\ \frac{3}{2} \end{bmatrix}$$

上述 $x^{(2)}$ 即极小点.

牛顿法的优点是在极小点附近收敛速度快,但是当维数较高时,计算 $-[\nabla^2 f(x^{(k)})]^{-1}$ 的工作量很大甚至不可能. 在假定目标函数二次可微的条件下,要保证牛顿法收敛,还必须满足目标函数海赛矩阵的逆矩阵正定.

在目标函数的极小点附近,牛顿法收敛很快,而在远离极小点时,最速下降法是优良的,因此,最速下降法与牛顿法的适当组合,会比两种方法单独使用好.

8.6 共轭梯度法

共轭梯度法是介于最速下降法与牛顿法之间的一个方法. 它仅需利用一阶导数信息,克服了最速下降法收敛慢的缺点,又避免了存储和计算牛顿法所需要的二阶导数信息. 本节将要介绍的共轭梯度法就是一种著名的共轭方向法,它的基本思想是把共轭性与最速下降方法相结合,利用已知点的梯度构造一组共轭方向,并沿此组方向进行搜索,求出目标函数的极小点. 根据共轭方向的基本性质,这种方法具有二次终止性. 共轭梯度法首先由 Hestenes 和 Stiefel(1952) 提出来作为解线性方程组的方法. 由于解线性方程组等价于极小化一个正定二次函数,故 1964 年 Fletcher 和 Reeves 提出了无约束极小化的共轭梯度法,简称 FR 法,它是直接从 Hestenes 和 Stiefel 解线性方程组的共轭梯度法发展而来的.

下面先介绍有关的基本概念和基本定理.

8.6.1 基本概念和基本定理

1. 正交

设 x 和 y 是 n 维欧氏空间 $\mathbb{R}^n$ 中的两个向量,若有 $x^T \cdot y = 0$,就称 x 和 y 正交.

2. 共轭方向

设 A 是 $n \times n$ 对称正定矩阵, 若 n 维欧氏空间 $\mathbb{R}^n$ 中的两个向量 x 和 y 满足

$$x^T A y = 0$$

即 Ax 与 y 正交, 则称向量 x 和 y 关于 A 共轭, 或称它们关于 A 正交. 易见, 正交是共轭的特殊情况, 或者说共轭是正交的推广, 当 A 为单位矩阵时, 共轭就是正交.

一般而言, 设 A 是 $n \times n$ 对称正定矩阵, 若 n 维欧氏空间 $\mathbb{R}^n$ 中的非零向量组 $d^{(1)}, d^{(2)}, \dots, d^{(k)}$, 它们两两关于 A 共轭, 即满足

$$(d^{(i)})^T A d^{(j)} = 0 \quad (i \neq j; i = 1, 2, \dots, k; j = 1, 2, \dots, k)$$

则称这个向量组关于 A 共轭, 或称它们为 A 的 k 个共轭方向.

3. 基本定理

定理 8-2 设 A 是 $n \times n$ 对称正定矩阵, $d^{(1)}, d^{(2)}, \dots, d^{(k)}$ 是关于 A 共轭的非零向量组, 则该向量组线性无关.

证 设存在 $\alpha_1, \alpha_2, \dots, \alpha_k$, 使得

$$\alpha_1 d^{(1)} + \alpha_2 d^{(2)} + \dots + \alpha_k d^{(k)} = 0 \quad (8-17)$$

对于 $i = 1, 2, \dots, k$, 用 $(d^{(i)})^T A$ 左乘式 (8-17) 两端, 根据向量组关于 A 共轭的假设, 左乘后等式右侧仅剩一项, 即有

$$\alpha_i (d^{(i)})^T A d^{(i)} = 0$$

由于 A 是正定矩阵, $d^{(i)}$ 是非零向量, 故

$$(d^{(i)})^T A d^{(i)} > 0$$

因此有

$$\alpha_i = 0 \quad (i = 1, 2, \dots, k)$$

即 $d^{(1)}, d^{(2)}, \dots, d^{(k)}$ 线性无关. $\square$

由于上述原因, 共轭方向有时也被简单说成是线性无关方向.

定理 8-3 设有二次函数

$$f(x) = \frac{1}{2} x^T A x + B^T x + C$$

其中 A 是 $n \times n$ 对称正定矩阵, $d^{(1)}, d^{(2)}, \dots, d^{(n)}$ 为关于 A 共轭的非零向量, 则从任一点 $x^{(1)}$ 出发, 相继以 $d^{(1)}, d^{(2)}, \dots, d^{(n)}$ 为搜索方向的下述算法

$$\begin{cases} f(x^{(k)} + \lambda_k d^{(k)}) = \min_{\lambda} f(x^{(k)} + \lambda d^{(k)}) \\ x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)} \end{cases} \quad (8-18)$$

经 n 次一维搜索收敛于 $f(x)$ 的极小点. $\square$

证 考虑问题

$$\min f(x) = \frac{1}{2} x^T A x + B^T x + C \quad (8-19)$$

因为 A 是 $n \times n$ 对称正定矩阵, 则 $f(x)$ 是凸函数, 因此 $f(x)$ 的驻点即是它的极小点. 证明的思路就是: 当以 $x^{(1)}$ 出发, 相继以 $d^{(1)}, d^{(2)}, \dots, d^{(n)}$ 为搜索方向, 以式 (8-18) 为算法相继得到迭代点 $x^{(2)}, x^{(3)}, \dots, x^{(n+1)}$, 则 $x^{(n+1)}$ 就是驻点, 即应有 $\nabla f(x^{(n+1)}) = 0$.

由式 (8-19), 则有

$$\nabla f(x) = Ax + B$$

设由式 (8-18) 各次搜索得到的近似点为 $x^{(2)}, x^{(3)}, \dots, x^{(n+1)}$, 则有

$$\nabla f(\mathbf{x}^{(k)}) = \mathbf{A}\mathbf{x}^{(k)} + \mathbf{B}$$

及

$$\begin{aligned}\nabla f(\mathbf{x}^{(k+1)}) &= \mathbf{A}\mathbf{x}^{(k+1)} + \mathbf{B} \\ &= \mathbf{A}(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}) + \mathbf{B} \\ &= (\mathbf{A}\mathbf{x}^{(k)} + \mathbf{B}) + \lambda_k \mathbf{A}\mathbf{d}^{(k)} \\ &= \nabla f(\mathbf{x}^{(k)}) + \lambda_k \mathbf{A}\mathbf{d}^{(k)}\end{aligned}\quad (8-20)$$

若有 $\nabla f(\mathbf{x}^{(k)}) \neq 0, k=1, 2, \dots, n$ (即 $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(n)}$ 都不是驻点), 则有

$$\begin{aligned}\nabla f(\mathbf{x}^{(n+1)}) &= \nabla f(\mathbf{x}^{(n)}) + \lambda_n \mathbf{A}\mathbf{d}^{(n)} \\ &= \nabla f(\mathbf{x}^{(n-1)}) + \lambda_{n-1} \mathbf{A}\mathbf{d}^{(n-1)} + \lambda_n \mathbf{A}\mathbf{d}^{(n)} \\ &= \nabla f(\mathbf{x}^{(k+1)}) + \lambda_{k+1} \mathbf{A}\mathbf{d}^{(k+1)} + \lambda_{k+2} \mathbf{A}\mathbf{d}^{(k+2)} + \dots + \lambda_n \mathbf{A}\mathbf{d}^{(n)}\end{aligned}\quad (8-21)$$

因为 $\lambda_{k+1}, \lambda_{k+2}, \dots, \lambda_n$ 是在进行一维搜索时所确定的各次最优步长, 因此有

$$\begin{aligned}\frac{df(\mathbf{x}^{(k+1)})}{d\lambda} &= \frac{df(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})}{d\lambda} = \frac{df(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})}{d(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})} \cdot \frac{d(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})}{d\lambda} \\ &= \nabla f(\mathbf{x}^{(k+1)})^T \cdot \mathbf{d}^{(k)} = 0\end{aligned}\quad (8-22)$$

式(8-22)实际上就是定理6-8的结论.

故对 $k=1, 2, \dots, n$, 考虑到式(8-21), 有

$$\begin{aligned}(\mathbf{d}^{(k)})^T \cdot \nabla f(\mathbf{x}^{(n+1)}) &= (\mathbf{d}^{(k)})^T \cdot [\nabla f(\mathbf{x}^{(k+1)}) + \lambda_{k+1} \mathbf{A}\mathbf{d}^{(k+1)} + \lambda_{k+2} \mathbf{A}\mathbf{d}^{(k+2)} + \dots + \lambda_n \mathbf{A}\mathbf{d}^{(n)}] \\ &= (\mathbf{d}^{(k)})^T \cdot \nabla f(\mathbf{x}^{(k+1)}) + \lambda_{k+1} (\mathbf{d}^{(k)})^T \mathbf{A}\mathbf{d}^{(k+1)} + \lambda_{k+2} (\mathbf{d}^{(k)})^T \mathbf{A}\mathbf{d}^{(k+2)} \\ &\quad + \dots + \lambda_n (\mathbf{d}^{(k)})^T \mathbf{A}\mathbf{d}^{(n)}\end{aligned}\quad (8-23)$$

考虑到共轭性质

$$(\mathbf{d}^{(i)})^T \mathbf{A}\mathbf{d}^{(j)} = 0 \quad (i \neq j)$$

及式(8-22)有

$$(\mathbf{d}^{(k)})^T \cdot \nabla f(\mathbf{x}^{(k+1)}) = \nabla f(\mathbf{x}^{(k+1)})^T \cdot \mathbf{d}^{(k)} = 0$$

代入式(8-23)有

$$(\mathbf{d}^{(k)})^T \cdot \nabla f(\mathbf{x}^{(n+1)}) = 0 \quad (k=1, 2, \dots, n) \quad (8-24)$$

式(8-24)表明向量 $\nabla f(\mathbf{x}^{(n+1)})$ 与非零向量 $\mathbf{d}^{(1)}, \mathbf{d}^{(2)}, \dots, \mathbf{d}^{(n)}$ 均正交. 若 $\nabla f(\mathbf{x}^{(n+1)}) \neq 0$, 则出现了 $(n+1)$ 个向量线性无关, 这与 $\mathbb{R}^n$ 中最多只有 n 个线性无关向量的结论相矛盾, 故必有 $\nabla f(\mathbf{x}^{(n+1)}) = 0$, 即 $\mathbf{x}^{(n+1)}$ 必为正定 n 维二次函数的极小点. $\square$

定理8-3表明, 对于正定二次函数, 若沿一组共轭方向(非零向量)搜索, 经有限步迭代必达到极小点. 这是一种极好的性质, 称为二次终止性.

根据 Taylor 展开式的近似可知, 一般函数在极小点附近的性态近似于二次函数, 因此一个算法若对于二次函数比较有效, 则可望对一般函数(至少在极小点附近)也有较好的效果. 下面重点研究求二次函数的极小值的共轭梯度法, 它在整个最优化问题中占有重要的地位.

8.6.2 正定二次函数的共轭梯度法

1. 基本定理

正定二次函数的共轭梯度法的主要依据就是本节的定理8-3.

给定正定二次函数的极小化问题:

$$\min f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{B}^T \mathbf{x} + C$$

其中, $\mathbf{A}$ 是 $n \times n$ 对称正定矩阵($\mathbf{A}$ 即为 $f(\mathbf{x})$ 的海赛矩阵), $\mathbf{x}$ 为 n 维向量, $\mathbf{B}$ 为 n 维常向量, C 是常数.

求解上述问题时, 首先任意给定一个初始点 $\mathbf{x}^{(1)}$, 选择 $f(\mathbf{x})$ 在 $\mathbf{x}^{(1)}$ 点的负梯度方向 $-\mathbf{g}_1$ (g 为 gradient 的缩写) 为第一个搜索方向 $\mathbf{d}^{(1)}$, 并在 $\mathbf{d}^{(1)}$ 方向上进行一维寻优, 以确定最优步长 λ_1 , 进而得到 $\mathbf{x}^{(2)}$ 点:

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda_1 \mathbf{d}^{(1)}$$

因此, 共轭梯度法搜索的第一步与最速下降法相同.

那么共轭梯度法的第二步、第三步……如何选择搜索方向, 才能保证各搜索方向是关于 $\mathbf{A}$ 共轭的呢?

假设经过若干次迭代已经求出当前点 $\mathbf{x}^{(k)}$, 基于 $\mathbf{x}^{(k)}$ 构造一个搜索方向, 构造方法有很多, 本节要介绍的是由 Fletcher - Reeves 提出的构造方法, 具体来说就是采用当前点的负梯度方向 $-\mathbf{g}_k$ 和上一点 $\mathbf{x}^{(k-1)}$ 的搜索方向 $\mathbf{d}^{(k-1)}$ 的线性组合作为当前点的搜索方向 $\mathbf{d}^{(k)}$, 即

$$\mathbf{d}^{(k)} = -\mathbf{g}_k + \beta_{k-1} \mathbf{d}^{(k-1)} \quad (8-25)$$

其中, β_{k-1} 是线性组合系数.

为保证 $\mathbf{d}^{(k)}$ 与 $\mathbf{d}^{(k-1)}$ 关于 $\mathbf{A}$ 共轭, 必须合理地选择 β_{k-1} . 将式 (8-25) 两端左乘 $(\mathbf{d}^{(k-1)})^T \mathbf{A}$, 有

$$(\mathbf{d}^{(k-1)})^T \mathbf{A} \mathbf{d}^{(k)} = -(\mathbf{d}^{(k-1)})^T \mathbf{A} \mathbf{g}_k + \beta_{k-1} (\mathbf{d}^{(k-1)})^T \mathbf{A} \mathbf{d}^{(k-1)} \quad (8-26)$$

令

$$(\mathbf{d}^{(k-1)})^T \mathbf{A} \mathbf{d}^{(k)} = 0$$

即 $\mathbf{d}^{(k-1)}$ 与 $\mathbf{d}^{(k)}$ 关于 $\mathbf{A}$ 共轭. 再根据式 (8-26), 可以求出系数 β_{k-1} . 因为

$$-(\mathbf{d}^{(k-1)})^T \mathbf{A} \mathbf{g}_k + \beta_{k-1} (\mathbf{d}^{(k-1)})^T \mathbf{A} \mathbf{d}^{(k-1)} = 0$$

故有

$$\beta_{k-1} = \frac{(\mathbf{d}^{(k-1)})^T \mathbf{A} \mathbf{g}_k}{(\mathbf{d}^{(k-1)})^T \mathbf{A} \mathbf{d}^{(k-1)}} \quad (8-27)$$

进一步推导(参见参考文献[9])可得

$$\beta_{k-1} = \frac{(\mathbf{g}_k)^T \mathbf{g}_k}{(\mathbf{g}_{k-1})^T \mathbf{g}_{k-1}} = \frac{\|\mathbf{g}_k\|^2}{\|\mathbf{g}_{k-1}\|^2} \quad (8-28)$$

按式 (8-27) 或式 (8-28) 确定 β_{k-1} 的大小, 就能保证当前点的搜索方向与以前各点的搜索方向关于 $\mathbf{A}$ 共轭.

这里要着重指出, 选择最速下降方向作为初始搜索方向(即 $\mathbf{d}^{(1)} = -\nabla f(\mathbf{x}^{(1)})$) 是十分重要的, 如果选择别的方向作为初始搜索方向, 其余方向均按 Fletcher - Reeves 方法构造, 那么极小化正定二次函数时, 这样构造出来的一组方向不能保证共轭性.

下面, 再来推导搜索方向上最优步长 λ_k 的计算公式.

对于正定二次函数

$$f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{B}^T \mathbf{x} + C$$

有

$$\nabla f(\mathbf{x}) = \mathbf{Ax} + \mathbf{B}$$

又根据定理 6-8 的结论有

$$\nabla f(\mathbf{x}^{(k+1)})^T \cdot \mathbf{d}^{(k)} = 0$$

故

$$(\mathbf{Ax}^{(k+1)} + \mathbf{B})^T \mathbf{d}^{(k)} = 0$$

因为

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}$$

故

$$[\mathbf{Ax}^{(k)} + \lambda_k \mathbf{d}^{(k)} + \mathbf{B}]^T \mathbf{d}^{(k)} = 0$$

$$[(\mathbf{Ax}^{(k)} + \mathbf{B}) + \lambda_k \mathbf{Ad}^{(k)}]^T \mathbf{d}^{(k)} = 0$$

$$[\mathbf{g}_k + \lambda_k \mathbf{Ad}^{(k)}]^T \mathbf{d}^{(k)} = 0$$

即得

$$\lambda_k = -\frac{(\mathbf{g}_k)^T \mathbf{d}^{(k)}}{(\mathbf{d}^{(k)})^T \mathbf{Ad}^{(k)}} = \frac{(\mathbf{g}_k)^T \mathbf{g}_k}{(\mathbf{d}^{(k)})^T \mathbf{Ad}^{(k)}} \quad (8-29)$$

8.6.3 正定二次函数共轭梯度法的计算步骤

(1) 给定初始点 $\mathbf{x}^{(1)}$, 允许误差 $\varepsilon > 0$, 置 $k=1$.

(2) 判断精度. 计算 $\mathbf{g}_k = \nabla f(\mathbf{x}^{(k)})$, 若 $\|\mathbf{g}_k\| < \varepsilon$, 则停止迭代, 得近似极小点 $\mathbf{x}^* = \mathbf{x}^{(k)}$; 否则, 转下一步.

(3) 构造搜索方向. 令

$$\mathbf{d}^{(k)} = -\mathbf{g}_k + \beta_{k-1} \mathbf{d}^{(k-1)}$$

其中, 当 $k=1$ 时, $\beta_0=0$; 当 $k>1$ 时, β_{k-1} 的计算公式见式(8-27)或式(8-28).

(4) 令新点 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}$, 其中最优步长 λ_k 的计算公式见式(8-29).

(5) 若 $k=n$, 则停止迭代, 得近似极小点

$$\mathbf{x}^* = \mathbf{x}^{(k+1)}$$

否则, 令 $k:=k+1$, 返回步骤(2)

8.6.4 计算举例

例 8-6 试用共轭梯度法求下述二次函数的极小点

$$\min f(\mathbf{x}) = \frac{3}{2}x_1^2 + \frac{1}{2}x_2^2 - x_1x_2 - 2x_1$$

取 $\varepsilon = 10^{-4}$, $\mathbf{x}^{(1)} = \begin{bmatrix} -2 \\ 4 \end{bmatrix}$.

解 首先将 $f(\mathbf{x})$ 化成式(8-19)的形式:

$$f(\mathbf{x}) = \frac{1}{2}(x_1, x_2) \begin{bmatrix} 3 & -1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + (-2, 0) \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

其中 $\mathbf{A} = \begin{bmatrix} 3 & -1 \\ -1 & 1 \end{bmatrix}$ 是一个正定矩阵, $\mathbf{B} = \begin{bmatrix} -2 \\ 0 \end{bmatrix}$, $\mathbf{C} = 0$. 因

$$\mathbf{x}^{(1)} = \begin{bmatrix} -2 \\ 4 \end{bmatrix}$$

故

$$\begin{aligned} \nabla f(\mathbf{x}^{(1)}) &= \mathbf{A}\mathbf{x}^{(1)} + \mathbf{B} \\ &= \begin{bmatrix} 3 & -1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} -2 \\ 4 \end{bmatrix} + \begin{bmatrix} -2 \\ 0 \end{bmatrix} \\ &= \begin{bmatrix} -10 \\ 6 \end{bmatrix} + \begin{bmatrix} -2 \\ 0 \end{bmatrix} = \begin{bmatrix} -12 \\ 6 \end{bmatrix} \end{aligned}$$

所以

$$\mathbf{d}^{(1)} = -\nabla f(\mathbf{x}^{(1)}) = \begin{bmatrix} 12 \\ -6 \end{bmatrix}$$

以 $\mathbf{x}^{(1)}$ 为出发点, 沿 $\mathbf{d}^{(1)}$ 方向做最佳一维搜索, 可用式(8-29)求最优步长 λ_1 :

$$\lambda_1 = -\frac{\nabla f(\mathbf{x}^{(1)})^T \cdot \mathbf{d}^{(1)}}{(\mathbf{d}^{(1)})^T \mathbf{A} \mathbf{d}^{(1)}} = \frac{5}{17}$$

故

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda_1 \mathbf{d}^{(1)} = \begin{bmatrix} -2 \\ 4 \end{bmatrix} + \frac{5}{17} \begin{bmatrix} 12 \\ -6 \end{bmatrix} = \begin{bmatrix} \frac{26}{17} \\ \frac{38}{17} \end{bmatrix} \approx \begin{bmatrix} 1.529 \\ 2.235 \end{bmatrix}$$

$$\nabla f(\mathbf{x}^{(2)}) = \mathbf{A}\mathbf{x}^{(2)} + \mathbf{B} = \begin{bmatrix} 3 & -1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} \frac{26}{17} \\ \frac{38}{17} \end{bmatrix} + \begin{bmatrix} -2 \\ 0 \end{bmatrix} = \begin{bmatrix} \frac{6}{17} \\ \frac{12}{17} \end{bmatrix} \approx \begin{bmatrix} 0.353 \\ 0.706 \end{bmatrix}$$

计算

$$\|\nabla f(\mathbf{x}^{(2)})\| \approx 0.789 > \varepsilon$$

不满足精度要求, 需要迭代, 由式(8-28)计算 β_1 :

$$\beta_1 = \frac{\|\mathbf{g}_2\|^2}{\|\mathbf{g}_1\|^2} = \frac{1}{289} \approx 0.00346$$

故有

$$\mathbf{d}^{(2)} = -\mathbf{g}_1 + \beta_1 \mathbf{d}^{(1)} = \left(-\frac{90}{289}, -\frac{210}{289}\right)^T \approx (-0.311, -0.727)^T$$

再用式(8-29)求最优步长 λ_2 :

$$\lambda_2 = -\frac{\nabla f(\mathbf{x}^{(2)})^T \cdot \mathbf{d}^{(2)}}{(\mathbf{d}^{(2)})^T \mathbf{A} \mathbf{d}^{(2)}} = \frac{17}{10}$$

故有

$$\mathbf{x}^{(3)} = \mathbf{x}^{(2)} + \lambda_2 \mathbf{d}^{(2)} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

计算

$$\|\nabla f(\mathbf{x}^{(3)})\| = 0$$

所以

$$\|\nabla f(\mathbf{x}^{(3)})\| = 0 < \varepsilon$$

故 $\mathbf{x}^{(3)}$ 即为本题最优解. 因为本题函数是正定二维二次函数, 因此, 经过二次迭代即达到了

最优解.

8.6.5 用于一般函数的共轭梯度法

我们把上述用于正定二次函数的共轭梯度法加以推广,用于极小化任意 n 元函数. 推广后的共轭梯度法与原有方法的主要差别在于,步长 λ_k 不能再用公式(8-29)计算,可以用其他一维搜索方法来确定,此外,凡是用到矩阵 A 之处,需改用当前点处的海赛矩阵 $H(\mathbf{x}^{(k)}) = \nabla^2 f(\mathbf{x}^{(k)})$. 另外,对任意函数而言,一般不能在有限步内达到最优解,可以采用循环的方法,具体做法就是每迭代 n 步作一轮,每搜索完一轮后,用这轮最后一个迭代点作为下一轮的初始点开始新一轮迭代,直到满足精度要求为止. 具体计算步骤如下:

(1) 给定初始点 $\mathbf{x}^{(1)}$, 允许误差 $\varepsilon > 0$.

(2) 求初始点梯度. 计算 $\mathbf{g}_1 = \nabla f(\mathbf{x}^{(1)})$, 若 $\|\mathbf{g}_1\| < \varepsilon$, 则停止迭代, 得近似极小点 $\mathbf{x}^* = \mathbf{x}^{(1)}$; 否则转下一步.

(3) 构造初始搜索方向. 令

$$\mathbf{d}^{(1)} = -\nabla f(\mathbf{x}^{(1)})$$

置 $k=1$, 进行第(4)步.

(4) 进行一维寻优, 求最优步长 λ_k . 使

$$f(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}) = \min_{\lambda \geq 0} f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})$$

令 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}$, 转第(5)步.

(5) 求梯度向量. 计算 $\nabla f(\mathbf{x}^{(k+1)})$, 若 $\|\nabla f(\mathbf{x}^{(k+1)})\| < \varepsilon$, 停止迭代, 输出 $\mathbf{x}^*$ 的近似值 $\mathbf{x}^* \approx \mathbf{x}^{(k+1)}$. 否则进行第(6)步.

(6) 检验迭代步数. 若 $k=n$, 令 $\mathbf{x}^{(1)} := \mathbf{x}^{(n+1)}$, 转第(3)步. 否则进行第(7)步.

(7) 构造搜索方向, 利用公式

$$\mathbf{d}^{(k)} = -\mathbf{g}_k + \beta_{k-1} \mathbf{d}^{(k-1)}$$

取 $\beta_{k-1} = \frac{\|\mathbf{g}_k\|^2}{\|\mathbf{g}_{k-1}\|^2}$, 令 $k := k+1$, 转第(4)步.

共轭梯度法对正定二次函数具有二次终止性. 对于一般函数, 共轭梯度法在一定条件下也是收敛的, 且收敛速度通常优于最速下降法. 共轭梯度法不用求矩阵的逆, 在使用计算机求解时, 所需存储量较小, 因此求解变量较多的大规模问题可用共轭梯度法.

8.7 拟牛顿法

前面介绍的牛顿法, 其突出优点是收敛速度快. 但是, 运用牛顿法需要计算二阶偏导, 而且目标函数的海赛矩阵可能是非正定. 为了克服牛顿法的缺点, 人们提出了拟牛顿法 (Quasi Newton Method). 它的基本思想是用不包含二阶导数的矩阵 $\mathbf{H}_k$ 取代牛顿法中的海赛矩阵的逆矩阵 $[\nabla^2 f(\mathbf{x}^{(k)})]^{-1}$, 再沿方向 $\mathbf{d}^{(k)} = -\mathbf{H}_k \mathbf{g}_k$ 作一维搜索. 由于构造近似矩阵 $\mathbf{H}_k$ 的方法不同, 因而有不同的拟牛顿法, 经理论证明和实践检验, 拟牛顿法已经成为一类公认的比较

有效的方法. 拟牛顿法又叫变尺度法 (Variable Metric Algorithm), 是近 20 多年来发展起来的, 它不仅是求解无约束极值问题非常有效的算法, 而且也被推广用来求解约束极值问题. 由于它既避免了计算二阶导数矩阵及其求逆过程, 又比梯度法的收敛速度快, 特别是对高维问题具有显著的优越性, 因而使拟牛顿法获得了很高的声誉. 下面简要地介绍一种变尺度法——DFP 法的基本原理及其计算过程. 这一方法首先由 Davidon 在 1959 年提出, 后经 Fletcher 和 Powell 加以改进.

8.7.1 拟牛顿条件

已经知道牛顿法的搜索方向是 $-\left[\nabla^2 f(\mathbf{x}^{(k)})\right]^{-1} \nabla f(\mathbf{x}^{(k)})$, 为了不计算二阶导数矩阵 $[\nabla^2 f(\mathbf{x}^{(k)})]$ 及其逆阵, 我们设法构造另一个矩阵, 用它来逼近二阶导数矩阵的逆阵 $[\nabla^2 f(\mathbf{x}^{(k)})]^{-1}$.

下面研究如何构造这样的近似矩阵 $\mathbf{H}_k$, 用来取代牛顿法中的海赛矩阵中的逆矩阵. 要求每一步都能以现有的信息来确定下一个搜索方向; 每做一次迭代, 目标函数值均有所下降; 这些近似矩阵最后应收敛于解点处的海赛阵的逆阵.

当 $f(\mathbf{x})$ 是二次函数时, 其海赛阵为常数阵 $\mathbf{A}$, 任两点 $\mathbf{x}^{(k)}$ 和 $\mathbf{x}^{(k+1)}$ 处的梯度之差为

$$\nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)}) = \mathbf{A}(\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)})$$

或

$$\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)} = \mathbf{A}^{-1}[\nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})]$$

对于非二次函数, 仿照二次函数的情形, 要求其海赛阵的逆阵的第 $k+1$ 次近似矩阵 $\mathbf{H}_{k+1}$ 满足关系式

$$\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)} = \mathbf{H}_{k+1}[\nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})] \quad (8-30)$$

这就是常说的拟牛顿条件. 现在的问题是怎样确定满足这个条件的 $\mathbf{H}_{k+1}$, 各种不同的拟牛顿法的区别就在于 $\mathbf{H}_{k+1}$ 的确定方法上.

8.7.2 DFP 法

若令

$$\begin{cases} \Delta \mathbf{g}^{(k)} = \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)}) \\ \Delta \mathbf{x}^{(k)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)} \end{cases} \quad (8-31)$$

则式(8-30)变为

$$\Delta \mathbf{x}^{(k)} = \mathbf{H}_{k+1} \Delta \mathbf{g}^{(k)} \quad (8-32)$$

当 $[\nabla^2 f(\mathbf{x}^{(k)})]^{-1}$ 是 n 阶对称正定矩阵时, 满足拟牛顿条件的 $\mathbf{H}_{k+1}$ 也应该是 n 阶对称正定矩阵. 构造这样的近似矩阵的一般策略是, 任意给定一个 n 阶对称正定矩阵为初始矩阵 $\mathbf{H}_1$ (通常选择 $\mathbf{H}_1$ 为 n 阶单位矩阵 $\mathbf{I}_n$). 现假定 $\mathbf{H}_k$ 已知, 用下式求 $\mathbf{H}_{k+1}$ (设 $\mathbf{H}_k$ 和 $\mathbf{H}_{k+1}$ 均为对称正定阵)

$$\mathbf{H}_{k+1} = \mathbf{H}_k + \Delta \mathbf{H}_k \quad (8-33)$$

其中 $\Delta \mathbf{H}_k$ 称为第 k 次校正矩阵. 显然, $\mathbf{H}_{k+1}$ 应满足拟牛顿条件(8-30), 即要求

$$\Delta \mathbf{x}^{(k)} = (\mathbf{H}_k + \Delta \mathbf{H}_k) \Delta \mathbf{g}^{(k)}$$

或

$$\Delta H_k \Delta g^{(k)} = \Delta x^{(k)} - H_k \Delta g^{(k)} \quad (8-34)$$

由此可以设想, ΔH_k 的一种比较简单的形式是

$$\Delta H_k = \Delta x^{(k)} (q^{(k)})^T - H_k \Delta g^{(k)} (w^{(k)})^T \quad (8-35)$$

其中 $q^{(k)}$ 和 $w^{(k)}$ 为两个待定列向量.

将式(8-35)中的 ΔH_k 代入式(8-34)得

$$\Delta x^{(k)} (q^{(k)})^T \Delta g^{(k)} - H_k \Delta g^{(k)} (w^{(k)})^T \Delta g^{(k)} = \Delta x^{(k)} - H_k \Delta g^{(k)}$$

这说明, 应使

$$(q^{(k)})^T \Delta g^{(k)} = (w^{(k)})^T \Delta g^{(k)} = 1 \quad (8-36)$$

考虑到 ΔH_k 应为对称阵, 最简单的办法就是取

$$\begin{cases} q^{(k)} = \eta_k \Delta x^{(k)} \\ w^{(k)} = \xi_k H_k \Delta g^{(k)} \end{cases} \quad (8-37)$$

由式(8-37)得

$$\eta_k (\Delta x^{(k)})^T \Delta g^{(k)} = \xi_k (\Delta g^{(k)})^T H_k \Delta g^{(k)} = 1 \quad (8-38)$$

若 $(\Delta x^{(k)})^T \Delta g^{(k)}$ 和 $(\Delta g^{(k)})^T H_k \Delta g^{(k)}$ 不等于零, 则有

$$\begin{cases} \eta_k = \frac{1}{(\Delta x^{(k)})^T \Delta g^{(k)}} = \frac{1}{(\Delta g^{(k)})^T \Delta x^{(k)}} \\ \xi_k = \frac{1}{(\Delta g^{(k)})^T H_k \Delta g^{(k)}} \end{cases} \quad (8-39)$$

于是, 得校正矩阵

$$\Delta H_k = \frac{\Delta x^{(k)} (\Delta x^{(k)})^T}{(\Delta g^{(k)})^T \Delta x^{(k)}} - \frac{H_k \Delta g^{(k)} (\Delta g^{(k)})^T H_k}{(\Delta g^{(k)})^T H_k \Delta g^{(k)}} \quad (8-40)$$

从而得到

$$H_{k+1} = H_k + \frac{\Delta x^{(k)} (\Delta x^{(k)})^T}{(\Delta g^{(k)})^T \Delta x^{(k)}} - \frac{H_k \Delta g^{(k)} (\Delta g^{(k)})^T H_k}{(\Delta g^{(k)})^T H_k \Delta g^{(k)}} \quad (8-41)$$

上述矩阵 H_{k+1} 称为尺度矩阵, ΔH_k 称为校正矩阵. 通常, 取第一个尺度矩阵 H_1 为单位阵, 以后的尺度矩阵按式(8-12)逐步形成. 可以证明:

- (1) 当 $x^{(k)}$ 不是极小点且 H_k 正定时, 式(8-40)右端两项的分母不为零, 从而可按式(8-41)产生下一个尺度矩阵 H_{k+1} ;
- (2) 若 H_k 为对称正定阵, 则由式(8-41)产生的 H_{k+1} 也是对称正定阵;
- (3) 由此推出 DFP 法的搜索方向为下降方向.

8.7.3 DFP 变尺度法的计算步骤

DFP 变尺度法的计算步骤如下:

- (1) 给定初始点 $x^{(1)} \in \mathbb{R}^n$ 及允许误差 $\varepsilon > 0$.
- (2) 计算 $x^{(1)}$ 点的梯度 g_1 , 并令 $H_1 = I_n, k=1$.

$$g_1 = \nabla f(x^{(1)})$$

- (3) 计算 $d^{(k)} = -H_k g_k$.

- (4) 从 $x^{(k)}$ 出发, 沿 $d^{(k)}$ 方向作一维搜索(步长变量为 λ), 以求出最优步长 λ_k , 进而得到

新点 $\mathbf{x}^{(k+1)}$, λ_k 和 $\mathbf{x}^{(k+1)}$ 的计算式如下:

$$f(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}) = \min_{\lambda \geq 0} f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}$$

(5) 判断精度. 若 $\|\nabla f(\mathbf{x}^{(k+1)})\| < \varepsilon$, 则停止迭代, 得到近似极小点 $\mathbf{x}^* = \mathbf{x}^{(k+1)}$, 否则转步骤(6).

(6) 若 $k = n$, 则令 $\mathbf{x}^{(1)} = \mathbf{x}^{(k+1)}$, 返回步骤(2); 否则转步骤(7).

(7) 计算 $\mathbf{g}_{k+1} = \nabla f(\mathbf{x}^{(k+1)})$, $\Delta \mathbf{x}^{(k)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$, $\Delta \mathbf{g}^{(k)} = \mathbf{g}_{k+1} - \mathbf{g}_k$, 利用式(8-41)计算 $\mathbf{H}_{k+1}$. 令 $k := k + 1$, 返回步骤(3).

8.7.4 计算举例

例 8-7 用 DFP 方法求解下列问题:

$$\min f(\mathbf{x}) = 2x_1^2 + x_2^2 - 4x_1 + 2$$

初始点及初始矩阵分别取为

$$\mathbf{x}^{(1)} = (2, 1)^T, \quad \mathbf{H}_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

解 第 1 次迭代:

在 $\mathbf{x}^{(1)}$ 处的梯度及搜索方向为

$$\mathbf{g}_1 = (4, 2)^T, \quad \mathbf{d}^{(1)} = -\mathbf{H}_1 \mathbf{g}_1 = (-4, -2)^T$$

从 $\mathbf{x}^{(1)}$ 出发沿 $\mathbf{d}^{(1)}$ 作一维搜索, 求最优步长 λ_1 :

$$\min_{\lambda \geq 0} f(\mathbf{x}^{(1)} + \lambda \mathbf{d}^{(1)})$$

得到 $\lambda_1 = \frac{5}{18}$. 因此沿 $\mathbf{d}^{(1)}$ 方向搜索得到的点 $\mathbf{x}^{(2)}$ 及在此点目标函数的梯度为

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda_1 \mathbf{d}^{(1)} = \left(\frac{8}{9}, \frac{4}{9}\right)^T,$$

$$\mathbf{g}_2 = \left(-\frac{4}{9}, \frac{8}{9}\right)^T$$

第 2 次迭代:

令

$$\Delta \mathbf{x}^{(1)} = \mathbf{x}^{(2)} - \mathbf{x}^{(1)} = \lambda_1 \mathbf{d}^{(1)} = \left(-\frac{10}{9}, -\frac{5}{9}\right)^T$$

$$\Delta \mathbf{g}^{(1)} = \mathbf{g}_2 - \mathbf{g}_1 = \left(-\frac{40}{9}, -\frac{10}{9}\right)^T$$

计算矩阵 $\mathbf{H}_2$ 及搜索方向 $\mathbf{d}^{(2)}$:

$$\mathbf{H}_2 = \mathbf{H}_1 + \frac{\Delta \mathbf{x}^{(1)} (\Delta \mathbf{x}^{(1)})^T}{(\Delta \mathbf{g}^{(1)})^T \Delta \mathbf{x}^{(1)}} - \frac{\mathbf{H}_1 \Delta \mathbf{g}^{(1)} (\Delta \mathbf{g}^{(1)})^T \mathbf{H}_1}{(\Delta \mathbf{g}^{(1)})^T \mathbf{H}_1 \Delta \mathbf{g}^{(1)}} = \frac{1}{306} \begin{bmatrix} 86 & -38 \\ -38 & 305 \end{bmatrix}$$

$$\mathbf{d}^{(2)} = -\mathbf{H}_2 \mathbf{g}_2 = \frac{12}{51} \begin{bmatrix} 1 \\ -4 \end{bmatrix}$$

从 $\mathbf{x}^{(2)}$ 出发沿 $\mathbf{d}^{(2)}$ 作一维搜索

$$\min_{\lambda \geq 0} f(\mathbf{x}^{(2)} + \lambda \mathbf{d}^{(2)})$$

得到 $\lambda_2 = \frac{17}{36}$, 经第 2 次迭代得到的点及在此点目标函数的梯度分别为

$$\mathbf{x}^{(3)} = \mathbf{x}^{(2)} + \lambda_2 \mathbf{d}^{(2)} = (1, 0)^T$$

$$\mathbf{g}_3 = \nabla f(\mathbf{x}^{(3)}) = (0, 0)^T$$

因此, $\mathbf{x}^{(3)}$ 为最优解.

对于正定二次函数, 可以证明, DFP 方法中构造出来的搜索方向是一组共轭方向, 因此 DFP 方法具有正定性和二次终止性.

拟牛顿法集中了许多算法的长处, 它的主要缺点就是所需存储量较大.

习 题

8-1 用变量轮换法求解无约束问题:

$$\min f(\mathbf{x}) = x_1^2 + 2x_2^2 - 4x_1 - 2x_1x_2$$

给定初始点为 $\mathbf{x}^{(1)} = (1, 1)^T$, 终止条件为

$$\frac{|f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)})|}{|f(\mathbf{x}^{(k)})|} \leq \delta = 0.005$$

8-2 用可变单纯形法求解

$$\min f(\mathbf{x}) = x_1^2 + 2x_2^2$$

初始顶点为 $\mathbf{x}^{(1)} = (-2, -1)^T$, $\mathbf{x}^{(2)} = (2, 3)^T$, $\mathbf{x}^{(3)} = (-3, 2)^T$, 取 $\alpha = 1, \beta = 0.5, \gamma = 2$, 允许误差 $\varepsilon = 1$, 计算到单纯形的三个初始顶点全部被取代为止.

8-3 用模式搜索法求解

$$\min f(\mathbf{x}) = x_1^2 + 2x_2^2 - x_1$$

取初始顶点 $\mathbf{x}^{(1)} = (-2, -1)^T$, 初始步长 $\alpha = \frac{1}{2}$, 计算 10 到 15 个点.

8-4 分别用最速下降法(要求迭代两次)和共轭梯度法求解下列问题的近似极小解.

(1) $\min f(\mathbf{x}) = 2x_1^2 + x_2^2$, 取初始点 $\mathbf{x}^{(1)} = (1, 1)^T$.

(2) $\min f(\mathbf{x}) = x_1^2 + 2x_2^2 + 4x_3^2 - 4x_1 - 2x_1x_2 - 8x_3$, 取初始点

$$\mathbf{x}^{(1)} = (1, 1, 1)^T.$$

8-5 用牛顿法求解:

$$\min f(\mathbf{x}) = 2x_1^2 + (x_2 - 1)^2,$$

要求 $\mathbf{x}^{(1)} = (1, 0)^T, \varepsilon = 0.2$.

8-6 用阻尼牛顿法求解:

$$\min f(\mathbf{x}) = (x_1 - 1)^4 + (x_1 - x_2)^2$$

要求 $\mathbf{x}^{(1)} = (0, 0)^T, \varepsilon = 10^{-6}$.

8-7 用共轭梯度法求解无约束问题

$$\min f(\mathbf{x}) = 2x_1^2 - 2x_1x_2 + x_2^2 + 2x_1 - 2x_2$$

取 $\mathbf{x}^{(1)} = (0, 0)^T$.

8-8 用 DFP 方法求解无约束问题

$$\min f(\mathbf{x}) = x_1^2 - x_1x_2 + x_2^2 + x_1 - 2x_2$$

取 $x^{(1)} = (0, 0)^T$.

8-9 证明阻尼牛顿法具有二次终止性.

8-10 设 $f(x)$ 是 n 维正定二次函数

$$f(x) = \frac{1}{2}x^T A x + B^T x + C$$

若 $d^{(1)}, d^{(2)}, \dots, d^{(n)}$ 是关于 A 的 n 个非零共轭方向, 证明: $f(x)$ 的极小点 x^* 可以表示成

$$x^* = - \sum_{k=1}^n \frac{B^T d^{(k)}}{(d^{(k)})^T A d^{(k)}} d^{(k)}$$

第9章 约束问题最优化方法

上一章介绍了无约束问题的最优化方法. 但实际问题大多是有约束条件的问题. 求解有约束条件的问题比起无约束问题要困难得多, 也复杂得多. 在每次迭代时, 不仅要使目标函数值有所下降, 而且要使迭代点都落在可行域内(个别算法除外). 求解带有约束的极值问题的基本思路在第七章已经做过介绍, 即将约束问题化为一个或一系列的无约束极值问题; 将非线性规划问题化为近似的线性规划; 将复杂问题变为简单问题等.

9.1 约束优化问题的最优性条件

约束条件下求极小值的非线性规划问题的数学模型如下:

$$\begin{aligned} \min & f(x) \\ \text{s. t. } & h_i(x) = 0 \quad (i = 1, 2, \dots, m) \\ & g_j(x) \geq 0 \quad (j = 1, 2, \dots, l) \end{aligned} \quad (9-1)$$

9.1.1 基本概念

1. 起作用约束

设非线性规划问题(9-1)的可行域为 $\mathcal{H}$

$$\mathcal{H} = \{x \mid x \in \mathbb{R}^n, h_i(x) = 0, g_j(x) \geq 0, i = 1, 2, \dots, m, j = 1, 2, \dots, l\}$$

$x^{(1)} \in \mathcal{H}$, 考虑某一个不等式约束 $g_j(x) \geq 0$, $x^{(1)}$ 满足它有两种可能: 其一是 $g_j(x) > 0$, 这时, $x^{(1)}$ 不是处于由这一约束条件形成的可行域的边界上, 因此当点不论沿什么方向稍微离开 $x^{(1)}$ 时, 都不会违背这一约束条件, 这样的约束就称为 $x^{(1)}$ 点的不起作用约束, 它对 $x^{(1)}$ 的微小扰动不起限制作用; 注意, 不起作用约束并不是无效约束! 其二是 $g_j(x) = 0$, 这时 $x^{(1)}$ 处于由这一约束条件形成的可行域的边界上, 它对 $x^{(1)}$ 点的扰动起到了某种限制作用, 即当点沿某些方向稍微离开 $x^{(1)}$ 时, 仍能满足约束条件, 而当点沿另一些方向离开 $x^{(1)}$ 时, 不论步长多么小, 都将违背该约束条件. 这样的约束称为 $x^{(1)}$ 点的起作用约束. 显然, 等式约束对所有可行点来说都是起作用约束. 特别地, 对于只含不等式约束的非线性规划问题, 严格内点(即不在可行域边界上的点)不存在起作用的约束.

2. 正则点

对于非线性规划问题(9-1), 如果在可行点 $x^{(1)}$ 处, 各起作用约束的梯度线性无关, 则 $x^{(1)}$ 是约束条件的一个正则点, 特别地, 严格内点也是约束条件的正则点.

3. 可行下降方向的判定条件

在 7.4 节给出了可行下降方向的定义, 在这里推导可行下降方向的判定条件.

设 $x^{(1)} \in \mathcal{H}$, 定义集合

$$I(x^{(1)}) = \{i \mid g_i(x^{(1)}) = 0, 1 \leq i \leq l\}$$

为 $\mathbf{x}^{(1)}$ 点所有起作用约束的下标的集合.

若 $\mathbf{d}$ 是可行点 $\mathbf{x}^{(1)}$ 处的任一可行方向, 根据可行方向的定义, 则存在实数 $\lambda_1 > 0$, 使对于任意的 λ ($0 < \lambda < \lambda_1$) 均有

$$(\mathbf{x}^{(1)} + \lambda \mathbf{d}) \in \mathcal{H}$$

即

$$g_j(\mathbf{x}^{(1)} + \lambda \mathbf{d}) \geq 0$$

亦即

$$g_j(\mathbf{x}^{(1)} + \lambda \mathbf{d}) \geq g_j(\mathbf{x}^{(1)}) = 0 \quad (j \in I(\mathbf{x}^{(1)}))$$

因此有

$$\left. \frac{dg_j(\mathbf{x}^{(1)} + \lambda \mathbf{d})}{d\lambda} \right|_{\lambda \rightarrow 0} = \nabla g_j(\mathbf{x}^{(1)})^T \cdot \mathbf{d} \geq 0 \quad (j \in I(\mathbf{x}^{(1)}))$$

也就是说, 如果 $\mathbf{d}$ 是可行点 $\mathbf{x}^{(1)}$ 处的可行方向, 那么一定有

$$\nabla g_j(\mathbf{x}^{(1)})^T \cdot \mathbf{d} \geq 0 \quad (j \in I(\mathbf{x}^{(1)}))$$

另一方面, 若 $\mathbf{d}$ 是可行点 $\mathbf{x}^{(1)}$ 处的一个方向, 由 Taylor 公式有

$$g_j(\mathbf{x}^{(1)} + \lambda \mathbf{d}) = g_j(\mathbf{x}^{(1)}) + \lambda \nabla g_j(\mathbf{x}^{(1)})^T \mathbf{d} + O_1(\lambda) \quad (9-2)$$

先考虑 $\mathbf{x}^{(1)}$ 点的所有起作用约束: 因为 $g_j(\mathbf{x}^{(1)}) = 0$, 故当 $\lambda > 0$ 足够小时, 由式(9-2)可知, 只要

$$\nabla g_j(\mathbf{x}^{(1)})^T \cdot \mathbf{d} > 0 \quad (j \in I(\mathbf{x}^{(1)})) \quad (9-3)$$

就有

$$g_j(\mathbf{x}^{(1)} + \lambda \mathbf{d}) \geq 0 \quad (j \in I(\mathbf{x}^{(1)}))$$

即 $(\mathbf{x}^{(1)} + \lambda \mathbf{d}) \in \mathcal{H}$, $\mathbf{d}$ 是可行方向.

再考虑 $\mathbf{x}^{(1)}$ 的不起作用约束: 因为 $g_j(\mathbf{x}^{(1)}) > 0$, 故当 $\lambda > 0$ 足够小时, 即在 $\mathbf{d}$ 方向上稍稍离开 $\mathbf{x}^{(1)}$ 时, 根据函数的连续性, 必然有

$$g_j(\mathbf{x}^{(1)} + \lambda \mathbf{d}) \geq 0 \quad (j \notin I(\mathbf{x}^{(1)}))$$

即 $(\mathbf{x}^{(1)} + \lambda \mathbf{d}) \in \mathcal{H}$, $\mathbf{d}$ 是可行方向.

综上所述, 只要 $\mathbf{d}$ 满足式(9-3), 即可保证它是 $\mathbf{x}^{(1)}$ 处的可行方向.

若 $\mathbf{d}$ 是可行点 $\mathbf{x}^{(1)}$ 处的某一方方向, 由 Taylor 公式有

$$f(\mathbf{x}^{(1)} + \lambda \mathbf{d}) = f(\mathbf{x}^{(1)}) + \lambda \nabla f(\mathbf{x}^{(1)})^T \mathbf{d} + O_2(\lambda) \quad (9-4)$$

由式(9-4)可知, 当 λ 足够小时, 只要

$$\nabla f(\mathbf{x}^{(1)})^T \mathbf{d} < 0 \quad (9-5)$$

就有 $f(\mathbf{x}^{(1)} + \lambda \mathbf{d}) < f(\mathbf{x}^{(1)})$, 也就是说, 只要方向 $\mathbf{d}$ 满足式(9-5), 即可保证它为 $\mathbf{x}^{(1)}$ 点的下降方向.

如果方向 $\mathbf{d}$ 同时满足式(9-3)和式(9-5), 则方向 $\mathbf{d}$ 既是 $\mathbf{x}^{(1)}$ 点的可行方向, 又是 $\mathbf{x}^{(1)}$ 点的下降方向, 从而是 $\mathbf{x}^{(1)}$ 点的可行下降方向.

假如 $\mathbf{x}^{(1)}$ 不是极小点, 继续寻优时的搜索方向就应从该点的可行下降方向中去找. 显然, 若某点存在可行下降方向, 它就不会是极小点; 若某点为极小点, 则在该点不存在可行下降方向, 反之未必能成立.

可行下降方向有十分明确的几何意义: 点 $\mathbf{x}^{(1)}$ 处的可行下降方向 $\mathbf{d}$ 与该点处目标函数

的负梯度方向的夹角为锐角,与该点处起作用约束函数的梯度方向的夹角也为锐角.

9.1.2 Kuhn - Tucker 条件(一阶必要条件)

Kuhn - Tucker 条件是非线性规划领域中最重要理论成果之一,是确定某点是最优点的一阶必要条件.只要是最优点(在一定的附加条件下)就必须满足这个条件,但一般来说它并不是充分条件,因而满足这个条件的点不一定是最优点.但对于凸规划,Kuhn - Tucker 条件既是最优点存在的必要条件,同时也是充分条件.

1. Kuhn - Tucker 条件

Kuhn - Tucker 条件就是下面的定理.

定理 9-1 考虑问题(9-1),设 $x^* \in \mathcal{R}$, $I(x^*) = \{i | g_i(x^*) = 0, 1 \leq i \leq l\}$, $f(x)$ 与 $g_i(x)$ ($i \in I(x^*)$) 在点 x^* 处可微, $g_i(x)$ ($i \notin I(x^*)$) 在点 x^* 处连续, $h_j(x)$ ($j = 1, 2, \dots, m$) 在点 x^* 处连续可微,且向量集

$$\{\nabla g_i(x^*), \nabla h_j(x^*) | i \in I(x^*), j = 1, 2, \dots, l\}$$

线性无关.若 x^* 是问题(9-1)的局部最优解,则存在 $\gamma^* = (\gamma_1^*, \gamma_2^*, \dots, \gamma_l^*)^T$ 和向量 $\lambda^* = (\lambda_1^*, \lambda_2^*, \dots, \lambda_m^*)^T$,使下述条件成立:

$$\begin{cases} \nabla f(x^*) - \sum_{j=1}^l \gamma_j^* \nabla g_j(x^*) - \sum_{i=1}^m \lambda_i^* \nabla h_i(x^*) = 0 \\ \gamma_j^* g_j(x^*) = 0 \quad (j = 1, 2, \dots, l) \\ \gamma_j^* \geq 0 \quad (i = 1, 2, \dots, l) \end{cases} \quad (9-6)$$

式(9-6)就是既含有等式约束又含有不等式约束的非线性规划问题的 Kuhn - Tucker 条件,简称 K - T 条件,满足 Kuhn - Tucker 条件的点称为 Kuhn - Tucker 条件点或者 K - T 点.如果一个非线性规划问题只含有等式约束或者只含有不等式约束,其相应的 Kuhn - Tucker 条件也相应地具有更简化的形式.

通常称函数 $[f(x) - \sum_{j=1}^l \gamma_j g_j(x) - \sum_{i=1}^m \lambda_i h_i(x)]$ 为问题(9-1)的广义拉格朗日函数,称乘子 $\gamma_1^*, \gamma_2^*, \dots, \gamma_l^*$ 和 $\lambda_1^*, \lambda_2^*, \dots, \lambda_m^*$ 为广义拉格朗日乘子,称向量 λ^* 和 γ^* 为乘子向量.

由式(9-6)的第二个向量方程可知,当不等式约束 $g_j(x) \geq 0$ 在 x^* 处为不起作用约束时, γ_j^* 必为零,在运用 K - T 条件求 K - T 点时,利用这一点可以大大简化计算,另外还要把约束条件都加上.

2. 求满足 Kuhn - Tucker 条件的点

下面通过两个例子来介绍如何根据 Kuhn - Tucker 条件求 Kuhn - Tucker 点.

例 9-1 求下列非线性规划问题的 Kuhn - Tucker 点.

$$\begin{aligned} \min f(x) &= 2x_1^2 + 2x_1x_2 + x_2^2 - 10x_1 - 10x_2 \\ \text{s. t. } 5 - x_1^2 - x_2^2 &\geq 0 \\ 6 - 3x_1 - x_2 &\geq 0 \end{aligned}$$

解 设 $g_1(x) = 5 - x_1^2 - x_2^2$, $g_2(x) = 6 - 3x_1 - x_2$, K - T 点为 $x^* = (x_1, x_2)^T$, 因为

$$\nabla f(x^*) = \begin{bmatrix} 4x_1 + 2x_2 - 10 \\ 2x_1 + 2x_2 - 10 \end{bmatrix}$$

$$\nabla g_1(\mathbf{x}^*) = \begin{bmatrix} -2x_2 \\ -2x_2 \end{bmatrix}$$

$$\nabla g_2(\mathbf{x}^*) = \begin{bmatrix} -3 \\ -1 \end{bmatrix}$$

故根据 K-T 条件有

$$4x_1 + 2x_2 - 10 + 2\gamma_1 x_1 + 3\gamma_2 = 0$$

$$2x_1 + 2x_2 - 10 + 2\gamma_1 x_2 + \gamma_2 = 0$$

$$\gamma_1(5 - x_1^2 - x_2^2) = 0$$

$$\gamma_2(6 - 3x_1 - x_2) = 0$$

$$\gamma_1 \geq 0$$

$$\gamma_2 \geq 0$$

联立求解上述方程组(若原问题含有等式约束,还要把各等式约束也作为方程加到联立方程组中),即可求出 $\gamma_1, \gamma_2, x_1, x_2$, 得到满足 K-T 条件的点. 上述方程组方程的个数与未知量的个数相等,理论上讲是可解的,但是方程组中包含高次方程,直接求解不容易. 一般的做法是分情况讨论 γ_1, γ_2 的取值情况,以简化方程组的求解. 此外,方程组的解也未必就是要求的 K-T 点,需要进行检验,即检验以下两个条件成立:① $\gamma_1 \geq 0, \gamma_2 \geq 0$;② $\mathbf{x}^* = (x_1, x_2)^T$ 是可行点.

下面讨论 γ_1, γ_2 的取值情况,对应两个约束在 $\mathbf{x}^* = (x_1, x_2)^T$ 是否为起作用约束.

(1) 假设两个约束全不是起作用约束. 这时, $\gamma_1 = \gamma_2 = 0$, 故有

$$4x_1 + 2x_2 - 10 = 0$$

$$2x_1 + 2x_2 - 10 = 0$$

解得

$$x_1 = 0$$

$$x_2 = 5$$

代入原问题约束中,它不是可行点.

(2) 假设第一个约束为起作用约束,第二个约束为不起作用约束. 这时, $\gamma_2 = 0$, 故有

$$4x_1 + 2x_2 - 10 + 2\gamma_1 x_1 = 0$$

$$2x_1 + 2x_2 - 10 + 2\gamma_1 x_2 = 0$$

$$\gamma_1(5 - x_1^2 - x_2^2) = 0$$

$$\gamma_1 \geq 0$$

解得

$$x_1 = 1$$

$$x_2 = 2$$

$$\gamma_1 = 1$$

$$\gamma_2 = 0$$

经检验后可知, $\mathbf{x} = (1, 2)^T$ 是可行点且符合原假设,故它是一个 K-T 点. 当 $\gamma_1 = 0$ 时求出的解,情况(1)已经检验过不是可行点.

(3) 假设第一个约束为不起作用约束, 第二个约束为起作用约束。这时, $\gamma_1 = 0$, 故有

$$4x_1 + 2x_2 - 10 + 3\gamma_2 = 0$$

$$2x_1 + 2x_2 - 10 + \gamma_2 = 0$$

$$\gamma_2(6 - 3x_1 - x_2) = 0$$

$$\gamma_2 \geq 0$$

求解上述方程组可知, γ_2 有两组解: $\gamma_2 = 0$ 或 $\gamma_2 = -\frac{2}{5}$. 舍去 $\gamma_2 = -\frac{2}{5}$, 而由 $\gamma_1 = \gamma_2 = 0$ 求出的解, 情况(1)已经检验过不是可行点.

(4) 假设两个约束均为起作用约束。这时, $\gamma_1 > 0, \gamma_2 > 0$, 故有

$$4x_1 + 2x_2 - 10 + 2\gamma_1 x_1 + 3\gamma_2 = 0$$

$$2x_1 + 2x_2 - 10 + 2\gamma_1 x_2 + \gamma_2 = 0$$

$$\gamma_1(5 - x_1^2 - x_2^2) = 0$$

$$\gamma_2(6 - 3x_1 - x_2) = 0$$

求解上述方程组, 得到的解不满足 $\gamma_1 \geq 0$ 与 $\gamma_2 \geq 0$, 故舍去.

综上所述, 求出满足 K-T 条件的点是

$$\mathbf{x}^* = (1, 2)^T$$

例 9-2 求下列非线性规划问题的 K-T 点.

$$\begin{aligned} \min f(\mathbf{x}) &= \sum_{i=1}^n x_i^p \\ \text{s. t. } h(\mathbf{x}) &= \sum_{i=1}^n x_i - a = 0 \end{aligned}$$

其中 $p > 1, a > 0$.

解 设 K-T 点为 $\mathbf{x}^* = (x_1, x_2, \dots, x_n)^T$, 因为

$$\nabla f(\mathbf{x}^*) = (px_1^{p-1}, px_2^{p-1}, \dots, px_n^{p-1})^T$$

$$\nabla h(\mathbf{x}^*) = (1, 1, \dots, 1)^T$$

故根据 K-T 条件有

$$px_1^{p-1} - \lambda = 0$$

$$px_2^{p-1} - \lambda = 0$$

$$\vdots$$

$$px_n^{p-1} - \lambda = 0$$

再把等式约束也看成一个方程

$$h(\mathbf{x}) = \sum_{i=1}^n x_i - a = 0$$

联立求解以上方程组得

$$x_1 = x_2 = \dots = x_n = \frac{a}{n}$$

经检验 $\mathbf{x}^* = \left(\frac{a}{n}, \frac{a}{n}, \dots, \frac{a}{n}\right)^T$ 是一个可行点, 从而是一个 K-T 点.

9.1.3 关于凸规划的全局最优解定理

对于非线性规划问题(9-1)而言,若 $f(x)$ 是凸函数, $g_j(x)$ ($j=1,2,\dots,l$)是凹函数, $h_i(x)$ ($i=1,2,\dots,m$)是线性函数,可行域为 $\mathcal{H}$, $x^* \in \mathcal{H}$,且在 x^* 处有K-T条件(9-6)成立,则 x^* 是全局最优解.

显然,上述定理中的可行域 $\mathcal{H}$ 是凸集,又目标函数 $f(x)$ 是凸函数,故问题属于凸规划.由上述定理可知,对凸规划问题而言,K-T条件是局部极小点的一阶必要条件,同时也是充分条件,而且局部极小点就是全局极小点.例9-1和例9-2(当 $x \geq 0$ 时)中的问题都是凸规划,因此所求得的K-T点是全局极小点.

9.1.4 二阶充分条件

9.1.4.1 二阶充分条件

对非线性规划问题(9-1)而言,若 $f(x)$ 、 $g_j(x)$ ($j=1,2,\dots,l$)、 $h_i(x)$ ($i=1,2,\dots,m$)二次连续可微, x^* 是可行点,又存在向量

$$\lambda^* = (\lambda_1^*, \lambda_2^*, \dots, \lambda_m^*)^T \quad \text{和} \quad \gamma^* = (\gamma_1^*, \gamma_2^*, \dots, \gamma_l^*)^T$$

使K-T条件(9-6)成立,且对满足式(9-7)、式(9-8)、式(9-9)三个条件的任意非零向量 z 有式(9-10)成立,则 x^* 是问题(9-1)的严格局部极小点.

$$z^T \cdot \nabla g_j(x^*) = 0, \quad j \in I(x^*) \text{ 且 } \gamma_j^* > 0 \quad (9-7)$$

$$z^T \cdot \nabla g_j(x^*) \geq 0, \quad j \notin I(x^*) \text{ 且 } \gamma_j^* = 0 \quad (9-8)$$

$$z^T \cdot \nabla h_i(x^*) = 0 \quad (i = 1, 2, \dots, m) \quad (9-9)$$

$$z^T \left[\nabla^2 f(x^*) - \sum_{i=1}^m \lambda_i^* \nabla^2 h_i(x^*) - \sum_{j=1}^l \gamma_j^* \nabla^2 g_j(x^*) \right] z > 0 \quad (9-10)$$

其中 $I(x^*)$ 是 x^* 处起作用的不等式约束函数下标 j 的集合.

显然,上述二阶充分条件中的式(9-10)的

$$\left[\nabla^2 f(x^*) - \sum_{i=1}^m \lambda_i^* \nabla^2 h_i(x^*) - \sum_{j=1}^l \gamma_j^* \nabla^2 g_j(x^*) \right]$$

即为广义拉格朗日函数在点 x^* 处的海赛矩阵.若令满足式(9-7)、式(9-8)、式(9-9)三个条件的非零向量 z 构成的子空间为 M ,则式(9-10)表明,广义拉格朗日函数在点 x^* 处的海赛矩阵在子空间 M 上是正定的.

9.1.4.2 利用Kuhn-Tucker条件和二阶充分条件求约束极小

1. 第一种情况

如果能用其他方法(如几何作图或通过解约束方程组求出约束条件的交点等)先求出一个点 x^* ,这个点是约束极小的可能性很大,不妨先假设其为约束极小,再逐一证之.

(1) 证明 x^* 是可行点.

(2) 证明 x^* 是正则点.

(3) 把 x^* 代入Kuhn-Tucker条件式(9-6)中,应能求出符合条件的向量 λ^* 和 γ^* .

(4) 证明广义拉格朗日函数在点 x^* 处的海赛矩阵在子空间 M 上是正定的.

若能证明上述四点,则 x^* 是一个严格局部极小点.

2. 第二种情况

若不能先求出一个可能极小点的具体值,就先求出满足 Kuhn - Tucker 条件的点 x^* ,再证明上述(3)和(4),则 x^* 是一个严格局部极小点.

9.2 近似规划法

近似规划法是一种线性化的方法,即将非线性规划线性化,然后通过求解一系列线性规划来求原问题的近似最优解.

考虑非线性规划问题

$$\begin{aligned} \min & f(x) \\ \text{s. t. } & h_i(x) = 0 \quad (i = 1, 2, \dots, m) \\ & g_j(x) \geq 0 \quad (j = 1, 2, \dots, l) \\ & x \in \mathcal{H} \subset \mathbb{R}^n \end{aligned} \quad (9-11)$$

其中 $\mathcal{H}$ 是可行域, $\mathbb{R}^n$ 是 n 维欧氏空间.

$$f(x), h_i(x) \quad (i = 1, 2, \dots, m) \quad \text{和} \quad g_j(x) \quad (j = 1, 2, \dots, l)$$

均存在一阶连续偏导数.

近似规划法的基本思想是:将问题(9-11)中的目标函数和各约束函数都近似为线性函数,并对各变量的取值范围加以限制,从而得到一近似的线性规划.再用单纯形法求解之,把符合原始约束条件的最优解作为问题(9-11)的近似解.每得到一个近似解后,都从这一点出发,重复以上步骤.这样,通过求解一系列线性规划,产生一个由线性规划最优解组成的序列.经验表明,这样的序列往往收敛于非线性规划问题的解.应用近似规划法时,必须给定一个初始的可行点.

9.2.1 线性近似规划的构成

近似规划法的基本做法是:将问题(9-11)中的目标函数、约束函数

$$f(x), h_i(x) \quad (i = 1, 2, \dots, m) \quad \text{和} \quad g_j(x) \quad (j = 1, 2, \dots, l)$$

在点 $x^{(k)}$ 处作一阶 Taylor 展开,并取其线性近似(即舍去余项),从而得到线性近似规划,并对各变量的取值范围加以限制.因为用线性函数逼近非线性函数时,一般只在展开点附近的近似程度较好,远离展开点,可能产生较大偏差,特别是函数的非线性程度较高时,会产生更大偏差,因此需要对变量的取值范围进行限制.

设 $x^{(k)} \in \mathcal{H}$,将目标函数 $f(x)$ 与约束条件函数

$$h_i(x) \quad (i = 1, 2, \dots, m) \quad \text{和} \quad g_j(x) \quad (j = 1, 2, \dots, l)$$

在点 $x^{(k)}$ 处作一阶 Taylor 展开,并取其线性近似式,可得到下列线性规划问题:

$$\begin{aligned} \min & f(x^{(k)}) + \nabla f(x^{(k)})^T (x - x^{(k)}) \\ \text{s. t. } & g_j(x^{(k)}) + \nabla g_j(x^{(k)})^T (x - x^{(k)}) \geq 0 \quad (j = 1, 2, \dots, l) \\ & h_i(x^{(k)}) + \nabla h_i(x^{(k)})^T (x - x^{(k)}) = 0 \quad (i = 1, 2, \dots, m) \\ & |x_j - x_j^{(k)}| \leq \delta_j^{(k)} \quad (j = 1, 2, \dots, n) \end{aligned} \quad (9-12)$$

上述线性规划中最后一组不等式约束,即是对变量 x 所施加的限制.其中 x_j 是 x 的第 j 个分

量, $\delta_j^{(k)}$ ($j=1, 2, \dots, n$) 是预先给定的变量限制范围, 称为步长限制量.

求解线性规划(9-12). 设得到的最优解为 $\mathbf{x}^{(k+1)}$, 若 $\mathbf{x}^{(k+1)}$ 是原问题(9-11)的可行解, 则在这一点再将目标函数与各约束函数线性化, 并沿用步长限制:

$$\delta_j^{(k+1)} := \delta_j^{(k)} \quad (j=1, 2, \dots, n)$$

若 $\mathbf{x}^{(k+1)}$ 不属于原问题(9-11)的可行域, 则减少步长限制量, 取

$$\delta_j^{(k+1)} := \beta \cdot \delta_j^{(k)} \quad (j=1, 2, \dots, n)$$

一般 β 取 $\frac{1}{2}, \frac{1}{4}$ 等值, 重新求解当前的线性规划问题.

9.2.2 近似规划法的算法步骤

(1) 给定初始可行点 $\mathbf{x}^{(1)} \in \mathcal{H}$, 步长限制 $\delta_j^{(1)}$ ($j=1, 2, \dots, n$), 缩小系数 $\beta \in (0, 1)$, 允许误差 $\varepsilon_1, \varepsilon_2$, 置 $k=1$.

(2) 求解线性规划问题:

$$\begin{aligned} \min & f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) \\ \text{s. t. } & g_j(\mathbf{x}^{(k)}) + \nabla g_j(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) \geq 0 \quad (j=1, 2, \dots, l) \\ & h_i(\mathbf{x}^{(k)}) + \nabla h_i(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) = 0 \quad (i=1, 2, \dots, m) \\ & |x_j - x_j^{(k)}| \leq \delta_j^{(k)} \quad (j=1, 2, \dots, n) \end{aligned}$$

得最优解 $\bar{\mathbf{x}}$.

(3) 若 $\bar{\mathbf{x}}$ 满足原问题(9-11)的可行性, 则令 $\mathbf{x}^{(k+1)} = \bar{\mathbf{x}}$, 转第(4)步; 否则, 置

$$\delta_j^{(k+1)} := \beta \cdot \delta_j^{(k)} \quad (j=1, 2, \dots, n)$$

返回第(2)步.

(4) 若 $|f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)})| < \varepsilon_1$, 且满足

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| < \varepsilon_2$$

或

$$|\delta_j^{(k)}| < \varepsilon_2 \quad (j=1, 2, \dots, n)$$

则 $\mathbf{x}^{(k+1)}$ 为原问题的近似最优解, 停止迭代, 输出 $\mathbf{x}^{(k+1)}$. 否则, 令

$$\delta_j^{(k+1)} := \delta_j^{(k)} \quad (j=1, 2, \dots, n)$$

置 $k := k+1$, 返回第(2)步.

9.2.3 计算举例

例 9-3 用近似规划法求解下列问题:

$$\begin{aligned} \min & f(\mathbf{x}) = -2x_1 - x_2 \\ \text{s. t. } & g_1(\mathbf{x}) = 25 - x_1^2 - x_2^2 \geq 0 \\ & g_2(\mathbf{x}) = 7 - x_1^2 + x_2^2 \geq 0 \\ & 0 \leq x_1 \leq 5 \\ & 0 \leq x_2 \leq 10 \end{aligned}$$

给定初始可行点 $\mathbf{x}^{(1)} = \begin{bmatrix} 3 \\ 2.5 \end{bmatrix}$, $\delta^{(1)} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$, $\beta = \frac{1}{2}$, $\varepsilon_1 = \varepsilon_2 = 10^{-3}$.

解 因 $f(x) = -2x_1 - x_2$ 已是线性函数, 只需要将 $g_1(x)$ 和 $g_2(x)$ 线性化:

$$g_1(x) \approx g_1(x^{(1)}) + \nabla g_1(x^{(1)})^T (x - x^{(1)})$$

$$= 9.75 + (-6, -5) \begin{bmatrix} x_1 - 3 \\ x_2 - 2.5 \end{bmatrix}$$

$$= 40.25 - 6x_1 - 5x_2 \geq 0$$

$$g_2(x) \approx g_2(x^{(1)}) + \nabla g_2(x^{(1)})^T (x - x^{(1)})$$

$$= 4.25 + (-6, 5) \begin{bmatrix} x_1 - 3 \\ x_2 - 2.5 \end{bmatrix}$$

$$= 9.75 - 6x_1 + 5x_2 \geq 0$$

步长限制

$$|x - x^{(1)}| < \delta^{(1)}$$

即有

$$-2 \leq x_1 - 3 \leq 2$$

$$-1 \leq x_2 - 2.5 \leq 1$$

或

$$1 \leq x_1 \leq 5$$

$$1.5 \leq x_2 \leq 3.5$$

又由约束条件的限制

$$0 \leq x_1 \leq 5$$

$$0 \leq x_2 \leq 10$$

故合起来有

$$1 \leq x_1 \leq 5$$

$$1.5 \leq x_2 \leq 3.5$$

故得到近似线性规划问题

$$\min f(x) = -2x_1 - x_2$$

$$\text{s. t. } 40.25 - 6x_1 - 5x_2 \geq 0$$

$$9.75 - 6x_1 + 5x_2 \geq 0$$

$$1 \leq x_1 \leq 5$$

$$1.5 \leq x_2 \leq 3.5$$

为求解此线性规划问题, 先标准化, 令

$$y_1 = x_1 - 1$$

$$y_2 = x_2 - 1.5$$

得到

$$\min (-2y_1 - y_2 - 3.5)$$

$$\text{s. t. } 6y_1 + 5y_2 + y_3 = 26.75$$

$$6y_1 - 5y_2 + y_4 = 11.25$$

$$y_1 + y_5 = 4$$

$$y_2 + y_6 = 2$$

$$y_i \geq 0 \quad (i = 1, 2, \dots, 6)$$

用单纯形法求解,得到

$$\mathbf{x}^{(2)} = \left(\frac{25}{6}, \frac{61}{20} \right)^T$$

将 $\mathbf{x}^{(2)}$ 代入原问题的约束集,经检验, $\mathbf{x}^{(2)}$ 不满足约束条件,因此 $\mathbf{x}^{(2)}$ 不是可行点. 为此取 $\beta = 0.5$, 缩小步长限制为 $\delta^{(1)} = \beta(2, 1)^T = (1, 0.5)^T$, 返回去修改上述线性规划中的步长限制约束

$$-1 \leq x_1 - 3 \leq 1$$

$$-0.5 \leq x_2 - 2.5 \leq 0.5$$

或

$$2 \leq x_1 \leq 4$$

$$2 \leq x_2 \leq 3$$

得到 $\mathbf{x}^{(1)}$ 点新的近似线性规划:

$$\min f(\mathbf{x}) = -2x_1 - x_2$$

$$\text{s. t. } 40.25 - 6x_1 - 5x_2 \geq 0$$

$$9.75 - 6x_1 + 5x_2 \geq 0$$

$$2 \leq x_1 \leq 4$$

$$2 \leq x_2 \leq 3$$

与上次解法相似,先将上述问题标准化,再用单纯形法解之,可得到新的 $\mathbf{x}^{(2)}$ 解:

$$\mathbf{x}^{(2)} = (4, 3)^T$$

$$f(\mathbf{x}^{(2)}) = -11$$

将 $\mathbf{x}^{(2)}$ 代入原问题的约束集,经检验, $\mathbf{x}^{(2)}$ 满足约束条件,因此 $\mathbf{x}^{(2)}$ 是可行点.

因此需要将 $g_1(\mathbf{x})$ 和 $g_2(\mathbf{x})$ 在 $\mathbf{x}^{(2)}$ 线性化,得到一个新的线性规划问题,与上面的过程是一致的,求解这个新的线性规划问题,得到线性规划问题的最优解为

$$\mathbf{x}^{(3)} = (4, 3)^T$$

故有

$$|f(\mathbf{x}^{(3)}) - f(\mathbf{x}^{(2)})| = 0 < \varepsilon_1$$

$$\|\mathbf{x}^{(3)} - \mathbf{x}^{(2)}\| = 0 < \varepsilon_2$$

因此原问题的最优解和最优目标函数值分别是

$$\mathbf{x}^* = (4, 3)^T$$

$$f(\mathbf{x}^*) = -11$$

9.3 可行方向法

在9.1节中介绍了约束问题的最优性条件,也看到了利用K-T条件来求极小点是很困难的. 因此带有约束的非线性规划问题仍以迭代算法为主要的求解算法.

考虑非线性规划问题:

$$\begin{aligned} \min & f(\mathbf{x}) \\ \text{s. t. } & g_j(\mathbf{x}) \geq 0 \quad (j = 1, 2, \dots, l) \\ & \mathbf{x} \in \mathcal{H} \subset \mathbb{R}^n \end{aligned} \quad (9-13)$$

其中 $\mathcal{H}$ 是问题(9-13)的可行域, 设 $\mathbf{x}^{(k)}$ 是它的一个可行点, 但并不是所要求的极小点. 为了求得极小点或近似极小点, 应在 $\mathbf{x}^{(k)}$ 的可行下降方向中选取某一方向 $\mathbf{d}^{(k)}$ 为搜索方向, 然后确定该方向上的步长 λ_k , 使

$$\begin{aligned} \mathbf{x}^{(k+1)} &= \mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)} \in \mathcal{H} \\ f(\mathbf{x}^{(k+1)}) &< f(\mathbf{x}^{(k)}) \end{aligned} \quad (9-14)$$

若满足精度要求, 停止迭代, $\mathbf{x}^{(k+1)}$ 就是所要求的点; 否则, 从 $\mathbf{x}^{(k+1)}$ 出发继续迭代, 直到满足要求为止. 上述方法称为可行方向法. 它具有下述特点: 迭代过程中所采用的搜索方向为可行方向, 所产生的迭代点列 $\{\mathbf{x}^{(k)}\}$ 始终在可行域内, 目标函数值单调下降. 这是一类算法, 由不同的规则产生出的可行方向作为搜索方向形成了不同的可行方向法, 这类方法可以看作无约束非线性规划问题下降迭代类算法的自然推广. 但通常说的可行方向法指的是 Zoutendijk 在 1960 年提出的算法及其变形. 下面介绍 Zoutendijk 可行方向法, 这是一种线性化方法.

9.3.1 基本原理与算法步骤

1. 给定初始可行点 $\mathbf{x}^{(1)} \in \mathcal{H}$, 允许误差 $\varepsilon_1 > 0, \varepsilon_2 > 0$, 并置 $k = 1$

2. 确定 $\mathbf{x}^{(k)}$ 点处的起作用约束下标集 $I(\mathbf{x}^{(k)})$:

$$I(\mathbf{x}^{(k)}) = \{i \mid g_i(\mathbf{x}^{(k)}) = 0, 1 \leq i \leq l\}$$

(1) 若 $I(\mathbf{x}^{(k)}) = \emptyset$ (空集), 而且 $\|\nabla f(\mathbf{x}^{(k)})\| < \varepsilon_1$, 则停止迭代, 得到近似极小点 $\mathbf{x}^{(k)}$.

(2) 若 $I(\mathbf{x}^{(k)}) = \emptyset$, 但 $\|\nabla f(\mathbf{x}^{(k)})\| \geq \varepsilon_1$, 则取搜索方向 $\mathbf{d}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$, 然后转第 5 步.

因为 $I(\mathbf{x}^{(k)}) = \emptyset$, 表明 $\mathbf{x}^{(k)}$ 处于可行域内部, 因此任一方向均是 $\mathbf{x}^{(k)}$ 点处的可行方向, 类似于无约束的极值问题. 因此可采用最速下降法寻求下一个迭代点 $\mathbf{x}^{(k+1)}$. 需要注意的是, 毕竟不是真正的无约束问题, 因此步长不能太大, 仍要保证 $\mathbf{x}^{(k+1)} \in \mathcal{H}$. 此时作一维搜索时, 对步长 λ 的最大值提出控制范围 (具体内容见第 5 步).

(3) 若 $I(\mathbf{x}^{(k)}) \neq \emptyset$, 转第 3 步.

这时表明 $\mathbf{x}^{(k)}$ 处于可行域 $\mathcal{H}$ 的边界上, 故要找出一个可行方向作为搜索方向. 本方法是通过构造并求解一个线性规划问题来求得搜索方向.

3. 求解线性规划问题, 得最优解 $(\mathbf{d}^{(k)}, \eta)$

当 $I(\mathbf{x}^{(k)}) \neq \emptyset$ 时, $\mathbf{x}^{(k)}$ 点的可行下降方向为 $\mathbf{d}^{(k)}$, 根据 $\mathbf{x}^{(k)}$ 处可行下降方向的判定条件, 即式(9-3)和式(9-5)有

$$\begin{cases} \nabla f(\mathbf{x}^{(k)})^T \cdot \mathbf{d} < 0 \\ \nabla g_i(\mathbf{x}^{(k)})^T \cdot \mathbf{d} > 0, \quad i \in I(\mathbf{x}^{(k)}) \end{cases}$$

而上述方程组当引进数 η 后, 等价于下述不等式组求向量 $\mathbf{d}$ 与实数 η .

$$\begin{cases} \nabla f(\mathbf{x}^{(k)})^T \cdot \mathbf{d} \leq \eta \\ -\nabla g_i(\mathbf{x}^{(k)})^T \cdot \mathbf{d} \leq \eta, i \in I(\mathbf{x}^{(k)}) \\ \eta < 0 \end{cases}$$

因为满足上述不等式组的可行方向 $\mathbf{d}$ 与实数 η 一般有很多个, 而我们希望求出能使目标函数值下降最快的方向 $\mathbf{d}$. 因此将问题转化为对 η 求极小值的一个线性规划问题. 此外, 求一个向量 $\mathbf{d}$ 只需知道该向量各分量之间的相对大小, 就可确定该向量的方向. 为此, 对向量 $\mathbf{d}$ 的各分量增加一个约束, 即各分量 d_j 的绝对值不超过 1. 若不加此约束, 线性规划就可能得出无界的解. 故有下述线性规划

$$\begin{aligned} \min \quad & \eta \\ \text{s. t.} \quad & \nabla f(\mathbf{x}^{(k)})^T \cdot \mathbf{d} \leq \eta \\ & -\nabla g_i(\mathbf{x}^{(k)})^T \cdot \mathbf{d} \leq \eta, i \in I(\mathbf{x}^{(k)}) \\ & -1 \leq d_j \leq 1 \quad (j = 1, 2, \dots, n) \end{aligned} \quad (9-15)$$

求解之, 设其最优解为 $(\mathbf{d}^{(k)}, \eta_k)$.

4. 判断精度

若满足 $|\eta_k| < \varepsilon_2$, 则停止迭代, 得到点 $\mathbf{x}^{(k)}$. 因为 $\eta_k \approx 0$, 说明 $\mathbf{x}^{(k)}$ 点找不到可行下降方向, 因此 $\mathbf{x}^{(k)}$ 点是一个 Kuhn-Tucker 点(假定 $\mathbf{x}^{(k)}$ 是一个正则点); 否则以 $\mathbf{d}^{(k)}$ 为搜索方向, 转第 5 步.

5. 在搜索方向上, 确定可行的最优步长 λ_k

λ_k 的选择, 除了要使目标函数尽可能减小外(在 $\mathbf{d}^{(k)}$ 方向上), 还要保证 $(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)})$ 点的可行性. 因此先要找出使点 $(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)}) \in \mathcal{H}$ 的 λ 的上限 $\bar{\lambda}$, 然后在 $0 \leq \lambda \leq \bar{\lambda}$ 范围内选择 λ_k , 即

$$f(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}) = \min_{0 \leq \lambda \leq \bar{\lambda}} f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})$$

其中

$$\bar{\lambda} = \max \left\{ \lambda \mid \mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)} \in \mathcal{H} \right\}$$

6. 令 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}$, 置 $k := k + 1$, 返回第 2 步

9.3.2 计算举例

例 9-4 用可行方向法求解以下非线性规划问题:

$$\begin{aligned} \min \quad & f(\mathbf{x}) = -4x_1 - 4x_2 + x_1^2 + x_2^2 \\ \text{s. t.} \quad & g_1(\mathbf{x}) = -x_1 - 2x_2 + 3 \geq 0 \end{aligned}$$

给定初始点 $\mathbf{x}^{(1)} = (0, 0)^T$, $\varepsilon_1 = \varepsilon_2 = 10^{-3}$.

解

$$f(\mathbf{x}^{(1)}) = 0$$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 - 4 \\ 2x_2 - 4 \end{bmatrix}$$

$$\nabla f(\mathbf{x}^{(1)}) = \begin{bmatrix} -4 \\ -4 \end{bmatrix}$$

$$\nabla g_1(\mathbf{x}) = \begin{bmatrix} -1 \\ -2 \end{bmatrix}$$

因为 $g_1(\mathbf{x}^{(1)}) = 3 > 0$, 故 $I(\mathbf{x}^{(1)}) = \emptyset$, 又因为

$$\|\nabla f(\mathbf{x}^{(1)})\|^2 = 32$$

故 $\mathbf{x}^{(1)}$ 不是极小点. 现取搜索方向

$$\mathbf{d}^{(1)} = -\nabla f(\mathbf{x}^{(1)}) = (4, 4)^T$$

假设

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda \mathbf{d}^{(1)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \lambda \begin{bmatrix} 4 \\ 4 \end{bmatrix} = \begin{bmatrix} 4\lambda \\ 4\lambda \end{bmatrix}$$

为保证 $\mathbf{x}^{(2)}$ 是可行点, 应有 $g_1(\mathbf{x}^{(2)}) \geq 0$, 即

$$-4\lambda - 8\lambda + 3 \geq 0$$

$$\lambda \leq \frac{1}{4}$$

即满足约束条件的步长 λ 的上限 $\bar{\lambda}_1 = \frac{1}{4}$.

将 $\mathbf{x}^{(2)}$ 代入目标函数, 有

$$f(\mathbf{x}^{(2)}) = -16\lambda - 16\lambda + 16\lambda^2 + 16\lambda^2 = 32\lambda^2 - 32\lambda$$

令

$$\frac{df(\mathbf{x}^{(2)})}{d\lambda} = 64\lambda - 32 = 0$$

可得

$$\lambda_1^* = \frac{1}{2}$$

因为 $\lambda_1^* > \bar{\lambda}_1$, 故舍去 λ_1^* . 求满足

$$\min_{0 \leq \lambda \leq \bar{\lambda}_1} f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})$$

的 λ 值, 令其为可行的最优步长 λ_1 , 有 $\lambda_1 = \bar{\lambda}_1 = \frac{1}{4}$. 故

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda_1 \mathbf{d}^{(1)} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$f(\mathbf{x}^{(2)}) = -6$$

$$\nabla f(\mathbf{x}^{(2)}) = \begin{bmatrix} -2 \\ -2 \end{bmatrix}$$

$$g_1(\mathbf{x}^{(2)}) = 0$$

现构成下述线性规划问题

$$\begin{aligned} \min \quad & \eta \\ \text{s. t.} \quad & -d_1 - 2d_2 \leq \eta \\ & d_1 + 2d_2 \leq \eta \\ & -1 \leq d_1 \leq 1 \\ & -1 \leq d_2 \leq 1 \end{aligned}$$

求解以上线性规划得最优结果为

$$\eta = -\frac{1}{2}, \quad \mathbf{d}^{(2)} = \left(1, -\frac{3}{4}\right)^T$$

不满足精度要求,需要继续迭代.

假设

$$\mathbf{x}^{(3)} = \mathbf{x}^{(2)} + \lambda \mathbf{d}^{(2)} = \left(1 + \lambda, 1 - \frac{3}{4}\lambda\right)^T$$

将 $\mathbf{x}^{(3)}$ 代入目标函数,有

$$f(\mathbf{x}^{(3)}) = \frac{25}{16}\lambda^2 - \frac{1}{2}\lambda - 6$$

令

$$\frac{df(\mathbf{x}^{(3)})}{d\lambda} = \frac{25}{8}\lambda - \frac{1}{2} = 0$$

可得

$$\lambda_2^* = 0.16$$

现暂定可行的最优步长 $\lambda_2 = \lambda_2^*$, 则有

$$\mathbf{x}^{(3)} = \mathbf{x}^{(2)} + \lambda_2 \mathbf{d}^{(2)} = (1.16, 0.88)^T$$

将 $\mathbf{x}^{(3)}$ 代入约束条件,有

$$g_1(\mathbf{x}^{(3)}) = 0.08 > 0$$

故 $\mathbf{x}^{(3)}$ 为可行点,即选取 $\lambda_2 = \lambda_2^* = 0.16$ 是正确的,有 $f(\mathbf{x}^{(3)}) = -6.04$.

如此继续迭代下去,一定可得最优解. 限于篇幅,后面的过程不再列出.

9.4 罚函数法

本节介绍求解非线性规划问题的罚函数法,其基本思想是通过构造罚函数,将约束问题转化为一系列无约束问题,进而用无约束最优化方法求解,因此该方法也称为序列无约束最小化技术,简记为 SUMT(Sequential Unconstrained Minimization Technique). 罚函数法共分外点罚函数法(简称外点法)、内点罚函数法(简称内点法)和混合罚函数法(简称混合法).

9.4.1 外点法

考虑非线性规划问题

$$\begin{aligned} \min & f(\mathbf{x}) \\ \text{s. t. } & h_i(\mathbf{x}) = 0 \quad (i = 1, 2, \dots, m) \\ & g_j(\mathbf{x}) \geq 0 \quad (j = 1, 2, \dots, l) \\ & \mathbf{x} \in \mathcal{H} \subset \mathbb{R}^n \end{aligned} \quad (9-16)$$

其中, $f(\mathbf{x})$ 、 $h_i(\mathbf{x})$ 和 $g_j(\mathbf{x})$ 是 $\mathbb{R}^n$ 上的连续函数, $\mathcal{H}$ 是可行域.

9.4.1.1 外点法的基本原理

外点法可以用来解决只含有等式约束、只含有不等式约束或同时含有等式和不等式约束的问题.

由于上述问题的约束为非线性,不能用消元法将该问题化为无约束问题,而在求解时必须同时考虑既使目标函数值下降,又要满足约束条件. 为此,可以通过构造一个由目标函数与约束函数组成的罚函数的办法. 对罚函数实行极小化来实现这一目的.

为了便于说明问题,先考虑只含有不等式约束的问题:

$$\begin{aligned} \min & f(x) \\ \text{s. t. } & g_j(x) \geq 0 \quad (j = 1, 2, \dots, l) \end{aligned} \quad (9-17)$$

构造一个函数 $\psi(t)$:

$$\psi(t) = \begin{cases} 0 & \text{当 } t \geq 0 \\ \infty & \text{当 } t < 0 \end{cases} \quad (9-18)$$

现把 $g_j(x)$ 看成 t , 显然当 $x \in \mathcal{H}$ 时, $\psi(g_j(x)) = 0$ ($j = 1, 2, \dots, l$); 当 $x \notin \mathcal{H}$ 时, $\psi(g_j(x)) = \infty$.

再构造函数 $\varphi(x)$:

$$\varphi(x) = f(x) + \sum_{j=1}^l \psi(g_j(x)) \quad (9-19)$$

现来求解无约束问题

$$\min \varphi(x) \quad (9-20)$$

若问题(9-20)有解, 设其最优解为 x^* , 则由式(9-18)与式(9-19)应有

$$\psi(g_j(x^*)) = 0$$

(请读者思考式成立的理由是什么?)

这就是说 $x^* \in \mathcal{H}$, 因此 x^* 不仅是式(9-20)的极小解, 它也是问题(9-17)的极小解, 因此就将约束问题(9-17)的求解化为无约束问题(9-20)的求解.

但是上述函数性态不好, 它在 $t=0$ 点不连续, 也不可导. 我们希望构造出一个在任意点 t 处函数及其导数都连续的辅助函数. 可选择如下的函数

$$\psi(t) = \begin{cases} 0 & \text{当 } t \geq 0 \\ t^2 & \text{当 } t < 0 \end{cases} \quad (9-21)$$

函数(9-21)在 t 为任意值时, $\psi(t)$ 与 $\psi'(t)$ 都连续, 且当 $x \in \mathcal{H}$ 时仍有

$$\sum_{j=1}^l \psi(g_j(x)) = 0$$

当 $x \notin \mathcal{H}$ 时

$$0 < \sum_{j=1}^l \psi(g_j(x)) < \infty$$

为了使辅助函数能更快地满足要求, 将引入一个充分大的正数 M ($M > 0$), 修改 $\varphi(x)$ 为

$$p(x, M) = f(x) + M \sum_{j=1}^l \psi(g_j(x)) \quad (9-22)$$

或等价地

$$p(x, M) = f(x) + M \sum_{j=1}^l [\min(0, g_j(x))]^2 \quad (9-23)$$

求解问题(9-20)就变为求解无约束问题(9-23), 设 $p(x, M)$ 的最优解为 $\bar{x}_M$, 若 $\bar{x}_M \in \mathcal{H}$, 它必也是原问题的最优解, 这是因为对所有的 $x_M \in \mathcal{H}$, 都有

$$p(x, M) \geq p(\bar{x}_M, M)$$

而

$$\begin{aligned} p(x, M) &= f(x) + M \cdot \sum_{j=1}^l [\min(0, g_j(x))]^2 \\ &= f(x) + 0 = f(x) \end{aligned}$$

$$\begin{aligned}
 p(\bar{x}_M, M) &= f(\bar{x}_M) + M \cdot \sum_{j=1}^l [\min(0, g_j(\bar{x}_M))]^2 \\
 &= f(\bar{x}_M) + 0 = f(\bar{x}_M)
 \end{aligned}$$

(请读者思考上述两个等式成立的理由是什么?)

故有

$$f(x) \geq f(\bar{x}_M), \quad x \in \mathcal{H}$$

上式说明了 $\bar{x}_M$ 也为问题(9-17)的极小解.

称函数 $p(x, M)$ 为惩罚函数(或罚函数), 其中第二项 $M \cdot \sum_{j=1}^l [\min(0, g_j(x))]^2$ 为惩罚项, 称 M 为罚因子.

惩罚函数只对不满足约束条件的点实行惩罚. 当 $x \in \mathcal{H}$ 时, 所有的约束不等式都满足(即 $g_j(x) \geq 0$ ($j=1, 2, \dots, l$)), 故罚项等于0, 不受惩罚; 当 $x \notin \mathcal{H}$ 时, 至少有一个约束不等式不成立, 故罚项大于0, 对极小化罚函数的问题, 就要受惩罚.

同理, 对于只含有等式约束的非线性极值问题:

$$\begin{aligned}
 &\min f(x) \\
 &\text{s. t. } h_i(x) = 0 \quad (i = 1, 2, \dots, m)
 \end{aligned}$$

可以定义罚函数为

$$p(x, M) = f(x) + M \sum_{i=1}^m [h_i(x)]^2 \quad (9-24)$$

对于同时含有等式与不等式约束的非线性规划问题(9-16), 可以定义罚函数为

$$p(x, M) = f(x) + M \left\{ \sum_{j=1}^l [\min(0, g_j(x))]^2 + \sum_{i=1}^m [h_i(x)]^2 \right\} \quad (9-25)$$

对无约束问题(9-25)求解, 所得到的极小点便是约束极值问题(9-16)的极小点或近似极小点. 需要说明的是, 罚函数的形式不是唯一的.

在实际计算中, 罚因子 M 的值选得过小或过大都不好. 如果选得过小, 则罚函数的极小点远离约束问题的最优解, 计算效率很差; 如果 M 过大, 则给罚函数的极小化增加计算上的困难. 因此, 一般策略是取一个趋向无穷大的严格递增正数列 $\{M_k\}$. 从某个 M_1 开始, 对每个 M_k 求解:

$$p(x, M_k) = f(x) + M_k \left\{ \sum_{j=1}^l [\min(0, g_j(x))]^2 + \sum_{i=1}^m [h_i(x)]^2 \right\} \quad (9-26)$$

随着 M_k 值的增加, 罚函数中罚项所起的作用越来越大, 即对点远离可行域 $\mathcal{H}$ 的惩罚越来越重, 这就迫使罚函数的极小点 $x^{(k)}$ 与可行域 $\mathcal{H}$ 的“距离”越来越近. 当 M_k 趋向于正无穷大时, 点列 $\{x^{(k)}\}$ 就从可行域外部趋于原问题的极小点(可以证明, 在适当条件下, 这个点列 $\{x^{(k)}\}$ 收敛于约束问题的最优解), “外点法”正是因此而得名.

外点法是对罚函数 $p(x, M_k)$ 在整个空间 $\mathbb{R}^n$ 内进行优化, 因此, 初始点可以任意给定, 它给计算提供了方便, 这也是外点法的另一优点.

9.4.1.2 外点法的计算步骤

(1) 给定初始点 $x^{(0)}$, 初始罚因子 M_1 (例如 $M_1 = 1$), 放大系数 $\beta > 1$ (如取 $\beta = 5$ 或 10), 允许误差 $\varepsilon > 0$, 令 $k = 1$.

(2) 求解罚函数 $p(x, M_k)$ 的无约束极小化问题.

以 $x^{(k-1)}$ 为初始点, 选择适当的方法求解 $\min p(x, M_k)$, 得其极小点 $x^{(k)}$.

(3) 判断精度. 在 $x^{(k)}$ 点, 若罚项 $< \varepsilon$, 则停止计算, 得到原问题的近似极小点 $x^{(k)}$; 否则令 $M_{k+1} = \beta M_k$, 令 $k := k + 1$, 返回第(2)步.

9.4.1.3 计算举例

例 9-5 试用外点法求解非线性规划问题

$$\begin{aligned} \min f(x) &= (x_1 - 2)^2 + x_2^2 \\ \text{s. t. } g(x) &= x_2 - 1 \geq 0 \end{aligned}$$

解 构造罚函数

$$\begin{aligned} p(x, M_k) &= f(x) + M_k [\min(0, g(x))]^2 \\ &= (x_1 - 2)^2 + x_2^2 + M_k [\min(0, x_2 - 1)]^2 \\ &= \begin{cases} (x_1 - 2)^2 + x_2^2 & \text{当 } x_2 \geq 1 \\ (x_1 - 2)^2 + x_2^2 + M_k (x_2 - 1)^2 & \text{当 } x_2 < 1 \end{cases} \end{aligned}$$

用解析法求罚函数的无约束极小点:

因为

$$\begin{aligned} \frac{\partial p}{\partial x_1} &= 2(x_1 - 2) \\ \frac{\partial p}{\partial x_2} &= \begin{cases} 2x_2 & \text{当 } x_2 \geq 1 \\ 2x_2 + 2M_k(x_2 - 1) & \text{当 } x_2 < 1 \end{cases} \end{aligned}$$

令

$$\frac{\partial p}{\partial x_1} = \frac{\partial p}{\partial x_2} = 0$$

即

$$\begin{aligned} 2(x_1 - 2) &= 0 \\ 2x_2 + 2M_k(x_2 - 1) &= 0 \end{aligned}$$

故

$$x = (x_1, x_2)^T = \left(2, \frac{M_k}{1 + M_k} \right)^T$$

将 M_k 取不同值时的计算结果列于表 9-1 中.

表 9-1

M_k	1	10	100	1000	10000	$M_k \rightarrow \infty$
x_1	2	2	2	2	2	2
x_2	0.5	0.909	0.990	0.999	0.9999	1

从表 9-1 可知, 在 M_k 从 $1 \rightarrow \infty$ 逐渐增加的过程中, 罚函数的一系列无约束极小点是从可行域外部趋向 x^* 的. 本例的最优结果是

$$\begin{aligned} \mathbf{x}^* &= \begin{bmatrix} 2 \\ 1 \end{bmatrix} \\ f(\mathbf{x}^*) &= 1 \end{aligned}$$

9.4.2 内点法

9.4.2.1 内点法的基本原理

考虑非线性规划

$$\begin{aligned} \min f(\mathbf{x}) \\ \text{s. t. } g_j(\mathbf{x}) \geq 0 \quad (j = 1, 2, \dots, l) \end{aligned} \quad (9-27)$$

记

$$\mathcal{H}_1 = \{\mathbf{x} \mid g_j(\mathbf{x}) > 0, j = 1, 2, \dots, l\} \quad (9-28)$$

为可行域内部(或说是严格内点集合).

与外点法不同的是,内点法要求整个迭代过程始终在可行域内部进行,初始点也必须选一个严格内点.在可行域边界上设置一道“障碍”,以阻止搜索点到可行域边界上去,一旦接近可行域边界时,就要受到很大的惩罚,迫使迭代点始终留在可行域内部.

与外点法相似,用目标函数叠加一个惩罚项来构成罚函数,在内点法中称为障碍函数.要求障碍函数具备这样的功能:在可行域内部离边界面较远之处,障碍函数与原目标函数 $f(\mathbf{x})$ 尽可能接近,而在接近边界面时,可以变成很大的值.因此,满足这种要求的障碍函数其极小值显然不会在可行域的边界上达到.也就是说,用障碍函数来代替原有目标函数,且在可行域内使其极小化.因极小点不在可行域的边界上,因而这种障碍函数具有无约束性质的极值,可用无约束极值法求解.

类似于外点法中构造罚函数,在内点法中,我们构造障碍函数

$$p(\mathbf{x}, r_k) = f(\mathbf{x}) + r_k \sum_{j=1}^l \frac{1}{g_j(\mathbf{x})} \quad (9-29)$$

或

$$p(\mathbf{x}, r_k) = f(\mathbf{x}) - r_k \sum_{j=1}^l \ln(g_j(\mathbf{x})) \quad (9-30)$$

其中, r_k 是很小的正数.通常称 r_k 为障碍因子,称 $r_k \sum_{j=1}^l \frac{1}{g_j(\mathbf{x})}$ 或 $-r_k \sum_{j=1}^l \ln(g_j(\mathbf{x}))$ 为障碍项.

由于 r_k 很小,因此在可行域内部距离边界较远的地方,障碍函数与目标函数 $f(\mathbf{x})$ 的值可以很接近;而当 $\mathbf{x}$ 趋于边界时,至少有一个 $g_j(\mathbf{x})$ 趋于 0,即障碍函数 $p(\mathbf{x}, r_k)$ 趋于正无穷大.显然 r_k 的值越小,障碍函数的无约束极小点越接近原问题的极小点.但是 r_k 的取值过小,将给障碍函数的极小化计算带来很大的困难.因此与外点法类似,仍可采用序列无约束极小化方法,取一个严格单调递减且趋于零的障碍因子数列 $\{r_k\}$.对每一个 r_k 值,求障碍函数(9-29)或(9-30)的无约束极小点 $\mathbf{x}^{(k)}$.当 r_k 趋于零时,点列 $\{\mathbf{x}^{(k)}\}$ 就可从可行域内部趋于原问题的极小点.若原问题的极小点在可行域 $\mathcal{H}$ 的边界上,则随着 r_k 的减小,障碍作用逐步降低,所求出的障碍函数的无约束极小点不断靠近边界,直到满足某一精度为止.

9.4.2.2 算法步骤

(1) 给定严格内点 $x^{(0)}$ 为初始点, 初始障碍因子 $r_1 > 0$ (如取 $r_1 = 1$), 缩小系数 $\beta \in (0, 1)$ (如取 $\beta = 0.1$ 或 0.2), 允许误差 $\varepsilon > 0$, 置 $k = 1$.

(2) 构造障碍函数 $p(x, r_k)$, 障碍函数可取式(9-29)的形式, 也可取式(9-30)的形式.

(3) 求障碍函数 $p(x, r_k)$ 的无约束极小化问题.

以 $x^{(k-1)}$ 为初始点, 求解

$$\min_{x \in \mathcal{R}_1} p(x, r_k)$$

得其极小点 $x^{(k)}$. 式中, $\mathcal{R}_1$ 是可行域中所有严格内点的集合.

(4) 判断精度.

若满足收敛准则, 则停止迭代, 以 $x^{(k)}$ 作为原问题的近似极小点; 否则取 $r_{k+1} = \beta r_k$, 置 $k := k + 1$, 转第(3)步.

收敛准则可采用以下几种形式之一:

$$\begin{aligned} r_k \sum_{j=1}^l \frac{1}{g_j(x^{(k)})} &\leq \varepsilon; \quad \left| r_k \sum_{j=1}^l \ln(g_j(x^{(k)})) \right| < \varepsilon \\ |x^{(k)} - x^{(k-1)}| &< \varepsilon; \quad |f(x^{(k)}) - f(x^{(k-1)})| < \varepsilon \end{aligned}$$

9.4.2.3 初始内点的求法

如果不能找出严格内点作为初始内点, 内点法就不能应用, 而求初始内点, 也需要采用序列无约束最小化方法. 下面介绍求初始内点的步骤.

(1) 任意给定初始点 $x^{(1)} \in \mathbb{R}^n$, 初始障碍因子 $r_1 > 0$ (例如取 $r_1 = 1$), 缩小系数 $\beta \in (0, 1)$ (例如取 $\beta = 0.1$ 或 0.2), 令 $k = 1$.

(2) 对 $x^{(k)}$ 点, 确定不等式约束的下标集合 T_k 及 S_k .

$$T_k = \{j | g_j(x^{(k)}) > 0, 1 \leq j \leq l\}$$

$$S_k = \{j | g_j(x^{(k)}) \leq 0, 1 \leq j \leq l\}$$

$$R_k = \{x | g_j(x) > 0, j \in T_k\}$$

$$R_1 = \{j | g_j(x) > 0, j = 1, 2, \dots, l\}$$

(3) 若 $S_k = \emptyset$ (空集), 则 $x^{(k)} \in R_1$, $x^{(k)}$ 即为初始内点, 停止搜索. 否则转步骤(4).

(4) 构造障碍函数

$$Q(x, r_k) = - \sum_{j \in S_k} g_j(x) + r_k \sum_{j \in T_k} \frac{1}{g_j(x)} \quad (r_k > 0)$$

对照前面介绍的内点法可知, 这里障碍函数的第一项是虚拟目标函数, 它是由 $g_j(x) \leq 0$ 的那些约束函数的和的相反数构成, 其最小值为 0. 第二项由虚拟约束条件即满足 $g_j(x) > 0$ 的那些约束条件构成, 也就是说, 在 R_k 域的边界上设置了一道“障碍”, 它阻止已得到满足的约束条件再变为不满足.

(5) 以 $x^{(k)}$ 为初始点, 在 R_k 域内, 求障碍函数 $Q(x, r_k)$ 的无约束极小, 得其极小点 $x^{(k+1)} \in \mathbb{R}_k$.

(6) 减小 r_k 的大小, 令 $r_{k+1} = \beta r_k$, 置 $k := k + 1$. 返回步骤(2).

由以上可知, 求初始内点的过程, 就是在 R_k 域内反复使用内点法的过程. 随着得到满足的约束条件的个数的增加, R_k 域逐渐缩小以趋近于 R_1 域.

内点法的优点是,由于迭代点总是在可行域内进行,每一个中间结果都是可行解,可以作为近似解.缺点是选取初始可行点较困难,且只适用于含有不等式约束的非线性规划问题.

9.4.2.4 计算举例

例9-6 试用内点法求解非线性规划

$$\begin{aligned} \min f(x) &= x_1 + x_2 \\ \text{s. t. } g_1(x) &= -x_1^2 + x_2 \geq 0 \\ g_2(x) &= x_1 \geq 0 \end{aligned}$$

解 障碍函数采用对数函数来构造

$$p(x, r_k) = x_1 + x_2 - r_k \ln(-x_1^2 + x_2) - r_k \ln x_1$$

本例可用解析法求解

$$\begin{cases} \frac{\partial p(x, r_k)}{\partial x_1} = 1 - \frac{-2x_1 r_k}{-x_1^2 + x_2} - \frac{r_k}{x_1} \\ \frac{\partial p(x, r_k)}{\partial x_2} = 1 - \frac{r_k}{-x_1^2 + x_2} \end{cases}$$

令 $\frac{\partial p}{\partial x_1} = \frac{\partial p}{\partial x_2} = 0$, 解方程组得

$$x_1 = \frac{1}{4}(-1 + \sqrt{1 + 8r_k}), \quad x_2 = \frac{3r_k}{2} - \frac{-1 + \sqrt{1 + 8r_k}}{8}$$

因此

$$x(r_k) = \left(\frac{-1 + \sqrt{1 + 8r_k}}{4}, \frac{3r_k}{2} - \frac{-1 + \sqrt{1 + 8r_k}}{8} \right)^T$$

当 $r_k \rightarrow 0$ 时, $x(r_k)$ 趋向于原问题的最优解为

$$x^* = (0, 0)^T$$

各次迭代结果见表9-2.

表9-2

r_k	1.000	0.500	0.250	0.100	0.0001	$r_k \rightarrow 0$
x_1	0.500	0.309	0.183	0.085	0.000	0
x_2	1.250	0.595	0.283	0.107	0.000	0

9.4.3 混合法

所谓混合法,就是外点法和内点法结合起来使用.即对等式约束和当前不被满足的不等式约束使用外点法(构造罚函数);对已满足的那些不等式约束使用内点法(构造障碍函数).和外点法、内点法相类似,混合法也是一种序列无约束最小化方法.下面简要介绍混合法的几个问题.

1. 适用问题

$$\begin{aligned} \min f(x) \\ \text{s. t. } h_i(x) &= 0 \quad (i = 1, 2, \dots, m) \\ g_j(x) &\geq 0 \quad (j = 1, 2, \dots, l) \end{aligned}$$

2. 罚函数形式

$$p(x, r_k) = f(x) + \frac{1}{r_k} \left\{ \sum_{i=1}^m h_i^2(x) + \sum_{j \in S_k} [\min(0, g_j(x))]^2 \right\} - r_k \sum_{j \in T_k} \ln(g_j(x)) \quad (r_k > 0)$$

其中 $T_k = \{j | g_j(x^{(k)}) > 0, 1 \leq j \leq l\}$, $S_k = \{j | g_j(x^{(k)}) \leq 0, 1 \leq j \leq l\}$.

3. 初始点 $x^{(0)}$ 及初始障碍因子 r_0 的选择

初始点 $x^{(0)}$ 可任意给定. 但是无论什么时候, 只要可能就应当使用一个可行的初始点, 即使给不出可行的初始点, 也要使它满足尽可能多的约束条件, 否则, 可能将大量时间耗费在确定一个可行的初始点上.

对于初始障碍因子 r_0 , 一般取为 1, 而选 $r_{k+1} = \frac{r_k}{C}$, 其中 C 是大于 1 的常数, 通常取 $C=4$ 或 5.

4. 计算举例

例 9-7 用混合法求解非线性规划:

$$\begin{aligned} \min f(x) &= \ln x_1 - x_2 \\ \text{s. t. } h(x) &= x_1^2 + x_2^2 - 4 = 0 \\ g(x) &= x_1 - 1 \geq 0 \end{aligned}$$

解 对上述等式约束按外点法构造罚函数, 对不等式约束按内点法构造罚函数, 这样可得混合法的罚函数, 即有

$$p(x, r_k) = (\ln x_1 - x_2) + \frac{1}{r_k} (x_1^2 + x_2^2 - 4) - r_k \ln(x_1 - 1)$$

给定初始点 $x^{(0)}$ ($x^{(0)}$ 应满足 $x_1 > 1$), 选择初始障碍因子 $r_0 = 1$, 用无约束条件下多变量函数的寻优方法, 求罚函数 $p(x, r_k)$ 的无约束极小, 得近似极小点 $x^{(1)}$. 然后减小障碍因子 r_k 的值, 仍然用无约束条件下多变量函数的寻优方法, 求罚函数 $p(x, r_k)$ 的无约束极小, 如此继续, 采用序列无约束最小化方法, 可得一近似极小点点列, 其极限即原问题的最优解. 将 r_k 取不同值时得到的近似极小点列于表 9-3.

表 9-3

r_k	1.000	1/4	1/16	1/64	1/256	$r_k \rightarrow 0$
x_1	1.553	1.159	1.040	1.010	1.002	1
x_2	1.334	1.641	1.711	1.727	1.731	$\sqrt{3}$

从表 9-3 可知, 近似极小点点列是从可行域外部 (但满足 $x_1 > 1$) 趋向原问题的最小点的. 本例题的最优结果是

$$\begin{aligned} x^* &= (1, \sqrt{3})^T \\ f(x^*) &= -\sqrt{3} \end{aligned}$$

以上介绍了外点法、内点法、混合法等几种常见的罚函数法. 它们均采用序列无约束最小化方法, 不必计算导数, 方法简单, 使用方便, 因此在实际中得到了广泛的应用. 但是罚函数法存在固有的缺点, 即随着罚因子或障碍因子趋向其极限, 罚函数的海赛矩阵的条件数无限增大, 因而变得越来越病态. 罚函数的这种性态给无约束极小化带来了很大的困难. 为克服这一缺点, Powell 和 Hestenes 于 1969 年各自独立地提出了乘子法.

9.5 乘子法

乘子法与罚函数法最大的不同, 是在乘子法中引进了乘子罚函数. 乘子罚函数是在罚函数的基础上增加了拉格朗日乘子项, 从而成为增广拉格朗日函数. 因此, 乘子罚函数的性态既不同于拉格朗日函数, 也不同于罚函数. 在乘子法中, 罚因子不必趋于无穷大, 只要足够大, 就可以通过极小化乘子罚函数, 得到原来约束问题的局部最优解, 故避免了罚函数法中的病态问题. 实践证明, 乘子法优于罚函数法, 乘子法已受到广大使用者的欢迎.

9.5.1 只有等式约束的问题

1. 基本原理

考虑只有等式约束的问题

$$\begin{aligned} \min f(x) \\ \text{s. t. } h_i(x) = 0 \quad (i = 1, 2, \dots, m) \end{aligned} \quad (9-31)$$

为介绍乘子法, 先定义增广拉格朗日函数(乘子罚函数)

$$\varphi(x, \lambda, M) = f(x) - \sum_{i=1}^m \lambda_i h_i(x) + \frac{M}{2} \sum_{i=1}^m [h_i(x)]^2 \quad (9-32)$$

其中, λ 为等式约束的拉格朗日乘子向量, $\lambda = (\lambda_1, \lambda_2, \dots, \lambda_m)^T$.

$\varphi(x, \lambda, M)$ 与普通拉格朗日函数的区别是增加了罚项 $\frac{M}{2} \sum_{i=1}^m [h_i(x)]^2$, 而与罚函数的区别是增加了乘子项 $[- \sum_{i=1}^m \lambda_i h_i(x)]$.

如果知道最优拉格朗日乘子向量 $\lambda^* = (\lambda_1^*, \lambda_2^*, \dots, \lambda_m^*)^T$, 再给定一个足够大的罚因子 M (不必趋于无穷大), 就可通过极小化 $\varphi(x, \lambda^*, M)$ 得到问题(9-31)的局部最优解. 但是问题是实际上事先并不知道 λ^* , 故采取先给定一个足够大的 M 和一个初始估计 $\lambda^{(1)}$, 然后在迭代过程中不断修正它, 使它逐渐趋于 λ^* . 假设在第 k 次迭代中, 拉格朗日乘子向量的估计为 $\lambda^{(k)}$, 罚因子取为 M , 得到 $\varphi(x, \lambda^{(k)}, M)$ 的极小点 $x^{(k)}$, 则修正的拉格朗日乘子向量的公式为

$$\lambda_i^{(k+1)} = \lambda_i^{(k)} - M h_i(x^{(k)}) \quad (i = 1, 2, \dots, m) \quad (9-33)$$

然后进行第 $k+1$ 次迭代, 求 $\varphi(x, \lambda^{(k+1)}, M)$ 的无约束极小点. 这样继续下去, 可望向量 $\lambda^{(k)}$ 趋于 λ^* , 从而 $x^{(k)}$ 趋于 x^* . 如果 $\{\lambda^{(k)}\}$ 不收敛或者收敛很慢, 可增大罚因子 M , 再进行迭代. 收敛快慢一般用

$$\frac{\|h(x^{(k)})\|}{\|h(x^{(k-1)})\|}$$

来衡量,其中 $h(x^{(k)}) = (h_1(x^{(k)}), h_2(x^{(k)}), \dots, h_m(x^{(k)}))^T$.

2. 算法步骤

(1) 给定初始点 $x^{(0)}$, 拉格朗日乘子向量的初始估计 $\lambda^{(1)}$, 初始罚因子 M , 常数 $\alpha > 1$, $\beta \in (0, 1)$, 允许误差 $\varepsilon > 0$, 令 $k = 1$.

(2) 以 $x^{(k-1)}$ 为初始点, 求解无约束问题

$$\min \varphi(x, \lambda^{(k)}, M)$$

得到点 $x^{(k)}$.

(3) 若 $\|h(x^{(k)})\| < \varepsilon$, 则停止计算, 得到近似极小点 $x^{(k)}$, 否则转步骤(4).

(4) 若

$$\frac{\|h(x^{(k)})\|}{\|h(x^{(k-1)})\|} \geq \beta$$

则令 $M = \alpha M$, 转步骤(5). 否则, 直接转步骤(5).

(5) 用公式(9-33)计算 $\lambda_i^{(k+1)}$ ($i = 1, 2, \dots, m$), 令 $k := k + 1$, 返回步骤(2).

3. 计算举例

例 9-8 用乘子法求解下列问题:

$$\begin{aligned} \min f(x) &= 2x_1^2 - x_1x_2 + x_2^2 \\ \text{s. t. } h_1(x) &= x_1 + x_2 - 2 = 0 \end{aligned}$$

解 构造乘子罚函数

$$\varphi(x, \lambda, M) = 2x_1^2 - x_1x_2 + x_2^2 - \lambda_1^{(1)}(x_1 + x_2 - 2) + \frac{M}{2}(x_1 + x_2 - 2)^2$$

给定罚因子 $M = 2$, 拉格朗日乘子向量的初始估计 $\lambda^{(1)} = \lambda_1^{(1)} = 1$, 下面采用解析法求 $\varphi(x, \lambda^{(1)}, M)$ 的无约束极小点.

$$\varphi(x, \lambda^{(1)}, M) = 2x_1^2 - x_1x_2 + x_2^2 - (x_1 + x_2 - 2) + (x_1 + x_2 - 2)^2$$

令

$$\frac{\partial \varphi}{\partial x_1} = 6x_1 + x_2 - 5 = 0$$

$$\frac{\partial \varphi}{\partial x_2} = x_1 + 4x_2 - 5 = 0$$

得

$$x^{(1)} = (x_1^{(1)}, x_2^{(1)})^T = \left(\frac{15}{23}, \frac{25}{23}\right)^T$$

一般而言, 假设第 k 次迭代时, 取罚因子 $M = 2$, 拉格朗日乘子向量为 $\lambda^{(k)} = \lambda_1^{(k)}$, 则乘子罚函数为

$$\varphi(x, \lambda^{(k)}, M) = 2x_1^2 - x_1x_2 + x_2^2 - \lambda_1^{(k)}(x_1 + x_2 - 2) + (x_1 + x_2 - 2)^2$$

仍然采用上述解析方法求得 $\varphi(x, \lambda^{(k)}, M)$ 的无约束极小点(把 $\lambda_1^{(k)}$ 当作常数), 即有

$$x^{(k)} = (x_1^{(k)}, x_2^{(k)})^T = \left(\frac{3\lambda_1^{(k)} + 12}{23}, \frac{5\lambda_1^{(k)} + 20}{23}\right)^T \quad (9-34)$$

然后, 再根据式(9-33)及式(9-34)修正 $\lambda_1^{(k)}$ 而得到 $\lambda_1^{(k+1)}$

$$\begin{aligned} \lambda_1^{(k+1)} &= \lambda_1^{(k)} - Mh_1(x^{(1)}) \\ &= \lambda_1^{(k)} - 2(x_1^{(k)} + x_2^{(k)} - 2) \\ &= \frac{7}{23}x_1^{(k)} + \frac{28}{23} \end{aligned} \quad (9-35)$$

式(9-35)中的 $\lambda_1^{(k+1)}$ 即 λ^{k+1} .

将 $\lambda_1^{(1)}$ 代入式(9-35),可求出 $\lambda_1^{(2)}$.如此反复计算,可得

$$\lambda^{(2)} \approx 1.522$$

$$\lambda^{(3)} \approx 1.681$$

$$\lambda^{(4)} \approx 1.729$$

$$\lambda^{(5)} \approx 1.744$$

$$\lambda^{(6)} \approx 1.748$$

$$\lambda^{(7)} \approx 1.749$$

$$\lambda^{(8)} \approx 1.7497$$

$$\lambda^{(9)} = 1.75$$

$$\lambda^{(10)} = 1.75$$

故序列 $\{\lambda^{(k)}\}$ 收敛,得到最优拉格朗日乘子

$$\lambda^* = \lambda_1^* = 1.75$$

将 λ^* 代入式(9-34),可得原问题的最优结果:

$$\mathbf{x}^* = \left(\frac{3}{4}, \frac{5}{4}\right)^T$$

$$f(\mathbf{x}^*) = \frac{7}{4}$$

从本例可以看出,罚因子 M 确实不必趋于无穷大,就能得到原约束问题的局部最优解.

9.5.2 只有不等式约束的问题

1. 基本原理及算法步骤

考虑只有不等式约束的问题

$$\begin{aligned} \min f(\mathbf{x}) \\ \text{s. t. } g_j(\mathbf{x}) \geq 0 \quad (j = 1, 2, \dots, l) \end{aligned} \quad (9-36)$$

为应用关于等式约束问题乘子法的结论,引入变量 y_j ,把问题(9-36)化为只有等式约束的问题:

$$\begin{aligned} \min f(\mathbf{x}) \\ \text{s. t. } g_j(\mathbf{x}) - y_j^2 = 0 \quad (j = 1, 2, \dots, l) \end{aligned}$$

于是乘子罚函数可定义为

$$\varphi_1(\mathbf{x}, \mathbf{y}, \boldsymbol{\gamma}, M) = f(\mathbf{x}) - \sum_{j=1}^l \gamma_j (g_j(\mathbf{x}) - y_j^2) + \frac{M}{2} \sum_{j=1}^l (g_j(\mathbf{x}) - y_j^2)^2 \quad (9-37)$$

其中, $\boldsymbol{\gamma}$ 为不等式约束的拉格朗日乘子向量, $\boldsymbol{\gamma} = (\gamma_1, \gamma_2, \dots, \gamma_l)^T$.

这样问题(9-36)就转化为求解

$$\min \varphi_1(\mathbf{x}, \mathbf{y}, \boldsymbol{\gamma}, M) \quad (9-38)$$

先用配方法将 $\varphi_1(\mathbf{x}, \mathbf{y}, \boldsymbol{\gamma}, M)$ 化为

$$\begin{aligned} \varphi_1(\mathbf{x}, \mathbf{y}, \boldsymbol{\gamma}, M) &= f(\mathbf{x}) + \sum_{j=1}^l \left[-\gamma_j (g_j(\mathbf{x}) - y_j^2) + \frac{M}{2} (g_j(\mathbf{x}) - y_j^2)^2 \right] \\ &= f(\mathbf{x}) + \sum_{j=1}^l \left\{ \frac{M}{2} \left[y_j^2 - \frac{1}{M} (Mg_j(\mathbf{x}) - \gamma_j) \right]^2 - \frac{\gamma_j^2}{2M} \right\} \end{aligned} \quad (9-39)$$

令

$$\frac{\partial \varphi_1}{\partial y_j} = 2My_j \left[y_j^2 - \frac{1}{M}(Mg_j(\mathbf{x}) - \gamma_j) \right] = 0 \quad (j = 1, 2, \dots, l)$$

则 $\varphi_1(\mathbf{x}, \mathbf{y}, \boldsymbol{\gamma}, M)$ 对于 y_j 取极小时, y_j 的取值如下:

当 $Mg_j(\mathbf{x}) - \gamma_j \geq 0$ 时,

$$y_j^2 = \frac{1}{M}(Mg_j(\mathbf{x}) - \gamma_j)$$

当 $Mg_j(\mathbf{x}) - \gamma_j < 0$ 时,

$$y_j = 0$$

将上述两种情况统一为一个表达式, 即有

$$y_j^2 = \frac{1}{M} \max\{0, (Mg_j(\mathbf{x}) - \gamma_j)\} \quad (9-40)$$

将式(9-40)代入式(9-39), 即得不等式约束问题的乘子罚函数:

$$\varphi(\mathbf{x}, \boldsymbol{\gamma}, M) = f(\mathbf{x}) + \frac{1}{2M} \sum_{j=1}^l \left\{ [\max(0, \gamma_j - Mg_j(\mathbf{x}))]^2 - \gamma_j^2 \right\} \quad (9-41)$$

因此, 原问题(9-36)即转化为求解乘子罚函数 $\varphi(\mathbf{x}, \boldsymbol{\gamma}, M)$ 的无约束极小问题. 在迭代过程中, 与只有等式约束的问题类似, 也是给定足够大的罚因子 M , 并给定不等式约束的拉格朗日乘子向量的初始估计 $\boldsymbol{\gamma}^{(1)}$, 然后通过修正第 k 次迭代中的 $\boldsymbol{\gamma}^{(k)}$, 得到第 $k+1$ 次迭代的 $\boldsymbol{\gamma}^{(k+1)}$. 修正公式如下:

$$\gamma_j^{(k+1)} = \max(0, \gamma_j^{(k)} - Mg_j(\mathbf{x}^{(k)})) \quad (j = 1, 2, \dots, l) \quad (9-42)$$

只有不等式约束问题的算法步骤与只有等式约束问题的相同, 这里不再重复.

2. 计算举例

例 9-9 用乘子法求解下列问题:

$$\begin{aligned} \min f(\mathbf{x}) &= 2x_1^2 - x_1x_2 + x_2^2 \\ \text{s. t. } g_1(\mathbf{x}) &= x_1 + x_2 - 2 \geq 0 \end{aligned}$$

解 根据式(9-41)构造乘子罚函数, 即有

$$\begin{aligned} \varphi(\mathbf{x}, \boldsymbol{\gamma}, M) &= f(\mathbf{x}) + \frac{1}{2M} \sum_{j=1}^l \left\{ [\max(0, \gamma_j - Mg_j(\mathbf{x}))]^2 - \gamma_j^2 \right\} \\ &= 2x_1^2 - x_1x_2 + x_2^2 + \frac{1}{2M} \left\{ [\max(0, \gamma_1 - M(x_1 + x_2 - 2))]^2 - \gamma_1^2 \right\} \end{aligned}$$

当 $x_1 + x_2 - 2 \leq \frac{\gamma_1}{M}$ 时:

$$\varphi(\mathbf{x}, \boldsymbol{\gamma}, M) = 2x_1^2 - x_1x_2 + x_2^2 + \frac{1}{2M} \left\{ [\gamma_1 - M(x_1 + x_2 - 2)]^2 - \gamma_1^2 \right\}$$

$$\frac{\partial \varphi}{\partial x_1} = 4x_1 - x_2 - \gamma_1 + M(x_1 + x_2 - 2)$$

$$\frac{\partial \varphi}{\partial x_2} = -x_1 + 2x_2 - \gamma_1 + M(x_1 + x_2 - 2)$$

令

$$\frac{\partial \varphi}{\partial x_1} = \frac{\partial \varphi}{\partial x_2} = 0$$

$$\text{即} \quad 4x_1 - x_2 - \gamma_1 + M(x_1 + x_2 - 2) = 0 \quad (9-43)$$

$$-x_1 + 2x_2 - \gamma_1 + M(x_1 + x_2 - 2) = 0 \quad (9-44)$$

将方程(9-43)和方程(9-44)联立求解,可得 $\varphi(x, \gamma, M)$ 的无约束极小点为

$$x_1 = \frac{6M + 3\gamma_1}{8M + 7} \quad (9-45)$$

$$x_2 = \frac{10M + 5\gamma_1}{8M + 7} \quad (9-46)$$

当 $x_1 + x_2 - 2 > \frac{\gamma_1}{M}$ 时:

$$\varphi(x, \gamma, M) = 2x_1^2 - x_1x_2 + x_2^2 + \frac{\gamma_1^2}{2M}$$

$$\frac{\partial \varphi}{\partial x_1} = 4x_1 - x_2$$

$$\frac{\partial \varphi}{\partial x_2} = -x_1 + 2x_2$$

令

$$\frac{\partial \varphi}{\partial x_1} = \frac{\partial \varphi}{\partial x_2} = 0$$

即

$$4x_1 - x_2 = 0 \quad (9-47)$$

$$-x_1 + 2x_2 = 0 \quad (9-48)$$

将方程(9-43)和方程(9-44)联立求解,得

$$x_1 = x_2 = 0 \quad (9-49)$$

因结果(9-49)不满足原约束式 $g_1(x) \geq 0$,故舍去。

假设给定罚因子 $M=2$,不等式约束的拉格朗日乘子向量的初始估计 $\gamma^{(1)} = \gamma_1^{(1)} = 1$,根据式(9-45)和式(9-46),可得到 $\varphi(x, \gamma^{(1)}, M)$ 的无约束极小点为

$$x^{(1)} = (x_1^{(1)}, x_2^{(1)})^T = \left(\frac{15}{23}, \frac{25}{23}\right)^T$$

再根据式(9-42)修正 $\gamma_1^{(k)}$ 而得到 $\gamma_1^{(k+1)}$:

$$\gamma_j^{(k+1)} = \max[0, \gamma_j^{(k)} - 2(x_1^{(k)} + x_2^{(k)} - 2)] \quad (9-50)$$

式(9-50)中的 $\gamma_1^{(k+1)}$ 即 $\gamma^{(k+1)}$ 。

将已知的 $\gamma_1^{(1)}, x^{(1)}$ 代入式(9-50),可求出 $\gamma_1^{(2)}$

$$\gamma_1^{(2)} = \max[0, \gamma_1^{(1)} - 2(x_1^{(1)} + x_2^{(1)} - 2)]$$

即

$$\gamma_1^{(2)} \approx 1.522 \quad (9-51)$$

将式(9-51)代入式(9-45)和式(9-46),可得到 $\varphi(x, \gamma^{(2)}, M)$ 的无约束极小点为

$$x^{(2)} = (x_1^{(1)}, x_2^{(1)})^T = (0.720, 1.200)^T \quad (9-52)$$

类似地,将式(9-51)和式(9-52)代入式(9-50),可求出 $\gamma_1^{(3)}$:

$$\gamma_1^{(3)} \approx 1.682 \quad (9-53)$$

将式(9-53)代入式(9-45)和式(9-46),可得到 $\varphi(x, \gamma^{(3)}, M)$ 的无约束极小点:

$$x^{(3)} = (x_1^{(1)}, x_2^{(1)})^T = (0.741, 1.235)^T$$

如此迭代下去,当 $k \rightarrow \infty$ 时,序列 $\{\gamma^{(k)}\}$ 收敛,得到原约束问题的最优结果:

$$\gamma^* = \gamma_1^* = 1.75$$

$$\mathbf{x}^* = \left(\frac{3}{4}, \frac{5}{4}\right)^T$$

$$f(\mathbf{x}^*) = \frac{7}{4}$$

9.5.3 同时含有等式约束与不等式约束的问题

对于既有等式约束又有不等式约束的问题

$$\begin{aligned} \min f(\mathbf{x}) \\ \text{s. t. } h_i(\mathbf{x}) = 0 \quad (i = 1, 2, \dots, m) \\ g_j(\mathbf{x}) \geq 0 \quad (j = 1, 2, \dots, l) \end{aligned}$$

其乘子罚函数为

$$\begin{aligned} \varphi(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\gamma}, M) = f(\mathbf{x}) - \sum_{i=1}^m \lambda_i h_i(\mathbf{x}) + \frac{M}{2} \sum_{i=1}^m [h_i(\mathbf{x})]^2 \\ + \frac{1}{2M} \sum_{j=1}^l \{ [\max(0, \gamma_j - M g_j(\mathbf{x}))]^2 - \gamma_j^2 \} \end{aligned} \quad (9-54)$$

式(9-54)其实就是式(9-32)和式(9-41)的综合。

在迭代过程中,与只有等式约束的问题类似,也是给定足够大的罚因子 M ,另外,还要给定等式约束的拉格朗日乘子向量的初始估计 $\boldsymbol{\lambda}^{(1)}$ 和不等式约束的拉格朗日乘子向量的初始估计 $\boldsymbol{\gamma}^{(1)}$,然后通过修正第 k 次迭代中的 $\boldsymbol{\lambda}^{(k)}$ 和 $\boldsymbol{\gamma}^{(k)}$,得到第 $k+1$ 次迭代中的 $\boldsymbol{\lambda}^{(k+1)}$ 和 $\boldsymbol{\gamma}^{(k+1)}$.修正公式详见式(9-33)和式(9-42).

既有等式约束又有不等式约束的问题的算法步骤与只有等式约束的问题相同,此处就不重复了。

有关乘子法的相关定理及其证明等,读者可参看参考文献[10,12].

9.6 二次规划

二次规划是特殊的非线性规划,它形式简单,既可以使用求解非线性规划的一般方法求解,又有特定的解法;此外,二次规划在实际中有着广泛的应用,例如著名的支持向量机,在本质上就是一个二次规划问题.本节着重介绍凸二次规划问题的一些性质和求解方法。

9.6.1 二次规划的基本概念与基本性质

二次规划是最简单的约束非线性规划问题(9-1)在 $f(\mathbf{x})$ 是二次函数、

$$h_i(\mathbf{x}) \quad (i = 1, 2, \dots, m) \quad \text{和} \quad g_j(\mathbf{x}) \quad (j = 1, 2, \dots, l)$$

都是线性函数的特殊情形,即可写成

$$\begin{aligned} \min f(\mathbf{x}) &= \frac{1}{2} \mathbf{x}^T \mathbf{G} \mathbf{x} + \mathbf{r}^T \mathbf{x} \quad (\mathbf{x} \in \mathbb{R}^n) \\ \text{s. t. } \mathbf{A}_i^T \mathbf{x} - b_i &= 0 \quad (i = 1, 2, \dots, m) \\ \mathbf{A}_i^T \mathbf{x} - b_i &\geq 0 \quad (i = m+1, m+2, \dots, m+l) \end{aligned} \quad (9-55)$$

其中 G 为 $n \times n$ 阶对称矩阵, r, A_i ($i=1, 2, \dots, m+l$) 为 n 维列向量, b_i ($i=1, 2, \dots, m+l$) 为纯量(实数). 若矩阵 G 为(正定)半正定矩阵, 则称问题(9-55)为(严格)凸二次规划, 它是一种特殊形式的凸规划. 对于二次规划, 可行域只要不空必定是凸集, 所以当目标函数是凸函数时, 二次规划的任何 K-T 点必为二次规划的全局极小点.

关于凸二次规划, 有如下性质.

定理 9-2 设矩阵 G 半正定, 则 x^* 是二次规划问题(9-55)的全局极小点的充分必要条件是: x^* 是一个 K-T 点, 即存在 $\lambda^* = (\lambda_1^*, \lambda_2^*, \dots, \lambda_{m+l}^*)^T$, 使得

$$\begin{aligned} Gx^* + r - \sum_{i=1}^{m+l} \lambda_i^* A_i &= 0 \\ A_i^T x^* - b_i &= 0, \quad 1 \leq i \leq m \\ A_i^T x^* - b_i &\geq 0, \quad m+1 \leq i \leq m+l \\ \lambda_i^* &\geq 0, \quad m+1 \leq i \leq m+l \\ \lambda_i^* (A_i^T x^* - b_i) &= 0, \quad m+1 \leq i \leq m+l \end{aligned} \quad (9-56)$$

证 必要性由约束问题的一阶必要条件得证. 下面证明充分性.

设 x^* 是一个 K-T 点, 考虑 $\forall x \neq x^*, x \in \mathcal{H}$, 这里 $\mathcal{H}$ 是问题(9-55)的可行域,

$$\mathcal{H} = \{x \mid A_i^T x - b_i = 0, 1 \leq i \leq m, A_i^T x - b_i \geq 0, m+1 \leq i \leq m+l\}$$

由于矩阵 G 半正定, 因此有

$$\begin{aligned} f(x) - f(x^*) &= \nabla f(x^*)^T (x - x^*) + \frac{1}{2} x^T G x \\ &\geq \nabla f(x^*)^T (x - x^*) \\ &= \sum_{i=1}^l \lambda_i^* A_i^T (x - x^*) + \sum_{i=m+1}^{m+l} \lambda_i^* A_i^T (x - x^*) \end{aligned}$$

很明显, $\sum_{i=1}^l \lambda_i^* A_i^T (x - x^*) = 0$, 而 $\sum_{i=m+1}^{m+l} \lambda_i^* A_i^T (x - x^*)$ 可以写成两部分之和, 分别是根据 x^* 处起作用约束和不起作用不等式约束下标分别求和, 由(9-56)和 $x \in \mathcal{H}$ 可以推出

$$\sum_{i=m+1}^{m+l} \lambda_i^* A_i^T (x - x^*) \geq 0$$

因此

$$f(x) - f(x^*) \geq 0$$

从而, x^* 是全局极小点, 易见, 若 G 正定, x^* 是严格全局极小点. $\square$

定理 9-3 若 x^* 是凸二次规划问题(9-55)的全局极小点, 设 $I(x^*)$ 为凸二次规划问题(9-55)在 x^* 处起作用的不等式约束下标集, 则 x^* 是如下等式约束二次规划问题

$$\begin{aligned} \min f(x) &= \frac{1}{2} x^T G x + r^T x \quad (x \in \mathbb{R}^n) \\ \text{s. t. } h_i(x) &= A_i^T x - b_i = 0, \quad i \in \{1, 2, \dots, m\} \cup I(x^*) \end{aligned} \quad (9-57)$$

的全局极小点.

证 若 x^* 是凸二次规划问题(9-55)的全局极小点, 则 x^* 是问题(9-55)的 K-T 点, 也是问题(9-57)的 K-T 点, 由定理 9-3 可知, x^* 是问题(9-57)的全局极小点. $\square$

9.6.2 等式约束二次规划问题

本小节讨论等式约束二次规划问题

$$\begin{aligned} \min f(x) &= \frac{1}{2}x^T Gx + r^T x \\ \text{s. t. } A^T x &= b \end{aligned} \quad (9-58)$$

其中, G 为 $n \times n$ 阶对称矩阵, r 为 n 维列向量, A 为 $n \times m$ 阶矩阵, $m < n$ 且 $\text{rank}(A) = m$, 即矩阵 A 是列满秩的.

定理 9-4 设 G 是半正定(正定)矩阵, 则 x^* 是约束问题(9-58)的全局最优解, λ^* 是相应的乘子向量的充分必要条件是: x^* 、 λ^* 是线性方程组

$$\begin{bmatrix} G & -A \\ A^T & 0 \end{bmatrix} \begin{bmatrix} x \\ \lambda \end{bmatrix} = \begin{bmatrix} -r \\ b \end{bmatrix} \quad (9-59)$$

的解.

证 考虑问题(9-58)的拉格朗日函数

$$L(x, \lambda) = \frac{1}{2}x^T Gx + r^T x - \lambda^T (A^T x - b) \quad (9-60)$$

则问题(9-58)的 Kuhn-Tucker 条件等价于线性方程组(9-59), 由定理 9-1, 本定理成立.

定理 9-4 表明, 求解等式约束的二次规划问题, 可转化为求解线性方程组的问题, 但是问题的维数也由 n 变成了 $n+m$, 维数的增大会增加求解线性方程组的难度. 一种克服上述缺点的方法是变量消去法, 消去法包括直接消去法和广义消去法.

9.6.2.1 直接消去法

首先对矩阵 A 作分块, 设

$$A = \begin{bmatrix} A_B \\ A_N \end{bmatrix}, \text{ 且 } A_B \in \mathbb{R}^{m \times m} \text{ 非奇异} \quad (9-61)$$

则其他相应的分块有

$$x = \begin{bmatrix} x_B \\ x_N \end{bmatrix}, \quad G = \begin{bmatrix} G_{BB} & G_{BN} \\ G_{NB} & G_{NN} \end{bmatrix}, \quad r = \begin{bmatrix} r_B \\ r_N \end{bmatrix} \quad (9-62)$$

因此, 等式约束二次规划问题(9-58)可以写成

$$\begin{aligned} \min f(x) &= \frac{1}{2}(x_B^T G_{BB} x_B + x_B^T G_{BN} x_N + x_N^T G_{NB} x_B + x_N^T G_{NN} x_N) \\ &\quad + r_B^T x_B + r_N^T x_N \\ \text{s. t. } A_B^T x_B + A_N^T x_N &= b \end{aligned} \quad (9-63)$$

考虑问题(9-63)的约束条件, 由于 A_B 非奇异, 可将 x_B 表示成 x_N 的函数, 即消去 x_B , 得到

$$x_B = (A_B^T)^{-1} b - (A_B^T)^{-1} A_N^T x_N \quad (9-64)$$

将式(9-64)代入问题(9-63)的目标函数, 得到相应的无约束问题, 其目标函数为

$$\begin{aligned}
\bar{f}(x_N) = & \frac{1}{2}x_N^T(G_{NN} - A_N A_B^{-1} G_{BN} \\
& - G_{NB}(A_B^T)^{-1} A_N^T + A_N A_B^{-1} G_{BB}(A_B^T)^{-1} A_N^T)x_N \\
& + b^T A_B^{-1}(G_{BN} - G_{BB}(A_B^T)^{-1} A_N^T)x_N \\
& + (r_N^T - r_B^T(A_B^T)^{-1} A_N^T)x_N \\
& + \frac{1}{2}b^T A_B^{-1} G_{BB}(A_B^T)^{-1} b + r_B^T(A_B^T)^{-1} b
\end{aligned} \quad (9-65)$$

令

$$\begin{aligned}
\bar{G}_N &= G_{NN} - A_N A_B^{-1} G_{BN} - G_{NB}(A_B^T)^{-1} A_N^T + A_N A_B^{-1} G_{BB}(A_B^T)^{-1} A_N^T \\
\bar{r}_N &= r_N - A_N(A_B^T)^{-1} r_B + (G_{NB} - A_N A_B^{-1} G_{BB})(A_B^T)^{-1} b \\
\bar{\delta} &= \frac{1}{2}b^T A_B^{-1} G_{BB}(A_B^T)^{-1} b + r_B^T(A_B^T)^{-1} b
\end{aligned} \quad (9-66)$$

则相应的无约束问题为

$$\min \bar{f}(x_N) = \frac{1}{2}x_N^T \bar{G}_N x_N + \bar{r}_N^T x_N + \bar{\delta} \quad (9-67)$$

若 $\bar{G}_N$ 是正定对称矩阵, 则问题(9-67)有唯一解

$$x_N^* = -\bar{G}_N^{-1} \bar{r}_N \quad (9-68)$$

由式(9-64)可以得到问题(9-58)的最优解

$$x^* = \begin{bmatrix} x_B^* \\ x_N^* \end{bmatrix} = \begin{bmatrix} (A_B^T)^{-1} b + (A_B^T)^{-1} A_N^T \bar{G}_N^{-1} \bar{r}_N \\ -\bar{G}_N^{-1} \bar{r}_N \end{bmatrix} \quad (9-69)$$

由于相应的乘子向量 λ^* 满足

$$Gx^* + r - A\lambda^* = 0$$

即

$$\begin{bmatrix} G_{BB} & G_{BN} \\ G_{NB} & G_{NN} \end{bmatrix} \begin{bmatrix} x_B^* \\ x_N^* \end{bmatrix} + \begin{bmatrix} r_B \\ r_N \end{bmatrix} - \begin{bmatrix} A_B \\ A_N \end{bmatrix} \lambda^* = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

所以

$$\lambda^* = A_B^{-1}(G_{BB}x_B^* + G_{BN}x_N^* + r_B) \quad (9-70)$$

定理 9-5 若等式约束问题(9-58)中的 G 是正定对称矩阵, 则相应的无约束问题(9-67)中的 $\bar{G}_N$ 也是正定对称矩阵.

证 构造矩阵

$$F = \begin{bmatrix} -(A_B^T)^{-1} A_N^T \\ I \end{bmatrix} \quad (9-71)$$

并且 $\text{rank}(F) = n - m$, 因此

$$\bar{G}_N = F^T G F = (-A_N A_B^{-1}, I) \begin{pmatrix} G_{BB} & G_{BN} \\ G_{NB} & G_{NN} \end{pmatrix} \begin{pmatrix} -(A_B^T)^{-1} A_N^T \\ I \end{pmatrix} \quad (9-72)$$

由于 F 是列满秩的, 并且 G 正定, 因此 $\bar{G}_N$ 也是正定的, 对称性显然.

定理 9-5 表明, 对于等式约束的严格凸二次规划问题, 可以用直接消去法得到原问题

的解.

例 9-10 用直接消去法求解凸二次规划

$$\min f(\mathbf{x}) = x_1^2 + x_2^2 + x_3^2$$

$$\text{s. t. } x_1 + 2x_2 - x_3 = 4$$

$$x_1 - x_2 + x_3 = -2$$

解 将约束写成

$$x_1 + 2x_2 = 4 + x_3 \quad (9-73)$$

$$x_1 - x_2 = -2 - x_3$$

求解方程组(9-73)得到

$$x_1 = 0 - \frac{1}{3}x_3, \quad x_2 = 2 + \frac{2}{3}x_3 \quad (9-74)$$

将式(9-74)代入目标函数 $f(\mathbf{x})$ 中,得到

$$\bar{f}(x_3) = \frac{14}{9}x_3^2 + \frac{8}{3}x_3 + 4 \quad (9-75)$$

求解无约束问题(9-75),得到

$$x_3^* = -\frac{6}{7}$$

代入式(9-74)中,得到约束问题的最优解

$$\mathbf{x}^* = \left(\frac{2}{7}, \frac{10}{7}, -\frac{6}{7} \right)^T$$

注意到乘子满足方程

$$\mathbf{G}\mathbf{x}^* + \mathbf{r} - \mathbf{A}\boldsymbol{\lambda}^* = 0$$

因此有

$$\begin{pmatrix} 1 & 1 \\ 2 & -1 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} \lambda_1^* \\ \lambda_2^* \end{pmatrix} = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{pmatrix} \begin{pmatrix} \frac{2}{7} \\ \frac{10}{7} \\ -\frac{6}{7} \end{pmatrix}$$

求解前两行得到

$$\lambda_1^* = \frac{8}{7}, \quad \lambda_2^* = -\frac{4}{7}$$

9.6.2.2 广义消去法

直接消去法简单、直观,但它的不足之处是 $\mathbf{A}_B$ 可能接近一奇异阵,从而利用式(9-69)求解 $\mathbf{x}^*$ 可能导致数值不稳定.消去法的一个直接推广就是广义消去法.

设 $\mathbf{s}_1, \mathbf{s}_2, \dots, \mathbf{s}_m$ 是域空间 $\text{range}(\mathbf{A})$ 中的一组线性无关的列向量; $\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_{n-m}$ 是零空间 $\text{null}(\mathbf{A}^T)$ 中的一组线性无关的列向量.记

$$\mathbf{S} = [\mathbf{s}_1, \mathbf{s}_2, \dots, \mathbf{s}_m],$$

$$\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_{n-m}]$$

则不难看出 $\mathbf{A}^T\mathbf{S}$ 非奇异, $\mathbf{A}^T\mathbf{Z} = 0$,且 $[\mathbf{S}, \mathbf{Z}]$ 为非奇异矩阵,并且对矩阵 $\mathbf{S}$ 进行一些变换还可

以使得

$$A^T S = I, \quad A^T Z = 0 \quad (9-76)$$

由式(9-76)得到

$$x = Sb \quad (9-77)$$

是方程

$$A^T x = b \quad (9-78)$$

的一个可行解. 现在讨论方程(9-78)的通解, 设 d 是齐次方程 $A^T d = 0$ 的解, 则方程(9-78)的通解为

$$x = Sb + d \quad (9-79)$$

由于 Z 的列是零空间 $\text{Null}(A^T)$ 中的一组基, 因此 d 可以表示成

$$d = Zy = \sum_{i=1}^{n-m} y_i z_i \quad (9-80)$$

因此方程(9-78)的通解可以写成

$$x = Sb + Zy \quad (9-81)$$

这样, 由式(9-81)来消去问题的约束, 化为无约束问题, 即

$$\bar{f}(y) = \frac{1}{2} y^T (Z^T G Z) y + (r + G Sb)^T Z y + \frac{1}{2} (2r + G Sb)^T Sb \quad (9-82)$$

若 $Z^T G Z$ 是正定的, 则问题(9-82)有唯一极小点, 并可通过求解线性方程组

$$(Z^T G Z) y = -Z^T (G Sb + r) \quad (9-83)$$

得到其解 y^* . 将 y^* 代入式(9-81), 得到约束问题(9-78)的最优解

$$x^* = Sb + Zy^* = Sb - Z(Z^T G Z)^{-1} Z^T (G Sb + r) \quad (9-84)$$

下面计算相应的乘子, 由一阶必要条件有 $A\lambda^* = Gx^* + r$, 左乘 S^T 得到

$$\begin{aligned} \lambda^* &= S^T (Gx^* + r) \\ &= S^T (G - GZ(Z^T G Z)^{-1} Z^T G) Sb \\ &\quad + (S^T - S^T GZ(Z^T G Z)^{-1} Z^T) r \end{aligned} \quad (9-85)$$

因此, 一旦确定了 S 和 Z , 就可计算出 x^* 和 λ^* . 特别地, 若取

$$Z = \begin{pmatrix} -(A_B^T)^{-1} A_N^T \\ I \end{pmatrix}, \quad S = \begin{pmatrix} (A_B^T)^{-1} \\ 0 \end{pmatrix}, \quad y = x_N \quad (9-86)$$

则广义消去法就是前面讲过的直接消去法.

一种重要的取法是基于 A 的 QR 分解, 将矩阵 A 分解为

$$A = Q \begin{pmatrix} R \\ 0 \end{pmatrix} = (Q_1, Q_2) \begin{pmatrix} R \\ 0 \end{pmatrix} = Q_1 R \quad (9-87)$$

其中 Q 为 $n \times n$ 阶正交阵, R 为 $m \times m$ 阶上三角阵, Q_1 和 Q_2 分别为 $n \times m$ 和 $n \times (n-m)$ 阶矩阵. 此时取

$$S = Q_1 (R^T)^{-1}, \quad Z = Q_2 \quad (9-88)$$

满足条件(9-76), 且 $[S, Z]$ 非奇异.

下面讨论最优解的计算方法. 注意 $Sb = Q_1 (R^T)^{-1} b$, 先解方程

$$R^T v = b \quad (9-89)$$

得到 v , 因此, $Sb = Q_1 v$.

再解方程组(9-83),得到 y^* , 所以 $x^* = Sb + Zy^*$. 乘子 λ^* 可由方程

$$R\lambda^* = Q_1^T(Gx^* + r) \quad (9-90)$$

确定.

请注意,若采用求解方程组的方法求出 Sb , 则在实际计算中并不要求直接求出 S .

下面给出矩阵 S 和 Z 的一般格式. 任取 $n \times (n-m)$ 阶矩阵 V , 使得矩阵 (A, V) 是非奇异的, 令其逆分解形式为

$$(A, V)^{-1} = \begin{pmatrix} S^T \\ Z^T \end{pmatrix} \quad (9-91)$$

其中 S 和 Z 分别为 $n \times m$ 和 $n \times (n-m)$ 阶矩阵. 显然 S 和 Z 满足式(9-76), 若取

$$V = \begin{pmatrix} 0 \\ I \end{pmatrix} \quad (9-92)$$

则有

$$(A, V)^{-1} = \begin{pmatrix} A_B & 0 \\ A_N & I \end{pmatrix}^{-1} = \begin{pmatrix} A_B^{-1} & 0 \\ -A_N A_B^{-1} & I \end{pmatrix} = \begin{pmatrix} S^T \\ Z^T \end{pmatrix} \quad (9-93)$$

此时, 该方法是直接消去法. 另外, 如果取

$$V = Q_2$$

这时

$$(A, V)^{-1} = (Q_1 R, Q_2)^{-1} = \begin{pmatrix} R^{-1} Q_1^T \\ Q_2^T \end{pmatrix}$$

得到的方法就是由 QR 分解得到的.

9.6.3 有效集法

本小节介绍凸二次规划的有效集法. 有效集法又叫积极集法, 其基本思想是通过求解有限个等式约束二次规划问题来求解一般约束下的二次规划问题. 直观上, 不起作用(不积极)的不等式约束在解的附近不起任何作用, 可以去掉不考虑; 而起作用(积极)的不等式约束, 由于它在解处等于零, 故可以用等式约束来代替不等式约束.

有效集法是一个可行点方法, 即每个迭代点都要求是可行点. 它每次迭代求解一个等式约束的二次规划. 由定理9-2可知, 若 x^* 是约束问题(9-55)的全局最优解, 则 x^* 是等式约束问题(9-57)的全局最优解. 因此, 只要能确定出 x^* 处的起作用约束的下标集 $I(x^*)$, 通过求解等式约束问题(9-57)就可得到一般约束问题的最优解.

9.6.3.1 有效集法基本原理

已知 $x^{(1)}$ 是一般约束问题(9-55)的可行点, 确定相应的起作用约束下标集

$$I(x^{(1)}) = \{i \mid A_i^T x^{(1)} = b_i, m+1 \leq i \leq m+l\} \quad (9-94)$$

并假设 $A_i (i \in \{1, 2, \dots, m\} \cup I(x^{(1)}))$ 线性无关.

考虑等式约束问题

$$\begin{aligned} \min f(x) &= \frac{1}{2} x^T G x + r^T x \\ \text{s. t. } A_i^T x - b_i &= 0, \quad i \in \{1, 2, \dots, m\} \cup I(x^{(1)}) \end{aligned} \quad (9-95)$$

求解等式约束问题(9-95),其最优解为 $\bar{x}^{(1)}$, 相应的乘子为 $\lambda^{(1)}$, 下面分几种情况进行讨论:

(1) 若 $\bar{x}^{(1)} \neq x^{(1)}$, 由于 $\bar{x}^{(1)}$ 是问题(9-95)的最优解, 因此有

$$f(\bar{x}^{(1)}) < f(x^{(1)}) \quad (9-96)$$

再分两种情况讨论.

①若 $\bar{x}^{(1)}$ 是原问题(9-55)的可行点, 此时取 $x^{(2)} = \bar{x}^{(1)}$, 若 $x^{(2)}$ 在不等式约束域内部, 则 $x^{(2)}$ 处的起作用不等式约束个数不变, 即 $I(x^{(2)}) = I(x^{(1)})$. 若 $x^{(2)}$ 位于某一不等式约束的边界上(不妨设是第 p 个约束), 则在 $x^{(2)}$ 处的起作用不等式约束的个数增加一个, 即

$$I(x^{(2)}) = I(x^{(1)}) \cup \{p\}$$

重复上一轮的计算.

②若 $\bar{x}^{(1)}$ 不是原问题(9-55)的可行点, 构造方向

$$d^{(1)} = \bar{x}^{(1)} - x^{(1)} \quad (9-97)$$

由于 $x^{(1)}$ 是可行点, 这表明从 $x^{(1)}$ 出发, 沿方向 $d^{(1)}$ 前进, 在达到 $\bar{x}^{(1)}$ 之前, 一定能遇到某约束的边界, 下面作进一步分析.

由于 $\bar{x}^{(1)}$ 是问题(9-95)的最优解, 因此, $\bar{x}^{(1)}$ 满足等式约束和 $x^{(1)}$ 处的起作用不等式约束. 问题只能出在 $x^{(1)}$ 处的不起作用不等式约束上, 令

$$x = x^{(1)} + \alpha d^{(1)} \quad (9-98)$$

考虑 $i \in \{m+1, m+2, \dots, m+l\} - I(x^{(1)})$, 要求

$$A_i^T x - b_i = A_i^T x^{(1)} - b_i + \alpha A_i^T d^{(1)} \geq 0 \quad (9-99)$$

当 α 增加, 只有 $A_i^T d^{(1)} < 0$ 时, 才有可能破坏约束条件(9-99), 因此

$$\alpha \leq \frac{b_i - A_i^T x^{(1)}}{A_i^T d^{(1)}}, \quad A_i^T d^{(1)} < 0$$

即得到

$$\begin{aligned} \alpha_1 &= \min \left\{ \frac{b_i - A_i^T x^{(1)}}{A_i^T d^{(1)}} \mid A_i^T d^{(1)} < 0, i \notin I(x^{(1)}) \right\} \\ &= \frac{b_p - A_p^T x^{(1)}}{A_p^T d^{(1)}} \end{aligned} \quad (9-100)$$

此时

$$x^{(2)} = x^{(1)} + \alpha_1 d^{(1)} \quad (9-101)$$

是问题(9-55)的可行点, 并且满足

$$f(x^{(2)}) < f(x^{(1)})$$

可见, 在 $x^{(2)}$ 处起作用的不等式约束下标集 $I(x^{(2)})$ 满足

$$I(x^{(2)}) = I(x^{(1)}) \cup \{p\} \quad (9-102)$$

重复上一轮计算.

(2) 若 $\bar{x}^{(1)} = x^{(1)}$, 它表明 $\bar{x}^{(1)}$ 无进展, 仍分两种情况讨论.

①若存在 $q \in I(x^{(1)})$, 并且 $\lambda_q^{(1)} < 0$. 去掉问题(9-95)的约束 $A_q^T x - b_q = 0$, 则可得到一个更好的点. 因此, 令

$$x^{(2)} = \bar{x}^{(1)} = x^{(1)}, \quad I(x^{(2)}) = I(x^{(1)}) - \{q\} \quad (9-103)$$

重复上一轮计算.

②若 $\lambda_i^{(1)} \geq 0, \forall i \in I(\mathbf{x}^{(1)})$, 此时, $\bar{\mathbf{x}}^{(1)} = \mathbf{x}^{(1)}$ 是 K-T 点. 由定理 9-1 可知, $\mathbf{x}^{(1)}$ 是二次规划的最优解.

9.6.3.2 有效集法的计算步骤

求解凸二次规划的有效集法的计算步骤如下.

(1) 取初始可行点 $\mathbf{x}^{(1)}$, 即 $\mathbf{x}^{(1)}$ 满足

$$\mathbf{A}_i^T \mathbf{x}^{(1)} - b_i = 0, \quad i \in \{1, 2, \dots, m\}$$

$$\mathbf{A}_i^T \mathbf{x}^{(1)} - b_i \geq 0, \quad i \in \{m+1, m+2, \dots, m+l\}$$

确定 $\mathbf{x}^{(1)}$ 处的起作用不等式约束下标集为

$$I(\mathbf{x}^{(1)}) = \{i | \mathbf{A}_i^T \mathbf{x}^{(1)} - b_i = 0, m+1 \leq i \leq m+l\}$$

置 $k=1$.

(2) 求解等式约束二次规划问题

$$\min \frac{1}{2} \mathbf{d}^T \mathbf{G} \mathbf{d} + \nabla f(\mathbf{x}^{(k)})^T \mathbf{d}$$

$$\text{s. t. } \mathbf{A}_i^T \mathbf{d} = 0, \quad i \in \{1, 2, \dots, m\} \cup I(\mathbf{x}^{(k)})$$

得到 $\mathbf{d}^{(k)}$.

(3) 若 $\mathbf{d}^{(k)} = 0$, 则计算相应的乘子 $\boldsymbol{\lambda}^{(k)}$. 若 $\lambda_i^{(k)} \geq 0, \forall i \in I(\mathbf{x}^{(k)})$, 则停止计算, $\mathbf{x}^{(k)}$ 为一般二次规划问题(9-55)的最优解, $\boldsymbol{\lambda}^{(k)}$ 为相应的乘子向量; 否则求

$$\lambda_q^{(k)} = \min \{ \lambda_i^{(k)} | i \in I(\mathbf{x}^{(k)}) \}$$

并置 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)}, I(\mathbf{x}^{(k+1)}) = I(\mathbf{x}^{(k)}) - \{q\}, k := k+1$, 转第(2)步.

(4) 若 $\mathbf{d}^{(k)} \neq 0$, 计算

$$\begin{aligned} \bar{\alpha}_k &= \min \left\{ \frac{b_i - \mathbf{A}_i^T \mathbf{x}^{(k)}}{\mathbf{A}_i^T \mathbf{d}^{(k)}} \mid \mathbf{A}_i^T \mathbf{d}^{(k)} < 0, i \notin I(\mathbf{x}^{(k)}) \right\} \\ &= \frac{b_p - \mathbf{A}_p^T \mathbf{x}^{(k)}}{\mathbf{A}_p^T \mathbf{d}^{(k)}} \end{aligned}$$

取 $\alpha_k = \min(\bar{\alpha}_k, 1)$, 则置

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$$

如果 $\alpha_k = \bar{\alpha}_k$, 则置

$$I(\mathbf{x}^{(k+1)}) = I(\mathbf{x}^{(k)}) \cup \{p\}$$

否则置

$$I(\mathbf{x}^{(k+1)}) = I(\mathbf{x}^{(k)})$$

置 $k := k+1$ 转步骤(2).

9.6.3.3 计算举例

例 9-11 用有效集法求解二次规划问题

$$\min f(\mathbf{x}) = x_1^2 + x_2^2 - 2x_1 - 4x_2$$

$$\text{s. t. } g_1(\mathbf{x}) = 1 - x_1 - x_2 \geq 0$$

$$g_2(\mathbf{x}) = x_1 \geq 0$$

$$g_3(\mathbf{x}) = x_2 \geq 0$$

取初始点 $\mathbf{x}^{(1)} = (0, 0)^T$.

解 计算 $\nabla f(\mathbf{x}) = (2x_1 - 2, 2x_2 - 4)^T$, 因为 $\mathbf{x}^{(1)} = (0, 0)^T$, 所以

$$I(\mathbf{x}^{(1)}) = \{2, 3\}, \quad \nabla f(\mathbf{x}^{(1)}) = (-2, -4)^T$$

相应的等式约束问题为

$$\min d_1^2 + d_2^2 - 2d_1 - 4d_2$$

$$\text{s. t. } d_1 = 0$$

$$d_2 = 0$$

由等式约束的一阶必要条件(Kuhn-Tucker 条件), 可以得到 $d_1 = d_2 = 0, \lambda_2 = -2, \lambda_3 = -4$, 即

$$\mathbf{d}^{(1)} = (0, 0)^T, \quad \lambda_2 = -2 < 0, \quad \lambda_3 = -4 < 0$$

所以 $\mathbf{x}^{(1)} = (0, 0)^T$ 不是最优解.

再进行第二轮计算. 取 $\mathbf{x}^{(2)} = (0, 0)^T, I(\mathbf{x}^{(2)}) = I(\mathbf{x}^{(1)}) - \{3\} = \{2\}$, 相应的等式约束二次规划问题为

$$\min d_1^2 + d_2^2 - 2d_1 - 4d_2$$

$$\text{s. t. } d_1 = 0$$

由相应的一阶必要条件, 可得 $d_1 = 0, d_2 = 2, \lambda_2 = 2$ 即 $\mathbf{d}^{(2)} = (0, 2)^T \neq 0$. 计算

$$\bar{\alpha}_2 = \frac{b_1 - \mathbf{A}_1^T \mathbf{x}^{(2)}}{\mathbf{A}_1^T \mathbf{d}^{(2)}} = \frac{1 - 0}{2} = \frac{1}{2}$$

$$\alpha_2 = \min\left\{\frac{1}{2}, 1\right\} = \frac{1}{2}$$

所以

$$\mathbf{x}^{(3)} = \mathbf{x}^{(2)} + \alpha_2 \mathbf{d}^{(2)} = (0, 0)^T + \frac{1}{2}(0, 2)^T = (0, 1)^T$$

由于 $\alpha_2 = \bar{\alpha}_2 = \frac{1}{2}$, 所以在 $\mathbf{x}^{(3)}$ 处的起作用不等式约束下标集为

$$I(\mathbf{x}^{(3)}) = I(\mathbf{x}^{(2)}) + \{1\} = \{1, 2\}$$

下面进行第三轮计算. 在 $\mathbf{x}^{(3)}$ 处 $\nabla f(\mathbf{x}^{(3)}) = (-2, -2)^T$, 相应的等式约束二次规划问题为

$$\min d_1^2 + d_2^2 - 2d_1 - 2d_2$$

$$\text{s. t. } d_1 + d_2 = 0$$

$$d_1 = 0$$

再由等式约束的一阶必要条件可得到

$$d_1 = d_2 = 0, \quad \lambda_1 = 2, \quad \lambda_2 = 0$$

即 $\mathbf{d}^{(3)} = (0, 0)^T, \lambda_1 = 2 > 0, \lambda_2 = 0$, 因此, $\mathbf{x}^{(3)} = (0, 1)^T$ 是最优解, $\lambda_1 = 2, \lambda_2 = 0$ 是相应的乘子.

在实际计算中, 初始点 $\mathbf{x}^{(1)}$ 的选取并非易事, 需要用类似于线性规划求初始基本可行点的方法构造辅助问题, 得到初始可行点. 若二次规划是严格凸的, 且是非退化的, 则有效集法经有限步运算, 可求出二次规划的最优解(证明略). 当 $\mathbf{G}$ 是非正定矩阵时, 按照上述方法计

算,有可能得不到最优解.若想得到最优解,需对算法作必要的改动,在这里就不深入讨论了.

9.6.4 对偶问题

与线性规划一样,每一个严格凸二次规划都存在唯一一个二次规划问题与之对偶,这样一对问题有着非常密切的联系,本节只给出严格凸二次规划问题的对偶问题的定义形式及原问题与对偶问题的一些关系,详细的推导参见参考文献[9].

假定 G 正定,则(9-55)为严格凸二次规划,其对偶问题为

$$\begin{aligned} \max Q(\lambda, y) &= b^T \lambda - \frac{1}{2} y^T G^{-1} y \\ \text{s. t. } A\lambda - y &= r \\ \lambda_i &\geq 0, \quad i \in \{m+1, m+2, \dots, m+l\} \end{aligned} \quad (9-104)$$

其中 y 为 n 维列向量, λ 为 $m+l$ 维列向量对应于原问题的乘子向量. 易见,对偶问题(9-104)要比原二次规划问题(9-55)要简单得多.

下面以定理的形式介绍对偶问题的两个性质(证明过程参见参考文献[9]).

定理 9-4 设 G 正定,如果原问题有可行点,则 x^* 是原问题(9-55)的解,当且仅当存在 (λ^*, y^*) 是对偶问题(9-104)之解且 $x^* = G^{-1}y^*$, 以及 λ^* 是原问题在 x^* 处的拉格朗日乘子向量.

对于原问题无可行点的情形,有下列结果.

定理 9-5 设 G 正定,则原问题无可行点,当且仅当其对偶问题无界.

9.6.5 二次规划的应用——支持向量机简介

支持向量机(Support Vector Machine, SVM)的主要思想是针对两类模式的分类问题,在高维特征空间中寻找一个超平面作为两类模式的分界面,以保证最小的错误率.可见,支持向量机也是一类优化问题.

支持向量机是近 10 多年发展起来的新型通用的知识发现和统计学习方法.在模式分类和预测回归等方面具有良好的性能,目前正处在发展阶段,但已在很多领域里取得了成功的应用,因而越来越引起广大学者的关注.本小节主要介绍支持向量机的一些基本概念以及支持向量机与二次规划问题的关系.

9.6.5.1 最优分类面

考虑图 9-1 所示的二维两类线性可分的情况.图中实心点和空心点分别表示两类训练样本, H_2 为把两类没有错误地分开的分类线, H_1 、 H_3 分别为过各类样本中离分类线最近的点且平行于分类线的直线, H_1 和 H_3 之间的距离叫做两类的分类空隙或分类间隔(margin).所谓最优分类线就是要求分类线不仅能将两类无错误地分开,而且要使两类的分类空隙最大.前者保证经验风险最小(等于 0);使分类空隙最大,实际上就是使推广性(推广性即机器学习结束后的一般化或泛化)的界中的置信




图 9-1 线性可分最优分类面示意图

范围最小. 推广到高维空间, 最优分类线就成为最优分类面.

如果学习样本是线性可分的, 则分类面方程为

$$g(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b = 0 \quad (9-105)$$

对它进行归一化, 使两类所有样本都满足 $|g(\mathbf{x})| \geq 1$, 即使得离分离面最近的样本满足 $|g(\mathbf{x})| = 1$, 这样, 线性可分的样本集 $(\mathbf{x}_i, y_i) (i = 1, 2, \dots, n, \mathbf{x}_i \in \mathbb{R}^m, y_i \in \{1, -1\})$, 满足

$$y_i[(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1 \geq 0 \quad (i = 1, 2, 3, \dots, n) \quad (9-106)$$

此时分类间隔等于 $2/\|\mathbf{w}\|$, 使分类间隔最大就等价于使 $\|\mathbf{w}\|^2$ 最小, 因此满足条件(9-106)且使 $\|\mathbf{w}\|^2$ 最小的分类面叫做最优分类面. 过两类样本中离分类面最近的点且平行于最优分类面的超平面 H_1 和 H_3 上的训练样本就是式(9-106)中等号成立的那些样本, 它们称作支持向量. 因为它们支撑了最优分类面.

下面介绍如何求最优分类面. 根据上面的讨论, 最优分类面问题可以表示成如下的约束优化问题, 即在条件(9-106)的约束下, 求函数

$$\varphi(\mathbf{w}) = \frac{1}{2}\|\mathbf{w}\|^2 = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) \quad (9-107)$$

的最小值. 式(9-107)中, “ $\cdot$ ”为向量内积算子. 为此可以定义以下的拉格朗日函数:

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) - \sum_{i=1}^n \alpha_i \{y_i[(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\} \quad (9-108)$$

其中, $\alpha_i > 0$ 为拉格朗日系数, 我们的问题是对 $\mathbf{w}$ 和 b 求式(9-108)的极小值.

把式(9-108)分别对 $\mathbf{w}$ 和 b 偏微分并令它们等于 0, 就可以将原问题转化为如下这种较简单的对偶问题(也可以根据式(9-104)得到)

$$\begin{aligned} \max Q(\alpha) &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) \\ \text{s. t. } \sum_{i=1}^n y_i \alpha_i &= 0 \\ \alpha_i &\geq 0 \quad (i = 1, 2, \dots, n) \end{aligned} \quad (9-109)$$

若 α_i^* 为最优解, 则

$$\mathbf{w}^* = \sum_{i=1}^n \alpha_i^* y_i \mathbf{x}_i \quad (9-110)$$

即最优分类面的权系数向量是训练样本向量的线性组合.

这是一个不等式约束下二次函数的极大值问题(目标函数为凹函数, 想一想, 为什么?), 存在唯一解. 根据 Kuhn-Tucker 条件, 这个优化问题的解需满足

$$\alpha_i (y_i (\mathbf{w} \cdot \mathbf{x}_i + b) - 1) = 0 \quad (i = 1, 2, \dots, n)$$

因此, 对多数样本 α_i^* 将为 0, 取值不为 0 的 α_i^* 对应于使式(9-106)等号成立的样本即支持向量, 它们通常只是全体样本中的很少一部分.

解这个二次规划问题(可利用 Lagrange 方法求解)便得到最优分类函数

$$f(\mathbf{x}) = \text{sgn} \left\{ \sum \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b^* \right\} \quad (9-111)$$

由于非支持向量对应的 α_i^* 均为 0, 因此式中的求和实际上只对支持向量进行. 而 b^* 是分类的阈值, 可以由任意一个支持向量用式(9-106)求得(因为支持向量满足其中的等式), 或通过两类中任意一对支持向量取中值求得.

9.6.5.2 广义最优分类面

如果学习样本是线性不可分的,也就是说,就是某些训练样本不能满足式(9-106)的条件,可在条件(9-106)中增加一个松弛项 $\xi_i \geq 0$ 成为

$$y_i[(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1 + \xi_i \geq 0 \quad (i = 1, 2, 3, \dots, n) \quad (9-112)$$

将最小化目标函数改为

$$R(\mathbf{w}, \xi) = \frac{1}{2} \|\mathbf{w}\|^2 + C \left[\sum_{i=1}^n \xi_i \right] \quad (9-113)$$

其中 C 为某个指定常数,它实际上起控制对错分样本惩罚程度的作用,实现在错分样本的比例与算法复杂度之间的折中. 引进松弛量就是允许一定程度的错分,式(9-113)的第一项减小 VC 维(VC 维的概念是由 Vapnik 和 Cheyvonenkis 提出的,定义为能被一个函数集合分开最大数目的训练例子数),第二项减小经验风险,从而可得到最小期望风险,即折中考考虑最小错分样本和最大分类间隔. 求解式(9-113)(约束条件为式(9-112))就得到广义最优分类面.

用与求解最优分类面同样的方法来求解这一优化问题,同样得到二次函数极值问题,其结果与线性可分情况下的式(9-109)~式(9-111)几乎完全相同,只是式(9-109)中有关 α_i 的取值范围变为

$$0 \leq \alpha_i \leq C \quad (i = 1, 2, \dots, n) \quad (9-114)$$

9.6.5.3 高维空间的最优分类面

对于非线性分类,则首先通过非线性变换把学习样本变换到高维特征空间,然后在变换空间求最优分类面,见图 9-2. 这种变换可能比较复杂,还会导致特征空间的维数骤然增加,即陷入“维数灾难”,但可以用核函数技术避免,用核函数 $k(x, y)$ 代替内积运算 $(x \cdot y)$. 因为在对目标函数的寻优过程中只涉及训练样本之间的内积运算. 由 Mercer 定理可知,核函数 $k(x, y)$ 通过与其对应的非线性变换 ϕ 隐含地把输入样本变换到高维特征空间的特征向量. 如果用内积 $K(x, x')$ 代替最优分类面的内积,就相当于把原特征空间变换到了某一新




图 9-2 高维空间最优分类面

的特征空间,此时式(9-109)中的目标函数变为

$$\max Q(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j) \quad (9-115)$$

相应的最优分类函数式(9-111)也变为

$$f(\mathbf{x}) = \text{sgn} \left\{ \sum \alpha_i^* y_i k(\mathbf{x}_i, \mathbf{x}) + b^* \right\} \quad (9-116)$$

这就是支持向量机,常用的核函数包括:

(1) 多项式核函数, 即

$$k(\mathbf{x}, \mathbf{y}) = [(\mathbf{x} \cdot \mathbf{y}) + 1]^d \quad (9-117)$$

(2) RBF 型(radial basis function, 径向基函数)核函数, 即

$$k(\mathbf{x}, \mathbf{y}) = \exp\left\{-\frac{\|\mathbf{x} - \mathbf{y}\|^2}{\sigma^2}\right\} \quad (9-118)$$

(3) Sigmoid 核函数, 即

$$k(\mathbf{x}, \mathbf{y}) = \tanh(v(\mathbf{x} \cdot \mathbf{y}) + c) \quad (9-119)$$

式(9-118)中 v, c 为常数. 当核函数是线性函数时, 式(9-116)等价于式(9-111).

概括地说, 支持向量机就是通过用内积函数定义的非线性变换将输入空间变换到一个高维空间, 在这个空间中求(广义)最优分类面. SVM 分类函数形式上类似于一个神经网络, 输出是中间节点的线性组合, 每一个中间节点对应于输入样本与一个支持向量的内积, 因此 SVM 也被叫做支持向量网络, 如图 9-3 所示.




图 9-3 支持向量网络

由于最终的分类判别函数中实际只包含支持向量的内积, 因此泛化或推广分类判别函数用于识别新模式时的计算复杂度取决于支持向量的个数.

习 题

9-1 分析非线性规划问题

$$\begin{aligned} \min f(\mathbf{x}) &= (x_1 - 6)^2 + (x_2 - 2)^2 \\ \text{s. t. } &-x_1 + 2x_2 \leq 4 \\ &3x_1 + 2x_2 \leq 12 \\ &x_1 \geq 0, \quad x_2 \geq 0 \end{aligned}$$

在下列各点的可行下降方向 $\mathbf{d} = (d_1, d_2)^T$:

$$(1) \mathbf{x}^{(1)} = (0, 0)^T$$

$$(2) \mathbf{x}^{(2)} = (4, 0)^T$$

$$(3) \mathbf{x}^{(3)} = (2, 3)^T$$

$$(4) \mathbf{x}^{(4)} = (0, 2)^T$$

$$(5) \mathbf{x}^{(5)} = \left(\frac{48}{13}, \frac{6}{13}\right)^T$$

9-2 试写出非线性规划

$$\min f(x) = -(x-7)^2$$

$$\text{s. t. } 1 \leq x \leq 10$$

在 $\mathbf{x}^*$ 处的 Kuhn-Tucker 条件, 并进行求解.

9-3 求下列非线性规划问题

$$(1) \min f(\mathbf{x}) = -\ln(x_1 + x_2)$$

$$(2) \min f(\mathbf{x}) = -x_1$$

$$\text{s. t. } x_1 + 2x_2 \leq 5$$

$$\text{s. t. } (x_1 - 3)^2 + (x_2 - 2)^2 = 13$$

$$x_1 \geq 0, x_2 \geq 0$$

$$(x_1 - 4)^2 + x_2^2 \leq 16$$

的 Kuhn-Tucker 点.

9-4 试用 Kuhn-Tucker 条件和二阶充分条件求解下列非线性规划问题, 并画图说明之.

$$\min f(\mathbf{x}) = (x_1 - 1)^2 + (x_2 - 2)^2$$

$$\text{s. t. } x_2 - x_1 = 1$$

$$x_1 + x_2 \leq 2$$

$$x_1 \geq 0, x_2 \geq 0$$

9-5 用近似规划法求解下列问题:

$$\min f(\mathbf{x}) = (x_1 - 3)^2 + (x_2 - 3)^2$$

$$\text{s. t. } g_1(\mathbf{x}) = 8 - x_1^2 - x_2^2 \geq 0$$

$$g_2(\mathbf{x}) = x_1 + x_2 - 1 \geq 0$$

$$g_3(\mathbf{x}) = x_1 \geq 0$$

$$g_4(\mathbf{x}) = x_2 \geq 0$$

给定初始可行点 $\mathbf{x}^{(1)} = (1, 1)^T$, 步长限制 $\delta^{(1)} = (2, 2)^T$, 步长缩小系数 $\beta = 0.25$.

9-6 试用可行方向法求解下列非线性规划问题:

$$(1) \min f(\mathbf{x}) = x_1^2 + x_2^2 - 4x_1 - 4x_2 + 8$$

$$\text{s. t. } g_1(\mathbf{x}) = -x_1 - 2x_2 + 4 \geq 0$$

初始点为 $\mathbf{x}^{(1)} = (0, 0)^T$, 迭代两步.

$$(2) \min f(\mathbf{x}) = 2x_1^2 + 2x_2^2 - 2x_1x_2 - 4x_1 - 6x_2$$

$$\text{s. t. } g_1(\mathbf{x}) = x_1 + 5x_2 \leq 5$$

$$g_2(\mathbf{x}) = 2x_1^2 - x_2 \leq 0$$

$$x_1 \geq 0, x_2 \geq 0$$

初始点为 $\mathbf{x}^{(1)} = (0, 0.75)^T$, 迭代两步.

9-7 用外点法求解下列非线性规划问题:

$$(1) \min f(x) = (x_1 - 2)^2 + x_2^2$$

$$\text{s. t. } g(x) = x_2 - 1 \geq 0$$

$$(2) \min f(x) = x_1^2 + x_2^2$$

$$\text{s. t. } h(x) = x_2 - 1 = 0$$

9-8 用内点法求解下列非线性规划问题:

$$(1) \min f(x) = \frac{1}{12}(x_1 + 1)^3 + x_2$$

$$\text{s. t. } g_1(x) = x_1 - 1 \geq 0$$

$$g_2(x) = x_2 \geq 0$$

$$(2) \min f(x) = x_1^2 - 6x_1 + 2x_2 + 9$$

$$\text{s. t. } g_1(x) = x_1 - 3 \geq 0$$

$$g_2(x) = x_2 - 3 \geq 0$$

9-9 试用 SUMT 的混合法重新求解习题 9-4.

9-10 试用乘子法求解下列非线性规划问题:

$$(1) \min f(x) = \frac{1}{6}x_1^2 + \frac{1}{2}x_2^2$$

$$\text{s. t. } x_1 + x_2 - 1 = 0$$

$$(2) \min f(x) = x_1^2 + x_2^2$$

$$\text{s. t. } x_1 \geq 1$$

$$(3) \min f(x) = x_1 + \frac{1}{3}(x_2 + 1)^2$$

$$\text{s. t. } x_1 \geq 0$$

$$x_2 \geq 1$$

9-11 分别用直接消去法和广义消去法求解下列等式约束二次规划问题:

$$(1) \min f(x) = x_1^2 + x_2^2$$

$$\text{s. t. } h(x) = x_1 + x_2 - 1 = 0$$

$$(2) \min f(x) = \frac{3}{2}x_1^2 + x_2^2 + \frac{1}{2}x_3^2 - x_1x_2 - x_2x_3 + x_1 + x_2 + x_3$$

$$\text{s. t. } h(x) = x_1 + 2x_2 + x_3 - 4 = 0$$

9-12 用有效集法求解下列凸二次规划问题:

$$(1) \min f(x) = x_1^2 + 4x_2^2 - 2x_1 - x_2$$

$$\text{s. t. } x_1 + x_2 \leq 1$$

$$x_1, x_2 \geq 0$$

$$(2) \min f(x) = x_1^2 + 4x_2^2$$

$$\text{s. t. } x_1 - x_2 \leq 1$$

$$x_2 \leq 1$$

$$x_1 + x_2 \geq 1$$

9-13 x^* 是二次规划问题

$$\min f(x) = \frac{1}{2}x^T Gx + r^T x$$

$$\text{s. t. } A^T x = b$$

的全局最优解的充分必要条件是 x^*, λ^* 满足

$$\lambda^* = (A^T G^{-1} A)^{-1} (A^T Gr + b)$$

$$x^* = G^{-1} (A \lambda^* - r)$$

第三篇 现代最优化算法

第10章 最优化问题概论

前几章介绍了经典的最优化理论和方法,这些大多具有局限性,主要表现在:一是难以得到全局最优解,二是对有些优化问题虽有求最优解的最优算法,但计算时间之长令人难以接受.本章作为第三篇的导言,对最优化问题从计算复杂性(时间复杂性和空间复杂性)方面加以归类,特别是从时间复杂性方面着手,介绍最优化问题的分类.目的有二,一是说明学习后续各章全局优化算法的必要性;二是说明并不是对任何最优化问题,用这些方法求解都是有效、经济和可靠的.

本章对最优化问题的分类、最优化算法分类进行简单介绍,并引入计算复杂性、NP 等概念,为后文介绍启发式最优化算法做必要的准备.

10.1 最优化问题

最优化方法涉及的应用领域很广,问题的种类与性质繁多,归纳起来,可分为函数优化问题和组合优化问题两大类,其中函数优化问题的解是一定区域内的连续取值的量,而组合优化问题的解则是离散取值的量(本书以后各章假设解的个数是有限).

10.1.1 函数优化问题

前九章介绍的最优化计算方法基本上都属于函数优化问题.函数优化问题一般可描述为:设 D 为 n 维实数空间 $\mathbb{R}^n$ 上的区域,函数 f 为 $D \rightarrow \mathbb{R}$ 的映射.所谓函数 f 在区域 D 上全局最大化就是寻求点 $x^* \in D$,使得 $f(x^*)$ 在区域 D 上最大,即 $f(x) \leq f(x^*), \forall x \in D$.

通常函数优化问题又分为有约束和无约束两类,可分别表述为

$$\max_{x \in D} f(x) \quad \text{和} \quad \begin{cases} \max_{x \in D} f(x), \\ g(x) \geq 0, \\ h(x) = 0. \end{cases}$$

对有约束优化问题,一般都是先想办法转换成同解的无约束问题来求解,常用的方法有:

(1) 把问题约束在“状态”的表达形式中体现出来,并设计专门的算子,使状态所表示的解在搜索过程中始终保持可行性.这种方法最直接,但适用领域有限,算子的设计也较困

难.

(2) 在解的编码过程中不考虑约束,而在搜索过程中通过检验解的可行性来决定解的弃或用.这种方法只适用于简单的约束问题.

(3) 采用惩罚的方法来处理约束越界的问题.这种方法比较通用,适当选择罚函数可得到较好的结果.比如,将以上带约束优化问题采用罚函数

$$\begin{cases} \max f(x) + \lambda h^2(x) + \beta [\min\{0, g(x)\}]^2 \\ x \in D \end{cases}$$

另外,为了比较和测试各种算法的性能,通常是基于一些典型问题展开的,参考文献[13]列举了数十种这样的典型问题.

10.1.2 组合优化问题

组合优化问题在表达形式上与函数优化问题没有差别,比如

$$\begin{aligned} & \max f(x) \\ & \text{s. t. } g(x) \geq 0 \\ & x \in D \end{aligned}$$

它由目标函数 $f(x)$,约束函数 $g(x)$ 和决策变量 x 及其取值范围 D 等构成,这里 D 为有限个点的集合.若令 $F = \{x | x \in D, g(x) \geq 0\}$,则一个组合优化问题可用三元组 (D, F, f) 表示,如果 $x^* \in F$ 使得 $f(x^*) = \max\{f(x) | x \in F\}$,则称 x^* 为该问题的全局最优解.

例 10-1 0-1 背包问题(knapsack problem)

设有一个容积为 b 的包, n 个体积分别为 a_i 、价值分别为 c_i 的物品, $i = 1, 2, \dots, n$,如何以最大的价值装包?

这个问题称为0-1背包问题,也可表述为

$$\max \sum_{i=1}^n c_i x_i \quad (10-1)$$

$$\text{s. t. } \sum_{i=1}^n a_i x_i \leq b \quad (10-2)$$

$$x_i \in \{0, 1\} \quad (i = 1, 2, \dots, n) \quad (10-3)$$

其中目标函数(10-1)欲使包内所装物品的价值最大,(10-2)为包的能力限制,(10-3)表示二进制变量, $x_i = 1$ 表示装第 i 个物品, $x_i = 0$ 表示不装.此时, $D = \{0, 1\}^n$,其中共有 $|D| = 2^n$ 个维数为 n 的0-1向量,这里及以后 $|D|$ 表示集合 D 中元素的个数.

例 10-2 旅行商问题(Traveling Salesman Problem, TSP)

一个商人欲到 n 个城市推销商品,每两个城市 i 和 j 之间的距离为 d_{ij} ,如何选择一条路径使得商人走遍每个城市回到起点的路程最短. TSP还可以分为对称和非对称距离两大类问题.当 $d_{ij} = d_{ji}$, $\forall 1 \leq i, j \leq n$ 时,称为对称(距离)TSP,否则称为非对称(距离)TSP.此问题也可表述为

$$\min \sum_{i=1}^n d_{ij} x_{ij} \quad (10-4)$$

$$\text{s. t. } \sum_{j=1}^n x_{ij} = 1 \quad (i = 1, 2, \dots, n) \quad (10-5)$$

$$\sum_{i=1}^n x_{ij} = 1 \quad (j = 1, 2, \dots, n) \quad (10-6)$$

$$\sum_{i,j \in S} x_{ij} \leq |S| - 1, \quad 2 \leq |S| \leq n - 2, S \subset \{1, 2, \dots, n\} \quad (10-7)$$

$$x_{ij} \in \{0, 1\} \quad (i, j = 1, 2, \dots, n, i \neq j) \quad (10-8)$$

以上是基于图论的数学模型,其中(10-8)中的决策变量 $x_{ij}=1$ 表示商人行走的路线包含从城市 i 到城市 j 路径, $x_{ij}=0$ 表示没有选择走这条路径, $i \neq j$ 的约束可以减少变量的个数,使得决策变量共有 $n \times (n-1)$ 个。(10-4)要求距离之和最小。(10-5)要求商人从城市 i 出来一次,(10-6)要求商人走入城市 j 只有一次,(10-7)要求商人在城市子集中不形成回路.此时, $D = \{0, 1\}^{n \times (n-1)}$, $|D| = 2^{n \times (n-1)}$.

例 10-3 装箱问题(Bin Packing)

如何以个数最少的尺寸为 1 的箱子装进 n 个尺寸不超过 1 的物品,此问题称为装箱问题.

例 10-4 约束机器排序问题(Capacitated Machine Scheduling)

n 个加工量为 $\{d_i, i = 1, 2, \dots, n\}$ 的产品在一台机器上加工,机器在第 j 个时段的工作能力为 c_j ,为完成所有产品加工的最少时段数,它可以表述为

$$\min T \quad (10-9)$$

$$\text{s. t. } \sum_{j=1}^n x_{ij} = 1 \quad (i = 1, 2, \dots, n) \quad (10-10)$$

$$\sum_{i=1}^n d_i x_{ij} \leq c_j \quad (j = 1, 2, \dots, T) \quad (10-11)$$

$$x_{ij} \in \{0, 1\} \quad (i = 1, 2, \dots, n, j = 1, 2, \dots, T) \quad (10-12)$$

其中, x_{ij} 、 T 为决策变量, $x_{ij}=1$ 表示第 t 时段加工产品 i 。(10-9)要求加工所用时段数最少,(10-10)表示产品 i 一定在某一时段被加工,(10-11)表示每个时段的加工量不超过加工能力.

例 10-5 三精确覆盖问题

已知 $S = \{u_1, u_2, \dots, u_{3m}\}$ 的 n 个子集构成的子集族 $F = \{S_1, S_2, \dots, S_n\}$,其中每个子集包含 S 中的 3 个元素, F 中是否存在 m 个子集 $S_{i_1}, S_{i_2}, \dots, S_{i_m}$,使得 $\bigcup_{j=1}^m S_{i_j} \supset S$? 如果此式成立,我们称 m 个子集 $S_{i_1}, S_{i_2}, \dots, S_{i_m}$ 覆盖 S .

10.2 计算复杂性与 NP 完全问题

10.2.1 计算复杂性的概念

由组合优化问题的定义可知,每一个组合最优化问题的解集都是有限集,因而都可以通过枚举的方法求得最优解.枚举是以时间为代价的,有的枚举时间还可以接受,有的则不可能接受.如例 10-2 的对称 TSP,可以用另一种决策变量更少的方法来表示它的可行解,即用 n 个城市的一个排列表示商人按这个排列顺序走遍每个城市并返回起点.若固定起点城

市,且以路径比较为基本操作,则需要 $\frac{(n-1)!}{2} - 1$ 次基本操作. 对于每秒执行一百万次操作的计算机,当 $n=20$ 时,就需要1929年的时间才能找到最优解. 所以,我们必须对计算复杂性理论有所了解,这也是最优化算法的理论基础. 只有了解所研究问题的复杂性,才能有针对性地设计算法,进而提高优化效率.

首先,我们以组合优化问题为背景,介绍一些计算复杂性的概念. 复杂性的研究是从“问题(problem)”开始的. 问题是需要回答的一般性提问,通常含有若干个满足一定条件的参数. 一般地,问题通过下面的描述给定:

(1)描述所有参数的特性;

(2)描述答案所满足的条件. 一旦所有参数确定,则称之为问题的一个实例.

定义 10-1 给定一个组合优化问题,当问题中的参数赋予具体值时,称为问题的一个实例(instance). 这些具体参数值称为数据(data),这些数据输入计算机所占空间称为实例的输入长度(size).

输入长度与数据在计算机的存储编码方式有关. 下面结合例子解释和体会这几个概念. 在例10-2中,TSP是一个问题,它由式(10-4)~式(10-8)表示,参数为城市数 n 和城市间距离 d_{ij} ,这些参数的具体取值为数据,一旦数据给定,它就是TSP的一个实例.

衡量一个算法的好坏通常是用算法中的加、减、乘、除和比较等基本运算的总次数同实例在计算机具体计算时的编码(比如二进制编码)数据的输入长度的大小关系来度量. 对于一个整数,二进制表示是以

$$x = a_l 2^l + a_{l-1} 2^{l-1} + \cdots + a_1 \times 2 + a_0 \quad (a_l \neq 0)$$

的系数 $(a_l a_{l-1} \cdots a_1 a_0)$ 来表示的,其中 $a_i \in \{0, 1\}$ ($i=1, 2, \cdots, l-1$). 由

$$2^l \leq 2^{\log_2 x} = x \leq 2^{l+1} \leq 2^{\log_2 x + 1}$$

可知,这个二进制数的位数是 $l+1$,即 x 的输入长度为 $l+1$,它在 $\log_2 x$ 和 $\log_2 x + 1$ 之间. 于是 x 的二进制数的输入长度在 $[\log_2 x]$ 和 $[\log_2 x] + 1$ 之间,这里 $[x]$ 表示不小于 x 的最小整数,并约定 $\log_2 0 = 0$.

现在来计算TSP数据的二进制输入长度,其解的表达形式为城市的一个排序,一条路径上商人行走的长度的基本运算为两个城市间的 n 个求和. 因为有 $(n-1)!$ 条路径,枚举所有路径进行 $(n-1)!$ 次比较,可以得到最优路径,这个枚举算法的基本运算总次数为

$$n \times (n-1)! = n!$$

实例在计算机计算时只需输入城市数 n 和城市间的距离 d_{ij} ($1 \leq i, j \leq n, i \neq j$),且假设这些数为整数,对任何一个非零距离 d_{ij} ,它的二进制输入数据的输入长度不超过

$$[\log_2 |d_{ij}| + 1]$$

实例的二进制输入长度总量不超过

$$L = n(n-1) + \log_2 |p|$$

其中, p 为 $\{d_{ij}, 1 \leq i, j \leq n, i \neq j\}$ 中所有非零数的乘积.

若假设 $S = \{d_{ij}, 1 \leq i, j \leq n, i \neq j\}$ 中元素的绝对值有一个上界 K ,则

$$L = n(n-1) + \log_2 |p| \leq n(n-1)(1 + \log_2 K)$$

至此我们发现,TSP实例的计算机二进制输入长度和算法的基本运算次数都是城市数 n 的函数. TSP实例的二进制输入长度是 n 的多项式函数,而枚举法的基本运算总数是 n 的阶乘

函数,比指数函数增加的速度还快.

以上对 TSP 实例的二进制输入长度和算法的基本运算总次数是粗略估计的. 一般是给予一个上限,一个求解实例 I 的算法基本运算总次数 $C(I)$ 同实例的计算机二进制输入长度 $d(I)$ 的关系常用符号 $C(I) = f(d(I)) = O(g(d(I)))$ 表示. 它的含义是:求解实例 I 的算法的基本运算总次数 $C(I)$ 是实例输入长度 $d(I)$ 的一个函数,这个函数被另一个函数 $g(x)$ 控制,即存在一个函数 $g(x)$ 和正常数 α ,使得

$$C(I) \leq \alpha g(d(I)) \quad (10-13)$$

其中, $g(x)$ 的函数特性决定了基本运算次数的性能,且引出如下定义.

定义 10-2 假设问题和解决该问题的一个算法已经给定. 若对给定问题的一个实例 I , 存在多项式函数 $g(x)$ 使不等式 (10-13) 成立, 则称该算法是实例 I 的多项式时间算法; 若存在多项式函数 $g(x)$, 对该问题的每个实例都有式 (10-13) 成立, 则称该算法为解决该问题的多项式时间算法. 特别对优化问题, 当一个算法为求解该优化问题的多项式时间算法, 则称该算法为该问题的多项式时间最优算法.

当不存在多项式函数 $g(x)$ 使式 (10-13) 成立时, 通常称相应的算法为非多项式时间算法.

复杂性分析的一个研究方向是对算法进行评价. 对于解决一个问题的算法, 如何评估这个算法的性能? 复杂性是评价算法的一个指标. 复杂性分析是针对最坏的实例, 确定是否存在多项式函数 $g(x)$ 使式 (10-13) 成立. 即可叙述为: 对一个求解问题的算法, 是否存在多项式函数 $g(x)$ 和常数 α , 使得对问题的任意一个实例 I , 都有式 (10-13) 成立.

例 10-6 整数规划问题 (Integer Programming)

$$\begin{aligned} \min \quad & c^T x \\ \text{s. t.} \quad & Ax = b \\ & x \geq 0, x \in \mathbb{R}^n \end{aligned} \quad (\text{IP})$$

其中, $c = (c_1, c_2, \dots, c_n)^T$, $A = (a_{ij})_{m \times n}$, $b = (b_1, b_2, \dots, b_m)^T$, A, b, c 各分量为整数, x 为 n 维决策变量, 取非负整数值. 由于任何一个非负整数 s 的二进制输入长度至少是 1 且不超过 $\log_2 s + 1$, (LP) 的三组数据 A, b, c 的二进制输入长度的上下限分别为下列区间的左右端点.

$$\begin{aligned} & \left[\max \{ mn, \sum_{i=1}^m \sum_{j=1}^n \log_2 |a_{ij}| \}, \sum_{i=1}^m \sum_{j=1}^n (\log_2 |a_{ij}| + 1) \right] \\ & \left[\max \{ m, \sum_{i=1}^m \log_2 |b_i| \}, \sum_{i=1}^m (\log_2 |b_i| + 1) \right] \\ & \left[\max \{ n, \sum_{i=1}^n \log_2 |c_i| \}, \sum_{i=1}^n (\log_2 |c_i| + 1) \right] \end{aligned}$$

这三组数据输入长度累计之和的上下限分别为 $mn + m + n + \log_2 |p|$ 和

$$\max \{ mn + m + n, \log_2 |p| \}$$

其中, p 为 A, b, c 中所有非零数的乘积.

注 大家知道, 如果对以上 IP 中的系数和解不要求为整数, 则该问题就是一般的线性规划问题 (LP).

以下简单讨论单纯形法对解线性规划问题的复杂性. 大家知道, 单纯形法是求解线性规划问题的主要算法之一, 对于大多数实例, 它的计算效果非常好, 也可以说, 线性规划问题的

大多数实例存在多项式时间算法,但也存在极端情形,Klee 和 Minty 给出了下面这样一个实例

$$\begin{aligned}
 & \min \{-x_n\} \\
 & \text{s. t. } 4x_1 - 4r_1 = 1 \\
 & \quad x_1 + s_1 = 1 \\
 & \quad 4x_j - x_{j-1} - 4r_j = 0 \quad (j = 2, 3, \dots, n) \\
 & \quad 4x_j + x_{j-1} + 4s_j = 4 \quad (j = 2, 3, \dots, n) \\
 & \quad x_j, r_j, s_j \geq 0 \quad (j = 1, 2, \dots, n)
 \end{aligned} \tag{10-14}$$

参考文献[18]中证明了用单纯形算法求解线性规划实例(10-14)时,其迭代步数为 $2^n - 1$. 但是,另外一方面,由于实例(10-14)共有 $2n$ 个约束和 $3n$ 个变量,从例10-14可知,对二进制输入长度大小的估计,不超过 $6n^2 + 2n + 3n + \log_2 |p|$,其中 p 是式(10-14)的参数中所有非零数的乘积. 可见,单纯形法不是线性规划问题的多项式时间算法.

复杂性分析的另一个研究方向是对组合优化问题归类. 下面加以简单介绍.

定义 10-3 对于给定的一个优化问题,若存在一个求解该问题最优解的算法、一个多项式函数 $g(x)$ 和常数 α ,使得式(10-13)对给定优化问题的任何一个实例成立,则称给定的优化问题是多项式时间可解问题,或简称为多项式问题,所有多项式问题的集合记为 $P(\text{polynomial})$.

单纯形法不是线性规划问题的多项式时间算法,但这不能说线性规划问题不是多项式问题,Khachian 成功地构造了椭球算法并证明了其算法是线性规划问题的多项式时间算法,因此,线性规划问题是多项式问题.

并不是所有的组合优化问题都找到了求解的多项式时间算法. 为对那些迄今为止还没有找到多项式时间算法的组合优化问题(或不能肯定其是否属于多项式问题)进行归类,在计算复杂性研究中提出了 NP, NP-C 和 NP-hard 等概念,这将在下节作简单介绍.

10.2.2 NP, NP-C 和 NP-hard 概念

迄今为止,许多组合优化问题还没有找到求解最优解的多项式时间算法,比多项式问题(即 P 问题)更广泛的一类是非多项式问题(Nondeterministic Polynomial, 简记 NP). NP 问题的概念通常是由判定问题引入的.

定义 10-4 如果一个问题的问题的一个实例只有“是”或“否”两种答案,则称这个问题为判定问题,称答案为是的实例为是实例,称答案为否的实例为否实例或非是实例.

在研究组合优化问题复杂性时,处理的方法是对给定的一类优化问题转化为判定问题,使得每个实例只有“是”或“否”两种答案,从而归结为判定问题的复杂性来讨论.

例 10-7 将(LP)转化为 LP-判定问题.

先给出一个目标函数值 z ,将极小化目标函数转化为:判定是否有可行解使其目标值不超过这个 z ,判定问题的数学表达式可写为

$$\text{给定 } z \text{ 是否有 } \{x \mid c^T x \leq z, Ax = b, x \geq 0\} \neq \emptyset$$

$\{x \mid c^T x \leq z, Ax = b, x \geq 0\}$ 称为对应线性规划问题的可行解. 同样,对例 10-6 的整数(IP)问题也可以转化为与上类似的判定问题

例 10-8 将 TSP 转化为一个判定问题.

用 n 个城市的一个排列 $(i_1 i_2 \cdots i_n)$ 表示商人从城市 i_1 出发依次通过 $i_2, i_3, \cdots, i_n$, 最后返回 i_1 这样一个路径, 判定问题为:

给定 z , 是否存在 n 个城市的一个排列 $W = (i_1, i_2, \cdots, i_n)$, 使得

$$f(W) = \sum_{i=1}^n d_{i_j i_{j+1}} \leq z$$

其中 $i_{n+1} = i_1$, 满足 $f(W) = \sum_{i=1}^n d_{i_j i_{j+1}} \leq z$ 的一个排列 W 称为对应判定问题的一个可行解.

下面讨论判定问题的复杂性的刻画. 对于判定问题, 其求解过程可以分为两个阶段, 第一阶段是猜测阶段, 第二阶段是验证阶段. 对于“是”实例, 就是先猜测出回答为“是”的实例的解, 然后验证此解是否为该实例“是”的回答. 由于在计算机求解时, 问题及其解都是用编码表示的, 因而在判定问题求解的两个阶段中, 第一阶段有实例的输入长度, 第二阶段有猜测解的输入长度, 为以下叙述的方便, 把这两个输入长度分别称为实例输入长度和猜测解输入长度.

定义 10-5 若存在一个多项式 g 和一个验证算法 H , 对一类判定问题 A 的任何一个“是”的判定实例 I , 都存在一个“是”答案 S , 满足其输入长度 $d(S) \leq g(d(I))$, 且算法 H 验证 S 为实例 I 的“是”答案的计算时间 $f(H) \leq g(d(I))$, 则称判定问题 A 是非多项式确定的, 简记为 NP. 在不致混淆的情况下, 用 NP 表示所有非多项式确定问题的集合.

由以上定义知, 回答判定问题是否属于 NP, 只需对其“是”实例讨论是否存在一个猜测解、多项式 g 和验证算法 H , 满足定义中输入长度和验证时间的要求, 而不讨论非“是”实例, 也不问解和算法是如何得到的. 另外, 由定义 10-5 和定义 10-3, 显然 $P \subset NP$.

例 10-9(例 10-8 续) TSP 属于 NP

实例在计算机计算时只需输入城市数 n 和城市间的距离 d_{ij} ($1 \leq i, j \leq n, i \neq j$), 且假设这些数为整数, 对任何一个非零距离 d_{ij} , 它的二进制输入数据的输入长度不超过

$$\max\{\log_2 |d_{ij}|, 1\}$$

实例的二进制输入长度总量不超过 $L = \max\{n(n-1), \log_2 |p|\}$. 其中, p 为

$$\{d_{ij}, 1 \leq i, j \leq n, i \neq j\}$$

中所有非零数的乘积. 即实例输入长度不超过 $n(n-1)$.

再看一个猜测解输入长度, 解的形式如例 10-8 所示, 任何一个排列 $W = (i_1, i_2, \cdots, i_n)$ 的输入长度不超过

$$\sum_{i=1}^n ([\log_2 i] + 1) < n + n[\log_2 n] < 2n(n-1) \quad (n \geq 2)$$

要验证任何这样一个猜测解是否满足 $f(W) = \sum_{i=1}^n d_{i_j i_{j+1}} \leq z$, 需要 n 次加法和 1 次比较, 共 $n+1$ 次运算.

于是, 取 $g(x) = 2x$, 则实例输入长度和验证算法都满足定义 10-5 的要求, 从而 TSP 属于 NP.

为研究一般组合优化问题的复杂性, 还有一种方法就是转换和归约, 即设法把几类问题归约为同一个问题, 而这个问题的复杂性研究清楚了, 那么原来几类问题的复杂性也就知道了.

定义 10-6 给定问题 A_1 和 A_2 , 若存在一个多项式 g 和一个字符串映射 f 满足:

(1) 对 A_1 的任何一个实例 I_1 , 在实例 I_1 输入长度的多项式时间 $g(d(I_1))$ 内构造 A_2 的一个实例 I_2 , 使其输入长度不超过 $g(d(I_1))$;

(2) 映射 f 使得实例 I_1 和 I_2 的解一一对应, 且 S_1 为 I_1 的“是”答案的充分必要条件为 $S_2 = f(S_1)$ 是 I_2 的一个“是”答案, 则称问题 A_1 多项式转换(transformation)为问题 A_2 .

例 10-10 三精确覆盖问题多项式转换为 0-1 背包问题

由例 10-5, 集合 S 中有 $3m$ 个元素, 按其下标排列这些元素, 此时子集族 F 中的每个子集 $S_i (i=1, 2, \dots, n)$ 对应唯一一个 $3m$ 维向量, 即那些元素属于 S_i 的分量位置取 1, 其余位置取 0. 这样 F 中的 m 个元素 $S_{i_1}, S_{i_2}, \dots, S_{i_m} (i=1, 2, \dots, m)$ 是 S 的三精确覆盖的充分必要条件是其相应的 m 个 $3m$ 维的向量的和为 $(1, 1, \dots, 1)$.

由于这个一一对应关系, 对任一 $S_j \in F$, 可定义它与一个整数的对应关系

$$S_j \rightarrow c_j = \sum_{u_i \in S_j} (n+1)^{(i-1)} \quad (10-15)$$

如此, 将一个向量对应唯一的一个整数. 特别对于每个分量都为 1 的 $3m$ 维向量

$$(1, 1, \dots, 1)$$

选 K 为

$$(1, 1, \dots, 1) \rightarrow K = \sum_{j=1}^{3m} (n+1)^{(j-1)} \quad (10-16)$$

由以上定义的对对应关系, 三精确覆盖的一个实例就唯一对应 0-1 背包问题的一个实例 (物品的一个价格向量), 并且对应实例的输入长度满足定义 10-6 的条件(1).

另外, 三精确覆盖实例的一个解 $\{S_{i_1}, S_{i_2}, \dots, S_{i_m}\} \subset F$ 对应背包问题实例的唯一一个解 $B = (i_1, i_2, \dots, i_m)$. 我们来证明, S 存在一个三精确覆盖 $\{S_{i_1}, S_{i_2}, \dots, S_{i_m}\}$ 的充分必要条件是

$$\sum_{j=1}^m c_{i_j} = K, \text{ 亦即定义 10-6 的条件(2) 成立.}$$

事实上, 设存在 $T \subset \{1, 2, \dots, n\}$, 使得 $\sum_{j \in T} c_j = K$. 则一方面, 由式(10-15) 和式(10-16), K 和 $c_j (j \in T)$ 都是关于 $(n+1)$ 次多项式, 且多项式的系数都是 1; 另一方面, T 中总项数不超过 n , 从而 $\sum_{j \in T} c_j$ 中关于 $(n+1)$ 的同次幂的系数和不超过 n , 于是 $\sum_{j \in T} c_j$ 中 $(n+1)$ 各次幂的系数都是 1, 进而由式(10-15) 作反变换, 得 $S_j \in T$ 是 S 的一个三精确覆盖.

反之, 设 $\{S_{i_1}, S_{i_2}, \dots, S_{i_m}\}$ 是 S 的三精确覆盖, 则由式(10-15) 定义的 $c_j (j=1, 2, \dots, m)$ 使得 $\sum_{j=1}^m c_{i_j}$ 中 $(n+1)$ 的各次幂的系数都为 1, 且为关于 $(n+1)$ 的 $3m-1$ 次多项式. 从而由式

$$(10-16) \text{ 知, } \sum_{j=1}^m c_{i_j} = K.$$

Cook 给出并证明了有一类问题具有下述性质: (1) 这类问题中任何一个问题至今未找到多项式时间算法; (2) 如果这类问题中存在一个问题有多项式时间算法, 那么这类问题都有多项式时间算法. 这类问题记为 NPC 或 NP-C (NP-Complete). 下面先给出多项式归约的概念.

定义 10-7 已知判定问题 A_1 和 A_2 , 若存在多项式 g_1 和 g_2 , 使得对 A_1 的任何实例 I ,

在多项式时间内构造 A_2 的一个实例,其输入长度不超过 $g_1(d(I))$,并对 A_2 的任何一个算法 H_2 ,都存在 A_1 的一个算法 H_1 ,使得算法 H_1 调用算法 H_2 并使得计算时间

$$f_{H_1}(d(I)) \leq g_2(f_{H_2}(g_1(d(I))))$$

则称问题 A_1 多项式归约(reduction)为问题 A_2 . 其中, $f_{H_1}(d(I))$ 和 $f_{H_2}(d(I))$ 分别表示 H_1 和 H_2 的计算时间与实例输入长度 $d(I)$ 之间的关系.

注 (1)从定义 10-7 看出,若 A_2 存在多项式时间算法,则 A_1 一定存在多项式时间算法.

(2)比较定义 10-6 和定义 10-7,可以看到,若问题 A_1 多项式转化为问题 A_2 ,则问题 A_1 多项式归约为问题 A_2 ,所以多项式归约比多项式转化更广泛.

事实上,对于 A_2 的任何算法 H_2 ,构造求解问题 A_1 的算法可按如下步骤进行:对问题 A_1 的任何实例 I_1 ,先用多项式时间 $g_1(d(I_1))$ 构造问题 A_2 的一个实例 I_2 ;再调用算法 H_2 求解实例 I_2 ,这一步的计算时间为 $f_{H_2}(g_1(d(I)))$. 这样构造的算法对问题 A_1 的任意实例 I_1 的计算时间不超过 $g_1(d(I_1)) + f_{H_2}(g_1(d(I)))$,满足定义 10-6.

定义 10-8 称判定问题 A 属于 NPC(NP-Complete),如果 $A \in \text{NP}$ 且 NP 中任何一个问题可在多项式时间内归约为问题 A . 另外,若 NP 中的任何一个问题可在多项式时间内归约为判定问题 A ,则称问题 A 为 NP 难或 NP-hard.

由定义 10-8 可以看到, $\text{NPC} \subset \text{NP-hard}$. NPC 与 NP-hard 两者的区别是 NP-hard 问题无须判断 A 是否属于 NP. 验证一个问题 A 是否为 NPC 的关键有两点:一是 NP 中任何一个问题是否可在多项式时间内归约为 A ;二是验证 A 是否属于 NP,即是否存在一个字符串,其输入长度为问题 A 的实例长度的多项式函数及一个多项式时间的验证算法.

由多项式转换和归约、NPC、NP-hard 等的定义,当已知一个问题为 NPC 或 NP-hard,再遇到一个新问题时,只要已知问题可由多项式归约为新问题,则知新问题是 NP-hard. 当可以验证新问题是属于 NP 时,则该问题属于 NPC. 由此可知,研究一个新问题的复杂性,往往借助于已知问题的复杂性和多项式归约(参见例 10-7).

例 10-11 三精确覆盖问题属于 NPC

例 10-12 背包判定问题属于 NPC

背包问题的解对应一个 n 维 0-1 分量的向量,于是很容易验证属于 NP. 而例 10-10 已证明三精确覆盖多项式转换为背包判定问题,从而由定义 10-7 的注(2),三精确覆盖多项式归约为背包判定问题. 利用例 10-11 的事实知,背包判定问题属于 NPC.

算法复杂性的四类问题之间的关系可用示意图 10-1 表示.




图 10-1 组合优化问题复杂性分类示意图

示意图 10-1 表示 $P \subset \text{NP}$, $\text{NPC} \subset \text{NP-hard}$, NP 与 NP-hard 的公共部分为 NPC. 在 NP 中,除 P 和 NPC,还有一部分问题的复杂性是未知的.

10.3 邻域概念

大家知道,光滑函数极值的数值求解中,邻域是一个非常重要的概念,函数的下降或上升都是在一点的邻域中寻求变化方向.在距离空间中,通常的邻域定义是以一点为中心的一个圆.在组合优化中,经典的距离的概念通常不再适用,但是在一点附近搜索另一个下降(或上升)的点仍然是组合优化数值求解的基本思想.因此,需要重新定义邻域的概念.

定义 10-9 对于组合优化问题 (D, F, f) , D 上的一个映射:

$$N: D \rightarrow 2^D, D \ni s \mapsto N(s) \in 2^D$$

称为一个邻域映射,其中 2^D 表示 D 的所有子集组成的集合, $N(s)$ 称为 s 的邻域, $s' \in N(s)$ 称为 s 的一个邻居.

例 10-13 对例 10-2 给出的 TSP 模型, $D = \{x | x \in \{0, 1\}^{n \times (n-1)}\}$,可以定义它的一种邻域为:

$$n(x) = \{y | |y - x| = \sum_{i \neq j} |y_{ij} - x_{ij}| \leq k, y \in D\}$$

k 为取定的一个正整数.由这个邻域定义, $N(x)$ 是由 x 经最多 k 个分量的值发生变化而得的 $n \times (n-1)$ 维 0-1 向量的集合, x 的邻居个数为 $C_{n(n-1)}^1 + C_{n(n-1)}^2 + \cdots + C_{n(n-1)}^k$.

例 10-14 对 TSP 的解的另一种编码方式,即以 n 个城市序号的一个全排列来表示商人无重复走完 n 个城市的一种路径,则

$$D = F = \{s = (i_1, i_2, \dots, i_n) | i_1, i_2, \dots, i_n \text{ 是 } 1, 2, \dots, n \text{ 的一个排列}\}$$

此时,可定义它的邻域映射为 2-opt,即对任 $s \in F$, $N(s)$ 定义为由 s 的任意两个分量调换所得的向量构成的集合,从而 s 共有 C_n^2 个邻居.比如,取 $n=4$, $s=(1, 2, 3, 4)$,则

$$N(s) = \{(2, 1, 3, 4), (3, 2, 1, 4), (4, 2, 3, 1), (1, 3, 2, 4), (1, 4, 3, 2), (1, 2, 4, 3)\}.$$

邻域的构造依赖于问题决策变量的表示(问题解的编码方式),邻域在现代优化算法中起很重要的作用,这一点将在后续各章中看到.有了邻域的定义,类似于光滑函数的情形,可以定义局部、全局最优概念.

定义 10-10 对于组合优化问题 (D, F, f) ,若 s^* 满足

$$f(s^*) \leq (\geq) f(s), \quad s \in N(s^*) \cap F$$

则称 s^* 为 f 在 F 上的局部(local)最小(最大)解.若

$$f(s^*) \leq (\geq) f(s), \quad s \in F$$

则称 s^* 为 f 在 F 上的全局(global)最小(最大)解.

现代优化算法所要解决的问题就是寻求问题的全局最优(最大或最小)解.

10.4 启发式算法

10.4.1 启发式算法的概念

启发式算法(Heuristic Algorithm)是相对于最优算法提出的,一个问题的最优算法求得该问题每个实例的最优解.但在某些情况下,特别是在实际问题中,最优算法的计算时间使

人无法忍受或因问题的难度使其计算时间随问题规模的增加以指数速度增加,如在 10.2 节提到的 TSP 的枚举解法就是如此,因而人们想到基于直观或经验构造一种算法,去求问题的一个可行解. 这种方法就是所谓的启发式算法.

启发式算法可以这样定义:一个基于直观或经验构造的算法,在可接受的花费(指计算时间、占用空间等)下给出待解决组合优化问题每一个实例的一个可行解,该可行解与最优解的偏离程度不一定事先可以预计.

另一种定义为:启发式算法是一种技术. 这种技术使得在可接受的计算费用内去寻找最好的解,但不一定能保证所得解的可行性和最优性,甚至在多数情况下,无法阐述所得解同最优解的近似程度. 启发式方法是对启发式算法的综合应用.

上述启发式算法的两个定义中,一个共同的特点是不考虑算法所得解与最优解的偏离程度. 如果采用分析最坏情况的误差界限的概念来评价启发式算法,则可以将近似算法定义如下.

定义 10-11 设 A 是一个问题,记问题 A 的任何一个实例 I 的最优解和启发式算法 H 解的目标值分别为 $z_{opt}(I)$ 和 $z_H(I)$. 对于某个 $\varepsilon > 0$, 如果

$$|z_H(I) - z_{opt}(I)| \leq \varepsilon |z_{opt}(I)|, \forall I \in A.$$

则称 H 是问题 A 的 ε 近似算法(ε -approximation algorithm).

上面的定义给出启发式算法和近似算法两个概念的联系和区别. 启发式算法概念定义的算法集合包含了近似算法概念定义的算法集合. 近似算法强调给出算法最坏情况的误差界限,而启发式算法不需考虑偏差程度. 由于很多组合优化问题算法的最坏情况误差界估计需要很强的数学基础和较强的技巧,甚至一些问题很难或无法给出最坏情况误差界,而实际问题又迫切要求求解的方法,因此,只能通过启发式算法解决问题.

早在 20 世纪 40 年代末期,由于实际问题的需要,人们已提出一些解决实际问题的快捷有效的启发式算法. 有代表性的工作是 1948 年 Polya 的著作(参考文献[18]). 20 世纪 60~70 年代随着对数学模型及最优解算法的重视,这些算法被称为“快速与丑陋(quick and dirty)”方法. 20 世纪 70 年代由于算法复杂性理论的完善,不再强调一定要求到最优解,因此促使 80 年代初兴起的现代优化算法在今天得到了巨大的发展. 通过下面的例子先对启发式算法有一定的了解.

例 10-15 背包问题的贪婪算法(Greedy Algorithm)

对例 10-1 的背包问题可以构造下面的贪婪算法:

STEP1 对物品以比值 c_i/a_i 从大到小排列,不妨将排列记为 $\{1, 2, \dots, n\}$, $k := 1$;

STEP2 若 $\sum_{i=1}^{k-1} a_i \leq b$, 则 $x_k = 1$, 否则 $x_k = 0$. $k := k + 1$;

当 $k = n + 1$ 时,停止;否则,重复 STEP2.

计算结束时, $(x_1, x_2, \dots, x_n)$ 即为贪婪算法所得解. 这种算法思想是单位体积价值较大的物品先装包,非常直观,也容易操作.

例 10-16 简单的邻域搜索(local search)算法

给定组合优化问题是最小化目标函数,假设其邻域结构已确定. 设 S 为解集合, f 是 S

上的目标函数, N 为邻域结构, 算法如下:

STEP1 任选一个初始解 $s_0 \in S$;

STEP2 在 $N(s_0)$ 中按某一规则选一 s ; 若 $f(s) < f(s_0)$, 则 $s_0 := s$;

否则 $N(s_0) := N(s_0) \setminus \{s_0\}$; 若 $N(s_0) = \emptyset$, 停止; 否则, 重复 STEP2.

简单的领域搜索从任何一点出发, 达到一个局部最优值点. 从算法中可以看出, 算法停止时得到点的性质依赖算法初始解的选取、邻域的结构和邻域选点的规则. 一个直观的看法是, 只要选好初始点, 就一定可以求得最优解. 对 NP-hard 的组合最优化问题, 确定这样的初始点是非常困难的, 如非对称 TSP 问题, 若固定一个城市为起始点, 共有 $(n-1)!$ 个解, 也就是有 $(n-1)!$ 个初始点. 如何选初始点和如何跳出局部最优值点以达最优点是本书后续部分的一个主要内容.

启发式算法能够迅速发展是因为它有以下长处:

(1) 有些难的组合优化问题可能还没有找到最优算法, 即使找到最优算法, 由算法复杂性理论, 得知它们的计算时间是无法接受或不实际的.

(2) 一些启发式算法可以用在最优算法中, 如在分支定界算法中, 可以用启发式算法估界.

(3) 简单易行, 比较直观, 易被使用者接受.

(4) 速度快, 在适时管理或控制中非常重要.

(5) 多数情况下程序简单, 因此易于修改.

虽说有诸多好处, 但它有其短处, 这些不足往往成为争论的焦点.

(1) 不能保证求得最优解.

(2) 表现不稳定. 启发式算法在同一问题的不同实例计算中会有不同的效果. 有些解很好, 而有些则很差. 在实际应用中, 这种不稳定性造成计算结果不可信.

(3) 算法的好坏依赖于实际问题、经验和设计者的技术, 这一点很难总结规律, 同时使不同算法之间难以比较.

10.4.2 启发式算法的分类

本节对启发式算法进行简单的分类.

1. 一步算法

该算法的特点是, 不在两个可行解之间选择, 在未终止的迭代中, 有可能不是一个可行解, 算法结束时得到一个可行解. 一步算法的一个典型例子是例 10-15 给出的背包问题的贪婪算法. 每一步迭代选一物品入包, 直到无法再装. 该算法没有两个可行解之间比较选择, 算法结束时得到一可行解.

2. 改进算法

改进算法的迭代过程是从一个可行解到另一个可行解, 通常通过两个解的比较而选择好的解, 进而作为新的起点进行新的迭代, 直到满足一定的要求为止. 因此, 也可以称之为迭代算法. 如例 10-16 给出的局部搜索算法.

3. 数学规划算法

数学规划算法主要指用线性规划的方法求解组合优化问题,其中包括一些启发式规则.在这一类方法中,典型的是线性规划及对偶理论在网络流中的应用,产生标号算法等一系列最优算法.

4. 解空间松弛算法

这一类方法是线性规划松弛法,比如将整数线性规划问题(IP)松弛为一般线性规划问题(LP).LP是多项式时间可解问题,先解LP,得到IP目标值的一个下界,再通过取整过程得到IP的可行解.另一类方法是拉格朗日(Lagrange)松弛法,参见参考文献[17].

5. 现代优化算法

现代优化算法是20世纪80年代初兴起的启发式算法.这些算法包括禁忌搜索(Tabu Search)、模拟退火(Simulated Annealing)、遗传算法(Genetic Algorithms)、人工神经网络(Neural Networks),它们主要用于解决大量的实际应用问题.目前,这些算法在理论和实际应用方面都得到了较大的发展.无论这些算法是怎样产生的,它们有一个共同的目标——求NP-hard组合优化问题的全局最优解.虽说有这样的目标,但NP-hard理论限制它们只能以启发式的算法去求解实际问题.本书第三部分将介绍模拟退火、遗传算法、人工神经网络等优化方法.

10.4.3 启发式算法的性能分析

虽说启发式算法有诸多优点,但它的一个缺陷是无法保证得到最优解,于是,对算法的评价显得尤为重要.一个好的启发式算法可以使其解同最优解尽可能地接近,同时保证有较好的稳定性.评价启发式算法的性能有不同的方法,主要分为对算法计算复杂性的分析和对算法计算效能的分析.下面仅简单介绍常用的方法.

1. 最坏情形分析

最坏情形分析(Worst Case Analysis)可以考虑计算复杂性和计算解的效果两个方面.最坏情形计算复杂性分析关注算法基本运算总次数同实例计算机二进制输入长度之间的关系,从最坏实例的角度来研究算法的计算时间复杂性.这一部分内容已在10.2节讨论过,在这里不再讨论.下面通过一个例子来了解对一些比较简单的启发式算法是如何估计计算时间的复杂性.

例 10-17 估计例 10-15 贪婪算法的计算时间复杂性.

它的STEP1需要 n 个除法和将 n 个比值 $\{c_i/a_i, i=1,2,\dots,n\}$ 从大到小排序. STEP2中的最多需要 $k-1$ 个乘法、 k 个加法、一个比较和一个赋值($x_k=1$,等价于一个加法),全部循环最多用 $n(n+1)+2n$.考虑每个循环和STEP1的所有基本运算次数,该算法的计算时间复杂性为 $O(n^2)$,对0-1背包问题的任何实例,这个估计都是适用的,因而这样的估计是从最坏情形分析得到的.

2. 概率分析

最坏情形分析是以最坏的实例来评价一个算法或其解,这样免不了只因一个实例而影响对一个算法或其解的总体评价.从另一个方面讲,应该从总体来评价算法,概率方法则是从理论上考虑的.对一个算法同样可以从算法的计算时间复杂性和计算解的效果两个方面进行概率分析.无论进行哪一个方面的分析,都假设实例的数据服从一定的概率分布,在这

个数据概率分布的假设下,研究其算法或解的平均效果.

概率方法在评价算法方面的一个成功应用是对线性规划单纯形法的评价. Klee 和 Minty 在参考文献[15]中证明了线性规划的单纯形法不是多项式时间的,其构造的实例为 10.2 节的例 10-7.

概率分析方法是一种理论分析方法,它需要对问题本身有较深入的理解,并且掌握概率模型的建立和概率理论. 最坏情形分析和概率分析方法的共同特点是,用理论方法分析算法同最优解之间的误差界,要求有较强的数学基础.

3. 大规模计算分析

前面两种分析方法都是理论分析方法,要求有很强的数学基础和推演能力. 正因为如此,目前研究者只对一些特殊和简单的问题采用上面两种理论分析方法. 实际中大量的组合优化问题是采用大规模计算分析方法. 简单地说,大规模计算分析就是通过大量的实例计算,评价算法的计算效果. 算法的计算效果分成两个方面:一方面是算法的计算复杂性,它的效果通过计算机的中央处理器(CPU)计算时间表现;另一个方面是计算解的性能,它通过计算停止时输出的解表现.

大规模计算分析可对一个算法进行评价. 对一个算法进行评价时,它的计算时间效果往往通过目前的计算机设备能否承受、用户能否接受现有的计算时间来衡量. 对它的计算解进行评价时,一个简单的要求是用户是否满意,更深一步需要知道问题的最优解或问题的一个下界(假设目标为最小),这时,可以通过数据的计算比较一个算法的计算效果.

大规模计算分析可对多个算法进行评价,比较分析不同算法的效果. 通过大量数据的计算,根据各个算法的计算结果,采用简单或统计的方法比较不同算法的性能. 这种比较不需要已知问题的最优解或上下界.

10.5 小结与注记

计算复杂性理论是组合最优化的基础,只有了解所研究问题的复杂性才可能有针对性地设计算法,才能提高工作效率,起到事半功倍的作用. 比如,对 NP-hard 问题,我们不得不用启发式算法,而对一个多项式时间可解的问题,也用启发式算法,势必造成解的效果较差或计算时间的浪费.

另外,对启发式算法的评价,最坏情况分析和概率分析一般都需要较深的数学知识,但在以后的各章中还是尽可能加以介绍,这也是作为数学教材应该力争去做的. 对于数值计算评价方法,虽因它具有简单、易行、利于理解和较好的说服力等原因,得到实际应用者的广泛使用,但以后各章中不作重点介绍.

注记:本章主要取材于参考文献[14]. 限于篇幅,这里未能给出多项式归约的例子,感兴趣的读者可参见参考文献[14]中给出的适定问题多项式归约为三精确覆盖的例子. 另外,也没有给出属于 NP-hard 但不属于 NPC 的例子. 对于计算复杂性的更多讨论,可参见专著[19]. 安排这一章内容,是将它作为以后各章内容的导言,使读者对计算复杂性有大概的了解,并了解到以后各章介绍的启发式算法,是目前为止求解 NP-hard 的比较有效的方法. 然而,对于启发式算法,由本章介绍的优点和缺点看到,它与前几章介绍的经典算法不同,不是简单地套用求解公式,就可一蹴而就,得到问题的解的. 以后会看到,每种启发式算

法在具体运用中都要确定一些参数,对不同的问题,其求解技术实现也有所不同.这就要求应用者对所要求解的问题有较深入的理解,才能得到良好的效果.对于启发式算法的介绍,应注重三点,一是算法的由来和基本思想,二是算法的基本步骤,三是算法的收敛性分析.另外,还介绍具体实现的技术问题,希望读者从这几方面理解和掌握这些方法.

习 题

- 10-1 举例说明什么是组合优化问题并以此说明问题与实例的区别.
- 10-2 试证三精确覆盖属于 NP.
- 10-3 试证背包判定问题属于 NP.

第 11 章 模拟退火算法

模拟退火算法(Simulated Annealing,简称 SA)是一种启发式算法,它将局部搜索算法扩展为全局搜索算法,其基本思想是由 Metropolis 等(1953)在用 Monte Carlo 方法迭代求解统计力学方程时提出的一种随机寻优算法,因该算法的计算步骤类似于固体物质的退火过程,被称为模拟退火算法. Kirkpatrick 等(1983)注意到固体物质的退火过程与一般组合优化(Combinatorial Optimization)问题的相似性,将该种随机寻优算法成功运用于一般组合优化问题的求解,使之成为一种通用的全局优化算法. 本章将从算法的物理背景、优化流程、收敛性及实现技术等对模拟退火算法进行介绍,并扼要介绍改进的 SA 算法及该算法的理论研究和成功算例的参考文献.

11.1 物理退火过程与 SA 算法的马氏链描述

11.1.1 物理退火过程与 Metropolis 准则

将固体物质加热至其熔点,然后以某种退温方式进行冷却,以得到欲求的物质的固体结构性质,这一过程称为退火. 简单而言,物理退火过程有以下三个阶段:

(1)加温阶段. 其目的是增强粒子的热运动,使其偏离原来的平衡位置. 当温度足够高时,固体将熔化为液体,从而消除系统原先可能存在的非均匀态,也使系统的能量增大.

(2)等温阶段. 在绝热环境下,使系统状态自由变化,当自由能达到最小时,系统达到平衡态.

(3)冷却阶段. 其目的是使粒子的热运动减弱并趋于有序,系统能量逐渐下降,从而得到所要的固体结构.

物理知识告诉我们,从固体物质熔化成液态开始冷却,其冷却的速度直接影响其还原成固体的结构,当降温速度足够慢时,就会得到均匀的结晶体,而快速降温则导致晶体不均匀.

固体在给定温度下达到热平衡的过程可以用 Monte Carlo 方法加以模拟,虽然方法简单,但必须大量采样才能达到比较精确的结果,因而计算量很大. 鉴于物理系统总是倾向于能量较低的状态,而热运动又妨碍它准确落到最低态的固体结构,采样时着重取那些有重要贡献的状态则可较快达到较好的模拟结果. 因此, Metropolis 等(1953)提出了重要性采样法,即每次迭代以一定的概率接受新状态. 具体而言,在温度 T ,由当前状态 i 产生新状态 j ,两者的能量分别为 E_i 和 E_j ,若 $E_j < E_i$,则接受新状态 E_j 为当前状态;否则,若概率

$$p_{ij} = \frac{1}{Z(T)} \exp \left[-\frac{E_j - E_i}{k_B T} \right] \quad (\text{详细定义见 11.1.2 节})$$

大于 $[0,1)$ 区间内的随机数则仍接受新状态 E_j 为当前状态,若不成立则保持 E_i 为当前状态. 按这种方法多次迭代,就可模拟系统在温度 T 下逐渐趋于平衡态的过程,以及系统状态的平衡分布. 同时,从 p_{ij} 的定义可以看到(详见 11.1.2 节),这种采样过程在高温下以较大

的概率接受与当前状态能量差较大的、能量高于现状态的新状态,而在低温下基本以较小的概率接受与当前状态能量差较小的、能量高于现状态的新状态,这与前述物理退火过程随温度下降的粒子热运动的情形相一致,而且当温度趋于零时,就不能接受比当前状态高的新状态. 这种接受准则统称为 Metropolis 准则,按这一准则迭代搜索来求解的计算量相对 Monte Carlo 方法显著减少.

11.1.2 物理退火过程的统计力学模型

统计力学的研究表明,在温度 T , 分子能量 $\bar{E}$ 服从波兹曼 (Boltzmann) 概率分布

$$P(\bar{E} = E(r)) = \frac{1}{Z(T)} \exp\left[-\frac{E(r)}{k_B T}\right] \quad (11-1)$$

其中, $E(r)$ 为状态 r 的能量, $k_B > 0$ 为波兹曼常数, $Z(T)$ 为概率分布的标准化因子 (记 Ω 为状态空间)

$$Z(T) = \sum_{s \in \Omega} \exp\left[-\frac{E(s)}{k_B T}\right]$$

下面通过简单讨论概率分布式 (11-1) 依状态能量 E 和温度 T 的变化趋势, 来解释退火过程.

对于任意选定的两个状态能量 E_1 和 E_2 , 设 $E_1 < E_2$, 则

$$P(\bar{E} = E_1) - P(\bar{E} = E_2) > 0, \quad \forall T > 0 \quad (11-2)$$

事实上

$$P(\bar{E} = E_1) - P(\bar{E} = E_2) = \frac{1}{Z(T)} \exp\left[-\frac{E_1}{k_B T}\right] \left[1 - \exp\left(-\frac{E_2 - E_1}{k_B T}\right)\right]$$

由于

$$\exp\left(-\frac{E_2 - E_1}{k_B T}\right) < 1, \quad \forall T > 0$$

所以, 式 (11-2) 是显然的. 式 (11-2) 说明, 在同一温度下, 能量较小的状态出现的概率较大.

式 (11-2) 还表明, 在温度不变的条件下, 分子停留在能量较小状态的概率大于停留在能量较大状态的概率. 当温度很高时, 式 (11-1) 的概率分布使得每个能量状态出现的概率基本相同, 接近平均值 $\frac{1}{|\Omega|}$, $|\Omega|$ 为状态空间 Ω 中状态的个数. 而且具有最低能量的状态出现的概率接近并超出平均值 $\frac{1}{|\Omega|}$.

另外, 由于

$$\frac{\partial P(\bar{E} = E(r))}{\partial T} = \frac{\exp\left(-\frac{E(r)}{k_B T}\right)}{Z(T) k_B T^2} \left[E(r) - \frac{\sum_{s \in \Omega} E(s) \exp\left[-\frac{E(s)}{k_B T}\right]}{Z(T)} \right] \quad (11-3)$$

如果 $r_{\min}^T$ 是 Ω 中在温度 T 下具有最低能量的状态构成的集合, 则有

$$\frac{\partial P(\bar{E} = E(r_{\min}^T))}{\partial T} < 0$$

所以, $P(\bar{E} = E(r_{\min}^T))$ 关于 T 是单调下降的, 即随温度下降, 系统处于能量最低值的可能性

增大. 并且, 利用 $Z(T)$ 的表达式, 注意到 Ω 为有限集, 有

$$P(\bar{E} = E(r_{\min}^T)) = \frac{1}{Z(T)} \exp\left[-\frac{E(r_{\min}^T)}{k_B T}\right] = \frac{1}{|\Omega_0| + R}$$

其中, Ω_0 是具有最低能量的状态集合,

$$R = \sum_{s \in \Omega, E(s) > E(r_{\min}^T)} \exp\left(-\frac{E(s) - E(r_{\min}^T)}{k_B T}\right) \rightarrow 0, \quad T \rightarrow 0$$

由此得到, 当 $T \rightarrow 0$ 时,

$$P(\bar{E} = E(r_{\min}^T)) \rightarrow \frac{1}{|\Omega_0|}, \quad T \rightarrow 0 \quad (11-4)$$

由以上讨论可得如下结论: 当温度 T 趋向 0 时, 式 11-1 决定的概率分布渐近于均匀分布 $\frac{1}{|\Omega_0|}$. 也就是说, 当温度 T 趋向 0 时, 分子停留在能量最低状态的概率趋向 1, 而分子停留在能量较高状态的概率趋向 0. 换言之, 在温度越低时, 能量越低的状态出现的概率越大. 在极限情况下, 只有能量最低的状态出现的概率不为 0, 可从下面的例子了解式 (11-1) 的变化规律.

例 11-1 简化概率分布式 (11-1) 为

$$P(x) = \frac{1}{q(t)} \exp\left(-\frac{x}{t}\right) \quad (11-5)$$

设共有四个能量值 $x = 1, 2, 3, 4$, 此处 $q(t) = \sum_{i=1}^4 \exp\left(-\frac{i}{t}\right)$, 观察 $t = 20, 5, 0.5$ 三个温度点概率分布的变化.

表 11-1 $t=20, 5, 0.5$ 三个温度点各能量状态的概率分布

	$x=1$	$x=2$	$x=3$	$x=4$
$t=20$	0.269	0.256	0.243	0.232
$t=5$	0.329	0.269	0.221	0.131
$t=0.5$	0.865	0.117	0.016	0.002

从表 11-1 可以看到, 当温度较高时 ($t=20$), 四个能量点的概率分布相差比较小, 也可以看成概率分布是均匀的. 但最低能量点 $x=1$ 出现的概率为 0.269, 超出平均值 0.25, 这接近于分子的随机游动. 当温度下降后 ($t=5$), 能量点 $x=4$ 出现的概率变得比较小了, 而当 $t=0.5$ 时, 能量点 $x=1$ 出现的概率达 0.865, 其他三个能量点出现的概率都很小, 合起来为 0.135. 另外, 从这个表中也可以看到, 非最低能量点 $x=2$ 出现的概率在三个温度点 (0.5, 5, 20) 上有一个上升和下降的过程, 在 $t=20, 5$ 时出现的概率都超过平均概率值 0.25.

11.1.3 SA 算法的基本步骤

为方便将 SA 算法与一般组合优化问题的求解相类比, 不失一般性, 本章将一般组合优化问题提为

$$\begin{aligned} & \min_{x \in \Omega} f(x) \\ & \text{s. t. } g(x) \geq 0 \end{aligned}$$

其中, $f(x)$ 为目标函数, $g(x)$ 为约束方程, Ω 为定解区域.

在用 SA 算法求解一般组合优化问题时, 物理退火过程及例 11-1 中出现的“温度”是人为引进的一个参数, 习惯上, 称该参数为温度. SA 算法就是在随该参数逐步下降的过程中, 利用该参数确定的概率分布, 按 Metropolis 准则搜索全局最优解. 为理解 SA 算法, 举一个极为简单的例子.

例 11-2 设组合优化问题的目标函数 $f(x) = x^2$, 约束函数为 $g(x) = x^2 - 1$, 定解区域为 $D = \{1, \sqrt{2}, \sqrt{3}, 2\}$. 显然此问题的全局最优解为 $x = 1$.

可以尝试用 SA 算法求解此问题, 取能量概率分布如式 (11-5) 所定义. 可以用以下步骤来完成 SA 搜索.

第一步, 取初始温度 (初始参数) $t_0 = 20$, 初始解 $x_0 = \sqrt{3}$; 外循环步数 $k = 0$; 令 $x_i = x_0$, $t_k = t_0$.

第二步, 在 D 中选一个新状态 x_j , 比如 $x_j = \sqrt{2}$, 计算能量差

$$\Delta f_{ij} = f(x_j) - f(x_i) = (\sqrt{2})^2 - (\sqrt{3})^2 = -1$$

因 $\Delta f_{ij} \leq 0$, 我们接受新状态 $x_j = \sqrt{2}$ 为当前状态 x_i (即令 $x_i = \sqrt{2}$);

再在 D 中选一个新状态 x_j , 比如 $x_j = 2$, 计算能量差

$$\Delta f_{ij} = f(x_j) - f(x_i) = 2^2 - (\sqrt{2})^2 = 2$$

因 $\Delta f_{ij} > 0$, 需随机判断 (Metropolis 准则) 是否接受 $x_j = 2$ 为当前状态:

先产生 $(0, 1)$ 区间内的一个随机数, 记为 $\text{random}(0, 1)$, 再计算

$$\exp\left(-\frac{\Delta f_{ij}}{t_k}\right) = \exp\left(-\frac{2}{20}\right) = \exp\left(-\frac{1}{10}\right) \quad (11-6)$$

若 $\exp\left(-\frac{1}{10}\right) > \text{random}(0, 1)$, 则接受 $x_j = 2$ 为当前状态, 否则, 仍以原 $x_i = \sqrt{2}$ 为当前状态.

重复第二步, 直到搜到最优点 (记为 x_i) 为止 (本例中最优点为 1);

第三步, 取 $t_k = 5$, 转到第二步, 再取 $t_k = 0.5$ 转到第二步, 最终搜得最优解 $x = 1$.

值得注意的是, 在 $t_k = 20$, $t_k = 5$ 和 $t_k = 0.5$ 的三个内循环中, 对同样的搜索结果 $x_i = \sqrt{2}$, $x_j = 2$, 仿式 (11-6) 算得的值在下降, 分别为 $\exp\left(-\frac{1}{10}\right)$, $\exp\left(-\frac{2}{5}\right)$ 和 $\exp(-4)$, 即随温度 t 的下降, 接受能量较高状态 x_j 的可能性越来越小, 这与我们希望最终找到目标函数的最小值点的愿望一致. 同样, 由于在温度较高时, 接受能量较高的状态的可能性较大, 这是为了避免使搜索算法陷入局部搜索, 这也是 SA 算法基本思想的关键所在.

通过以上示例, 我们可以将组合优化问题的求解与物理退火过程相类比.

表 11-2 物理退火过程与组合优化问题求解比较表

组合优化	物理退火	组合优化	物理退火
目标函数	能量	可行解	粒子状态
设定初温	熔化过程	最优解	能量最低态
Metropolis 抽样	等温过程	控制参数下降	冷却过程

SA 算法的一般步骤为:

-
- STEP1 任选初始解 $x_0; x_i := x_0; k := 0; t_0 = t_{\max}$ (初始温度);
- STEP2 若在该温度达到内循环停止条件, 则转到 STEP3; 否则, 从邻域 $N(x_i)$ 中随机选一 x_j , 计算 $\Delta f_{ij} = f(x_j) - f(x_i)$; 若 $\Delta f_{ij} \leq 0$, 则 $x_i := x_j$, 否则若 $\exp(-\Delta f_{ij}/t_k) > \text{random}(0, 1)$, 则 $x_i := x_j$; 重复 STEP2;
- STEP3 $t_{k+1} = d(t_k); k := k + 1$; 若满足停止条件, 终止计算; 否则, 回到 STEP2.
-

以上的算法步骤包含一个内循环和一个外循环, 涉及所谓的三函数两准则等重要的技术实现环节. 内循环是 STEP2, 它表示在温度 t_k 时一些状态随机搜索, 它包括产生新状态 x_j 的新状态产生函数、新状态接受函数(通常与目标函数 $f(x)$ 有关)和抽样稳定准则(内循环停止准则). 外循环主要是 STEP3 的温度下降、迭代步数增加和停止准则, 它包括退温函数 $d(x)$ 和退火结束准则. 另外, 初始温度的选择也是影响算法优化结果的关键环节.

以上 SA 算法可直观解释为: 选定初始温度, 随着温度下降, 在给定的温度点上从一个状态出发, 按一定概率规律随机地搜索到另一个状态, 直至搜索到该温度下的能量最低状态. 当温度很低时, 由式(11-4)知, 以概率 1 搜索到能量最低状态, 即最优解.

11.1.4 SA 算法的马尔科夫(Markov)链描述

设 Ω 为所有可行解构成的集合(有限集或可列集), 称取值于 Ω 的随机变量序列

$$X = \{X(k), k \in \mathbb{Z}^+\}$$

为马尔科夫链(简称为马氏链), 如果 $\forall n \in \mathbb{Z}^+, \forall i_0, i_1, \dots, i_n, j \in \Omega$ 满足

$$\begin{aligned} P(X(n+1) = j | X(0) = i_0, X(1) = i_1, \dots, X(n) = i_n) \\ = P(X(n+1) = j | X(n) = i_n) \end{aligned}$$

并称

$$p_{ij}(n) = P(X(n+1) = j | X(n) = i)$$

为一步转移概率. 若对 $\forall n, m \in \mathbb{Z}^+$, 有 $p_{ij}(n) = p_{ij}(m)$, 则称 X 为时齐马氏链, 此时, 记

$$p_{ij}^{(n)} = P(X(n) = j | X(0) = i),$$

约定 $p_{ii}^{(0)} = 1, p_{ij}^{(0)} = 0, j \neq i$. 对 $n \geq 0$, 称 $P^{(n)} = (p_{ij}^{(n)})_{i,j \in \Omega}$ 为 n 步转移概率矩阵.

考虑 SA 算法的搜索进程, 算法从一个初始状态开始后, 每一步状态的转移都是在当前状态 i 的邻域 $N(i)$ 中随机产生新状态 j , 然后以一定的概率接受的. 可见, 接受概率仅依赖于当前状态和新状态, 并由温度加以控制. 因此, SA 算法对应了一个马氏链. 若固定每一温度 t , 算法都按马氏链的转移概率进行随机搜索, 直至得到平稳分布, 然后下降温度, 直至温度 $t=0$ 时, 得到的平稳分布就对应全局最优解, 则称这种算法为时齐算法, 它对应于求时齐马氏链的平稳分布. 若无需各温度下算法均达到平稳分布, 但温度按一定的速度下降, 则称这种算法为非时齐算法(后文中看到它对应非时齐马氏链).

在 SA 算法中, 在每一给定的温度 t 之下, 对任意 $i, j \in \Omega$, 通常定义转移概率为

$$p_{ij}(t) = \begin{cases} G_{ij}(t)A_{ij}(t) & j \neq i \\ 1 - \sum_{l=1, l \neq i}^{|\Omega|} G_{il}(t)A_{il}(t) & j = i \end{cases} \quad (11-7)$$

上式中的 $G_{ij}(t)$ 称为从 i 到 j 的产生概率, $G_{ij}(t)$ 表示在状态 i 时, j 状态被选取的概率. 一般地, j 取自 i 的一个邻域 $N(i)$ 内, 此时邻域内每个状态可等概率选取, 即

$$G_{ij}(t) = \begin{cases} \frac{1}{|N(i)|} & j \in N(i) \\ 0 & j \notin N(i) \end{cases} \quad (11-8)$$

式(11-7)中的 $A_{ij}(t)$ 称为接受概率, 它表示在状态 i 产生 j 后, 接受 j 的概率. 比如, 可用目标函数 $f(x)$ 来定义接受概率如下:

$$A_{ij}(t) = \begin{cases} 1 & f(i) \geq f(j) \\ \exp(-\Delta f_{ij}/t) & f(i) < f(j) \end{cases} \quad (11-9)$$

$G(t) = (G_{ij}(t))_{i,j \in \Omega}$, $A(t) = (A_{ij}(t))_{i,j \in \Omega}$, $P(t) = (p_{ij}(t))_{i,j \in \Omega}$, 分别称为产生矩阵、接受矩阵和一步转移概率矩阵, 并称 $P(t)$ 所确定的马氏链为 SA 算法所对应的马氏链.

从理论上和直观上, 要使 SA 算法有效, 算法所对应的马氏链应满足下列条件:

(1) 各状态之间的互通性. 任何两个状态可以相互到达, 否则就无法保证搜寻到全局最优解.

(2) 渐近不依赖于出发状态. 随着转移步数的增加, 过程到达任何状态的可能性不依赖于初始出发的状态, 这样才能保证从任何初始解出发搜索到全局最优解.

(3) 平稳分布的存在唯一性. 在温度不变或温度趋近于 0 时, 马氏链都存在唯一的平稳分布, 此时平稳分布所集中的状态都是组合优化问题的最优解.

(4) 收敛性. 当温度趋近于 0 时, 各个温度水平下所得到的平稳分布有唯一的极限分布存在.

这些问题都归结为马氏链的遍历性(不可约性、周期性、常返性)和极限分布(下文中看到, 当马氏链为不可约、正常返、非周期时, 极限分布就是平稳分布)等问题的讨论, 且这些讨论的关键是对转移概率矩阵 $P(t)$ 附加某种特殊要求. 11.2 节将简单介绍这方面的知识. 并讨论如何定义前述的产生矩阵 $G(t)$ 、接受矩阵 $A(t)$, 使得一步转移概率矩阵 $P(t)$ 达到这些要求.

11.2 马尔科夫链简介

本节简单介绍时齐马氏链的有关概念和结果. 沿用上节马氏链有关定义和记号, 设

$$X = \{X(k), k \in \mathbb{Z}^+\}$$

为时齐马氏链, 它的状态空间为 Ω , 以 $P = (p_{ij})_{i,j \in \Omega}$ 为一步转移概率矩阵. 我们先给出两个重要的引理.

引理 11-1 (Chapman - Kolmogolov 方程)

$$p_{ij}^{(n+m)} = \sum_{k \in \Omega} p_{ik}^{(n)} p_{kj}^{(m)}, \quad \forall n, m \in \mathbb{Z}^+ \quad (i, j \in \Omega) \quad (11-10)$$

证 由初等概率论中的全概率公式、条件概率的定义和过程的马氏性和时齐性, 有

$$\begin{aligned} p_{ij}^{(n+m)} &= P(X(n+m)=j | X(0)=i) \\ &= P(X(n+m)=j, \bigcup_{k \in \Omega} \{X(n)=k\} | X(0)=i) \end{aligned}$$

$$\begin{aligned}
&= \sum_{k \in \Omega} P(X(n+m)=j, X(n)=k | X(0)=i) \quad (\text{全概率公式}) \\
&= \sum_{k \in \Omega} P(X(n+m)=j | X(n)=k, X(0)=i) \cdot P(X(n)=k | X(0)=i) \\
&= \sum_{k \in \Omega} P(X(n+m)=j | X(n)=k) \cdot P(X(n)=k | X(0)=i) \quad (\text{马氏性}) \\
&= \sum_{k \in \Omega} P(X(m)=j | X(0)=k) \cdot P(X(n)=k | X(0)=i) \quad (\text{时齐性}) \\
&= \sum_{k \in \Omega} p_{ik}^{(n)} p_{kj}^{(m)} \quad \square
\end{aligned}$$

记 $f_{ij}^{(n)} = P(X(n)=j, X(k) \neq j, 0 < k < n | X(0)=i)$, 则有

引理 11-2

$$p_{ij}^{(n)} = \sum_{k=1}^n f_{ij}^{(k)} p_{ij}^{(n-k)}, \quad \forall n \in \mathbb{Z}^+ \quad (i, j \in \Omega) \quad (11-11)$$

证 记 $T_j = \min\{n | X(n)=j, n>0\}$, 它表示过程首次到达状态 j 时间, 则 $\forall i, j \in \Omega$, $\forall n \in \mathbb{Z}^+$ 有

$$\begin{aligned}
&p_{ij}^{(n)} \\
&= P(X(n)=j | X(0)=i) \\
&= P(X(n)=j, T_j \leq n | X(0)=i) \\
&= \sum_{k=1}^n P(X(n)=j, T_j = k | X(0)=i) \quad (\text{全概率公式}) \\
&= \sum_{k=1}^n P(X(n)=j | T_j = k, X(0)=i) \cdot P(T_j = k | X(0)=i) \\
&= \sum_{k=1}^n P(T_j = k | X(0)=i) \cdot P(X(n)=j | X(k)=j, \\
&\quad X(k-1) \neq j, X(1) \neq j, X(0)=i) \\
&= \sum_{k=1}^n P(T_j = k | X(0)=i) \cdot P(X(n)=j | X(k)=j) \quad (\text{马氏性}) \\
&= \sum_{k=1}^n f_{ij}^{(k)} p_{ij}^{(n-k)} \quad (\text{时齐性}) \quad \square
\end{aligned}$$

如果存在 $n \geq 0$, 使得 $p_{ij}^{(n)} > 0$, 称状态 i 可达状态 j (记为 $i \rightarrow j$); 如果 $i \rightarrow j$, 且 $j \rightarrow i$, 称状态 i 与状态 j 互通 (记为 $i \leftrightarrow j$).

命题 11-1 若 $i \rightarrow j, j \rightarrow k$, 则 $i \rightarrow k$.

证 由 $i \rightarrow j$, 存在 $n \geq 0$, 使得 $p_{ij}^{(n)} > 0$; 而由 $j \rightarrow k$, 存在 $m \geq 0$, 使得 $p_{jk}^{(m)} > 0$. 从而, 由式 (11-10) 有

$$p_{ik}^{(n+m)} = \sum_{l \in \Omega} p_{il}^{(n)} p_{lk}^{(m)} \geq p_{ij}^{(n)} p_{jk}^{(m)} > 0 \quad \square$$

记 $f_{ij} = \sum_{n=1}^{\infty} f_{ij}^{(n)}$, 它表示从状态 i 出发, 经有限步转移到达状态 j 的概率.

命题 11-2 $f_{ij} > 0$ 的充分必要条件是 $i \rightarrow j$.

证 设 $i \rightarrow j$, 即存在 $n \geq 0$, 使得 $p_{ij}^{(n)} > 0$; 而由式(11-11)有 $p_{ij}^{(n)} = \sum_{k=1}^n f_{ij}^{(k)} p_{jj}^{(n-k)} > 0$, 从而至少有一个 l , 使得 $f_{ij}^{(l)} > 0$, 亦即 $f_{ij} > 0$.

反之, 设 $f_{ij} > 0$, 则存在 $n \geq 0$, 使得 $f_{ij}^{(n)} > 0$, 从而由式(11-11)有

$$p_{ij}^{(n)} \geq f_{ij}^{(n)} p_{jj}^{(0)} > 0 \quad \square$$

如果 $f_{ii} = 1$, 称状态 i 为常返的; 如果 $f_{ii} < 1$ 称, 状态 i 为非常返的.

记 $\nu(i) = \sum_{n=1}^{\infty} I_i(X(n))$, 其中, 如果 $y = x$, $I_x(y) = 1$; 否则, $I_x(y) = 0$. $\nu(i)$ 表示过程到达状态 i 的次数. 记 $g(i, j) = P(\nu(j) = \infty | X(0) = i)$. 下面的命题揭示了常返态与非常返态的本质区别.

命题 11-3

$$g(i, i) = \begin{cases} 1 & f_{ii} = 1 \\ 0 & f_{ii} < 1 \end{cases}$$

证 我们先证明

$$P(\nu(j) \geq n | X(0) = i) = f_{ij} [f_{jj}]^{n-1} \quad (11-12)$$

事实上, 当 $n=1$ 时, $P(\nu(j) \geq 1 | X(0) = i) = P(T_j < \infty | X(0) = i) = f_{ij}$. 当 $n=2$ 时,

$$P(\nu(j) \geq 2 | X(0) = i) = P(T_j < \infty | X(0) = i) P(T_j \geq 1 | X(0) = j) = f_{ij} f_{jj}$$

归纳地, 得到式(11-12).

于是, 由概率的下连续性, 有

$$g(i, i) = P(\nu(i) = \infty | X(0) = i) = \lim_{n \rightarrow \infty} P(\nu(i) \geq n | X(0) = i) = \lim_{n \rightarrow \infty} [f_{ii}]^n \quad \square$$

命题 11-4 状态 i 常返的充分必要条件是 $\sum_{n=1}^{\infty} p_{ii}^{(n)} = \infty$.

证 由式(11-12)有

$$\sum_{n=1}^{\infty} p_{ii}^{(n)} z^n = \sum_{n=1}^{\infty} \left(\sum_{k=1}^n f_{ii}^{(k)} p_{ii}^{(n-k)} \right) z^n$$

令 $P(z) = \sum_{n=0}^{\infty} p_{ii}^{(n)} z^n$, $|z| < 1$, $F(z) = \sum_{n=1}^{\infty} f_{ii}^{(n)} z^n$, $|z| \leq 1$ 则有

$$P(z) - 1 = P(z)F(z), \quad |z| < 1$$

即

$$P(z) = \frac{1}{1 - F(z)}, \quad |z| < 1$$

上式两端取极限($z \rightarrow 1$), 可以看出, $\sum_{n=1}^{\infty} p_{ii}^{(n)} = \infty$ 的充分必要条件是 $F(1) = 1$, 但

$$F(1) = \sum_{n=1}^{\infty} f_{ii}^{(n)} = f_{ii} \quad \square$$

记 $\mu_i = \sum_{n=1}^{\infty} n f_{ii}^{(n)}$, 它表示过程返回状态 i 所需步数的平均值, 简称为平均返回时间. 如果 $\mu_i < \infty$, 称常返状态 i 正常返的, 否则, 称为零常返的.

记 $d(i) = \text{GCD}\{n > 0 | p_{ii}^{(n)} > 0\}$, 它是过程从状态 i 出发, 可达状态 i 所需步数的最大公

约数(Greatest Common Divisor). 如果 $d(i) > 1$, 称状态 i 为周期的(周期为 $d(i)$), 否则, 称状态 i 为非周期的.

注 若 i 是周期为 d 的周期状态, 则只有 n 是 d 的倍数时, 才有 $p_{ii}^{(n)} > 0$.

下面的命题说明常返性和周期性是互通状态共有的性质.

命题 11-5 设 $i \leftrightarrow j$, 则

(1) i, j 同为非常返的或同为常返的(或同为正常返的);

(2) i, j 同为非周期的或同为周期的且周期相同.

证 先证明(1). 由 $i \rightarrow j$, 存在 $n \geq 0$, 使得 $p_{ij}^{(n)} > 0$; 而由 $j \rightarrow i$, 存在 m , 使得 $p_{ji}^{(m)} > 0$. 从而, 由式(11-10)有

$$p_{ii}^{(n+k+m)} = \sum_{r \in \Omega} \sum_{s \in \Omega} p_{ir}^{(n)} p_{rs}^{(k)} p_{si}^{(m)} \geq p_{ij}^{(n)} p_{jj}^{(k)} p_{ji}^{(m)} \quad (11-13)$$

从而

$$\sum_{k=1}^{\infty} p_{ii}^{(n+k+m)} \geq p_{ij}^{(n)} p_{ji}^{(m)} \sum_{k=1}^{\infty} p_{jj}^{(k)}$$

若状态 j 常返, 由命题 11-4, 上式右端的级数发散, 从而(注意到 $p_{ij}^{(n)} > 0, p_{ji}^{(m)} > 0$) 左端的级数发散, 即状态 i 常返; 反之, 若状态 i 非常返, 由命题 11-4, 上式左端的级数收敛, 从而(同样注意到 $p_{ij}^{(n)} > 0, p_{ji}^{(m)} > 0$) 右端的级数收敛, 即状态 j 非常返. 这说明 i, j 同为非常返的或同为常返的(还可以证明 i, j 同为正常返的, 此处从略).

下面证明(2). 设 $d(i) = s, d(j) = t$, 在式(11-13)中令 $k = 0$ 有

$$p_{ii}^{(n+m)} \geq p_{ij}^{(n)} p_{ji}^{(m)}$$

这说明 $n+m$ 是 s 的倍数. 再由式(11-13)知, 若 k 是 t 的倍数, 则 $n+k+m$ 也是 s 的倍数, 从而 k 也是 s 的倍数, 即对任何 $k \in \mathbb{Z}^+$, 若它是 t 的倍数, 就一定是 s 的倍数, 这说明 $t \geq s$. 类似可证, $s \geq t$. $\square$

在讨论马氏链的极限分布(遍历理论)时, 还有两个重要的概念, 即不可约性和平稳分布.

设 $C \subset \Omega$, 称 C 为闭集, 如果 $\forall i \in C, j \notin C$, 有 $p_{ij} = 0$. 它表示从状态转移角度看, C 是一个封闭的集合, 如果除整个状态空间 Ω 外, 没有别的闭集, C 中任何状态与其外的任何状态都不可达, 称马氏链是不可约的.

注 所有状态之间两两互通的马氏链必是不可约链. 另外, 若存在 $n > 0$, 使得 $p_{ij}^{(n)} > 0, \forall i, j \in \Omega$, 则必是不可约链.

如果对 X 的一步转移概率矩阵 $P = (p_{ij})$ 满足

$$\nu_j = \sum_{i \in \Omega} \nu_i p_{ij}, \quad \forall j \in \Omega$$

称概率分布 $\{\nu_i, i \in \Omega\}$ (即 $\nu_i \geq 0, i \in \Omega$, 且 $\sum_{i \in \Omega} \nu_i = 1$) 为马氏链 X 的平稳分布.

以下给出两个重要定理, 其证明此处略去, 对证明有兴趣的读者可参见一般随机过程的教科书.

定理 11-1 有限状态时齐马氏链必有正常返态.

注 由命题 11-5 可知, 不可约的有限状态时齐马氏链的每个状态都是正常返的.

定理 11-2 非周期不可约马氏链是正常返的充分必要条件是存在唯一平稳分布

$\{\nu_i, i \in \Omega\}$, 此时

$$\nu_j = \lim_{n \rightarrow \infty} p_{ij}^{(n)} = \frac{1}{\mu_j} > 0, \quad \forall j \in \Omega$$

其中 μ_j 为前面定义的平均返回时间.

注 若时齐马氏链是不可约正常返非周期的, 则可以证明对绝对概率 $p_j^{(n)} = P(X(n) = j)$, 也有

$$\nu_j = \lim_{n \rightarrow \infty} p_j^{(n)} = \frac{1}{\mu_j} > 0, \quad \forall j \in \Omega$$

所以称这里的 $\{\nu_i, i \in \Omega\}$ 为极限分布, 也称平稳分布为马氏链的不变分布, 它还是一步转移概率矩阵 P 的特征值为 1 的左特征向量. 另外, 称不可约正常返非周期链为遍历链.

SA 算法的时齐算法和非时齐算法的收敛性可分别归结为时齐和非时齐马氏链的平稳分布的存在唯一性.

为保证时齐算法的收敛性, 需要完成如下工作:

(1) 在每一个给定的温度 t , 构造一步转移概率矩阵 $P(t) = (p_{ij}(t))$ (见式(11-7)), 使之满足一定的条件, 比如使时齐马氏链满足定理 11-2 的条件, 从而得到平稳分布(也为极限分布)

$$\nu_j(t) = \lim_{n \rightarrow \infty} p_{ij}^{(n)}(t) = \lim_{n \rightarrow \infty} P(X(n, t) = j | X(0, t) = i) = \frac{1}{\mu_j(t)} > 0$$

其中 $X(n, t)$, $\nu_j(t)$, $\mu_j(t)$ 分别表示在温度 t 时的时齐马氏链第 n 步的随机变量、平稳分布在状态 j 上的取值以及状态 j 的平均返回时间.

(2) 给出平稳分布 $\nu_j(t)$, 当温度逐步下降时, 使 $\lim_{t \rightarrow 0} \nu_j(t) = \pi_j$ 存在的条件.

(3) 给出某种条件以使平稳分布的极限具有全局最优性条件

$$\pi_j = \begin{cases} \frac{1}{|\Omega_{\text{opt}}|} & j \in \Omega_{\text{opt}} \\ 0 & j \notin \Omega_{\text{opt}} \end{cases}$$

其中 Ω_{opt} 为最优状态集合, 即马氏链极限分布集中于最优解集上, 且均匀分布.

总之, 就是要构造转移概率矩阵和寻求温度下降规律等, 保证

$$\lim_{t \rightarrow 0} \left\{ \lim_{n \rightarrow \infty} P(X(n, t) \in \Omega_{\text{opt}}) \right\} = 1$$

对于非时齐算法, 因为迭代搜索的每一步温度可能不同, 为保证随温度下降时最终得到全局最优解, 要对温度的下降速率和式(11-7)中的 $A(t)$, $G(t)$ 随温度变化的规则加一定条件, 详细叙述见 11.4 节.

11.3 时齐算法的收敛性

本节讨论如何定义前述的产生矩阵 $G(t)$ 、接受矩阵 $A(t)$, 使得一步转移概率矩阵 $P(t)$ 达到上节提到的使马氏链遍历的要求. 由于组合优化问题的状态空间是有限的, 由定理 11-1 和定理 11-2, 为保证平稳分布存在唯一, 只要所对应的马氏链是不可约和非周期就够了.

定理 11-3 设时齐算法的马氏链的转移概率矩阵 $P(t)$ 中接受矩阵 $A(t)$ 和产生均阵

$G(t)$ 见式(11-7)满足

$$(1) A_{ij}(t) > 0, \forall t \geq 0 \quad i, j \in \Omega;$$

$$(2) \forall t \geq 0, i, j \in \Omega \text{ 存在 } q \geq 1, l_1, l_2, \dots, l_q \in \Omega, l_0 = i, l_q = j, \text{ 使得}$$

$$G_{l_k l_{k+1}}(t) > 0 \quad (k = 0, 1, \dots, q-1)$$

则该马氏链是不可约的。

证 当 t 给定时, 由式(11-7)确定的马氏链是时齐的, 其 n 步转移概率矩阵记为 $P^{(n)} = (p_{ij}^{(n)})$, 从而由式(11-10)有

$$\begin{aligned} p_{ij}^{(q)} &\geq p_{i l_1} p_{l_1 l_2} \cdots p_{l_{q-1} j} \\ &= A_{i l_1}(t) G_{i l_1}(t) A_{l_1 l_2}(t) G_{l_1 l_2}(t) \cdots A_{l_{q-1} j}(t) G_{l_{q-1} j}(t) > 0, \quad \forall i, j \in \Omega \end{aligned}$$

这说明马氏链的所有状态是互通的, 从而是不可约的。□

注 定理的条件(1)要求对每个当前状态 i , 状态空间中的每个状态都是可接受的; 而条件(2)要求对任何两个状态, 都可产生一条转移路径来连接它们。

定理 11-4 设接受矩阵 $A(t)$ 和产生矩阵 $G(t)$ 满足定理 11-3 的条件, 并设对给定的 $t > 0$, 存在 $i \neq j \in \Omega$ 使得 $A_{ij}(t) < 1, G_{ij}(t) > 0$, 则该马氏链是非周期的。

证 首先, 由 $A(t)$ 和 $G(t)$ 满足定理 11-3 的条件知, 该马氏链是不可约的。

另外, 由温度 t 时的一步转移概率 $p_{ij}(t)$ 的定义(见式(11-7))有

$$\begin{aligned} p_{ii}(t) &= 1 - \sum_{l=1, l \neq i}^{|\Omega|} G_{il}(t) A_{il}(t) \\ &= 1 - G_{ij}(t) A_{ij}(t) - \sum_{l=1, l \neq i, j}^{|\Omega|} G_{il}(t) A_{il}(t) \\ &> 1 - G_{ij}(t) - \sum_{l=1, l \neq i, j}^{|\Omega|} G_{il}(t) \\ &= 1 - \sum_{l=1, l \neq i}^{|\Omega|} G_{il}(t) \\ &= G_{ii}(t) \geq 0 \end{aligned}$$

这说明状态 i 是非周期的。进而, 由命题 11-5 知, 该马氏链是非周期的。□

定理 11-3 和定理 11-4, 给出了平稳分布存在唯一的一个充分条件, 下面讨论如何求出这个平稳分布。

定理 11-5 设接受矩阵 $A(t)$ 和产生矩阵 $G(t)$ 满足

$$(1) G(t) \text{ 与 } t \text{ 无关};$$

$$(2) G_{ij} = G_{ji}, \forall i, j \in \Omega, \text{ 且 } \forall i, j \in \Omega, \text{ 存在 } q \geq 1 \text{ 和 } l_1, l_2, \dots, l_q \in \Omega, l_0 = i, l_q = j, \text{ 使得}$$

$$G_{l_k l_{k+1}} > 0 \quad (k = 0, 1, \dots, q-1)$$

$$(3) \forall i, j, k \in \Omega, \text{ 若 } f(i) \leq f(j) \leq f(k), \text{ 则 } A_{ik}(t) = A_{ij}(t) A_{jk}(t);$$

$$(4) \forall i, j \in \Omega, \forall t > 0, \text{ 若 } f(i) \geq f(j), \text{ 则 } A_{ij}(t) = 1;$$

$$(5) \forall i, j \in \Omega, \forall t > 0, \text{ 若 } f(i) < f(j), \text{ 则 } 0 < A_{ij}(t) < 1.$$

则时齐 SA 算法对应的马氏链在温度 t 时有唯一的平稳分布

$$\nu(t) = (\nu_1(t), \nu_1(t), \dots, \nu_{|\Omega|}(t))$$

且

$$\nu_i(t) = \frac{A_{i_0 i}(t)}{\sum_{j \in \Omega} A_{i_0 j}(t)} \quad (i \in \Omega) \quad (11-14)$$

其中 $i_0 \in \Omega_{\text{opt}}$.

证 若 $f(i) = C, \forall i \in \Omega$, 即目标函数取常值, 则任何状态都是最优解, 定理的结果不用证明.

对于目标函数不取同一值时, 定理的证明可分为两个方面, 一是说明算法的马氏链存在唯一的平稳分布, 这只需说明马氏链是不可约非周期的; 另一方面是直接验证 $\nu(t)$ 是平稳分布.

由条件(4)、(5)知 $A(t)$ 满足定理 11-3 的条件(1), 而由条件(1)、(2)知 $G(t)$ 满足定理 11-3 的条件(2), 从而马氏链不可约; 再由条件(2)、(5)和定理 11-4 知马氏链是非周期的; 加之状态空间为有限集, 再由定理 11-2 知存在唯一的平稳分布.

下面验证式(11-7)给出的分布 $\nu(t)$ 是平稳分布.

记 $K = \sum_{j \in \Omega} A_{i_0 j}(t)$, 由式(11-7)中 $P(t)$ 的定义, 有

$$\begin{aligned} & \sum_{j \in \Omega} \nu_j(t) p_{ji}(t) \\ &= \sum_{j \in \Omega} \frac{A_{i_0 j}(t)}{K} G_{ji} A_{ji}(t) \\ &= \sum_{j \neq i, f(j) \leq f(i)} \frac{1}{K} A_{i_0 j}(t) G_{ji} A_{ji}(t) + \sum_{j \neq i, f(j) > f(i)} \frac{1}{K} A_{i_0 j}(t) G_{ji} A_{ji}(t) + \nu_i(t) p_{ii}(t) \\ &= \sum_{j \neq i, f(j) \leq f(i)} \frac{1}{K} A_{i_0 i}(t) G_{ij} + \sum_{j \neq i, f(j) > f(i)} \frac{1}{K} A_{i_0 j}(t) G_{ji} + \nu_i(t) p_{ii}(t) \\ &= \nu_i(t) \sum_{j \neq i, f(j) \leq f(i)} G_{ij} + \sum_{j \neq i, f(j) > f(i)} \nu_j(t) G_{ji} + \nu_i(t) p_{ii}(t) \end{aligned}$$

而

$$\begin{aligned} & \nu_i(t) p_{ii}(t) \\ &= \nu_i(t) \left(1 - \sum_{j \neq i} A_{ij}(t) G_{ij} \right) \\ &= \nu_i(t) \left(1 - \sum_{j \neq i, f(j) \leq f(i)} A_{ij}(t) G_{ij} - \sum_{j \neq i, f(j) > f(i)} A_{ij}(t) G_{ij} \right) \\ &= \nu_i(t) - \nu_i(t) \sum_{j \neq i, f(j) \leq f(i)} A_{ij}(t) G_{ij} - \sum_{j \neq i, f(j) > f(i)} \frac{1}{K} A_{i_0 i}(t) A_{ij}(t) G_{ij} \\ &= \nu_i(t) - \nu_i(t) \sum_{j \neq i, f(j) \leq f(i)} A_{ij}(t) G_{ij} - \sum_{j \neq i, f(j) > f(i)} \frac{1}{K} A_{i_0 j}(t) G_{ij} \\ &= \nu_i(t) - \nu_i(t) \sum_{j \neq i, f(j) \leq f(i)} A_{ij}(t) G_{ij} - \sum_{j \neq i, f(j) > f(i)} \nu_j(t) G_{ij} \end{aligned}$$

于是

$$\nu_i(t) = \sum_{k \in \Omega} \nu_k(t) p_{ki}(t) \quad (i \in \Omega) \quad \square$$

例 11-3 取接受概率 $A(t)$ 如式(11-9)定义, 则它满足定理 11-5 的条件(3), (4), (5); 另外, 如果任何一个状态的邻域中邻居的个数相同(记为 L), 且任何两个状态或者互

为邻居或者互不为邻居,我们可定义如下的产生概率

$$G_{ij}(t) = \begin{cases} \frac{1}{L} & j \in N(i) \\ 0 & j \notin N(i) \end{cases}$$

则 $G(t)$ 满足定理 11-5 的条件(1),也满足(2)的 $G_{ij} = G_{ji}$. 若再在 $G(t)$ 加上某种条件(见后文定理 11-7,往往与组合优化问题的解的形式和邻域结构有关),使之满足状态之间的连通性,我们就找到了一组满足定理 11-5 的接受概率和产生概率,从而获得唯一的平稳分布.

注 从定理 11-5 的证明看出,如果只考虑时齐算法在温度 t 下的平稳分布,条件(1)是可去掉的.但条件(2)要作相应修改(G_{ij} 需改为 $G_{ij}(t)$).

定理 11-6 在 $A(t)$ 和 $G(t)$ 满足定理 11-5 的条件下,如果对满足 $f(i) < f(j)$ 的任何两个状态 i, j ,还有 $\lim_{t \rightarrow 0} A_{ij}(t) = 0$,则

$$\lim_{t \rightarrow 0} \nu_i(t) = \begin{cases} \frac{1}{|\Omega_{\text{opt}}|} & i \in \Omega_{\text{opt}} \\ 0 & j \notin \Omega_{\text{opt}} \end{cases}$$

证 由式(11-14)

$$\nu_i(t) = \frac{A_{i_0 i}(t)}{\sum_{j \in \Omega} A_{i_0 j}(t)}$$

因为 Ω 为有限集,故当 $\forall i \in \Omega_{\text{opt}}$ 时,有

$$f(i_0) < f(i) \quad (i_0 \in \Omega_{\text{opt}})$$

于是由定理的条件知

$$\lim_{t \rightarrow 0} A_{i_0 j}(t) = 0$$

而对于 $\forall i \in \Omega_{\text{opt}}$,由定理 11-5 的条件(4),有 $A_{i_0 i}(t) = 1$,故定理结论成立. $\square$

下面讨论产生矩阵 $G(t)$ 的一个替换条件,它使 SA 算法对应的马氏链为不可约非周期的,且给出平稳分布的计算公式.

定理 11-7 设 $A(t), G(t)$ 满足定理 11-5 中除(2)以外的条件,且定理 11-5 的条件(2)改为:任何两个状态 i, j 或互为邻居或不互为邻居,但状态空间具有邻域连通性,即存在 $i_0 \in N(i), j_0 \in N(j)$,使得 $i_0 \leftrightarrow j_0$,且令

$$G_{ij}(t) = \begin{cases} \frac{1}{|N(i)|} & j \in N(i) \\ 0 & j \notin N(i) \end{cases}$$

则 SA 算法对应的马氏链存在唯一的平稳分布:

$$\nu_i(t) = \frac{|N(i)| A_{i_0 i}(t)}{\sum_{j \in \Omega} |N(j)| A_{i_0 j}(t)} \quad (i \in \Omega) \quad (11-15)$$

证 与定理 11-5 的证明类似,我们只需验证转移概率保证马氏链是不可约非周期的,并验证式(11-15)给出的分布确是平稳分布.

首先,由满足邻域连通性和定理 11-5 的条件(4)和(5),由定理 11-3 知,马氏链是不可约的;而由 $G_{ij}(t)$ 的定义,显然满足定理 11-4 的条件,从而马氏链是非周期的.

下面验证式(11-15)给出的分布是马氏链的平稳分布.

$$\begin{aligned}
 \text{记 } K &= \sum_{j \in \Omega} |N(j)| A_{i_0 j}(t), \text{ 由式(11-7)中 } P(t) \text{ 的定义, 有} \\
 &\sum_{j \in \Omega} \nu_j(t) p_{ji}(t) \\
 &= \sum_{j \in \Omega, i \in N(j)} \nu_j(t) p_{ji}(t) + \sum_{j \in \Omega, i \notin N(j)} \nu_j(t) p_{ji}(t) \\
 &= \sum_{j \neq i, i \in N(j)} \frac{|N(j)|}{K} A_{i_0 j}(t) G_{ji} A_{ji}(t) + \frac{|N(i)|}{K} A_{i_0 i}(t) \left[1 - \sum_{l \in \Omega, l \neq i} G_{il} A_{il}(t) \right] \\
 &\quad + \sum_{j \neq i, i \notin N(j)} \frac{|N(j)|}{K} A_{i_0 j}(t) G_{ji} A_{ji}(t) \\
 &= \sum_{j \neq i, i \in N(j)} \frac{1}{K} A_{i_0 j}(t) A_{ji}(t) + \frac{|N(i)|}{K} A_{i_0 i}(t) \left[1 - \sum_{l \in \Omega, l \neq i} G_{il} A_{il}(t) \right] \\
 &= \sum_{j \neq i, i \in N(j)} \frac{1}{K} A_{i_0 j}(t) A_{ji}(t) + \frac{|N(i)|}{K} A_{i_0 i}(t) - \sum_{l \in \Omega, l \neq i} \frac{1}{K} A_{i_0 i}(t) A_{il}(t)
 \end{aligned}$$

但是

$$\begin{aligned}
 &\sum_{j \neq i, i \in N(j)} \frac{1}{K} A_{i_0 j}(t) A_{ji}(t) - \sum_{l \in \Omega, l \neq i} \frac{1}{K} A_{i_0 i}(t) A_{il}(t) \\
 &= \sum_{j \neq i, i \in N(j), f(i) \leq f(j)} \frac{1}{K} A_{i_0 j}(t) A_{ji}(t) + \sum_{j \neq i, i \in N(j), f(i) > f(j)} \frac{1}{K} A_{i_0 j}(t) A_{ji}(t) \\
 &\quad - \sum_{l \in \Omega, l \neq i, f(l) \leq f(i)} \frac{1}{K} A_{i_0 i}(t) A_{il}(t) - \sum_{l \in \Omega, l \neq i, f(l) > f(i)} \frac{1}{K} A_{i_0 i}(t) A_{il}(t) \\
 &= \sum_{j \neq i, i \in N(j), f(i) \leq f(j)} \frac{1}{K} A_{i_0 j}(t) + \sum_{j \neq i, i \in N(j), f(i) > f(j)} \frac{1}{K} A_{i_0 i}(t) \\
 &\quad - \sum_{l \in \Omega, l \neq i, f(l) \leq f(i)} \frac{1}{K} A_{i_0 i}(t) - \sum_{l \in \Omega, l \neq i, f(l) > f(i)} \frac{1}{K} A_{i_0 l}(t) = 0
 \end{aligned}$$

于是, 式(11-15)给出的分布是马氏链的平稳分布. $\square$

例 11-4 设四个状态 1, 2, 3, 4 的邻居分别为

$$\begin{aligned}
 N(1) &= \{1, 2\}, & N(2) &= \{1, 2, 3, 4\} \\
 N(3) &= \{2, 3, 4\}, & N(4) &= \{2, 3, 4\}
 \end{aligned}$$

则容易验证, 每个状态满足互为邻居或互不为邻居, 但按定理 11-7 中 $G_{ij}(t)$ 的定义, 不满足对称性条件 $G_{ij} = G_{ji}$. 这个例子说明定理 11-7 的条件比定理 11-5 的条件要弱一些.

注 有关通过定义产生矩阵 $G(t)$ 和接受矩阵 $A(t)$, 使 SA 算法对应的马氏链为不可约非周期的讨论, 除以上给出的定义外, 还可以有其他形式的定义. 比如, 参考文献[22]按以下途径给出产生概率:

取对称矩阵 $Q = (Q_{ij})_{|N| \times |N|}$, 定义

$$G_{ij} = \frac{Q_{ij}}{\sum_{l \in \Omega} Q_{il}}, \quad \forall i \in \Omega, \quad \forall j \in N(i)$$

此时, 可求得平稳分布为

$$\nu_i(t) = \frac{(\sum_{l \in \Omega} Q_{il}) A_{i_0 i}(t)}{\sum_{l \in \Omega} (\sum_{j \in \Omega} Q_{jl}) A_{i_0 j}(t)} \quad (i \in \Omega) \quad (11-16)$$

另外,以上给出的只是有关平稳分布存在的充分条件,而非必要条件. 比如参考文献 [23] 给出的接受概率为

$$A_{ij}(t) = \left[1 + \exp\left(-\frac{f(j) - f(i)}{t}\right) \right]^{-1}$$

它不满足定理 11-5 的条件(2)和(3),但它有平稳分布

$$\nu_i(t) = \frac{\exp\left(-\frac{f(i)}{t}\right)}{\sum_{j \in \Omega} \exp\left(-\frac{f(j)}{t}\right)}, \quad \forall i \in \Omega \quad (11-17)$$

11.4 非时齐 SA 算法的收敛性简介

与时齐 SA 算法不同,非时齐 SA 算法在用 Metropolis 准则迭代搜索时,前后两次搜索在不同的温度参数下进行,此时算法所对应的马氏链是非时齐的,而非时齐马氏链的遍历性(有关极限分布和平稳分布)的讨论,要比 11.3 节介绍的时齐情形困难得多,也没有较为一般的、类似于定理 11-5 遍历性定理. 再加上要使对应的 SA 算法收敛,还需构造接受矩阵、产生矩阵使之满足收敛性条件,就更没有较一般的结果. 所以本节只能简要介绍一些相对成熟的零星研究结果.

非时齐 SA 算法对应的非时齐马氏链的一步转移概率可写为如下形式:

$$\begin{aligned} p_{ij}(k, k+1) &= P(X(k+1) = j | X(k) = i) \\ &= \begin{cases} G_{ij}(t_k) A_{ij}(t_k) & j \neq i \\ 1 - \sum_{l=1, l \neq i}^{|\Omega|} G_{il}(t_k) A_{il}(t_k) & j = i \end{cases} \end{aligned} \quad (11-18)$$

其中 $t_{k+1} < t_k, \lim_{k \rightarrow \infty} t_k = 0$, 一步转移概率矩阵记为 $P(k, k+1) = (p_{ij}(k, k+1))_{|\Omega| \times |\Omega|}$, 多步转移概率矩阵记为 $P(m, k) = (p_{ij}(m, k))_{|\Omega| \times |\Omega|}$, $p_{ij}(m, k), k > m$ 表示过程第 m 步在状态 i 的条件下,第 k 步在状态 j 的条件概率.

非时齐 SA 算法的收敛性归结为对应的非时齐马氏链的强遍历性. 如果存在分布

$\nu = (\nu_1, \nu_2, \dots, \nu_{|\Omega|})$ (即 $\nu_i \geq 0, \forall i \in \Omega, \sum_{i=1}^{|\Omega|} \nu_i = 1$) 使得

$$\forall i, j \in \Omega, m \geq 1, \quad \lim_{k \rightarrow \infty} p_{ij}(m, k) = \nu_j$$

称马氏链(设其状态空间为有限集 Ω)为强遍历的. 如果

$$\forall i, j, l \in \Omega, m \geq 1, \quad \lim_{k \rightarrow \infty} (p_{il}(m, k) - p_{jl}(m, k)) = 0$$

称马氏链是弱遍历的.

与时齐 SA 算法的收敛性的讨论类似,我们需要给出判断非时齐马氏链强遍历的条件,然后想法构造式(11-18)中的接受矩阵和产生矩阵,使式(11-18)确定的转移概率满足这些条件,从而使马氏链的极限分布集中在最优解集上,亦即从理论上保证算法搜索到全局最

优解.

有关弱遍历和强遍历性的判断,我们不加证明地给出两个结果.

定理 11-8 非时齐马氏链为弱遍历的充分必要条件是存在一个严格上升的正序列 $\{k_l, l=0,1,2,\dots\}$,使得

$$\sum_{l=1}^{\infty} (1 - \tau(P(k_l, k_{l+1}))) = \infty \quad (11-19)$$

其中 $\tau(P) = 1 - \min_{i,j \in \Omega} \sum_{l=1}^{|\Omega|} \min(p_{il}, p_{jl})$, $P = (p_{ij})_{|\Omega| \times |\Omega|}$.

定理 11-9 非时齐马氏链为强遍历的充分必要条件是:马氏链弱遍历且存在 $P(k, k+1)$ 的特征值为 1 的左特征向量 $\nu(k) = (\nu_1(k), \nu_2(k), \dots, \nu_{|\Omega|}(k))$, 使得 $\sum_{i=1}^{|\Omega|} |\nu_i(k)| = 1$, 且

$$\sum_{k=0}^{\infty} \sum_{i=1}^{|\Omega|} |\nu_i(k) - \nu_i(k+1)| < \infty \quad (11-20)$$

另外,若 $\lim_{k \rightarrow \infty} \nu(k) = \nu$, 则 $\forall j \in \Omega, \lim_{k \rightarrow \infty} p_{ij}(m, k) = \nu_j, i \in \Omega$

如前所述,为使非时齐 SA 算法收敛,需构造接受矩阵和产生矩阵使得算法对应的非时齐马氏链是强遍历的. 现在的想法是能否借助时齐 SA 算法讨论的结果,再在退温函数上加某种条件,使非时齐 SA 算法也收敛到全局优解. 具体地说,在温度 $t = t_k$ 时,在定理 11-5 和定理 11-7 所要求的条件下,已经得到了平稳分布 $\nu(k) = (\nu_1(k), \nu_2(k), \dots, \nu_{|\Omega|}(k))$, 我们试图在式(11-18)中的接受矩阵 $A(t_k)$ 和产生矩阵 $G(t_k)$ 满足原来的条件的前提下,通过适当选择温度的下降序列 $\{t_k, k=0,1,2,\dots\}$, $\lim_{k \rightarrow \infty} t_k = 0$, 使得:

(1) 非时齐马氏链由式(11-18)确定的转移概率矩阵满足式(11-19);

(2) 温度 $t = t_k$ 时,按时齐算法得到的平稳 $\nu(t_k) = (\nu_1(t_k), \nu_2(t_k), \dots, \nu_{|\Omega|}(t_k))$ 满足式(11-20);

(3) 极限分布 $\lim_{k \rightarrow \infty} \nu(t_k) = \nu$ 集中分布在最优解集 Ω_{opt} 上,即 $\lim_{k \rightarrow \infty} P(X(k) \in \Omega_{\text{opt}}) = 1$.

定理 11-10 设在温度 $t = t_k$ 时,式(11-18)定义的一步转移概率中的接受概率如式(11-9)定义,即

$$A_{ij}(t_k) = \begin{cases} 1 & f(i) \geq f(j) \\ \exp(-\Delta f_{ij}/t_k) & f(i) < f(j) \end{cases}$$

产生概率定义为

$$\forall i \in \Omega, G_{ij}(t) = \begin{cases} \frac{1}{|\Omega|} & j \in N(i) \\ 0 & j \notin N(i) \end{cases} \quad (11-21)$$

如果退温策略满足存在 $k_0 \geq 2$, 使得 $\forall k \geq k_0$, 有

$$t_k \geq \frac{|\Omega| \Delta f_{\max}}{\ln k} \quad (11-22)$$

其中

$$\Delta f_{\max} = \max\{f(i) | i \in \Omega\} - \min\{f(i) | i \in \Omega\} \quad (11-23)$$

则马氏链 $\{X(t_k), k=0,1,2,\dots\}$ 是强遍历的.

参考文献[26]证明了满足定理 11-10 条件的马氏链是弱遍历的. 再由定理 11-5 知, 由式(11-9)和式(11-21)确定的马氏链有平稳分布

$$\nu_i(t_k) = \frac{\exp\left(-\frac{f(i)}{t_k}\right)}{\sum_{j \in \Omega} \exp\left(-\frac{f(j)}{t_k}\right)}, \quad \forall i \in \Omega$$

可以验证, 此平稳分布满足式(11-20), 于是非时齐马氏链是强遍历的. 另外, 由 $A(t)$ 的定义及定理 11-6 知, 满足本定理条件的非时齐马氏链的平稳分布 $\nu(t_k)$ 有极限分布, 且该极限分布集中在最优解集上, 并为均匀分布. 这说明此时非时齐 SA 算法收敛到全局最优解.

注 定理 11-10 给出的温度下降的最快速度为 $\frac{|\Omega|\Delta f_{\max}}{\ln k}$. 参考文献[30]在定理 11-9 其他条件不变的情况下, 给出了使马氏链强遍历的较快的温度下降速度:

$$\forall k \geq 2, \quad t_k \geq \frac{n\Delta}{\ln k}.$$

其中, $\Delta = \max_{i,j} \{f(j) - f(i) \mid i \in \Omega, j \in N(i)\}$, n 是从任何一个状态可达到最优解的转移步数的上限, 它显然不会超过 $|\Omega|$, k 是 n 的倍数. 参考文献[30]在增强了状态可达条件, 并在目标函数具有较小起伏的前提下, 给出了使一个非时齐 SA 算法对应的非时齐马氏链强遍历的充分必要条件(用温度下降速度来表述).

11.5 SA 算法实现的技术问题

从前面介绍的 SA 算法的物理背景、计算步骤以及收敛性讨论, 我们看到 SA 算法通过一个内循环和一个外循环来实现, 而要使算法具体实现必须确定所谓的三函数两准则, 即新状态产生函数 $G(t)$ 、新状态接受函数 $A(t)$ 、退温函数(控制温度下降速度)以及抽样稳定准则、退火结束准则. 从理论上讲, 确定三函数两准则是要保证算法对应马氏链强遍历(平稳分布存在唯一), 从实际上讲, 要保证算法的有效性和可行性, 这主要指保证在具体求解时能搜索到最优解, 并且至少比穷举法搜索次数明显减少. 从前述定理中 $G(t)$ 和 $A(t)$ 的定义看, 为保证状态可达性和互通的对称性, 需要对具体组合优化问题的解的形式、解的邻域结构给出适当的表达. 另外, 初温的选择也是保证算法可行和有效的关键. 本节将就这些问题逐一进行讨论.

11.5.1 初温的选择

因为无论从物理退火的实际要求还是 SA 算法的需要, 初始温度越高, 粒子能量分布越均匀, 搜索到的解状态越多; 但从物理上讲, 温度只要使固体熔化就够了, 而对 SA 算法来讲, 温度太高则需要的迭代次数会增大, 从而耗费的机时增加. 所以, 需要给出一个确定初始温度参数的较为一般的方法.

一个最直观的想法是用具体组合优化问题的目标函数取值的最大差值来确定初始温度.

如前所述, 初始温度 t_0 的选取应尽量使每个解状态被接受, 也就是使

$$\exp\left(-\frac{\Delta f_{ij}}{t_0}\right) \approx 1$$

由此可估计一个值

$$t_0 = K\delta \quad (11-24)$$

其中 $\delta = \max\{f(i) \mid i \in \Omega\} - \min\{f(i) \mid i \in \Omega\}$, K 为一个较大的数, 实际计算时可以选取 $K = 10, 20, 100, \dots$ 等试验值.

当然, 实际中是无法计算出 δ 的, 只能根据具体的组合优化问题作出估计. 比如对 TSP 问题, 记对应的距离矩阵为 $(d_{ij})_{n \times n}$, 则

$$\begin{aligned} \max\{f(i) \mid i \in \Omega\} &\leq \sum_{i=1}^n \max\{d_{ij} \mid j \neq i, j = 1, 2, \dots, n\} \\ \min\{f(i) \mid i \in \Omega\} &\geq \sum_{i=1}^n \min\{d_{ij} \mid j \neq i, j = 1, 2, \dots, n\} \end{aligned}$$

而取

$$\delta = \sum_{i=1}^n \max\{d_{ij} \mid j \neq i, j = 1, 2, \dots, n\} - \sum_{i=1}^n \min\{d_{ij} \mid j \neq i, j = 1, 2, \dots, n\}$$

对于一般的组合优化问题, 往往不能较为准确地估计 δ . 另外, K 若取得过大会造成计算时间增加, 取得过小又会使得算法早早陷入局部最优点. 这里介绍两种方法: 数值计算估计方法和统计推断估计方法.

(1) 数值计算估计方法用来直接确定初始温度 t_0 . 它的思想是先给出一个新状态接受率 ρ ($\rho = 0.9, 0.8$ 等) 和迭代调整温度增减的一个幅度 T , 通过试算确定合适的 t_0 . 其算法步骤如下:

-
- STEP1 给定常量 T ; 初始温度 t_0 ; ρ ; $R_0 = 0$; $k := 1$;
- STEP2 在温度 t_0 下迭代搜索 L 步 (L 为选定的常数), 分别记录 SA 算法中接受和不接受状态的个数, 计算接受状态数与 L 的比值 R_k ;
- STEP3 当 $|R_k - \rho| < \varepsilon$ (事先取定 ε 充分小) 时, 停止计算; 否则,
- 当 $R_{k-1} < \rho$, 且 $R_k < \rho$ 时, $k := k + 1$, $t_0 := t_0 + T$, 转到 STEP2;
- 当 $R_{k-1} \geq \rho$, 且 $R_k \geq \rho$ 时, $k := k + 1$, $t_0 := t_0 - T$, 转到 STEP2;
- 当 $R_{k-1} \geq \rho$, 且 $R_k \leq \rho$ 时, $k := k + 1$, $t_0 := t_0 + T/2$, $T := T/2$, 转到 STEP2;
- 当 $R_{k-1} \leq \rho$, 且 $R_k \geq \rho$ 时, $k := k + 1$, $t_0 := t_0 - T/2$, 转到 STEP2.
-

(2) 统计推断估计方法用来估计 δ . 近似认为 $\{f(i), i \in \Omega\}$ 为一个大样本空间, 且服从正态分布. 在样本空间随机地选取 n 个样本 $X_1, X_2, \dots, X_n$, 计算样本均值

$$\overline{f(X)} = \frac{1}{n} \sum_{i=1}^n f(X_i)$$

和样本方差

$$f^2(X) = \frac{1}{n-1} \sum_{i=1}^n \left(f(X_i) - \overline{f(X)} \right)^2$$

根据正态分布均值和方差的估计量分别为样本均值和样本方差,以及 3σ 原则,取

$$\delta = 6 \sqrt{f^2(X)}$$

另外, Rayward - Dmuth(1996) 建议先置温度于很高的值,然后使温度迅速下降直至约 60% 的“坏”状态(迭代搜索时,新状态的能量高于原先状态的能量)被接受时,开始缓慢降温,进 SA 算法. 与此想法类似, Dowsland(1995) 建议从某一较低温度开始,急速增温,直至一定比例的“坏”状态被接受时,开始缓慢降温,进入 SA 算法,这个想法与物理退火处理的过程很相似.

11.5.2 时齐 SA 算法的退温过程控制方法

由上节介绍知道,非时齐算法中温度的下降速度一般有一个上限,往往太慢,可由其他变通的形式或与其他方法混合,以利于节省计算时间,我们暂不讨论. 这里只简单介绍时齐 SA 算法的退温过程下降方法.

(1) 一种非常直观的下降方法是线性退温方法:

$$t_k = \frac{K - k}{K} t_0$$

其中 t_0 为初始温度, K 为事先选定的温度下降总次数. 这种退温方法的特点是可以简单地控制温度下降总次数,每次下降的幅度相同.

(2) 另一种非常直观的下降方法是指数退温方法:

$$t_{k+1} = \alpha t_k \quad (k \geq 0)$$

其中 $0 < \alpha < 1$, 可分阶段调整参数 α , 使降温速度加快或减缓.

(3) 基于目标函数的统计推断方法. 这种方法是以平稳分布与目标函数的联系得到合适的退温策略. 先作简单推导,而后给出具体退温表达式.

设 $\nu(t) = \{\nu_i(t), i \in \Omega\}$ 为温度 t 时的平稳分布,定义

$$\langle f(t) \rangle = \sum_{i \in \Omega} f(i) \nu_i(t)$$

$$\langle f^2(t) \rangle = \sum_{i \in \Omega} f^2(i) \nu_i(t)$$

$$\overline{f(t)} = \frac{1}{n} \sum_{i=1}^n f(X_i(t))$$

$$\overline{f^2(t)} = \frac{1}{n} \sum_{i=1}^n f^2(X_i(t))$$

其中, $X_i(t)$ ($i=1, 2, \dots, n$) 为依分布 $\nu(t) = \{\nu_i(t), i \in \Omega\}$ 在样本空间 Ω 上随机抽样(实际计算时取为各温度状态下的样本一并作为样本,且具体计算时只需累计求和,而不用将所有样本都记录下来). 显然, $\langle f(t) \rangle$ 和 $\langle f^2(t) \rangle$ 分别表示目标函数在平稳分布 $\nu(t)$ 下的均值和二阶矩,而 $\overline{f(t)}$ 和 $\overline{f^2(t)}$ 表示温度 t 下目标函数的样本均值和样本二阶矩.

关于 $\langle f(t) \rangle$ 和 $\langle f^2(t) \rangle$ 有如下事实.

定理 11-11 设产生概率 $G(t)$ 和接受概率 $A(t)$ 满足定理 11-7 的条件,且分别如式 (11-8) 和式 (11-9) 定义,则

$$(1) \frac{d\langle f(t) \rangle}{dt} = \frac{\overline{f^2(t)} - \overline{f(t)}^2}{t^2};$$

(2) $\langle f(t) \rangle$ 为 t 的单调增函数, 且 $\langle f(t) \rangle \rightarrow f(i_{\text{opt}}), t \rightarrow 0$;

(3) 当 $i \neq i_{\text{opt}}$ 时, 平稳分布 $\nu(t)$ 在 $t=0$ 的一个邻域内为 t 的单调增函数; 当 $i = i_{\text{opt}}$ 时, 平稳分布 $\nu(t)$ 在 $t=0$ 的一个邻域内为 t 的单调减函数.

证 (1) 注意到由定理 11-7, 此时平稳分布可写为

$$\nu_i(t) = \frac{\exp\left(-\frac{f(i) - f(i_{\text{opt}})}{t}\right)}{\sum_{j \in \Omega} \exp\left(-\frac{f(j) - f(i_{\text{opt}})}{t}\right)}, \quad \forall i \in \Omega$$

经简单求导得

$$\frac{d\nu_i(t)}{dt} = \frac{\nu_i(t) f(t)}{t^2} - \frac{\nu_i(t) \langle f(t) \rangle}{t^2} \quad (11-25)$$

将此代入 $\langle f(t) \rangle$, 整理即得.

(2) 由(1)有

$$\begin{aligned} \frac{d\langle f(t) \rangle}{dt} &= \frac{\overline{f^2(t)} - \overline{f(t)}^2}{t^2} \\ &= \frac{\sum_{i \in \Omega} \left(\overline{f^2(t)} - \overline{f(t)} \right)^2 \nu_i(t)}{t^2} \geq 0 \end{aligned}$$

即 $\langle f(t) \rangle$ 为 t 的单调增函数, 从而由定理 11-6 知,

$$\lim_{t \rightarrow 0} \nu_i(t) = \begin{cases} \frac{1}{|\Omega_{\text{opt}}|} & i \in \Omega_{\text{opt}} \\ 0 & j \notin \Omega_{\text{opt}} \end{cases}$$

即 $\langle f(t) \rangle \rightarrow f(i_{\text{opt}}), t \rightarrow 0$.

(3) 由式(11-25)利用 $f(i_{\text{opt}}) < f(i), i \neq i_{\text{opt}}$, 经简单分析即得. $\square$

由定理 11-11, 在相邻温度, 平稳分布的变化是相对稳定的, 即对较小的 $\delta > 0$, 应有

$$\forall i \in \Omega, \quad \frac{1}{1+\delta} < \frac{\nu(t_k)}{\nu(t_{k+1})} < (1+\delta) \quad (k = 0, 1, 2, \dots)$$

再用定理 11-7, 上式可近似为

$$\exp\left(-\frac{f(i) - f(i_{\text{opt}})}{t_k}\right) < (1+\delta) \exp\left(-\frac{f(i) - f(i_{\text{opt}})}{t_{k+1}}\right)$$

即

$$\frac{f(i) - f(i_{\text{opt}})}{t_{k+1}} < \ln(1+\delta) + \frac{f(i) - f(i_{\text{opt}})}{t_k}$$

进而得

$$t_{k+1} \left(1 + \frac{t_k \ln(1+\delta)}{f(i) - f(i_{\text{opt}})} \right) > t_k$$

现在只需用统计推断方法估计 $f(i) - f(i_{\text{opt}})$ 的上界.

设想在温度 t_k , $\{f(i), i = 1, 2, \dots, |\Omega|\}$ 出现的频率服从 $\{\nu_1(t_k), \nu_2(t_k), \dots, \nu_{|\Omega|}(t_k)\}$, 其对应的均值和二阶矩分别为 $\langle f(t_k) \rangle$ 和 $\langle f^2(t_k) \rangle$, 经随机抽样得样本均值和样本二阶矩分别为 $\mu(t_k) = \overline{f(t_k)}$ 和 $\overline{f^2(t_k)}$, 样本方差为 $\sigma^2(t_k) = \overline{f^2(t_k)} - \overline{f(t_k)}^2$.

近似地,用正态分布的 3σ 原则,得到 $f(i) - f(i_{\text{opt}})$ 的上界为 $\mu(t_k) + 3\sigma^2(t_k)$,于是最后取

$$t_{k+1} = t_k \left(1 + \frac{t_k \ln(1 + \delta)}{\mu(t_k) + 3\sigma^2(t_k)} \right)^{-1}$$

另外,基于与上类似的想法,Lundy 和 Mees 得到退温规则

$$t_{k+1} = t_k \left(1 + \frac{rt_k}{U} \right)^{-1}$$

其中, U 是 $f(i) - f(i_{\text{opt}})$ 的一个上界, r 是一个充分小的数.

Huang M. D. 等基于以下等式

$$\frac{d\langle f(t) \rangle}{d\ln t} = \frac{\langle f^2(t) \rangle - \langle f(t) \rangle^2}{t^2}$$

通过用样本均值 $\overline{f(t_k)}$ 和样本二阶矩 $\overline{f^2(t_k)}$ 分别代替 $\langle f(t) \rangle$ 和 $\langle f^2(t) \rangle$,用差商代替导数得到以下降温规则

$$t_{k+1} = t_k \exp \left(- \frac{\lambda t_k}{\sqrt{\overline{f^2(t_k)} - \overline{f(t_k)}^2}} \right)$$

其中 $0 < \lambda < 1$.

11.5.3 时齐 SA 算法各温度下的迭代长度规则

对于时齐算法,还存在权衡温度下降速度与在每个温度 t 处迭代搜索次数两个方面. 因为从理论上讲,在每个温度 t 处应迭代搜索足够多次以找到平稳分布,但可以证明这将使计算时间按指数增长;而温度下降太快,则无论从物理背景和理论上看都无法保证找到最优解,这就需要在二者之间加以权衡,或者温度下降较快而每个温度状态多迭代,或者每个温度状态少迭代而温度下降速度放慢. 这里介绍几种控制迭代长度的方法.

1. 固定长度

在每个温度 t ,迭代相同的步数,步数的选取与组合优化问题的解的表达编码和邻域结构有关. 比如,对于 TSP 问题的两城市位置交换所定义的邻域,它的大小是 $\frac{n(n-1)}{2}$ (n 是城市数),则迭代长度可取为 $n, \frac{n}{2}, n^2, \frac{n^2}{2}$ 等.

2. 由接受和拒绝的比率来控制迭代长度

由于在温度参数很高时,每一个状态被接受的可能性基本相同,而且几乎所有状态都被接受,此时,在同一温度下的迭代次数应少一些;相反地,温度较低时,有较多的状态被拒绝,此时应加多迭代次数,以跳出局部最小. 所以可用以下两种方案来实现迭代次数的控制.

一种方案是给定一个充分大的迭代次数上限 U 和一个接受次数指标 R ,当接受次数达到 R 时,在此温度不再迭代;否则,一直迭代到上限步数 U .

另一种方案是给定一个接受比率指标 R 、迭代次数的上限 U 和下限 L ,每一温度至少迭代 L 次且记录同一温度下迭代总次数和被接受的次数,当迭代次数超过 L 时,若接受次数与总次数之比不小于 R 时,停止迭代;否则,一直迭代到上限步数 U .

11.5.4 SA 算法的停止准则

从理论上讲,SA 算法最终要使温度达到 0 而得到全局最优解,但从退火的物理背景和算法的具体实现时,都未必一定要达到或能达到 0. 关于 SA 算法的停止准则虽有理论上的推导结果,但真正可行的还是一些直观的原则,在此作简单介绍.

(1) 零度法. 给定一个充分小的正数 ε , 当 $t_k \leq \varepsilon$ 时, 算法终止;

(2) 循环总数控制法. 这种方法是规定算法循环的总次数, 完成规定的次数即终止计算. 总次数的指定又可分为两大类, 一是分别规定内循环和外循环的次数, 另一类是规定内外循环的总次数, 并随温度降低而调整内外各循环的次数.

(3) 基于无改进规则的控制法. 此法是迭代算法停止的通常做法, 即前后两个温度点搜索到的局部最优解差别很小, 就认为已搜索到的是全局最优解. 另外, SA 算法本身是温度较高时较容易跳离局部最优解, 如果在温度较高时未能跳离局部最优, 在温度较低时更不容易跳离局部最优, 所以前后两个温度点搜索到的局部最优解差别很小时, 再多的循环已于事无补, 只好停止计算.

还有一些关于算法终止规则的讨论, 可参见参考文献[22]及其所引文献.

11.5.5 组合优化问题解的形式和邻域结构设计

在 SA 算法的实施中, 还有一个重要的环节是设计组合优化问题解的形式和邻域结构, 它一方面关系到算法所对应的马氏链状态的互通性(或遍历性), 也关系到算法的有效性和可行性.

正如在定义产生函数 $G(t)$ 时所看到的, 必须考虑迭代搜索如何从一个原状态到达另一个新状态, 这意味着对每一个状态给定一个邻域, 即规定它可达哪些状态. 另外, 由定理 11-5、定理 11-6 以及定理 11-7 给出的充分条件, 邻域结构应是对称的, 即从 i 可以产生 j 、从 j 可以产生 i 而且可能性相同, 或者将此条件弱化为状态空间是互通的.

通常意义下搜索空间应越小越好, 至少使得迭代搜索次数小于解空间中状态的个数. 另外一方面, 为了保证状态互通性, 不得不扩大搜索空间, 有时甚至使不可行解也在其内. 所以, 解的表达形式以及对具体组合优化问题的深入了解(直接找到收敛的具体条件)是很重要的.

下面用两个例子来简单说明这些问题.

例 11-5 (1) 求目标函数为 $f(x) = x^2, 0 \leq x \leq 100$ 的满足某种约束的整数解. 它的解可以用 0-1 编码, 即解空间 Ω 可以取为 7 位的 0-1 编码

$$\Omega = \{x_1 x_2 \cdots x_7 \mid x_i = 0, 1, i = 1, 2, \cdots, 7\}$$

而解的一个邻域自然可以构造为

$$N(S) = \{S' \mid S \in \Omega, |S - S'| = \sum_{i=1}^7 |s_i - s'_i| \leq k, k \geq 1, \text{整数}\}$$

(2) n 个城市的 TSP 问题. 它的一个解可用 n 个城市的一个排序来表示, 即解空间是所有这样的不同排序构成的集合, 而一个解 X 的邻域就可由 X 的若干个不同位置交换而得到.

以上两个问题有如下共同特点:

(1) 每个邻域内所含状态个数(邻居)相同,如(1)中每个邻域中都有

$$C_7^k + C_7^{k-1} + \cdots + C_7^0$$

个邻居;TSP 中若采用 2-opt,则有 $C_n^2 + 1$ 个邻居.

(2) 每个邻居都是可行解.

(3) 空间中任何两个状态都互通且到达是对称的.

我们知道,由以上条件再补充加接受概率一定的条件,就可保证时齐算法搜索到全局最优解.

例 11-6 (1)将例 11-5 中(1)的解的形式和邻域结构用于“背包问题”:三个物品体积分别为 5,3,1,包的容积为 4,则可行解集合(用 5,3,1 在包中的个数依次排列)为

$$\{(0,0,0), (0,1,0), (0,0,1), (0,1,1)\}$$

显然,其中的状态不可能用例 11-5 的邻域结构使之互通,必须扩大搜索空间,即把(1,0,0), (1,1,0), (1,0,1), (1,1,1)等不可行解列入搜索空间.

这种简单扩大搜索空间的方法,有时是不可接受的.比如下例.

(2)将 TSP 用于“车间作业问题”.由于会出现车间作业的死锁现象,如仍用以上 TSP 解的形式和邻域结构,无法保证状态互通.此时,若改变解的表示方法,商人走 (i,j) 弧,则 $x_{ij} = 1$, 否则 $x_{ij} = 0$,这样每个解的维数为 $n \times (n-1)$,共有 $2^{n \times (n-1)}$ 个解,对于 TSP 来讲,这些解中只有 $(n-1)!$ 个可行解,搜索空间扩大了 $\frac{2^{n \times (n-1)}}{(n-1)!}$ 倍,当 $n=5$ 时,扩大倍数约为 4.37×10^4 ,当 $n=10$ 时,扩大倍数约为 3.41×10^{21} .

11.6 改进 SA 算法及注记

到目前为止,本章还只是介绍了标准的 SA 算法的基本思想和方法,要真正将该方法运用于具体组合优化问题求解,特别是求解较复杂的问题,除需对问题本身有比较深入的了解之外,还需与其他启发式算法相结合,才能收到较好效果,比如禁忌搜索法、遗传算法和神经网络等方法相结合的所谓混合优化策略,参见参考文献[13]的第 8 章.另外,SA 算法的各个环节都有各种各样的改进,这方面参考文献[13]作了简单介绍.有关算法改进和成功算例,还可参见参考文献[14]、[32]~[35].

注记: 本章内容主要取材于参考文献[14]和[13].关于模拟退火算法的物理背景,参考文献[20]从统计力学和 Monte Carlo 模拟的角度有详细阐述,但那里并没有提及“模拟退火”(Simulated Annealing).“模拟退火算法”始见于参考文献[21],在那里详细解释了如何将 SA 算法运用于组合优化问题求解,包括基本思想、物理退火与组合优化问题的联系以及算法的可行性和有效性等.有了基本思想,SA 算法的可行性,理论上归结为对应马氏链的遍历性,有关时齐马氏链的遍历性讨论,可以说是成熟的或经典的,可参见参考文献[29]或一般随机过程教科书;而有关非时齐马氏链的遍历性讨论则没有成熟的理论结果,有各种各样的弱收敛和强收敛的定义和结果,其证明方法和工具涉及高深的随机分析理论,参见参考文献[24]~[28], [30]~[31], [36]~[37]等.而 SA 算法的有效性,很大程度上依赖于对具体组合优化问题的深入了解,并在此基础上,设计解的形式、邻域结构、接受函数、产生函数、退温函数、接受准则、停止准则以及初始温度等,才能得到良好的结果.总之,尽管 SA 算法是

一种通用的全局优化算法,但要成功运用还需作细致、深入的前期准备工作.

习 题

11-1 你认为能将模拟退火思想用于组合优化问题求解的关键在于何处?

11-2 SA 算法区别于经典“瞎子爬山法”(局部搜索法)的关键在哪里?为何称 SA 算法是全局优化算法?

11-3 为什么非时齐 SA 算法对应的马氏链是非时齐的?对非时齐马氏链,式(11-10)和式(11-11)是否成立?

11-4 设 $P^{(n)} = (p_{ij}^{(n)})_{i,j \in \Omega}$ 为时齐马氏链 X 的 n 步转移概率矩阵($n \geq 1$).

(1) 试证: $P^{(n)} = (P^{(1)})^n$;

(2) 设 $\nu = \{\nu_i, i \in \Omega\}$ 为 X 的平稳分布,试证:对任一 $n \geq 1$,有

$$\nu_j = \sum_{i \in \Omega} \nu_i p_{ij}^{(n)}, \quad \forall j \in \Omega$$

11-5 若产生概率定义为

$$G_{ij}(t) = \begin{cases} \frac{1}{L} & j \in N(i) \\ 0 & j \notin N(i) \end{cases}$$

其中 L 为一个正数,接受概率按式(11-9)定义.当邻域的定义使得对应马氏链的状态空间互通时,试证明该时齐马氏链有平稳分布,并求出平稳分布.

11-6 设接受概率满足定理 11-5 的条件,取对称矩阵 $Q = (Q_{ij})_{|\Omega| \times |\Omega|}$, 定义

$$G_{ij} = \frac{Q_{ij}}{\sum_{l \in \Omega} Q_{il}}, \quad \forall i \in \Omega, \quad \forall j \in N(i)$$

试证在温度 t 时,对应的马氏链有平稳分布

$$\nu_i(t) = \frac{(\sum_{l \in \Omega} Q_{il}) A_{i_{0i}}(t)}{\sum_{j \in \Omega} (\sum_{l \in \Omega} Q_{jl}) A_{i_{0j}}(t)} \quad (i \in \Omega)$$

11-7 若接受概率如习题 11-4 定义,接受概率为

$$A_{ij}(t) = \left[1 + \exp\left(-\frac{f(j) - f(i)}{t}\right) \right]^{-1}$$

使验证对应的时齐马氏链有平稳分布

$$\nu_i(t) = \frac{\exp\left(-\frac{f(i)}{t}\right)}{\sum_{j \in \Omega} \exp\left(-\frac{f(j)}{t}\right)}, \quad \forall i \in \Omega$$

11-8 设产生概率 $G(t)$ 和接受概率 $A(t)$ 满足定理 11-7 条件,且分别如式(11-8)和式(11-9)定义.试证:当 $i \neq i_{\text{opt}}$ 时,平稳分布 $\nu(t)$ 在 $t=0$ 的一个邻域内为 t 的单调增函数;当 $i = i_{\text{opt}}$ 时,平稳分布 $\nu(t)$ 在 $t=0$ 的一个邻域内为 t 的单调减函数.

11-9 在时齐马氏链有平稳分布存在的条件下,若接受概率 $A(t)$ 如式 11-9 定义,试证:

$$\frac{d\langle f(t) \rangle}{d \ln t} = \frac{\langle f^2(t) \rangle - \langle f(t) \rangle^2}{t^2}$$

第 12 章 遗传算法

遗传算法 (Genetic Algorithms, 简称 GA) 是美国密执根 (Michigan) 大学的 Holland 教授于 20 世纪 60 年代末 70 年代初创立的一种仿生算法, 旨在研究自然系统的适应现象. 该方法通过对生物进化现象的抽象, 在人工适应系统中设计一种基于自然演化原理的搜索机制, 来描述自然系统的适应性. J. Holland (1975) 首次系统地阐述了 GA 的基本理论和方法, 提出了对 GA 的理论发展极为重要的模式理论 (Schema Theory), 确认了选择、杂交和变异等遗传算子, 建立了 GA 的模式定理和隐并行性原理, 并将 GA 应用于适应性系统的模拟、函数优化、机器学习和自动控制等领域.

GA 是一种高度并行、随机和自适应的优化算法, 它将问题的求解表示成“染色体”的适者生存过程, 通过染色体群的一代代不断进化, 包括选择、杂交、变异等操作, 最终收敛到“最适应环境”的个体, 从而求得问题的最优解或满意解. GA 是一种通用的优化算法, 其编码技术和遗传操作比较简单, 优化不受限制性条件的约束, 具有隐含并行性和全局解空间搜索等显著优点. 本章将分别介绍 GA 的基本概念与计算流程、模式理论、收敛性分析和技术实现等内容.

12.1 遗传算法的基本概念与计算流程

12.1.1 遗传算法的基本概念

GA 抽象于生物进化过程, 通过全面模拟自然选择和遗传机制, 形成一种具有“生成 + 检验”特征的搜索算法. GA 以编码空间代替问题的参数空间, 以适应度函数为评价依据, 以编码群体为进化基础, 以对群体中个体的遗传操作实现选择和遗传机制, 建立一个迭代过程. 在这一过程中, 通过随机重组个体中重要的基因, 使新一代的个体集合优于老一代的个体集合, 群体的个体不断进化, 逐渐接近最优解, 最终达到求解问题的目的.

为方便理解生物进化过程与优化问题求解的联系, 我们以人类进化为例子, 介绍有关术语和机理. 大家知道, 生物体由细胞构成, 每个细胞含有若干个染色体 (chromosome), 每个染色体含有一个脱氧核糖核酸 (DNA) 分子, 而每个 DNA 分子含有很多基因 (gene), 一个基因是 DNA 分子的一部分, 是具有遗传效应的 DNA 分子片段. 人类群体在自然竞争、淘汰后, 形成了繁殖后代的群体, 即成人群体. 群体的每一个体是一个人, 每个人的每个细胞中包含 46 条染色体, 组成 23 对同源染色体 (其中有 22 对称为常染色体, 还有 1 对称为性染色体), 男女性的结合使得对应的 23 对染色体优胜劣汰再产生 23 对染色体, 因而形成一个新的生命. 以性别染色体为例, 母亲的性染色体由一对染色体 XX 构成, 父亲的性染色体由一对染色体 XY 构成, 两个染色体的结合是这两对染色体竞争的产物, 竞争的结果得到四对性染色体, 且这四对染色体有 Y 的子代为男性. 新的每一条染色体的形成都由上代各条染色体的基因特点经选择、杂交 (交配)、变异等遗传环节决定.

为方便地将 GA 与一般组合优化问题的求解相类比,不失一般性,本章将一般优化问题提为

$$\begin{aligned} \max_{x \in D} f(x) \\ \text{s. t. } g(x) \geq 0 \end{aligned}$$

其中, $f(x)$ 为目标函数, $g(x)$ 为约束函数, D 为定解区域.

GA 主要是借鉴了生物进化的一些特征,主要体现在:

(1) 染色体的不同性质是由基因的排序确定的. 对优化问题来说就是把解用编码表述出来,即一个解就是一个染色体,解编码的每个分量为基因位置,每个分量的取值为基因. 解空间就对应一个生物种群;优化问题的求解就是通过个体(染色体)之间的选择、杂交和变异等遗传操作,最终找到“最适合生存”的个体(优化问题的最优解).

(2) 自然选择规律. “适者生存”规律使得染色体产生出适应能力超过平均水平的后代. 而在优化问题求解时,是根据优化目标人为地构造适应函数,自然选择规律就以适应函数值的大小决定的概率分布来确定哪些解保留、哪些解被淘汰,以使迭代过程中下一步得到的解超过平均适应值.

(3) 交配(杂交)双亲的遗传基因的结合使得子女保持父母的特征. 在优化问题求解时,通过染色体(编码)之间杂交运算产生一个新解,使得迭代搜索在一定范围内寻优.

(4) 变异. 双亲的染色体结合后,随机变异会造成子代的不同. 在优化问题求解时,通过染色体(编码)的变异运算,使解的搜索范围扩大,避免陷入局部最优搜索.

我们将以上生物遗传基本概念和用 GA 求解优化问题的对应关系的讨论总结于表 12-1.

表 12-1 生物遗传概念和 GA 有关概念的对应关系

生物遗传概念	GA 概念
群体(population)	选定的一组解(其中解的个数为群体的规模)
种群(reproduction)	根据适应函数值选取的一组解
个体(individual)	解
染色体(chromosome)	解的编码(字符串、向量等)
基因(gene)	解的每个分量的特征(如各分量的值)
适者生存	在算法结束时,最优目标值的解有最大的可能性被保留
适应性(adaptation)	适应函数值
选择(selection)	在已有的一组解中选出一个解或一对解
杂交(crossover)	通过交配原则产生一组新解
变异(mutation)	解的某些分量发生变化而产生一个新解

在给出 GA 的数学模型之前,先看一个简单的例子.

例 12-1 用 GA 求解问题

$$\begin{cases} \max x^2 \\ 0 \leq x \leq 31 \\ x \text{ 取整数} \end{cases}$$

用 GA 求解的第一步是编码. 由于这里是求整数解,我们采用最简单直观的二进值编

码,即0,1字符串.由于变量的最大值为31,因此可以用5位数的二进制码.如

$$16 \rightarrow 10000, \quad 31 \rightarrow 11111, \quad 9 \rightarrow 01001, \quad 2 \rightarrow 00010$$

这样的5位字符串称为染色体,每个分量称为等位基因,有0和1两个状态,每个分量的取值称为基因.所有的5位0-1字符串的集合称为群体或群体空间 S .

第二步是在群体空间中产生一个种群,作为求解的搜索范围.比如,取 $X_1 = (00000)$, $X_2 = (11001)$, $X_3 = (01111)$, $X_4 = (01000)$ 这4个个体构成一个种群 Ω .

第三步是确定适应函数.比如,按目标函数在每个染色体上的取值来定义其适应值,即定义适应值函数 $f(x) = x^2$ (本章自此之后 f 皆表示适应值函数),于是

$$f(x_1) = 0, \quad f(x_2) = 25^2, \quad f(x_3) = 15^2, \quad f(x_4) = 8^2$$

进而,定义每个个体入选种群的概率为

$$p(X_i) = \frac{f(X_i)}{\sum_{j \in \Omega} f(X_j)}, \quad X_i \in \Omega$$

即适应函数值大的染色体(个体)的生存概率较大.

第四步,遗传运算.先作选择运算,若群体中选前面的4个个体作为种群,则竞争能力较大的是(可重复选择) $X_2 = (11001)$, $X_2 = (11001)$, $X_3 = (01111)$, $X_4 = (01000)$.

再由 X_2, X_3, X_4 作杂交运算,比如,取第二个基因位置作为杂交点,作一次单点杂交,结果如下

$$\begin{array}{l} \left. \begin{array}{l} X_2 = (11 \mid 001) \\ X_3 = (01 \mid 111) \end{array} \right\} \longrightarrow \left\{ \begin{array}{l} Y_1 = (11 \mid 111) \\ Y_2 = (01 \mid 001) \end{array} \right. \\ \left. \begin{array}{l} X_2 = (11 \mid 001) \\ X_4 = (01 \mid 000) \end{array} \right\} \longrightarrow \left\{ \begin{array}{l} Y_3 = (11 \mid 000) \\ Y_4 = (01 \mid 001) \end{array} \right. \end{array}$$

最后,作变异运算.比如, Y_4 的第一个基因位置发生变异,使得 $z_1 = (11001)$.经反复作以上三种运算,进行迭代搜索,最后得最优解.

12.1.2 遗传算法的计算流程

我们通过例12-1介绍求解优化问题的GA的一般计算流程(详见下节).

遗传算法

STEP1 对问题解作一种编码,给出一个有 N 个染色体(个体)的初始种群

$$\text{pop}(1), t := 1;$$

STEP2 对 $\text{pop}(t)$ 中的每一个染色体 $\text{pop}(t)_i$ 计算它的适应值,

$$f_i = f(\text{pop}(t)_i);$$

STEP3 若停止规则满足,则算法停止;否则,计算概率

$$p_i = \frac{f_i}{\sum_{j=1}^N f_j} \quad (i = 1, 2, \dots, N)$$

并依此概率分布从 $\text{pop}(t)$ 中随机地选 N 个染色体构成一个新种群

$$\text{newpop}(t+1) = \{\text{pop}(t)_i, i = 1, 2, \dots, N\};$$

[注] $\text{newpop}(t+1)$ 中可能有重复选到的个体, 参见例 12-1.

STEP4 通过杂交, 杂交概率为选定的 p_c , 得到一个有 N 个染色体的 $\text{crosspop}(t+1)$;

STEP5 以一个较小的概率 p_m , 使得一个染色体的一个基因发生变异, 形成 $\text{mutpop}(t+1)$;

$t := t+1, \text{pop}(t) := \text{mutpop}(t)$; 返回到 STEP2

从以上计算流程看到, 要实施 GA, 必须解决一些技术问题.

(1) 解的编码和解码. 编码方式不只限于 0-1 编码, 采取何种编码与实际的优化问题有关, 本章有关理论的叙述和证明都是针对 0-1 编码, 其他编码形式可参见参考文献 [44]. 与编码相对应, 算法最后的工作是通过解码得到优化问题的解.

(2) 初始群体的选择和计算中群体的大小的确定. 初始群体过小, 会使搜索过早地陷入局部最优搜索; 初始群体过大, 其代表性越广泛, 最终进化到全局最优解的可能性越大, 但这势必造成计算时间的增加. 有时, 群体大小的选择, 采用与遗传代数有关的量, 可以使计算更有效.

(3) 适应函数的确定. 一般情况下, 适应函数同优化问题的目标函数有关, 以保证较优的解有较大的生存机会.

(4) 三个遗传算子的确定. 一是以何种方式选择种群, 以上流程中 STEP3 介绍的选择规则被称为轮盘赌 (Roulette Wheel), 其他方式可参见参考文献 [44]. 一般来讲, 它与由适应值确定的一个概率分布有关. 二是杂交规则的确定, 比如有单点杂交、两点杂交和多点杂交, 还得确定杂交点、杂交的概率等. 三是变异规则的确定, 以后会看到 (例 12-1 也已看到) 变异会使种群规模扩大, 所以变异概率的大小也直接影响算法的有效性.

从以上计算流程也能看到 GA 有以下特点:

(1) GA 是对解进行编码成染色体后进行进化操作, 而不是针对解本身, 这使得算法不受目标函数和约束函数的性态的限制, 比如连续性、可微性等.

(2) GA 的搜索过程是从问题的解的一个集合开始的, 而不是从单个个体开始的, 从而具有隐含并行搜索特性, 大大减少了陷入局部极小的可能.

(3) GA 的遗传操作都是随机操作, 同时只根据个体适应值信息进行搜索, 无需其他信息, 比如导数信息等.

(4) GA 的搜索是全局搜索, 最善于求解复杂问题和非线性问题.

12.2 遗传算法的数学模型

12.2.1 生物进化概念的数学描述

本节基于 0-1 编码, 介绍 GA 中有关概念的数学表达, 为后续模式理论和收敛性分析作准备.

定义 12-1 (个体与群体) 一个长度为 l 的 0-1 字符串称为 l -个体, l 称为个体的链长. l -个体的全体记作 $S = \{0, 1\}^l$, 称为群体 (或个体空间).

例如, 例 12-1 中的 0-1 编码中一个解就是一个长度为 5 的个体, 群体 S 中含有 2^5 个

不同的长度为5的个体.

定义 12-2(种群与种群空间) 由 N 个个体构成的集合称为 N -种群(个体允许重复),简称种群. N 称为种群规模.

$$S^N = \{\vec{X} = (X_1, X_2, \dots, X_N), X_i \in S; i = 1, 2, \dots, N\}$$

称为 N -种群空间.

例如,例 12-1 中见到的两个 4-种群为

$$\vec{X}_1 = (X_1, X_2, X_3, X_4), \quad \vec{X}_2 = (X_2, X_2, X_3, X_4)$$

注 一个 N -种群是由个体构成的,因此它是群体的 S 的一部分. 如果将种群中重复出现的个体视为一个元素,则可以记为 $\vec{X} \subset S$. 如果视 $\vec{X}$ 为向量,则 $\vec{X}$ 可写为向量形式,每一段为一个个体,例如

$$\vec{X}_1 = (00000 \ 11001 \ 01111 \ 01000)$$

$$\vec{X}_2 = (11001 \ 11001 \ 01111 \ 01000)$$

一般地,对于一个长度为 l 、规模为 N 的种群 $\vec{X}$,可以用表示长度为 $N \times l$ 的字符串来记

$$\vec{X} = (x_{11}x_{12}\cdots x_{1l}; x_{21}x_{22}\cdots x_{2l}; x_{N1}x_{N2}\cdots x_{Nl})$$

其中 $X_i = (x_{i1}, x_{i2}, \dots, x_{il})$ 为一个个体.

定义 12-3(齐次种群) 一个 N -种群 $\vec{X} = (X_1, X_2, \dots, X_N)$ 称为齐次种群,如果对于任意 $i, j \leq N$ 有 $X_i = X_j$,用 β^N 表示齐次种群的全体.

显然 $\beta^N \subset S^N$, 每个齐次种群只含有一个重复的个体,因此, β^N 中的个体数目等于群体 S 中个体的数目,即 $|\beta^N| = |S|$. 这里及以后,我们用 $|x|$ 表示集合 x 中元素的个数. 对于链长为 l 的群体和规模为 N 的种群空间,有 $|S| = 2^l$, $|S^N| = 2^{Nl}$.

定义 12-4(计数泛函) 对于 $\vec{X} \in S^N, X \in S$, 定义计数泛函

$$\varphi(\vec{X}, X) = \sum_{i=1}^N I_{\{X\}}(X_i)$$

其中 I_A 表示集合 A 的示性函数, $\varphi(\vec{X}, X)$ 表示种群 $\vec{X}$ 含有个体 X 的数目.

如果

$$\varphi(\vec{X}, X) = \varphi(\vec{Y}, X), \quad \forall X \in S$$

称种群 $\vec{X}$ 和 $\vec{Y}$ 等价,记作 $\vec{X} \sim \vec{Y}$. $\vec{X} \sim \vec{Y}$ 表示两层意思:一是 $\vec{X}$ 与 $\vec{Y}$ 含有相同的个体;二是 $\vec{X}$ 与 $\vec{Y}$ 含有相同的个体重复的次数一样多. 因此, $\vec{X} \sim \vec{Y}$ 表示 $\vec{Y}$ 是 $\vec{X}$ 的个体次序的某种变换.

定理 12-1 “ $\sim$ ”关系是 S^N 上的等价关系.

证 由二种群等价的定义,很容易验证“ $\sim$ ”关系具有自反性、对称性和传递性,从而是等价关系. $\square$

定理 12-2 等价关系“ $\sim$ ”在 S^N 上诱导出的等价类 $\mathcal{L} = S^N / \sim$ 的个数为

$$|\mathcal{L}| = \binom{N + 2^l - 1}{2^l - 1}$$

证 由二种群等价的定义和 $|S| = 2^l$ 知,等价类与集合

$$\Phi = \{(\varphi_1, \varphi_2, \dots, \varphi_{2^l}); \varphi_i \text{ 为非负整数}, \sum_{i=1}^{2^l} \varphi_i = N\}$$

一一对应. 而 $|\Phi|$ 则为多项式 $(1 + x + x^2 + \dots + x^{N-1})^{2^l}$ 中 x^N 的系数. 由于

$$(1 + x + x^2 + \cdots + x^N)^{2^l} = \left(\frac{1 - x^{N+1}}{1 - x} \right)^{2^l} = \frac{(1 - x^{N+1})^{2^l}}{(1 - x)^{2^l}}$$

而 $\frac{1}{(1-x)^{2^l}}$ 中 x^N 的系数为

$$\frac{1}{N!} \left(\frac{1}{(1-x)^{2^l}} \right)^{(N)} \Big|_{x=0} = \binom{N+2^l-1}{2^l-1} \quad \square$$

考虑例 12-1, $l=5, N=4$, 此时种群空间中种群数目为 $2^{5 \times 4} = 1\,048\,576$, 群体中个体数目为 $2^5 = 32$. 而等价类空间中等价类的数目为

$$|\mathcal{L}| = \binom{N+2^l-1}{2^l-1} = \binom{35}{31} = 52\,360$$

可见等价类空间中等价类的数目只有种群空间中种群数目的 $1/20$.

我们在使用种群时只关心种群中个体的作用, 这些个体出现的次数在某种程度上反映了种群的性质, 而这些个体如何排序是不起作用的. 因此, 使用个体等价类可以使遗传过程的刻画简单化.

12.2.2 遗传机制的数学描述

遗传机制主要包括选择、杂交和变异. GA 就是对种群通过遗传机制模拟自然进化过程而不断产生新一代种群, 并使新一代种群有更好的性质(适应性). 本节从数学模型的角度, 介绍这几种遗传算子的定义和简单性质, 有关这些算子在 GA 的作用和实现技术见 12.5 节.

定义 12-5(适应值函数) 对于一个个体产生的效益称为适应值. 称群体 S 到正实数空间 $\mathbb{R}^+$ 的映射为适应值函数, 即

$$f: S \rightarrow \mathbb{R}^+; S \ni X \mapsto f(X) \in \mathbb{R}^+$$

定义 12-6(选择算子) 选择算子在一个种群中选择一个个体, 它是一个随机映射:

$$T_s: S^N \rightarrow S, \quad S^N \ni \vec{X} \mapsto T_s(\vec{X}) \in S$$

特别地, 若按轮盘赌选择规则, 则选择算子可定义为

$$P\{T_s^\alpha(\vec{X}) = X_i\} = \frac{f^\alpha(X_i)}{\sum_{j=1}^N f^\alpha(X_j)} \quad (12-1)$$

其中, $f^\alpha(X_i)$ 表示种群 $\vec{X}$ 中个体 X_i 的适应值. $0 < \alpha < \infty$, 对于 $\alpha=1$ 的情形, 称为比例选择算子, 简记为 T_s .

由定义可以看出, 一个选择算子在一个种群 $\vec{X} = (X_1, X_2, \dots, X_N)$ 上导出一个一维概率分布

$T_s^\alpha(\vec{X})$	X_1	X_2	$\dots$	X_N
P	$\frac{f^\alpha(X_1)}{\sum_{j=1}^N f^\alpha(X_j)}$	$\frac{f^\alpha(X_2)}{\sum_{j=1}^N f^\alpha(X_j)}$	$\dots$	$\frac{f^\alpha(X_N)}{\sum_{j=1}^N f^\alpha(X_j)}$

例 12-2(例 12-1 续) 如例 12-1, 已有

$$X_1 = (00000), f(X_1) = 0$$

$$X_2 = (11001), f(X_2) = 25^2$$

$$X_3 = (01111), f(X_3) = 15^2$$

$$X_4 = (01000), f(X_4) = 8^2$$

采用比例选择算子得初始种群的分布

$\vec{X}$	X_1	X_2	X_3	X_4
P	0	$\frac{625}{866}$	$\frac{225}{866}$	$\frac{16}{866}$

按照概率规则选择个体, X_2, X_3 可能被选择两次, 而 X_1, X_4 可能被淘汰, 选择的结果可能为 $\vec{X} = (X_2, X_2, X_3, X_3)$.

按照式(12-1), 新种群 $\vec{X} = (X_2, X_2, X_3, X_3)$ 的概率分布为

$T_s^\alpha(\vec{X})$	X_2	X_2	X_3	X_3
P	$\frac{625}{1700}$	$\frac{625}{1700}$	$\frac{225}{1700}$	$\frac{225}{1700}$

从选择算子的定义和以上执行结果可以看到, 适应值大的个体容易被选择, 适应值小的个体容易被淘汰, 这样经过不断地选择使适应值大的个体不断重复出现, 使一个种群可能变为齐次种群. 但是, 选择算子只在固定的种群中进行选择, 选择的结果不可能跑到初始种群之外, 处于初始种群之外好的个体是选择不到的.

定义 12-7 (母体与母体空间) 两个个体 X_1, X_2 构成的对 (X_1, X_2) 称为母体, 其中 $X_1, X_2 \in S$. 所有母体构成的集合称为母体空间, 即

$$S^2 = \{(X_1, X_2), X_1, X_2 \in S\}$$

定义 12-8 (母体选择算子) 母体选择算子是在种群空间上选择一个母体, 即

$$T_s: S^N \mapsto S^2, \quad S^N \ni \vec{X} = (X_1, X_2, \dots, X_N) \mapsto T_s(\vec{X}) = (X_i, X_j) \in S^2$$

特别地, 若按照适应值选择算子独立地选取两个个体, 就构成一个按适应值选择母体的算子, 即

$$P\{(X_i, X_j)\} = P\{T_s^\alpha = (X_i, X_j)\} = \frac{f^\alpha(X_i)}{\sum_{k=1}^N f^\alpha(X_k)} \cdot \frac{f^\alpha(X_j)}{\sum_{k=1}^N f^\alpha(X_k)} \quad (12-2)$$

显然, 母体选择算子导出种群空间 $\vec{X}$ 上的一个二维概率分布, 其边缘分布就是个体选择算子导出的一维概率分布.

例 12-3 (例 12-2 续) 考虑例 12-2 中种群和它的 4 个个体的适应值及按比例个体选择算子, 得二维概率分布为

母体选择	X_1	X_2	X_3	X_4	边缘分布
X_1	0	0	0	0	0
X_2	0	$\frac{625}{866} \cdot \frac{625}{866}$	$\frac{225}{866} \cdot \frac{625}{866}$	$\frac{16}{866} \cdot \frac{625}{866}$	$\frac{625}{866}$
X_3	0	$\frac{625}{866} \cdot \frac{225}{866}$	$\frac{225}{866} \cdot \frac{225}{866}$	$\frac{16}{866} \cdot \frac{225}{866}$	$\frac{225}{866}$
X_4	0	$\frac{625}{866} \cdot \frac{16}{866}$	$\frac{225}{866} \cdot \frac{16}{866}$	$\frac{16}{866} \cdot \frac{16}{866}$	$\frac{16}{866}$
边缘分布	0	$\frac{625}{866}$	$\frac{225}{866}$	$\frac{16}{866}$	

下面来讨论选择算子的性质. 对于个体选择算子和母体选择算子, 在以下表达式中用同一个记号, 不会引起混淆.

定理 12-3 对于选择算子 T_s^α 及种群 $\vec{X} = (X_1, X_2, \dots, X_N)$, 有

$$(1) P\{T_s^\alpha(\vec{X}) \subset \vec{X}\} = 1;$$

$$(2) P\{T_s^\alpha(\vec{X}) = X\} = \frac{\varphi(\vec{X}, X)f^\alpha(X)}{\sum_{k=1}^N f^\alpha(X_k)}, \quad \forall X \in S.$$

$$(3) P\{T_s^\alpha(\vec{X}) = (X, Y)\} = \frac{\varphi(\vec{X}, X)f^\alpha(X)}{\sum_{k=1}^N f^\alpha(X_k)} \cdot \frac{\varphi(\vec{X}, Y)f^\alpha(Y)}{\sum_{k=1}^N f^\alpha(X_k)}, \quad \forall (X, Y) \in S^2$$

证 (1) 由于个体选择算子在种群上导出一个一维概率分布, 母体选择算子在种群上导出一个二维概率分布, 所以(1)是显然的. 事实上, 对于个体选择算子有

$$P\{T_s^\alpha(\vec{X}) \subset \vec{X}\} = \sum_{k=1}^N P\{T_s^\alpha(\vec{X}) = X_k\} = 1$$

对于母体选择算子有

$$P\{T_s^\alpha(\vec{X}) \subset \vec{X}\} = \sum_{i=1}^N \sum_{j=1}^N P\{T_s^\alpha(\vec{X}) = (X_i, X_j)\} = 1$$

(2) 对于 $X \in S$, 由全概率公式, 有

$$\begin{aligned}
P\{T_s^\alpha(\vec{X}) = X\} &= \sum_{i=1}^N P\{T_s^\alpha(\vec{X}) = X, X = X_i\} \\
&= \sum_{i=1}^N P\{T_s^\alpha(\vec{X}) = X \mid X = X_i\} P\{X = X_i\} \\
&= \sum_{i=1}^N P\{T_s^\alpha(\vec{X}) = X_i\} P\{X = X_i\} \\
&= \sum_{i=1}^N P\{T_s^\alpha(\vec{X}) = X_i\} I_{|X_i|}(X) \\
&= \sum_{i=1}^N \frac{f^\alpha(X_i) I_{|X_i|}(X)}{\sum_{k=1}^N f^\alpha(X_k)}
\end{aligned}$$

$$= \frac{\varphi(\vec{X}, X) f^{\alpha}(X)}{\sum_{k=1}^N f^{\alpha}(X_k)}$$

(3) 类似于(2)的证明可证. $\square$

推论 12-1 若有 $\vec{X} \sim \vec{Y}$, 则 $T_{\alpha}^{\alpha}(\vec{X})$ 与 $T_{\alpha}^{\alpha}(\vec{Y})$ 同分布.

证 由于 $\vec{X} \sim \vec{Y}$, 则 $\varphi(\vec{X}, X) = \varphi(\vec{Y}, X)$, $\forall X \in S$. 于是由定理 12-3 即得. $\square$

推论 12-2 若 $\vec{X} = (X, X, \dots, X) \in \beta^N$ 为齐次种群, 则

$$P\{T_{\alpha}^{\alpha}(\vec{X}) = X\} = 1, \quad P\{T_{\alpha}^{\alpha}(\vec{X}) = (X, X)\} = 1$$

证 由于此时有 $\varphi(\vec{X}, X) = N$, $\sum_{k=1}^N f^{\alpha}(X_k) = Nf^{\alpha}(X)$, 于是由定理 12-3 即得. $\square$

定理 12-4 (1) 设 $\vec{X}$ 为一种群, $I \subset \{1, 2, \dots, N\}$, 使得 $f(X_i) = f(X_j)$, $\forall i, j \in I$, 且 $f(X_i) > f(X_j)$, $\forall i \in I, j \notin I$, 则

$$\lim_{\alpha \rightarrow \infty} P\{T_{\alpha}^{\alpha}(\vec{X}) = (X_i, X_j)\} = \frac{1}{|I|^2}, \quad \forall i, j \in I$$

(2) 任给种群 $\vec{X} = (X_1, X_2, \dots, X_N)$, 必有

$$\lim_{\alpha \rightarrow 0} P\{T_{\alpha}^{\alpha}(\vec{X}) = (X_i, X_j)\} = \frac{1}{N^2}, \quad \forall i, j \leq N$$

证 由定理假设及式(12-2)有

$$\begin{aligned} & \lim_{\alpha \rightarrow \infty} P\{T_{\alpha}^{\alpha}(\vec{X}) = (X_i, X_j)\} \\ &= \lim_{\alpha \rightarrow \infty} \sum_{i=1}^N \left[\frac{\sum_{k=1}^N f^{\alpha}(X_k)}{f^{\alpha}(X_i)} \right]^{-1} \cdot \left[\frac{\sum_{k=1}^N f^{\alpha}(X_k)}{f^{\alpha}(X_j)} \right]^{-1} \\ &= \lim_{\alpha \rightarrow \infty} \sum_{i=1}^N \left[|I| + \sum_{k \notin I} \frac{f^{\alpha}(X_k)}{f^{\alpha}(X_i)} \right]^{-1} \cdot \left[|I| + \sum_{k \notin I} \frac{f^{\alpha}(X_k)}{f^{\alpha}(X_j)} \right]^{-1} \\ &= \frac{1}{|I|^2} \end{aligned}$$

(2) 类似于(1)的证明可证. $\square$

注 读者可以给出关于个体选择的类似事实.

由定理 12-4 可知, 选择算子的指数 α 对于选择有重要作用. α 越大, 适应值大的两个个体越容易被选择; α 越小, 选择的随机性越大, 适应值的大小对选择不起作用. α 很大时搜索空间很小, 基本上是在一个种群中适应值大的个体中搜索; 而当 α 很小时搜索空间很大, 它在种群的全体中搜索. 选择算子具有“优胜”的性质.

定义 12-9 (杂交算子) 杂交算子是母体空间到个体空间(群体)的映射:

$$T_c: S^2 \rightarrow S, \quad S^2 \ni (X_i, X_j) \mapsto T_c(X_i, X_j) \in S$$

(1) 单点杂交算子: 等概率地随机确定一个基因位置作为杂交点, 再把一对母体的两个个体从杂交点分成前后两部分, 交换两个个体后半部分得到两个新个体, 取第一个个体为杂交结果.

(2) 单点随机杂交算子: 等概率地随机确定一个基因位置作为杂交点, 再把一对母体的

两个个体从杂交点分成前后两部分,依概率 p_c 交换两个个体后半部分得到两个新个体,取第一个个体为杂交结果. 称 p_c 为杂交概率.

如果确定两个基因位置将一对母体两个个体分成三部分,交换中间部分,称为双点杂交算子. 同样还有双点随机杂交算子.

(3) 均匀随机杂交算子: 独立地依概率 p_c 把母体第一个个体的相应的分量替换为第二个个体的相应分量,所得的第一个个体为杂交结果.

例 12-4 (例 12-2 续) 在例 12-1 中,取第二个基因位置作为杂交点,取 (X_2, X_3) 作一次单点杂交,结果为

$$T_c(X_2, X_3) = T_c((11|001), (01|111)) = (11|111)$$

如果取 (X_2, X_3) 作一次均匀随机杂交,则可能的结果有

$$(01001), (11101), (11011)$$

由例 12-4 看出,杂交的结果可能在种群之中,也可能在种群之外. 这一点与选择算子不同,杂交算子扩大了搜索空间.

定理 12-5 (1) 设 T_c 为单点杂交算子,则对任意的 $(X_1, X_2) \in S^2, Y \in S$ 有

$$P\{T_c(X_1, X_2) = Y\} = \frac{k}{l} \quad (12-3)$$

其中 $k = k(X_1, X_2, Y)$ 为用单点杂交 (X_1, X_2) 可以生成的 Y 的基因位置的个数.

(2) 设 T_c 为单点随机杂交算子, p_c 为杂交概率,对于任意的 $(X_1, X_2) \in S^2, Y \in S$ 有

$$P\{T_c(X_1, X_2) = Y\} = \begin{cases} \frac{kp_c}{l} & Y \neq X_1 \\ (1 - p_c) + \frac{kp_c}{l} & Y = X_1 \end{cases} \quad (12-4)$$

(3) 设 T_c 为均匀随机杂交算子, p_c 为杂交概率,对于任意的

$$(X_1, X_2) \in S^2, Y \in S, X_i = (x_{i1}, x_{i2}, \dots, x_{il}), i = 1, 2, Y = (y_1, y_2, \dots, y_l)$$

有

$$P\{T_c(X_1, X_2) = Y\} = \prod_{j=1}^l [(1 - p_c) \cdot (y_j \oplus' x_{1j}) + p_c \cdot (y_j \oplus' x_{2j})] \quad (12-5)$$

其中 $\oplus'$ 为异或算子,即对任意 $x, y \in \{0, 1\}$ 有

$$x \oplus' y = \begin{cases} 1 & x = y \\ 0 & x \neq y \end{cases}$$

证 (1) 由于杂交点有 $0, 1, 2, \dots, l-1$,每一种杂交点的选择通过单点杂交后可能是 Y ,也可能不是 Y . k 记录了选择的杂交点通过杂交后生成 Y 的个数,而杂交点的选择是均匀分布(随机地)的,于是(1)得证.

(2) 对单点随机杂交算子分两种情况来考虑.

当 $Y \neq X_1$ 时,取决于杂交 (X_1, X_2) 可以生成 Y 的基因位置的个数 k . 与(1)不同的是,即使选择的杂交点通过杂交后可以生成 Y ,而它未必杂交,杂交的概率为 p_c . 于是, $Y \neq X_1$ 时,

$$P\{T_c(X_1, X_2) = Y\} = \frac{kp_c}{l}$$

当 $Y = X_1$ 时, X_1 与 X_2 在任何杂交点都不杂交,即杂交结果为 $Y = X_1$,这种每点都不杂交情况出现的概率为 $1 - p_c$.

于是,由概率的加法公式得式(12-4).

(3)对于均匀随机杂交算子,由于它是每个分量独立地确定杂交与不杂交,所以分别按分量考虑.考虑 Y 的第 j 个分量,若 x_{1j} 与 y_j 相同,则不杂交;若 x_{2j} 与 y_j 相同,则要杂交.于是,利用全概率公式,有

$$\begin{aligned} P\{T_c(X_1, X_2)_{j=y_j}\} &= P\{T_c(X_1, X_2)_j = y_j \mid y_j = x_{1j}\} p\{y_j = x_{1j}\} \\ &\quad + P\{T_c(X_1, X_2)_j = y_j \mid y_j = x_{2j}\} p\{y_j = x_{2j}\} \\ &= (1 - p_c) \cdot (y_j \oplus x_{1j}) + p_c \cdot (y_j \oplus x_{2j}) \end{aligned}$$

由各分量杂交是独立的,得到式(12-5). $\square$

推论 12-3 设 T_c 为杂交算子(单点杂交、单点随机杂交、均匀随机杂交),则对任何母体 (X, X) ,必有

$$P\{T_c(X, X) = X\} = 1, \quad \text{亦即 } T_c(X, X) = X$$

证 由定理 12-4,显然. $\square$

定理 12-6 设 T_c 为单点随机杂交算子或均匀随机杂交算子,对于任给种群

$$\vec{X} = (X_1, X_2, \dots, X_N)$$

以及 $i \leq N$,必有

$$P\{T_c(T_s^a(\vec{X})) = X_i\} > 0 \quad (12-6)$$

证 首先,由全概率公式有

$$\begin{aligned} &P\{T_c(T_s^a(\vec{X})) = X_i\} \\ &= \sum_{k=1}^N \sum_{l=1}^N P\{T_c(T_s^a(\vec{X})) = X_i \mid T_s^a(\vec{X}) = (X_k, X_l)\} \cdot P\{T_s^a(\vec{X}) = (X_k, X_l)\} \\ &\geq P\{T_c(T_s^a(\vec{X})) = X_i \mid T_s^a(\vec{X}) = (X_i, X_i)\} \cdot P\{T_s^a(\vec{X}) = (X_i, X_i)\} \\ &= P\{T_c(X_i, X_i) = X_i\} \cdot P\{T_s^a(\vec{X}) = (X_i, X_i)\} \end{aligned}$$

又因为(一般地,假定适应值函数 $f(x) > 0$)

$$P\{T_s^a(\vec{X}) = (X_i, X_i)\} = \left(\frac{f^a(X_i)}{\sum_{j=1}^N f^a(X_j)} \right)^2 > 0$$

而 $P\{T_c(X_i, X_i) = X_i\} = 1$. $\square$

推论 12-4 设 T_c 为杂交算子, T_s^a 为选择算子, $\vec{X} = (X, X, \dots, X)$ 为齐次种群,则

$$P\{T_c(T_s^a(\vec{X})) = \vec{X}\} = 1$$

证 $P\{T_c(T_s^a(\vec{X})) = X\} = P\{T_c(X, X) = X\} \cdot P\{T_s^a(\vec{X}) = (X, X)\}$

从而由推论 12-2 和推论 12-3 即得. $\square$

定义 12-10(变异算子) 变异算子是个体空间(群体)到个体空间的随机映射:

$$T_m: SS, \quad S \ni X \rightarrow T_m(x) \in S$$

其作用方式是独立地依概率 p_m 改变个体分量取值. p_m 称为变异概率.

定理 12-7 任给两个个体 $X, Y \in S$,有

$$P\{T_m(X) = Y\} = p_m^{d(X,Y)} (1 - p_m)^{l-d(X,Y)} \quad (12-7)$$

其中, $d(X, Y)$ 表示海明 (Hamming) 距离, 即

$$d(X, Y) = \sum_{i=1}^l |x_i - y_i|$$

而 $X = (x_1, x_2, \dots, x_l), Y = (y_1, y_2, \dots, y_l)$.

证 由于变异算子作用方式是独立地依概率 p_m 改变个体分量取值, 所以只需按分量来讨论.

Y 的分量有两种: 一种是 $y_i \neq x_i$, 另一种是 $y_i = x_i$. 显然, $y_i \neq x_i$ 的个数为 $d(X, Y)$, 这时 x_i 变异为 y_i 的概率为 p_m . 而 $y_i = x_i$ 的个数为 $l - d(X, Y)$, 这时 x_i 不变异, 不变异的概率为 $1 - p_m$, 由各分量变异的独立性即得证. $\square$

基于生物遗传学的考虑, 一般认为杂交是自然演化的主要机制, 变异为自然演化的背景, 它们分别承担遗传和变异两种功能. 因此, 在具体应用 GA 过程中, 杂交概率一般取值较大, 在 0.65 与 0.9 之间, 而变异概率取值较小, 一般在 0.001 与 0.01 之间.

定理 12-8 设 T_s 为选择算子, T_c 为杂交算子, T_m 为变异算子, 则对任意 $\vec{X} \in S^N$, $\vec{Y} \in S$, 使

$$P\{T_m \circ T_c \circ T_s(\vec{X}) = Y\} > 0$$

的充分必要条件是 p_m 满足 $0 < p_m < 1$. 其中

$$T_m \circ T_c \circ T_s(\vec{X}) = T_m(T_c(T_s(\vec{X})))$$

证 充分性 当 $0 < p_m < 1$ 时, 由定理 12-7 知, 对于任一 $X, Y \in S$ 有

$$P\{T_m(\vec{X}) = Y\} = p_m^{d(X, Y)} (1 - p_m)^{l-d(X, Y)} > 0$$

于是, 对任一 $\vec{X} \in S^N, Y \in S$, 用全概率公式和定理 12-6 有

$$\begin{aligned} P\{T_m \circ T_c \circ T_s(\vec{X}) = Y\} \\ = \sum_{X \in S} P\{T_m(X) = Y\} \cdot P\{T_c \circ T_s(\vec{X}) = X\} > 0 \end{aligned}$$

必要性 假设 $p_m = 0$, 设 $\vec{X} = (X_1, X_1, \dots, X_1)$ 为齐次种群, $Y \in S, Y \neq X_1$. 由于

$$P\{T_c \circ T_s(\vec{X}) = X_1\} = 1, \quad P\{T_m(X_1) = Y\} = 0$$

于是由全概率公式有

$$\begin{aligned} P\{T_m \circ T_c \circ T_s(\vec{X}) = Y\} \\ = \sum_{X \in S} P\{T_m(X) = Y\} \cdot P\{T_c \circ T_s(\vec{X}) = X\} \\ = P\{T_m(X_1) = Y\} \cdot P\{T_c \circ T_s(\vec{X}) = X_1\} \\ = 0 \end{aligned}$$

这与 $P\{T_m \circ T_c \circ T_s(\vec{X}) = Y\} > 0$ 矛盾, 故 $p_m > 0$. 同理可证 $p_m < 1$. $\square$

定义 12-11 (删除算子) 删除算子是从一个种群删除掉一个个体, 它是 S^N 到 S^{N-1} 的随机映射, 即

$$T_d: S^N \rightarrow S^{N-1}. \quad S^N \ni \vec{X} \mapsto T_d(\vec{X}) \in S^{N-1}$$

指数为 $0 \leq \alpha \leq \infty$ 的随机删除算子, 由下面概率分布确定

$$P\{T_d^\alpha(\vec{X}) = \vec{X} \setminus \{X_i\}\} = \frac{f^{-\alpha}(X_i)}{\sum_{j=1}^N f^{-\alpha}(X_j)} \quad (12-8)$$

特别地,称 $\alpha=1$ 的删除算子 T_d^1 为比例删除算子,称 $\alpha=0$ 的删除算子 T_d^0 为均匀删除算子.

定理 12-9 (1) 设 $\vec{X}$ 为一种群,且对于某个 $i \leq N$, 存在 $j \leq N$, 使 $f(X_i) > f(X_j)$, 则

$$\lim_{\alpha \rightarrow \infty} P\{X_i \in T_d^\alpha(\vec{X})\} = 1$$

(2) 对于任意种群 $\vec{X} = (X_1, X_2, \dots, X_N)$, 必有

$$\lim_{\alpha \rightarrow 0} P\{X_i \notin T_d^\alpha(\vec{X})\} = \frac{1}{N}$$

证 由于 $f(X_i) > f(X_j)$, 则

$$\begin{aligned} & \lim_{\alpha \rightarrow \infty} P\{X_i \in T_d^\alpha(\vec{X})\} \\ &= 1 - \lim_{\alpha \rightarrow \infty} P\{T_d^\alpha(\vec{X}) = \vec{X} \setminus \{X_i\}\} \\ &= 1 - \lim_{\alpha \rightarrow \infty} \left[1 + \sum_{k \neq i} \left(\frac{f(X_i)}{f(X_k)} \right)^\alpha \right]^{-1} \\ &\geq 1 - \lim_{\alpha \rightarrow \infty} \left[1 + \left(\frac{f(X_i)}{f(X_j)} \right)^\alpha \right]^{-1} \\ &= 1 \end{aligned}$$

(1) 得证.

(2) 对于 $\vec{X} = (X_1, X_2, \dots, X_N)$

$$\begin{aligned} & \lim_{\alpha \rightarrow 0} P\{X_i \notin T_d^\alpha(\vec{X})\} \\ &= \lim_{\alpha \rightarrow 0} P\{T_d^\alpha(\vec{X}) = \vec{X} \setminus \{X_i\}\} \\ &= \lim_{\alpha \rightarrow 0} \frac{f^{-\alpha}(X_i)}{\sum_{j=1}^N f^{-\alpha}(X_j)} \\ &= \frac{1}{N} \end{aligned}$$

从定理 12-9 看到,随机删除算子中, α 的选择很重要. α 越大时适应值大的个体越容易被保留; α 越小时删除算子越具有随机性,与适应值的大小关系不大. 删除算子体现了“劣汰”的性质.

有了以上概念,可以介绍几种常见的 GA.

标准 GA (Canonical Genetic Algorithm):

-
- | | |
|-------|---|
| STEP1 | 置 $k=0$, 随机产生初始种群
$\vec{X}(0) = (X_1(0), X_2(0), \dots, X_N(0)) \in S^N$; |
| STEP2 | 独立地从当前种群中选取 N 对母体; |
| STEP3 | 独立地对于 N 对母体进行杂交, 得到 N 个中间个体; |
| STEP4 | 独立地对于 N 个杂交后的个体进行变异, 得到下代种群
$\vec{X}(k+1) = (X_1(k+1), X_2(k+1), \dots, X_N(k+1)) \in S$; |
| STEP5 | 检验停止准则. 若满足则停止, 否则, $k := k+1$, 返回到 STEP2. |
-

精英选择 GA (Elitist Selection Genetic Algorithm):

- STEP1 置 $k=0$, 随机产生初始种群
 $\vec{X}(0) = (X_1(0), X_2(0), \dots, X_N(0)) \in S^N$;
- STEP2 独立地从当前种群中选取 $N-1$ 对母体;
- STEP3 独立地对于 $N-1$ 对母体进行杂交, 得到 $N-1$ 个中间个体;
- STEP4 独立地对于 $N-1$ 个杂交后的个体进行变异, 得到 $k+1$ 代种群的前 $N-1$ 个个体: $X_1(k+1), X_2(k+1), \dots, X_{N-1}(k+1)$;
- STEP5 计算 $i = \arg \max_{1 \leq j \leq N} \{f(X_j(k))\}$, 令 $X_N(k+1) = X_i$.
- STEP6 检验停止准则. 若满足则停止, 否则, $k := k+1$, 返回到 STEP2.
-

在精英选择 GA 中, $i = \arg \max_{1 \leq j \leq N} \{f(X_j(k))\}$ 表示使 $f(X_j(k))$ 取最大值的个体的下标为 i . 有关本选择方法的进一步说明见本章第 5 节.

稳定状态 GA (Steady State Genetic Algorithm):

- STEP1 置 $k=0$, 随机产生初始种群
 $\vec{X}(0) = (X_1(0), X_2(0), \dots, X_N(0)) \in S^N$;
- STEP2 从当前种群中选择一对母体;
- STEP3 对所选母体进行杂交和变异, 得到一个新个体;
- STEP4 删去 $\vec{X}(k)$ 中的一个个体而代之以产生的新个体形成下一代种群
 $X_1(k+1), X_2(k+1), \dots, X_N(k+1) \in S^N$;
- STEP5 检验停止准则. 若满足则停止, 否则, $k := k+1$, 返回到 STEP2.
-

以上是几种常见的 CA. 通过变化选择、杂交、变异、删除的方法, 还可以得到不同的 GA. 更多的其他算法可参见参考文献[44]. GA 通过遗传机制的“优胜”或“劣汰”, 保留好的解, 淘汰差的解, 使遗传过程不断进化, 最终得到全局最优解.

12.3 遗传算法的模式理论

模式理论 (Schema Theory) 是 Holland 为解释二进制编码的标准 GA 的机制和有效性而建立的, 是最早对遗传算法全局收敛性作定性分析的理论基础. 它说明了适应值高、长度短、阶数低的模式在后代中至少以指数增长包含该模式的个体数.

12.3.1 模式与遗传算子

基于二进制编码的标准 GA 中, 个体 (染色体) 是以 0-1 字符串表示的, 个体长度为 l 的个体空间 (群体) $S = \{0, 1\}^l$ 可以看成是 l 维欧氏空间中单位立方体的顶点集.

我们知道, l 维欧氏空间中的点可用坐标表示为 $(x_1, x_2, \dots, x_l)$, 如果其中一些坐标分量固定, 而其余坐标分量任意取值, 则构成 l 维欧氏空间中的一个超平面, 比如, 在 3 维欧氏空间中, $\{(x, y, z) | z=0, x, y \in \mathbb{R}\}$ 就是 $X-Y$ 平面. 如果我们用 $*$ 表示任意值, 则 $(*, *, 0)$ 就表示 3 维欧氏空间中 $X-Y$ 平面.

现在, 在个体空间 $S = \{0, 1\}^l$, 如果用 $*$ 表示 0 或 1, 让个体的一些分量有固定的取值, 而其余坐标分量取 $*$, 就得到 l 维单位立方体的一个面(或一条边). 为区别于超平面, 称它为一个模式(schema), 这样的模式的全体记为 $\mathcal{M} = \{0, 1, *\}^l$, 共有 3^l 个模式,

下面具体讨论模式的定义及在遗传算子作用下是如何变化的.

定义 12-11 设 $a_{ik} \in \{0, 1\}$, $1 \leq i_k < i_{k+1} \leq l$, 称个体空间中的一个“超平面”为一个模式, 记作

$$\mathcal{L}[(i_k, a_{ik}); 0 \leq k \leq K] = \{X = (x_1, x_2, \dots, x_l) \in S; x_{i_k} = a_{i_k}, 0 \leq k \leq K\}$$

其中, K 称为模式的阶, 记作 $O(\mathcal{L}) = K$; 称 $(i_1, i_2, \dots, i_K)$ 为 $\mathcal{L}$ 的定义分量(或定义基因位置); 称 a_{i_k} 为定义分量值(定义基因), 而称

$$\delta(\mathcal{L}) = i_K - i_1$$

为模式 $\mathcal{L}$ 的定义长度.

在不致引起混淆的情况下, 将模式 $\mathcal{L}[(i_k, a_{ik}); 0 \leq k \leq K]$ 简记为

$$\mathcal{L} \text{ 或 } \mathcal{L}[(i_k, a_{ik}); K]$$

例 12-5 取 $l=3$, 则个体空间为

$$S = \{0, 1\}^3 = \{(000), (100), (010), (001), (100), (110), (101), (111)\}$$

若取 $a_1 = 1$, 则

$$\mathcal{L}_1[(1, 1)] = \{(100), (110), (101), (111)\}$$

若取 $a_1 = 1, a_2 = 0$, 则

$$\mathcal{L}_2[(1, 1), (2, 0)] = \{(100), (101)\}$$

再如

$$\mathcal{L}_3[(1, 0), (2, 1)] = \{(010), (011)\}$$

$$\mathcal{L}_4[(2, 1), (3, 0)] = \{(010), (110)\}$$

且

$$O(\mathcal{L}_2) = O(\mathcal{L}_3) = O(\mathcal{L}_4) = 2, \quad O(\mathcal{L}_1) = 1$$

$$\delta(\mathcal{L}_2) = \delta(\mathcal{L}_3) = \delta(\mathcal{L}_4) = 1, \quad \delta(\mathcal{L}_1) = 0$$

另外, 也可以用通配符 $*$, 将以上模式简单记为

$$\mathcal{L}_1 = (1, *, *), \quad \mathcal{L}_2 = (1, 0, *), \quad \mathcal{L}_3 = (0, 1, *), \quad (\mathcal{L}_4 = *, 1, 0)$$

定义 12-12 对于第 i 个基因, 若

$$\begin{aligned} & f(x_1, x_2, \dots, x_{i-1}, 1, x_{i+1}, \dots, x_l) \\ & \geq f(x_1, x_2, \dots, x_{i-1}, 0, x_{i+1}, \dots, x_l) \quad (x_k = 0, 1; k \neq i) \end{aligned} \quad (12-9)$$

或

$$f(x_1, x_2, \dots, x_{i-1}, 0, x_{i+1}, \dots, x_l) \geq f(x_1, x_2, \dots, x_{i-1}, 1, x_{i+1}, \dots, x_l) \quad (x_k = 0, 1; k \neq i) \quad (12-10)$$

则称基因 i 是重要基因, 且当式(12-9)成立时, 称重要基因取值 1 时为优良选择; 当式

(12-10) 成立时,称重要基因取值 0 时为优良选择.

可以看出,若基因 i 是重要基因,1 是优良选择,则最优解必在模式 $\mathcal{L}[(i,1)]$ 中;若基因 i 是重要基因,0 是优良选择,则最优解必在模式 $\mathcal{L}[(i,0)]$ 中. 如果存在一个重要基因,搜索空间就缩小了一半,即只需搜索 2^{l-1} 个个体. 一般地,若有 k 个重要基因,则搜索空间仅有 2^{l-k} 个个体.

定义 12-13 设 $\mathcal{L}$ 是一个模式, $\vec{X} = (X_1, X_2, \dots, X_N) \in S^N$ 是一个种群.

- (1) 如果对任意 $i \leq N$, 有 $X_i \in \mathcal{L}$, 称 $\vec{X}$ 包含于 $\mathcal{L}$ 中(记作 $\vec{X} \subset \mathcal{L}$);
- (2) 如果存在 $i \leq N$, 使 $X_i \in \mathcal{L}$, 称 $\vec{X}$ 与 $\mathcal{L}$ 相交非空(记作 $\vec{X} \cap \mathcal{L} \neq \emptyset$);
- (3) 如果对于任意包含 $\vec{X}$ 的模式 $\mathcal{L}$, 都有 $\mathcal{L}[\vec{X}] \subset \mathcal{L}$, 称 $\mathcal{L}[\vec{X}]$ 为包含 $\vec{X}$ 的最小模式.

定理 12-10 (1) 设 $\mathcal{L}$ 是一个模式, 则 $|\mathcal{L}| = 2^{l-O(\mathcal{L})}$.

(2) 若 $\mathcal{L}[(i_k, a_{ik}); K_1]$ 和 $\mathcal{L}[(j_k, a_{jk}); K_2]$ 为两个模式, 且满足条件:

$$\text{如果 } i_k = j_k, a_{ik} = a_{jk}$$

则

$$\mathcal{L}_1[(i_k, a_{ik}); K_1] \cap \mathcal{L}_2[(j_k, a_{jk}); K_2]$$

也是一个模式;

(3) 任给 $\vec{X} \in S^N$, $\mathcal{L}[\vec{X}]$ 必存在唯一.

证 (1) 由于模式中每个个体的取值固定的基因位置数为 $O(\mathcal{L})$, 于是, 取值变化的基因位置数为 $l - O(\mathcal{L})$, 所以 $|\mathcal{L}| = 2^{l-O(\mathcal{L})}$.

(2) 取 $I = \{q_k \mid q_k = i_k, k \leq K_1 \text{ 或 } q_k = j_k, k \leq K_2\}$, 则

$$\begin{aligned} \mathcal{L} &= \mathcal{L}[(q_k, a_k), q_k = i_k, (q_k, b_k), q_k = j_k, q_k \in I] \\ &= \mathcal{L}_1[(i_k, a_{ik}); K_1] \cap \mathcal{L}_2[(j_k, a_{jk}); K_2] \end{aligned}$$

为一个模式.

(3) 显然, 个体空间 S 包含任意 $\vec{X}$. 再由(2), 所有包含 $\vec{X}$ 的模式的交就是 $\mathcal{L}[\vec{X}]$, 即 $\mathcal{L}[\vec{X}]$ 存在唯一. $\square$

例 12-6 对于 $S = \{0, 1\}^3$, 若取 $\mathcal{L}_1 = \mathcal{L}[(2,1)]$, $\mathcal{L}_2 = \mathcal{L}[(1,1)]$, $\mathcal{L}_3 = \mathcal{L}[(2,1), (3,0)]$, 则 $|\mathcal{L}_1| = |\mathcal{L}_2| = 2^{3-1} = 4$, $|\mathcal{L}_3| = 2^{3-2} = 2$, 且

$$\mathcal{L}_1 \cap \mathcal{L}_2 = \mathcal{L}[(1,1), (2,1)] = \{(111), (110)\}$$

$$\mathcal{L}_1 \cap \mathcal{L}_3 = \mathcal{L}_3 = \{(010), (110)\}$$

由此可以看到, $\mathcal{L}_1$ 与 $\mathcal{L}_2$ 之间仅有三种情况: $\mathcal{L}_1 \cap \mathcal{L}_2 = \emptyset$; $\mathcal{L}_1 \subset \mathcal{L}_2$ 或 $\mathcal{L}_2 \subset \mathcal{L}_1$; $\mathcal{L}_1 \cap \mathcal{L}_2 \neq \emptyset$, 且 $\mathcal{L}_1$ 与 $\mathcal{L}_2$ 互不包含. 如果两个模式各自确定了一个重要基因, 则它们的交(如果非空)产生的模式即是由两个重要基因产生的模式, 搜索空间跟着缩小.

定理 12-11 设 T_s 为选择算子, T_c 为杂交算子, 而 $\mathcal{L} = \mathcal{L}[(i_k, a_{ik}), K]$ 为一个模式, $\vec{X} \subset \mathcal{L}$, 则有

$$P\{T_c \circ T_s^a(\vec{X}) \subset \mathcal{L}\} = 1$$

即

$$T_c \circ T_s^a(\vec{X}) \subset \mathcal{L}$$

特别地有

$$T_c \circ T_s^a(\vec{X}) \subset \mathcal{L}[\vec{X}]$$

证 对于任意 $(X, Y) \in \mathcal{L}, Z \notin \mathcal{L}$ 则 (X, Y) 杂交后生成 Z 的基因位置的个数

$$k = k(X, Y, Z) = 0$$

由定理 12-5 有

$$P\{T_c(X, Y) = Z\} = 0$$

进而由概率的性质和全概率公式有

$$\begin{aligned} & P\{T_c \circ T_s^a(\vec{X}) \in \mathcal{L}\} \\ &= 1 - \sum_{Z \notin \mathcal{L}} P\{T_c \circ T_s^a(\vec{X}) = Z\} \\ &= 1 - \sum_{Z \notin \mathcal{L}} \sum_{(X, Y) \in \mathcal{L}} P\{T_c(X, Y) = Z\} \cdot P\{T_s^a(\vec{X}) = (X, Y)\} \\ &= 1 \quad \square \end{aligned}$$

定理 12-3 和定理 12-11 表明,对任何种群 $\vec{X}$,选择在 $\vec{X}$ 中进行,而杂交在 $\mathcal{L}[\vec{X}]$ 中进行,杂交扩大了搜索范围.

例 12-7 对于 $S = \{0, 1\}^3$, 研究初始种群

$$\vec{X} = (X_1, X_2, X_3) = ((001), (110), (010))$$

显然

$$\mathcal{L}[\vec{X}] = \mathcal{L}[(2, 1)] = ((001), (110), (010), (111))$$

考虑在 $\vec{X}$ 杂交运算和选择运算.

X_1 和 X_2 在杂交点 2 处杂交可得到

$$X'_1 = (010) = X_3, \quad X'_2 = (111)$$

X_1 和 X_2 在杂交点 1 处杂交可得到

$$X''_1 = (010) = X_3, \quad X''_2 = (111)$$

不管怎样杂交,第二个基因位置总是 1,于是杂交结果在 $\mathcal{L}[\vec{X}]$ 中,同时也看到选择只能取 X_1, X_2 和 X_3 ,而杂交产生的(111)不在种群中,可见杂交较选择有更大的个体搜索范围.

下面研究模式在选择、杂交和变异等遗传算子作用下变化的一般情况.

记

$$\begin{aligned} C(\vec{X}, 0) &= \vec{X} \\ C(\vec{X}, k) &= T_c \circ T_s^a(C(\vec{X}, k-1)) \\ &= \{Y; \text{存在 } Y_1, Y_2 \in C(\vec{X}, k-1), \text{使得 } T_c(Y_1, Y_2) = Y\}, (k \geq 1) \end{aligned}$$

$$\mathcal{H}(\vec{X}) = \bigcup_{k=0}^{\infty} C(\vec{X}, k)$$

定理 12-12 设 $\vec{X}$ 为一种群,则

$$\mathcal{L}[\vec{X}] = \mathcal{H}(\vec{X})$$

证 由于 $\vec{X} \subset \mathcal{L}[\vec{X}]$, 于是 $C(\vec{X}, 0) \subset \mathcal{L}[\vec{X}]$. 若 $C(\vec{X}, k-1) \subset \mathcal{L}[\vec{X}]$, 由定理 12-11 知

$$C(\vec{X}, k) = T_c \circ T_s^a(C(\vec{X}, k-1)) \subset \mathcal{L}[\vec{X}]$$

于是由归纳证明即得,对任一 $k \geq 0$ 有

$$C(\vec{X}, k) \subset \mathcal{L}[\vec{X}]$$

从而

$$\mathcal{H}[\vec{X}] \subset \mathcal{L}(\vec{X})$$

反之,对于 $Y \in \mathcal{L}(\vec{X})$, 必有 $X_i \in \vec{X}$, 使得在 $\mathcal{L}(\vec{X})$ 的固定取值的每个基因位置 j 上有

$$x_{ij} = y_j$$

于是由 X_i 反复进行均匀随机杂交或单点杂交就可得到 Y . 这说明

$$\mathcal{H}[\vec{X}] \supset \mathcal{L}(\vec{X}) \quad \square$$

由定理 12-12 可知,若 $\vec{X} \cap \mathcal{L} = \emptyset$, 则 $P\{T_c \circ T_s^a(\vec{X}) \subset \mathcal{L}\} = 0$, 有下面的定理.

定理 12-13 设 T_s 为选择算子, T_c 为杂交算子, $\mathcal{L}$ 为模式, 若 $\vec{X} \cap \mathcal{L} \neq \emptyset$, 则

$$P\{T_c \circ T_s^a(\vec{X}) \subset \mathcal{L}\} > 0$$

证 由于 $\vec{X} \cap \mathcal{L} \neq \emptyset$, 不妨设 $X_i \in \mathcal{L}$, 则由定理 12-4 有

$$P\{T_c \circ T_s^a(\vec{X}) = X_i\} > 0$$

于是

$$P\{T_c \circ T_s^a(\vec{X}) \subset \mathcal{L}\} > 0 \quad \square$$

对于变异算子, 根据定理 12-5 有

$$P\{T_m(X) = Y\} = p_m^{d(X,Y)} (1 - p_m)^{l-d(X,Y)}$$

一般来说 p_m 取值较小, 于是 $d(X, Y)$ 越小, $P\{T_m(X) = Y\}$ 越大, 从而变异算子使个体在它的邻域内变化.

12.3.2 模式定理

上节通过引进模式的概念, 讨论了经选择、杂交和变异算子作用后, 个体的变化情况. 可以看到, 选择是在种群中进行的, 选择的结果仍在种群中; 杂交是在包含种群的最小模式 $\mathcal{L}(\vec{X})$ 中进行的, 杂交的结果仍在 $\mathcal{L}(\vec{X})$ 中; 变异在个体的邻域进行, 变异的结果在个体 X 的一个邻域内. 如果初始种群 X , $\mathcal{L}(\vec{X})$ 的阶数 K 很大, 则选择和杂交的结果范围很小, 仅用选择和杂交结果不可能越过 $\mathcal{L}(\vec{X})$. 变异虽然在一个个体邻域进行, 它可能越过 $\mathcal{L}(\vec{X})$, 从而扩大搜索空间, 原则上可以扩大到整个个体空间. 选择和杂交以及变异三者结合构成遗传机制.

但从以上讨论中我们还看不出有一个适应性“好”的模式, 在三种遗传运算的过程中被搜索到的搜索进程是如何变化的. Holland 最早对此问题作出了严格表述, 给出了著名的模式定理: 具有短的定义长度、低阶, 并且模式采样的平均适应值在种群平均适应值以上的模式, 随 GA 中搜索次数的增加, 将按指数增长率被采样. (具有短的定义长度、低阶、适应值高的模式被称为建筑模块)

记 $\mathcal{L}$ 为一模式, $O(\mathcal{L})$ 表示模式的阶, $\delta(\mathcal{L})$ 表示模式的长度. $\{\vec{X}(n)\}$ 表示 GA 迭代搜索序列, $\vec{X}(n) = (X_1(n), X_2(n), \dots, X_N(n))$, N 为种群规模, p_c 是杂交概率, p_m 为变异概率.

$\bar{f}_n$ 表示 $\{\vec{X}(n)\}$ 的平均适应值

$$\bar{f}_n = \frac{\sum_{i=1}^N f(X_i(n))}{N}$$

$\bar{f}_n(\mathcal{L})$ 表示 $\mathcal{L} \cap \vec{X}(n)$ 的平均适应值为

$$\bar{f}_n(\mathcal{L}) = \frac{1}{|\mathcal{L} \cap \vec{X}(n)|} \sum_{Y \in \mathcal{L} \cap \vec{X}(n)} f(Y)$$

其中, $|\mathcal{L} \cap \vec{X}(n)|$ 表示 $\mathcal{L} \cap \vec{X}(n)$ 中个体数目, $m(\mathcal{L}, n) = E[|\mathcal{L} \cap \vec{X}(n)|]$ 表示 $\mathcal{L}$ 中包含种群 $\vec{X}(n)$ 的个体数目的期望值, 则有

定理 12-13 (模式定理) 对于标准 GA, 有

$$m(\mathcal{L}, n+1) \geq m(\mathcal{L}, n) \frac{\bar{f}^n(\mathcal{L})}{\bar{f}^n} \cdot \left[1 - p_c \frac{\delta(\mathcal{L})}{l-1} - O(\mathcal{L})p_m \right] \quad (12-11)$$

注 若模式的阶数 $O(\mathcal{L})$ 和定义长度 $\delta(\mathcal{L})$ 都较小, 且模式平均适应值 $\bar{f}^n(\mathcal{L})$ 大于种群平均适应值, 使得

$$\frac{\bar{f}^n(\mathcal{L})}{\bar{f}^n} \cdot \left[1 - p_c \frac{\delta(\mathcal{L})}{l-1} - O(\mathcal{L})p_m \right] > 1$$

则由定理 12-13, $m(\mathcal{L}, n)$ 可以写为 (存在某常数 $C > 0$)

$$m(\mathcal{L}, n) = m(\mathcal{L}, 0)(1 + C)^n$$

为证定理 12-13, 需要下面四个引理.

引理 12-1 对任意随机变量 ξ, η , 若 $E|\xi| < \infty, E|\eta| < \infty$, 则

$$E[\xi] = E\{E[\xi|\eta]\}, \quad E[\eta] = E\{E[\eta|\xi]\} \quad (12-12)$$

证 对于连续型随机变量或离散型随机变量, 式 (12-12) 的证明, 可见于初等概率论的教科书; 一般情形的证明, 参见随机过程论的教科书. $\square$

引理 12-2 若 $\vec{X}(n+1) = T_s(\vec{X}(n))$, 即对 GA 搜索序列 $\{\vec{X}(n)\}$ 下一步只作选择运算, 则有

$$E[|\mathcal{L} \cap \vec{X}(n+1)|] = m(\mathcal{L}, n) \cdot \frac{\bar{f}^n(\mathcal{L})}{\bar{f}^n} \quad (12-13)$$

证 先证明

$$E[|\mathcal{L} \cap T_s(\vec{X}(n))| | \vec{X}(n)] = |\mathcal{L} \cap \vec{X}(n)| \cdot \frac{\bar{f}^n(\mathcal{L})}{\bar{f}^n} \quad (12-14)$$

事实上, 按照标准 GA, 选择过程是从种群 $\vec{X}(n)$ 中独立地选择 N 对母体, 因为我们关心的是选择的母体中是否有 $\mathcal{L}$ 中的个体, 且母体选择时是独立地选择两个个体构成一对母体, 所以在记录 N 次选择的母体中包含 $\mathcal{L}$ 中的个体总数时, 按作 N 次独立的个体选择, 记录每次选择中包含 $\mathcal{L}$ 中的个体数 (记为 ξ_i), 即

$$|\mathcal{L} \cap T_s(\vec{X}(n))| = \xi_1 + \xi_2 + \cdots + \xi_N$$

而按适应值比例选择规则有

$$E[\xi_i | \vec{X}(n)] = \frac{\sum_{Z \in \mathcal{L} \cap \vec{X}(n)} f(Z)}{\sum_{i=1}^N f(X_i(n))}$$

于是有

$$E[|\mathcal{L} \cap T_s(\vec{X}(n))| | \vec{X}(n)] = \frac{\sum_{Z \in \mathcal{L} \cap \vec{X}(n)} f(Z)}{\sum_{i=1}^N f(X_i(n))} \cdot N$$

$$\begin{aligned}
&= |\mathcal{L} \cap \vec{X}(n)| \cdot \frac{1}{|\mathcal{L} \cap \vec{X}(n)|} \cdot \frac{\sum_{Z \in \mathcal{L} \cap \vec{X}(n)} f(Z)}{\sum_{i=1}^N f(X_i(n))} \cdot N \\
&= |\mathcal{L} \cap \vec{X}(n)| \cdot \frac{\bar{f}_n(\mathcal{L})}{\bar{f}_n}
\end{aligned}$$

为证式(12-13),注意到 $\mathcal{L} \cap \vec{X}(n+1) = \mathcal{L} \cap T_s(\vec{X}(n))$, 由式(12-14)有

$$\begin{aligned}
E[|\mathcal{L} \cap T_s(\vec{X}(n))|] &= E(E[|\mathcal{L} \cap T_s(\vec{X}(n))| | \vec{X}(n)]) \\
&= E[|\mathcal{L} \cap \vec{X}(n)|] \cdot \frac{\bar{f}_n(\mathcal{L})}{\bar{f}_n} \\
&= m(\mathcal{L}, n) \cdot \frac{\bar{f}_n(\mathcal{L})}{\bar{f}_n} \quad \square
\end{aligned}$$

引理 12-3 若 $\vec{X}(n+1) = T_c \circ T_s(\vec{X}(n))$, 则有

$$E[|\mathcal{L} \cap \vec{X}(n+1)|] \geq E[|\mathcal{L} \cap T_s(\vec{X}(n))|] \cdot p_1 \quad (12-15)$$

且

$$p_1 \geq 1 - p_c \cdot \frac{\delta(\mathcal{L})}{l-1} \quad (12-16)$$

其中 p_1 为 $\mathcal{L} \cap T_s(\vec{X}(n))$ 中任一对母体经杂交后属于 $\mathcal{L}$ 的概率.

证 记 $M = |\mathcal{L} \cap T_s(\vec{X}(n))|$, 有

$$|\mathcal{L} \cap T_c \circ T_s(\vec{X}(n))| \geq \eta_1 + \eta_2 + \cdots + \eta_M \quad (12-17)$$

其中 η_i 表示 $\mathcal{L} \cap T_s(\vec{X}(n))$ 中的一个个体杂交的结果属于 $\mathcal{L}$ 的数目, 即

$$\eta_i = \begin{cases} 1 & \text{如果第 } i \text{ 个个体杂交的结果} \in \mathcal{L} \\ 0 & \text{其他} \end{cases} \quad (i = 1, 2, \dots, M)$$

设 $\mathcal{L} = \mathcal{L}[(i_k, a_{ik}), 1 \leq k \leq K]$, 根据单点杂交是等可能地在 $1, 2, \dots, l-1$ 等位置确定一个杂交点, 再依概率 p_c 进行杂交的规则, 如果与第 i 个个体作杂交的另一个个体也属于 $\mathcal{L}$, 则杂交结果必然仍属于 $\mathcal{L}$; 如果只有第 i 个个体属于 $\mathcal{L}$, 则第 i 个个体经杂交后不属于 $\mathcal{L}$ 的最大概率为 $p_c \cdot \frac{\delta(\mathcal{L})}{l-1}$ (这里假定 $i_1 = 1$). 所以, 第 i 个个体经杂交后属于 $\mathcal{L}$ 的概率 p_1

至少为 $1 - p_c \cdot \frac{\delta(\mathcal{L})}{l-1}$, 即

$$p_1 \geq 1 - p_c \cdot \frac{\delta(\mathcal{L})}{l-1}$$

且

$$E[\eta_i] = p_1 \quad (i = 1, 2, \dots, M)$$

于是, 由式(12-17)有

$$\begin{aligned}
&E[|\mathcal{L} \cap T_c \circ T_s(\vec{X}(n))| | \mathcal{L} \cap T_s(\vec{X}(n))] \\
&\geq |\mathcal{L} \cap T_s(\vec{X}(n))| \cdot p_1
\end{aligned}$$

进而,由引理 12-1 得到

$$\begin{aligned} & E[|\mathcal{L} \cap T_c \circ T_s(\vec{X}(n))|] \\ &= E\{E[|\mathcal{L} \cap T_c \circ T_s(\vec{X}(n))| | \mathcal{L} \cap T_s(\vec{X}(n))]\} \\ &\geq E[|\mathcal{L} \cap T_s(\vec{X}(n))|] \cdot p_1 \quad \square \end{aligned}$$

引理 12-4 若 $\vec{X}(n+1) = T_m \circ T_c \circ T_s(\vec{X}(n))$, 则有

$$E[|\mathcal{L} \cap \vec{X}(n+1)|] \geq E[|\mathcal{L} \cap T_c \circ T_s(\vec{X}(n))|] \cdot p_2 \quad (12-18)$$

且

$$p_2 \geq (1 - p_m)^{O(\mathcal{L})} \quad (12-19)$$

其中 p_2 为 $\mathcal{L} \cap T_c \circ T_s(\vec{X}(n))$ 中任一个体经变异后属于 $\mathcal{L}$ 的概率.

证 设 $\mathcal{L} = \mathcal{L}[(i_k, a_{ik}), 1 \leq k \leq K]$, 因变异是各基因位置独立地依概率 p_m 进行变异, 设 $X \in \mathcal{L} \cap T_c \circ T_s(\vec{X}(n))$, 则 X 在模式固定位置的基因不变的概率为 $(1 - p_m)^{O(\mathcal{L})}$, 所以 X 经变异后仍属于 $\mathcal{L}$ 的概率为

$$p_2 \geq (1 - p_m)^{O(\mathcal{L})}$$

另外,与引理 12-3 的证明类似,可证式(12-18). $\square$

定理 12-5 的证明如下:

由引理 12-1 ~ 12-4 有

$$\begin{aligned} & E[|\mathcal{L} \cap \vec{X}(n+1)|] \\ &= E[|\mathcal{L} \cap T_m \circ T_c \circ T_s(\vec{X}(n))|] \\ &= E\{E[|\mathcal{L} \cap T_m \circ T_c \circ T_s(\vec{X}(n))| | \mathcal{L} \cap T_c \circ T_s(\vec{X}(n))]\} \\ &\geq E[|\mathcal{L} \cap T_c \circ T_s(\vec{X}(n))|] \cdot p_2 \quad (\text{引理 12-4}) \\ &= \{E[|\mathcal{L} \cap T_c \circ T_s(\vec{X}(n))| | \mathcal{L} \cap T_s(\vec{X}(n))]\} \cdot p_2 \\ &\geq E[|\mathcal{L} \cap T_s(\vec{X}(n))|] \cdot p_1 \cdot p_2 \quad (\text{引理 12-3}) \\ &= E\left[|\mathcal{L} \cap \vec{X}(n)| \cdot \frac{\bar{f}_n(\mathcal{L})}{\bar{f}_n}\right] \cdot p_1 \cdot p_2 \quad (\text{引理 12-2}) \\ &= m(\mathcal{L}, n) \cdot \frac{\bar{f}_n(\mathcal{L})}{\bar{f}_n} \cdot p_1 \cdot p_2 \end{aligned}$$

另外,由于 $p_m \ll 1$, 所以近似地有 $(1 - p_m)^{O(\mathcal{L})} = 1 - O(\mathcal{L}) \cdot p_m$, 即

$$p_2 \geq 1 - O(\mathcal{L}) \cdot p_m$$

联合式(12-16)有

$$p_1 \cdot p_2 \geq \left(1 - p_c \cdot \frac{\delta(\mathcal{L})}{l-1}\right) (1 - O(\mathcal{L}) \cdot p_m) \geq \left(1 - p_c \cdot \frac{\delta(\mathcal{L})}{l-1} - O(\mathcal{L}) \cdot p_m\right)$$

于是得到式(12-11). $\square$

虽然模式定理在一定意义上揭示了标准 GA 的有效性,但它还存在以下缺点:

- (1) 模式定理仅适用于基于二进制编码的标准 GA, 对其他编码方式, 此定理未必成立;
- (2) 模式定理仅提供一个期望值的下界, 仍不能说明算法的收敛性;
- (3) 模式定理对算法参数的选取不能提供实用的指导.

下节用马氏链模型来讨论 GA 的收敛性.

在本节结束之前,我们不加证明地给出 GA 理论中一个重要的定理.

定理 12-14 (隐含并行性定理) 设 ε 为一小正数, $l_s < \varepsilon(l-1)$, $N = 2^{\frac{l_s}{2}}$, 则标准 GA 一次处理(选择、杂交、变异)的定义长度不大于 l_s 、模式中固定位置数不降低的概率不小于 $1 - \varepsilon$ 的这种模式数为 $O(N^3)$.

此定理说明标准 GA 表面上每代仅对 N 个个体作处理,但实际上并行处理了约 $O(N^3)$ 个模式,并且无需额外的存储,这正是 GA 具有高效搜索能力的原因所在.

12.4 遗传算法的收敛性分析

本节将用马氏链模型来分析 GA 的收敛性. 在 11.2 节介绍的马氏链有关概念的基础上,还将介绍马氏链收敛性分析的几个简单事实,进而介绍标准 GA 及其改进的收敛性.

12.4.1 矩阵序列的收敛性与马氏链

定义 12-14 一个方阵 $A \in R^{n \times n}$ 称为:

- (1) 非负的(记作 $A \geq 0$), 如果 $a_{ij} \geq 0, i, j \in \{1, 2, \dots, n\}$;
- (2) 全正的(记作 $A > 0$), 如果 $a_{ij} > 0, i, j \in \{1, 2, \dots, n\}$;
- (3) 本原的, 如果 A 非负且存在一个整数 $k \geq 1$ 使得 $A^k > 0$;
- (4) 归约的, 如果 A 非负且经过相同的行和列初等变换可得到如下形式

$$\begin{pmatrix} C & 0 \\ R & T \end{pmatrix},$$

其中 C 和 T 皆为方阵;

- (5) 不可约的, 如果 A 非负且不是归约的;
- (6) 随机的, 如果 A 非负且每行之和为 1;
- (7) 稳定的, 如果 A 是随机的且所有行相同, 即每一列中的元素全部相同;
- (8) 列容的, 如果 A 是随机的且每一列中至少有一个元素为正数.

下面的几个关于矩阵非负和收敛性的事实是本节讨论 GA 收敛性的基础.

引理 12-5 若 C, M 和 V 是随机的, 且 $M > 0, V$ 是列容的, 则 $CMV > 0$.

证 记 $A = CM, B = AV$. 因为 C 是随机的, 则 C 的每一行中至少有一个正元素, 而 $M > 0$, 所以

$$a_{ij} = \sum_{k=1}^n c_{ik} m_{kj} > 0, \quad \forall i, j \in \{1, 2, \dots, n\}$$

即 $A > 0$. 又因为 V 是列容的, 有

$$b_{ij} = \sum_{k=1}^n a_{ik} v_{kj} > 0, \quad \forall i, j \in \{1, 2, \dots, n\} \quad \square$$

引理 12-6 若 P 是本原随机阵, 则 P^k 收敛到一个全正稳定随机阵, 即

$$P^\infty = \lim_{k \rightarrow \infty} P^k = (1, 1, \dots, 1)^T (\pi_1, \pi_2, \dots, \pi_n)$$

其中 $\pi_j = \lim_{k \rightarrow \infty} p_{ij}^{(k)} (i = 1, 2, \dots, n)$ 且 $(\pi_1, \pi_2, \dots, \pi_n)$ 是方程

$$\begin{cases} \pi_j = \sum_{i=1}^n \pi_i p_{ij} & (j = 1, 2, \dots, n) \\ \sum_{i=1}^n \pi_i = 1 \end{cases}$$

的唯一解.

注 (1)引理 12-6 的事实,用马氏链的术语可表述为:有限状态的不可约非周期链

$$\xi = \{\xi_k, k \in \mathbb{Z}^+\}$$

存在极限分布, $\pi_j = \lim_{k \rightarrow \infty} p_{ij}^{(k)} = \lim_{k \rightarrow \infty} P\{\xi_k = j\}$ ($i = 1, 2, \dots, n$), 它是 P 的唯一的平稳分布(参见定理 11-2 和定理 11-9 及其注).

证 利用定理 11-1 和定理 11-2, 此事实显然, 证明留作习题. $\square$

引理 12-7 设 $P = \begin{pmatrix} C & 0 \\ R & T \end{pmatrix}$ 为随机阵, 其中 C 为一个 $m \times m$ 的全正随机阵, R 的每一行中至少有一个非零元素, 则

$$P^\infty = \lim_{k \rightarrow \infty} P^k = \lim_{k \rightarrow \infty} \begin{pmatrix} C^k & 0 \\ \sum_{i=0}^{k-1} T^i R C^{k-i} & T^k \end{pmatrix} = \begin{pmatrix} C^\infty & 0 \\ R_\infty & 0 \end{pmatrix}$$

是一个稳定的随机阵, 且满足

$$\begin{cases} P^\infty = \lim_{k \rightarrow \infty} P^k = (1, 1, \dots, 1)^T (\pi_1, \pi_2, \dots, \pi_n) \\ \sum_{i=1}^n \pi_i = 1, \pi_i > 0 \quad (1 \leq i \leq m), \pi_i = 0 \quad (m+1 \leq i \leq n) \\ \pi_j = \lim_{k \rightarrow \infty} p_{ij}^{(k)} \quad (j = 1, 2, \dots, n) \end{cases}$$

其中 $R_\infty = \lim_{k \rightarrow \infty} \sum_{i=0}^{k-1} T^i R C^{k-i}$.

证 参见参考文献[44].

注 引理 12-7 用马氏链的术语可表述为:有限状态的马氏链如果有唯一不可约非周期的真闭子集 M , 它的转移概率矩阵为 $C = (c_{ij})_{m \times m}$, 记子链 M 的唯一平稳分布(也是极限分布)为 $\pi = (\pi_1, \pi_2, \dots, \pi_m)$, 则

$$P^\infty = \lim_{k \rightarrow \infty} P^k = \begin{pmatrix} 1^T \cdot \pi & 0 \\ F \otimes \pi & 0 \end{pmatrix}$$

其中 $1 = (1, 1, \dots, 1)$, $F \otimes \pi = (f_{ij} \pi_j)_{(n-m) \times m}$, 而 $f_{ij} = \sum_{n=1}^{\infty} f_{ij}^{(n)}$ (参见 11.2 节).

现在转入对标准 GA 的收敛性分析.

我们知道, 以 l 个个体构成的规模为 N 的种群空间

$$S^N = \{\vec{X} = (X_1, X_2, \dots, X_N) \mid X_i \in S, i = 1, 2, \dots, N\}$$

而对 $X \in S$, 如果是 0-1 编码, 则 $X = (a_1, a_2, \dots, a_l)$, $a_j = 0, 1$ ($1 \leq j \leq l$), 这时 S^N 为有限集, 共有 $|S|^N = 2^N$ 个元素. 由于 GA 在种群空间上进行选择、杂交和变异操作, 每次操作都把一个种群变为另一个种群, 且每次操作把目前种群 $\vec{X}_i$ 变为种群 $\vec{X}_j$ 的概率只与 $\vec{X}_i$ 有关, 而与以前遗传操作的结果无关, 也与进行的遗传操作是哪一次无关(详见定理 12-3、定理 12-5

和定理 12-7), 所以如果将这种遗传操作看成是马氏链状态的转移, 则 GA 就对应一个时齐的有限状态的马氏链 ξ , 其状态空间为 $\Omega = S^N$. 共有 $|S|^N$ 个状态, 每个状态是长度为 $N \cdot l$ 的字符串. GA 的收敛性的讨论, 就归结为 ξ 的遍历性(收敛性)的讨论, 进而又归结为 ξ 的一步转移概率矩阵是否满足马氏链遍历性的充分条件.

下面, 先分别讨论选择、杂交和变异操作确定的马氏链的一步转移概率矩阵.

(1) 选择算子. 一次选择算子确定的马氏链的一步转移概率矩阵 $V = (v_{ij})_{|\Omega| \times |\Omega|}$ 是列容的.

如果能证明 $v_{ii} > 0$, 则 V 就是列容的. 事实上, 对任意 $i = (X_1, X_2, \dots, X_N)$, 标准 GA 的选择是在 $\{X_1, X_2, \dots, X_N\}$ 中按适应值比例选取的, 即 i 的任一分量 X_j 被选取的概率为

$$\frac{f(X_j)}{\sum_{k=1}^N f(X_k)} > 0$$

从而 i 被一次选择算法选到的概率为

$$v_{ii} = \prod_{j=1}^N \frac{f(X_j)}{\sum_{k=1}^N f(X_k)} > 0$$

(2) 杂交算子. 一次杂交运算确定的马氏链的一步转移概率矩阵 $C = (c_{ij})_{|\Omega| \times |\Omega|}$ 是随机的.

事实上, 对任意 $i = (X_1, X_2, \dots, X_N)$, 无论进行何种杂交, 总是把 $X_1, X_2, \dots, X_N$ 变成 $Y_1, Y_2, \dots, Y_N \in S$, 当 $(Y_1, Y_2, \dots, Y_N)$ 取遍 $\Omega = S^N$ 时, 就有

$$c_{ij} \geq 0, \quad i, j \in \{1, 2, \dots, |\Omega|\}, \quad \sum_{j=1}^{|\Omega|} c_{ij} = 1, \quad \forall i \in \Omega$$

(3) 变异算子. 一次变异运算确定的马氏链的一步转移概率矩阵 $M = (m_{ij})_{|\Omega| \times |\Omega|}$ 是全正的.

事实上, 对任意 $i, j \in \Omega$, 设

$$i = (x_{11}x_{12}\cdots x_{1l}x_{21}x_{22}\cdots x_{2l}\cdots x_{N1}x_{N2}\cdots x_{Nl})$$

$$j = (y_{11}y_{12}\cdots y_{1l}y_{21}y_{22}\cdots y_{2l}\cdots y_{N1}y_{N2}\cdots y_{Nl})$$

记 p_m 为变异概率 ($0 < p_m < 1$), 记 H_{ij} 为这两个字符串对应位置上元素相同的位置总数, 则

$$m_{ij} = p_m^{(Nl-H_{ij})} (1 - p_m)^{H_{ij}} > 0$$

注 (1) 由以上对选择、杂交及变异算子确定的马氏链的一步转移概率矩阵的分析结果, 利用引理 12-5, 可以知道 GA 对应的马氏链的一步转移概率矩阵 $P = CMS$ 是全正的, 再由引理 12-6 及其注, 知道该马氏链为不可约非周期链的有唯一的极限分布(平稳分布)存在.

(2) 以上直观分析的实质是为了说明标准 GA 对应的马氏链为时齐不可约非周期的. 事实上, 由定理 12-3、定理 12-5 和定理 12-7, 可以看到马氏链是时齐的, 而由定理 12-8 又可看出是不可约非周期的.

12.4.2 标准遗传算法的收敛性分析

定义 12-15 设优化问题是要求目标函数 $f(x)$ 达到最大 ($x \in D$). 令

$$Z_t = \max \{f(X_j(t)) \mid j = 1, 2, \dots, N\}$$

记 $\vec{X}(t) = (X_1(t), X_2(t), \dots, X_N(t))$ 为 GA 第 t 代的一个种群. 如果

$$\lim_{t \rightarrow \infty} P\{Z_t = f^*\} = 1$$

其中, $f^* = \max \{f(x) \mid x \in D\}$, 称一个 GA 收敛到全局最优.

由于标准 GA 总是按选择—杂交—变异循环进行的, 但显然调换杂交和变异的执行次序不会影响搜索结果, 所以, 不失一般性, 在以下讨论中, 我们把执行一次 GA 按执行一遍选择—变异—杂交来讨论.

定理 12-15 设 GA 的参数满足: 变异概率 $0 < p_m < 1$, 杂交概率 $0 \leq p_c \leq 1$, 则标准 GA 不收敛到全局最优.

证 设 $i = (X_1, X_2, \dots, X_N)$, 使 $\max \{f(X_j) \mid j = 1, 2, \dots, N\} < f^*$, 记 $p_i(t) = P\{\xi_t = i\}$ 为状态 i 出现的概率, 则

$$P\{Z_t = f^*\} \leq 1 - p_i(t)$$

另外, 由以上对选择、杂交、变异确定的马氏链的一步转移概率矩阵的讨论, 利用引理 12-5 和引理 12-6 及其注, 我们知道

$$\lim_{t \rightarrow \infty} p_i(t) = \pi_i > 0$$

从而

$$\lim_{t \rightarrow \infty} P\{Z_t = f^*\} \leq 1 - \lim_{t \rightarrow \infty} p_i(t) = 1 - \pi_i < 1 \quad \square$$

定理 12-15 说明, 标准 GA 不收敛到全局最优, 但只要对标准 GA 作简单改动, 每次记录当前最优解并在种群状态向量加一分量位置存放它, 且要求下次遗传操作所得的最优解要比当前最优解“好”(目标值大), 则 GA 收敛到全局最优.

先来讨论这样的改进算法所对应的马氏链的一步转移概率矩阵. 标准算法时, 一步转移概率矩阵为 $P = CMV = (p_{ij})_{|\Omega| \times |\Omega|}$, 第 t 代搜索的结果为 $\vec{X}(t) = (X_1(t), X_2(t), \dots, X_N(t))$, 现在加上一个分量 $X^*(t-1)$, 它表示第 t 次搜索之前所得的最优解, 此时, 状态向量改为

$$\vec{Y}(t) = (X^*(t-1), X_1(t), X_2(t), \dots, X_N(t))$$

这时新马氏链 ξ^* 的状态空间为 $\Omega^* = S^{N+1}$, 共有 $|S|^{N+1}$ 个状态, 每个状态是长度为 $(N+1) \cdot l$ 的字符串, 马氏链的一步转移概率矩阵阶数也由原来的 $|\Omega| = |S|^N$ 变为 $|\Omega^*| = |S|^{(N+1)}$. 设在标准 GA 时的一步转移概率矩阵对应的形如

$$i = \vec{X} = (X_1, X_2, \dots, X_N) = (x_{11}x_{12} \cdots x_{1l}x_{21}x_{22} \cdots x_{2l} \cdots x_{N1}x_{N2} \cdots x_{Nl})$$

状态的排列顺序为

$$(i_1, i_2, \dots, i_{|S|^N})$$

新加分量 $z \in S$ 按其目标值从“好”(大)到“坏”(小)排列为

$$(z_1, z_2, \dots, z_{|S|})$$

亦即

$$f(z_1) \geq f(z_2) \geq \cdots \geq f(z_{|S|})$$

我们约定用

$$((z_1, i_k), 1 \leq k \leq |S|^N; (z_2, i_k), 1 \leq k \leq |S|^N; \cdots; (z_{|S|}, i_k), 1 \leq k \leq |S|^N)$$

作为 $\Omega^* = S^{N+1}$ 中状态的一个排列, 相应的一步转移概率矩阵记为

$$P^* = (p_{ij}^*)_{|\Omega^*| \times |\Omega^*|}$$

对这样排列的状态顺序,因新加的放在第一位的个体不参与遗传运算,利用原来 GA 对应矩阵 C, M, S ,我们先定义

$$\begin{aligned} C^+ &= \text{diag}(C, C, \dots, C) \\ M^+ &= \text{diag}(M, M, \dots, M) \\ V^+ &= \text{diag}(V, V, \dots, V) \end{aligned}$$

其中各对角矩阵中各有 $|S|$ 个 C, M, V .

另外,用 U 表示第一个记忆位(记录到的最优值)的转移矩阵,由于状态排序按第一位个体的目标值从大到小排列的原因, U 具有以下形式:

$$U = \begin{pmatrix} U_{11} & 0 & 0 & 0 \\ U_{21} & U_{22} & 0 & \\ \vdots & \vdots & \ddots & 0 \\ U_{|S|1} & U_{|S|2} & \dots & U_{|S||S|} \end{pmatrix}$$

其中 U_{ij} 是一个 $|\Omega| \times |\Omega|$ 阶矩阵, $i, j = 1, 2, \dots, |S|$. 它表示从目标值低的记录到目标值高的记录的转移概率.

具体地说,为记录第一个记忆位的转移情况,在一步转移中,在还未进行遗传操作之前,从状态 $\vec{Y}(t) = (X^*(t-1), X_1(t), X_2(t), \dots, X_N(t))$ 到

$$\vec{Y}(t+1) = (X^*(t), X_1(t+1), X_2(t+1), \dots, X_N(t+1))$$

的转移概率为

$$\begin{aligned} &P(\vec{Y}(t+1) | \vec{Y}(t)) \\ &= \begin{cases} 1 & \text{若 } \max\{f(X(t)), f(X_2(t)), \dots, f(X_N(t))\} = f(X^*(t)), \\ & \text{且 } (X_1(t), X_2(t), \dots, X_N(t)) = (X_1(t+1), X_2(t+1), \dots, X_N(t+1)); \\ 1 & \text{若 } \max\{f(X_1(t)), f(X_2(t)), \dots, f(X_N(t))\} < f(X^*(t)), \\ & \text{且 } (X_1(t), X_2(t), \dots, X_N(t)) = (X_1(t+1), X_2(t+1), \dots, X_N(t+1)); \\ & \text{且 } X^*(t) = X^*(t-1); \\ 0 & \text{其他.} \end{cases} \end{aligned}$$

例如, $U_{ij} = (U_{rs}^{(ij)})_{|\Omega| \times |\Omega|}$ (其中 $i \geq j$), 它是马氏链 ξ^* 从状态 $r = (z_i, X_1, X_2, \dots, X_N)$ 到状态 $s = (z_j, Y_1, Y_2, \dots, Y_N)$ 的转移概率(未经遗传操作之前). 记

$$F(r) = \max\{f(X_1), f(X_2), \dots, f(X_N)\}$$

$$\text{则 } U_{rs}^{(ij)} = \begin{cases} 1 & \text{如果 } F(r) = f(z_j), \text{ 并且 } (X_1, X_2, \dots, X_N) = (Y_1, Y_2, \dots, Y_N) \\ 1 & \text{如果 } F(r) < f(z_j), \text{ 并且 } (z_i, X_1, X_2, \dots, X_N) = (z_j, Y_2, \dots, Y_N) \\ 0 & \text{否则} \end{cases}$$

于是,由于 U_{11} 所对应的第 1 分量为 z_1 , 它已是目标最大值 $f(z_1) = \max_{x \in D} f(x)$, 设

$$r = X = (z_1, X_1, X_2, \dots, X_N) \in \Omega$$

由于此时总有 $F(r) \leq f(z_1)$, 按 U_{11} 的定义, U_{11} 的对角元素为 1, 其余元素必为 0, 即 U_{11} 必然为 $|\Omega|$ 阶单位阵. 同理, U 的每一行恰有一个 1. 于是我们得到改进标准 GA 对应的马氏链的转移概率矩阵为

$$P^+ = C^+ M^+ V^+ U$$

$$\begin{aligned}
 &= \begin{pmatrix} CMV & & & \\ & CMV & & \\ \vdots & \vdots & \ddots & \\ & & \cdots & CMV \end{pmatrix} \begin{pmatrix} U_{11} & 0 & 0 & 0 \\ U_{21} & U_{22} & 0 & \\ \vdots & \vdots & \ddots & 0 \\ U_{|S|1} & U_{|S|2} & \cdots & U_{|S||S|} \end{pmatrix} \\
 &= \begin{pmatrix} CMVU_{11} & & & \\ CMVU_{21} & CMVU_{22} & & \\ \vdots & \vdots & \ddots & \\ CMVU_{|S|1} & CMVU_{|S|2} & \cdots & CMVU_{|S||S|} \end{pmatrix}
 \end{aligned}$$

定理 12-16 设标准 GA 按选择—杂交—变异进行的过程中,记录并更新当前最优解的改进 GA 收敛到全局最优.

证 记转移概率矩阵

$$\begin{aligned}
 P^+ &= \begin{pmatrix} CMVU_{11} & & & \\ CMVU_{21} & CMVU_{22} & & \\ \vdots & \vdots & \ddots & \\ CMVU_{|S|1} & CMVU_{|S|2} & \cdots & CMVU_{|S||S|} \end{pmatrix} \\
 &= \begin{pmatrix} CMVU_{11} & 0 \\ R & T \end{pmatrix}
 \end{aligned}$$

则由 $P = CMV$ 全正,知 $CMVU_{11}$ 全正,且

$$R = \begin{pmatrix} CMVU_{21} \\ CMVU_{31} \\ \vdots \\ CMVU_{|S|1} \end{pmatrix}, \quad T = \begin{pmatrix} CMVU_{22} & & \\ \vdots & \ddots & \\ CMVU_{|S|2} & \cdots & CMVU_{|S||S|} \end{pmatrix}$$

其中 R 的每一行中至少有一个非零元素.

• 利用引理 12-7 及其注,包含最优值状态的子链(以 $CMVU_{11}$ 为转移概率矩阵)有极限分布,即改进标准 GA 收敛到的所有最优状态的概率之和为 1,亦即算法收敛全局到最优. $\square$

12.5 遗传算法的技术实现

GA 同模拟退火算法一样,要能成功运用还有具体实现的技术问题,主要包括确定问题的编码方案、确定适应值函数、遗传算子的设计、算法参数的选取(比如种群规模、交叉和变异的概率、进化代数等)以及确定算法终止条件等.

12.5.1 编码方案的确定

按 GA 的计算流程,当用 GA 求解问题时,必须在目标问题实际表示与 GA 的染色体串结构之间建立联系,即确定编码和解码运算.实际运用中,大多数问题都可以采用基因呈一维排列的定长染色体表现形式,尤其是 0-1 二进制编码形式.然而,编码的策略或方法对于

遗传算子,尤其是杂交和变异算子的功能和设计有很大的影响.

对于编码策略的选择,一般要满足以下三个原则:

- (1) 完备性(completeness):问题的每个可行解都是 GA 编码后群体的一个个体(染色体串);
- (2) 健全性(soundness):GA 编码后群体中每个个体都对应问题某一可行解;
- (3) 非冗余性(non-redundancy):染色体与可行解一一对应.

按照 GA 的模式定理,De Jong 提出了较为客观明确的两条编码规则:

- (1) 有意义建筑模块编码规则:编码应当易于生成所求问题的阶数低、定义长度短的模式;
- (2) 最小字符集编码规则:编码应采用最小字符集以使问题得到自然、简单的表达.

下面举例来说明.

例 12-8 0-1 背包问题:

$$\begin{cases} z = \max \sum_{i=1}^n c_i x_i \\ \text{s. t. } \sum_{i=1}^n c_i x_i \leq b \\ x_i \in \{0, 1\} \end{cases}$$

此问题的解是 0-1 向量,1 表示装包,0 表示不装. 于是,可以按 $(x_1, x_2, \dots, x_n)$ 的取值形成一个自然编码. 这样的编码很直观且易于 GA 的运算.

再看 n 城市 TSP. 若采用二进制编码,商人走 (i, j) 弧,则 $x_{ij} = 1$, 否则 $x_{ij} = 0$, 这样每个解对应的个体为长度为 $n \times (n-1)$ 的 0-1 字符串,群体 $S = \{0, 1\}^{n \times (n-1)}$, 共有 $2^{n \times (n-1)}$ 个个体. 但对于 TSP 来讲,可以用城市间的排列来表示可行解,当确定一个城市为始终点时,可行解的个数为 $(n-1)!$. 若用 0-1 编码,计算过程中只有极小的比例 $\frac{2^{n \times (n-1)}}{(n-1)!}$ 为可行解. 大量浪费计算时间.

然而,对城市间的排列来表示可行解的编码策略,杂交算子会跑出群体. 比如 $n=8$; 取 $\vec{X}_1 = (14562387)$, $\vec{X}_2 = (56327841)$, 取杂交点为 6, 则

$$\begin{matrix} X_1 = (145623 | 87) \\ X_2 = (562378 | 41) \end{matrix} \longrightarrow \begin{cases} Y_1 = (145623 | 41) \\ Y_2 = (563278 | 87) \end{cases}$$

可见,杂交后的两个后代都不再是可行解.

非 0-1 编码称为非常规编码,非常规编码往往与具体问题紧密关联,更多编码的例子,特别是当解为非整数时的编码问题讨论可参见参考文献[44]. 编码问题讨论中有这样一种观点:虽然 GA、模拟退火算法等是具有通用性的全局优化算法,如果不针对问题设计算法,其计算可能耗费大量的时间;可以通过对问题的了解而换取计算时间的节省. 这正是目前被一些学者接受的“没有免费午餐”的观点.

12.5.2 遗传算法的性能评估

GA 的模式理论,只讨论模式进化趋势;马氏链收敛性分析,只是给出以概率 1 收敛的条件,实际计算时总是执行有限次遗传运算. 另外,GA 的性能与诸多因素有关,针对求解的

同一优化问题,不同的参数设置、编码的策略、遗传算子的确定、终止条件的确定等,如何进行性能比较呢?

对于搜索类算法的性能评估,一般可以归纳为算法的求解效率和求解质量两个方面.算法的求解效率是比较获得同样的可行解所需的计算时间;算法的求解质量是在规定的时间内(或者时间相关指标)所获得的可行解的优劣.这里介绍常用或通用的两个指标.

12.5.2.1 适应值函数的计算次数

该指标是指发现同样适应性的个体或者找到同样质量的可行解所需要的关于个体评价的适应值函数的计算次数.显然该值越小说明相应 GA 的搜索效率越高.同样,在预定的适应值函数计算次数的情况下,比较发现的最佳个体或者找到的可行解的质量也可以判断不同 GA 的搜索能力.

该指标还可以用于将 GA 同其他搜索算法相比较.

12.5.2.2 在线和离线性能函数

De Jong 在将 GA 用于一组优化函数求解的比较分析时,提出了 GA 在线评价指标和离线评价指标.

1. 在线性能函数(On-line Performance)

设 GA 的遗传策略为 s (包括 l, N, p_c, p_m , 遗传算子等), 该遗传策略的在线性能定义为

$$V_{\text{on-line}}(s) = \frac{1}{n(T+1)} \sum_{t=0}^T \sum_{j=1}^n f(x_j, t) \quad (12-19)$$

即在线性能反映了群体平均适应值经下滑处理后的变化情况,描述了群体的整体性状和进化能力.

2. 离线性能函数(Off-line Performance)

该遗传策略的离线性能定义为

$$V_{\text{off-line}}(s) = \frac{1}{T+1} \sum_{t=0}^T f(x^*, t) \quad (12-20)$$

其中 $f(x^*, t) = \max \{ f(x_1), f(x_2), \dots, f(x_n) \}$, 即当前群体中最佳个体的适应值. 该指标反映了群体中最佳个体适应值经平滑处理后的变化情况,描述了个体的进化能力和 GA 的搜索能力.

关于上述适应值的平滑处理,也可以通过赋予进化过程中各代不同的权重,改变适应值的加权平均计算,以消除初始种群带来的误差.

12.5.3 初始参数的选取和停止原则

1. 种群规模的确定

由定理 12-14 知,当 $l_s < \varepsilon(l-1)$ 时,标准 GA 会同时处理定义长度不大于 l_s 的模式约 $O(N^3)$ 个,其中 $N = 2^{\frac{l_s}{2}}$. 可见,种群规模选取合适会明显提高搜索效率,取种群规模 N 为个体长度(编码长度) l 的一个线性倍数是实际应用中经常采用的方法之一,比如, N 为在 l 和 $2l$ 之间的一个定数.

种群规模的选取也可以是变化的. 直观地,当经多次进化式(12-20)的值没有明显改进,保持现有的种群规模也很难改进,此时可扩大种群的规模;反之,若解的改进非常好,则可以减少种群的规模以便加快计算速度.

2. 初始种群的确定

初始种群中的个体一般是随机产生的. 在不具有关于问题解空间的先验知识的情况下, 很难判定最优解的数量及其在可行解空间的分布状况. 因此我们往往希望在问题解空间均匀采样, 随机产生一定数目(种群规模的 2 倍)的个体, 然后挑出较好的个体构成初始种群. 对于二进制编码, 染色体的位串上每一位基因在 $\{0, 1\}$ 上随机均匀选择, 所以种群初始化至少需要 $l \times N$ 次随机取值.

另外, 对于带约束的问题, 还需要判定随机初始化位串所对应的参数点是否在可行域内, 所以一般还得借助于问题可行域的知识.

3. 终止循环的条件

关于 GA 迭代过程如何终止的问题, 一般采用设定最大进化代数的方法. 该方法简单易行但不准确. 其次, 可以根据种群的收敛程度来判断, 通过计算种群中的基因多样性程度及所有基因位的相似性程度来进行控制, 根据算法的离线性能和在线性能的变化进行判定(即一次迭代改进的程度是否已经不大).

12.5.4 控制参数的选取和进化技术

12.5.4.1 适应值函数

由于适应值是群体中个体生存机会选择的唯一确定性指标, 所以适应函数的形式直接决定着群体的进化行为. 为了能够直接将适应函数与群体中个体优劣度量相联系, 在 GA 中适应值规定为非负, 并且在任何情况下总是希望越大越好. 这里介绍几种简单的适应函数的取法.

1. 简单适应函数

因目标函数的值有正有负, 甚至可能取复数值, 所以需要通过建立适应函数与目标函数的映射关系, 保证映射后的适应函数值是非负的, 而且目标函数的优化方向应对应于适应值增大方向. 简单适应函数是目标函数的简单变形. 若 $g(x)$ 为目标函数, 则适应函数 $f(x)$ 可以如下简单选取.

对于目标最大化问题, 令

$$f(x) = \begin{cases} g(x) - C_{\min} & \text{如果 } g(x) - C_{\min} > 0 \\ 0 & \text{其他} \end{cases}$$

其中 $C_{\min}$ 可以是一个特定的输入值或是理论上 $g(x)$ 的最小值.

对于目标最小化问题, 令

$$f(x) = \begin{cases} C_{\max} - g(x) & \text{如果 } C_{\max} - g(x) > 0 \\ 0 & \text{其他} \end{cases}$$

其中 $C_{\max}$ 可以是一个特定的输入值或是理论上 $g(x)$ 的最大值.

有时, 采用这种简单适应函数可能会出现各个体适应值差别很小的情形, 此时由其确定的概率分布接近均匀分布, 难以确定哪个个体占优.

2. 非线性加速适应函数

例如, 对优化问题 $z = \max_{x \in [0.5, 1]} g(x) = \max_{x \in [0.5, 1]} \{l + \ln x\}$, 若采用如上的简单适应函数, 则各个体适应值差别很小. 考虑到适应函数同目标函数有相同的变化趋势, 且变化得更快, 取

$$f(x) = \begin{cases} \frac{1}{1-x} & 0.5 < x < 1 \\ M & x \geq 1 \end{cases}$$

其中, M 是取定的一个充分大的正数.

用这个适应函数会看到个体的适应值有较大的差别. 但是要构造这样的适应函数需要对问题有较深入的了解, 比如, 对此问题我们知道 $x=1$ 是问题的最优解, 这一般来讲是不容易的.

一个有效且简便的方法是根据已有的信息构造适应函数. 如对目标最大化问题, 取

$$f(x) = \begin{cases} \frac{1}{g_{\max} - g(x)} & g(x) < g_{\max} \\ M & g(x) = g_{\max} \end{cases}$$

其中 M 是一个充分大的正数, $f_{\max}$ 是当前的最优目标值.

3. 线性加速适应函数

把根据已有的信息构造适应函数的思想进一步系统化可得到线性加速适应函数. 线性加速适应函数的一般形式为

$$f(x) = \alpha g(x) + \beta$$

对于目标最大化问题, 上式中的 α, β 按如下方程确定

$$\begin{cases} \alpha \frac{\sum_{i=1}^m g(x_i)}{m} + \beta = \frac{\sum_{i=1}^m g(x_i)}{m} \\ \alpha \max_{1 \leq i \leq m} \{g(x_i)\} + \beta = M \frac{\sum_{i=1}^m g(x_i)}{m} \end{cases}$$

其中, x_i ($i=1, 2, \dots, m$) 为当前代种群中的个体, 第一个方程平均值变换后不变, 第二个方程表示将当前最优值放大到平均值的 M 倍. 解此方程得

$$\begin{cases} \alpha = \frac{(M-1) \frac{\sum_{i=1}^m g(x_i)}{m}}{\max_{1 \leq i \leq m} \{g(x_i)\} - \frac{\sum_{i=1}^m g(x_i)}{m}} \\ \beta = \frac{\sum_{i=1}^m g(x_i)}{m} \left[\frac{\max_{1 \leq i \leq m} \{g(x_i)\} - M \frac{\sum_{i=1}^m g(x_i)}{m}}{\max_{1 \leq i \leq m} \{g(x_i)\} - \frac{\sum_{i=1}^m g(x_i)}{m}} \right] \end{cases}$$

其中, 选取 M 的策略是: 当个体目标值相差较大时, M 不要过大, 以便遗传保持随机性; 当个体目标值接近时, 逐步扩大 M .

12.5.4.2 控制参数的选择

在 GA 的运算过程中, 存在着对其性能产生重大影响的一组参数. 这组参数在初始阶段

或群体进化过程中需要合理地选择和控制,使算法以最佳的搜索路线达到最优解. 主要参数包括染色体位串长度(个体长度) l ,种群规模 N ,杂交概率 p_c 以及变异概率 p_m . 许多学者对此进行了大量实验研究,给出了参数的选取建议.

(1) 个体长度 l . 个体长度 l 的选择取决于特定问题解的精度要求. 要求的精度越高,个体长度越长,但需要更多的计算时间. 为提高运算效率,变长度个体或者在当前所达到的较小可行域内重新编码,是一种可行的方法,并显示了良好性能.

(2) 种群规模 N . 大的种群含有较多模式,为 GA 提供了足够的模式采样容量,可以改进算法的搜索质量,防止陷入局部最优解. 但大种群增加了个体适应性评价的计算量,从而使收敛速度降低. 一般情况下,专家建议 $N = 20 \sim 200$.

(3) 杂交概率 p_c . 杂交概率控制着杂交算子的应用频率. 在每一代新的种群中,平均来说需要对 $p_c \times N$ 个个体的染色体结构进行杂交操作. 杂交概率越大,种群新结构的引入越快,已获得的优良基因结构的丢失速度也相应升高. 而杂交概率太小则可能导致搜索阻滞. 一般取 $p_c = 0.6 \sim 1$.

(4) 变异概率 p_m . 变异操作是保持群体多样性的有效手段,杂交结束后,每个个体的每个基因位置上的基因都依概率 p_m 随机改变;因此每代中大约有 $p_m \times N \times l$ 次变异. 变异概率太小,可能使某些基因由于过早丢失信息而无法恢复;变异概率过大,则遗传搜索将变成纯随机搜索. 一般取 $p_m = 0.005 \sim 0.01$.

实际上,上述参数与优化问题的类型有直接关系. 优化问题的目标函数越复杂,参数选择就越困难. 从理论上讲,不存在一组适用于所有问题的最佳参数值,随着问题特征的变化,有效参数的差异往往非常显著. 如何设定 GA 的控制参数以使 GA 的性能得到改善,还需要结合实际问题深入研究,更有赖于 GA 理论研究的新进展.

12.5.4.3 进化过程技术问题

标准 GA 的操作算子一般都包括选择、杂交和变异三种基本形式,它们构成了 GA 具备强大搜索能力的核心,是模拟自然选择及遗传过程发生繁殖、杂交和突变现象的主要载体. GA 利用遗传操作算子产生新一代种群来实现种群的进化,算子的设计是 GA 的主要组成部分,也是调整和控制进化过程的基本工具.

1. 选择算子

关于 12.2 节已经介绍的个体选择和母体选择,都是基于适应值比例选择的,它是最基本和简单的,这里再简单介绍几种选择算子.

(1) 适应值比例选择. 对种群 $\vec{X} = (X_1, X_2, \dots, X_n)$,适应值比例选择算子定义为

$$P\{T_s(\vec{X}) = X_i\} = \frac{f(X_i)}{\sum_{j=1}^n f(X_j)}, \forall i = 1, 2, \dots, n$$

其中 $f(X_i)$ 表示种群 $\vec{X}$ 中个体 X_i 的适应值($i = 1, 2, \dots, n$). 详见定义 12-6.

(2) Boltzmann 选择. 这种选择的思想是结合了模拟退火的想法. 在种群进化过程中,不同阶段需要不同的选择压力. 早期阶段我们希望较差的个体也有一定的生存机会,使得种群保持较高的多样性;后期阶段选择压力较大,我们希望 GA 缩小搜索邻域,加快当前最优解改善的速度. 为了动态调整种群进化过程中的选择压力,Goldberg 设计了 Boltzmann 选择方法:

对种群 $\vec{X} = (X_1, X_2, \dots, X_N)$, Boltzmann 选择算子定义为

$$P\{T_i(\vec{X}) = X_i\} = \frac{\exp\left(\frac{f(X_i)}{T}\right)}{\sum_{j=1}^N \exp\left(\frac{f(X_j)}{T}\right)}, \quad \forall i = 1, 2, \dots, n$$

其中, $f(X_i)$ 表示种群 $\vec{X}$ 中个体 X_i ($i = 1, 2, \dots, n$) 的适应值; $T > 0$ 是退火温度, T 随着迭代的进行逐渐缩小, 选择压力将随之升高. Goldberg 通过一组试验分析认为, 此种选择明显好于适应值比例算子(另见在定理 12-4 中关于适应值比例 α 变化的讨论).

(3) 精英选择. 从 GA 的整个选择策略来讲, 精英选择是种群收敛到优化问题最优解的一种基本保障. 如果下一代种群的最佳个体的适应值小于当前种群最佳个体的适应值, 则将当前种群最佳个体或者适应值大于下一代最佳个体适应值的多个个体直接复制到下一代, 随机替代或替代最差的下一代种群中相应数量的个体(精英选择 GA 参见 12.2 节).

(4) 稳态选择. 注意到由于遗传操作的随机性, 或者采用精英选择策略, 下一代种群的部分个体可以与上一代相同, 稳态选择操作中, 每次先用适应值比例选择少量个体, 再经遗传操作产生新的个体, 将新个体放回到种群中时, 随机替代等量个体, 或者替代等量的最差个体.

另外, 还有排列选择、联赛选择以及很多新型选择方法, 不再赘述.

2. 杂交算子

杂交是所有进化算法中 GA 具备的最原始性的独有特征. 杂交操作是模仿自然界有性繁殖的基因重组过程, 其作用在于将原有的优良基因遗传给下一代个体, 并生成包含更复杂基因结构的新个体.

关于杂交操作已在 12.2 节有较详细的介绍. 一般认为, 一点杂交操作的信息量比较小, 杂交点位置的选择可能带来较大偏差. 按 Holland 的思想, 一点杂交不利于定义长度较长模式的保留和重组, 而且位串末尾的重要基因总是被交换, 故实际应用中采用较多的是两点杂交.

另外, 对于多点杂交, 杂交点的数目和位置的选择有多种方法. 特别对于优化问题的解是实数而不是整数时, 如采用二进制编码, 一般交叉点的数目不宜低于实数解空间的维数. Mitchell 建议每次杂交操作时, 按泊松(Poisson)分布确定杂交点数.

$$P(\xi = k) = \frac{e^{-\lambda} \lambda^k}{k!} \quad (k = 0, 1, 2, \dots)$$

其中 ξ 为杂交点数, 其均值 $E\xi$ 和方差 $D\xi$ 为 $E\xi = D\xi = \lambda$, 是个体长度的函数.

而 De Jong 认为, 均匀杂交优于多点杂交, 它不存在多点杂交引起的位置偏差, 任意基因位的基因在均匀杂交作用下均可重组, 并遗传给下一代.

3. 变异算子

变异操作模拟自然界生物体进化中染色体上某位基因发生的突变现象, 从而改变染色体的结构和物理性状. 当杂交操作产生的后代个体的适应值不再比它们的前辈更好, 但又未达到全局最优解时, 就会发生成熟前收敛或早熟收敛(Premature Convergence). 这时引入变异算子往往能产生很好的效果. 一方面, 变异操作可以使群体进化过程中丢失的基因信息得以恢复, 以保持群体中个体的差异性, 防止发生成熟前收敛; 另一方面, 当种群规模较大时,

在杂交操作基础上引入适度的变异,也能够提高 GA 的局部搜索效率.但总的来说,在群体进化的整个过程中,杂交操作是主要的基因重组和群体更迭的手段,变异操作的作用是第二位,变异算子仅仅充当背景性的角色(Background Role).

变异操作作用于个体每个分量上,由于变异概率比较小,在实施过程中一些个体可能根本不发生变异,造成大量计算资源的浪费.因此在 GA 具体应用中,可以采取一种变通措施,首先进行个体层次的变异发生的概率判断,然后再实施基因层次上的变异操作.一般包括两个步骤:

(1) 计算个体发生变异的概率.以原始选取的变异概率 p_m 为基础,可以计算出种群 $\vec{X}$ 中个体发生变异的概率

$$p_m(\vec{X}) = 1 - (1 - p_m)^l$$

对每个个体 X_i ,产生(0,1)区间上均匀分布的随机数 x ,若 $x \leq p_m(\vec{X})$,则对该个体进行变异,否则不进行变异操作.

(2) 计算发生变异的个体上基因变异的概率.由于变异操作方式发生了改变,被选择变异的个体上基因的变异概率也需要相应修改,以保证整个种群上基因发生变异的期望次数相等.传统变异方式下,整个种群基因变异的期望次数为 $N \times l \times p_m$.设新的基因变异概率为 p'_m ,新的变异方式下,整个种群基因变异的期望次数为 $(n \times p_m(\vec{X})) \times (l \times p'_m)$.要求两者相等,即

$$N \times l \times p_m = (n \times p_m(\vec{X})) \times (l \times p'_m),$$

就有

$$p'_m = \frac{p_m}{p_m(\vec{X})} = \frac{p_m}{1 - (1 - p_m)^l} > p_m$$

传统变异方式下的变异次数为 $N \times l$,新的变异方式的变异次数为 $N \times p_m(\vec{X}) \times l$,少变异 $N \times (1 - p_m(\vec{X})) \times l$ 次.

12.6 遗传算法的改进与注记

GA 属于启发式随机搜索算法(Random Heuristic Search, RHS),这类算法是目前关于复杂优化问题求解的一类有效方法,能适应不同领域的优化问题求解,并在大多数情况下都能得到比较满意的解. GA 的主要任务和目的是设法产生或有助于产生优良的个体,且这些成员能够充分表现出解空间中的解,从而使算法效率提高并避免早熟收敛现象.但在实际应用 GA 时,往往出现早熟收敛和收敛性能差等缺点,现今的改进方法,大都针对遗传算子、种群的宏观操作、基于知识的操作和并行化 GA 进行,参见文献[13]的介绍及其所引参考文献.另外,与其他启发式算法结合也是遗传算法一个重要的改进方向,比如,免疫 GA、遗传模拟退火算法、广义模拟退火 GA 以及并行 GA 等.有关 GA 的较新研究成果及应用实例可参见参考文献[14],[45]~[48].

注记: 本章主要取材于参考文献[40]和[14].应当说,有关 GA 的理论研究和实际应用研究还在蓬勃发展时期,研究成果不断涌现,也有多部专著出版,要用很小的篇幅介绍它是件很困难的事情.本章只介绍这种算法的基本思想和概念以及技术实现的一般方法.但是,就一种随机搜索来讲不外乎两个方面的问题:一是算法的基本步骤与实际的可操作性或

可行性,另一问题是理论上分析方法的收敛性.前者是通过各种思想和各种方法结合,通过实验验证方法的可行性,并与其他方法相比较;而任何一种改进,哪怕是基本遗传操作的一点变动,都会导致收敛性分析的实质困难.关于 GA 收敛性的讨论,基本上是两个部分:一部分是基于 Holland 等人提出的模式理论,通过研究遗传算子进化行为,讨论算法的性能;另一部分是基于马尔科夫链的遍历性理论,研究算法的收敛性.本章内容就是基于以上认识来组织的.特别是作为数学教材,我们试图对算法的概念和结果尽量有严格的数学推导和证明,这方面主要参考了文献[40]并受到该文献的启发.另外,模式定理的详细证明是编者新加的,对主要参考文献数学上不够严格的地方作了一些必要的改动.

习 题

12-1 对于选择算子 T^α 及种群 $\vec{X} = (X_1, X_2, \dots, X_N)$, 试证

$$P\{T^\alpha(\vec{X}) = (X, Y)\} = \frac{\varphi(\vec{X}, X)f^\alpha(X)}{\sum_{k=1}^N f^\alpha(X_k)} \cdot \frac{\varphi(\vec{X}, Y)f^\alpha(Y)}{\sum_{k=1}^N f^\alpha(X_k)}, \quad \forall (X, Y) \in S^2$$

12-2 任给种群 $\vec{X} = (X_1, X_2, \dots, X_N)$, 试证

$$\lim_{\alpha \rightarrow 0} P\{T^\alpha(\vec{X}) = (X_i, X_j)\} = \frac{1}{N^2}, \quad \forall i, j \leq N$$

12-3 试就个体选择给出平行于定理 12-4 的事实,并加以证明.

12-4 试完成定理 12-8 的必要性证明中“ $p_m < 1$ ”的证明.

12-5 试证明引理 12-4 中的式(12-18).

12-6 试用定理 11-1 和定理 11-2 的结论证明引理 12-6.

12-7 试用定理 12-3、定理 12-5、定理 12-7 和定理 12-8 的结论证明标准 GA 对应的随机序列是时齐的不可约非周期正常返马氏链.

第13章 人工神经网络

人工神经网络(Artificial Neural Networks, ANN)是由人工建造的、以有向图为拓扑结构的动态系统,它通过对连续或断续的输入作状态响应而进行信息处理. ANN实质上是以大脑生理变化过程为基础,模仿大脑的结构和功能,借助计算机处理大规模信息的一种信息处理系统.

13.1 概述

人工神经网络的研究与计算机的研究几乎是同步发展的. 自20世纪40年代美国生理学家麦克劳(W. S. McCulloch)和数学家匹茨(W. A. Pitts)总结生物神经元的基本特征,首次提出二值神经元模型(M-P模型,后被扩展为“认知(perceptron)”模型,它的一个功效是可以用来解决简单的分类问题)以来, ANN的发展走过了一条曲折的道路. 1969年Minsky等人指出,认知模型无法解决最为经典的“异或”问题. 这个结论使得神经网络陷入一个危机. 尽管ANN的研究曾经历了20世纪60~70年代的低潮期,但仍处于不断发展之中,尤其是20世纪80年代初期,美国物理学家霍普菲尔德(J. J. Hopfield)采用全互联神经网络模型,引入能量函数概念,成功地解决了TSP问题, ANN的研究又进入了一个新的高潮期. 越来越多的技术人员注意到了这一新的信息处理方法,并投入到神经网络的研究中,在ANN理论、模型、算法、应用软件开发等方面都取得了很大进展. 目前ANN的应用已渗透到了各个领域,尤其在组合优化问题求解、智能计算、模式识别、机器视觉、机器人控制、信号处理、联想记忆、编码理论、医学诊断、金融决策和数据挖掘等领域获得了卓有成效的应用.

人工神经网络是由大量的、简单的处理单元(神经元)互联组成的大规模分布式并行信息处理系统,它通过模拟人脑的神经系统组织结构,能对复杂问题进行有效求解. 与专家系统相比较,它有其独特的特点. 第一,在处理方法上,由于其广泛互联的非线性动力学特性,人工神经网络更长于处理联想记忆,也更适合于做表象的、浅层的经验推理及模糊推理;第二,网络的特性决定于各网络节点的连接权值及互连模式上,其计算处理过程是输入到网络内传播、调整至平衡的过程,这表明其总特性是分布记忆和并行计算,且有利于知识存储的简化和运行效率的提高;第三,神经网络具有自组织和自学习的能力,通过有导师和无导师学习,可以方便地记忆有关的知识,这有利于机械设计中的知识获取和表达;第四,人工神经网络表现出比较好的容错性,即使问题描述有部分错误时,往往也能得到较好的结果.

人工神经网络的模型要求发展神经计算机系统来代替传统的计算机. 这种计算机系统不再是传统计算机顺序执行命令的运行过程,而是希望对输入进行平行处理;这种计算机不再是只包含一个或几个复杂的计算设备,而是由众多简单设备有机组成在一起;这种计算机系统处理信息时,不再是将信息存储在一个精确的位置上,而是通过神经元的内部相连关系达到信息储存的功能.

在目前的条件下,还只能依赖传统的计算机来模拟人工神经网络的这些功能. 数值计算

和分析是模拟中的一个重要部分,只有当人工神经网络硬件系统得到发展,才能使目前的人工神经网络更快、更有效地解决大规模的实际问题.

13.2 人工神经网络的基本概念

13.2.1 基本人工神经网络模型

前向型神经网络是应用最广的模型之一,其原理或算法也是其他网络的基础.本章将讨论这种网络的结构和算法,其目的是为了了解影响学习速度和收敛性的因素,从而提出解决方法.

径向基函数神经网络也是一种前向型神经网络,可以认为它是一种通过改变神经元非线性变换函数的参数以实现非线性映射,并由此而导致连接权值调整的线性化从而提高学习速度.由于径向基函数网络学习收敛速度较快,近年来受到重视,特别是在以支持向量机为代表的核函数方法的应用和研究逐步深入之后.

Hopfield 神经网络是反馈型网络的代表.网络的运行是一个非线性的动力学系统,所以比较复杂. Hopfield 神经网络已在联想记忆和优化计算中得到成功应用.

优化计算过程陷入局部极小是长期以来困扰人们的一个问题.具有随机性值的模拟退火(SA)算法就是针对这一问题而提出来的,并已在神经网络的学习及优化计算中得到成功的应用. Boltzmann 机是具有随机输出值单元的随机神经网络,串行的 Boltzmann 机可以看作对二次组合优化问题的模拟退火的具体实现,同时它还可以模拟外界的概率分布,实现概率意义上的联想记忆.

自组织竞争型神经网络的特点是能识别环境的特征,并自动聚类.它们在特征抽取和大规模数据处理中已经有极为成功的应用.

13.2.2 人工神经网络的学习算法

神经网络的性质主要取决于以下两个因素:一个是网络的拓扑结构;另一个是网络的权值、工作规则.二者结合起来就可以构成一个网络的主要特征.

随着网络结构和功能的不同,网络权值的学习算法也不同,这里仅就神经网络基本学习算法的含义及特点作简要介绍.

人工神经网络学习问题就是网络的权值调整问题,权(值)是一个反映信息储存的关键量.在网络的结构和变换函数确定以后,如何设计权使网络达到一定的要求,这是必不可少的部分,大多数神经网络权的设计是通过学习得到的.一般将学习算法分为下列几种:

1. 死记式学习

网络的权是根据所处理问题和条件事先设计好,并保持固定不变.例如, Hopfield 网络在做优化时,权可根据优化的目标函数和约束条件来设计,一旦设计好了就不再改变. $M-P$ 模型也可设计好固定的权来实现与、或、非等逻辑运算.

2. 有监督学习

这种学习的学习结果,即网络的输出有一个评价标准,网络将实际输出和评价标准进行比较,由其误差信号决定连接权值的调整.评价标准是由外界提示给网络的,相当于有一个

知道正确结果的教师示教给网络,故这种学习又称为有教师(或导师)的学习.在这种学习中,网络的连接权值一般根据 δ 规则进行调整.

感知器、自适应线性单元、BP 网络等采用的学习方法都是有监督学习.

3. 无监督学习

无监督学习是一种自组织学习,此时网络的学习完全是一种自我调整的过程,不存在外部环境的示教,也不存在来自外部环境的反馈来指示网络期望输出什么或者当前输出是否正确,故又称为无教师学习.

所谓自组织学习就是网络根据某种规则反复地调整连接权值以适应输入模式的激励,指导网络最后某种有序状态.也可以说神经元对输入模式的不断适应,抽取输入信号的特征(如统计特征等),一旦网络完成了对输入信号的编码,当它再现时就能把它识别出来.在自组织学习中,常用的学习规则有 Hebb 学习规则和相近学习规则,前者产生放大作用,后者产生竞争作用.

(1) Hebb 学习规则. 几乎所有神经网络学习算法都可以看作 Hebb 学习规则的变形. Hebb 学习规则的基本思想是:

如果神经元 u_i 接收来自 u_j 的输出,则当两个神经元同时兴奋时,从 u_i 到 u_j 的权值 w_{ij} 就得到加强.

具体到神经元模型,可以将 Hebb 规则表现为如下的算法:

$$\Delta w_{ij} = \eta \Delta y_j x_i$$

式中, Δw_{ij} 是对 w_{ij} 的修正量, η 是控制学习速度的参数.

(2) 相近学习规则. 设 w_{ij} 为从神经元 j 到神经元 i 的权, y_j 为神经元 j 的输出,则

$$\Delta w_{ij} = y_j (x_i - w_{ij})$$

在以后各节中将详细讨论各类模型、算法,并从前馈、自组织和反馈等几个方面进行讨论.

13.2.3 人工神经元及感知器模型

13.2.3.1 生物神经元

关于单个生物神经元(神经细胞)的构造与功能在生物医学方面已有确切的了解.神经元的构造如图 13-1 所示.




图 13-1 典型的神经元构成示意图

神经元由“细胞体”与若干“突体”组成,其中“细胞体”由“细胞核”、“细胞膜”与“细胞

质”组成,而“突体”由“轴突”、“树突”、“突触”与“神经末梢”组成。

神经元的工作机制是:一个神经元有两种状态——兴奋和抑制。平时处于抑制状态的神经元,其树突和细胞体接受其他神经元经由突触传来的兴奋电位,多个输入在神经元中以代数的方式叠加;如果输入兴奋总量超过某个阈值,神经元就会被激活进入兴奋状态,发出输出脉冲,并由轴突的突触传递给其他的神经元。神经元被触发之后有一个不应期,在此期间内,阈值逐渐下降,恢复兴奋性。神经元按照“全或无”的原则工作,只有兴奋和抑制两种状态,但也不能认为神经元只能表达或传递二值逻辑信号。因为神经元兴奋时往往不是只发出一个脉冲,而是发出一串脉冲,如果把这一串脉冲看成是一个调频信号,脉冲的密度是可以表达连续量的。

以上关于神经元工作机制的描述是非常简化的。对于神经元已经有了很多更深入细致的研究,提出了一些更为精确而复杂的模型,有人甚至认为一个神经元的复杂程度就相当于一台微型计算机。但是从人工神经网络研究的目的出发,如果这种复杂和精确不能带来相应的性能改善,则追求真实性是没有意义的。这里需要留意的是,神经元的简化模型并非唯一,这也为发挥创造性留有充分的余地。

13.2.3.2 人工神经元

神经网络的基本处理单元是人工神经元,人工神经元的种类繁多,在这里只介绍工程上常用的最简单的模型,该模型是 McCulloch 和 Pitts 于 1943 年定义的,简称 M-P 模型,如图 13-2 所示。




图 13-2 人工神经元模型

图 13-2 给出了一个基本的人工神经元的结构。人工神经元又称为处理单元、结点或短期记忆。图中的 n 个输入 $x_i \in \mathbb{R}$, 相当于其他神经元的输出值, n 个权值 $w_i \in \mathbb{R}$, 相当于突触的联结强度, 是连接两个神经元的可调值。所有和神经元 j 相联结的权值构成向量

$$\mathbf{W}_j = (w_{j1}, w_{j2}, \dots, w_{jn})^T$$

其中 w_{ji} 代表处理单元 i 和 j 之间的联结权值, θ 为阈值常数。此时神经元的计算过程可以表示为

$$y_j = f(\mathbf{W}_j^T \mathbf{x} - \theta_j) \quad (13-1)$$

或者写成

$$y_j = f\left(\sum_{i=1}^n w_{ji}x_i - \theta_j\right) \quad (13-2)$$

其中, f 是一个非线性函数, 通常取为下列函数之一:

(1) 线性函数:

$$f(x) = \alpha \cdot x \quad (13-3)$$

(2) 带限线性函数:

$$f(x) = \begin{cases} \gamma & x \geq \gamma \\ x & |x| < \gamma \\ -\gamma & x \leq -\gamma \end{cases} \quad (13-4)$$

(3) 阈值型函数:

$$f(x) = \begin{cases} 1 & x \geq \theta \\ 0 & x < \theta \end{cases} \quad (13-5)$$

其中, θ 为神经元阈值.

(4) 最为常用的 Sigmoid 函数:

$$f(x) = \frac{1}{1 + e^{-x}} \quad (13-6)$$

与此类似的还有双曲函数:

$$f(x) = \frac{1 - e^{-x}}{1 + e^{-x}} \quad (13-7)$$

某些重要的学习算法要求输出函数 f 可微, 此时通常选用 Sigmoid 函数式 (13-7), 则输出 $y \in (-1, 1)$, 可取 -1 到 1 的开区间内的连续值. 也可以选式 (13-6), 则 $y \in (0, 1)$.

选择 Sigmoid 函数作为输出函数是由于它具有以下有益的特性: ①非线性, 单调性; ②无限次可微; ③当权值很大时可近似阈值函数, 当权值很小时可近似线性函数.

13.2.3.3 感知器模型

感知器是一种两层神经网络, 这两层分别是输入层和输出层, 其中输出层具有计算单元, 可以通过监督学习建立模式的判别的能力, 如图 13-3 所示.




图 13-3 感知器模型示意图

感知器模型的学习目标是通过改变权值使神经网络由给定的输入得到给定的输出. 作为分类器, 可以用已知类别的模式向量或特征向量作为训练集, 当输入为属于第 j 类的特征

向量 X 时,应使对应于该类的输出 $y_j = 1$,而其他神经元的输出则为 0(或 -1)。

不失一般性,可以假设输出层仅有一个神经元.外界信号 S 经过加权后输入到输出层的某个单元,若不小于阈值,则输出 1,否则输出 -1.设网络输入模式向量为

$$\mathbf{s}^{(k)} = (s_1^{(k)}, s_2^{(k)}, \dots, s_n^{(k)})^T$$

对应的期望输出为 $\mathbf{d}^{(k)}$;由输入至输出的权值向量为 $\mathbf{w} = (w_1, w_2, \dots, w_n)^T$,网络按以下规则学习.

感知器学习算法:

(1) 初始化,将权值向量和阈值赋予随机值, $t = 0$;

(2) 修正连接权值,对每一个输入模式对 $(\mathbf{s}^{(k)}, \mathbf{d}^{(k)})$ 完成如下计算:

$$\textcircled{1} \text{ 计算网络输出 } y = f\left(\sum_{i=1}^n w_i(t) s_i^{(k)} - \theta\right)$$

式中, f 为双极值阶跃函数, $f(x) = \begin{cases} 1 & x \geq 0 \\ -1 & x < 0 \end{cases}$;

② 计算输出层单元期望输出与实际输出间的误差 $\mathbf{e}^{(k)} = \mathbf{d}^{(k)} - y$;

③ 若 $\mathbf{e}^{(k)}$ 为零,则说明当前样本输出正确,不必更新权值,否则更新权值和阈值:

$$\mathbf{w}(t+1) = \mathbf{w}(t) + \alpha \cdot \mathbf{d}^{(k)} \cdot \mathbf{s}^{(k)}$$

$$\theta(t+1) = \theta(t) + \alpha \cdot \mathbf{d}^{(k)}$$

$$t = t + 1$$

式中, α 为学习率;

(3) 对所有输入模式重复步骤(2),直到所有的样本输出正确为止.

如果样本线性可分,则上述感知器学习算法是收敛的.

定理 13-1 对于预先给定 $\{-1, 1\}^n$ 中的 K 个样本 $\mathbf{s}^{(1)}, \mathbf{s}^{(2)}, \dots, \mathbf{s}^{(K)}$,若存在权值向量 $\mathbf{W}^*$ 满足 $\mathbf{d}^{(k)} \left(\sum_i w_i^* s_i^{(k)} + \theta \right) > \beta_0 > 0$ ($i = 1, 2, \dots, n, k = 1, 2, \dots, K$),那么上述感知器学习过程在有限步内收敛.

证 为了简便起见,可将阈值归入权值向量,相应地对样本增加一个分量.首先估计 $\frac{\langle \mathbf{w}^*, \mathbf{w}(t) \rangle}{\|\mathbf{w}^*\| \cdot \|\mathbf{w}(t)\|}$ 的值,其中 $\|\mathbf{w}^*\|$ 及 $\|\mathbf{w}(t)\|$ 为权值向量的模,而 $\langle \mathbf{w}^*, \mathbf{w}(t) \rangle$ 为它们的内积;这时有

$$-1 \leq \frac{\langle \mathbf{w}^*, \mathbf{w}(t) \rangle}{\|\mathbf{w}^*\| \cdot \|\mathbf{w}(t)\|} \leq 1 \quad (13-8)$$

成立.另一方面,又有

$$\begin{aligned} \langle \mathbf{w}^*, \mathbf{w}(t+1) \rangle &= \langle \mathbf{w}^*, \mathbf{w}(t) + \alpha \cdot \mathbf{d}^{(k)} \cdot \mathbf{s}^{(k)} \rangle \\ &= \langle \mathbf{w}^*, \mathbf{w}(t) \rangle + \alpha \cdot \mathbf{d}^{(k)} \langle \mathbf{w}^*, \mathbf{s}^{(k)} \rangle \\ &> \langle \mathbf{w}^*, \mathbf{w}(t) \rangle + \alpha \cdot \beta_0 \\ &> (t+1) \alpha \cdot \beta_0 \end{aligned} \quad (13-9)$$

式(13-9)的最后一个“ $>$ ”不等式可由归纳法得出.

同样地

$$\begin{aligned}
\langle \mathbf{w}(t+1), \mathbf{w}(t+1) \rangle &= \langle \mathbf{w}(t) + \alpha \cdot \mathbf{d}^{(k)} \cdot \mathbf{s}^{(k)}, \mathbf{w}(t) + \alpha \cdot \mathbf{d}^{(k)} \cdot \mathbf{s}^{(k)} \rangle \\
&= \langle \mathbf{w}(t), \mathbf{w}(t) \rangle + 2\alpha \cdot \mathbf{d}^{(k)} \cdot \langle \mathbf{w}(t), \mathbf{s}^{(k)} \rangle + \alpha^2 \cdot \|\mathbf{s}^{(k)}\|^2 \\
&\leq \|\mathbf{w}(t)\|^2 + \alpha^2 \cdot H \\
&\leq (t+1)\alpha^2 \cdot H
\end{aligned} \tag{13-10}$$

其中, $H = \max\{\|\mathbf{s}^{(k)}\|\}$, 将式(13-9)和式(13-10)代入式(13-8)可得

$$\frac{t \cdot \alpha \cdot \beta_0}{\|\mathbf{w}^*\| \cdot \sqrt{t\alpha^2 \cdot H}} \leq \frac{\langle \mathbf{w}^*, \mathbf{w}(t) \rangle}{\|\mathbf{w}^*\| \cdot \|\mathbf{w}(t)\|} \leq 1$$

成立. 因此, 必有 t 为有限数, 从而定理成立. $\square$

关于感知器, 这里指出它的一些特性: ①两层感知器只能用于解决线性可分问题; ②学习过程收敛很快, 且与初始值无关; ③如果激活函数 f 为线性函数, 则感知器无法识别“异或问题”.

13.3 前馈神经网络及其主要算法

构成前馈网络的各神经元接受前一级的输入, 并输出到下一级, 无反馈, 可用一有向无环图表示. 一般的前馈网络包括一个输入层、一个输出层和若干隐单元(也可以没有), 输入层和输出层由于可与外界相连, 直接受外界环境影响, 称为可见层, 而隐单元则称为隐层. 隐单元可以分层也可以不分层, 若分层, 则称为多层前馈网络, 如图 13-4 所示.




图 13-4 前馈神经网络结构示意图

前馈网络的输入、输出神经元, 其激活函数一般都取为线性函数, 而隐单元则为非线性函数.

前馈网络的输入单元从外部环境接受信号, 经处理并加权后输出到其投射域中的神经元, 网络中的隐含单元或输出单元 i 从其接受域中接受净输入 $\text{net}_i = \sum_{j \in R_i} w_{ij} y_j$ (其中 y_j 表示单元 j 的输出), 然后向它的投射域 P_i 发送输出信号 $y_i = f(\text{net}_i)$, f 为任意的可微函数, 一般取为 Sigmoid 函数. 上述过程一直持续到所有的输出单元得到输出为止, 它们的输出作为网络的输出.

感知器就是没有隐层的前馈网络, 有关它的模型和算法, 已在 13.2 节作了介绍. 本节介绍包含隐层的前馈神经网络(即多层前馈神经网络)的学习算法.

13.3.1 多层前馈网络

利用神经元的非线性特性,可以实现各种逻辑门,例如,利用前馈神经网络(使用阈值函数)可以实现与非门.由于任何逻辑函数都可以由与非门组成,所以可以得出以下结论:①任何逻辑函数都可以用前馈网络实现.②单个阈值神经元可以实现任意多输入的与、或及与非、或非门;由于任何逻辑函数都可以化为析取(或合取)形式,所以任何逻辑函数都可用一个三层(只有两层计算单元)的前馈网络实现.当神经元的输出函数为 Sigmoid 函数时,上述结论可以推广到连续的非线性函数,在很宽松的条件下,三层前馈网络可以逼近任意的多元非线性函数,突破了二层前馈网络局限于线性可分的限制.这种三层或三层以上的前馈网络通常又被叫做多层感知器(Multi-layer Perceptron, MLP).

多层前馈神经网络需要解决的关键问题是学习算法.以 Rumelhart 和 McClelland 为首的科研小组提出的误差(error)反向传播(Back Propagation, BP)算法,为多层前馈神经网络的研究奠定了基础.

13.3.2 反向传播算法(BP 算法)

多层前馈网络的适用范围大大超过二层前馈网络,但是其学习算法变得复杂,主要困难是中间的隐层不直接与外界连接,无法直接计算其误差.为解决这一问题,提出了误差反向传播算法.其主要思想是从后向前(反向)逐层传播输出层的误差,以间接算出隐层误差.算法分为两个阶段:第一阶段(正向过程),输入信息从输入层经隐层逐层计算各单元的输出值;第二阶段(反向传播过程),输出误差逐层向前算出各单元的误差,并用此误差修正前层权值.

BP 算法是基于梯度法极小化二次性能指标函数

$$E = \frac{1}{2} \sum_j (y_j - \hat{y}_j)^2 \quad (13-11)$$

以修正权值,为此要求输出函数可微,通常采用 Sigmoid 函数作为输出函数.为简便起见而又不失一般性,我们研究处于某一层的第 j 个计算单元,下标 i 代表其前层第 i 个单元,下标 k 代表后层第 k 个单元, O_j 代表本层输出, w_{ij} 是前层到本层的权值,如图 13-5 所示.




图 13-5 BP 算法中的某一层第 j 个计算单元

当输入某个样本时,从前到后对每层各单元作如下计算(正向算法)

$$\text{net}_j = \sum_i w_{ij} O_i \quad (13-12)$$

$$O_j = f(\text{net}_j) \quad (13-13)$$

对于输出层而言, $\hat{y}_j = O_j$ 是实际输出值, y_j 是理想输出值, 此样本下的误差就是式(13-1). 为简便起见, 定义

$$\delta_j = \frac{\partial E}{\partial \text{net}_j} \quad (13-14)$$

考虑权值 w_{ij} 对误差的影响, 可得

$$\frac{\partial E}{\partial w_{ij}} = \frac{\partial E}{\partial \text{net}_j} \frac{\partial \text{net}_j}{\partial w_{ij}} = \delta_j O_i \quad (13-15)$$

权值修正应使误差最快地减小, 因此沿目标函数 E 关于 w_{ij} 的负梯度方向 (即目标函数值下降最快的方向) 修正权值, 修正量为

$$\begin{aligned} \Delta w_{ij}(t) &= -\eta \delta_j O_i \\ w_{ij}(t+1) &= w_{ij}(t) + \Delta w_{ij}(t) \end{aligned} \quad (13-16)$$

其中, η 为步长系数, 又称学习速率.

如果 j 为输出结点, 则

$$\begin{aligned} O_j &= \hat{y}_j \\ \delta_j &= \frac{\partial E}{\partial \hat{y}_j} \frac{\partial \hat{y}_j}{\partial \text{net}_j} = -(y_j - \hat{y}_j) f'(\text{net}_j) \end{aligned} \quad (13-17)$$

如果 j 不是输出单元, 则 O_j 对后层的全部结点都有影响. 因此,

$$\begin{aligned} \delta_j &= \frac{\partial E}{\partial \text{net}_j} = \sum_k \frac{\partial E}{\partial \text{net}_k} \cdot \frac{\partial \text{net}_k}{\partial O_j} \cdot \frac{\partial O_j}{\partial \text{net}_j} \\ &= \sum_k \delta_k w_{jk} f'(\text{net}_j) \end{aligned} \quad (13-18)$$

在实际计算时, 为了加快收敛速度, 往往在权值修正量中加上前一次的权值修正量, 一般称之为惯性项, 即

$$\Delta w_{ij}(t) = -\eta \delta_j O_i + \alpha \Delta w_{ij}(t-1) \quad (13-19)$$

上述推导过程 (即求目标函数极小值过程) 是逐个处理各个样本, 即随机依次输入样本, 每输入一个样本都进行连接权的调整. 其实也可以成批处理, 即在所有样本输入后计算求总误差的极小值.

归纳起来, BP 算法的步骤如下 (设激活函数为 Sigmoid 函数):

- (1) 给定各权系数初始值.
- (2) 重复下述过程直至收敛 (对各样本依次计算).
 - ① 从前向后计算各层各单元的 O_j

$$\begin{aligned} \text{net}_j &= \sum_i w_{ij} O_i \\ O_j &= \frac{1}{1 + e^{-\text{net}_j}} \end{aligned}$$

- ② 对输出层计算 δ_j

$$\delta_j = (y - O_j) O_j (1 - O_j)$$

- ③ 从后向前计算各隐层 δ_j

$$\delta_j = O_j (1 - O_j) \sum_k w_{jk} \delta_k$$

④计算并保存各权值修正量

$$\Delta w_{ij}(t) = \alpha w_{ij}(t-1) + \eta \delta_j O_i$$

⑤修正权值

$$w_{ij}(t+1) = w_{ij}(t) + \Delta w_{ij}(t)$$

BP 算法解决了隐层权值修正问题,但它是基于梯度法求误差函数极小值的,因此有可能陷入局部极小点,不能保证收敛到全局极小点.此外,在应用 BP 算法时还需要注意以下问题:

(1)激活函数为 Sigmoid 函数,只能趋近 0 或 1,于是在神经网络的工作期,输出值只能接近 1 或 0.判定一个模式的归类问题就需要给出一个分界阈值,如 0.5,而不是绝对的 1 或 0.

(2)初始权值最好是随机的.

(3)算法的全局最优性.这里存在的理论问题:一是目标函数的选取及应满足的条件,如采用期望目标函数在什么条件下有唯一的极值点?二是一般情况下是否有唯一的极值点?有关这方面的进一步讨论,请读者参考其他神经网络的专著或者参考文献[57].

从原理上讲,BP 算法完全可以用于四层或更多层的前馈网络.三层网络可以应付任何问题,但对于较复杂的问题,更多层的网络有可能获得更精简的结果.遗憾的是,BP 算法直接用于多于三层的前馈网络时,陷入局部极小点而不收敛的可能性很大.此时需要运用更多的先验知识减小搜索范围,或者找出一些原则来逐层构筑隐层.

上述 BP 算法还存在以下缺点:①为了极小化总误差,学习速率 η 应选得足够小,但是小的学习速率会导致学习过程很慢;②大的学习速率虽然可以加快学习速度,但又可能导致学习过程的振荡,从而收敛不到期望解;③学习过程中可能收敛于局部极小点或在误差函数的平稳段停止不前.针对这些问题,很多学者对 BP 算法进行了改进,这里不作进一步介绍,有兴趣的读者请参考其他神经网络的专著或者参考文献[57].

13.4 自组织映射神经网络

13.4.1 竞争学习

前馈网络属于有监督的学习,需要同时提供输入样本和理想的输出.而竞争学习神经网络是无监督神经网络中的一类,给定输入数据,不同于有监督学习中需要对应的理想输出,无监督学习不需要对应的理想输出.也就是说,它的输出结果表明输入数据中的相关性或相似性.

对于单层神经网络,一类简单的线性竞争学习模型为

$$y_j = \begin{cases} 1 & \sum_{i=1}^m w_{ij}x_i = \max_{1 \leq k \leq n} \left(\sum_{i=1}^m w_{ik}x_i \right) \\ 0 & \text{其他} \end{cases}$$

当输入向量 X 和 $W^{(j)} = (w_{1j}, w_{2j}, \dots, w_{mj})^T$ ($j=1, 2, \dots, n$) 单位化以后,被选中神经元的权数向量 $W^{(j)}$ 同输入向量 X 的欧氏空间距离最近.因此,它的学习规则是

$$w_{ij}(t+1) = w_{ij}(t) + \delta w_{ij}(t)$$

其中

$$\delta w_{ij}(t) = y_j(t)(x_i(t) - w_{ij}(t))$$

竞争学习的最终结果使得相近的输入数据分为同一类。

竞争学习网络的结构与二层前馈网络类似,只是在输出层加上了侧抑制。侧抑制是在输出层各神经元之间相互用较大的负权值输入对方的输出,这种互连构成正反馈,类似于双稳态或多稳态触发器。

竞争学习网络虽然可用于无监督学习的聚类,但应用此网络时需要注意一些问题:首先网络不可能收敛到修正量趋于零的状态,因此可以采取强制收敛的方法。其次是学习结果受初始值和学习样本顺序的影响很大,聚类的结果未必是期望的结果,因此在实际应用中需要加入适当的人工干预。例如,先选择少量典型性好的样本作为权向量初始值。

13.4.2 自组织特征映射

大脑是由大量的神经元组成的,它们并非都起着同样的作用,处于空间不同部位的区域分工不同,各自对输入模式的不同特征敏感。

大脑中分布着大量的起协同作用的神经元群体,同时大脑网络又是一个复杂的反馈系统,既包括局部反馈,也包括整体反馈及化学交互作用,聚类现象对于大脑的信息处理起着重要的作用。在大脑皮层中,神经元呈二维空间排列,其输入信号主要有两部分:一是来自感觉组织或其他区域的外部输入信号;二是同一区域的反馈信号,形成信息交互。神经元之间的信息交互方式有很多种,然而邻近神经元之间的局部交互有一个共同的方式,就是侧向交互,最相近的“邻元”(小于 0.5 mm)互相兴奋,较远的邻元(1~2 mm)互相抑制,更远的又是弱兴奋,这种局部交互方式可以形象地比喻为“墨西哥草帽”,如图 13-6 所示。




图 13-6 邻近神经元之间的局部交互作用示意图

T. Kohonen 认为,神经网络中邻近的各个神经元通过侧向交互作用彼此相互竞争,自适应地发展成检测不同信号的特殊检测器,这就是自组织特征映射的含义。人工自组织映射与大脑映射有许多共同特性,通常又称作自组织映射神经网络或简称作 SOM 网络。

人工二维自组织映射网络结构如图 13-7 所示。总体连接与二层前馈网络相似,输入层的每一个单元 x_i 与输出层的每一个单元 y_j 相联。

自组织映射网络的学习算法也是一种竞争学习算法,区别只是在输出层具有几何分布,由交互作用函数取代了简单的侧抑制,因此其学习算法也是类似的。下面介绍 Kohonen 网络




图 13-7 自组织映射神经网络结构示意图

训练算法步骤.

(1) 用小随机数初始化所有连接权值.

(2) 反复进行以下运算,直到达到预定的训练次数或每次学习中权值改变量小于某一阈值.

①输入一个样本 X , 寻找最佳匹配结点 (即获胜结点) C . 如采用内积匹配, 则 C 为主兴奋单元 (即输出强度最大的单元); 若采用距离匹配, 则 C 为权值向量与输入样本向量距离最近的结点, 即

$$d(X, W_c) = \min_j \{d(X, W_j)\}$$

其中 $d(X, Y)$ 表示向量之间的某种距离.

②确定邻域交互函数 $F_c(j)$ (通常为给定半径的窗函数, 如“巴拿马草帽”窗、矩形窗等).

③计算各权值向量的修正量

$$\Delta W_j = \eta F_c(j) \delta(X, W_j)$$

其中, $\delta(X, W_j)$ 为 X 与权值向量 W_j 之间的偏差 (距离).

必要时根据学习次数更新学习步长 η 和邻域交互作用半径 R .

由于输出单元之间存在与几何位置有关的交互作用, 学习完成以后, 各输入向量在输出平面上存在对应的兴奋点, 而且兴奋点之间部分地满足一种关系, 即相似的输入向量 (在输入向量空间中夹角较小的) 在输出平面上离得较近. 此时的输出平面可以划分为若干个不同的区域, 每一个区域对应一个类别. 这种聚类方法比简单的竞争网络更为细致, 可适应多种不同的用途.

自适应特征映射是输入高维向量空间向二维平面的映射, 因此映射不是唯一的, 学习结果与权值初始值和样本顺序有关.

13.5 反馈型神经网络

在反馈型神经网络中, 神经元之间的信息传递不再是从一层到另一层, 而是各神经元之间存在着联系. 反馈型神经网络的基本单元是与前馈型神经网络类似的神经元, 其特性可以

取阈值函数或 Sigmoid 函数. 反馈网络的结构是单层的, 各单元地位均等, 每个神经元都可以与所有其他神经元连接. 反馈型神经网络有连续和离散系统两类, 主要取决于是用微分方程还是差分方程模型描述. Hopfield 神经网络是反馈型网络的代表. Hopfield 网络由美国学者 Hopfield 提出, 他为这类网络引入了一种稳定过程, 即提出了人工神经网络能量函数(也称李雅普诺夫函数)的概念, 使网络的运行稳定性判断有了可靠而简便的依据. Hopfield 网络在联想存取及优化计算等领域得到了成功的应用, 拓宽了神经网络的应用范围. 另外, Hopfield 网络还有一个显著的优点就是, 它与电子电路存在明显的对应关系, 使得该网络易于理解和便于实现. 本节以 Hopfield 神经网络为代表介绍反馈型神经网络.

13.5.1 离散 Hopfield 网络

13.5.1.1 网络拓扑结构

Hopfield 网络的基本结构如图 13-8 所示, 即神经元之间的信息传递不再是从一层到另一层, 而是各神经元之间存在联系. Hopfield 网络有离散和连续系统两类, 主要取决于用差分模型还是用微分模型描述.

设 $N_1, N_2, \dots, N_n$ 表示网络的 n 个神经元, 其转移特性函数为 $f_1(x), f_2(x), \dots, f_n(x)$, 阈值为 $\theta_1, \theta_2, \dots, \theta_n$. 对于离散型 Hopfield 网络, 各结点一般选用相同的转移特性函数(或激活函数), 且为符号函数, 即有

$$f_1(x) = f_2(x) = \dots = f_n(x) = \text{sign}(x)$$

为以后分析方便, 我们选各点阈值相等, 且等于 0, 即有

$$\theta_1 = \theta_2 = \dots = \theta_n = 0$$

同时 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T, \mathbf{x} \in \{-1, 1\}^n$ 为网络的输入, $\mathbf{y} = (y_1, y_2, \dots, y_n)^T, \mathbf{y} \in \{-1, 1\}^n$ 为网络的输出.




图 13-8 Hopfield 网络模型

$\mathbf{v}(t) = (v_1(t), v_2(t), \dots, v_n(t))^T, \mathbf{v}(t) \in \{-1, 1\}^n$ 为网络在时刻 t 的状态, 其中 $t \in \{0, 1, 2, \dots\}$

为离散时间变量; W_{ij} 为从 N_i 到 N_j 的连接权值. Hopfield 网络是对称的, 即有

$$W_{ij} = W_{ji}, i, j \in \{1, 2, \dots, n\}$$

整个网络所有 n 个结点之间的连接强度用矩阵 $\mathbf{W}$ 来表示, $\mathbf{W}$ 称为网络连接权矩阵, 显然它

是一个 $n \times n$ 对称矩阵.

可以看出, Hopfield 网络为一层结构的反馈网络, 能处理双极型离散数据 (即输入 $-1, +1$) 及二进制数据 (即输入 $0, 1$). 当网络经过适当训练以后, 可以认为网络处于等待工作状态. 而对网络给定初始输入时, 网络就处于特定的初始状态. 由此初始状态开始运行, 可得到网络输出 (即网络的下一状态). 然后这个输出状态通过反馈连接会送到网络的输入端, 作为网络下一阶段运行的输入信号, 而该输入信号可能与初始输入信号不同. 由这个新的输入可得到下一步的输出, 该输出也可能与上一步的输出不同. 如此下去, 网络的整个运行过程就是上述反馈过程的重复. 如果网络是稳定的, 那么随着多次反馈运行, 网络状态的变化将逐渐减少, 达到稳态. 这时可得到网络的稳定输出. 用公式表示为

$$\begin{cases} v_j(0) = x_j \\ v_j(t+1) = f_j\left(\sum_{i=1}^n W_{ij}v_i(t) - \theta_i\right) \end{cases} \quad (13-20)$$

其中, f_j 已被定义, 为方便起见, θ_i 常取 0 值. 若有某个时刻 t , 从此以后网络状态下不再变迁, 即有 $v(t+1) = v(t)$, 则有输出 $y = v(t)$. 在网络运行的过程中, 网络神经元状态的演变有两种形式:

(1) 异步更新. 在任一时刻 t , 只有神经元 N_j 的状态已更新, 而其余神经元保持不变, 即对某个特定的 i , $v_i(t+1) = \text{sign}\left(\sum_{j=1}^n W_{ij}v_j(t)\right)$.

(2) 全并行工作方式, 即 $v_i(t+1) = \text{sign}\left(\sum_{j=1}^n W_{ij}v_j(t)\right), i \in \{1, 2, \dots, n\}$.

这时也可以把状态转移方程写成向量形式 $v(t+1) = \text{sign}(Wv(t))$.

下面先给出几个基本概念的定义, 它们与网络运行过程中的状态变迁有关.

定义 13-1 (网络稳定性) 若网络从初始状态 $v(0)$ 开始, 经过有限时间 t 以后, 网络的状态不再发生变化, 即 $v(t+\Delta t) = v(t), \Delta t > 0$, 则称网络是稳定的.

定义 13-2 (网络吸引子) 设 $t=0$ 时对网络输入模式 x , 网络处于状态 $v(0)$, 而在时刻 t , 网络到达状态为 $v(t)$. 若 $v(t)$ 稳定, 则称 $v(t)$ 为网络的稳定吸引子. 在非稳定吸引子的情况, 若网络状态有规律地在某些状态震荡, 则称网络处在混沌状态.

定义 13-3 (吸引子的吸引域) 对于某些特定的初始状态, 网络按一定的运行规则最后可能稳定在同一吸引子上, 称能够稳定在吸引子 $v(t)$ 的所有初始状态的集合为吸引域 $v(t)$.

13.5.1.2 网络运行的收敛性

收敛性是评价反馈型网络的重要性能指标. 在离散 Hopfield 网络中, 如果网络权值对称, 则可以定义网络运行的能量函数. 当采用符号激活函数时, 设网络状态为 $(v_1, v_2, \dots, v_n)$, Hopfield 网络的能量函数可定义为

$$E = -\frac{1}{2} \sum_i \sum_j W_{ij}v_i v_j + \sum_i \theta_i v_i \quad (13-21)$$

其中, $W_{ii} = 0, W_{ij} = W_{ji}$.

定理 13-2 若能量函数 (13-21) 有下界, 设网络状态按异步方式更新, 且网络权值对称, 无自反馈, 那么网络状态在有限步内收敛到稳定点.

证 假设网络中的第 k 个神经元 N_k 的状态发生变化,由原状态 v_k 变为新状态 $v_k^{(1)}$, N_k 的状态变化后的网络能量 $E^{(1)}$ 为

$$E^{(1)} = -\frac{1}{2} \sum_i \sum_{j \neq i} W_{ij} v_i^{(1)} v_j^{(1)} + \sum_i \theta_i v_i^{(1)}$$

当 $i, j \neq k$ 时有 $v_i^{(1)} = v_i, v_j^{(1)} = v_j$, 所以

$$\Delta E = E^{(1)} - E = -\frac{1}{2} \sum_{i \neq k} W_{ik} \Delta v_k v_i - \frac{1}{2} \sum_{j \neq k} W_{kj} \Delta v_k v_j + \theta_k \Delta v_k$$

由于网络的对称性,有

$$\Delta E = -\Delta v_k \left(\sum_{i \neq k} W_{ik} v_i - \theta_k \right)$$

若无状态变化时,网络总能量保持不变. 则由网络的双极性 $v_k, v_k^{(1)} \in \{-1, 1\}$ 推得

$$\Delta v_k = v_k^{(1)} - v_k = 2v_k^{(1)}$$

进一步改写为

$$\Delta E = -2v_k^{(1)} \left(\sum_i W_{ik} v_i - \theta_k \right) = -2v_k^{(1)} s_k$$

网络状态演变按方程

$$v_k^{(1)} = \text{sign}(s_k)$$

进行,由 sign 函数(符号函数)性质立即可推得 $v_k^{(1)} s_k > 0$, 或

$$\Delta E = -2v_k^{(1)} s_k < 0$$

即网络能量函数随网络状态的变化单调下降. 另外,由于网络能量函数有下界,因此网络必在有限步后收敛.

定理 13-3 假设网络状态按同步全并行方式更新,则在网络权矩阵对称且非负定的条件下,对于网络状态的每一次变化,网络能量函数 E 单调下降.

证 把能量函数改写为矩阵形式

$$\Delta E = -\frac{1}{2} \mathbf{v} \mathbf{W} \mathbf{v}^T + \boldsymbol{\theta} \mathbf{v}^T$$

将 E 在 $\mathbf{v}(t)$ 处展开成 Taylor 级数,取前两项并稍加整理就可以得到网络状态由 $\mathbf{v}(t)$ 变为 $\mathbf{v}(t+1)$ 的能量变化为

$$\Delta E = -s(t) (\Delta \mathbf{v})^T - \frac{1}{2} (\Delta \mathbf{v}) \mathbf{W} (\Delta \mathbf{v})^T$$

其中 $s(t) = \mathbf{v}(t) \mathbf{W} - \boldsymbol{\theta}$. 而 $\Delta \mathbf{v} = \mathbf{v}(t+1) - \mathbf{v}(t)$. $\Delta v_i s_i(t) > 0$, 有 $s(t) (\Delta \mathbf{v})^T > 0$. 因为 $\mathbf{W}$ 为非负定的条件,有 $\frac{1}{2} (\Delta \mathbf{v}) \mathbf{W} (\Delta \mathbf{v})^T \geq 0$, 从而知道 $\Delta \mathbf{v} \neq 0$ 时,必有

$$\Delta E = E(t+1) - E(t) < 0$$

即网络能量下降. 网络对于状态的同步更新是稳定的. $\square$

能量函数是反馈网络中一个重要的概念,根据能量函数可以容易地判断网络的稳定性,网络的能量值是与网络状态相关的量. 当网络结构一定时,能量的改变对应着状态的变迁,神经网络的能量函数(又称李雅普诺夫函数)是一个拓展的概念,可能有也可能没有特定的物理能量定义. 但是对于特定的网络,其能量函数反映了该网络一定的动态性. 还有一点应该强调,若一个网络具有能量函数,那么该能量函数可能并不是唯一的. 同样地,如果网络连

接权值不对称,则怎样研究网络运行的收敛性是一直困扰人们的问题,因为此时一般来说不可能定义能量函数,这个问题还值得进一步研究.

13.5.1.3 网络的学习规则

Hopfield 的孤立吸引子可以用作联想存储器.吸引域的存在,意味着可以输入有噪声干扰的、残缺的或是部分的信息而联想出完整的信息.为此需要正确设定权值矩阵(由编码方法或学习规则确定),使得吸引子恰好对应于要存储的信息.

Hopfield 自联想记忆模型的提出已有近 20 年的历史,这个离散联想模型由于其简单又不失一般性而受到许多学者的广泛关注.因为它是分布式记忆的典型模型,所以对它的模式学习、记忆容量以及记忆模式的吸引域研究一直都是神经网络的热点之一.

联想记忆的编码方法或学习方法是实现神经网络联想记忆的基础.一般说来,在进行 Hopfield 联想记忆编码时,我们要求:(1)权值矩阵 W 为对称矩阵且对角线元素为 0(即无自反馈),即 $W_{ii} = 0, W_{ij} = W_{ji}, i \neq j$; (2)能够记忆预先给定的 K 个模式 $x^{(1)}, x^{(2)}, \dots, x^{(K)}$, 即 $x_i^{(k)} = \text{sign}(\sum_{j \neq i} W_{ij} x_j^{(k)} + \theta_i)$, ($i = 1, 2, \dots, n; k = 1, 2, \dots, K$). 其中 $\text{sign}(\cdot)$ 为符号函数, 即当 $x \geq 0$ 时, $\text{sign}(x) = 1$; 当 $x < 0$ 时, $\text{sign}(x) = -1$. 以后为方便起见,记 $W_{ii} = \theta_i$.

令 $W_{ij} = \alpha \sum_{k=1}^K x_i^{(k)} x_j^{(k)}$ 或矩阵形式为 $W = \alpha \sum_{k=1}^K [x^{(k)} (x^{(k)})^T - I]$, 可以得到 Hebb 学习规则.

由于它的简单性,往往成为其他记忆问题的分析基础,其中 I 为 $n \times n$ 单位矩阵.但是由于 Hebb 规则所编码的容量有限,并不能找到好的权值矩阵,因此还需要其他编码方法.

限制条件(1)主要为了保证网络在输入有误差的情况下仍能正确回忆所记忆的模式,而条件(2)则是为了使预先给定的模式成为网络的不动点.

如果不考虑限制条件(1),则网络的学习就成为感知器学习问题,可用感知器学习规则进行学习.但这时所得的权值矩阵一般不满足条件(1)的限制.考虑到联想记忆对网络权值矩阵的限制(1)所构成的集 S 为凸集,这时将学习所得的矩阵投影到该凸集 S 上,该投影算子可以显式地求得.这样可以得到对称的矩阵,但此时它不一定仍满足限制条件(2);如果不满足,再利用感知器学习规则进行学习,然后将学习所得的矩阵投影到该凸集 S 上,这样交替进行满足(1)和(2)的学习.

综合前面的讨论,可归结出以下的快速编码方法:

(1)开始赋予权值矩阵 $W(0)$ 以一个较小但不为 0 的随机数, $t=0$ 并且要求

$$W_{ij}(0) = W_{ji}(0) \quad (i, j = 1, 2, \dots, n)$$

(2)随机输入模式 $x^{(k)}$ ($1 \leq k \leq K$), 以 $x^{(k)}$ 作为当前的输入模式 $x(t)$, 即

$$x_i(t) = x_i^{(k)} \quad (i = 1, 2, \dots, n)$$

计算

$$r_i(t) = (\sum_{j \neq i} W_{ij}(t) x_j(t) + W_{ii}(t)) x_i(t) \quad (i = 1, 2, \dots, n)$$

若网络模式 $x^{(k)}$ 稳定,即对所有的 $i = 1, 2, \dots, n$ 有 $r_i(t) \geq 0$, 转到步骤(4); 否则进行步骤(3).

(3)更新网络权值:

$$W_{ij}(t+1) = W_{ij}(t) - \frac{1}{2}(\varphi(r_i(t)) + \varphi(r_j(t))) x_i(t) x_j(t), \quad i \neq j$$

$$W_{ii}(t+1) = W_{ii}(t) - \varphi(r_i(t)) x_i(t) \quad (i = 1, 2, \dots, n)$$

$$t = t + 1$$

(4) 若权值对所有模式稳定, 则停机; 否则转步骤(2).

其中 $\varphi(\cdot): \mathbb{R}^1 \rightarrow \mathbb{R}^1$ 定义为: 当 $r \geq 0$ 时, $\varphi(r) = 0$; 当 $r < 0$ 时, $\frac{2r}{n} - \beta < \varphi(r) < \alpha_0 < 0, \beta > 0$.

对于上述编码方法有下面的收敛定理:

定理 13-4 对于预先给定的 $\{-1, 1\}^n$ 中的 K 个模式 $x^{(1)}, x^{(2)}, \dots, x^{(K)}$, 若存在实对称矩阵 W^* 满足 $x_i^{(k)} \left(\sum_{j \neq i} W_{ij}^* x_j^{(k)} + W_{ii}^{(k)} \right) > \beta_0 > 0, (i = 1, 2, \dots, n, k = 1, 2, \dots, K)$, 那么上述关于 Hopfield 联想记忆的编码方法在有限步内收敛.

本定理的证明过程详见参考文献[49].

若不考虑网络的容错性能, 仅仅考虑网络的容量, 则意义不大. 用上述编码方法所给出的编码有时容错性能较差. 为了使所得的权值矩阵对记忆样本的吸引域尽可能地大, 利用网络权值矩阵所构成的集 S_w 为一个锥形凸集, 求 S_w 在一个截面的中心. 具体地, 利用前面的算法, 求出一组满足条件的权值矩阵 $W_1, W_2, \dots, W_M$, 每一个矩阵 W_i 除以其绝对值最大元素的绝对值使得它的绝对值最大的元素的绝对值为 1. 设新求得的矩阵为 $W_1^*, W_2^*, \dots, W_M^*$, 然后求出这些矩阵的平均值矩阵 $W = \frac{1}{M}(W_1^* + W_2^* + \dots + W_M^*)$ 即为所求.

至此, 我们涉及 Hopfield 网络的两种运行形式, 对应两种不同的应用方向, 即联想记忆和优化计算.

Hopfield 在联想记忆应用中利用网络稳定在其吸引子的性质. 具体讲就是对样本模式集 $\{x^{(1)}, x^{(2)}, \dots, x^{(p)}\}$ 采用一定的学习方法, 形成合理的权矩阵 W , 使样本模式成为网络的稳定状态, 学习过程结束后, 网络处于工作状态. 对网络输入初始模式 x , 若 x 成为样本模式之一, 则 x 为不动向量. 若 x 不属于样本模式, 则网络按海明距离收敛稳定在与 x 最为接近的某一样本模式.

Hopfield 网络应用于优化问题时, 是先把问题表述成能量函数, 进一步由能量函数推出网络权结构, 然后在某种条件下让网络运行. 网络的稳定状态, 一般来说对应于问题的解答.

由此可见, 反馈神经网络应用于联想记忆与优化是相对偶的. 应用于优化计算时, 网络权矩阵 W 为已知, 目的是寻找具有最小能量值的稳定状态. 用作联想记忆时, 稳定状态是给定的, 目的是通过学习过程来得到合适的权矩阵 W .

13.5.2 连续 Hopfield 网络

13.5.2.1 网络模型

Hopfield 网络可以推广到输入和输出都取连续值的情形. 这时网络的基本结构不变, 状态方程在形式上也相同. 若定义网络中第 j 个神经元 N_j 的总输入为 u_j , 输出状态为 v_j , 则网络的状态转移方程可写为

$$v_i = g(u_i) = g\left(\sum_j W_{ij}x_j - \theta_i\right) \quad (13-22)$$

其中神经元的转移特性函数(或激活函数) g 为 s 型函数, 一般常用的有

$$g_1(x) = \frac{1}{1 + e^{-\lambda x}}$$

$$g_2(x) = \text{th}(\lambda x)$$

两个函数的共同特点是当 $x \rightarrow \infty$ 及 $x \rightarrow -\infty$ 时, 函数值饱和于两极, 从而限制了神经网络中状态 v_i 及流动信息 u_i 的增长范围. 显然, 若使用 g_1 , 则 $v_i \in (0, 1)$; 若使用 g_2 , 则 $v_i \in (-1, 1)$. 函数 g_1, g_2 的参数 λ 用以控制 s 型函数在 0 点附近的变化数, 而 g_2 可看作为符号函数 $\text{sign}(x)$.

在网络的整个运行过程中, 所有结点状态的演变具有三种形式: 异步更新、同步更新和连续更新. 连续更新表示网络所有结点都随时间并行更新, 如同用电子元件实现的 Hopfield 网络结点状态随电路参量不断改变一样. 还有一点要说明的是, 离散 Hopfield 网络中状态改变就意味着网络输出在“1”和“-1”之间翻转, 而连续 Hopfield 网络的网络状态存在电子电路与 Hopfield 网络直接对应, 利用运算放大器模拟神经元的激活函数, 连接电阻决定各种神经元之间的连接强度, 电容 c_j 及电阻 ρ_j 用来模拟生物神经元的输出时间常数.

按克希荷夫电流定律有下列方程

$$c_j \frac{du_j}{dt} + \frac{u_j}{\rho_j} = \sum \frac{1}{R_{ij}}(v_i - u_j) + I_j$$

对上式进行整理得

$$c_j \frac{du_j}{dt} = \sum_i \frac{v_i}{R_{ij}} - \left(\frac{1}{\rho_j} + \sum_i \frac{1}{R_{ij}} \right) u_j + I_j \quad (13-23)$$

令

$$T_{ij} = \frac{1}{R_{ij}}$$

$$\frac{1}{R_j} = \frac{1}{\rho_j} + \sum_i \frac{1}{R_{ij}}$$

则有

$$\begin{cases} c_j \frac{du_j}{dt} = \sum_i T_{ij} v_i - \frac{u_j}{R_j} + I_j \\ v_i = g_i(u_i), i = 1, 2, \dots, n \end{cases} \quad (13-24)$$

式(13-24)是一个动力系统方程, 在连续 Hopfield 网络中要求函数 $v_i(t)$ 有很好的光滑性. 式(13-22)与式(13-23)或式(13-24)结合在一起就能较好地描述连续 Hopfield 网络的动态过程(对应离散网络的状态转换过程). 微分方程式(13-23)反映了网络状态的连续更新的意义.

连续 Hopfield 网络的吸引子、吸引子的稳定性和吸引域性质的研究方法主要是通过研究动力系统和与它相对应的李雅普诺夫能量函数的性质. 连续动力系统与离散动力系统有很多相似之处, 因此连续动力系统是反馈型神经网络研究的一个基础, 从物理学的角度看有这样的现象: 随着系统的运动, 其储存的能量随时间的增长而衰减, 直至趋于能量极小的平衡状态. 由此原理, Hopfield 人工神经网络一般采用稳定性的李雅普诺夫第二方法, 或称直接法, 它首先给出微分方程和对应的能量函数或广义能量函数, 在研究函数的特性后, 可以不用求解系统的运动方程, 而给出系统稳定性的信息.

13.5.2.2 网络运行的收敛性

Hopfield 根据模拟电子线路构造的能量函数是

$$E = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n T_{ij} v_i v_j - \sum_{i=1}^n v_i I_i + \sum_{i=1}^n \frac{1}{R_i} \int_1^{v_i} g^{-1}(v) dv \quad (13-25)$$

它所对应的动力系统就是式(13-24),式(13-24)与式(13-25)有如下关系

$$-\frac{du_i}{dt} = \frac{\partial E}{\partial v_i} \quad (13-26)$$

由式(13-24)、式(13-25)和式(13-26)得到

$$\begin{aligned} \frac{dE}{dt} &= \sum_{i=1}^n \frac{\partial E}{\partial v_i} \frac{dv_i}{dt} = - \sum_{i=1}^n \frac{du_i}{dt} \frac{dv_i}{dt} = - \sum_{i=1}^n \frac{du_i}{dv_i} \left(\frac{dv_i}{dt} \right)^2 \\ &= - \sum_{i=1}^n \frac{dg_i^{-1}(v_i)}{dv_i} \left(\frac{dv_i}{dt} \right)^2 \leq 0 \end{aligned} \quad (13-27)$$

特别地,当 $\frac{dv_i}{dt}=0, (i=1,2,\dots,n)$ 时, $\frac{dE}{dt}=0$.

对于能量函数式(13-25),可以得到如下定理.

定理 13-5 假设神经元转移特性函数 g 具有反函数 g^{-1} , 且 g^{-1} 是单调的、连续且递增的, 同时网络结构对称: $T_{ij} = T_{ji}, T_{ii} = 0, i, j \in \{1, 2, \dots, n\}$. 那么由方程(13-22)和(13-23)或(13-24)描述的网络是稳定的.

本定理的证明过程详见参考文献[49].

能量分布也可以用能量曲面来理解. 要注意, 能量分布曲面与吸引子分布应存在对应关系, 即吸引子对应着能量曲面的极小区域.

若网络结构不对称, 则无法保证网络的稳定性. 这时, 在网络的运行过程中可能出现极限环或混沌状态.

从式(13-24)、式(13-25)、式(13-26)和式(13-27)的推导可以看出, Hopfield 神经网络模型正是李雅普诺夫第二方法的应用. 第一步是根据实际问题构造能量函数, 然后利用电路系统的背景建立式(13-25)所描述的动力系统方程, 其次再利用动力系统方程的计算, 求解平衡点. 式(13-27)表明, 随着时间的推移, 能量函数逐渐下降. 当式(13-24)的系统方程组达到平衡点时, 式(13-27)也降到了一个能量函数的导数为 0 的点. 网络达稳定状态时, 能量 E 为极小值.

用 Hopfield 神经网络求解组合优化问题可归结为下面的计算步骤:

- (1) 针对实际的组合优化问题构造能量函数, 使得能量函数有好的稳定性, 如具有正定二次型形式;
- (2) 由能量函数, 根据式(13-26)的关系求解动力系统方程(13-24);
- (3) 用数值计算的方法求解动力系统方程(13-24)并解出平衡点(或吸引子). 在一定条件下, 平衡点就是稳定点, 达到极小值.

13.6 人工神经网络应用案例

人工神经网络的应用领域非常广泛, 各种不同的应用案例不胜枚举, 本节仅介绍几个经典性的案例.

13.6.1 自组织网络用于模式识别

自组织神经网络可以较好地完成任务,其中每一个神经元结点对应一个聚类中心.与普通聚类算法不同的是,所得的聚类之间仍保持一定的关系,就是在自组织网络结点平面上相邻或相距较近的结点对应的类别,它们之间的相似性要比相距较远的类别之间的大.因此可以根据各个类别在结点平面上的相对位置进行类别的合并和类别之间关系的分析.

自组织特征映射最早的提出者 Kohonen 的科研组就成功地利用这一原理进行了芬兰语语音识别.他们的做法是,将取自芬兰语各种基本语音的各个样本按一定顺序轮流输入到一个自组织网络中进行学习,经过足够次数的学习后这些样本逐渐在网络结点中形成确定的映射关系,即每个样本都映射到各自固定的一个结点(在这个样本作输入时,该结点为最佳匹配点或具有最大输出),而映射到同一结点的样本就可以看成一个聚类.学习完成以后,发现不但同一聚类中的样本来自同一音素,而且相邻结点对应的聚类中的样本往往来自相同或相近发音的音素.这样,把各个聚类对应的发音标到相应的结点上,在识别时,对于新的输入样本,将其识别为它映射到的结点所标的发音即可.这种做法实际上是在非监督学习的基础上进行监督模式识别.其最大的优点就是,最终的各个相邻聚类之间是有相似关系的,即使识别时把样本映射到了一个错误的结点,它也倾向于被识别成同一个音素或者一个发音相近的音素,这就十分接近人的识别特性.

13.6.2 Hopfield 人工神经网络在 TSP 中的应用

TSP 问题即旅行商问题(Traveling Salesman Problem, TSP),描述如下:

一个商人欲到 n 个城市推销商品,每两个城市 i 和 j 之间的距离为 d_{ij} ,如何选择一条道路使得商人在每个城市走一遍以后回到起点且所走路径最短?

TSP 还可以细分为对称和非对称距离两大类问题.当 $\forall i, j$ 时,有 $d_{ij} = d_{ji}$,称为对称 TSP,否则称为非对称 TSP.对一般的 TSP,它的一种数学模型描述为:

$$\begin{aligned}
 & \min \sum_{i \neq j} d_{ij} x_{ij} \\
 & \text{s. t. } \sum_{j=1}^n x_{ij} = 1 \quad (i = 1, 2, \dots, n) \\
 & \quad \sum_{i=1}^n x_{ij} = 1 \quad (j = 1, 2, \dots, n) \\
 & \quad \sum_{i, j \in s} x_{ij} \leq |s| - 1, 2 \leq |s| \leq n - 2, s \subset \{1, 2, \dots, n\} \\
 & \quad x_{ij} \in \{0, 1\} \quad (i, j = 1, 2, \dots, n; i \neq j)
 \end{aligned} \tag{13-28}$$

以上是基于图论的 TSP 数学模型.其中决策变量 $x_{ij} = 1$ 表示商人行走的路线包含从城市 i 到城市 j 的路径, $x_{ij} = 0$ 表示商人没有选择走这条路. $i \neq j$ 的约束可以减少变量的个数,使得共有 $n \times (n - 1)$ 个决策变量.目标函数要求距离之和最小.两个等式约束表示每个城市经过一次,不等式约束的目的是约束旅行商在任何一个城市子集中不形成回路,其中 $|s|$ 表示集合 s 中元素的个数.已经证明, TSP 问题是一个 NP 问题.

为了方便神经网络求解,本节采用另一种方法表示 TSP 问题的解. 用一个 $n \times n$ 矩阵表示 TSP 的一个解,第 i 行表示商人到达该城市的顺序,第 i 行由 0,1 数字组成一个 n 维向量,其中只能有一个分量为 1,1 所在的序数是商人到达的序数. 如向量(00010)表示商人第四个访问该城市.

例如,四个城市 TSP 的一个解的矩阵表示为

	1	2	3	4
城市 1	0	1	0	0
城市 2	0	0	1	0
城市 3	1	0	0	0
城市 4	0	0	0	1

它表示商人行走的城市顺序为:3—1—2—4.

从本例可以看出,用矩阵表示 TSP 解的方法实际上采用的还是图论的思想,与模型(13-28)是相似的,只是附加了每一行的和每一列的和各为 1. 由此构造一个有 $n \times n$ 个神经元的神经网络. 对应 (i,j) 位置的神经元,其输出为 y_{ij} ,输入为 z_{ij} ,两个城市 x 和 y 之间的距离是 d_{xy} . 由期望每一行的和为 1,一个等价的结论是

$$E_1 = \sum_{u=1}^n \sum_{i=1}^n \sum_{j \neq i} y_{ui} y_{uj} \quad (13-29)$$

为 0. 式(13-29)中 $E_1 = 0$ 的含义是每一行最多有一个 1,可以全为 0. 同理要求神经元的每一列的关系式

$$E_2 = \sum_{i=1}^n \sum_{u=1}^n \sum_{v \neq u} y_{ui} y_{vi} \quad (13-30)$$

为 0.

要保证每一行每一列正好有一个 1,理想状态是

$$E_3 = \left(\sum_{i=1}^n \sum_{j=1}^n y_{ij} - n \right)^2 \quad (13-31)$$

为 0.

当 E_1, E_2, E_3 三项都达到理想状态时也只保证得到 TSP 的一个可行解,而 TSP 的一个重要目标是得到一条费用最小的最短路径. 于是,当 $d_{uv} = d_{vu}$ 时,考虑使下式

$$E_4 = \sum_{u=1}^n \sum_{v \neq u} \sum_{i=1}^n d_{uv} y_{ui} (y_{vi-1} + y_{vi+1}) \quad (13-32)$$

最小,其中 $y_{u0} = y_{un}, y_{un+1} = y_{u1}$. 由神经元的构造,两相邻的列表示商人行走的相邻城市,故 $d_{uv} d_{ui} d_{vi+1}$ 表示城市 u 和 v 之间的距离,式(13-32)是其对称形式.

最后将能量函数写成

$$E = \frac{A}{2} E_1 + \frac{B}{2} E_2 + \frac{C}{2} E_3 + \frac{D}{2} E_4 + \alpha E_5 \quad (13-33)$$

式中, A, B, C, D, α 为非负常数,表示 E_1, E_2, E_3, E_4, E_5 项对能量 E 的贡献大小. 按式(13-25)有

$$E_5 = \sum_{i,j} \frac{1}{R_{ij}} \int_0^{y_{ij}} g_{ij}^{-1}(x) dx$$

由式(13-26)的关系,得

$$\begin{cases} \frac{dz_{ui}}{dt} = -\frac{\partial E}{\partial y_{ui}} \\ = -\alpha z_{ui} - A \sum_{j \neq i} y_{uj} - B \sum_{v \neq u} y_{vi} - C \left(\sum_{v=1}^n \sum_{j=1}^n y_{vj} - n \right) - D \sum_{v \neq u} d_{uv} (y_{vi+1} + y_{vi-1}) \\ y_{ui} = g(z_{ui}) \end{cases} \quad (13-34)$$

将方程组(13-34)的系数整理后,得

$$\begin{cases} w_{ui,vj} = -A\delta_{uv}(1-\delta_{ij}) - B\delta_{ij}(1-\delta_{uv}) \\ \quad - C - Dd_{uv}(\delta_{j,i+1} + \delta_{j,i-1}) \\ I_{ui} = nC \end{cases} \quad (13-35)$$

其中

$$\delta_{ij} = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}, \quad d_{uu} = 0$$

于是方程组(13-34)就是一个标准的动力系统方程。

上面的讨论将求解 TSP 问题归结为 Hopfield 计算常规步骤. 由式(13-33)的构造、式(13-27)推导和定理 13-2、定理 13-3 的结论,知式(13-34)的平衡点(或吸引子)是稳定点. 存在的问题是参数 α, A, B, C, D 的选取,这些参数的选择是实际计算中的难点. 实际计算中常常取多组参数计算比较,从中选择好的解.

下面是 Hopfield 给出的神经元初始值和参数选取的规则.

Hopfield 在求解 10 个城市的 TSP 问题时,数值计算的参数选取如下

$$\alpha = 1, \quad A = B = D = 500, \quad C = 200$$

Sigmoid 函数为

$$y_{ui} = f(z_{ui}) = \frac{1}{1 + e^{-\frac{2z_{ui}}{\mu_0}}}$$

其中, $\mu_0 = 0.02$.

初始设置 y_{ui} 都相等,使得

$$\sum_{u=1}^{10} \sum_{i=1}^{10} y_{ui} = 1$$

即期望最终的输出结果使得每一行和每一列只有一个输出非常接近 1. 用初始相等的 y_{ui} 可

以解出 $z_{00} = -\frac{\mu_0}{2} \ln 9$. 给 z_{00} 一个扰动

$$z_{ui} = z_{00} + \delta z_{ui}, \quad -0.1\mu_0 \leq \delta z_{ui} \leq 0.1\mu_0$$

其中, δz_{ui} 为区间 $[-0.1\mu_0, 0.1\mu_0]$ 上的均匀分布,为动力系统数值计算的初始点.

Hopfield 的开创性工作是给出求解组合优化问题的一种神经网络方法,但其不足也是显而易见的. 第一是参数 A, B, C, D, α 的选取. 过多的参数增加了计算的工作量. 第二是参数 μ_0 的确定. μ_0 较小时,使得 Sigmoid 函数曲线有较好的识别能力,输出值接近 0 或 1,但初始解的范围较小,因此计算收敛的速度慢. 当参数 μ_0 较大时,又难以使输出值接近 0 或 1,使得路径的描述产生混淆. 第三个不足是它的计算量和收敛的效果. 由于它的能量函数(13-33)实际上是罚函数. 罚函数势必造成计算量的增加. 再者, A, B, C, D, α 五个参数选取难以

突出 TSP 的目标值, 过多突出 D 会加大解的不可行性, 加大其他参数会忽略目标值.

用神经网络求解 TSP 问题还有其他形式的能量函数, 如用 $y_{ijk} = 1$ 表示商人的第 k 次行走是从 i 城市到 j 城市, 则能量函数可设为

$$E = \frac{A}{2} \sum_{j=1}^n \left(\sum_{i=1}^n \sum_{k=1}^n y_{ijk} - 1 \right)^2 + \frac{B}{2} \sum_{i=1}^n \left(\sum_{j=1}^n \sum_{k=1}^n y_{ijk} - 1 \right)^2 \\ + \frac{C}{2} \left(\sum_{i=1}^n \sum_{j=1}^n \sum_{k=1}^n y_{ijk} - n \right)^2 + \frac{D}{2} \sum_{i=1}^n \sum_{j=1}^n \sum_{k=1}^n d_{ij} y_{ijk}$$

其中上式右端第 1 项表示城市 j 恰好进去一次, 右端第 2 项表示城市 i 恰好进去一次, 第 3 项表示只有一条路径, 第 4 项为行走路线最短.

习 题

13-1 一个两分类问题是非线性可分的. 如果使用前馈神经网络设计分类器, 应使用什么类型的前馈网络, 有什么特殊要求?

13-2 线性规划问题能用神经网络方法求解吗? 阐述你的观点或思路.

13-3 就你关心的或实际遇到的组合优化问题用神经网络方法求解.

参考文献

- [1] 《运筹学》教材编写组. 运筹学[M](修订版). 北京:清华大学出版社,1990.
- [2] 张莹. 运筹学基础[M]. 北京:清华大学出版社,1995.
- [3] 胡运权. 运筹学习题集[M](修订版). 北京:清华大学出版社,2004.
- [4] 刁在筠,郑汉鼎,刘家壮等. 运筹学[M](第二版). 北京:高等教育出版社,2001.
- [5] 何坚勇. 运筹学基础[M]. 北京:清华大学出版社,2007.
- [6] 钱颂迪. 运筹学[M](修订版). 北京:清华大学出版社,1998.
- [7] 薛毅. 最优化原理与方法[M]. 北京:北京工业大学出版社,2001.
- [8] 马振华主编. 现代应用数学手册——运筹学与最优化理论卷[M]. 北京:清华大学出版社,1998.
- [9] 袁亚湘,孙文瑜著. 最优化理论与方法[M]. 北京:科学出版社,1997.
- [10] 胡毓达主编. 非线性规划[M]. 北京:高等教育出版社,1990.
- [11] 边肇祺,张学工等编著. 模式识别[M](第二版). 北京:清华大学出版社,2000.
- [12] 李董辉等编. 数值最优化[M]. 北京:科学出版社,2005.
- [13] 王凌. 智能优化算法及其应用[M]. 北京:清华大学出版社,2001.
- [14] 邢文训,谢金星. 现代优化计算方法[M]. 北京:清华大学出版社,1999.
- [15] Klee V, Minty G J. How Good is the Simplex Algorithm? [M] In: Shisha O. Inequalities III. New York: Academic Press Inc, 1972: 150 ~ 175.
- [16] Knachian L G. A Polynomial Algorithm for Linear Programming[J]. Doklady Acad Nauk USSR, 1979, 244 (5): 1093 ~ 1096.
- [17] Cook S A. The Complexity of Theorem Proving Procedures[M]. In: Proc 3rd ACM Symp on the Theory of Computing ACM, 1979: 151 ~ 158.
- [18] Polya G. How to Solve It? [M]. Princeton: Princeton University Press, 1948.
- [19] 加里 M R, 约翰逊 D S. 计算机和难解性: NP - C 理论导论[M]. 张立昂等译. 北京:科学出版社, 1987.
- [20] Metropolis N, Rosenbluth A W, Rosenbluth M N, et al. Equation of State Calculation by Fast Computing Machines[J]. Journal of Chemical Physics, 1953, 21(6): 1087 ~ 1092.
- [21] Kirkpatrick S, Gelatt Jr C D, Vecchi M P. Optimization by Simulated Annealing[J]. Science, 1983, 220 (13): 671 ~ 680.
- [22] Aarts E H L, Van Laarhoven P J M. Simulated Annealing, Theory and Applications[M]. Dordrecht: D Reidel Publishing Company, 1987.
- [23] Ackley D H, Hinton G E, Sejnowski T J. A Learning Algorithm for Boltzmann Machines[J]. Cognitive Science, 1985(9): 147 ~ 169.
- [24] Seneta E. Non-negative Matrices and Markov Chains[M]. 2nd Edition, New York: Springer Verlag, 1981.
- [25] Isaacson D, Madsen R. Markov Chains[M]. New York: Wiley.
- [26] Geman S, Geman D. Stochastic Relaxation, Gibbs Distributions and the Bayesian Restoration of Images[J]. In: IEEE Proc. Pattern Analysis and Machine Intelligence, PAMI - 6, 1984, 721 ~ 741.
- [27] Dowsland K A. Simulated Annealing. In: Modern heuristic Techniques for Combinatorial Problems (ed Reeves C R), McGraw - Hill.
- [28] Hajek B. Cooling Schedules for Optimal Annealing[J]. Mathematics of Operations Research. 1986, 13(2): 311 ~ 329.

- [29] Kannan D. An Introduction to Stochastic Processes[M]. Elsevier North Holland, Inc. 1979.
- [30] Rayward - Smith V J Osman I H, Reeves C R, Smith G D. Modern Heuristic Search Methods[M]. John Wiley & Sons, 1996
- [31] Huang M D, Romeo F, Sangiovanni - Vincentelli A I. An Efficient General Cooling Schedule for Simulated Annealing[C]. In: Proc of IEEE Int Conference on Computing-Aided Design. Santa Clara, 1986, 381 ~ 384.
- [32] 龚光鲁等. 多峰多维密度模拟退火的可逆算法[J]. 中国科学(A 辑), 2000, 30(2): 1064 ~ 1071.
- [33] 田澎等. 一类非线性规划的模拟退火求解[J]. 控制与决策, 1995, 9(3): 173 ~ 189.
- [34] 向阳等. 推广模拟退火方法及其应用[J]. 物理学进展, 2000, 20(3): 319 ~ 334.
- [35] 郭茂祖等. 模拟退火算法中冷却调度选取方法的研究[J]. 计算机工程, 2000, 29(9): 63 ~ 66
- [36] Pelletier M. Weak Convergence Rates for Stochastic Approximation with Application to Multiple Targets and Simulated Annealing[J]. The Annals of applied Probability, 1998(8): 10 ~ 44.
- [37] David Maquerez. Convergence Rates for Annealing Diffusion Processes [J]. The Annals of applied Probability, 1997, 7(4): 1118 ~ 1139.
- [38] Holland J H. Adaptation in Natural and Artificial Systems. Ann Arbor, MI: The University of Michigan Press, 1975; 2nd edition, Cambridge, MA: MIT Press, 1992.
- [39] 李敏强, 寇纪松等. GA 的数学基础[M]. 北京: 科学出版社, 2002.
- [40] 张文修, 梁怡. GA 的数学基础[M]. 西安: 西安交通大学出版社, 2000.
- [41] Goldberg D E. Genetic Algorithm in Search, Optimization and Machine Learning[M]. Addison - Wiley Publishing Company.
- [42] Wolpert D H, Macready W G. No Free Lunch Theorems for Search Technical Report SFI - TR - 95 - 02 - 010[R]. Santa Fe Institute.
- [43] Mitchell M. An Introduction to Genetic Algorithm[M]. Cambridge, MA: The MIT Press, 1996.
- [44] Rong Long Wang. A Genetic Algorithm for Subset Sum Problem[J]. Neurocomputing, 2004, 57: 463 ~ 468.
- [45] Yen Zen Wang. Using Genetic Algorithm Methods to Solve Course Scheduling Problems[J]. Expert systems with applications, 2003, (25): 39 ~ 50.
- [46] 王跃宣, 刘连臣等. 处理带约束的多目标优化进化算法[J]. 清华大学学报(自然科学版), 2005, 45(1): 103 ~ 106.
- [47] 霍红卫, 许进等. 选择和变异算子的作用分析[J]. 电子学报, 2000, 28(2): 31 ~ 34.
- [48] 谭永基, 曾毅等. 用混合遗传算法求解约束 NLP 问题[J]. 复旦大学学报(自然科学版), 2000, 39(5): 467 ~ 470.
- [49] 史忠植. 知识发现[M]. 北京: 清华大学出版社, 2002.
- [50] 沈世镓. 神经网络系统理论及其应用[M]. 北京: 科学出版社, 1998.
- [51] 杨行峻, 郑君里. 人工神经网络[M]. 北京: 高等教育出版社, 1992.
- [52] 焦李成. 神经网络计算[M]. 西安: 西安电子科技大学出版社, 1993.
- [53] 史忠植. 神经计算[M]. 北京: 电子工业出版社, 1993.

[G e n e r a l I n f o r m a t i o n]

书名=工科研究生教材 最优化计算方法

作者=蒋金山

页数= 2 8 4

S S 号= 1 1 8 8 8 6 1 4

出版日期= 2 0 0 7 年 1 0 月第 1 版