

参数模型谱估计方法

基本概念

经典谱估计的局限性：


1. 实际中常常要求较高的谱分辨率

需要更长的观察序列

2. 窗效应导致频谱“泄漏”

加延迟窗等手段的纠正能力有限，同时影响分辨率

因此：是否存在其他办法使得谱估计更合理？



基本概念

参数模型谱估计的思想:

系统的输入 $w(n)$ 与输出 $x(n)$ 之间存在关系:

$$H(z) = \frac{B(z)}{A(z)} = \frac{\sum_{k=0}^q b_k z^{-k}}{1 + \sum_{k=1}^p a_k z^{-k}} \quad x(n) = -\sum_{k=1}^p a_k x(n-k) + \sum_{k=0}^q b_k w(n-k)$$

若系统输入过程平稳, 输出亦平稳, 则:

$$S_{xx}(f) = |H(f)|^2 S_{ww}(f)$$

假设 $w(n)$ 为 $\mathcal{N} \sim (0, \sigma_w^2)$:

$$r_{ww}(m) = \sigma_w^2 \delta(m) \quad S_{xx}(f) = \sigma_w^2 |H(f)|^2 = \sigma_w^2 \frac{|B(f)|^2}{|A(f)|^2}$$

基本概念

$H(z)$ 的选择:

$$H(z) = \frac{B(z)}{A(z)} = \frac{\sum_{k=0}^q b_k z^{-k}}{1 + \sum_{k=1}^p a_k z^{-k}}$$

1) 若 $q=0$, $b_0=1$:

$$H(z) = \frac{1}{A(z)} = \frac{1}{1 + \sum_{k=1}^p a_k z^{-k}}$$

2) 若 $a_k=0$, $k=1,2,\dots,p$, 则:


$$H(z) = B(z) = \sum_{k=0}^q b_k z^{-k}$$

3) a_k 和 b_k 不全为0, ARMA(p, q)

基本概念

$H(f)$ 的选择:

- 1) AR模型应用最广泛，其参数可由线性方程组求解
- 2) 适合于描述窄谱峰频谱
- 3) MA模型求解难度大
- 4) ARMA模型相对AR和MA的参数少，同样模型参数求解难
- 5) world分解表明：ARMA和MA模型可用AR模型逼近



基本概念

模型的差分方程两边乘 $x^*(n-m)$:

$$E[x(n)x^*(n-m)] = -\sum_{k=1}^p a_k E[x(n-k)x^*(n-m)] + \sum_{k=0}^q b_k E[w(n-k)x^*(n-m)]$$

$$r_{xx}(m) = -\sum_{k=1}^p a_k r_{xx}(m-k) + \sum_{k=0}^q b_k r_{wx}(m-k)$$

其中，互相关与系统脉冲响应有关：

$$r_{wx}(m) = E[x^*(n)w(n+m)] = E\left[\sum_{k=0}^{\infty} h(k)w^*(n-k)w(n+m)\right] = \sigma_w^2 h(-m)$$

$$r_{wx}(m) = \begin{cases} 0, & m > 0 \\ \sigma_w^2 h(-m), & m < 0 \end{cases}$$

基本概念

因此，结合序列的自相关表达式，有：

$$r_{xx}(m) = \begin{cases} -\sum_{k=1}^p a_k r_{xx}(m-k), & m > q \\ -\sum_{k=0}^p a_k r_{xx}(m-k) + \sigma_w^2 \sum_{k=0}^{q-m} h(k) b_{k+m}, & 0 \leq m \leq q \\ r_{xx}^*(-m), & m < 0 \end{cases}$$

表明 $r_{xx}(m)$ 与模型的参数 a_k ， b_k 具有非线性关系。对于 $m > q$ 的情形：

$$\begin{bmatrix} r_{xx}(q) & r_{xx}(q-1) & \cdots & r_{xx}(q-p+1) \\ r_{xx}(q+1) & r_{xx}(q) & \cdots & r_{xx}(q-p+2) \\ \vdots & \vdots & \cdots & \vdots \\ r_{xx}(q+p-1) & r_{xx}(q+p-2) & \cdots & r_{xx}(q) \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_p \end{bmatrix} = - \begin{bmatrix} r_{xx}(q+1) \\ r_{xx}(q+2) \\ \vdots \\ r_{xx}(q+p) \end{bmatrix}$$

基本概念

因此，结合序列的自相关表达式，有：

$$r_{xx}(m) = \begin{cases} -\sum_{k=1}^p a_k r_{xx}(m-k), & m > q \\ -\sum_{k=0}^p a_k r_{xx}(m-k) + \sigma_w^2 \sum_{k=0}^{q-m} h(k) b_{k+m}, & 0 \leq m \leq q \\ r_{xx}^*(-m), & m < 0 \end{cases}$$

1) 求解模型参数 a_k

2) $r_{xx}(m)$ 由 $0 \leq m \leq p$ 时自相关和 a_k 唯一确定，同时外推 $m > q$ 时的自相关

$$\begin{bmatrix} r_{xx}(q) & r_{xx}(q-1) & \cdots & r_{xx}(q-p+1) \\ r_{xx}(q+1) & r_{xx}(q) & \cdots & r_{xx}(q-p+2) \\ \vdots & \vdots & \cdots & \vdots \\ r_{xx}(q+p-1) & r_{xx}(q+p-2) & \cdots & r_{xx}(q) \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_p \end{bmatrix} = - \begin{bmatrix} r_{xx}(q+1) \\ r_{xx}(q+2) \\ \vdots \\ r_{xx}(q+p) \end{bmatrix}$$

基本概念

若仅用AR模型估计，则：

$$r_{xx}(m) = \begin{cases} -\sum_{k=1}^p a_k r_{xx}(m-k), & m > 0 \\ -\sum_{k=1}^p a_k r_{xx}(m-k) + \sigma_w^2, & m = 0 \\ r_{xx}^*(-m), & m < 0 \end{cases}$$

$$\begin{bmatrix} r_{xx}(0) & r_{xx}(-1) & \cdots & r_{xx}(-p+1) \\ r_{xx}(1) & r_{xx}(0) & \cdots & r_{xx}(-p+2) \\ \vdots & \vdots & \cdots & \vdots \\ r_{xx}(p-1) & r_{xx}(p-2) & \cdots & r_{xx}(0) \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_p \end{bmatrix} = - \begin{bmatrix} r_{xx}(1) \\ r_{xx}(2) \\ \vdots \\ r_{xx}(p) \end{bmatrix}$$

同时：

$$\sigma_w^2 = r_{xx}(0) + \sum_{k=1}^p a_k r_{xx}(-k)$$

基本概念

合并后则有方程：

$$\begin{bmatrix} r_{xx}(0) & r_{xx}(1) & r_{xx}(2) & \cdots & r_{xx}(p) \\ r_{xx}(1) & r_{xx}(0) & r_{xx}(1) & \cdots & r_{xx}(p-1) \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ r_{xx}(p) & r_{xx}(p-1) & r_{xx}(p-2) & \cdots & r_{xx}(0) \end{bmatrix} \begin{bmatrix} 1 \\ a_1 \\ a_2 \\ \vdots \\ a_p \end{bmatrix} = \begin{bmatrix} \sigma_w^2 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

即AR模型的Yule-Walker方程。

若用MA(q)模型描述数据，则自相关与 b_k 的关系：

$$r_{xx}(m) = \begin{cases} \sigma_w^2 \sum_{k=0}^{q-m} h(k)b_{k+m}, & 0 \leq m \leq q \\ 0, & m > q \\ r_{xx}^*(-m), & m < 0 \end{cases}$$

AR模型谱估计

最大熵谱估计:

已知观察序列, 确定模型外推自相关序列

$$S_{xx}(f) = \sum_{m=-\infty}^{\infty} r_{xx}(m) e^{-j2\pi f m}$$

外推方法的不同, 自相关序列不同, 则谱就不同

最大熵准则: 最佳的信号模型应该使与功率谱估计对应的信号序列含有最大的信息量。同时满足:

$$\int_{-\frac{1}{2}}^{\frac{1}{2}} S_{xx}(f) e^{j2\pi f m} df = r_{xx}(m), \quad 0 \leq m \leq M$$

假设 $S_{xx}(f)$ 是限带高斯过程的谱, 则谱熵为:

$$H = \int_{-\frac{1}{2}}^{\frac{1}{2}} \ln S_{xx}(f) df$$

AR模型谱估计

最大熵谱估计:

已知观察序列, 确定模型外推自相关序列

$$S_{xx}(f) = \sum_{m=-\infty}^{\infty} r_{xx}(m) e^{-j2\pi f m}$$

最大熵谱估计等价于AR模型拟合, 则谱就不同
又称AR/ME谱估计

使与功率谱估计对应的信号序列含有最大的信息量。同时满足:

$$\int_{-\frac{1}{2}}^{\frac{1}{2}} S_{xx}(f) e^{j2\pi f m} df = r_{xx}(m), \quad 0 \leq m \leq M$$

假设 $S_{xx}(f)$ 是限带高斯过程的谱, 则谱熵为:

$$H = \int_{-\frac{1}{2}}^{\frac{1}{2}} \ln S_{xx}(f) df$$

AR模型谱估计

L-D (Levinson-Durbin) 算法:

利用平稳过程自相关矩阵的性质, 递推地由低阶推导高阶模型的算法。

步骤:

1) 利用已知观察序列估计自相关 $\hat{r}_{xx}(m)$:

$$\hat{r}_{xx}(m) = \frac{1}{N} \sum_{n=0}^{N-|m|-1} x^*(n)x(n+m)$$

2) 然后代入AR模型参数求解方程, 求解 a_k ;

3) 最后由下式估计功率谱:

$$S_{xx}^{YW}(f) = \frac{\hat{\sigma}_{wp}^2}{\left| 1 + \sum_{k=1}^p \hat{a}_p(k) e^{-j2\pi f k} \right|^2} \quad \hat{\sigma}_{wp}^2 = \hat{E}_p = \hat{r}_{xx}(0) \prod_{k=1}^p \left[1 - |\hat{a}_k(k)|^2 \right]$$

AR模型谱估计

L-D (Levinson-Durbin) 方法:

利用平稳过程自相关矩阵的性质, 递推地由低阶推导高阶模型的算法。

步骤:

1) 利用已知观察序列估计自相关 $\hat{r}_{xx}(m)$:

2) 然后代入AR模型

p 阶预测器的最小均方误差的估计值

3) 最后由下式估计功率谱:

$$S_{xx}^{YW}(f) = \frac{\hat{\sigma}_{wp}^2}{\left| 1 + \sum_{k=1}^p \hat{a}_p(k) e^{-j2\pi f k} \right|^2}$$

$$\hat{\sigma}_{wp}^2 = \hat{E}_p = \hat{r}_{xx}(0) \prod_{k=1}^p [1 - |\hat{a}_k(k)|^2]$$

AR模型谱估计

L-D (Levinson-Durbin) 算法:


线性方程组的紧凑形式:

$$\sum_{k=0}^p a_p(k) r_{xx}(l-k) = 0, \quad l=1, 2, \dots, p, \quad a_p(0)=1$$

若增加一组方程, 得到增广正规方程:

$$\sum_{k=0}^p a_p(k) r_{xx}(l-k) = \begin{cases} E_p^f, & l=0 \\ 0, & l=1, 2, \dots, p \end{cases}$$

即为AR(p)模型, $E_p^f = \sigma_w^2$,


$$\begin{bmatrix} r_{xx}(0) & r_{xx}(1) & r_{xx}(2) & \dots & r_{xx}(p) \\ r_{xx}(1) & r_{xx}(0) & r_{xx}(1) & \dots & r_{xx}(p-1) \\ \vdots & \vdots & \vdots & \dots & \vdots \\ r_{xx}(p) & r_{xx}(p-1) & r_{xx}(p-2) & \dots & r_{xx}(0) \end{bmatrix} \begin{bmatrix} 1 \\ a_1 \\ a_2 \\ \vdots \\ a_p \end{bmatrix} = \begin{bmatrix} \sigma_w^2 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

AR模型谱估计

L-D（Levinson-Durbin）算法：

自相关矩阵具有特殊的性质：

$$\mathbf{R}_p = \begin{bmatrix} r_{xx}(0) & r_{xx}^*(1) & \cdots & r_{xx}^*(p-1) \\ r_{xx}(1) & r_{xx}(0) & \cdots & r_{xx}^*(p-2) \\ \vdots & \vdots & \ddots & \vdots \\ r_{xx}(p-1) & r_{xx}(p-2) & \cdots & r_{xx}(0) \end{bmatrix}$$

即为Toeplitz矩阵，也是埃尔米特矩阵

算法思想：利用这种特殊性递归求解方程，从一阶着手，逐次增加阶次，用低阶的解获得高一阶的解

AR模型谱估计

L-D (Levinson-Durbin) 算法:

第一阶的解:

$$a_1(1) = -\frac{r_{xx}(1)}{r_{xx}(0)}$$


其MMSE为:

线性方程组的MMSE

$$\min[\varepsilon_p^f] \equiv E_p^f = r_{xx}(0) + \sum_{k=1}^p a_p(k) r_{xx}(-k)$$

$$E_1^f = r_{xx}(0) + a_1(1)r_{xx}(-1) = r_{xx}(0)[1 - |a_1(1)|^2]$$

令 $a_1(1)=K_1$, 即第一级反射系数



AR模型谱估计

L-D (Levinson-Durbin) 算法:

第二阶的解:

$$a_2(1)r_{xx}(0) + a_2(2)r_{xx}^*(1) = -r_{xx}(1)$$

$$a_2(1)r_{xx}(1) + a_2(2)r_{xx}(0) = -r_{xx}(2)$$

利用第一阶求得的MMSE, 可得:

$$a_2(2) = -\frac{r_{xx}(2) + a_1(1)r_{xx}(1)}{E_1^f}$$

$$a_2(1) = a_1(1) + a_2(2)a_1^*(1)$$

令 $a_2(2) = K_2$, 即第二级反射系数

AR模型谱估计

L-D（Levinson-Durbin）算法：

m 阶方程的系数矢量 $\mathbf{a}_m$ 表示为矢量和的形式：

$$\mathbf{a}_m = \begin{bmatrix} a_m(1) \\ a_m(2) \\ \vdots \\ a_m(m) \end{bmatrix} = \begin{bmatrix} \mathbf{a}_{m-1} \\ \vdots \\ \vdots \\ 0 \end{bmatrix} + \begin{bmatrix} d_{m-1} \\ \vdots \\ \vdots \\ k_m \end{bmatrix}$$

同时将自相关矩 $\mathbf{R}_m$ 阵表示成：

$$\mathbf{R}_m = \begin{bmatrix} \mathbf{R}_{m-1} & \mathbf{r}_{m-1}^{b*} \\ \mathbf{r}_{m-1}^{bT} & r_{xx}(0) \end{bmatrix}$$

其中上标 b 表示将 $\mathbf{r}_{m-1}^T = [r_{xx}(1) \ r_{xx}(2) \ \cdots \ r_{xx}(m-1)]$ 的元素做逆序排列。

AR模型谱估计

L-D (Levinson-Durbin) 算法:

m 阶方程组可被表示为 $\mathbf{R}_m \mathbf{a}_m = -\mathbf{r}_m$

进一步:

$$\begin{bmatrix} \mathbf{R}_{m-1} & \mathbf{r}_{m-1}^{b*} \\ \mathbf{r}_{m-1}^{bT} & r_{xx}(0) \end{bmatrix} \left(\begin{bmatrix} \mathbf{a}_{m-1} \\ 0 \end{bmatrix} + \begin{bmatrix} \mathbf{d}_{m-1} \\ k_m \end{bmatrix} \right) = - \begin{bmatrix} \mathbf{r}_{m-1} \\ r_{xx}(m) \end{bmatrix}$$

展开为:

$$\begin{aligned} \mathbf{R}_{m-1} \mathbf{a}_{m-1} + \mathbf{R}_{m-1} \mathbf{d}_{m-1} + k_m \mathbf{r}_{m-1}^{b*} &= -\mathbf{r}_{m-1} \\ \mathbf{r}_{m-1}^{bT} \mathbf{a}_{m-1} + \mathbf{r}_{m-1}^{bT} \mathbf{d}_{m-1} + k_m r_{xx}(0) &= -r_{xx}(m) \end{aligned}$$

由于 $\mathbf{R}_{m-1} \mathbf{a}_{m-1} = -\mathbf{r}_{m-1}$, 有: $\mathbf{d}_{m-1} = -k_m \mathbf{R}_{m-1}^{-1} \mathbf{r}_{m-1}^{b*}$

AR模型谱估计


L-D (Levinson-Durbin) 算法:

进一步, r_{m-1}^{b*} 是 r_{m-1} 倒序的复共轭, 则:

$$d_{m-1} = -k_m R_{m-1}^{-1} r_{m-1}^{b*} \longrightarrow d_{m-1} = k_m a_{m-1}^{b*} = k_m \begin{bmatrix} a_{m-1}^*(m-1) \\ a_{m-1}^*(m-2) \\ \vdots \\ a_{m-1}^*(1) \end{bmatrix}$$

代入 $r_{m-1}^{bT} a_{m-1} + r_{m-1}^{bT} d_{m-1} + k_m r_{xx}(0) = -r_{xx}(m)$

$$k_m [r_{xx}(0) + r_{m-1}^{bT} a_{m-1}^{b*}] + r_{m-1}^{bT} a_{m-1} = -r_{xx}(m)$$


$$k_m = -\frac{r_{xx}(m) + r_{m-1}^{bT} a_{m-1}}{r_{xx}(0) + r_{m-1}^{bT} a_{m-1}^{b*}}$$

AR模型谱估计

L-D (Levinson-Durbin) 算法:

将 d_m 和 k_m 代入
$$\mathbf{a}_m = \begin{bmatrix} a_m(1) \\ a_m(2) \\ \vdots \\ a_m(m) \end{bmatrix} = \begin{bmatrix} \mathbf{a}_{m-1} \\ 0 \end{bmatrix} + \begin{bmatrix} d_{m-1} \\ \vdots \\ k_m \end{bmatrix}$$

得到L-D算法的递归形式:

$$a_m(m) = k_m = -\frac{r_{xx}(m) + \mathbf{r}_{m-1}^{bT} \mathbf{a}_{m-1}}{r_{xx}(0) + \mathbf{r}_{m-1}^{bT} \mathbf{a}_{m-1}^{b*}} = -\frac{r_{xx}(m) + \mathbf{r}_{m-1}^{bT} \mathbf{a}_{m-1}}{E_m^f}$$

$$a_m(k) = a_{m-1}(k) + k_m a_{m-1}^*(m-k) = a_{m-1}(k) + a_m(m) a_{m-1}^*(m-k), \quad \begin{matrix} k = 1, 2, \dots, m-1 \\ m = 1, 2, \dots, p \end{matrix}$$

$$E_m^f = E_{m-1}^f [1 - |a_m(m)|^2] = E_{m-1}^f (1 - |k_m|^2), \quad m = 1, 2, \dots, p$$

AR模型谱估计

L-D (Levinson-Durbin) 方法:

具体步骤:

1) 令: $p = 0, \hat{E}_0 = \hat{r}_{xx}(0)$

2) 有已计算出 $p-1$ 阶时的 $\hat{a}_{p-1}(k) (1 \leq k \leq p-1)$ 和 $\hat{K}_{p-1}$, 第 p

次递归:

$$\hat{K}_p = \frac{-1}{\hat{E}_{p-1}} \sum_{k=0}^{p-1} \hat{a}_{p-1}(k) \hat{r}_{xx}(p-k)$$

$$\hat{a}_p(p) = \hat{K}_p$$

对于 $k=1, 2, \dots, p-1$, 有:

$$\hat{a}_p(k) = \hat{a}_{p-1}(k) + \hat{K}_p \hat{a}_{p-1}(p-k)$$

$$\hat{E}_p = \hat{E}_{p-1} (1 - |\hat{a}_p(p)|^2)$$

其中 $\hat{K}_i$ 表示第 i 阶的反射系数。

AR模型谱估计

Burg法:

直接利用观测序列 $x(n)$ 估计谱

对于一组观测数据 $x(n)$, $n=0, 1, \dots, N-1$, 前向预测与后向预测估计为:

$$\hat{x}(n) = -\sum_{k=1}^m a_m(k)x(n-k)$$

$$\hat{x}(n-m) = -\sum_{k=1}^m a_m^*(k)x(n+k-m)$$

其中 $a_m(k)$ ($0 \leq k \leq m-1, m=1, 2, \dots, p$) 为前向预测系数,

$a_m^*(k)$ 为后向预测系数, 若为平稳过程, $a_m^*(k) = a_m(k)$

前向预测: 用 m 个 n 时刻之前的数据预测 $x(n)$

后向预测: 用 m 个 $n-m$ 时刻之后的数据预测 $x(n-m)$

AR模型谱估计

Burg法:

前向后向预测误差分别为:

$$f_m(n) = x(n) - \hat{x}(n)$$

$$g_m(n) = x(n-m) - \hat{x}(n-m)$$

递推形式:

$$f_m(n) = f_{m-1}(n) + a_m(m)g_{m-1}(n-1), \quad m = 1, 2, \dots, p$$

$$g_m(n) = a_m(m)f_{m-1}(n) + g_{m-1}(n-1), \quad m = 1, 2, \dots, p$$

误差总平方和:

$$\zeta_m = \sum_{n=m}^{N-1} [|f_m(n)|^2 + |g_m(n)|^2]$$

每一阶的递推总要误差平方和最小:

$$\frac{\partial \zeta_m}{\partial a_m(m)} = 0$$

即可求出 $a_m(m)$, 且 $K_m = a_m(m)$

AR模型谱估计

Burg法:

偏导为:

$$a_m(m) = \hat{K}_m = \frac{-\sum_{n=m}^{N-1} f_{m-1}(n) g_{m-1}^*(n-1)}{\frac{1}{2} \sum_{n=m}^{N-1} \left[|f_{m-1}(n)|^2 + |g_{m-1}(n-1)|^2 \right]}, \quad m = 1, 2, \dots, p$$

式中分子为前向后向预测误差的互相关, 则有 $|K_m| < 1$, 保证全极点模型的稳定

对于 $a_m(k)$, $1 \leq k \leq m-1$ 可利用L-D算法求解:

$$a_m(k) = a_{m-1}(k) + K_m a_{m-1}^*(m-k), \quad \begin{array}{l} 1 \leq k \leq m-1 \\ 1 \leq m \leq p \end{array}$$

$$\hat{E}_m = \left[1 - |K_m|^2 \right] \hat{E}_{m-1} - |f_{m-1}(m-1)|^2 - |g_{m-2}(m-2)|^2$$

AR模型谱估计

Burg法:

算法的步骤归结为（阶次用 i 表示）：

1. 初始化: $i=1$

(1) $f_0(m)=x(m)=g_0(m)$

(2) 根据右1式计算 $\hat{a}_1(1)$;

(3) 根据右2式计算误差 $f(m)$ 和 $g(m)$;

2. $i=i+1$

(1) 根据右1式计算 $\hat{K}_i = \hat{a}_i(i)$;

(2) 根据右3式计算 $\hat{a}_i(j), j = 1, 2, \dots, i-1$;

(3) 根据右2式计算 $f(m)$ 和 $g(m)$;

(4) 根据右4式计算 $\hat{E}_i$;

3. $i=i+1$, 若 i 小于或等于 p , 回到步骤2, 否则: 递推结束

$$a_m(m) = \hat{K}_m = \frac{-\sum_{n=m}^{N-1} f_{m-1}(n) g_{m-1}^*(n-1)}{\frac{1}{2} \sum_{n=m}^{N-1} [|f_{m-1}(n)|^2 + |g_{m-1}(n-1)|^2]}$$

$$\begin{aligned} f_m(n) &= f_{m-1}(n) + a_m(m) g_{m-1}(n-1), \\ g_m(n) &= a_m(m) f_{m-1}(n) + g_{m-1}(n-1), \end{aligned}$$

$$a_m(k) = a_{m-1}(k) + K_m a_{m-1}^*(m-k),$$

$$\hat{E}_m = [1 - |K_m|^2] \hat{E}_{m-1} - |f_{m-1}(m-1)|^2 - |g_{m-2}(m-2)|^2$$

AR模型谱估计

Burg法:


系数递推求解后，计算功率谱:

$$S_{xx}^{\text{BU}}(f) = \frac{\hat{E}_p}{\left| 1 + \sum_{k=1}^p \hat{a}_p(k) e^{-j2\pi f k} \right|^2}$$

特点:

- 1) 分辨率高
- 2) 产生的AR模型稳定
- 3) 利用L-D, 高效
- 4) 高信噪比谱线分裂, 即虚峰

AR模型谱估计



AR模型谱估计


模型阶— p 的确定:

阶选择的影响:

p 太低, 功率谱高度平滑;

p 太高, 出现虚峰。

均方残余误差随着阶的增大而减小, 当两者变化相对趋缓时大致确定 p , 但不精确。



AR模型谱估计

模型阶— p 的确定:

1.最终预测误差准则 (FPE)
$$\text{FPE}(p) = E_p \left(\frac{N+p+1}{N-p-1} \right)$$

使得上式最小的 p 即为模型最佳阶数, 其中 E_p 为谱估计的方差

2.信息论准则 (AIC)

$$\text{AIC}(p) = \ln E_p + \frac{2p}{N}$$

右侧随着 p 的增大, 右侧两项变化方向相反

FPE和AIC得到的结果近似:
$$\lim_{N \rightarrow \infty} [\ln \text{FPE}(p)] = \text{AIC}(p)$$

3.自回归传递 (CAT) :

$$\text{CAT}(p) = \frac{1}{N} \sum_{k=1}^p \frac{N-k}{N \cdot E_k} - \frac{1}{E_p}$$

MA模型谱估计

全零点模型MA的参数 b_k 与自相关序列 $r_{xx}(m)$ 的关系:

$$r_{xx}(m) = \begin{cases} \sigma_w^2 \sum_{k=0}^{q-m} h(k)b_{k+m}, & 0 \leq m \leq q \\ 0, & m > q \\ r_{xx}^*(-m), & m < 0 \end{cases}$$

则有:

$$B(z)B(z^{-1}) = D(z) = \sum_{m=-q}^q d_m z^{-m}$$

则式中系数 d_m 与模型参数 b_k 的关系:

$$d_m = \sum_{k=0}^{q-|m|} b_k b_{k+m}, \quad |m| \leq q$$

MA模型谱估计

全零点模型MA的参数 b_k 与自相关序列 $r_{xx}(m)$ 的关系:

$$r_{xx}(m) = \begin{cases} \sigma_w^2 \sum_{k=0}^{q-m} h(k)b_{k+m}, & 0 \leq m \leq q \\ 0, & m > q \\ r_{xx}^*(-m), & m < 0 \end{cases}$$

则有:

$$B(z)B(z^{-1}) = D(z) = \sum_{m=-q}^q d_m z^{-m}$$

则式中系数 d_m 与模型参数 b_k 的关系:

$$d_m = \sum_{k=0}^{q-|m|} b_k b_{k+m}, \quad |m| \leq q \quad \longrightarrow \quad r_{xx}(m) = \begin{cases} \sigma_w^2 d_m, & |m| \leq q \\ 0, & m > q \end{cases}$$

MA模型谱估计

根据功率谱的定义得到MA谱估计：

$$S_{xx}^{\text{MA}}(f) = \sum_{m=-q}^q r_{xx}(m) e^{-j2\pi f m}$$

可看出MA谱估计不需要计算出模型参数 b_k

若要求解 b_k

可求解非线性方程组

又可用高阶AR模型逼近

$$\begin{aligned} \tau &= 0, 1, \dots, q. \\ \gamma_0 &= \sigma_\varepsilon^2(\mu_0^2 + \mu_1^2 + \dots + \mu_q^2), \\ \gamma_1 &= \sigma_\varepsilon^2(\mu_0\mu_1 + \mu_1\mu_2 + \dots + \mu_{q-1}\mu_q), \\ &\vdots \\ \gamma_q &= \sigma_\varepsilon^2\mu_0\mu_q. \\ \gamma_\tau &= 0 \text{ for all } \tau > q. \end{aligned}$$

MA模型谱估计

高阶模型逼近， $AR(p) \rightarrow MA(q)$:

要求 $p \gg q$:

$$B(z) = 1/A(z) \text{ 或 } B(z)A(z) = 1$$

因此，参数 b_k 和 a_k 的关系为:

$$\hat{a}_n + \sum_{k=1}^q b_k \hat{a}_{n-k} = \begin{cases} 1, & n=0 \\ 0, & n \neq 0 \end{cases}$$

其中 $\hat{a}_n$ 为利用观察序列估计出的 $AR(p)$ 模型的参数

因此的求解参数 b_k 为解该方程

MA模型谱估计

采用最小平方误差准则求解该方程：

$$\zeta = \sum_{n=0}^p \left[\hat{a}_n + \sum_{k=1}^q b_k \hat{a}_{n-k} \right]^2 - 1, \quad \hat{a}_0 = 1, \hat{a}_k = 0, k < 0$$

选择最佳参数 b_k 使得 ζ 最小。根据求最佳的方法，可得：

$$\hat{\mathbf{b}} = -\mathbf{R}_{aa}^{-1} \mathbf{r}_{aa}$$

式中 $\mathbf{R}_{aa}$ 和 $\mathbf{r}_{aa}$ 为：

$$R_{aa}(|i-j|) = \sum_{n=0}^{p-|i-j|} \hat{a}_n \hat{a}_{n+|i-j|}, \quad i, j = 1, 2, \dots, q$$

$$r_{aa}(i) = \sum_{n=0}^{p-i} \hat{a}_n \hat{a}_{n+i}, \quad i = 1, 2, \dots, q$$

模型阶次：

$$\text{AIC}(q) = \ln \hat{\sigma}_{wq}^2 + \frac{2q}{N}$$

ARMA模型谱估计

模型:

$$H(z) = \frac{B(z)}{A(z)} = \frac{\sum_{k=0}^q b_k z^{-k}}{1 + \sum_{k=1}^p a_k z^{-k}} \quad x(n) = -\sum_{k=1}^p a_k x(n-k) + \sum_{k=0}^q b_k w(n-k)$$

$$S_{xx}(f) = |H(f)|^2 S_{ww}(f)$$

模型参数的求解:

直接求解非线性方程组, 如相关矩阵法、极大似然等

问题: 收敛性不保证, 初值严格, 无法实时

非线性方程转化线性方程

ARMA模型谱估计

交叉相乘法:

$AR(p) \rightarrow ARMA(p, q)$, 步骤:

1. 求解高阶AR模型参数

将ARMA模型表示为:

$$H(z) = \frac{B(z)}{A(z)} = \frac{1}{C(z)} \quad C(z) = 1 + \sum_{k=1}^{\infty} c_k z^{-k}$$

即用无限阶次的AR模型逼近

实际中的阶次设为 $M > p+q$, 则:

$$\frac{\hat{B}(z)}{\hat{A}(z)} = \frac{1}{\hat{C}(z)}$$

$$\hat{C}(z) = 1 + \sum_{k=1}^M \hat{c}_k z^{-k}, \quad M > p+q$$

ARMA模型谱估计

AR(p) $\rightarrow$ ARMA(p, q)，步骤：

2. 模型参数关系：

$$\begin{aligned}\hat{A}(z) &= 1 + \hat{a}_1 z^{-1} + \dots + \hat{a}_p z^{-p} \\ \hat{B}(z) &= \hat{b}_0 + \hat{b}_1 z^{-1} + \dots + \hat{b}_q z^{-q}\end{aligned}$$

代入模型逼近表达式：

$$1 + \hat{a}_1 z^{-1} + \dots + \hat{a}_p z^{-p} = (\hat{b}_0 + \hat{b}_1 z^{-1} + \dots + \hat{b}_q z^{-q}) \cdot (1 + \hat{c}_1 z^{-1} + \dots + \hat{c}_M z^{-M})$$

另左右同幂项相等，则：

$$\hat{a}_n = \sum_{k=0}^q \hat{b}_k \hat{c}_{n-k}, \quad n=1, 2, \dots \text{ 其中: } \hat{b}_0 = 1$$

ARMA模型谱估计

$AR(p) \rightarrow ARMA(p, q)$ ，步骤：

3. 求MA系数 $\hat{b}_k$

$n > p$ ， $\hat{a}_n = 0$ 。则，取 $n = p+1, p+2, \dots, p+q$

$$\hat{a}_n = \sum_{k=0}^q \hat{b}_k \hat{c}_{n-k} \longrightarrow \sum_{k=0}^q \hat{b}_k \hat{c}_{n-k} = 0, \quad n = p+1, p+2, \dots, p+q$$

$$\begin{bmatrix} \hat{c}_p & \hat{c}_{p-1} & \cdots & \hat{c}_{p+1-q} \\ \hat{c}_{p+1} & \hat{c}_p & \cdots & \hat{c}_{p+2-q} \\ \vdots & \vdots & \cdots & \vdots \\ \hat{c}_{p+q-1} & \hat{c}_{p+q-2} & \cdots & \hat{c}_p \end{bmatrix} \begin{bmatrix} \hat{b}_1 \\ \hat{b}_2 \\ \vdots \\ \hat{b}_q \end{bmatrix} = \begin{bmatrix} \hat{c}_{p+1} \\ \hat{c}_{p+2} \\ \vdots \\ \hat{c}_{p+q} \end{bmatrix}$$

ARMA模型谱估计

$AR(p) \rightarrow ARMA(p, q)$, 步骤:

4. 求 $AR(p)$ 系数 $\hat{a}_k$

取 $n=1, 2, \dots, p$, 前 p 个方程:

$$\hat{a}_n = \sum_{k=0}^q \hat{b}_k \hat{c}_{n-k}, \quad n=1, 2, \dots, p, \quad \hat{c}_0 = 1$$

$$\begin{bmatrix} \hat{a}_1 \\ \hat{a}_2 \\ \vdots \\ \hat{a}_p \end{bmatrix} = \begin{bmatrix} \hat{c}_1 & 1 & 0 & \dots & 0 \\ \hat{c}_2 & \hat{c}_1 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \dots & \vdots \\ \hat{c}_p & \hat{c}_{p-1} & \hat{c}_{p-2} & \dots & \hat{c}_{p-q} \end{bmatrix} \begin{bmatrix} 1 \\ \hat{b}_1 \\ \vdots \\ \hat{b}_q \end{bmatrix}$$

ARMA模型谱估计

$AR(p) \rightarrow ARMA(p, q)$

则功率谱估计为:

$$S_{xx}^{ARMA}(f) = \frac{|B(f)|^2}{|A(f)|^2} \sigma_w^2 = \frac{\left| \sum_{k=0}^q \hat{b}_k e^{-j2\pi f k} \right|^2}{\left| 1 + \sum_{k=1}^p \hat{a}_k e^{-j2\pi f k} \right|^2} \sigma_w^2$$

模型定阶:

$$AIC(p, q) = \ln \hat{\sigma}_{wpq}^2 + \frac{2(p+q)}{N}$$

$\hat{\sigma}_{wpq}^2$ 是输入误差的方差估计

参数模型谱估计

三种模型的特点：

AR模型：

1) 全极点特性，谱峰表现好；

每一对极点对应一个谱峰，越靠近单位圆，峰越窄越尖锐

2) 跟随谷底的能力不足，需要若干对极点表现一个波谷

3) 分辨率与信噪比有关，极点的运动方向有关

MA模型：

1) 适合于描述频谱谷点：一对单位圆附近的零点描述一个陷波

2) 描述谱峰不理想

ARMA模型：

1) 零极点模型，适合描述即有峰又有谷的谱

2) 适合描述带噪声的观测数据

3) 模型求解困难

