

随机信号的更新及建模

基于滤波器的随机信号更新
基于矩阵操作的随机信号更新
随机信号模型



随机信号作为滤波器的输入(p.107-111)

我们利用统计量分析随机信号，因此重点考察滤波器对输入信号统计量的改变，特别是均值和相关函数的改变

连续系统	离散系统
单位冲激响应 $h(t)$ 是输入为 $\delta(t)$ 时的系统输出： $y(t) = x(t) * h(t)$	单位冲激响应 $h(n)$ 是输入为 $\delta(n)$ 时的系统输出： $y(n) = x(n) * h(n)$
传递函数 $H(s)$ 是 $h(t)$ 的拉氏变换： $Y(s) = X(s)H(s)$	传递函数 $H(z)$ 是 $h(n)$ 的Z变换： $Y(z) = X(z)H(z)$
频率特性 $H(\omega)$ 是 $h(t)$ 的Fourier变换： $Y(\omega) = X(\omega)H(\omega)$	$H(e^{j\omega})$ 是 $h(n)$ 的离散Fourier变换： $Y(e^{j\omega}) = X(e^{j\omega})H(e^{j\omega})$
$H(s) = \int_{-\infty}^{\infty} e^{-st} h(t) dt$	$H(z) = \sum_{n=-\infty}^{\infty} h(n) z^{-n}$

系统响应的均值、自相关函数和平稳性分析

设线性系统是稳定非时变的，其单位脉冲响应为 $h(n)$ ，输入是平稳随机序列 $x(n)$ ，系统的输出为

$$y(n) = x(n) * h(n) = \sum_{k=-\infty}^{\infty} h(k)x(n-k)$$

输出的均值为 $m_y = E[y(n)] = \sum_{k=-\infty}^{\infty} h(k)E[x(n-k)]$

输入是平稳随机序列 $E[x(n-k)] = m_x$

$$m_y = m_x \sum_{k=-\infty}^{\infty} h(k) = m_x H(e^{j0})$$

输出的自相关函数为

$$\begin{aligned} r_{yy}(n, n-m) &= E[y(n)y^*(n-m)] \\ &= E\left[\sum_{k=-\infty}^{\infty} h(k)x(n-k) \sum_{r=-\infty}^{\infty} h^*(r)x^*(n-m-r)\right] \\ &= \sum_{k=-\infty}^{\infty} h(k) \sum_{r=-\infty}^{\infty} h^*(r) E[x(n-k)x^*(n-m-r)] \end{aligned}$$

$x(n)$ 是平稳的

$$E[x(n-k)x^*(n-m-r)] = r_{xx}(m+r-k)$$

$$r_{yy}(n, n-m) = \sum_{k=-\infty}^{\infty} h(k) \sum_{r=-\infty}^{\infty} h^*(r) \cdot r_{xx}(m+r-k) = r_{yy}(m)$$

输出是平稳随机序列

$$r_{yy}(m) = \sum_{k=-\infty}^{\infty} h(k) \sum_{r=-\infty}^{\infty} h^*(r) \cdot r_{xx}(m+r-k) \quad \text{令 } l = k-r$$

$$= \sum_{l=-\infty}^{\infty} r_{xx}(m-l) \sum_{k=-\infty}^{\infty} h^*(r) h(l+r)$$

$$v(l) = \sum_{k=-\infty}^{\infty} h^*(k) h(l+k)$$

$$= \sum_{l=-\infty}^{\infty} r_{xx}(m-l) v(l) = r_{xx}(m) * v(m)$$

$v(l)$ 称为 $h(n)$ 的自相关函数，可以将 $v(l)$ 写成卷积形式

$$v(l) = h^*(l) * h(-l) = h^*(-l) * h(l)$$

线性系统输出的自相关函数等于输入的自相关函数与线性系统单位脉冲响应的自相关函数的卷积。

输出响应的功率谱密度函数

$$r_{yy}(m) = r_{xx}(m) * v(m) \xrightarrow{z} P_{yy}(z) = P_{xx}(z)V(z)$$

$$v(l) = h(l) * h^*(-l) \xrightarrow{z} V(z) = H(z)H^*\left(\frac{1}{z^*}\right)$$

$$P_{yy}(z) = P_{xx}(z)H(z)H^*\left(\frac{1}{z^*}\right)$$

将 $z = e^{j\omega}$ 代入，得到输出功率谱：

$$P_{yy}(e^{j\omega}) = P_{xx}(e^{j\omega})H(e^{j\omega})H^*(e^{j\omega}) = P_{xx}(e^{j\omega})|H(e^{j\omega})|^2$$

输出响应的功率谱密度函数

利用维纳辛钦定理

$$\begin{aligned} P_Y(f) &= \int_{-\infty}^{\infty} R_Y(\tau) e^{j2\pi f\tau} d\tau \\ &= \int_{-\infty}^{\infty} \left[\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} h(u_1) h(u_2) R_X(u_1 - u_2 + \tau) du_1 du_2 \right] e^{j2\pi f\tau} d\tau \end{aligned}$$

变量代换 $\zeta = u_1 - u_2 + \tau$

$$\begin{aligned} &= \int_{-\infty}^{\infty} h(u_2) e^{-j2\pi f u_2} du_2 \left[\int_{-\infty}^{\infty} h(u_1) e^{-j2\pi f u_1} du_1 \right]^* \int_{-\infty}^{\infty} R_X(\zeta) e^{-j2\pi f \zeta} d\zeta \\ &= H(f) H^*(f) P_X(f) = |H(f)|^2 P_X(f) \end{aligned}$$

$$P_{yy}(e^{j\omega}) = P_{xx}(e^{j\omega}) |H(e^{j\omega})|^2$$

利用上式证明功率谱密度函数的非负性

$$r_{yy}(m) = E[y(n)y^*(n-m)] \quad r_{yy}(0) = E[y^2(n)] \geq 0$$

随机序列的平均功率

$$r_{yy}(m) \leftrightarrow P_{yy}(e^{j\omega}) \quad r_{yy}(m) = \frac{1}{2\pi} \int_{-\pi}^{\pi} P_{yy}(e^{j\omega}) e^{j\omega \cdot m} d\omega$$


$$r_{yy}(0) = \frac{1}{2\pi} \int_{-\pi}^{\pi} P_{yy}(e^{j\omega}) d\omega \geq 0$$

$$r_{yy}(0) = \frac{1}{2\pi} \int_{-\pi}^{\pi} P_{xx}(e^{j\omega}) |H(e^{j\omega})|^2 d\omega \geq 0$$

$$\frac{1}{2\pi} \int_{-\pi}^{\pi} P_{xx}(e^{j\omega}) |H(e^{j\omega})|^2 d\omega \geq 0$$

$P_{xx}(e^{j\omega})$ 和 $|H(e^{j\omega})|^2$ 均是 ω 的偶函数

假设系统的幅度特性如下图所示



理想带通滤波器的幅度特性

$$\frac{1}{\pi} \int_{\omega_a}^{\omega_b} P_{xx}(e^{j\omega}) d\omega \geq 0$$

故 $P_{xx}(e^{j\omega}) \geq 0$ ，信号的功率谱是实、偶、非负函数

系统的输入、输出互相关函数

线性非时变系统输入与输出之间互相关函数为

$$\begin{aligned} r_{yx}(m) &= E[y(n)x^*(n-m)] = E[x^*(n-m) \sum_{k=-\infty}^{\infty} h(k)x(n-k)] \\ &= \sum_{k=-\infty}^{\infty} h(k)r_{xx}(m-k) = h(m) * r_{xx}(m) \end{aligned}$$

输入、输出互相关定理：输入、输出互相关函数等于系统的单位脉冲响应与输入自相关函数的卷积。

设 $x(n)$ 是零均值平稳随机序列，上式的 z 变换为

$$P_{yx}(z) = H(z)P_{xx}(z)$$

输入、输出的互功率谱表示为

$$P_{yx}(e^{j\omega}) = H(e^{j\omega})P_{xx}(e^{j\omega})$$

相关卷积定理

将系统输出的自相关函数公式重写：

$$r_{yy}(m) = r_{xx}(m) * v(m)$$

$$v(m) = \sum_{k=-\infty}^{\infty} h^*(k)h(m+k)$$

该公式用语言叙述如下： $x(n)$ 与 $h(n)$ 卷积的自相关函数等于 $x(n)$ 的自相关函数和 $h(n)$ 的自相关函数的卷积。

或者简单地说：**卷积的相关等于相关的卷积**

$$e(n) = a(n) * b(n)$$

$$f(n) = c(n) * d(n)$$

$$r_{ef}(m) = r_{ac}(m) * r_{bd}(m)$$

例1 假设系统的输入、输出和单位脉冲响应分别用 $x(n)$ 、 $y(n)$ 和 $h(n)$ 表示，试求输入、输出互相关函数和输入自相关函数之间的关系。

$$r_{xy}(m) \Leftrightarrow r_{xx}(m)$$

解 按照相关卷积定理，得到

$$x(n) = x(n) * \delta(n)$$

$$y(n) = x(n) * h(n)$$

$$r_{xy}(m) = r_{xx}(m) * r_{\delta h}(m)$$

$$r_{\delta h}(m) = \sum_{l=-\infty}^{\infty} \delta^*(l) h(l+m) = h(m)$$

$$r_{xy}(m) = r_{xx}(m) * h(m)$$

这就是已经推导出的输入、输出互相关卷积定理。

输出、输入互相关函数和输入自相关函数之间的关系：

$$\begin{aligned} r_{yx}(m) &= r_{xy}(-m) = r_{xx}(-m) * h(-m) \\ &= r_{xx}(m) * h(-m) \end{aligned}$$

$$P_{yx}(z) = P_{xx}(z)H(z^{-1})$$

例2 按照下图，推导两个系统的输出互相关函数与输入互相关函数之间的关系。

$$r_{y_1 y_2}(m) \Leftrightarrow r_{x_1 x_2}(m)$$


解：

$$y_1(n) = x_1(n) * h_1(n)$$

$$y_2(n) = x_2(n) * h_2(n)$$

按照相关卷积定理，有

$$r_{y_1 y_2}(m) = r_{x_1 x_2}(m) * r_{h_1 h_2}(m)$$



$$\begin{aligned}
 r_{h_1 h_2}(m) &= \sum_{n=-\infty}^{\infty} h_1(n) h_2^*(n-m) \\
 &= \sum_{n=-\infty}^{\infty} h_1(n) h_2^*(-(m-n)) \\
 &= h_1(m) * h_2^*(-m)
 \end{aligned}$$

$$r_{y_1 y_2}(m) = r_{x_1 x_2}(m) * r_{h_1 h_2}(m)$$

$$P_{y_1 y_2}(z) = P_{x_1 x_2}(z) H_1(z) H_2^*\left(\frac{1}{z^*}\right)$$

例3 已知实平稳白噪声 $x(n)$ 的功率谱是 σ_x^2 ，使通过一个 q 阶的FIR网络，求输出自相关函数 $r_{yy}(m)$ 、功率谱 $P_{yy}(e^{j\omega})$ 、互相关函数 $r_{yx}(m)$ 和互功率谱 $P_{yx}(e^{j\omega})$

解: $r_{yy}(m) \leftrightarrow P_{yy}(e^{j\omega}) \quad r_{yx}(m) \leftrightarrow P_{yx}(e^{j\omega})$

网络输出的功率谱为:

$$P_{yy}(e^{j\omega}) = P_{xx}(e^{j\omega}) |H(e^{j\omega})|^2$$

q 阶FIR网络的传输函数为:

$$H(z) = \sum_{n=0}^q b_n z^{-n} \quad H(e^{j\omega}) = \sum_{n=0}^q b_n e^{-j\omega n}$$

$$\begin{aligned}
 P_{yy}(e^{j\omega}) &= P_{xx}(e^{j\omega}) |H(e^{j\omega})|^2 = \sigma_x^2 \left| \sum_{n=0}^q b_n e^{-j\omega n} \right|^2 \\
 &= \sigma_x^2 \left[\left(\sum_{n=0}^q b_n \cos(\omega n) \right)^2 + \left(\sum_{n=0}^q b_n \sin(\omega n) \right)^2 \right] \\
 &= \sigma_x^2 \left[\sum_{n=0}^q b_n^2 \cos^2(\omega n) + \sum_{n=0}^q \sum_{\substack{j=0 \\ j \neq n}}^q b_n b_j \cos(\omega n) \cos(\omega j) \right. \\
 &\quad \left. + \sum_{n=0}^q b_n^2 \sin^2(\omega n) + \sum_{n=0}^q \sum_{j=0}^q b_n b_j \sin(\omega n) \sin(\omega j) \right]
 \end{aligned}$$

$$\left(\sum_{n=1}^q a_n \right)^2 = \sum_{n=1}^q a_n^2 + \sum_{n=1}^q \sum_{\substack{j=1 \\ j \neq n}}^q a_n a_j$$

$$(a + b + c)^2 = a^2 + b^2 + c^2 + ab + ac + ba + bc + ca + cb$$

$$P_{yy}(e^{j\omega}) = \sigma_x^2 \left[\sum_{n=0}^q b_n^2 + \sum_{n=0}^q \sum_{\substack{j=0 \\ j \neq n}}^q b_n b_j \cos(n-j)\omega \right]$$

$$\delta(m) \leftrightarrow 1$$

$$(e^{j\omega \cdot q} + e^{-j\omega \cdot q})/2$$

$$\delta(m-q) \leftrightarrow e^{-j\omega \cdot q} \quad \frac{1}{2}[\delta(m+q) + \delta(m-q)] \leftrightarrow \cos(q\omega)$$

$$r_{yy}(m) = \sigma_x^2 \left[\sum_{n=0}^q b_n^2 \right] \delta(m) + \sigma_x^2 \sum_{\substack{n=0 \\ n \neq j}}^q \sum_{j=0}^q \frac{b_n b_j}{2} [\delta(m+n-j) + \delta(m-n+j)]$$

同样方法，可求出互功率谱和互相关函数：

$$r_{yx}(m) = r_{xx}(m) * h(m)$$

$$P_{yx}(e^{j\omega}) = P_{xx}(e^{j\omega})H(e^{j\omega}) = \sigma_x^2 \sum_{n=0}^q b_n e^{-j\omega n}$$

$$= \sigma_x^2 \left[b_0 + \sum_{n=1}^q b_n \cos(\omega n) - j \sum_{n=1}^q b_n \sin(\omega n) \right]$$

$$\delta(m) \quad \frac{1}{2}[\delta(m+n) + \delta(m-n)] \quad \frac{1}{2j}[\delta(m+n) - \delta(m-n)]$$

$$r_{yx}(m) = \sigma_x^2 \left[b_0 \delta(m) + \sum_{n=1}^q b_n \delta(m-n) \right]$$

$$\frac{1}{2j}(e^{j\omega n} - e^{-j\omega n})$$

$$= \sigma_x^2 \sum_{n=0}^q b_n \delta(m-n)$$

例1.4.4 设实平稳白噪声 $x(n)$ 的方差是 σ_x^2 , 均值 $m_x=0$, 让 $x(n)$ 通过一个网络, 网络的差分方程为

$$y(n)=x(n)+ay(n-1)$$

式中 a 是实数。求网络输出的功率谱和自相关函数。

解: 先用归纳法求网络输出的自相关函数

$$r_{yy}(m) = E[y(n)y^*(n-m)]$$

令 $m=0$, 则

$$\begin{aligned} r_{yy}(0) &= E[y^2(n)] = E[(x(n) + ay(n-1))^2] \\ &= E[x^2(n)] + a^2 E[y^2(n-1)] + 2aE[x(n)y(n-1)] \\ &= \sigma_x^2 + a^2 r_{yy}(0) \end{aligned}$$

$$r_{yy}(0) = \sigma_x^2 + ar_{yy}(0) \quad r_{yy}(0) = \frac{\sigma_x^2}{1-a^2}$$

令 $m = 1$, 则

$$\begin{aligned} r_{yy}(1) &= E[y^*(n)y(n+1)] \\ &= E[y^*(n) \cdot (x(n+1) + ay(n))] = ar_{yy}(0) \end{aligned}$$

令 $m = 2$, 则

$$\begin{aligned} r_{yy}(2) &= E[y^*(n)y(n+2)] \\ &= E[y^*(n) \cdot (x(n+2) + ay(n+1))] \\ &= aE[y^*(n)y(n+1)] = ar_{yy}(1) = a^2r_{yy}(0) \end{aligned}$$

$$r_{yy}(m) = a^m r_{yy}(0) = a^m \frac{\sigma_x^2}{1-a^2} = a^{|m|} \frac{\sigma_x^2}{1-a^2}$$

$$y(n)=x(n)+ay(n-1) \quad H(z) = \frac{1}{1-az^{-1}}$$

网络输出功率谱为

$$\begin{aligned} P_{yy}(e^{j\omega}) &= P_{xx}(e^{j\omega}) |H(e^{j\omega})|^2 \\ &= \sigma_x^2 \left| \frac{1}{1-ae^{-j\omega}} \right|^2 = \frac{\sigma_x^2}{1+a^2-2a\cos\omega} \end{aligned}$$

a 是网络的极点，为了稳定，要求 $|a|<1$ 。

$$r_{yy}(m) \leftrightarrow P_{yy}(z)$$


$$P_{yy}(e^{j\omega}) = P_{yy}(z) \Big|_{z=e^{j\omega}}$$

$$r_{yy}(m) = a^{|m|} \frac{\sigma_x^2}{1-a^2}$$

矢量随机信号的线性变换

矢量随机信号的定义

多天线系统，信号通过多个天线发射，接收端通过多个天线接收



$$\begin{bmatrix} x(n_0) \\ y(n_0) \\ z(n_0) \\ \vdots \\ \vdots \end{bmatrix}$$

矢量的每个元素对于不同的随机信号

$$\begin{bmatrix} x(0) \\ x(1) \\ x(2) \\ \vdots \\ \vdots \end{bmatrix}$$

矢量的每个元素对应同一个随机信号的不同时间点

矢量随机信号的线性变换

矢量随机信号的定义

$$\begin{bmatrix} x(n_0) \\ y(n_0) \\ z(n_0) \\ \vdots \\ \vdots \end{bmatrix}$$

矢量的每个元素对于
不同的随机信号

$$\begin{bmatrix} x(0) \\ x(1) \\ x(2) \\ \vdots \\ \vdots \end{bmatrix}$$

矢量的每个元素对应
同一个随机信号的不
同时间点

自相关矩阵

$$\mathbf{x} = \begin{bmatrix} x(0) \\ x(1) \\ x(2) \\ \vdots \\ \vdots \\ x(N-1) \end{bmatrix}$$

$$\mathbf{R}_x = E[\mathbf{x}\mathbf{x}^H]$$

当用矩阵操作进行信号变换时,
统计量的分析一般用自相关矩
阵而不是自相关函数


✓ 自相关矩阵性质

矢量随机信号的线性变换

矢量随机信号的变换

$$\mathbf{y} = \mathbf{A}\mathbf{x}$$

例：MIMO信道模型



$$y_1 = a_{11}x_1(1) + a_{21}x_2(1) + \cdots + a_{N1}x_N(1)$$

$$\vdots$$

$$y_N = a_{1N}x_1(n) + a_{2N}x_2(n) + \cdots + a_{NN}x_N(n)$$



$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1N} \\ a_{21} & a_{22} & \cdots & a_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ a_{N1} & a_{N2} & \cdots & a_{NN} \end{bmatrix} \begin{bmatrix} x(0) \\ x(1) \\ \vdots \\ x(N-1) \end{bmatrix}$$

滤波器线性变换和矩阵操作线性变换的关系

FIR滤波器操作可转化为矩阵操作

$$y(n) = \sum_{k=0}^{L-1} h(k)x(n-k)$$

$$\begin{bmatrix} y(n) \\ y(n-1) \\ \vdots \\ y(n-N) \end{bmatrix} = \begin{bmatrix} h(0) & \cdots & h(L-1) & 0 & \cdots & 0 \\ 0 & h(0) & \cdots & h(L-1) & \ddots & \vdots \\ \vdots & \ddots & \ddots & & \ddots & 0 \\ 0 & \cdots & 0 & h(0) & \cdots & h(L-1) \end{bmatrix} \begin{bmatrix} x(n) \\ x(n-1) \\ \vdots \\ x(n-N-L+1) \end{bmatrix}$$

LTI形式：依据滤波器的线性性质与时不变性质

有限长序列x(n) 长度为N

$$\begin{bmatrix} y(N+L-2) \\ y(N+L-3) \\ \vdots \\ y(0) \end{bmatrix} = \begin{bmatrix} h_{L-1} & 0 & \cdots & \cdots & 0 \\ h_{L-2} & h_{L-1} & \ddots & & \vdots \\ \vdots & h_{L-2} & \ddots & \ddots & \vdots \\ h_0 & \vdots & \ddots & \ddots & 0 \\ 0 & h_0 & & \ddots & h_{L-1} \\ \vdots & \ddots & \ddots & & h_{L-2} \\ \vdots & & \ddots & \ddots & \vdots \\ 0 & \cdots & \cdots & 0 & h(0) \end{bmatrix} \begin{bmatrix} x(N) \\ x(N-1) \\ \vdots \\ x(0) \end{bmatrix}$$

矩阵形式：输入N，输出N+（L-1）。H是一个**Toeplitz**矩阵，表明滤波器的不变特性

$$\mathbf{y}(n) = \mathbf{H}\mathbf{x}(n)$$

矢量随机信号变换的均值和自相关

$$\mathbf{y} = \mathbf{A}\mathbf{x}$$

$$\begin{bmatrix} y(n) \\ y(n-1) \\ \vdots \\ y(n-N) \end{bmatrix} = \begin{bmatrix} a_{00} & a_{02} & \cdots & a_{0N} \\ a_{10} & a_{11} & \cdots & a_{1N} \\ \vdots & \vdots & \ddots & \vdots \\ a_{N0} & a_{N1} & \cdots & a_{NN} \end{bmatrix} \begin{bmatrix} x(n) \\ x(n-1) \\ \vdots \\ x(n-N) \end{bmatrix}$$

$$y(n-l) = \sum_{i=0}^N a_{li} x(n-i)$$

$$\mathbf{E}[\mathbf{y}] = \mathbf{A}\mathbf{E}[\mathbf{x}]$$

$$\mathbf{R}_y = \mathbf{A}\mathbf{E}[\mathbf{x}\mathbf{x}^H]\mathbf{A}^H$$

矢量随机信号线性变换的应用

信源编码中经常需要将时间相关，非零均值的随机信号转化成零均值，不相关的信号

假设随机矢量 $\mathbf{x} = [x_1, x_2, \dots, x_N]$, 令自相关矩阵为 $\mathbf{R}_x$

问题：对 $\mathbf{x}$ 去相关，求 $\mathbf{A}$

$$\tilde{\mathbf{x}} = \mathbf{x} - E[\mathbf{x}] \quad \mathbf{y} = \mathbf{A}\tilde{\mathbf{x}}$$

特征值分解：

$$\mathbf{R}_{\tilde{\mathbf{x}}} \mathbf{q}_i = \lambda_i \mathbf{q}_i \quad i = 1, \dots, N$$

$$\mathbf{R}_{\tilde{\mathbf{x}}} [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_N] = [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_N] \begin{bmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \\ & & & \lambda_N \end{bmatrix}$$

$$\mathbf{R}_{\tilde{\mathbf{x}}} = \mathbf{Q} \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_N \end{bmatrix} \mathbf{Q}^{-1} = \mathbf{Q} \mathbf{\Sigma} \mathbf{Q}^{-1}$$

矢量随机信号线性变换的应用

对于复随机信号，自相关矩阵是共轭对称矩阵，则有：

$$\mathbf{R}_x^H = \mathbf{Q}^{-H} \mathbf{\Sigma} \mathbf{Q}^H = \mathbf{R}_x = \mathbf{Q} \mathbf{\Sigma} \mathbf{Q}^{-1}$$

那么：

$$\mathbf{Q}^H = \mathbf{Q}^{-1}$$


若令变换矩阵 $\mathbf{A} = \mathbf{Q}^H = \mathbf{Q}^{-1}$ ，实现去相关操作：

$$\begin{aligned} \mathbf{R}_y &= E[\mathbf{y} \mathbf{y}^{-H}] \\ &= E[\mathbf{A} \mathbf{x} \mathbf{x}^H \mathbf{A}^H] \\ &= \mathbf{A} E[\mathbf{x} \mathbf{x}^H] \mathbf{A}^H \\ &= \mathbf{A} \mathbf{R}_x \mathbf{A}^H \\ &= \mathbf{A} \mathbf{Q} \mathbf{\Sigma} \mathbf{Q}^{-1} \mathbf{A}^H \\ &= \mathbf{\Sigma} \end{aligned}$$

$\mathbf{\Sigma}$ 为对角阵，行间相互独立，实现去相关

经过线性变换后的随机矢量具有以下特性

1. 如果 $\mathbf{x}$ 是零均值，则随机矢量 $\mathbf{y}$ 也是零均值，它的分量是非相关的（因为零均值，所以也是正交的）另外，如果 $\mathbf{x}$ 是服从 $N(0, \mathbf{R}_x)$ 的高斯分布，那么 $\mathbf{y}$ 是具有独立分量的 $N(0, \Sigma)$ 分布。
2. $\mathbf{y}$ 随机变量的方差是 $\mathbf{R}_x$ 的特征值。
3. 由 $\mathbf{y} = \mathbf{A}\mathbf{x}$ 得到 $y_i = \mathbf{q}_i^T \mathbf{x}$ ，因此 y_i 是 $\mathbf{x}$ 在单位矢量 $\mathbf{q}_i$ 上的投影。




正交线性变换在图像数据压缩中的应用

- 图像数据压缩的两个途径:
 - 1) 预测编码: 可预测性——减少冗余。
 - 2) 变换编码: 图像经过变换, 将富含信息量较大的数据压缩, 用信息量较小的数据进行表示。



正交线性变换在图像数据压缩中的应用



正交线性变换在图像数据压缩中的应用

1. 主要思想是通过对信号解相关，形成信号能量的不均匀分布，使大部分信号能量集中分布在较少的变换系数上，对不同的变换系数进行不同精细程度的量化，从而实现数据压缩。
2. 如果所有变换系数不经量化全部传送，则在接收端可以通过逆变换无失真的恢复原始信号。若为了进行数据压缩，变换后不将全部变换系数传送。
3. 寻找一种变换方式，在指定的失真准则下，经过变换所得的变换系数中需要传送的部分最少。经常使用且在数学上易处理的失真准则之一是最小均方误差准则（MMSE）。下面推导 MMSE 准则下的最佳变换



假设A为正交变换矩阵

$$\mathbf{a}_i^T \mathbf{a}_j = \begin{cases} 1 & i = j, \quad i, j = 1, \dots, N \\ 0 & i \neq j, \quad i, j = 1, \dots, N \end{cases}$$

$$\mathbf{A}^T \mathbf{A} = \mathbf{I}$$

正变换，逆变换定义：

$$\mathbf{y} = \mathbf{A}^T \mathbf{x}$$

$$\mathbf{x} = \mathbf{A} \mathbf{y} = \sum_{n=1}^N y_n \mathbf{a}_n$$

当保留全部 y_n ， x 可无失真恢复，为了达到数据压缩目的，仅保留 y 能量较大的 M 各分量 $y_1, \dots, y_M$ ，其他分量用预选常数 $b_{M+1}, \dots, b_N$ 代替，



恢复出来的信号

$$\hat{\mathbf{x}} = \sum_{n=1}^M y_n \mathbf{a}_n + \sum_{n=M+1}^N b_n \mathbf{a}_n$$

造成的误差为

$$\Delta \mathbf{x} = \mathbf{x} - \hat{\mathbf{x}} = \sum_{n=M+1}^N (y_n - b_n) \mathbf{a}_n$$

数据重构的均方误差

$$E[\|\Delta \mathbf{x}\|^2] = E\left[\sum_{n=M+1}^N (y_n - b_n)^2 \mathbf{a}_n^T \mathbf{a}_n\right] = \sum_{n=M+1}^N E[(y_n - b_n)^2]$$

首先考虑参数 $b_{M+1}, \dots, b_N$ ，令偏导数等于 0 可得到方程组：

$$\frac{\partial E[\|\Delta \mathbf{x}\|^2]}{\partial b_n} = -2E[y_n - b_n] = 0$$

b_n 是常数，由上式得

$$b_n = E[y_n]$$

根据变换定义有

$$y_n = \mathbf{a}_n^T \mathbf{x}$$

于是

$$b_n = E[y_n] = E[\mathbf{a}_n^T \mathbf{x}] = \mathbf{a}_n^T E[\mathbf{x}] = \mathbf{a}_n^T \bar{\mathbf{x}}$$



最佳参数b下的均方误差为

$$\begin{aligned} E[\|\Delta \mathbf{x}\|^2] &= \sum_{n=M+1}^N E[(y_n - \mathbf{a}_n^T \bar{\mathbf{x}})^2] \\ &= \sum_{n=M+1}^N E[(\mathbf{a}_n^T \mathbf{x} - \mathbf{a}_n^T \bar{\mathbf{x}})^2] \\ &= \sum_{n=M+1}^N E[(\mathbf{a}_n^T (\mathbf{x} - \bar{\mathbf{x}}))^2] \\ &= \sum_{n=M+1}^N E[\mathbf{a}_n^T (\mathbf{x} - \bar{\mathbf{x}})(\mathbf{x} - \bar{\mathbf{x}})^T \mathbf{a}_n] \\ &= \sum_{n=M+1}^N \mathbf{a}_n^T E[(\mathbf{x} - \bar{\mathbf{x}})(\mathbf{x} - \bar{\mathbf{x}})^T] \mathbf{a}_n \\ &= \sum_{n=M+1}^N \mathbf{a}_n^T \mathbf{C}_x \mathbf{a}_n \end{aligned}$$

接下来考虑 $\{\mathbf{a}_n\}$ 的选取，不仅要使得误差最小，还要满足归一化正交条件，定义解的搜索空间为闭空间 $\mathbf{a}_n^T \mathbf{a}_n \leq 1$ 。把约束条件重写为

$$1 - \mathbf{a}_n^T \mathbf{a}_n = 0$$

拉格朗日乘子法是求解约束优化问题的常用方法，这里用拉格朗日乘子法求解归一化约束下的最小均方误差问题，定义如下目标函数

$$J(\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_N) = \sum_{n=M+1}^N \mathbf{a}_n^T \mathbf{C}_x \mathbf{a}_n + (1 - \mathbf{a}_n^T \mathbf{a}_n)$$

上式目标函数是凸函数，同时搜索空间是凸集，因此该优化问题是凸优化问题，具有唯一全集最优解，该最优解在梯度为零的位置。建立方程

$$J(a_1, a_2, \dots, a_N) = \sum_{n=M+1}^N a_n^T C_x a_n + \beta_n (1 - a_n^T a_n)$$


建立方程

$$\frac{\partial J(\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_N)}{\partial \mathbf{a}_n} = 2\mathbf{C}_x \mathbf{a}_n - 2\beta_n \mathbf{a}_n = 0$$

解为：

$$\mathbf{C}_x \mathbf{a}_n = \beta_n \mathbf{a}_n, \quad n = M+1, \dots, N$$

使上式成立的条件是 $\mathbf{a}_n$ 为 $\mathbf{C}_x$ 的特征向量， β_n 为其对于的特征值。实际应用中 $\mathbf{C}_x$ 预先知道，对 $\mathbf{C}_x$ 进行特征值分解得到特征值 $\{\lambda_1, \lambda_2, \dots, \lambda_N\}$ 和特征向量 $\{\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_N\}$ 。假设 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_N$ 。取 $\{\mathbf{a}_{M+1}, \dots, \mathbf{a}_N\}$ 为 $\mathbf{C}_x$ 最小的 $N-M$ 个特征值对于的特征向量，得到数据压缩后的最小均方误差为：

$$E[\|\Delta \mathbf{x}\|^2] = \sum_{n=M+1}^N \mathbf{q}_n^T \mathbf{C}_x \mathbf{q}_n = \sum_{n=M+1}^N \lambda_n$$



正交线性变换特点

1. 由已知的协方差矩阵直接计算。
2. 误差由特征值确定，误差控制非常简便

一般化正交变换：Karhunen-Loeve变换，利用特征分解方法进行变换
属于酉变换的一种

$$X_t = \sum_{k=1}^{\infty} Z_k e_k(t)$$

相互正交的确定性函数

相互独立的随机变量

平稳随机信号

随机信号线性模型

- 确定信号模型与随机信号模型
 - In deterministic models, the output of the model is fully determined by the parameter values and the initial conditions.
 - Stochastic models possess some inherent randomness. The same set of parameter values and initial conditions will lead to an ensemble of different outputs.
 - Obviously, the natural world is buffeted by stochasticity. But, stochastic models are considerably more complicated.



随机信号线性模型



将滤波器(线性变换)作用于随机信号，可改变随机信号的统计量。在实际中需要反映信号变化规律的模型，即通过该模型产生随机信号

这种方法的好处是信号统计特性由系统参数确定，不需记录整个自相关序列（或功率谱），只需知道系统参数就可以描述信号。

模型：指代那些用于解释和描述隐含规律的假设，而隐含规律用于控制和约束物理数据的产生。

$$\left(\begin{array}{c} \text{present value} \\ \text{of model output} \end{array} \right) + \left(\begin{array}{c} \text{linear combination} \\ \text{of past values} \\ \text{of model output} \end{array} \right) = \left(\begin{array}{c} \text{linear combination of} \\ \text{present and past values} \\ \text{of model input} \end{array} \right).$$

随机信号线性模型



对随机信号的描述变成一个参数估计问题：系统参数（滤波器阶数和滤波器系数）

三种典型的随机线性模型：

- 1) 自回归模型(AR)
- 2) 滑动平均模型 (MA)
- 3) 自回归滑动平均模型 (ARMA)

随机信号线性模型

自回归模型（AR）

如果时间序列 $u(n), u(n-1) \dots u(n-M)$ 满足差分方程：

$$u(n) + a_1^* u(n-1) + \dots + a_M^* u(n-M) = v(n)$$

则称该序列实现了M阶自回归（AR, autoregressive），或可写为：

$$u(n) = w_1^* u(n-1) + w_2^* u(n-2) + \dots + w_M^* u(n-M) + v(n)$$

过程的当前值是有限的过去值的线性组合，再加上一个误差项
反应了自变量 y 与一组独立变量 x 加上误差项之间的线性模型


$$y = \sum_{k=1}^M w_k^* x_k + v$$

即自回归，在其自身的过去值上回归




随机信号线性模型

自回归模型 (AR)



(a) 编码器



(b) 译码器

$$x_e(k) = \sum_{i=1}^N a_i x_r(k-i)$$

$$d_q(k) \approx d(k) = x(k) - x_e(k) \approx x_r(k) - \sum_{i=1}^N a_i x_r(k-i)$$

$$d_q(k) \Leftrightarrow D_q(Z), \quad x_r(k) \Leftrightarrow X_r(Z)$$

$$H(Z) = \frac{X_r(Z)}{D_q(Z)} = \frac{1}{1 - \sum_{i=1}^N a_i Z^{-i}}$$


随机信号线性模型

滑动平均模型 (MA)

滤波器输出端所产生的过程 $u(n)$ 可被描述为:


$$u(n) = v(n) + b_1^* v(n-1) + \cdots + b_K^* v(n-K)$$

如果给定了 $v(n)$ 的一个实现, 可通过样本值 $v(n), v(n-1) \dots v(n-K)$ 的加权平均来计算 $u(n)$



随机信号线性模型

滑动平均模型 (MA)



$$x_e(k) = \sum_{i=1}^M b_i d_q(k-i)$$

$$x_r(k) = x_e(k) + d_q(k) = \sum_{i=1}^M b_i d_q(k-i) + d_q(k)$$

$$X_r(D) = \sum_{i=1}^M b_i Z^{-i} D_q(Z) + D_q(Z)$$

$$H(Z) = \frac{X_r(Z)}{D_q(Z)} = 1 + \sum_{i=1}^M b_i Z^{-i}$$

随机信号线性模型

自回归滑动平均模型（ARMA）

给定白噪声 $v(n)$ 作为滤波器输入，产生ARMA的过程可表示为：

$$u(n) + a_1^* u(n-1) + \cdots + a_M^* u(n-M) = v(n) + b_1^* v(n-1) + \cdots + b_K^* v(n-K)$$


同时含有零点和极点转移函数

滑动平均模型与自回归模型是ARMA模型的典型



随机信号线性模型

自回归滑动平均模型 (ARMA)



$$x_e(k) = \sum_{i=1}^N a_i x_r(k-i) + \sum_{i=1}^M b_i d_q(k-i)$$

$$x_r(k) = x_e(k) + d_q(k) = \sum_{i=1}^N a_i x_r(k-i) + \sum_{i=1}^M b_i d_q(k-i) + d_q(k)$$

$$X_r(Z) = \sum_{i=1}^N a_i Z^{-i} X_r(Z) + \sum_{i=1}^M b_i Z^{-i} D_q(Z) + D_q(Z) = X_r(Z) \sum_{i=1}^N a_i Z^{-i} + D_q(Z) \left(\sum_{i=1}^M b_i Z^{-i} + 1 \right)$$

$$H(Z) = \frac{X_r(Z)}{D_q(Z)} = \frac{1 + \sum_{i=1}^M b_i Z^{-i}}{1 - \sum_{i=1}^N a_i Z^{-i}}$$

随机信号线性模型

3种不同模型:

全零点模型
滑动平均模型 (Moving Average)
MA (Q)

$$x(n) = \sum_{k=0}^Q d_k w(n-k)$$

$$H(z) = \sum_{k=0}^Q d_k z^{-k}$$

$$x(n) = -\sum_{k=1}^P a_k x(n-k) + w(n)$$

$$H(z) = \frac{1}{1 + \sum_{k=1}^P a_k z^{-k}}$$

$$x(n) = \sum_{k=1}^P a_k x(n-k) + \sum_{k=0}^Q d_k w(n-k)$$

$$H(z) = \frac{1 + \sum_{k=1}^Q d_k z^{-k}}{1 + \sum_{k=1}^P a_k z^{-k}}$$

全极点模型
自回归模型 (Autoregressive)
AR (P)

零极点模型
自回归滑动均模型
ARMA (P, Q)

随机信号全极点模型

$$x(n) = -\sum_{k=1}^P a_k x(n-k) + w(n)$$

$$H(z) = \frac{1}{1 + \sum_{k=1}^P a_k z^{-k}}$$

冲激响应

$$w(n) = \delta(n)$$

$$h(0) = \sum_{k=1}^P -a_k x(-k) + 1 = 1$$

$$h(1) = -\sum_{k=1}^P a_k x(1-k) = a_1 x(0) = a_1$$

.....

$$h(n) = -\sum_{k=1}^P a_k x(n-k), \quad n > 0$$

随机信号全极点模型:模型参数求解

Yule-Walker方程

$$x(n) = -\sum_{k=1}^L a_k x(n-k) + w(n)$$

自相关函数

$$E[x(n-m)x(n)] = E\left\{x(n-m)\left[-\sum_{k=1}^L a_k x(n-k) + w(n)\right]\right\}$$



$$E[x(n-m)w(n)] = \begin{cases} 0 & m > 0 \\ \sigma_w^2 & m = 0 \end{cases}$$

$$R_x(m) = -\sum_{k=1}^L a_k E[x(n-m)x(n-k)] + \sigma_w^2 \delta(m)$$

$$R_x(m) = -\sum_{k=1}^L a_k R_x(m-k) + \sigma_w^2 \delta(m)$$

$R_x = E[x(n+m)x(n)]$ 结果如何?

随机信号全极点模型:模型参数求解

$$R_x(m) = -\sum_{k=1}^P a_k R_x(m-k) + \sigma_w^2 \delta(m)$$

Yule-Walker方程的矩阵形式

$$m=0 \quad R_x(0) + a_1 R_x(1) + \cdots + a_P R_x(-P) = \sigma_w^2$$

$$\begin{bmatrix} R_x(0) & R_x(-1) & \cdots & R_x(-P) \end{bmatrix} \begin{bmatrix} 1 \\ a_1 \\ \vdots \\ a_P \end{bmatrix} = \sigma_w^2$$

$$m=1 \quad R_x(1) + a_1 R_x(0) + \cdots + a_P R_x(-P+1) = 0$$

$$\begin{bmatrix} R_x(1) & R_x(0) & \cdots & R_x(-P+1) \end{bmatrix} \begin{bmatrix} 1 \\ a_1 \\ \vdots \\ a_P \end{bmatrix} = 0$$

$$\begin{matrix} m=0 \\ \vdots \\ m=P \end{matrix} \begin{bmatrix} R_x(0) & R_x(-1) & \cdots & R_x(-P) \\ R_x(1) & R_x(0) & \cdots & R_x(-P+1) \\ \vdots & \vdots & \ddots & \vdots \\ R_x(P) & R_x(P-1) & \cdots & R_x(0) \end{bmatrix} \begin{bmatrix} 1 \\ a_1 \\ \vdots \\ a_P \end{bmatrix} = \begin{bmatrix} \sigma_w^2 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

Yule-Walker方程的矩阵形式

对实信号，自相关函数为偶对称

$$\begin{bmatrix} R_x(0) & R_x(1) & \cdots & R_x(P) \\ R_x(1) & R_x(0) & \cdots & R_x(P-1) \\ \vdots & \vdots & \ddots & \vdots \\ R_x(P) & R_x(P-1) & \cdots & R_x(0) \end{bmatrix} \begin{bmatrix} 1 \\ a_1 \\ \vdots \\ a_P \end{bmatrix} = \begin{bmatrix} \sigma_w^2 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

对复信号，自相关函数为共轭对称

$$\begin{bmatrix} R_x(0) & R_x^*(1) & \cdots & R_x^*(P) \\ R_x(1) & R_x(0) & \cdots & R_x^*(P-1) \\ \vdots & \vdots & \ddots & \vdots \\ R_x(P) & R_x(P-1) & \cdots & R_x(0) \end{bmatrix} \begin{bmatrix} 1 \\ a_1 \\ \vdots \\ a_P \end{bmatrix} = \begin{bmatrix} \sigma_w^2 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

P个线性方程，P个未知数



Yule-Walker方程的其他形式

去掉第一行

$$\begin{bmatrix} R_x(1) & R_x(0) & \cdots & R(P-1) \\ \vdots & \vdots & \ddots & \vdots \\ R_x(P) & R_x(P-1) & \cdots & R(0) \end{bmatrix} \begin{bmatrix} 1 \\ a_1 \\ \vdots \\ a_P \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$$

$$\begin{bmatrix} R_x(1) \\ \vdots \\ R_x(P) \end{bmatrix} + \begin{bmatrix} R_x(0) & \cdots & R(P-1) \\ \vdots & \ddots & \vdots \\ R_x(P-1) & \cdots & R(0) \end{bmatrix} \begin{bmatrix} a_1 \\ \vdots \\ a_P \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$$

$$\begin{bmatrix} R_x(0) & \cdots & R(P-1) \\ \vdots & \ddots & \vdots \\ R_x(P-1) & \cdots & R(0) \end{bmatrix} \begin{bmatrix} a_1 \\ \vdots \\ a_P \end{bmatrix} = - \begin{bmatrix} R_x(1) \\ \vdots \\ R_x(P) \end{bmatrix}$$

✓直接解线性方程组

✓只包含模型参数

关于全极点模型

- ◆用自相关函数估计结果的 $P+1$ 个数值，可求解出模型参数，并且是唯一解
- ◆由自相关函数的 $P+1$ 个数值得到模型参数，再一步可得到自相关函数在其他时刻的取值，可实现对自相关函数（功率）的高分辨率估计
- ◆模型可解的前提是自相关矩阵满秩
- ◆如果自相关矩阵满秩（正定），利用Yule-Walker方程求解的模型为最小相位系统
- ◆基于Yule-Walker方程求解模型参数的缺陷：
 - ◆需要知道模型阶数，实际中阶数往往是未知的
 - ◆需要矩阵求逆运算，计算量较大



AR(1) 模型举例

求AR(1)模型 $x(n) = ax(n-1) + u(n)$ 的自相关函数。

解：由AR模型的Yule-Walker方程可知

$$\phi_x(m) = -\varphi_1\phi_x(m-1) + \sigma^2\delta(m) = a\phi_x(m-1) + \sigma^2\delta(m)$$

取 $m = 0, 1$ 有：

$$\phi_x(0) = a\phi_x(1) + \sigma^2, \quad \phi_x(1) = \phi_x(0)a,$$

解此方程组得：

$$\phi_x(0) = \frac{\sigma^2}{1 - a^2}$$

当 $m \geq 1$ 时有：

$$\phi_x(m) = a\phi_x(m-1)$$

可以得到：

$$\phi_x(m) = \frac{a^m}{1 - a^2}\sigma^2$$


AR(1) 模型举例

$$X_t = aX_{t-1} + \varepsilon_t, \quad t \in \mathbb{Z}$$
$$\{\varepsilon_t\} \sim \text{WN}(0, \sigma^2)$$


$$\gamma_0 = \sigma^2 \sum_{j=0}^{\infty} a^{2j} = \frac{\sigma^2}{1 - a^2}$$

$$\gamma_k = a\gamma_{k-1} = \cdots = a^k \gamma_0, \quad k \geq 1$$


AR(1): a = 0.85




ACF of AR(1): a = 0.85




AR(1): a = -0.85



ACF of AR(1): a = -0.85



AR(1) 模型举例



AR(1)正负系数的比较

	$a = 0.85$	$a = -0.85$
(1)	数据表现出趋势性, 相邻的数据差别不大;	数据上下摆动, 趋势性不明显;
(2)	(1)中的现象在 $\{\rho_k\}$ 得到体现: 相邻随机变量正相关	(1)中的现象在 $\{\rho_k\}$ 得到体现: 相邻随机变量负相关
(3)	ρ_k 单调减少趋于0	(3) ρ_k 正负交替 趋于0
(4)	谱密度的能量集中在低频, $f(\lambda) < f(0), \lambda \in (0, \pi]$, 数据无周期现象, 周期 $T = \frac{2\pi}{0} = \infty$	谱密度能量集中在高频, $f(\lambda) < f(\pi), \lambda \in [0, \pi)$, 数据有周期现象, 周期 $T = \frac{2\pi}{\pi} = 2$

随机信号全零点模型

$$x(n) = \sum_{k=0}^Q d_k w(n-k)$$

$$H(z) = \sum_{k=0}^L d_k z^{-k}$$

冲激响应

$$h(n) = \begin{cases} d_n & 0 \leq n \leq Q \\ 0 & \text{otherwise} \end{cases}$$



随机信号全零点模型

Yule-Worker方程

$$\begin{aligned}x(n) &= \sum_{k=0}^Q d_k w(n-k) \\x(n)x(n-l) &= \sum_{k=0}^Q d_k w(n-k) x(n-l) \\&= \sum_{k=0}^Q d_k w(n-k) \sum_{i=0}^Q d_i w(n-l-i) \\&= \sum_{k=0}^Q \sum_{i=0}^Q d_k d_i w(n-k) w(n-l-i)\end{aligned}$$

$$R_x(l) = \sigma_w^2 \sum_{k=0}^Q \sum_{i=0}^Q d_k d_i \delta(-k + l + i)$$

求和项只在 $i=k-l$ 时
不等于0

$$R_x(l) = \sigma_w^2 \sum_{k=0}^Q d_k d_{k-l}$$

基于冲激响应的自相关可推导出类似结果

随机信号全零点模型

Yule-Worker方程

$$R_x(l) = \begin{cases} \sigma_w^2 \sum_{k=0}^Q d_k d_{k-l} & 0 \leq l \leq Q \\ 0 & otherwise \end{cases}$$

$$R_x(-l) = R_x^*(l)$$

自相关序列单边长度等于冲激响应长度，——当模型输出的间隔大于Q，不包含共同的输入成分，因此不相关

从自相关函数出发求解模型参数时，全零点模型涉及非线性方程，比全极点模型复杂，没有统一的方法，只在低阶模型时才能得到闭式解。如下例：



随机信号全零点模型

Yule-Worker 方程

例如：

$$y(t) = \mu_0 \varepsilon(t) + \mu_1 \varepsilon(t-1) + \cdots + \mu_q \varepsilon(t-q)$$

$$\gamma_\tau = E(y_t y_{t-\tau})$$

$$= E\left\{ \sum_i \mu_i \varepsilon_{t-i} \sum_j \mu_j \varepsilon_{t-\tau-j} \right\}$$

$$= \sum_i \sum_j \mu_i \mu_j E(\varepsilon_{t-i} \varepsilon_{t-\tau-j}).$$

$$\leftarrow E(\varepsilon_{t-i} \varepsilon_{t-\tau-j}) = \begin{cases} 0, & \text{if } i \neq \tau + j; \\ \sigma_\varepsilon^2, & \text{if } i = \tau + j. \end{cases}$$



$$\gamma_\tau = \sigma_\varepsilon^2 \sum_j \mu_j \mu_{j+\tau}.$$



$$\tau = 0, 1, \dots, q.$$

$$\gamma_0 = \sigma_\varepsilon^2 (\mu_0^2 + \mu_1^2 + \cdots + \mu_q^2),$$

$$\gamma_1 = \sigma_\varepsilon^2 (\mu_0 \mu_1 + \mu_1 \mu_2 + \cdots + \mu_{q-1} \mu_q),$$

$$\vdots$$

$$\gamma_q = \sigma_\varepsilon^2 \mu_0 \mu_q.$$

$$\gamma_\tau = 0 \text{ for all } \tau > q.$$

随机信号全零点模型—低阶模型

一阶模型

$$y(t) = \varepsilon(t) - \theta \varepsilon(t-1)$$

自相关函数

$$\begin{aligned}\gamma_0 &= \sigma_\varepsilon^2(1 + \theta^2), \\ \gamma_1 &= -\sigma_\varepsilon^2\theta, \\ \gamma_\tau &= 0 \quad \text{if } \tau > 1.\end{aligned}$$

对于观察值序列: $y = [y_1, y_2, \dots, y_T]'$

自相关函数构成一个离差矩阵 (dispersion matrix)

$$D(y) = \sigma_\varepsilon^2 \begin{bmatrix} 1 + \theta^2 & -\theta & 0 & \dots & 0 \\ -\theta & 1 + \theta^2 & -\theta & \dots & 0 \\ 0 & -\theta & 1 + \theta^2 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 1 + \theta^2 \end{bmatrix}$$

随机信号零极点模型

$$\alpha_0 y_t + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} = \mu_0 \varepsilon_t + \mu_1 \varepsilon_{t-1} + \mu_2 \varepsilon_{t-2}.$$

两边同乘 y_t, y_{t-1}, y_{t-2} 并求期望

$$\begin{bmatrix} \gamma_0 & \gamma_1 & \gamma_2 \\ \gamma_1 & \gamma_0 & \gamma_1 \\ \gamma_2 & \gamma_1 & \gamma_0 \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} \delta_0 & \delta_1 & \delta_2 \\ 0 & \delta_0 & \delta_1 \\ 0 & 0 & \delta_0 \end{bmatrix} \begin{bmatrix} \mu_0 \\ \mu_1 \\ \mu_2 \end{bmatrix} \quad (1\text{式})$$

两边同乘 $\varepsilon_t, \varepsilon_{t-1}, \varepsilon_{t-2}$ 并求期望

$$\delta_{i-\tau} = E(y_{t-\tau} \varepsilon_{t-i})$$

$$\begin{bmatrix} \delta_0 & 0 & 0 \\ \delta_1 & \delta_0 & 0 \\ \delta_2 & \delta_1 & \delta_0 \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} \sigma_\varepsilon^2 & 0 & 0 \\ 0 & \sigma_\varepsilon^2 & 0 \\ 0 & 0 & \sigma_\varepsilon^2 \end{bmatrix} \begin{bmatrix} \mu_0 \\ \mu_1 \\ \mu_2 \end{bmatrix} \quad (2\text{式})$$

上式可被重写为：

$$\begin{bmatrix} \alpha_0 & 0 & 0 \\ \alpha_1 & \alpha_0 & 0 \\ \alpha_2 & \alpha_1 & \alpha_0 \end{bmatrix} \begin{bmatrix} \delta_0 \\ \delta_1 \\ \delta_2 \end{bmatrix} = \sigma_\varepsilon^2 \begin{bmatrix} \mu_0 \\ \mu_1 \\ \mu_2 \end{bmatrix} \quad (3\text{式})$$

上式在假设 $\alpha_0, \alpha_1, \alpha_2, \sigma_\varepsilon$ 已知的情况下可解

随机信号零极点模型

$$\alpha_0 y_t + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} = \mu_0 \varepsilon_t + \mu_1 \varepsilon_{t-1} + \mu_2 \varepsilon_{t-2}.$$

若有归一化处理: $\alpha_0 = \mu_0 = 1$, 并有 $\delta_0 = \sigma_\varepsilon^2$.

则有:

$$\begin{bmatrix} \gamma_0 & \gamma_1 & \gamma_2 \\ \gamma_1 & \gamma_0 & \gamma_1 \\ \gamma_2 & \gamma_1 & \gamma_0 \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} \delta_0 & \delta_1 & \delta_2 \\ 0 & \delta_0 & \delta_1 \\ 0 & 0 & \delta_0 \end{bmatrix} \begin{bmatrix} \mu_0 \\ \mu_1 \\ \mu_2 \end{bmatrix}$$



$$\begin{bmatrix} \alpha_0 & \alpha_1 & \alpha_2 \\ \alpha_1 & \alpha_0 + \alpha_2 & 0 \\ \alpha_2 & \alpha_1 & \alpha_0 \end{bmatrix} \begin{bmatrix} \gamma_0 \\ \gamma_1 \\ \gamma_2 \end{bmatrix} = \begin{bmatrix} \mu_0 & \mu_1 & \mu_2 \\ \mu_1 & \mu_2 & 0 \\ \mu_2 & 0 & 0 \end{bmatrix} \begin{bmatrix} \delta_0 \\ \delta_1 \\ \delta_2 \end{bmatrix}$$

当 $\tau > 2$ 时有

$$\alpha_0 \gamma_\tau + \alpha_1 \gamma_{\tau-1} + \alpha_2 \gamma_{\tau-2} = 0; \quad \tau > 2$$

若有 $\{\gamma_3, \gamma_4, \dots\}$ 并由上式求解 $\alpha_0, \alpha_1, \alpha_2$

Wold分解定理

Wold在1938年证明：任意平稳离散时间随机过程，都可被分解成两个互不相关的一般纯随机过程和可预测过程之和。即：

任一平稳离散时间随机过程过程 z_t 可表示为：

$$z_t = x_t + y_t$$

其中：

- 1) x_t 与 y_t 不相关；
- 2) x_t 是一个可预测过程，或称奇异过程。可以用其过去值描述其现在值；
- 3) y_t 是一个不可被预测的过程，或称正则过程。无法准确预测



Wold分解定理

奇异过程 x_t

- 1) 随机性不随时间变化。
- 2) 随着时间的发展，没有新的随机因素加入，过程所含信息量保持不变，不再提供任何新信息。
- 3) “可预测”过程，用过程的过去值对未来值进行预测时，能够实现一致性预测，即预测的均方误差能够趋于0

对于随机过程 x_t 考虑用 t 时刻之前的 p 个值的线性组合对 t 时刻的真值 x_t 进行线性预测：

$$x_t = \sum_{k=1}^p a_k x_{t-k} + e_t,$$



Wold分解定理

奇异过程 x_t

$$x_t = \sum_{k=1}^p a_k x_{t-k} + e_t,$$

其中， a_k 是常系数， e_t 是(预测)误差。如果预测的均方误差满足：

$$\lim_{p \rightarrow \infty} \left(x_t - \sum_{k=1}^p a_k x_{t-k} \right)^2 = 0,$$

则称过程 x_t 是可预测过程。

显然是一个 p 阶自回归差分方程，即： $AR(p)$

Wold分解定理

正则过程 y_t

- 1) 任意两个不同时刻的随机性不同
- 2) 任一时刻的下时刻，都有新信息加入
- 3) “不可预测”过程，即无法实现一致性预测

白噪声是典型的正则过程。对于任何分布的正则过程(不可预测过程)，总可以用白噪声的线性组合表示，则有：

$$y_t = u_t + \sum_{k=1}^q b_k u_{t-k},$$

$$E(u_t u_{t+k}) = 0, \forall k = \pm 1, \pm 2, \dots$$

是一个 q 阶滑动平均过程。即： $MA(q)$ 。

Wold分解定理

实际中的过程

1) 奇异过程(可预测过程)和正则过程(纯随机过程)是随机过程的两个极端。

2) 一般随机过程的随机性、可预测性介于奇异过程和正则过程之间。

因此，实际随机过程可以表示为：

$$x_t = \sum_{k=1}^p a_k x_{t-k} + e_t + \sum_{k=1}^q b_k u_{t-k},$$

是自回归-滑动平均过程，即：ARMA(p, q)。

